GOSIM

GOSIM Shenzhen 2026

面向端边云协同的异构数据通信框架

唐粲然——中国科学技术大学



CONTENTS

Part 01 典型机器人云边端协同推理架构

Part 02 DORA tensor-pool数据框架

Part 03 数据传输效果展示

Part 04 应用场景和未来工作

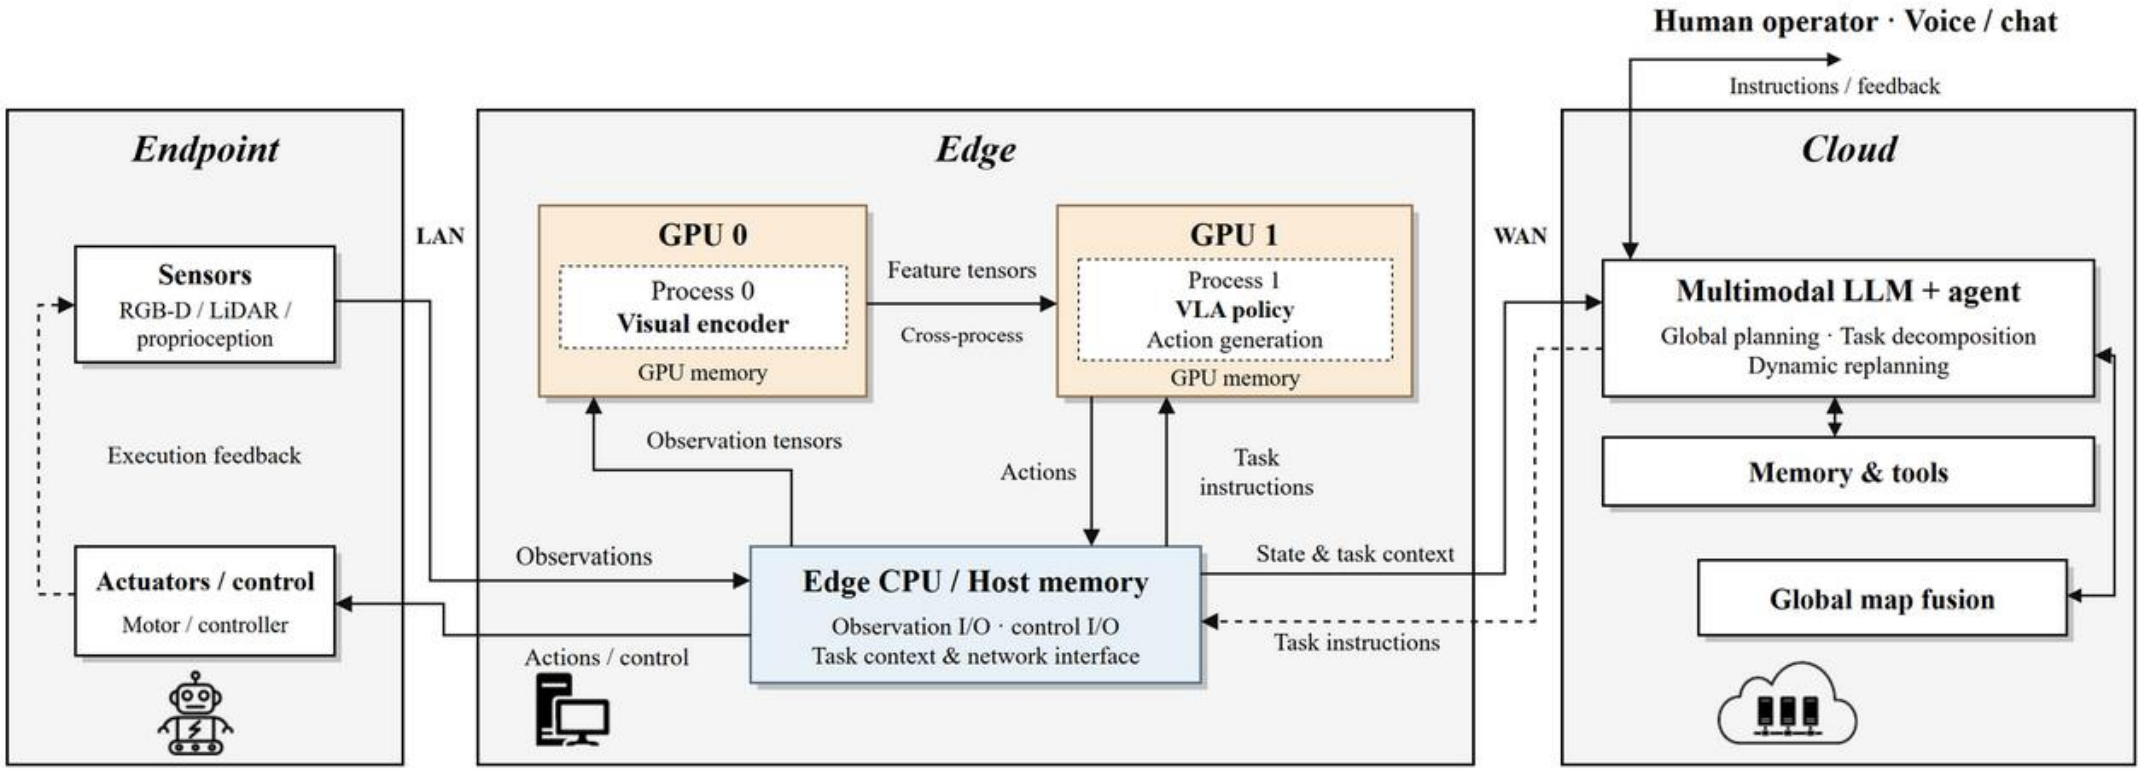


01

典型机器人云边端协同推理框架



面向机器人的 MLLM-VLA 云边端分层协同推理架构



机器人端侧负责感知与控制，边侧VLA负责实时策略推理，云侧多模态大模型（MLLM）负责全局规划。

机器人云边端分层推理的优势

单一 VLA 部署

局部观测与动作闭环



局限：缺少独立的任务分解与动态重规划
长时、多阶段任务的高层决策依赖单一 VLA

云边端分层部署

任务规划与动作执行协同



优势：云侧分解任务，并依据反馈动态重规划
边侧 VLA 专注动作生成，端侧保持及时控制

分层协同的意义：支持长时、多阶段任务的规划与重规划，同时保留端侧及时控制。

机器人云边端协同推理的数据面需求

01

异构计算

机器人系统中的GPU计算负载持续增长，然而现有机器人中间件通常仅能跨进程传递CPU数据，GPU数据需要通过CPU中转。

02

高频复用

机器人的连续推理中广泛存在形状、类型和大小稳定、仅数值变化的同源数据。我们希望为同源数据提前分配持久化缓冲区，从而避免反复分配、映射与释放。

03

跨进程资源管理

跨进程传递数据可以通过共享句柄零拷贝访问，但同时容易引发并发读写、访问一致性、资源回收等问题。

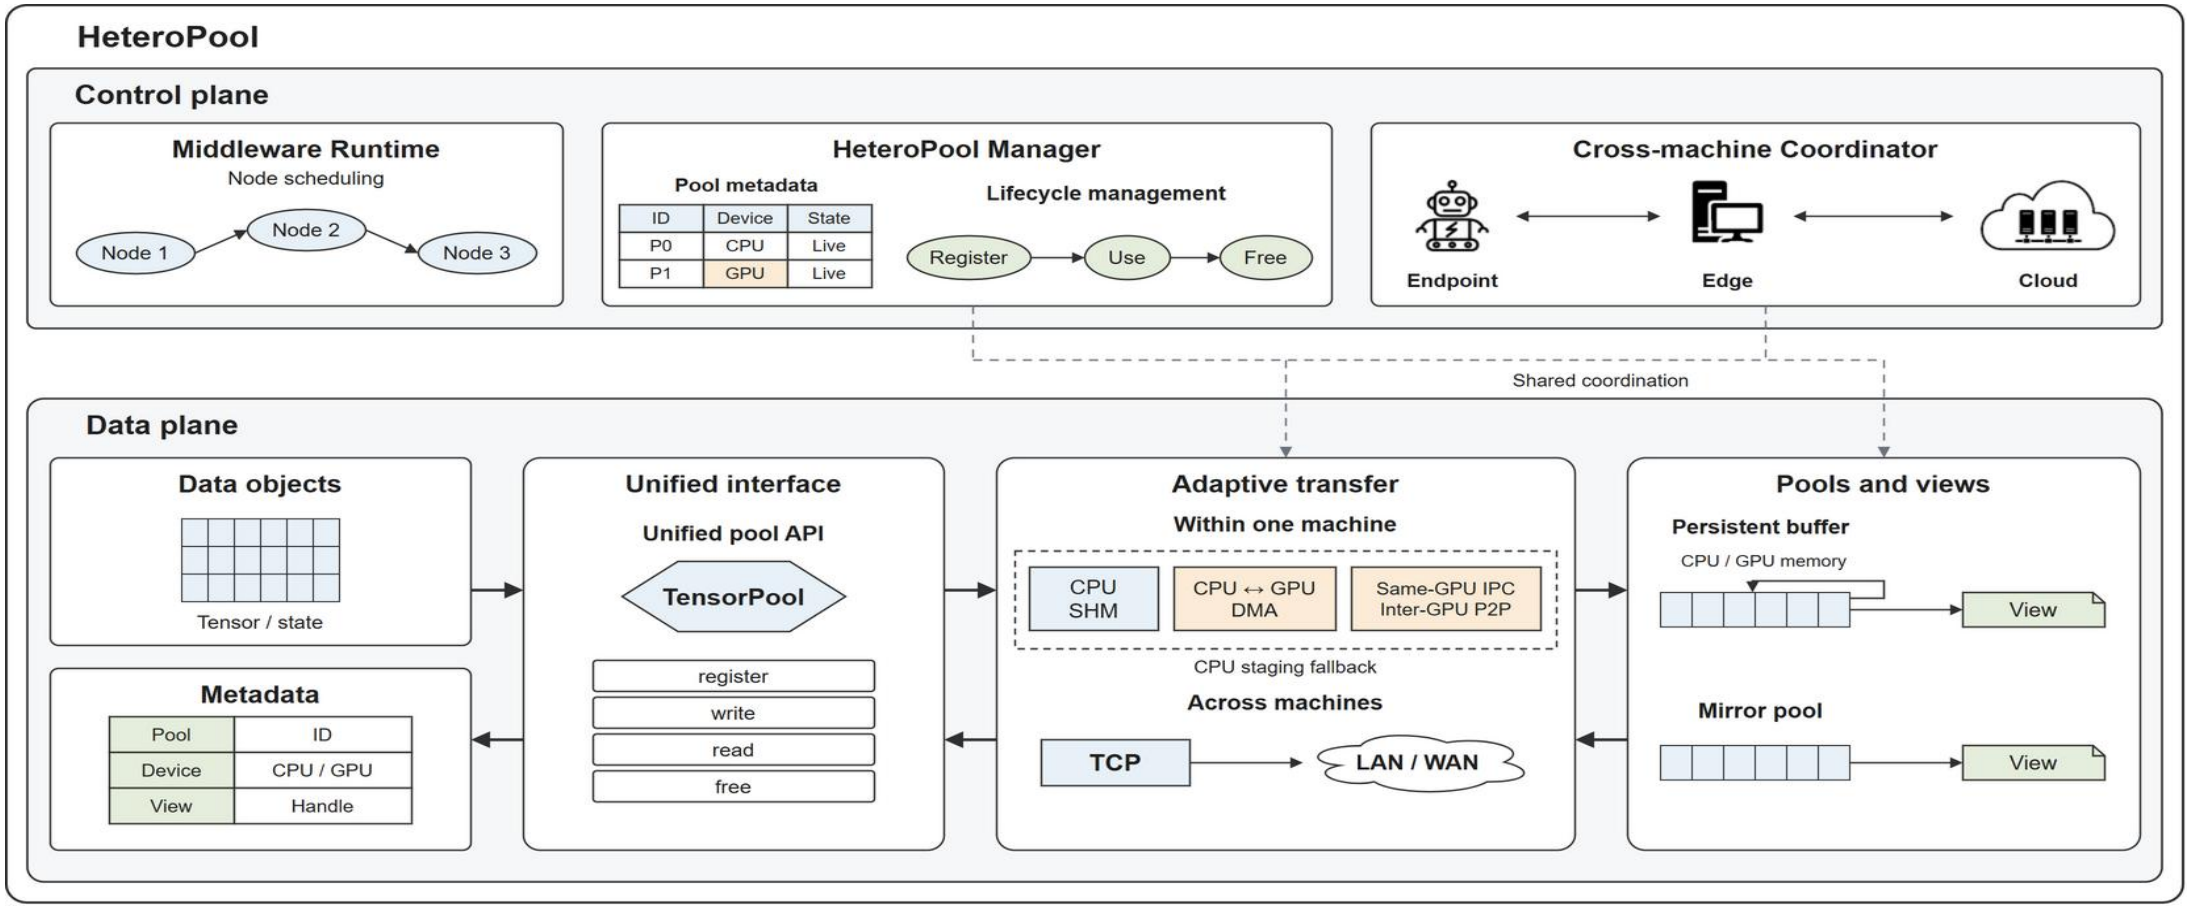
为解决端边云协同的这些需求，我为DORA开发了异构数据通信框架——tensor-pool

02

DORA tensor-pool数据框架

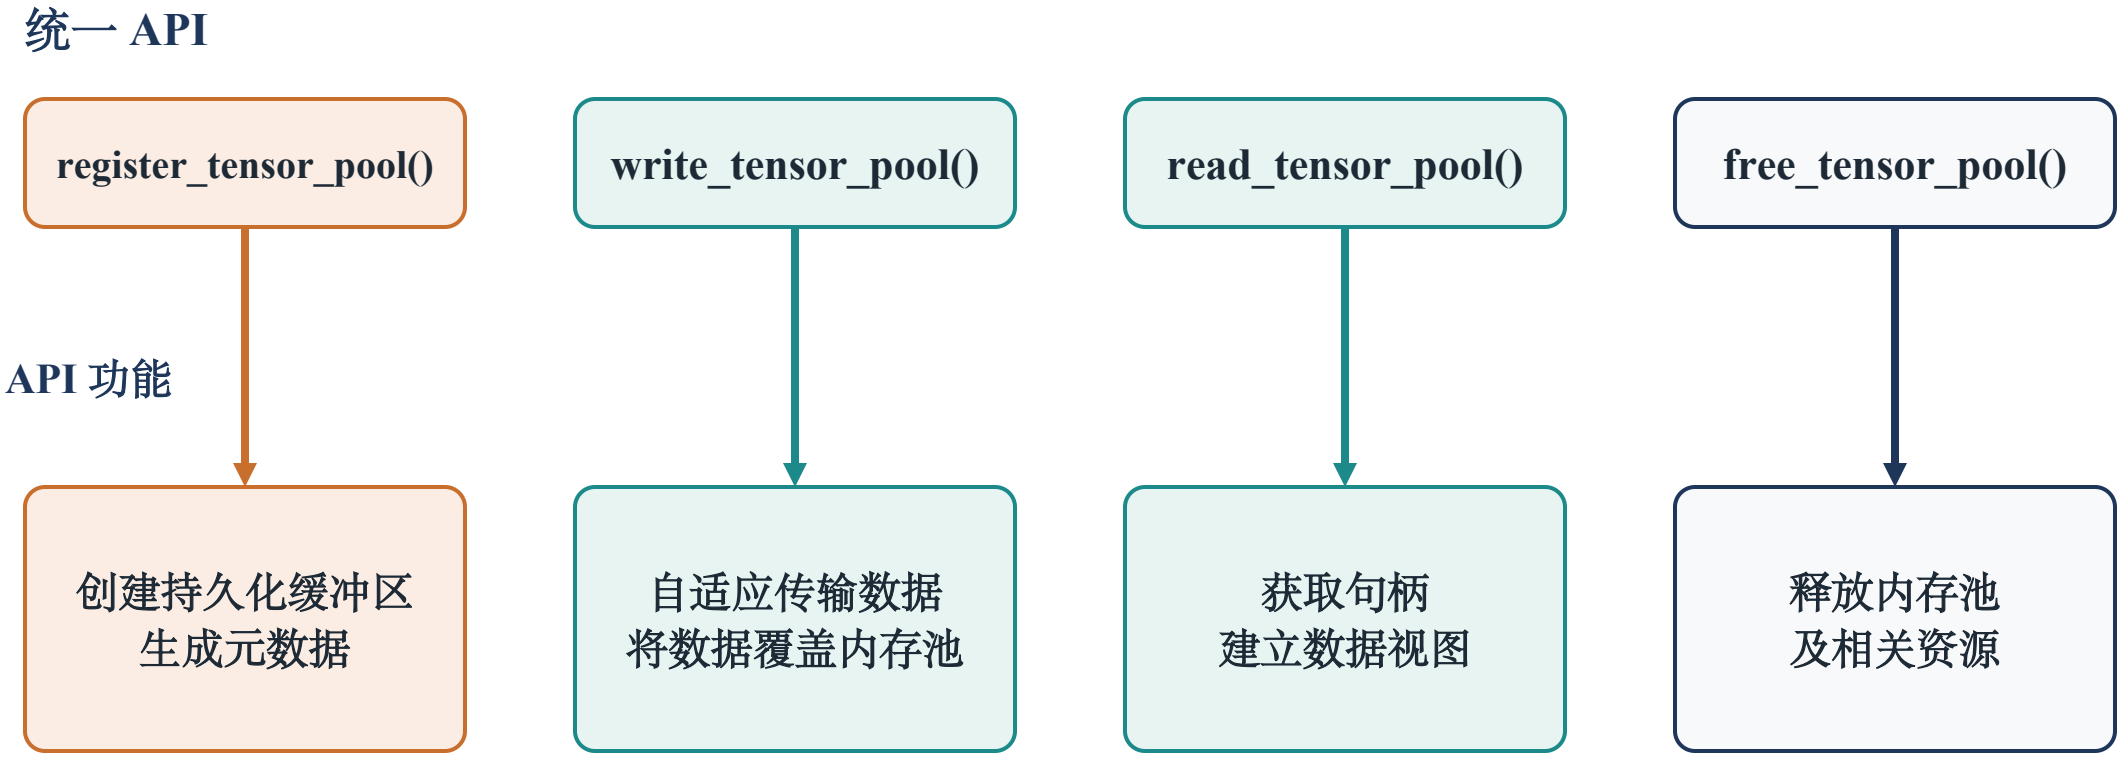


控制面协调全局生命周期，数据面承载高频传输



Editable source: figures/system overview.pptx

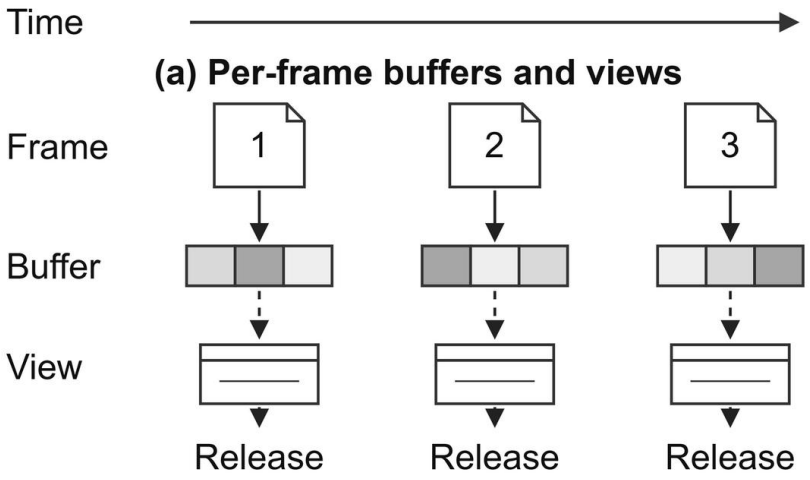
提供统一的API，建立跨进程、跨异构设备、跨机器的持久化内存池



通过建立持久化缓冲区与长期数据视图，减少同源数据逐帧开销

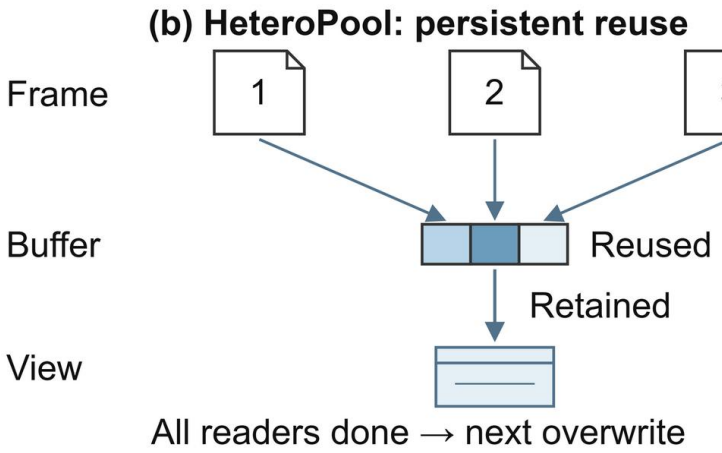
传统消息路径

每轮都分配、映射、传输、释放



HeteroPool

一次建立，持续更新



Memory pool layout

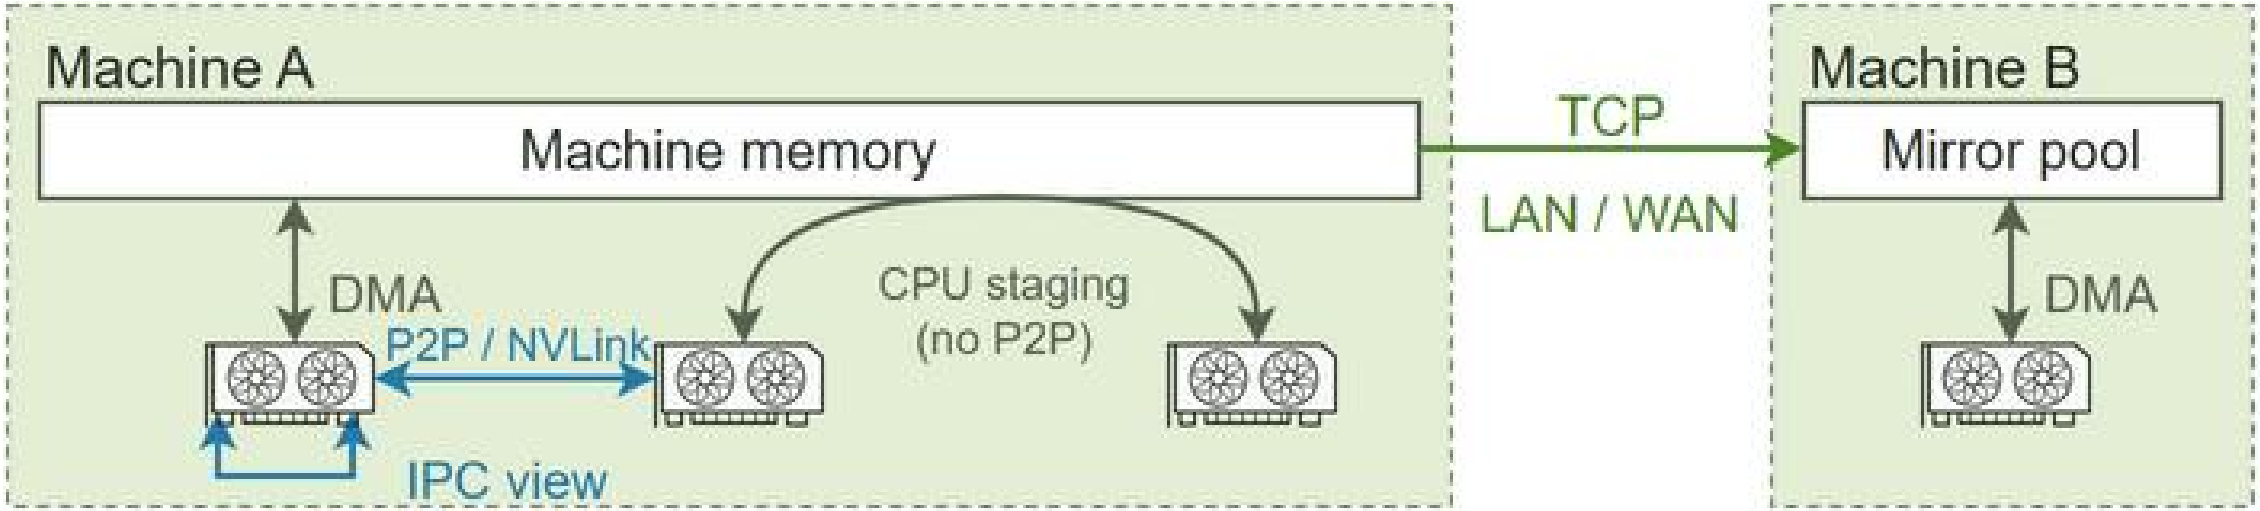
Offset (B)	Field	Size (B)
0	Magic	8
8	Metadata length	8
16	Payload offset	8
24	IPC flag	8
32	IPC handle	64
96	Write generation	8
104	Reserved	152
256	Metadata JSON size, dtype, shape, pinned_type	L
256 + L	Alignment padding	P
D	**Payload**	M

$D = 256 + L + P$

$P = (256 - L \bmod 256) \bmod 256$

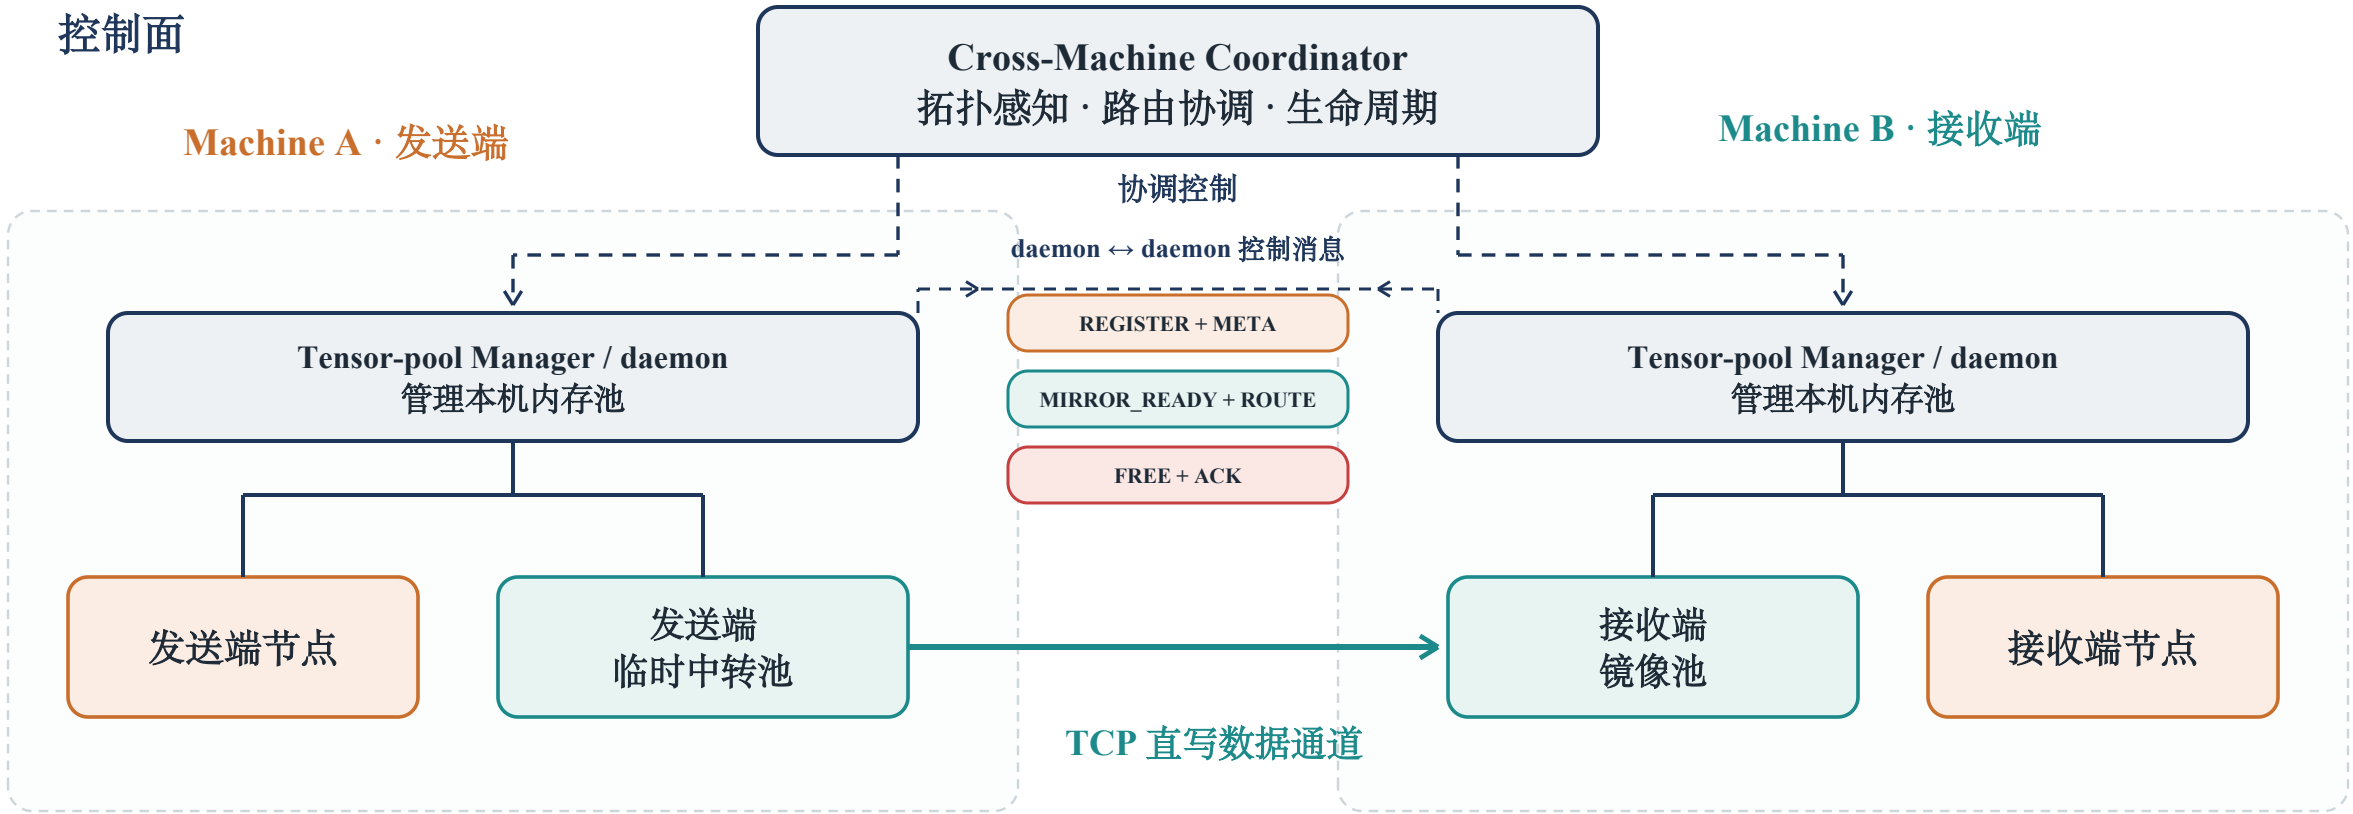
Offsets increase downward; not to scale.

数据位置决定传输路径，API 对上层保持透明



路径选择依据：内存域、设备能力、拓扑关系与节点部署边界。

跨机协调器统一管理两台机器的内存池



控制消息只携带池 ID、元数据与状态；大块张量直接写入目标镜像池。

内存池生命周期由 API 与全局确认协议驱动

01 注册与建视图

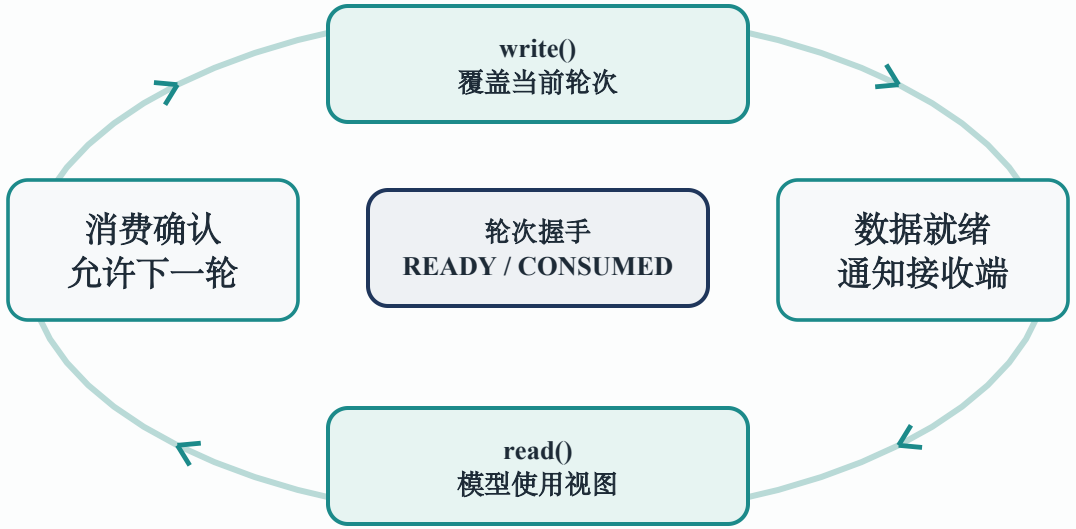
register()

创建持久化缓冲区
生成元数据

read()

导入共享句柄
建立长期数据视图

02 持续推理轮次



数据视图持续复用

03 释放与回收

free()

关键机制

通过全局释放确认协议
等待所有节点解除数据视图映射

回收共享句柄
内存池与镜像池

异常恢复：Manager 重启后扫描有效命名空间，清理已终止数据流的遗留资源。

Three takeaways

01	统一数据抽象	让 CPU、GPU 与跨机数据共享使用同一套内存池语义。
02	路径与拓扑匹配	让 API 隐藏通信差异，把直传能力交给数据面选择。
03	生命周期可协调	由控制面负责持久化视图、镜像池与异常清理



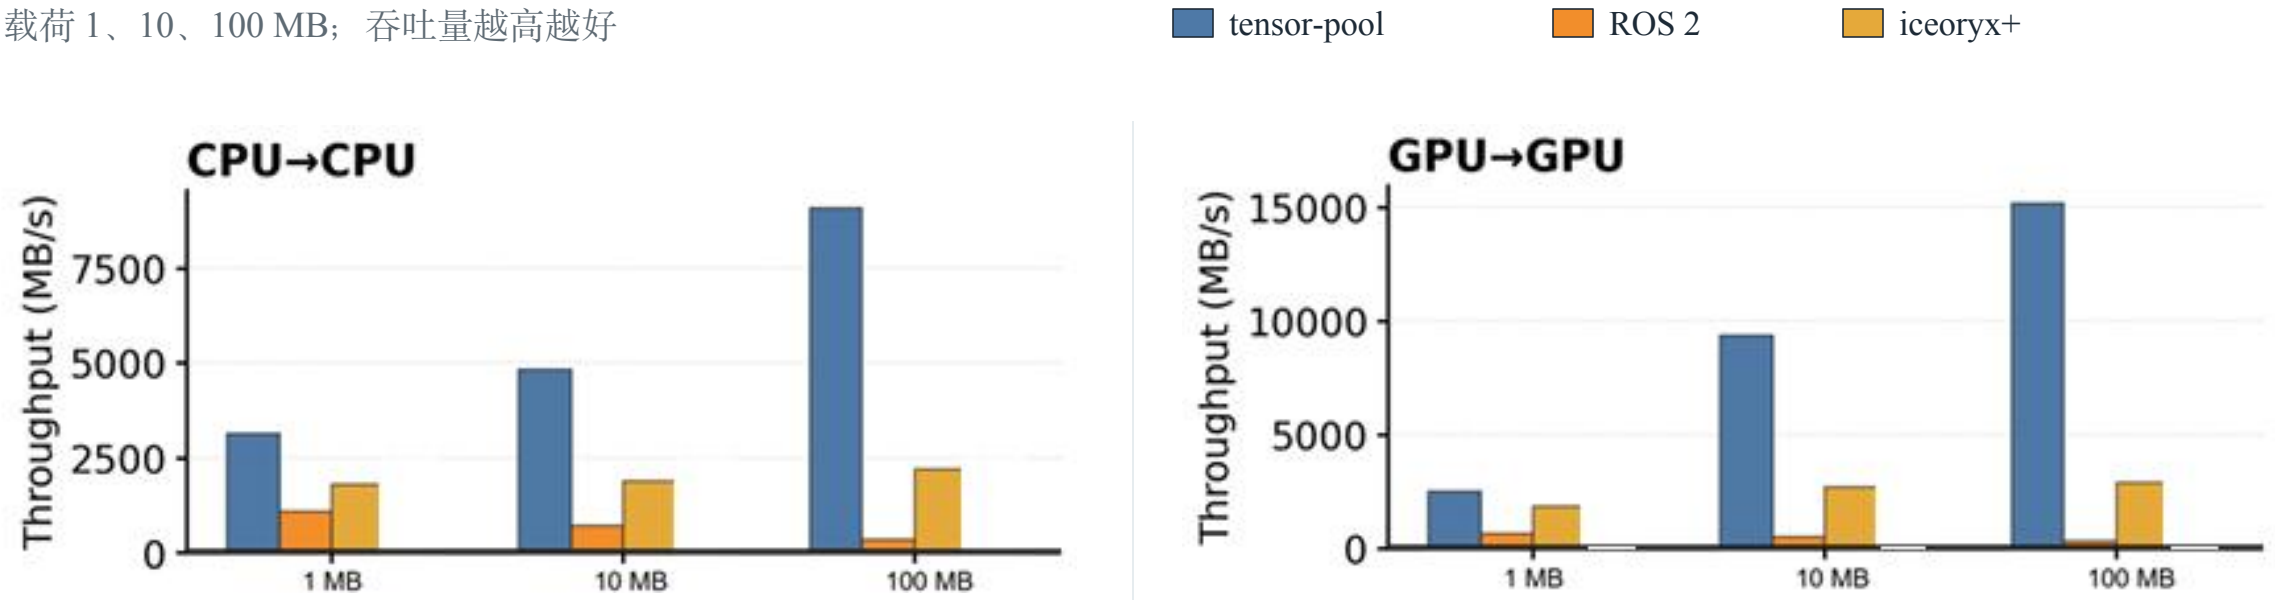
03

数据传输效果展示



同机纯传输测试：CPU 与 GPU 路径吞吐对比

载荷 1、10、100 MB；吞吐量越高越好



CPU→CPU

最高 25.87× ROS 2

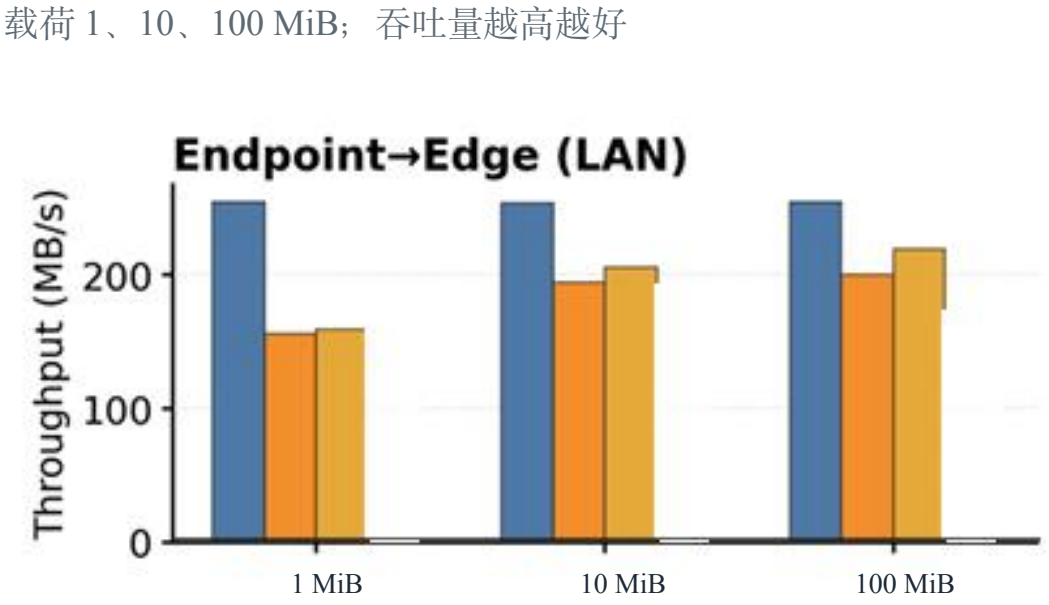
GPU→GPU

最高 52.56× ROS 2

数据来源：项目同机纯传输测试图；提升倍率见论文第 6.1 节。

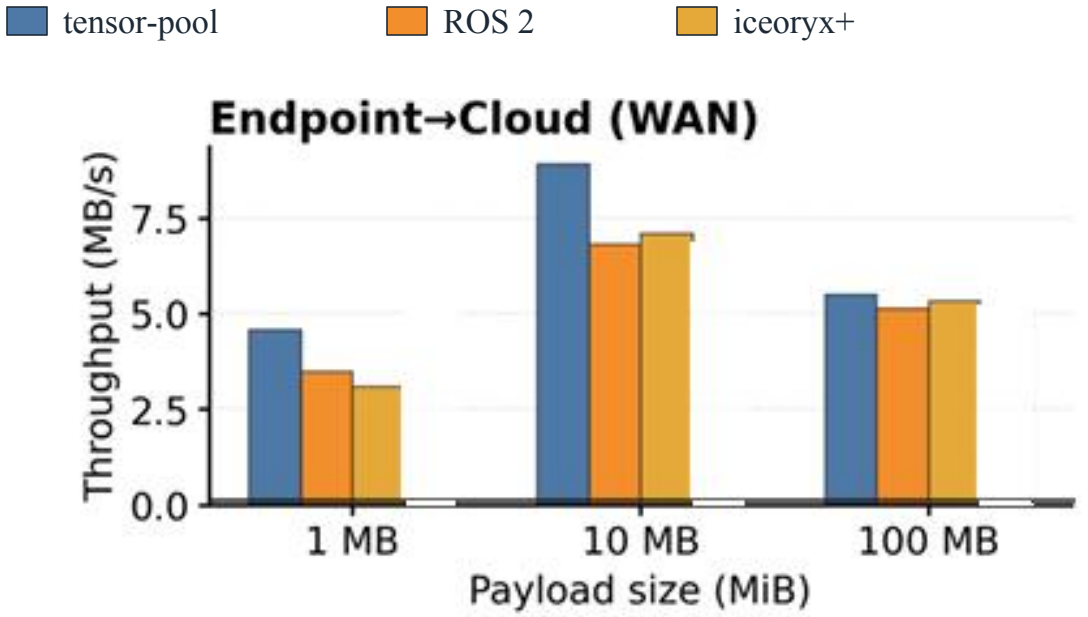
跨机纯传输测试：端边与端云路径吞吐对比

载荷 1、10、100 MiB；吞吐量越高越好



端边 LAN

最高 +63% / ROS 2



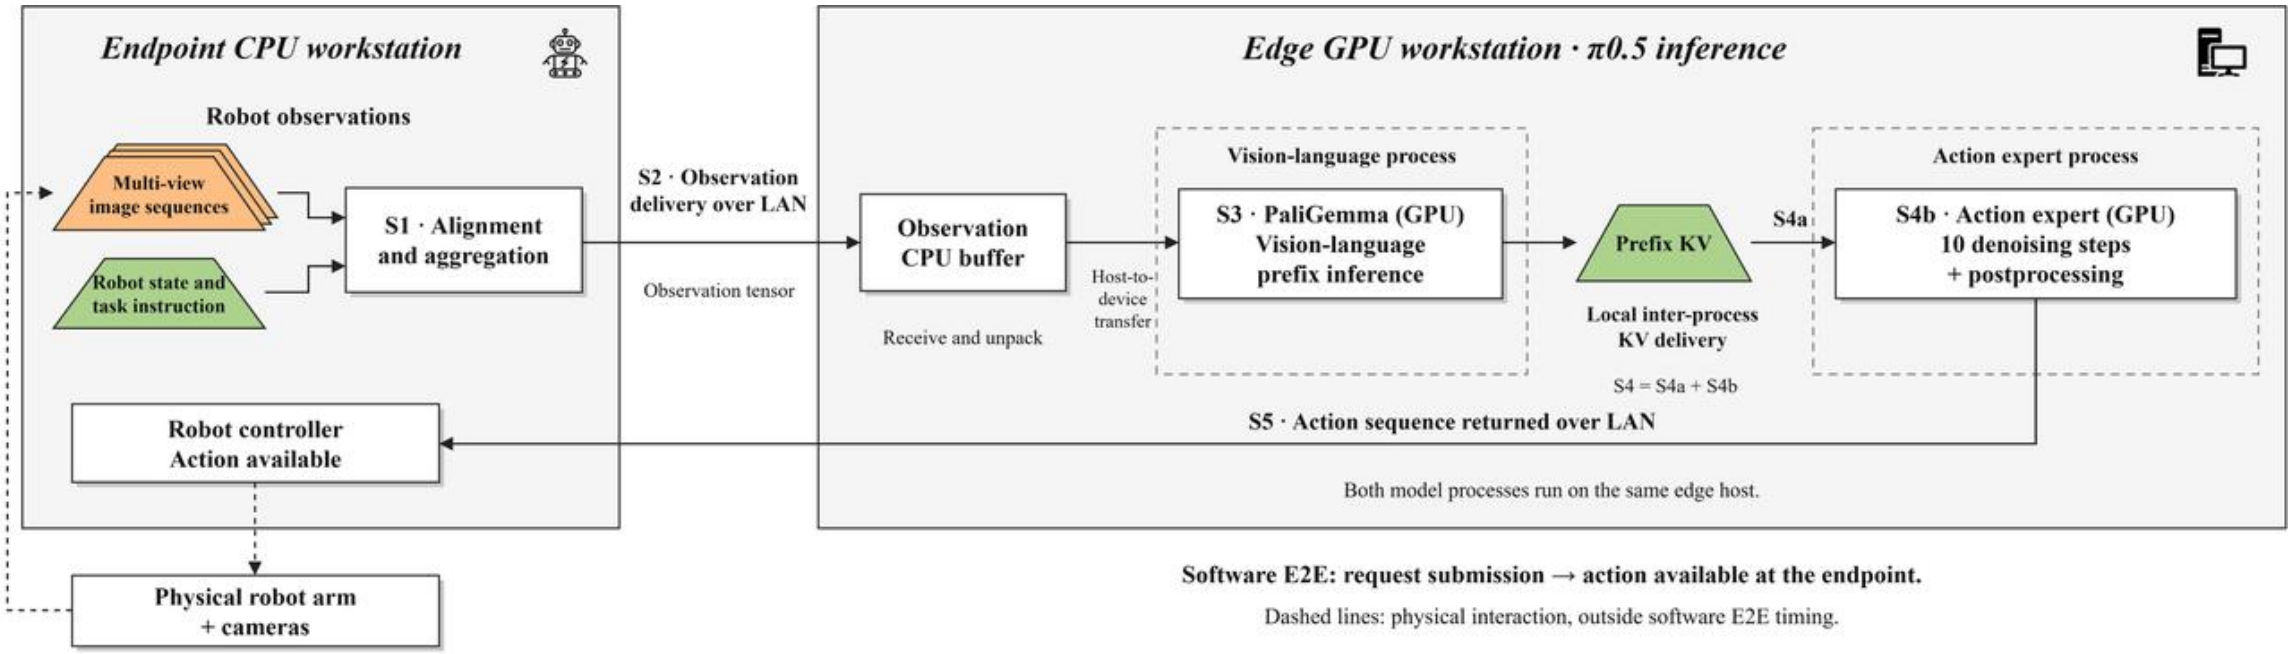
端云 WAN

最高 +32% / ROS 2

数据来源：项目跨机纯传输测试图；提升幅度见论文第 6.1 节。

基于π0.5模型的机器人端边协同推理测试

实验设置：端侧 CPU 工作站聚合观测，边侧 GPU 工作站完成 π0.5 VLA 推理



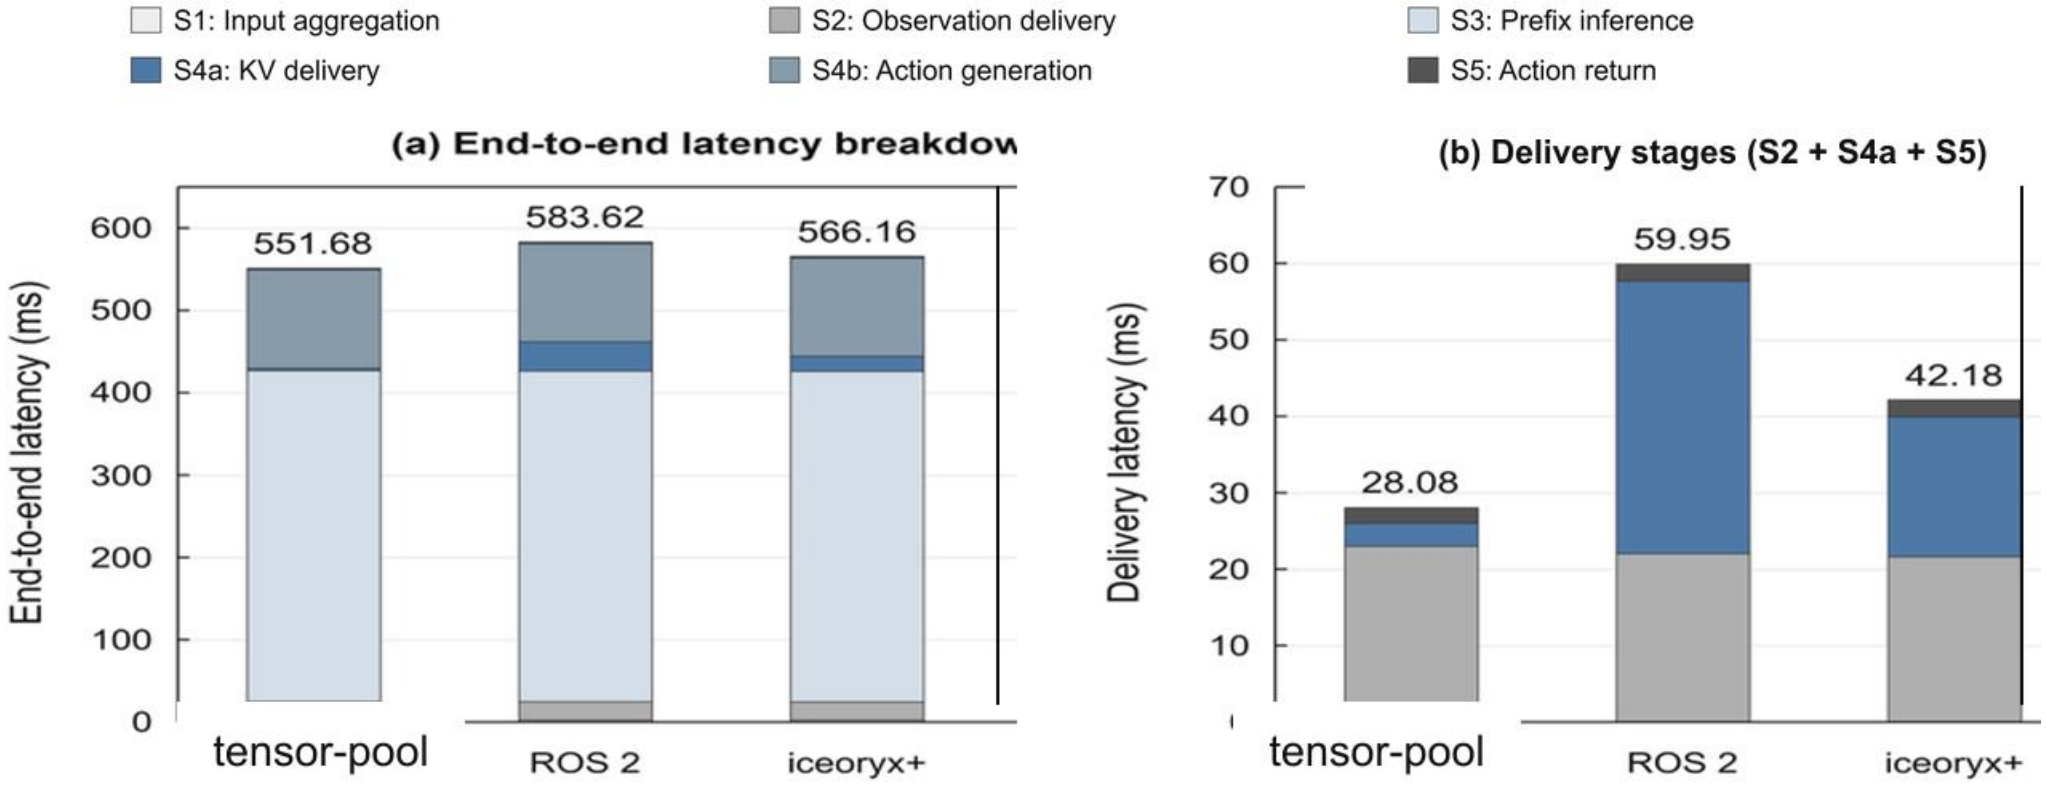
端侧
多视角观测聚合

端边链路
观测张量交付

边侧
VLA 推理与动作回传

基于π0.5模型的机器人端边协同推理测试

端到端延迟与传输延迟对比：



端到端延迟
↓5.47%
相较 ROS 2

传输延迟
↓53.16%
相较 ROS 2

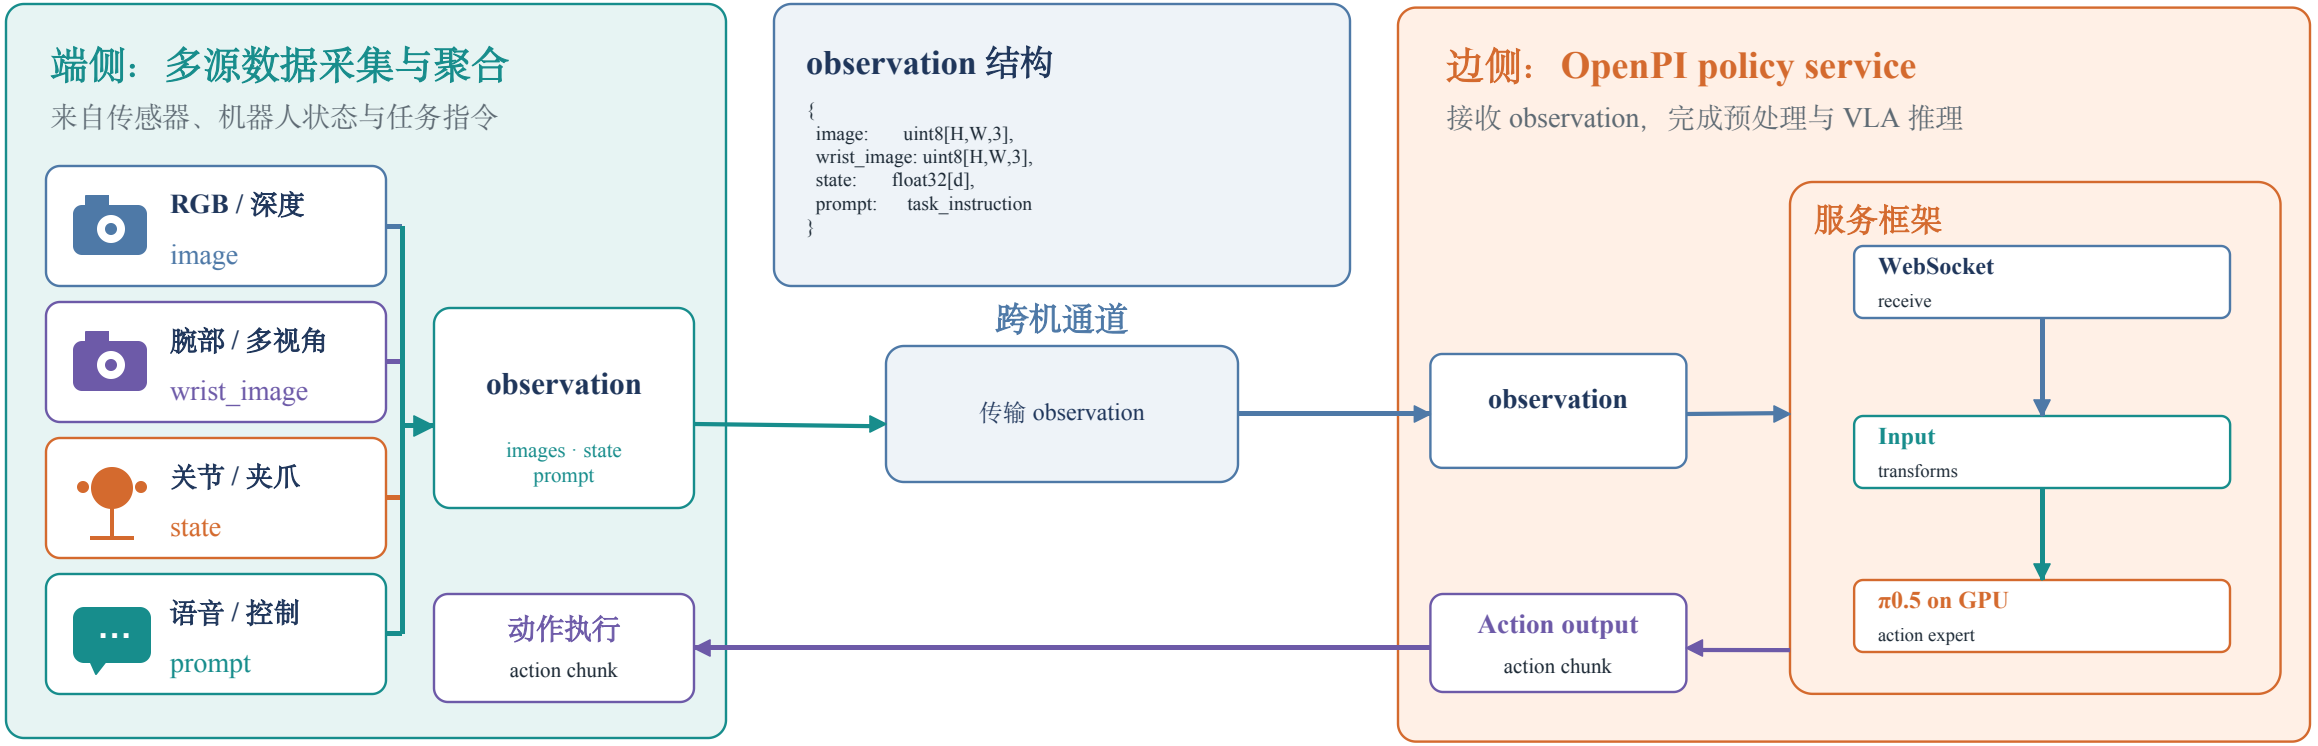
04

应用场景和未来工作



未来的机器人模型部署趋势：服务化部署

经典VLA服务框架：OpenPI



相较于VLA直接部署，服务化部署的主要优势

- GPU 资源集中
- 模型后端优化
- 统一策略接口
- 多机器人并发接入

tensor-pool未来扩展： 从 数据级复用 到 对象级复用

当前实现

tensor-pool

以 Tensor 为内存池与视图的基本对象

Tensor

持久化缓冲区 · 长期数据视图

register() write() read() free()

扩展对象边界

对象级复用

未来扩展

heteropool

以任务对象为内存池与视图的基本对象

Observation

images · robot state · prompt

Action chunk

multi-step actions

Model latent

visual features · hidden state

Trajectory buffer

observations · actions · rewards

设计思想保持不变：持久化内存池 + 长期视图 + 轮次更新；池化对象面向主流VLA和世界模型的任务对象进行拓展。

GOSIM

GOSIM Shenzhen 2026

Thanks!

Questions?

HeteroPool · DORA · GOSIM Shenzhen 2026

