高质量 Token 服务

从异构 PD 分离到算力网络

高算力设备如何支撑高质量 Token 服务，并进一步实现跨区域 P/D 协同

01 高质量 Token 服务 → 02 PD 分离 → 03 异构协同 → 04 跨区域算力网

方案与汇报材料：康鸿博 | 北京趋境科技有限责任公司 | 2026 年 10 月

从 Token 服务需求到跨区域算力网络

从 Token 服务需求理解 PD 分离，再介绍异构实践、跨机房实验与跨区域部署的网络需求。

为什么做 PD 分离

从 Token 服务需求出发，介绍分离的可行性与收益。

01

高质量 Token 服务

从模型能力进一步看到上下文、速度与稳定交付。

02

PD 分离基础

Prefill 与 Decode 天然分阶段，KV Cache 连接两段执行。

03

PD 分离收益

两阶段可以独立规划容量、硬件与部署位置。

从异构走向跨区域

介绍异构工业实践、跨机房实验，以及跨区域部署的网络需求。

04

异构 PD

高算力设备参与 Prefill，高带宽设备提升 Decode 输出速度。

05

跨机房异构实验

同园区与跨园区实验均保持高质量输出。

06

跨区域 PD

由模型与 Prefill 产能推导带宽和传输长尾要求。

CHAPTER 01

“

In the age of AI, intelligence tokens are the new currency, and AI factories generate them.

— Jensen Huang, NVIDIA

AI 基础设施的角色，
正由“运行模型”
转向“生产智能”。

高质量 Token 服务

AI 工厂的核心产品，是高质量 Token 服务

INPUT	→	FACTORY	→	OUTPUT
能源 + 算力		AI Factory		高质量 Token 服务

规模

在单位时间内生产更多 Token

质量

模型更强、上下文更长、响应更快更稳

本章界定高质量 Token 服务的内涵，并分析其价值与定价依据

行业对高质量 Token 服务的关注，往往聚焦模型能力

新模型发布已进入 Day 0 竞争，服务交付质量却较少被讨论

HIGH-QUALITY TOKEN SERVICE · 01

MODEL

最容易被看见的质量基础

DAY 0

更强模型，更早可用

模型能力决定任务上限，也最容易成为用户和平台选择服务时的显性依据。

新模型发布推动平台开展 Day 0 服务竞争

产业链争相将新增模型能力第一时间转化为可调用服务

2025.08	2026.01	2026.04	2026.07
OpenAI gpt-oss	**Kimi K2.5**	**Kimi K2.6**	**Kimi K3**
Cloudflare Day 0 Partner	Fireworks Day 0 Support	Cloudflare Day 0 Support	vLLM Day 0 Support

注意力集中： Day 0 已成为平台竞争标志，但它只回答“何时能调用模型”。

模型能力决定任务上限；用户获得的服务质量，还取决于模型如何被交付

Sources: Cloudflare Workers AI · Fireworks AI · vLLM official Day 0 announcements

高质量 Token 服务取决于模型能力与交付质量

上下文长度决定任务信息覆盖范围，输出时延与稳定性决定实际服务体验

01 · CAPABILITY

能力

决定任务完成能力

理解、推理、Coding 与工具调用。

Task success | Evals | Active compute

02 · CONTEXT

上下文长度

决定任务信息覆盖范围

长文档、代码库、工具定义与多轮历史。

Context window | Cache | Input length

03 · DELIVERY

输出体验

决定服务响应与连续性

响应速度、持续输出、吞吐与稳定性。

TTFT | Interactivity | Throughput | SLO

高质量 Token 服务 = 模型能力 + 交付质量（上下文长度 + 输出体验）

模型能力构成质量基础，上下文长度与输出体验共同决定交付质量

四个指标衡量 Token 服务的输出体验

上半部分给出技术定义，下半部分说明这些指标对应怎样的用户体验

USER WAIT

TTFT

首 Token 延迟

请求发出后，到收到第一个输出 Token 的时间。

s / request · 越低越好

GENERATION SPEED

Interactivity

单请求输出速度

单个请求每秒持续生成的 Output Token 数量。

token/s/request · 越高越好

SYSTEM CAPACITY

Throughput

系统聚合吞吐

整个系统每秒处理的 Input 或 Output Token 总量。

token/s · 越高越好

SERVICE QUALITY

SLO

服务等级目标

对 P90/P99 时延、成功率和稳定性设定的目标。

threshold / success rate

直观理解

把术语翻译成人话

TTFT	=	第一个 Token 要等多久
Interactivity	=	回答持续生成得有多快
Throughput	=	整个系统每秒能处理多少 Token
SLO	=	上述体验在高负载下能否稳定达到目标

单请求 Output TPS 对应 Interactivity；系统聚合 TPS 对应 Throughput

工作负载演进提高了对 Token 交付速度的敏感性

用户从直接阅读答案，走向与模型协作并让程序自动执行；速度的价值随 Token 消费方式改变

用户使用方式演变 →

工作负载	Chat	Coding & Agent	Agent Loop
典型任务	问答 · 阅读 · 内容交流	编程 · 工具调用 · 长程执行	代码迭代 · 深度研究 · 长程执行
输出消费者	人直接阅读	人与模型交替协作	程序连续消费中间结果
典型速度目标	**阅读级 · 约 5 TPS** 匹配成人阅读速度	**交互级 · 约 50 TPS** 约 250 Token / 轮，可在 5 秒内输出	**按完成时限选择** 多轮调用会累积等待时间

厂家将速度产品化
形成独立的可选服务等级

Standard（常规交付） → Fast / HighSpeed（更低交互等待） → Ultrafast（极致闭环完成时间）

不同工作负载对速度的敏感程度不同，厂商因此提供分层的速度服务

Sources: Reading-rate meta-analysis · Agentic Coding in the Wild · Kimi · GLM · OpenAI

高质量 Token 服务已形成分层计价体系

API 服务围绕模型能力、上下文长度与交付速度实施差异化定价

QUALITY
高质量 Token 服务 = 01 · 能力 **能力更强** + 02 · 上下文 **上下文更长** + 03 · 速度 **输出更快**

对应明确价格溢价

01 · 模型能力 — 能力更强

GPT-5.6 模型档位

基准	高质量端
Luna	Sol
$0.20 / $1.20	$4.00 / $20.00

价格溢价：Input 20× | Output 16.7×

模型档位直接决定 Token 基础单价

02 · 上下文长度 — 上下文更长

GPT-5.6 Sol 输入长度

基准	高质量端
⩽ 272K	> 272K
标准上下文	长上下文

价格溢价：Input 2× | Output 1.5×

超过阈值后，整个请求按长上下文档位计价

03 · 输出体验 — 输出更快

GPT-5.6 Sol 服务档位

基准	高质量端
Standard	Fast
标准速度	最高 2.5× 速度

价格溢价：Price 2× | Speed ⩽ 2.5×

Ultrafast：最高 14× / 750 TPS；价格暂未开放

质量提升已经转化为清晰的价格溢价

同一模型 **最高 4×**

跨模型与质量档位 **最高 80×**

Sources: OpenAI GPT-5.6 model/pricing docs · Fast mode · Ultrafast preview

CHAPTER 02

PD 分离基础

高质量 Token 服务，如何由推理系统交付?

用户感知到的服务

TTFT · Interactivity · Throughput / SLO

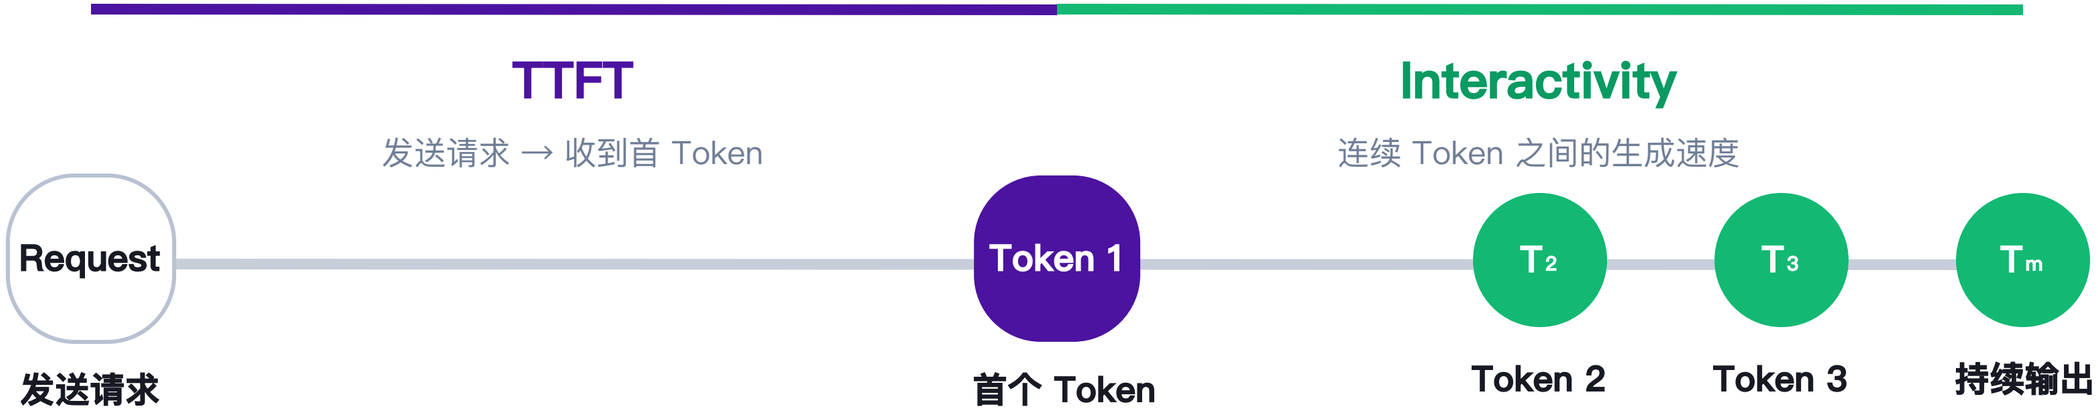
系统内部的一次自回归推理

Input → Token 1 → Token 2 → ...

接下来，从首 Token 边界拆开一次自回归推理。

首 Token 是 Prefill 与 Decode 的天然执行边界

执行上，一次 Prefill 之后进入多轮 Decode；体验上，用户先等待首 Token，再持续接收输出。



Prefill 处理输入，主要影响首 Token 到达时间

Decode 逐 Token 生成，主要影响持续输出速度

同一个首 Token 边界，同时划分推理执行阶段与用户体验阶段。

Prefill 与 Decode 的计算过程和硬件需求天然不同

同一模型在两个阶段呈现不同计算形态，分别受矩阵算力和显存带宽约束。

Prefill

一次并行处理 N 个 Input Token



核心需求：高矩阵计算吞吐

Decode

重复 M 轮，每轮生成 1 个 Output Token



核心需求：高显存带宽、低单步时延

Prefill	对比维度	Decode
一次并行处理 N 个 Input Token	推进方式	重复 M 轮，每轮生成 1 个 Output Token
读取权重，形成大规模矩阵计算	数据访问	每轮读取权重与 KV Cache
矩阵计算吞吐	主要瓶颈	显存带宽与单步时延

同一模型在两个阶段形成两类不同 Workload，适合分别调度与选择硬件。

可交付的 KV Cache，让 Prefill 与 Decode 可以分离

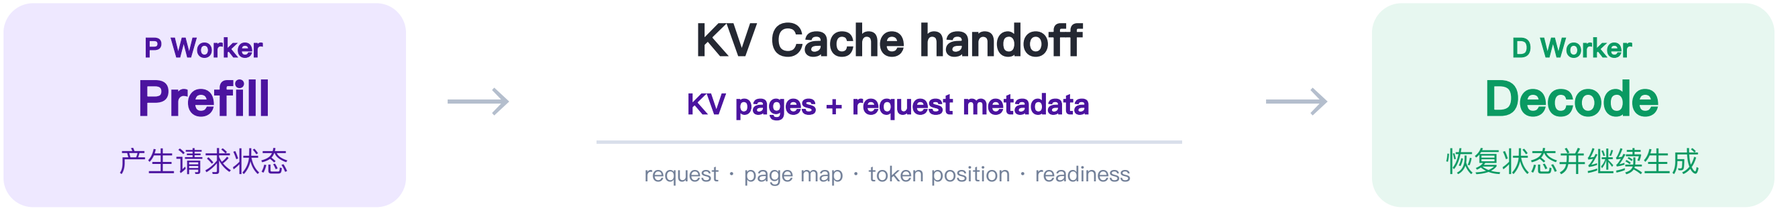
阶段边界本身还不够；当请求状态可以被显式交付，P/D 才能由独立 Worker 执行。

算法视角：同一请求存在连续的阶段依赖



将请求状态显式化为可交付接口

系统视角：由两个独立 Worker 执行



P/D 仍然存在状态依赖；依赖被收敛为一次明确、可传输的 KV Cache handoff，两个阶段因此可以独立执行。

CHAPTER 03

PD 分离的系统价值

P 和 D 分开以后，系统能做什么?

01

服务目标独立治理

分别优化 TTFT 与 Interactivity

02

容量独立配置

按不同业务的输入与输出配置资源

03

硬件与位置独立规划

资源池不再受固定机型和共址约束

PD 分离不只是拆开计算，更让 Prefill 和 Decode 可以各自按需组织资源。

P/D 分离让两类服务目标独立治理

两个阶段不再竞争同一套队列、batching 策略和设备资源。

未分离：共享调度与执行资源

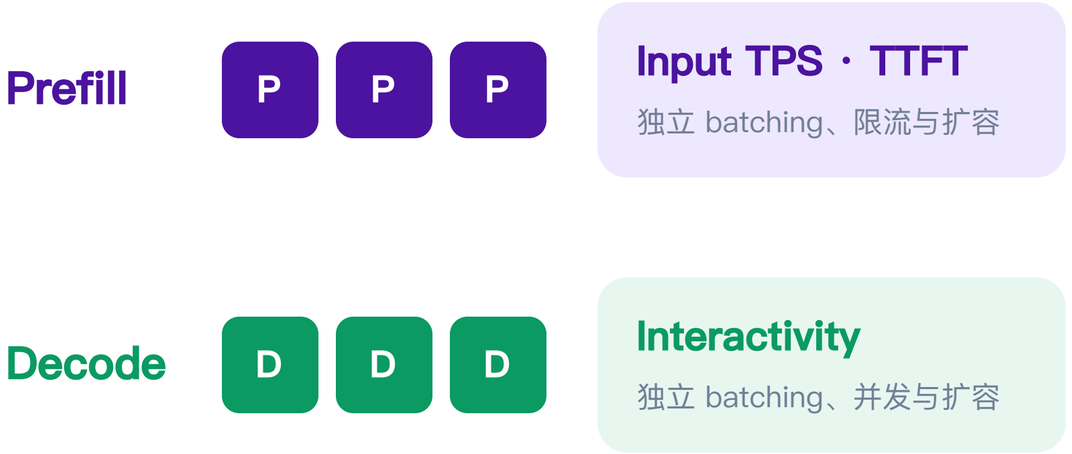
两类 workload 在同一资源上相互影响



Prefill 流量与 Decode 生成相互干扰，系统需要在 TTFT、Interactivity 和吞吐之间全局折中。

分离后：两条独立调度路径

每个阶段围绕自己的服务目标优化

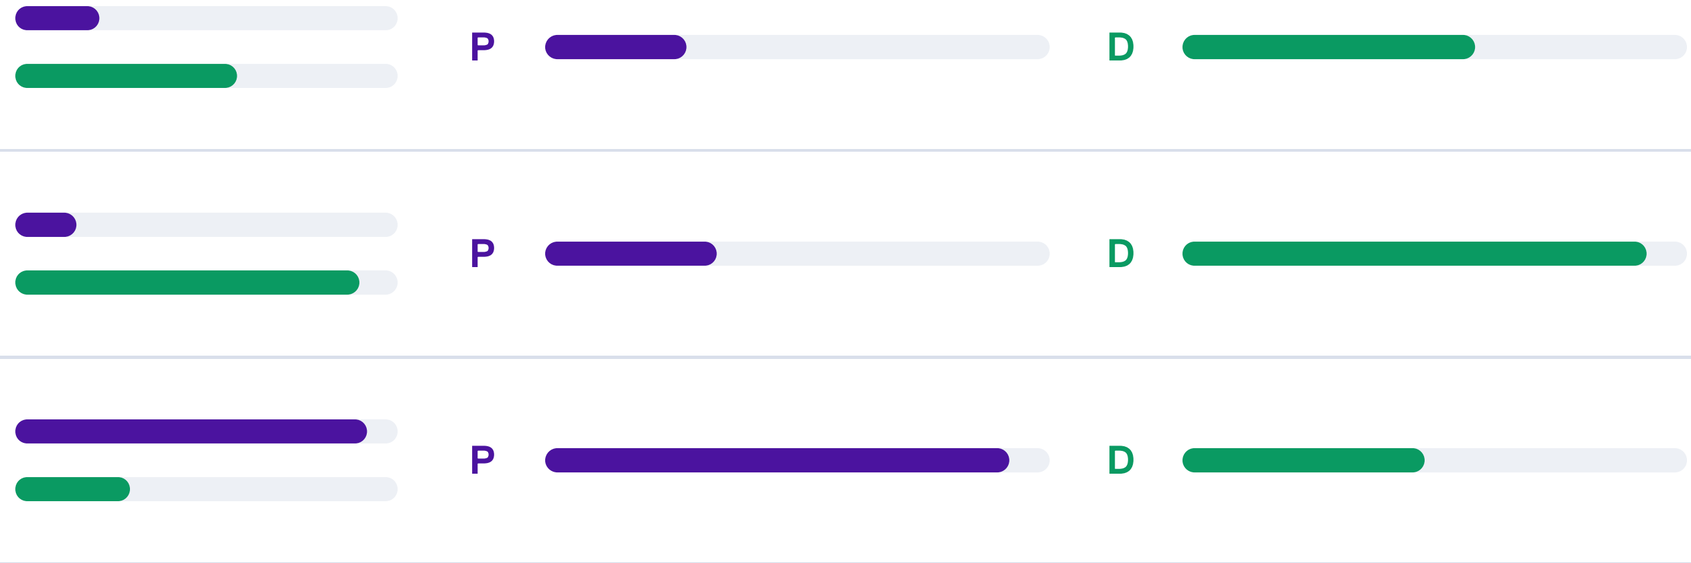


PD 分离把“一个全局折中”，变成两套可以分别调度、分别扩容、分别优化的目标。

不同业务可以独立配置 Prefill 与 Decode 容量

对话、长文本生成和 Agent 的 Input / Output 结构不同，对 P/D 容量的要求也不同。

业务场景	请求结构	Prefill 容量	Decode 容量
对话 短输入 · 中等输出 135 / 1,115 tok · 公开会话	Input Output	P	D
长文本生成 短指令 · 超长输出 16K / 32K output tok · 基准	Input Output	P	D
Agent 长输入 · 短输出 × 多轮 68K / 247 tok · 15 calls · 生产	Input Output	P	D



条形表示单次调用的相对量级；三组数据分别来自公开会话、benchmark 与生产 trace。

Sources: ShareChat · LongGenBench · Agentic Coding in the Wild

Prefill Pool与 Decode Pool可以分别扩缩容，资源供给随业务结构变化。

PD 分离让硬件与部署方式不再绑定

P/D 可以分别选择设备、组织资源池，并按照各自需求独立演进。

P

PREFILL POOL

围绕输入计算选型

计算吞吐 | 供给规模 | 成本效率

按大规模输入计算需求选择设备，并围绕可用算力组织资源池。

KV Cache handoff

D

DECODE POOL

围绕持续生成选型

显存带宽 | 互联能力 | 单步时延

按逐 Token 生成需求选择设备，并围绕服务入口组织资源池。

01 硬件独立

P/D 可以采用不同型号、代际或厂商的设备。

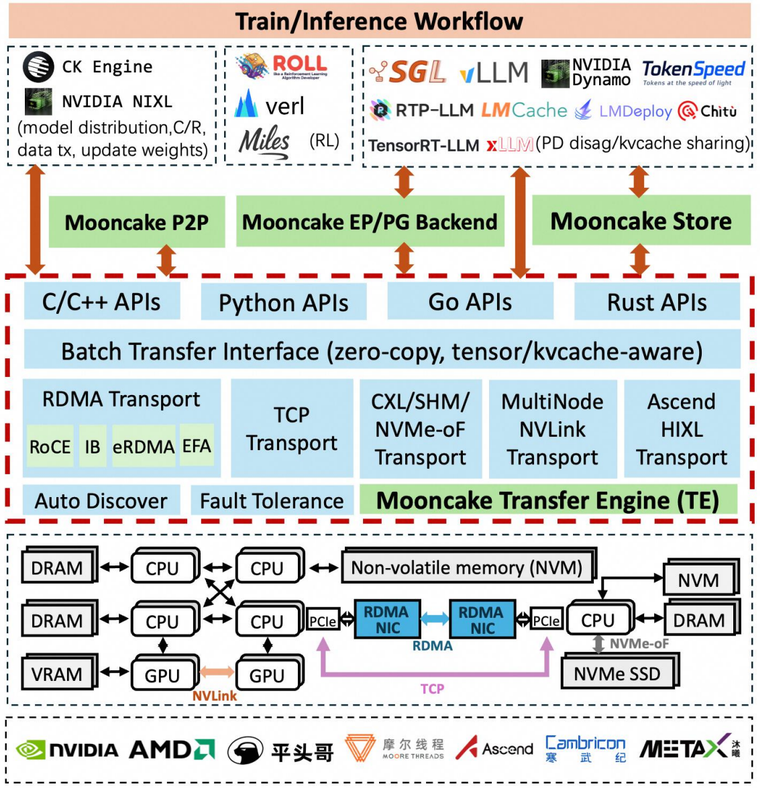
02 部署与演进独立

可以位于不同资源池，并分别采购、扩容和升级。

P/D 从固定硬件组合，变成两个可以独立选择、部署和演进的资源池。

Mooncake 已形成完整的数据基础设施体系

它连接多种训练与推理工作流，并统一跨设备、内存和网络的数据移动。



01 面向完整工作流

覆盖模型分发、RL、PD 分离、KV Cache sharing 与训练/推理系统。

02 统一数据移动底座

P2P、EP/PG Backend 与 Store 复用同一 Transfer Engine。

03 兼容异构基础设施

连接 GPU、NPU、CPU、内存、存储以及多种网络传输。

我们发起并持续维护 Mooncake，把生产系统中的数据移动能力沉淀为开源基础设施。

Source: Mooncake Train/Inference Workflow architecture.

Mooncake 已从 Kimi 生产系统走向主流生态

生产验证、框架采用、产业部署和学术认可，共同证明其已经超越单一项目。

01

PRODUCTION

近 4,000 万 MAU

Kimi 吞吐提升 75%+

真实业务规模验证

02

FRAMEWORK ADOPTION

SGLang 默认 PD Backend

vLLM · TensorRT-LLM

进入 PyTorch 生态，并被 NVIDIA Dynamo 参考

03

INDUSTRY DEPLOYMENT

数万张 GPU

每天数十亿 Tokens

多家头部互联网公司规模化落地

04

OPEN SOURCE & RECOGNITION

6.4K+ Stars

FAST '25 Best Paper

1.1K+ Forks · 全球开源基础设施

INDUSTRY VALUE

由项目能力沉淀为公共底座

统一框架接口

PD、KV Cache、权重与分布式执行复用同一数据底座

兼容异构资源

跨设备、内存和网络复用成熟的数据移动能力

降低生态接入成本

避免各框架为不同基础设施重复开发专用通路

我们不仅采用 PD 分离，也持续建设这条技术路线的通用基础设施与开源生态。

Sources: Kimi production report; Mooncake project; SGLang, vLLM, TensorRT-LLM, PyTorch; NVIDIA Dynamo; USENIX FAST '25.

CHAPTER 04

为什么进一步采用异构 PD

让不同硬件承担更适合的推理阶段

P

PREFILL

规模化输入计算

计算吞吐 · 供给规模

KV Cache

D

DECODE

保障高质量 Token 服务

显存带宽 · 互联 · Interactivity

异构 PD 的核心不是混用设备，而是把每类设备放到更适合的位置。

Prefill 与 Decode 对硬件的要求不同

Prefill 侧重规模化计算吞吐；Decode 更依赖显存带宽、容量与互联，以维持低单步时延和稳定输出速度。

P

PREFILL

一次处理大量 Input Token

第一优先级 **稠密计算吞吐**

- 矩阵计算并行度高
- 吞吐随集群规模扩展
- 适合组织大规模算力池

≠

D

DECODE

逐步生成 Output Token

第一优先级 **显存与互联系统**

- 每步反复读取权重与 KV
- 低并发时更容易受访存限制
- 直接决定 Interactivity

同一种设备同时做到“Prefill 成本最优”和“Decode 体验最优”，并非总是合理。

面向 Decode 的关键硬件指标存在差距

2023—2026 年代表性产品的显存容量与显存带宽对照。

同代窗口	产品	具体时间	显存容量	显存带宽
2023	Ascend 910B 国产	H2 推出	64 GB	1.6 TB/s
	MetaX C500 国产	H2 公开亮相	64 GB	约 1.84 TB/s*
	NVIDIA H200 NVIDIA	H2 发布	141 GB	4.8 TB/s
2024—2025	MTT S5000 国产	2024 H2 推出	80 GB	1.6 TB/s
	NVIDIA B300 NVIDIA	2025 H1 发布	288 GB	最高 8 TB/s
2026	Ascend 950DT 国产	H2 计划	最高 144 GB	4.0 TB/s
	NVIDIA Rubin NVIDIA	H2 供货	最高 288 GB	最高 22 TB/s**

2.6—3.0× 2023 · H200 对 910B / C500

5.0× 2025 · B300 对 S5000

5.5× 2026 · Rubin 对 950DT

Sources: iFLYTEK · MetaX tuning guide · MTT · Huawei · NVIDIA. *C500 为 Microbenchmark 参考值；**Rubin 规格为 preliminary。

异构 PD 将高带宽设备集中用于 Decode

资源组合的关键不是设备品牌，而是稀缺的高带宽能力被配置在哪个阶段。

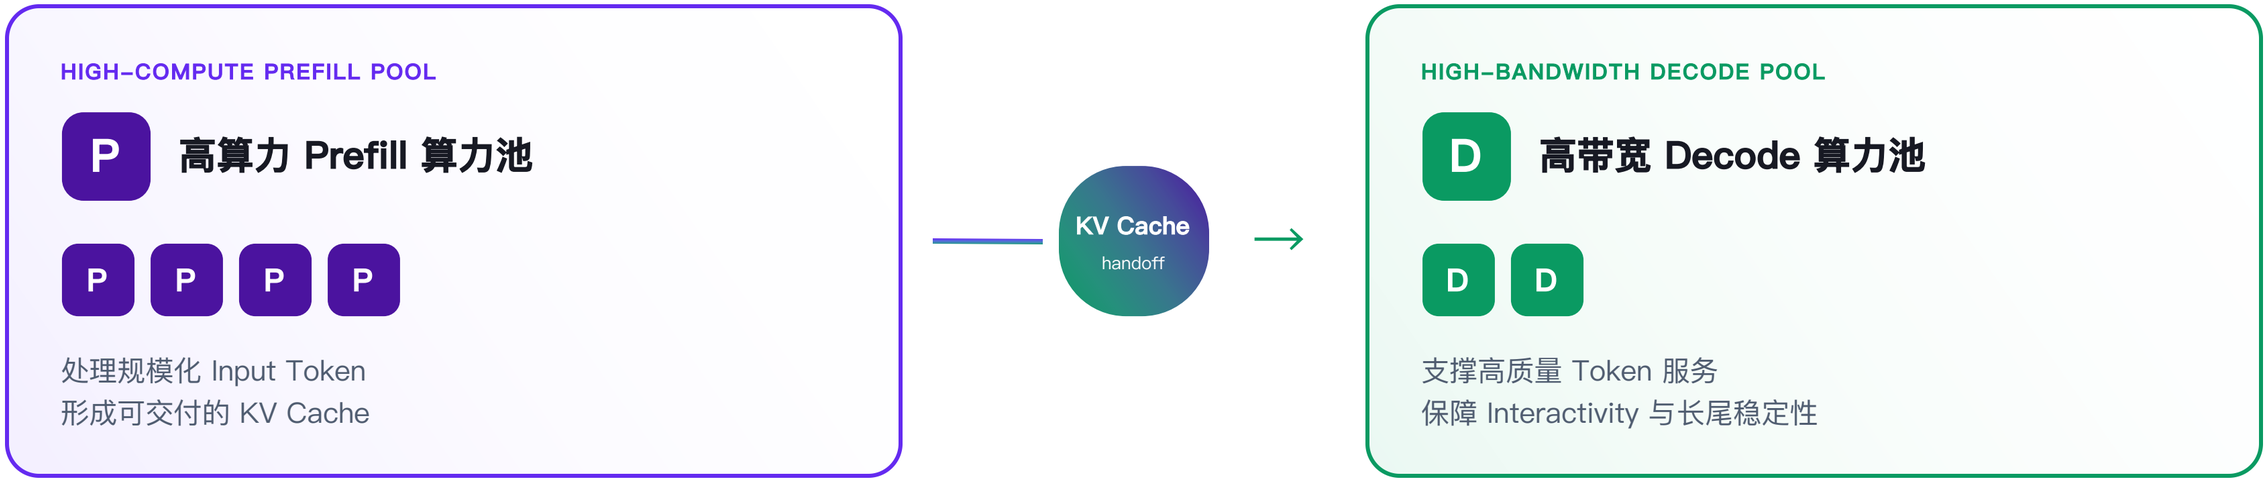
方案	Prefill Pool	Decode Pool	系统结果
高算力设备同构 High-compute Homogeneous	P 高算力设备	D 高算力设备	算力供给充分；Decode Interactivity 可能成为服务短板
高带宽设备同构 High-bandwidth Homogeneous	P 高带宽设备	D 高带宽设备	Decode 体验较好；Prefill 同样占用稀缺高配置设备
异构 PD Heterogeneous PD	P 高算力设备	D 高带宽设备	**两类设备分别承担更匹配的阶段**

资源配置原则：规模化算力进入 Prefill Pool，高价值显存与互联能力集中进入 Decode Pool。

异构方案不是降低 Decode 标准，而是用更少的高带宽设备守住输出体验。

异构 PD 的难点，是让两类硬件协同成一个服务

两类设备需要正确衔接 Prefill 和 Decode，保证端到端服务的性能与稳定性。



01 跨硬件正确性

同一模型在两类 Runtime 上保持语义一致；KV Cache 完成交付后仍能被 Decode 正确使用。

02 端到端性能

Prefill 计算、KV 交付与 Decode 生成形成流水，交付开销不主导吞吐与 Interactivity。

03 生产可用性

两个独立资源池仍作为一个服务，统一支持路由、扩缩容、故障处理与全链路观测。

只有同时满足正确、快速、稳定，异构设备才真正组成一个高质量 Token 服务。

我们已将异构 PD 投入千卡级商业生产

服务对象：一线大模型厂商 | 交付目标：高质量 Token 服务

INDUSTRIAL SCALE

千卡级

商业生产规模

工业实践一 · 高算力设备 A — 高带宽设备 A

已上线

高算力设备 A
Prefill

→

高带宽设备 A
Decode

工业实践二 · 高算力设备 B — 高带宽设备 A

已上线

高算力设备 B
Prefill

→

高带宽设备 A
Decode

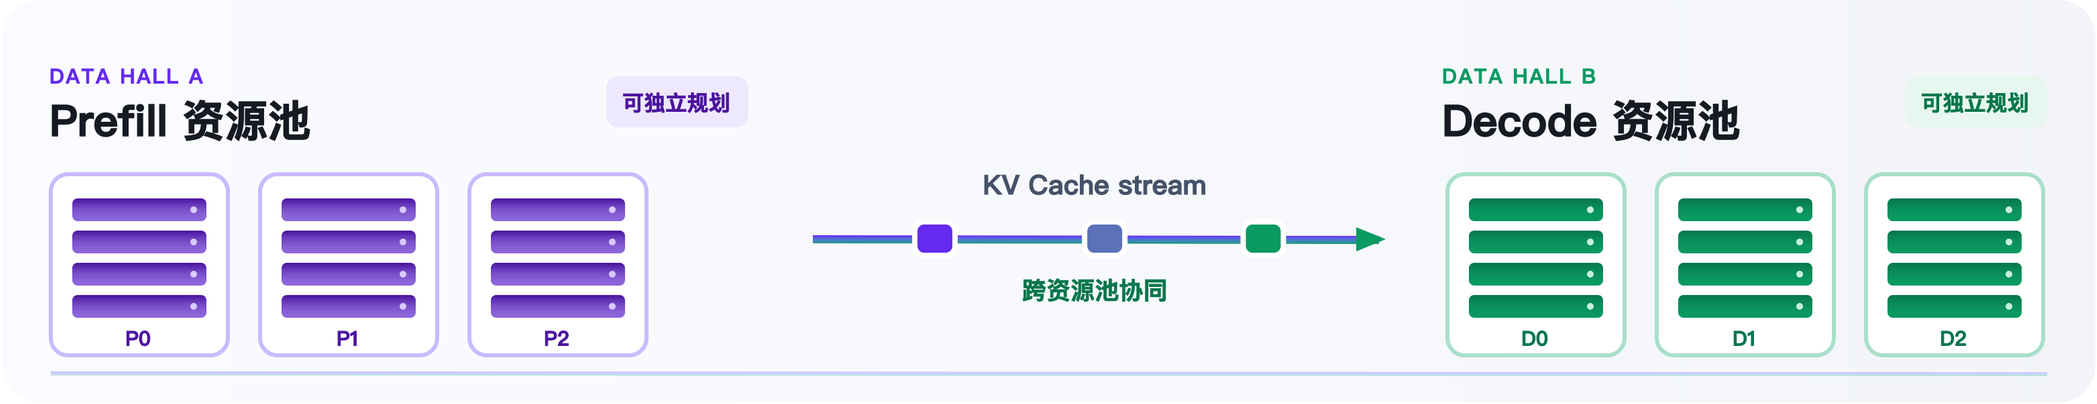
线上运行验证：高算力设备可承担规模化 Prefill，高带宽设备可集中保障 Decode。

Source: 北京趋境科技有限责任公司工业部署材料。

CHAPTER 05

跨机房异构 PD 实验

异构 PD 让分散资源池跨机房协同



同园区与跨园区实验验证：Prefill 与 Decode 不共址，仍能提供高质量 Token 服务。

PD 分离让已有异构资源池无需混布就能协同

Prefill 和 Decode 保留原有机柜、网络域与运维体系，通过 KV Cache handoff 组成一套服务。

EXISTING PREFILL POOL

已有 Prefill 资源

高算力设备 · 原有机柜与网络域

P P P P

计算 Input · 生成 KV Cache

PD DISAGGREGATION

KV Cache Handoff



设备保持原位 · 服务跨池组成

EXISTING DECODE POOL

已有 Decode 资源

高带宽设备 · 原有机柜与网络域

D D D D

接收 KV Cache · 持续生成

01 · DEPLOYMENT

不同设备不必混布

分别保留原有机柜、网络域与运维体系

02 · CAPACITY

P:D 比例独立调整

按 Input / Output workload 分别扩缩

03 · SERVICE

分散算力组成一套服务

不同位置的资源池共同对外提供能力

PD 分离让分散的异构资源池保持独立，同时组成一套可按需调整的服务。

Source: Qin et al., “Prefill-as-a-Service: KVCache of Next-Generation Models Could Go Cross-Datacenter,” arXiv:2604.15039, 2026.

带宽决定 KV 排出速度，最后一批 KV 的到达决定 Decode 何时启动

KV 传输与 Chunked Prefill 重叠；Decode 启动后，P→D 网络退出逐 Token 生成路径。



对 PREFILL 服务吞吐的影响

网络排出慢于 KV 产生，队列和反压才会出现

KV Production > Network Drain → Queue ↑ · Input TPS 被封顶

网络不降低 Prefill 算子的计算速度；它限制完成 KV 交付后的端到端服务吞吐。

对 DECODE 用户体验的影响

最后一批 KV 的交付长尾决定 Decode 何时启动

Last KV Completion → Decode Start → TTFT

Decode 启动后，P→D 网络退出逐 Token 关键路径；TPOT / Interactivity 仍由 D 侧决定。

带宽影响 Input TPS，KV 交付长尾影响 TTFT；Decode 输出速度主要由 Decode 侧决定。

Source: SGLang PD execution model; Prefill–as–a–Service communication model.

跨机房 PD 的网络需求

资源池可以独立建设；跨机房网络需要保障 KV Block 的持续交付能力和完成长尾。

PREFILL POOL

持续产生 KV Block

汇总多个 P Worker 的 KV 输出

CROSS-SITE NETWORK

KV Cache handoff



01 · CAPACITY

持续 Goodput 足够

承接全部 Prefill Pool 的聚合 KV 产生速率，避免传输队列持续积压

02 · COMPLETION

完成长尾受控

限制单请求最后一批必要 KV 的完成时间，避免 Decode 启动被长尾拖慢

DECODE POOL

必要 KV 到齐后启动生成

后续逐 Token 输出留在 D 侧

跨机房网络不必复刻同机房互联；需要满足的是 KV Block 的持续交付能力与完成长尾。

Source: Prefill–as–a–Service deployment model; cross–building network architecture.

同构与异构 3P1D 实验对照

两组使用相同模型与 Prefill 规模；同构方案采用 RDMA，异构方案采用 Mooncake TE TCP。

MODEL · 模型	INPUT LENGTH · 输入长度	CONCURRENCY · 并发请求数
Kimi K2.6 MLA KV · 70,272 B/token	**Input Sequence Length（ISL）** 2K / 8K / 32K input tokens	**Concurrency（C）** C1—C64 对照；异构扩展至 C1024

SAME PREFILL SCALE

相同 Prefill 规模

3P · 6 节点

高算力设备 C · 24 张物理卡
48 个逻辑 device

每个 P · 2 节点

每个 P：PP2 / TP8

异构 · 跨园区 / 跨机房
Mooncake TE TCP
100GbE 汇聚入口
TCP Goodput · 90.95Gb/s

→ **高算力设备 C + 高带宽设备 B 异构 3P1D**
Decode · 8 × 高带宽设备 B
TP8 · Attention DP8

同构 · 同楼 RDMA 网络
RDMA
DEVICE_RDMA

→ **纯高算力设备 C 同构 3P1D**
Decode · 8 × 高算力设备 C
PP2 / TP8 · Attn DP8 · EP8

以同构部署为参照，验证跨园区异构的 Prefill 吞吐与 Decode 输出优势。

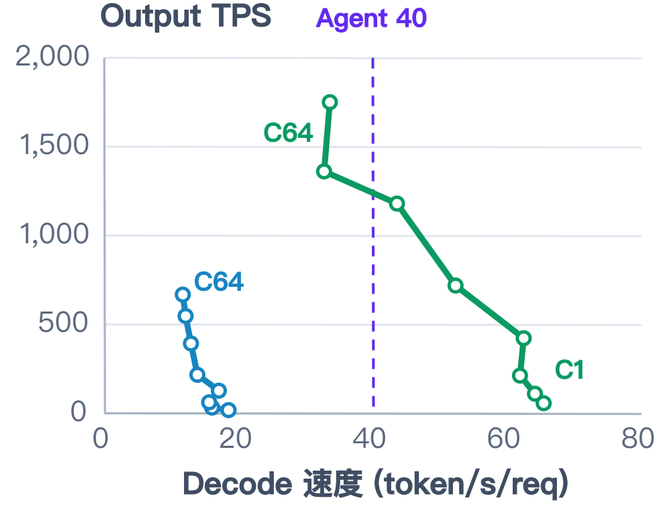
Source: Kimi K2.6 3P1D 部署与性能记录；四源聚合 iperf3 为链路容量参考，不是模型运行中的 KV goodput。

异构将 Decode 输出速度提升到高质量区间

2K / 8K / 32K 的单请求输出速度为 65.5 / 61.5 / 54.6 token/s/req，均超过 Agent 速度门槛（40 token/s/req）。

异构 · 高算力设备 C + 高带宽设备 B · Mooncake TE TCP　　同构 · 纯高算力设备 C · RDMA

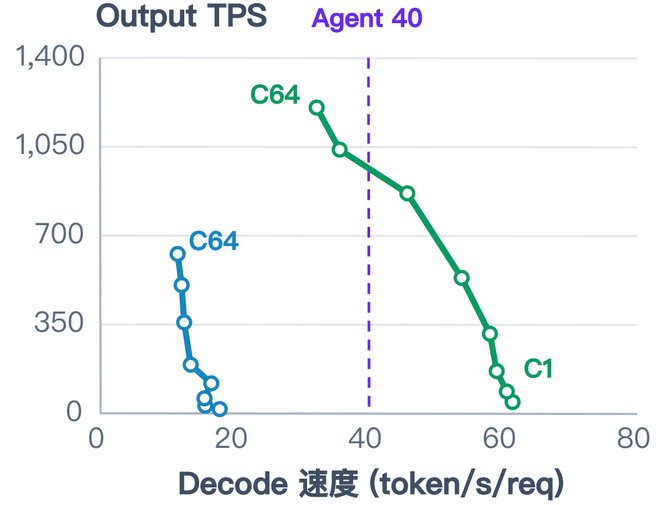
2K Input



C1 · 65.5 token/s/req

C64 · 1,751 Output TPS

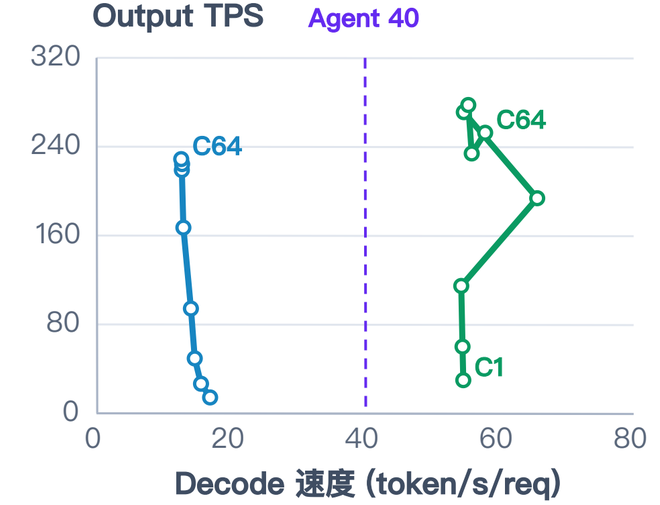
8K Input



C1 · 61.5 token/s/req

C64 · 1,204 Output TPS

32K Input



C1 · 54.6 token/s/req

C64 · 253 Output TPS

跨园区部署下，异构 PD 的单请求输出速度和总输出吞吐均优于同构方案。

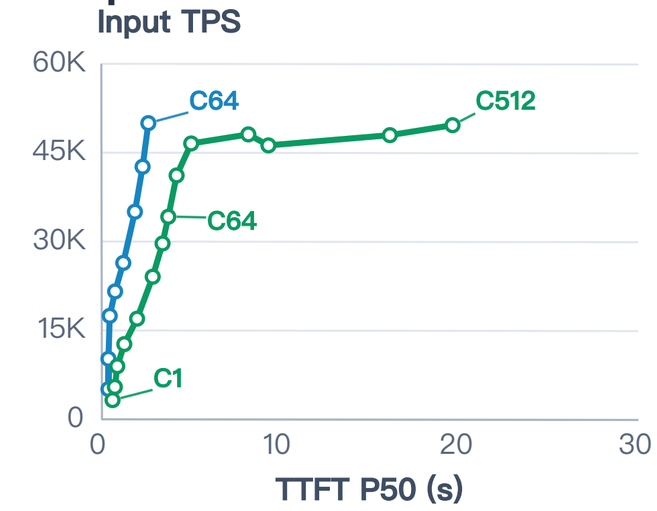
Source: Kimi K2.6 3P1D 性能曲线。单请求速度排除 TTFT，不以 Output TPS / C 估算。
两组对照来自独立实验测量，统计窗口口径存在差异。

异构 Prefill 吞吐接近同构

三种输入长度的异构峰值分别为 49.6K / 49.5K / 38.5K Input TPS。

异构 · 高算力设备 C + 高带宽设备 B · Mooncake TE TCP　同构 · 纯高算力设备 C · RDMA

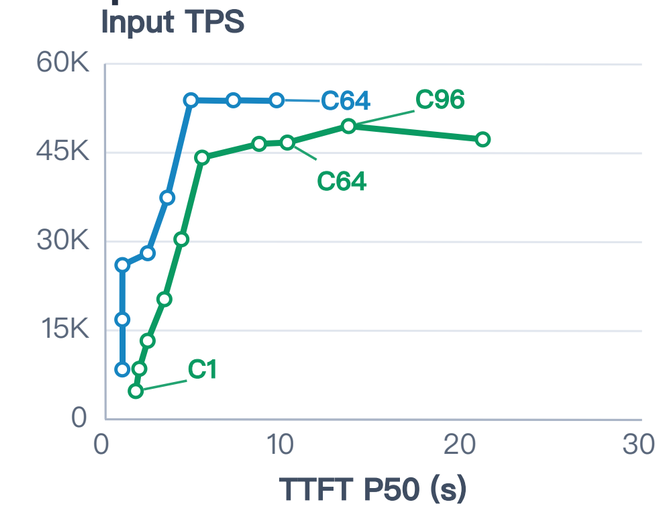
2K Input



峰值 49,647 Input TPS

C512 · TTFT P50 19.6 s

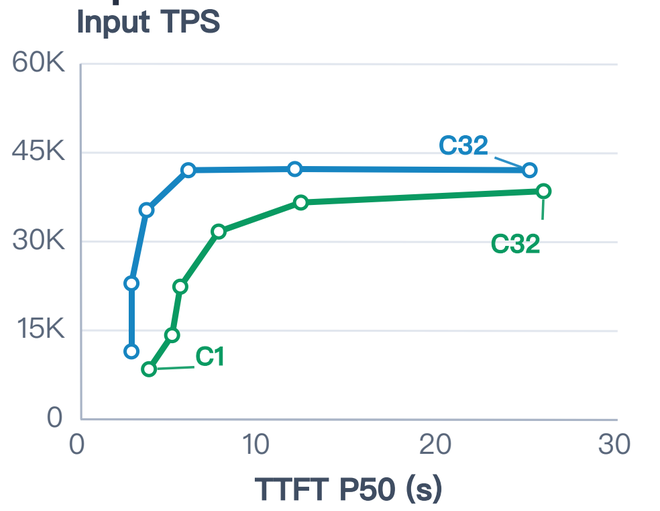
8K Input



峰值 49,493 Input TPS

C96 · TTFT P50 13.6 s

32K Input



峰值 38,502 Input TPS

C32 · TTFT P50 25.9 s

异构 PD 的 Prefill 吞吐接近同构方案，单请求输出速度更高。

Source: Kimi K2.6 3P1D 曲线；仅展示 TTFT ≤ 30 s。32K 峰值存在窗口波动，不作为稳态平台结论。
两组对照来自独立实验测量，统计窗口口径存在差异。

如果跨机房网络带宽受限，异构 PD 会怎样?

跨机房互联的带宽成本更高，在成本约束下，可用带宽往往更小。

PREFILL

3P · 24 × 高算力设备 C

6 个节点

每个 P：PP2 / TP8

→

同园区 · 跨机房

Mooncake TE TCP

100GbE → 20GbE

本组 TCP Goodput · 18.8Gb/s

→

DECODE

1D · 8 × 高带宽设备 B

1 个节点

TP8 / Attention DP8

PREFILL

吞吐能否接近网络容量上限?

用模型 KV 数据量换算链路可承载的 Input TPS

DECODE

高质量输出速度能否保持?

检查传输完成后的 Interactivity 与输出优势

同园区跨机房实验采用 20GbE，检验受限带宽下的 Prefill 吞吐与 Decode 输出。

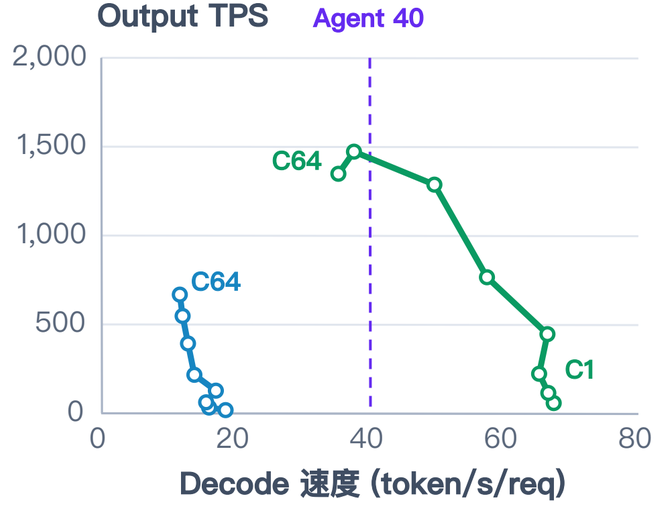
Source: Kimi K2.6 3P1D 部署与低带宽实验。跨园区实验为 100GbE，同园区实验为 20GbE；两组独立，不作纯带宽 A/B 归因。

网络受限时，异构仍保持高质量输出速度

20GbE 网络下，并发为 1 时，三种输入长度的单请求输出速度均超过 Agent 速度门槛（40 token/s/req）。

异构 · 高算力设备 C + 高带宽设备 B · Mooncake TE TCP　　同构 · 纯高算力设备 C · RDMA

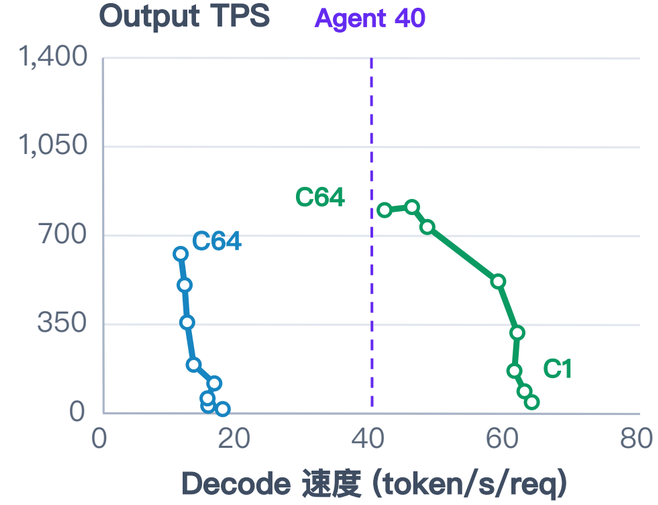
2K Input



C1 · 67.4 token/s/req

C64 · 1,347 Output TPS

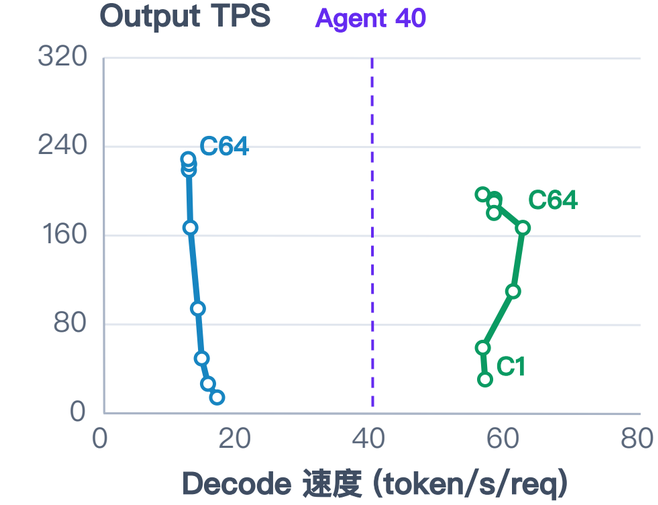
8K Input



C1 · 63.9 token/s/req

C64 · 800 Output TPS

32K Input



C1 · 56.8 token/s/req

C64 · 180 Output TPS

单请求测试中，20GbE 异构方案的输出速度约为同构方案的 3.4–3.6 倍。

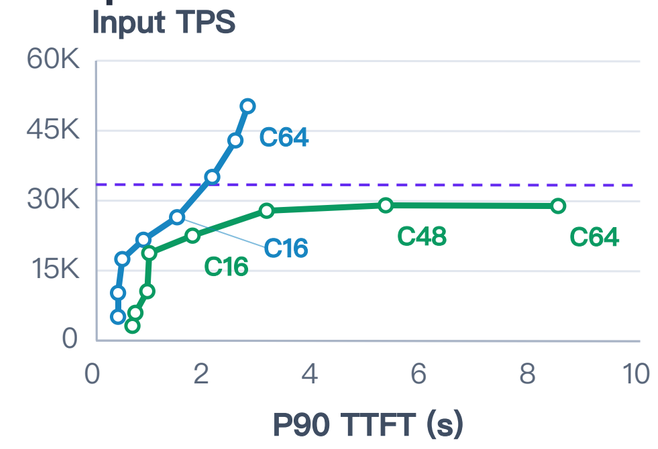
Source: Kimi K2.6 低带宽 Decode 曲线；输入 2K / 8K / 32K，输出 256 tokens，并发 1–64。单请求速度排除 TTFT。

网络受限时，Prefill 达到链路换算上限的 90.6%

20GbE 条件下实现 29K–30K Input TPS，接近链路可承载容量。

纯高算力设备 C　高算力设备 C + 高带宽设备 B　① 18.8Gb/s 实测 TCP goodput · 33,441 Input TPS

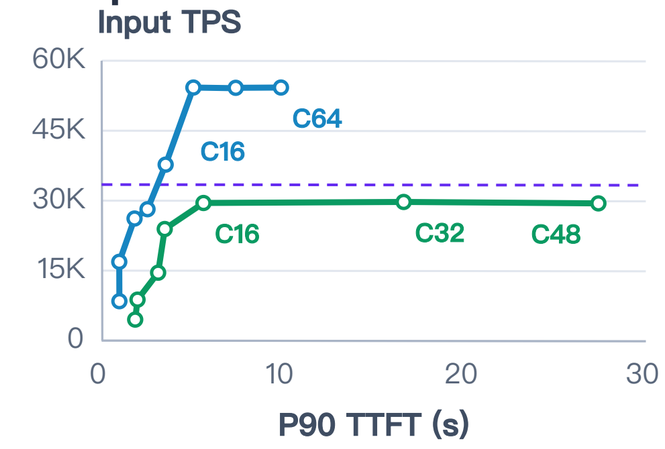
2K Input



30 s 内峰值 29,002

C48 · P90 TTFT 5.3 s

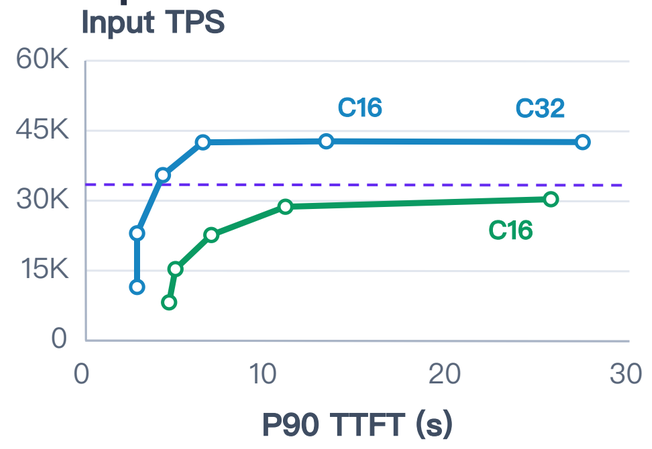
8K Input



30 s 内峰值 29,720

C32 · P90 TTFT 16.6 s

32K Input



30 s 内峰值 30,313

C16 · P90 TTFT 25.7 s

① P→D
网络上限计算

KV 数据量：70,272 B/token × 8 = 562,176 bit/token
链路实测：TCP goodput = 18.8Gb/s
18.8Gb/s ÷ 562,176 bit/token = 33,441 Input TPS

端到端峰值 / 链路上限
30,313 ÷ 33,441 = 90.6%

Source: Kimi K2.6 低带宽 Prefill 曲线、MLA KV 数据量及 TCP 链路测速。图中仅展示 P90 TTFT ≤ 30 s 的点。

跨机房异构 PD 已完成同园区与跨园区验证

跨园区实验接近同构吞吐，同园区低带宽实验接近链路容量，两组均保持高质量输出。

01

LONG CONTEXT

55K + 1K

长上下文验证成功

Input + Output tokens
10 / 10 请求成功

02

DECODE

54.6–65.5

高质量输出成立

三种输入长度的单请求输出速度均超过 Agent 速度门槛（40 token/s/req）

03

跨园区 · 充分带宽

约 50K

Prefill 吞吐接近同构

2K / 8K 峰值 Input TPS
100GbE · 跨机房 TCP 网络

04

同园区 · 带宽受限

90.6%

接近链路容量上限

30,313 Input TPS
20GbE · 18.8Gb/s goodput

CORE CHALLENGES

核心技术挑战

设备异构

KV 布局与设备内存不兼容

Host Mirror + MLA 布局转换

普通网络

机房间缺少共享 RDMA 通路

Mooncake TE TCP 跨机房传输

异步流水

KV 交付需与推理流水衔接

Readiness event 对齐计算完成

同园区与跨园区实验验证：Prefill 与 Decode 不必共址，仍能提供高质量 Token 服务。

Source: Kimi K2.6 3P1D 性能与长上下文验证。32K 高并发部分点存在窗口波动，不代表全部高压验证通过。

下一阶段验证更大规模的异构 PD 扩展

扩大 Prefill 与 Decode 资源池，验证聚合吞吐、资源配比与规模化服务质量。

EXPERIMENT EXPANSION

增大规模

从 3P1D 走向更大的异构 PD 集群

调整配比

验证不同 P:D 配比对 Input / Output 负载的适配

WHAT TO VALIDATE

验证更大规模的协同效率

01 **P:D 配比与负载适配**

不同业务负载下，两侧容量能否独立配置并充分利用

02 **资源扩展效率**

Input / Output TPS 是否随 P/D 资源池稳定增长

03 **规模化服务质量**

高并发下的 P90 / P99 TTFT 与 Interactivity 是否稳定

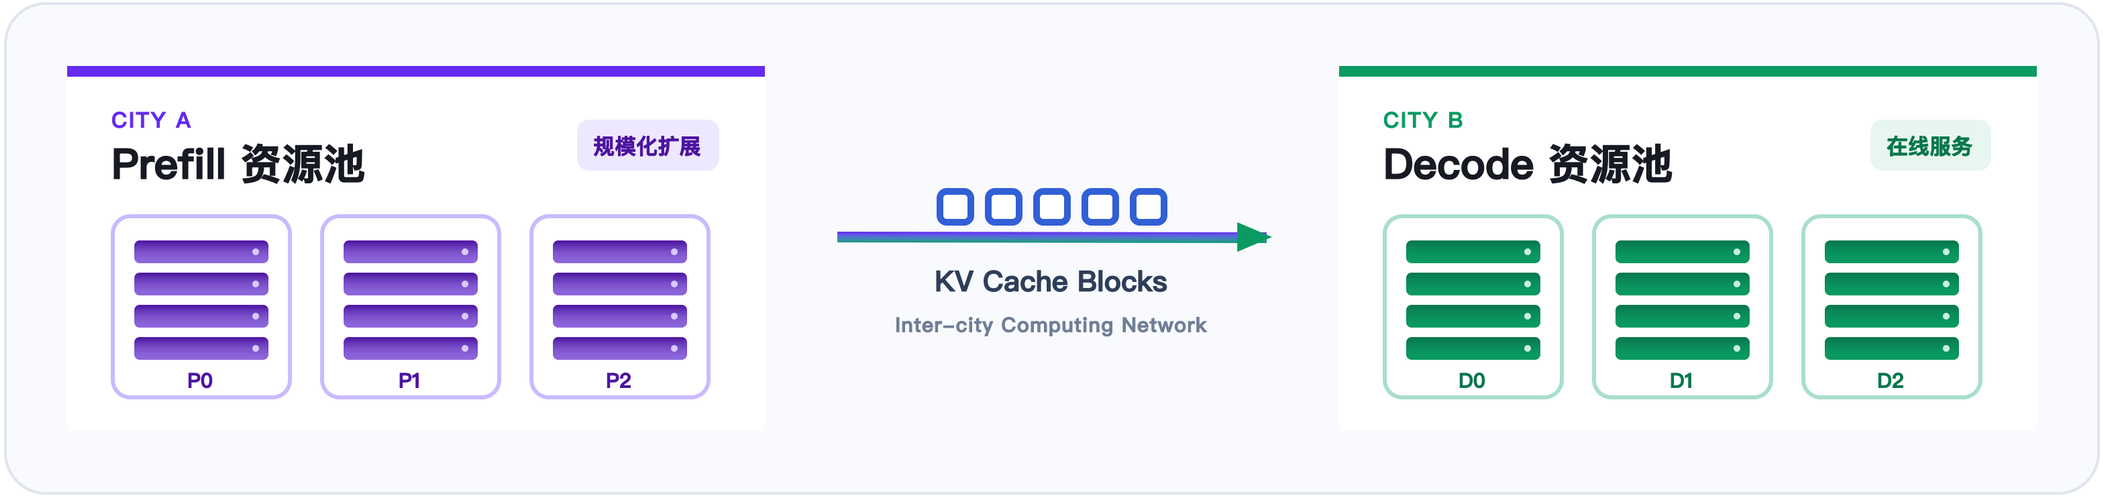
验证更大的资源池能否持续转化为更高吞吐，并保持高质量 Token 服务。

Plan: validate larger-scale heterogeneous PD with more Prefill and Decode resources and multiple capacity ratios.

CHAPTER 06

跨区域 PD 分析

从跨机房实验走向跨城算力网络



第三个问题：P 与 D 位于不同区域时，需要多大持续带宽，传输长尾应控制到什么程度?

跨城网络承载多个请求的 KV Cache Block 流

每个 Request 对应一组 KV Cache Block；多个 Prefill Pool 的请求流在 P→D 链路上持续汇聚。

MULTIPLE PREFILL POOLS

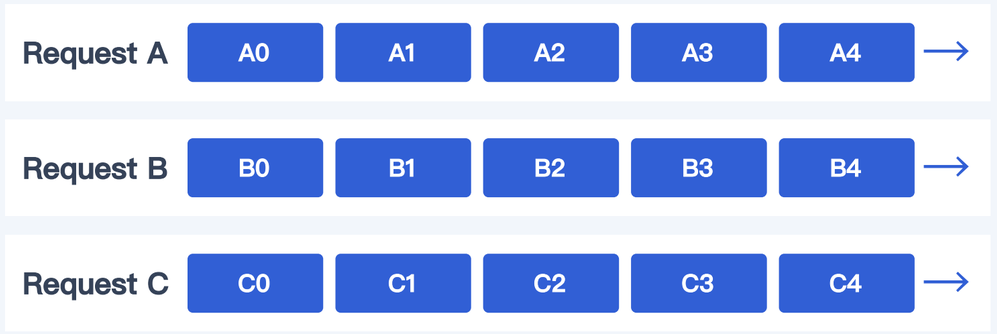
Prefill 资源池

P0 · P1 · P2 · …

持续完成请求的 Prefill 计算

CROSS-REGION P→D NETWORK

Request-scoped KV Cache Block Flow



示意图中 Block 大小一致；链路同时承载多个请求的 KV 数据流。

DECODE POOL

按请求接收 KV

Request A	KV Ready
Request B	KV Ready
Request C	KV Ready

KV 到齐后启动 Decode；Output Token 在 D 侧生成。

AGGREGATE P→D PAYLOAD GOODPUT Σ Prefill Input TPS × KV bytes / input token

Source: Prefill-as-a-Service workload model; KVCache.AI KV Cache Size Calculator.

跨城 PD 需要足够带宽和受控长尾，但不追求极低平均延迟

满足带宽、平均延迟和传输长尾目标即可；底层无需提供 RDMA 语义。

NETWORK DIMENSION	业务要求	实验依据与原理
01 Bandwidth	**足够 Payload Goodput** 网络排出速度至少匹配聚合 KV 产生速度，避免排队封顶 Input TPS。	**受限带宽实验：接近链路上限** 18.8Gb/s 对应 33.4K Input TPS 实测 30.3K，达换算上限 90.6%
02 Average Latency	**可容许较高平均传输延迟** 计算与传输流水重叠；可容许范围由 TTFT 目标决定。	**平均延迟不是首要约束** 流水隐藏重复等待，但末批传输仍进入 TTFT
03 Completion Tail	**控制 KV 传输长尾** 最后一批必要 KV 的到达时间决定 Decode 启动，并进入 P90 / P99 TTFT。	**P90 TTFT：同构的 1.9–2.4×** 网络受限实验的端到端观察
04 Network Semantics	**满足性能目标即可，无需 RDMA 语义** 传输接口只需稳定完成请求级 KV Cache Block 交付。	**两种网络条件均由 TCP 承载** Mooncake TE TCP；长上下文 10/10 成功

Source: 第五章实验。P90 倍数为网络受限条件的端到端观察，未分离纯网络贡献；平均延迟一行为流水原理推论。

跨区域带宽需求可由 Prefill 产能和模型结构直接计算

Prefill TPS 决定流量规模，KV bytes/token 决定模型系数；所有 Prefill Pool 使用聚合产能。

P→D PAYLOAD GOODPUT　Σ Prefill Input TPS × KV bytes / input token

模型与 KV 结构	KV bytes / input token	相对 KV 强度	30K Input TPS 对应 Payload Goodput
MLA · 实验模型 Kimi K2.6	70,272 B/token	1.00×	16.87 Gb/s
KDA + MLA Kimi K3	31,076 B/token	0.44×	7.46 Gb/s
HYBRID SPARSE · BF16 DeepSeek V4 Pro	9,909 B/token	0.14×	2.38 Gb/s

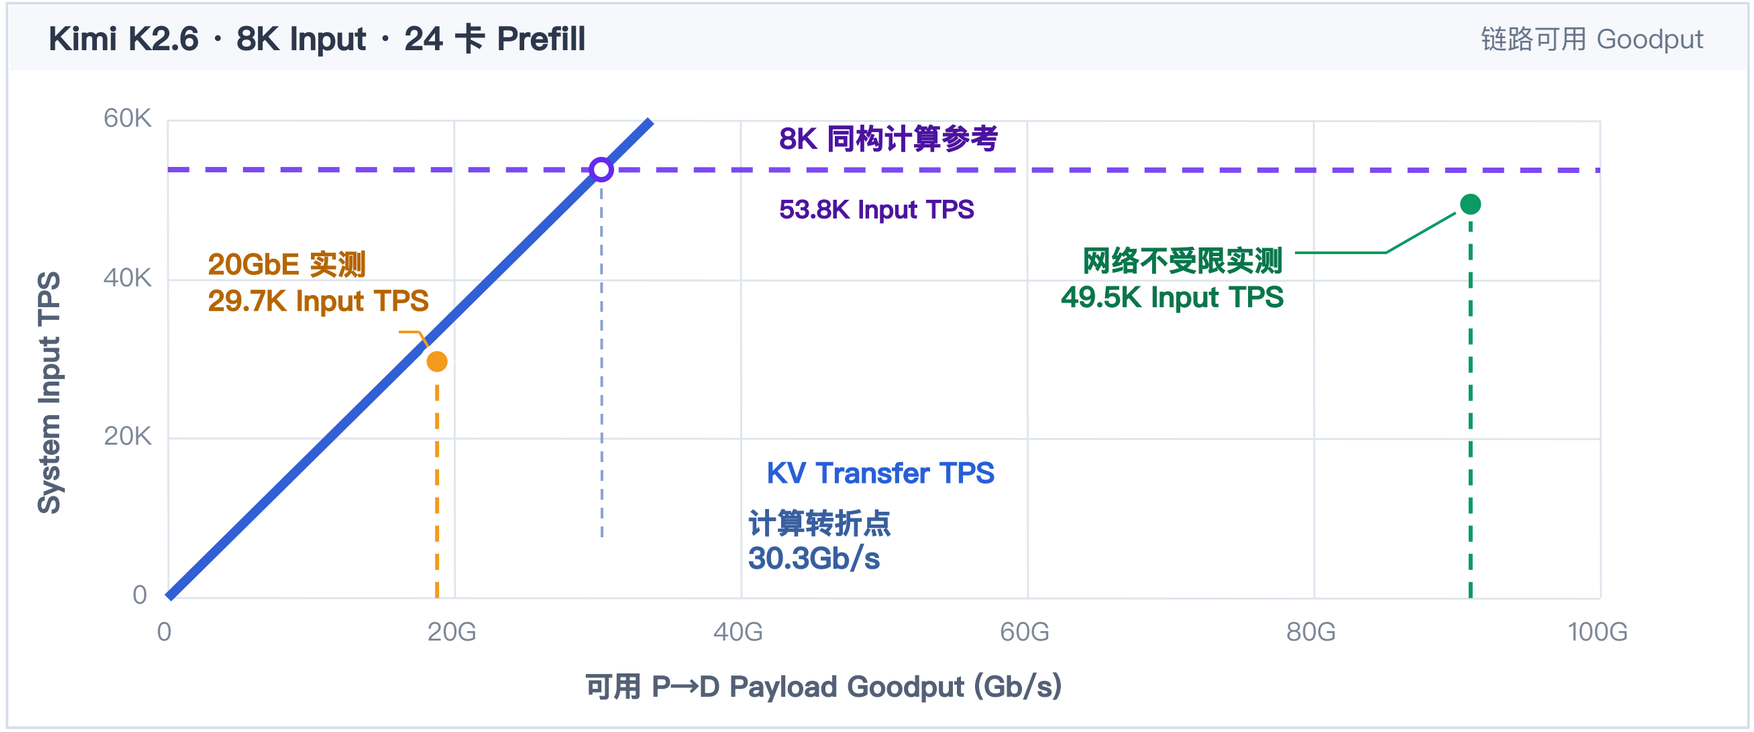
物理链路容量应高于 Payload Goodput　为协议开销、重传和容量波动预留余量。

Source: KVCache.AI and official model configs; 128K context, BF16-normalized cache; Kimi K2.6 value verified by transfer logs.

跨区域 PD 吞吐由 Prefill 计算与 KV 传输两条容量上限共同决定

随着 P→D Goodput 提升，系统先受 KV 传输限制；进入转折区后，吞吐逐步触及 Prefill 计算上限。

CAPACITY ENVELOPE **System Input TPS = min（Prefill Compute TPS，KV Transfer TPS）**



PIPELINE OVERLAP

计算与传输流水重叠

Chunk 计算与 KV 传输重叠，端到端时间并非两者简单相加。

NETWORK-LIMITED

受限网络下接近传输上限

可用 Goodput · 18.8Gb/s
换算上限 · 33.4K Input TPS
8K 实测 29.7K · 上限的 88.9%

COMPUTE CAPACITY

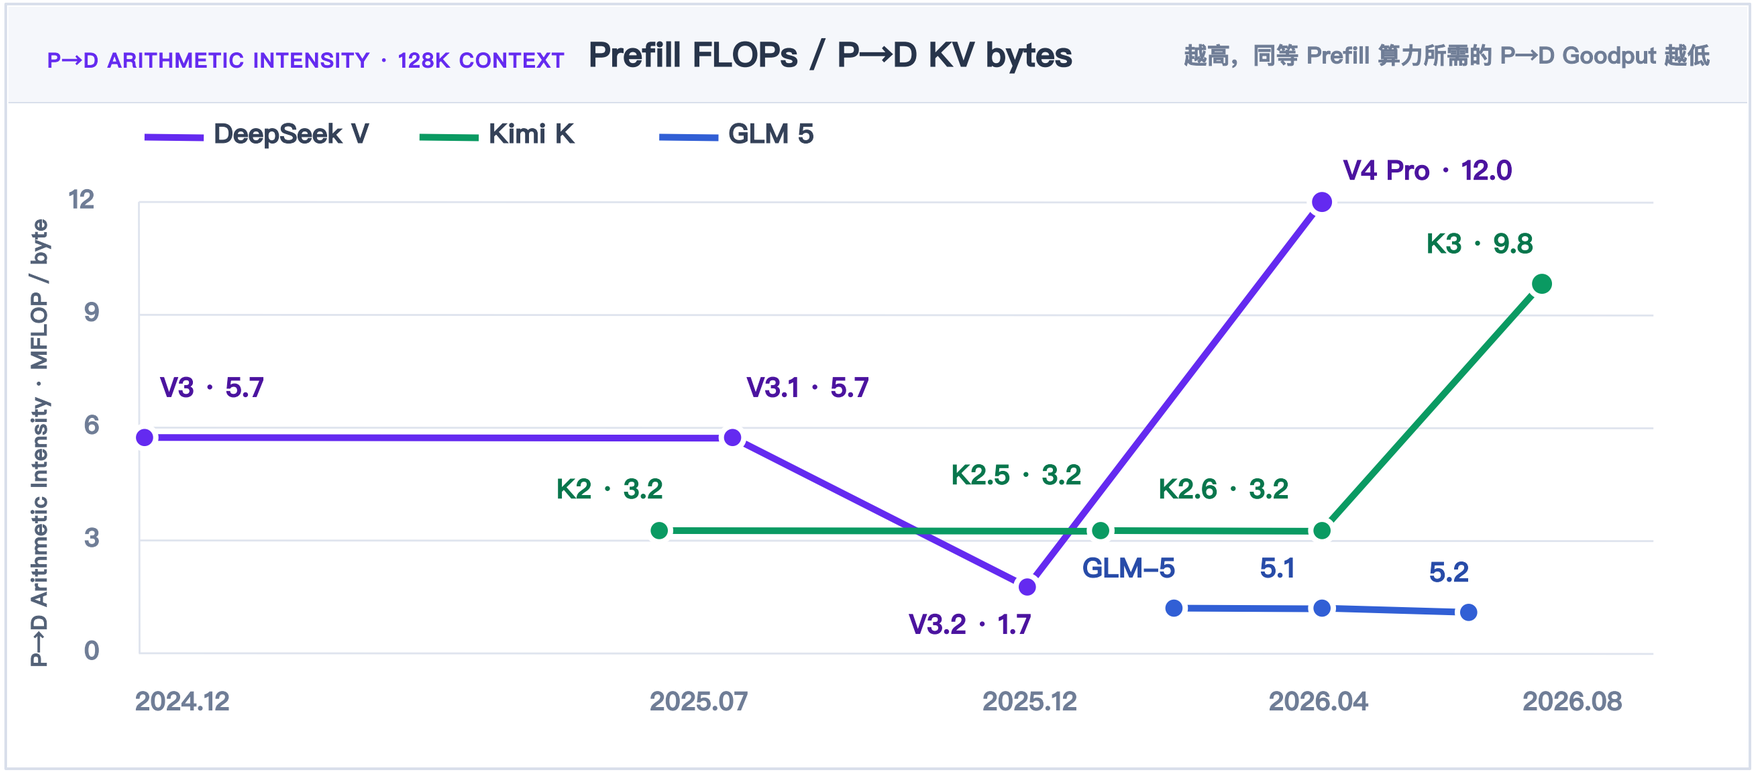
网络不受限时接近计算产能

8K 实测 49.5K Input TPS。
同构计算参考：53.8K Input TPS。

Source: Kimi K2.6 · 8K Input · 异构实测与同构计算参考。两组为独立实验，统计口径有差异。
横轴为链路可用 Goodput；90.95Gb/s 来自链路测速，并非压测期间的 KV 流量。

新模型提高 P→D Arithmetic Intensity，降低带宽需求

P→D Arithmetic Intensity = Prefill FLOPs / P→D KV bytes；越高，同等 Prefill 算力所需带宽越低。



OPEN-WEIGHT EXPANSION

≥ 500B 开放权重继续扩围

这些系列目前只有一个旗舰点进入 ≥500B 区间，因此不做连线。

- **Qwen3.8-2.4T-A95B**
  2.45T total params
- **MiMo-V2.5-Pro**
  1.02T total params
- **Mistral Large 3**
  675B total params

两个明确跃迁

Kimi K2.6 → K3
DeepSeek V3.2 → V4 Pro

新架构显著提高单位 KV 的 Prefill 计算强度

P→D Arithmetic Intensity 越高，支撑同等 Prefill 计算性能所需的网络带宽越低。

Source: official Hugging Face model cards/configs; KVCache.AI; 128K estimates in references/recent-model-prefill-kv-128k.md. V4 Pro uses BF16-normalized cache.

SUMMARY · KEY TAKEAWAYS

PD 分离让高质量 Token 服务走向设备异构、跨机房协同与跨区域部署

高质量 Token 服务 = 模型能力 + 交付质量；KV Cache handoff 解耦 Prefill 与 Decode。

DEVICE · 已上线

设备异构

高算力设备支撑高质量 Token 服务

高算力设备承担规模化 Prefill
高带宽设备集中保障 Decode

SITE · 已实测

跨机房协同

同园区与跨园区均完成验证

Prefill 约 50K Input TPS
低带宽下达到链路换算上限 90.6%

REGION · 可规划

跨区域拓展

网络容量与传输长尾可以定量设计

带宽需求由模型与 Prefill 产能换算
满足性能需求即可，无需 RDMA 语义

OUR DIRECTION

让合适的设备在合适的位置，共同提供高质量 Token 服务

Mooncake 基础设施 → 异构 PD 商业生产 → 跨机房实验验证 → 跨区域算力网络