GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



GOSIM

GOSIM Shenzhen 2026

vLLM系统级扩展
从网络 I/O 到分布式调度

皮振伟 <pizhenwei@tensorfer.com>



CONTENTS

Part 01 GPU Direct Distributed File System

Part 02 模型权重极速加载

Part 03 无状态化推理

Part 04 推理系统优化



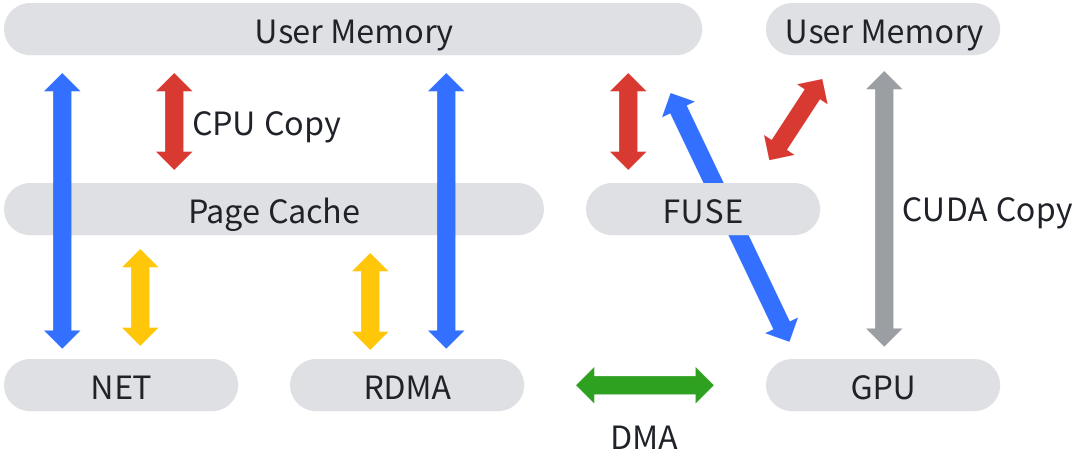
01

GPU Direct Distributed File System



	GPU	DDR5	网卡	NVMe
吞吐	2TB/s * 8 = 16TB/s	8 channels ~300GB/s	400Gbps * 4 = 200GB/s	W 2GB/s * 4 = 8GB/s R 6GB/s * 4 = 24 GB/s
延迟	~100+ ns	~80+ ns	1K RDMA ~2us 1K TCP ~6us	4K Write ~20us 4K Read ~80us

- AI场景下的主要运算发生在GPU，数据的读取、写入过程中，NVMe是性能瓶颈。
- 内存带宽和网卡性能接近，网络IO场景中，内存复制可能成为性能瓶颈
- 内存扩展空间受限，成本高



- GPU Direct RDMA（绿色）：性能最好，GDS部分支持和GD2FS
- 用户态文件系统（蓝色）：libnfs、libcephfs等
- 内核态文件系统（黄色）：NFS、SMB等
- FUSE based文件系统（红色）：性能最差，通用性好

25ms 100x

- 面向GPU设计的全新的分布式文件系统
- 400G 网卡 · 1GB KV Cache 读写延迟25ms
- 延迟约为Redis的1%

全程零拷贝

GPU — RDMA NIC — 远端存储

CPU/Host Memory bypass，GPU 显存直接通过 RDMA 读写远端存储，客户端与服务端均 zero-copy

存储分层

高性能池 · 1 副本

存储可重计算的KV Cache

高可用池 · 3 副本

存checkpoint等关键数据

缓存弹性副本

R1 — R2 — R3

副本策略与数据可重算性解耦
按需 1 副本或 3 副本，按数据价值弹性配置



02

模型权重极速加载



torch.zeros(SHAPE, dtype=DTYPE, device=CPU)

- Tensor的元信息
- Tensor的data_ptr()内存被实际分配
- 分配速度慢

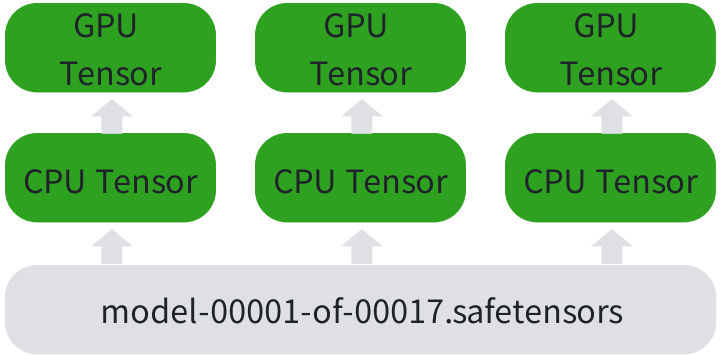
torch.empty(SHAPE, dtype=DTYPE, device=CPU)

- Tensor的元信息
- Tensor的data_ptr()内存没有实际分配，CPU访问的时候产生Page Fault
- 分配速度快

safetensors格式

- 8字节表示JSON控制信息长度
- JSON控制信息
- 权重数据

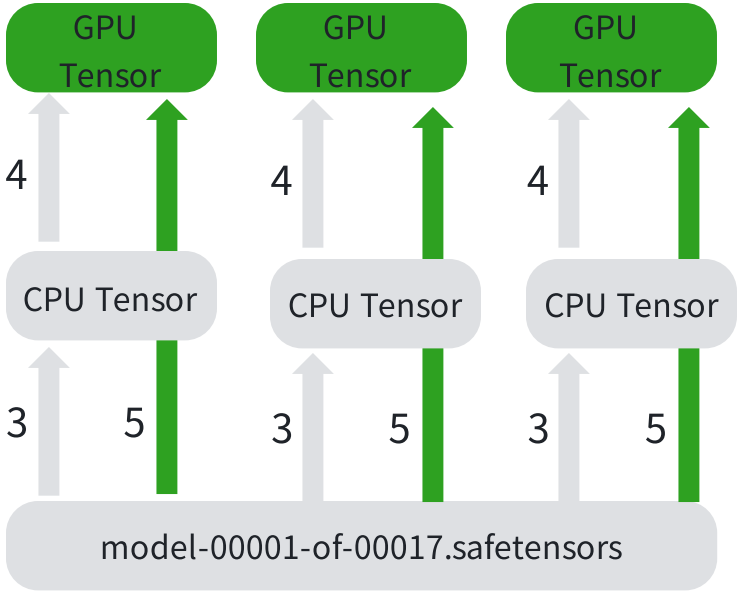
vLLM启动阶段，解析safetensors格式的权重文件，读取到CPU Tensor中，再从CPU Tensor复制到GPU Tensor



- 模型权重文件存放到GD2FS中
- 执行readahead，预热模型权重

vLLM使用GD2FS用户态客户端

1. 执行list请求获取所有的safetensors文件列表
2. 并发读取safetensor的meta信息
3. 使用torch.empty分配Tensor，并记录权重所处的偏移、长度等信息，不发生真正的数据读取
4. 重载CPU Tensor复制到GPU Tensor的函数
5. 触发远程的权重数据直接写入到GPU Tensor中，此过程是异步、并发的
6. 等待全部的数据读取请求完成

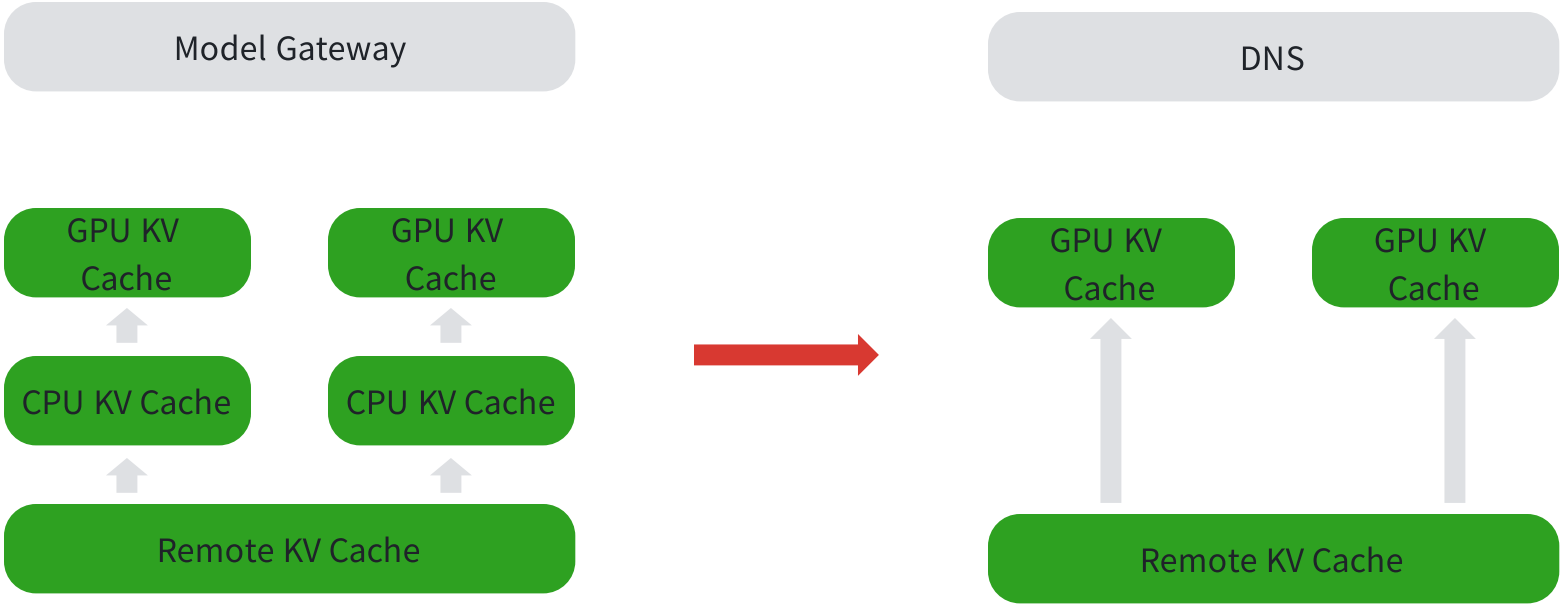


Qwen3-32B(62GB)模型加载时间**<3s**

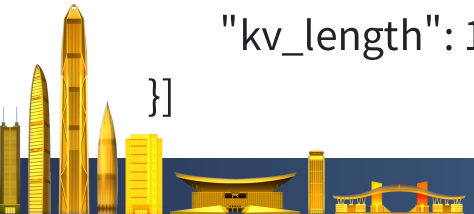
03

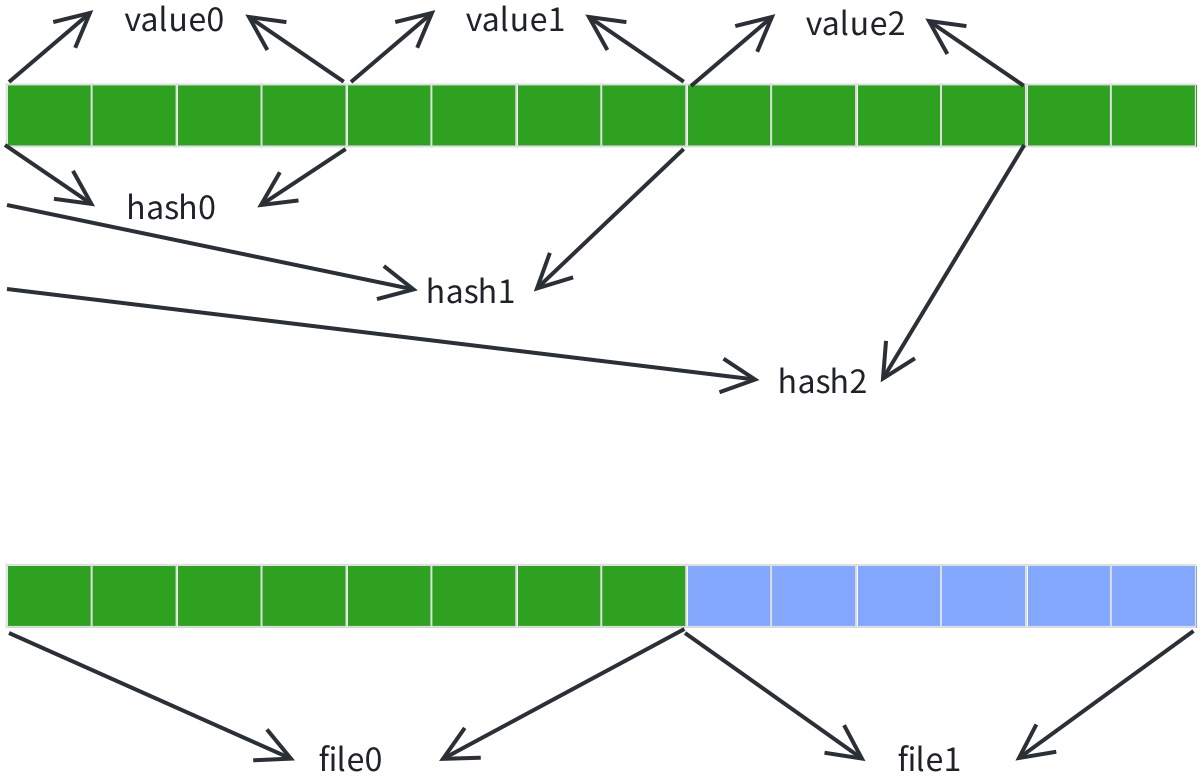
无状态化推理

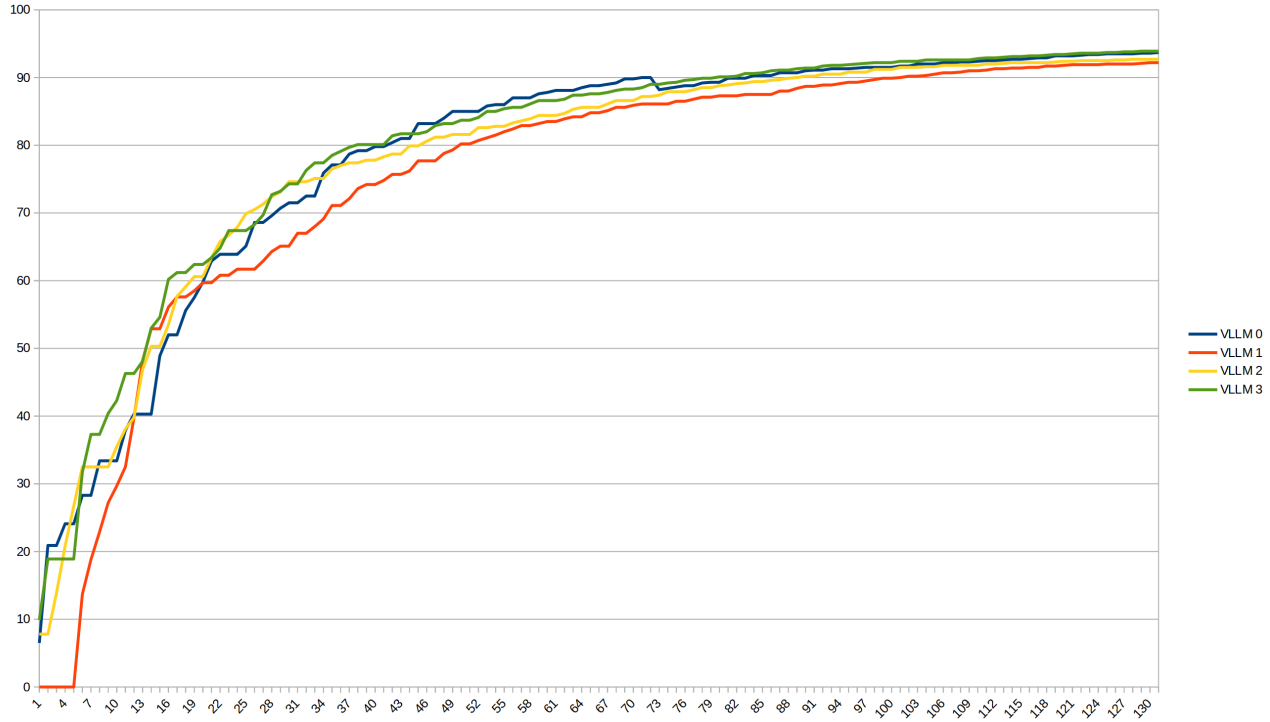



Model Gateway
GPU KV Cache
GPU KV Cache
CPU KV Cache
CPU KV Cache
Remote KV Cache
DNS
GPU KV Cache
GPU KV Cache
Remote KV Cache

```
"stored_kv_cache": [{
    "token_start": 0,
    "token_length": 8192,
    "kv_uri": "gd2fs://cluster-01/session-97f1226c-..."
    "kv_start": 0,
    "kv_length": 134217728
}],
"fresh_kv_cache": [{
    "token_start": 8192,
    "token_length": 8192,
    "kv_uri": "gd2fs://cluster-01/session-97f1226c-..."
    "kv_start": 134217728,
    "kv_length": 134217728
}]
```

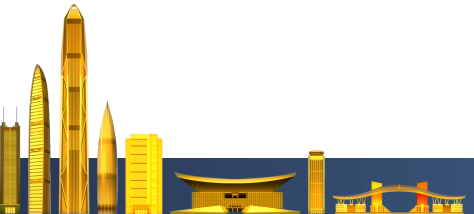




value0
value1
value2
hash0
hash1
hash2
file0
file1



4个vLLM实例共享GD2FS存储服务，5K-15K初始输入，10轮会话，每轮新增2K。60个会话随时间（横轴每10s），KV Cache命中率变化（纵轴）

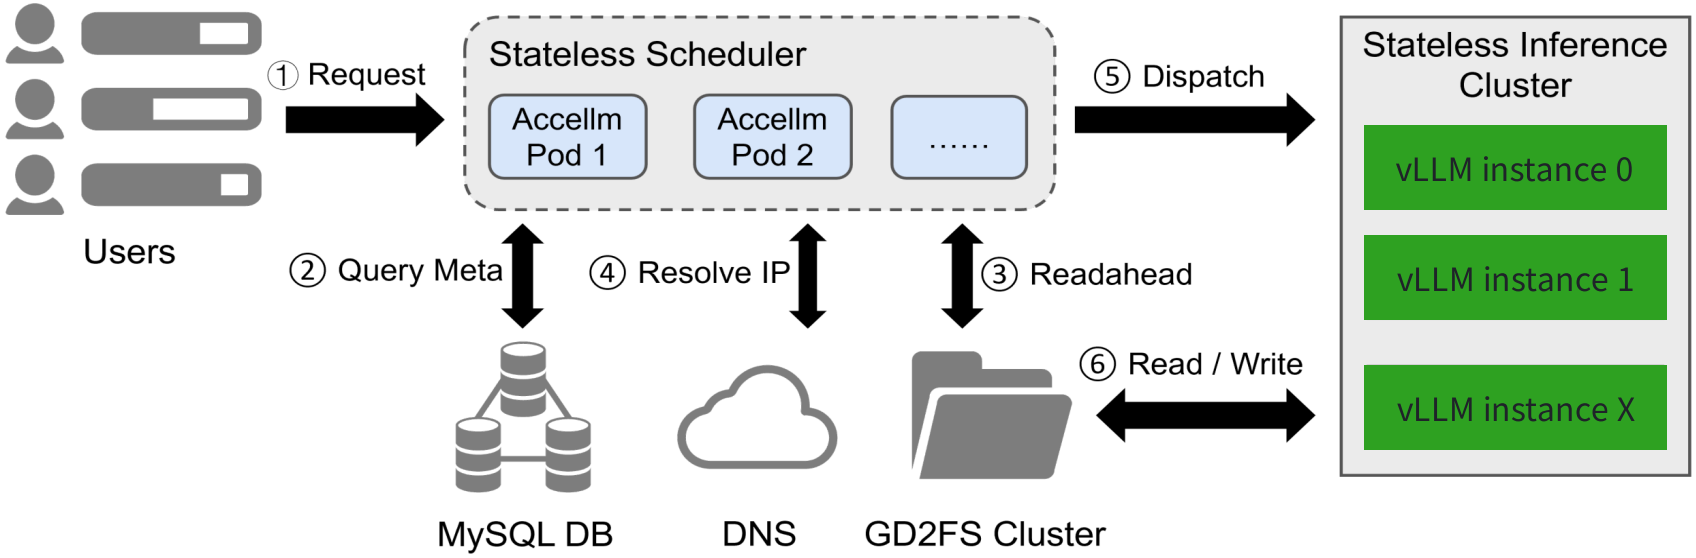
- KV Cache的控制信息和数据分离，历史会话100%命中
- 生命周期管理
- 高级容量控制
- 支持更多的业务策略
- 性能/成本可预期，在请求处理前获取：Cached、To prefill、To Decode的Token数量，能够做出更优的决策（PD分离、KV Cache预读）

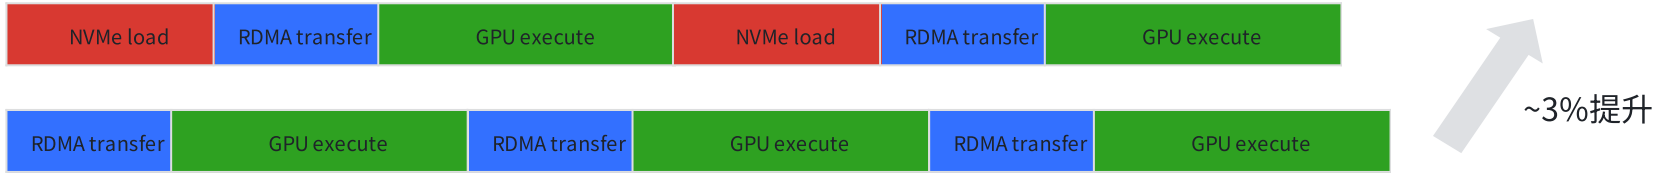


04

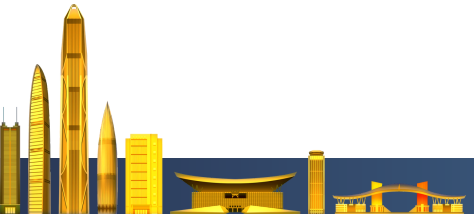
推理系统优化




Users
① Request
Stateless Scheduler
AccelIm Pod 1
AccelIm Pod 2
……
⑤ Dispatch
Stateless Inference Cluster
vLLM instance 0
vLLM instance 1
vLLM instance X
② Query Meta
④ Resolve IP
③ Readahead
⑥ Read / Write
MySQL DB
DNS
GD2FS Cluster


NVMe load
RDMA transfer
GPU execute
NVMe load
RDMA transfer
GPU execute
RDMA transfer
GPU execute
RDMA transfer
GPU execute
RDMA transfer
GPU execute
~3%提升

- TPOT在阈值内，Decode Batch越大越好，集群的平均吞吐越高
- waiting request/defered request对业务的性能有致命影响
- 显存容量永远都是临界资源。HBM的工艺问题、显存足够则可以降低服务器的数量
- 如何尽量增大Decode Batch，同时避免waiting request/defered request?
  - 调度器不做集中计算，集群规模、计算延迟
  - 推理请求增加no-wait参数，vLLM增加OOM Finish Reason
  - 基于DNS的请求重试



GOSIM

GOSIM Shenzhen 2026

Thanks!

联系我们 <support@tensorfer.com>

