GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China

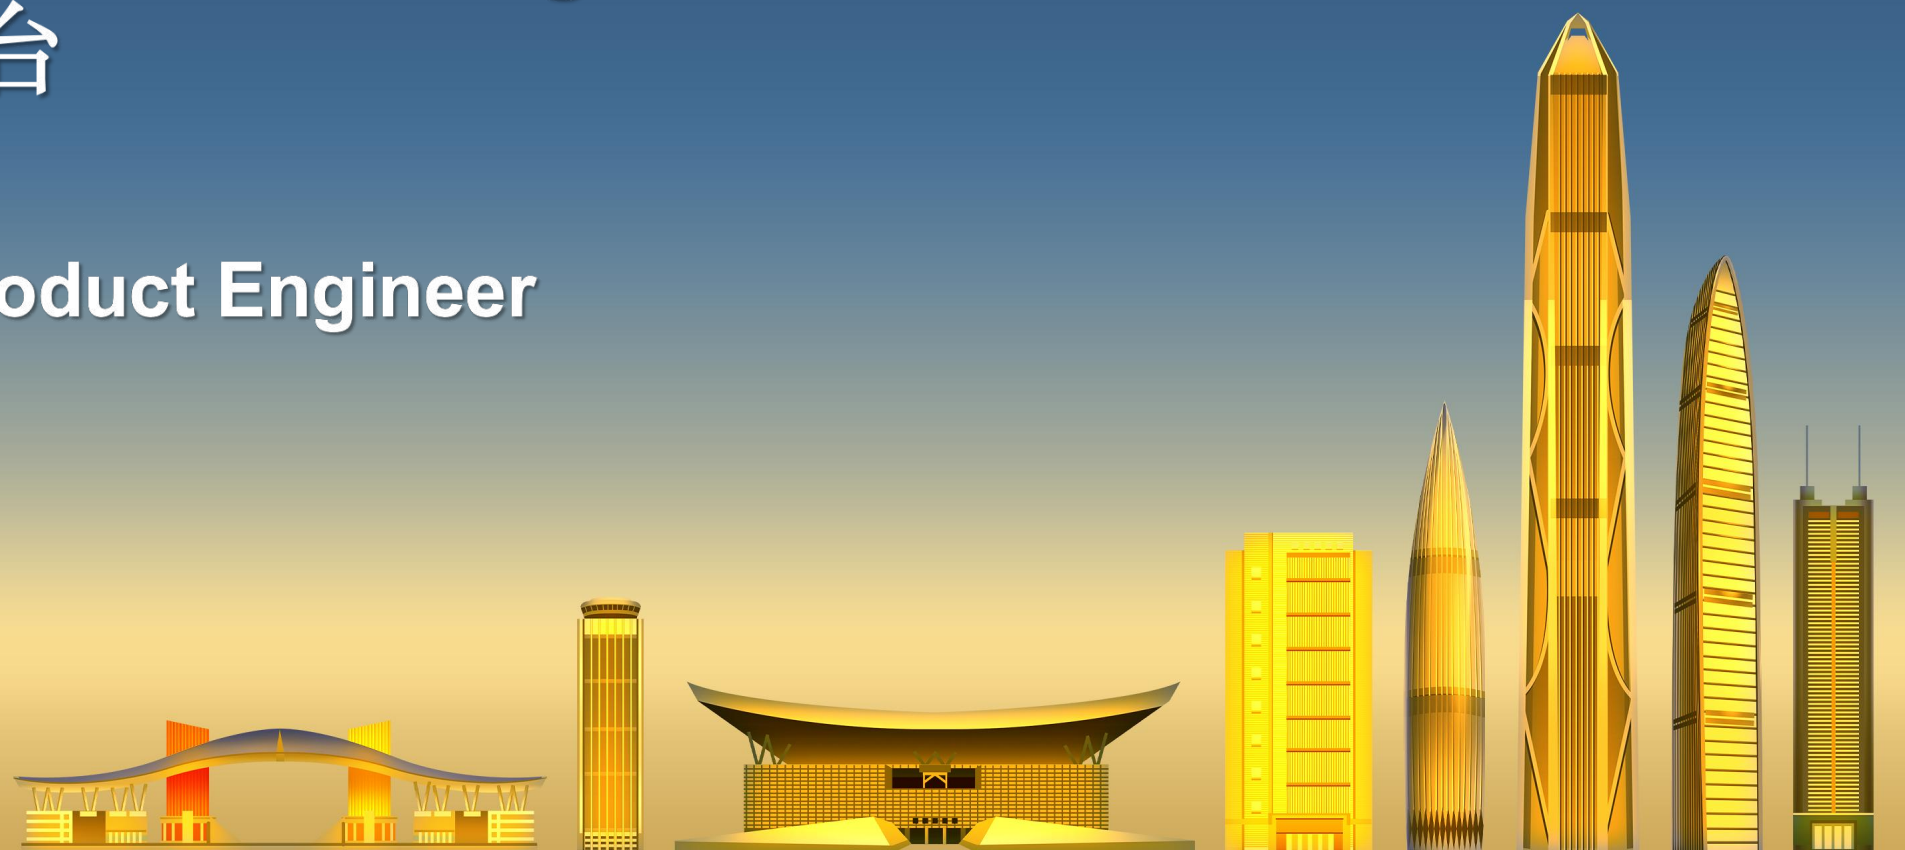


GOSIM

GOSIM Shenzhen 2026

深入ROCm 10.0：面向 Agentic AI 的开放 GPU 软件平台

蔡薇 · AMD Product Engineer



CONTENTS

Part 01 Agentic AI 时代：GPU 软件平台为什么需要进化

Part 02 ROCm 10.0：开放、模块化、AI-native

Part 03 ROCm.AI：从 Agent Skills 到自主推理优化

Part 04 AMD 开发者生态：从技术探索到实践落地



Agentic AI 对 GPU 软件平台提出双重要求

动态的推理负载与复杂的开发流程，推动 GPU 软件平台同时进化两类能力。

Inference Runtime

高效 AI 推理运行

动态与高并发请求

Dynamic Scheduling · Continuous Batching

长上下文与状态管理

KV Cache · Prefix Reuse · Memory Efficiency

低延迟与高吞吐

TTFT · TPOT · P99 · Throughput

AI-Native Development

AI 驱动的开发与优化

自动化部署与环境诊断

Deployment · Environment Diagnostics

AI Agents 理解 GPU 软件栈

Agent Skills · Developer Tools

自动性能分析与优化

Profiling · Optimization · Validation

GPU 软件平台需要同时提升运行效率与 AI 原生开发体验

Efficient AI Execution + AI-Native Developer Experience



ROCm 10.0：从开放软件栈到 AI-native 开发平台

开放、模块化的 GPU 计算基础设施 + AI 驱动的开发与优化体验

OPEN & MODULAR SOFTWARE STACK

Open AI Ecosystem
Models · PyTorch · vLLM · SGLang

ROCm Core SDK
Libraries · Compilers · Tools · Runtimes

Toolkits / Deployment & Ops
Modular Toolkits · Deployment & Operations

AI-NATIVE DEVELOPMENT EXPERIENCE

AMD Skills
Agent-ready ROCm knowledge & workflows

Hyperloom
AI-assisted end-to-end optimization

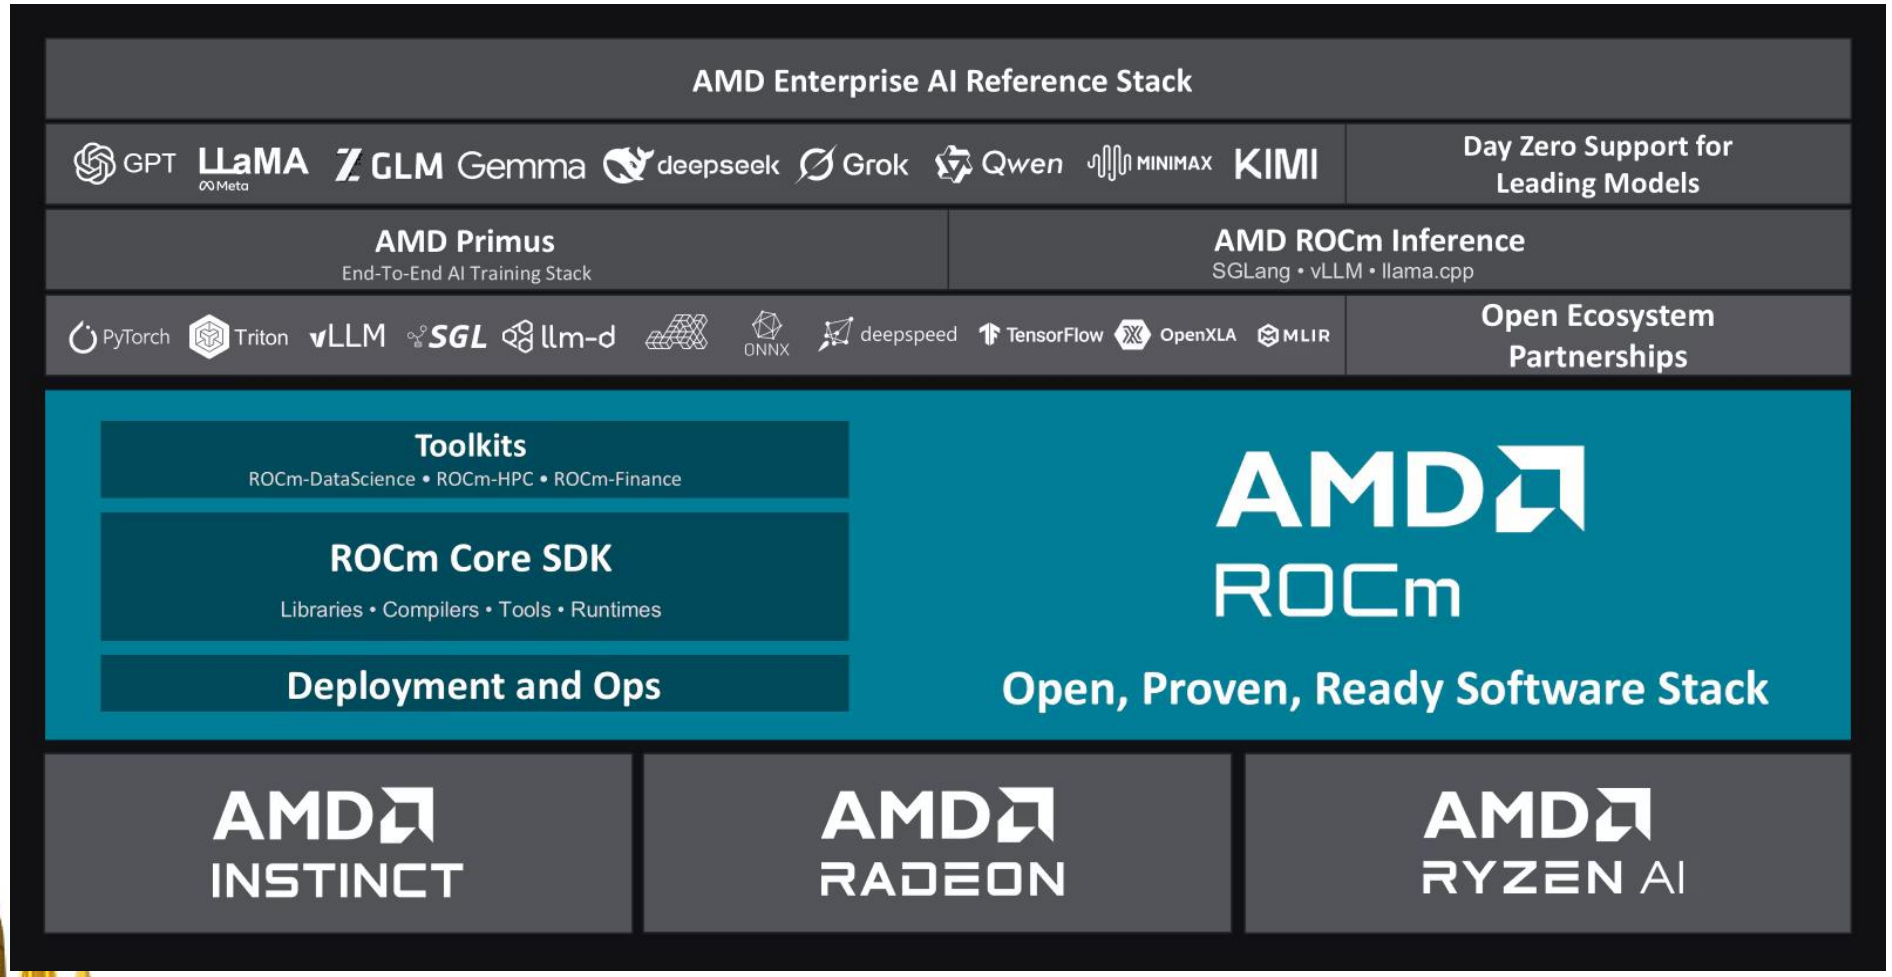
ROCm CLI / TUI / Console
Unified Interface · Diagnostics · Development Tools

Efficient AI Execution + AI-Native Developer Experience

ROCm Core 与开放生态支撑运行基础 | ROCm.AI 让 AI Agents 参与开发和优化

开放、模块化：ROCm Core 与开放生态

从主流模型、AI 框架与推理引擎，到 Core SDK、部署与硬件的开放软件栈



THREE KEY LAYERS

01 **开放模型与框架**

主流模型、PyTorch、Triton、vLLM、SGLang 等生态

02 **ROCm Core SDK**

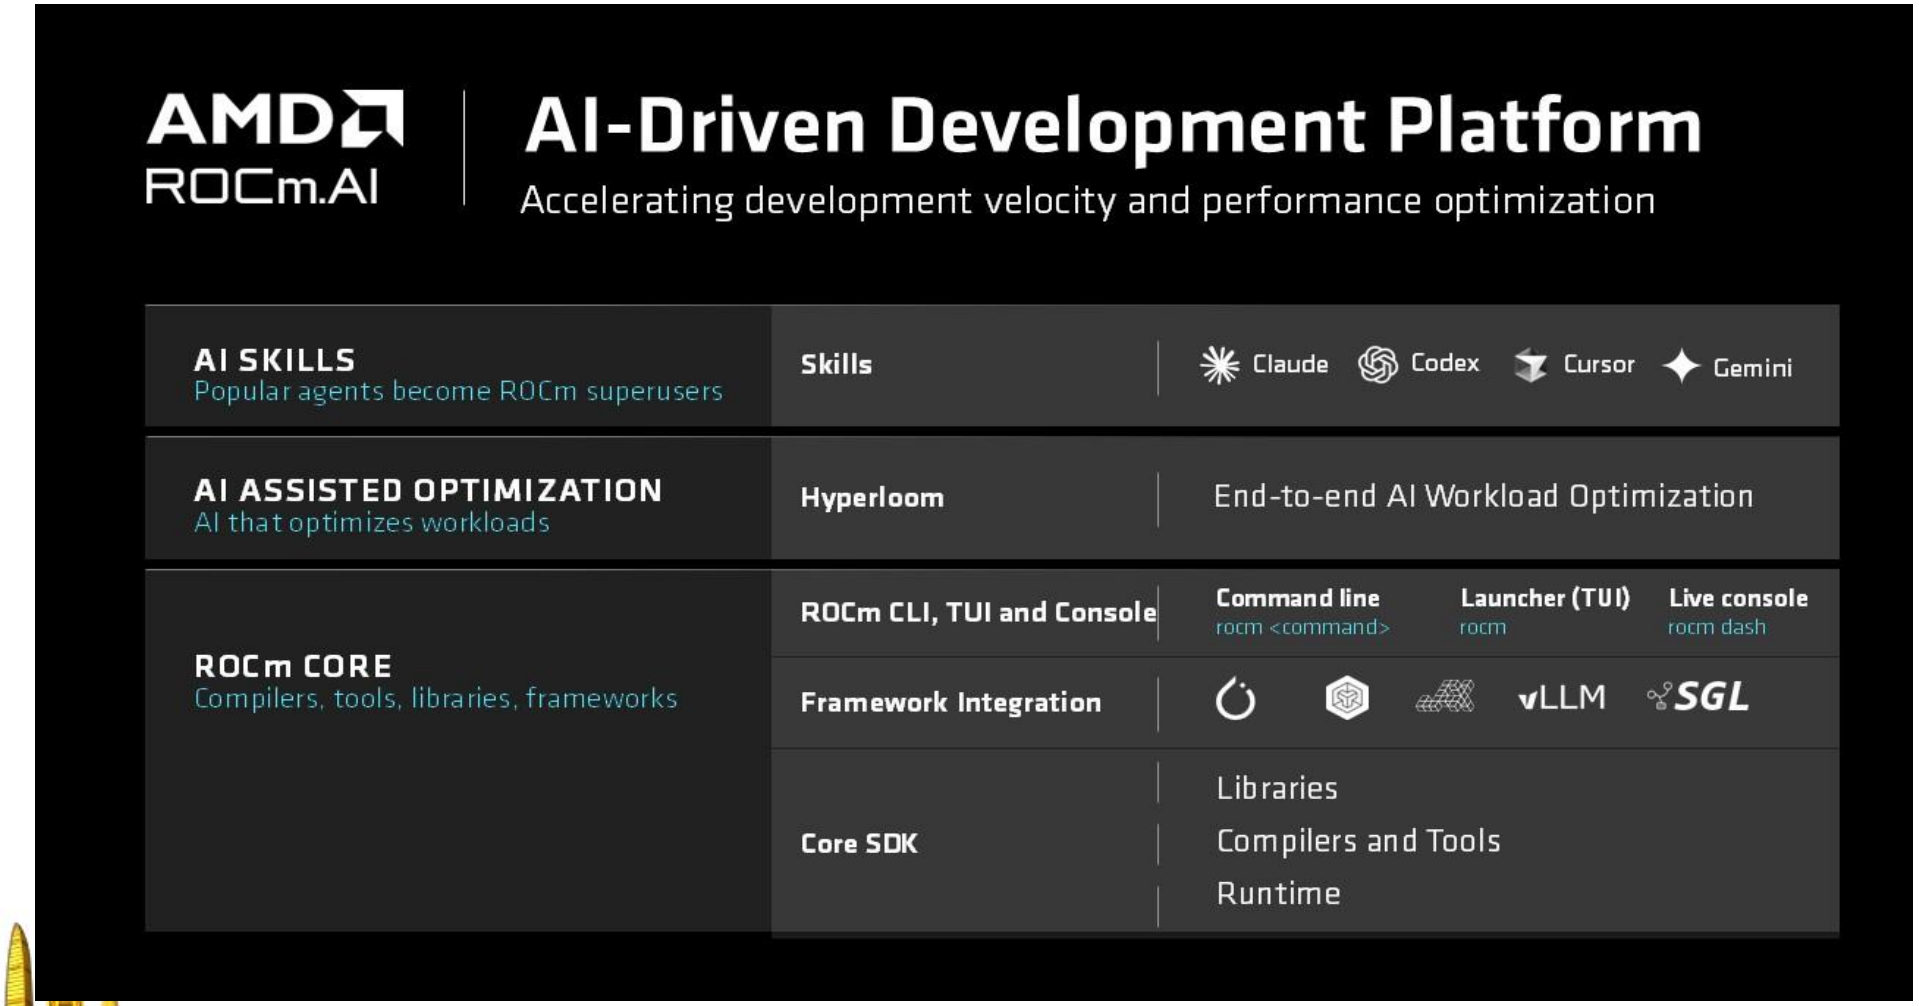
Libraries · Compilers
Tools · Runtimes

03 **部署与硬件基础**

Toolkits / Ops
Instinct · Radeon · Ryzen AI

AI-native：ROCm.AI 如何提升开发与优化效率

让 AI Agents 参与 GPU 软件开发，将部署、诊断与性能优化连接为统一工作流



THREE KEY CAPABILITIES

01 AMD Skills

让 Claude、Codex 等 AI Agents 更易使用 ROCm

02 Hyperloom

面向端到端 AI 负载的性能分析与优化

03 ROCm 开发工具

CLI / TUI / Console 框架集成与 Core SDK

AI 驱动的开发与优化体验

AMD Skills：让 AI Agents 理解与使用 ROCm

将经过 AMD 验证的 ROCm 知识与工作流提供给主流 AI Coding Agents

AI Coding Agents · Claude Code · Cursor · Codex

AMD Skills · Agent Skills Format

01 rocm-doctor

ROCm 环境诊断与故障排查
通过 ROCm CLI 的 rocm examine

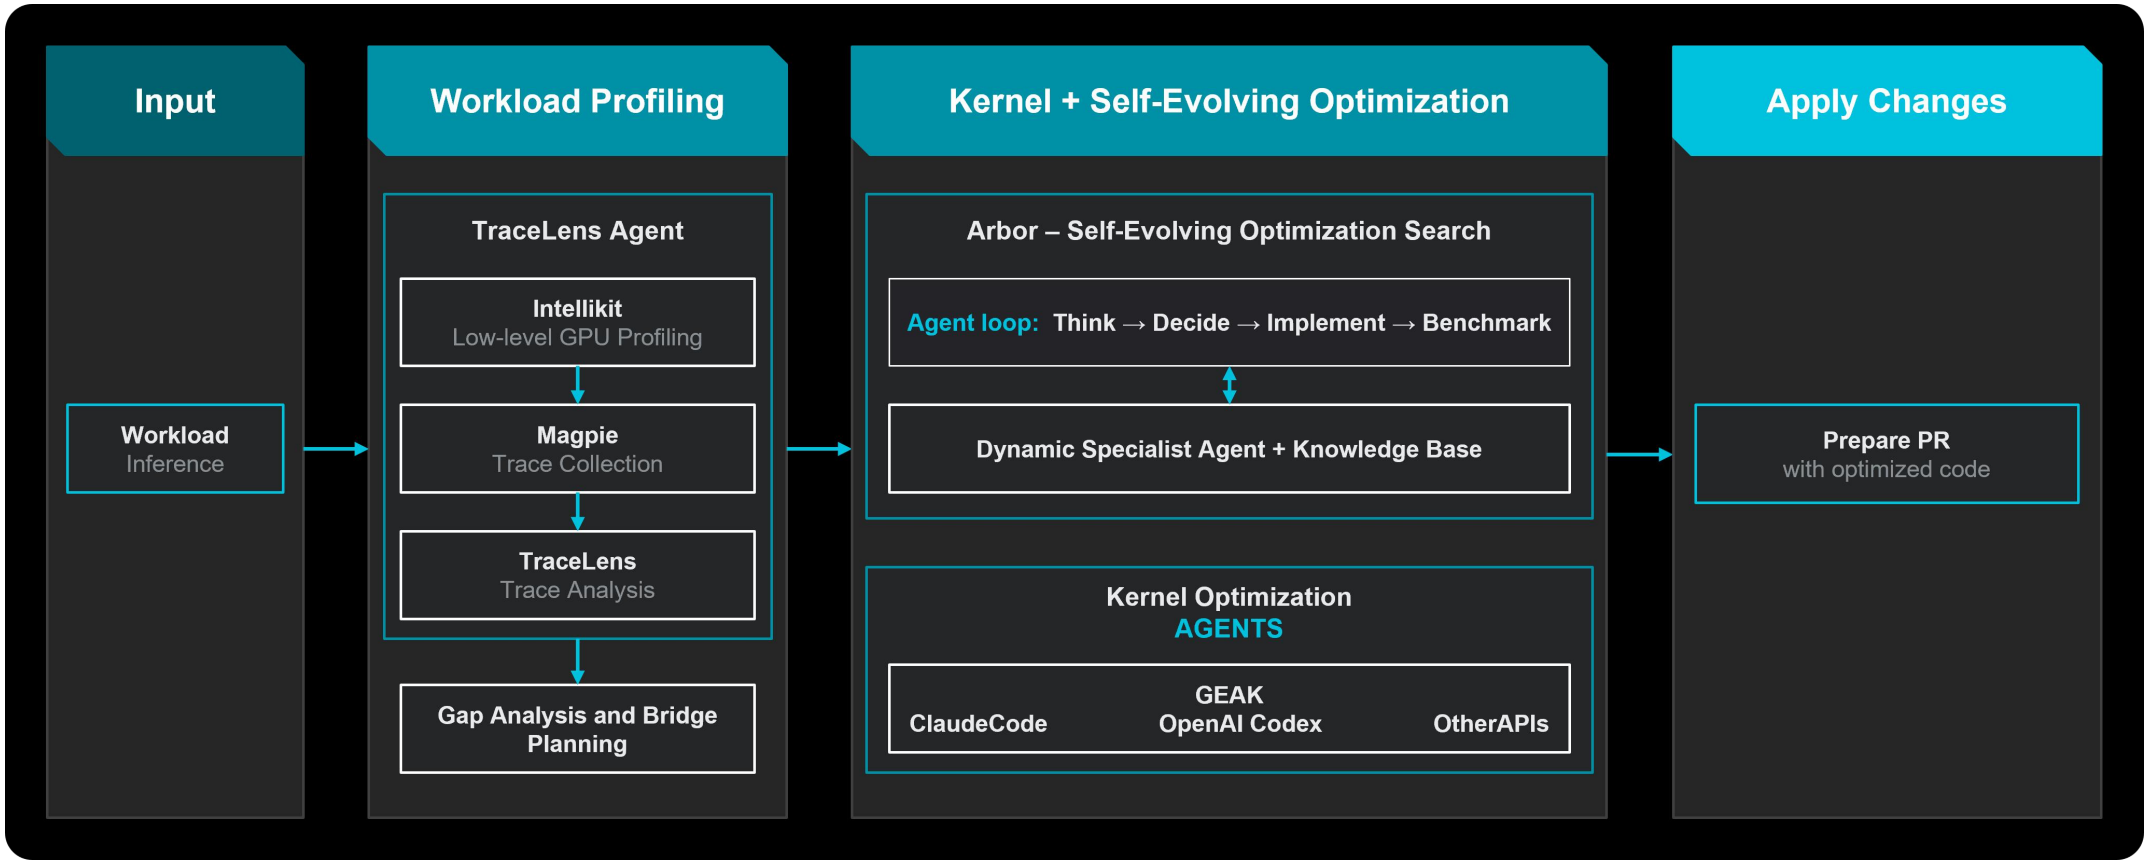
02 serving-llms-on-instinct

指导部署兼容 OpenAI API 的 vLLM 服务
面向 AMD Instinct GPUs

ROCm Software Platform · Diagnostics · LLM Serving

ROCm Hyperloom：Agentic AI 驱动的端到端推理优化

From Workload Profiling to Self-Evolving Optimization



Workload Profiling → Bottleneck Analysis → Agentic Optimization → Apply Changes

vLLM on ROCm：Hyperloom 如何优化端到端推理

一个工作负载，两层优化，统一验证

vLLM Inference Workload

Model · Serving Config · Concurrency · Sequence Length

01 MEASURE

Baseline & Profiling

测量当前推理性能
识别主要瓶颈与优化空间

→

02 OPTIMIZE ACROSS THE STACK

Framework

Serving & Execution Serving Config · Batching · Attention

GPU Kernels

Kernel Optimization Kernel Implementation · Compute & Memory Efficiency

→

03 VALIDATE

End-to-End

重新测量吞吐与正确性
决定 KEEP / REVERT

Optimize for End-to-End Inference Performance

GEAK：AI 驱动的 GPU Kernel 优化

从实际推理负载识别高价值 Kernel，并通过多 Agent 工作流完成生成、调优与验证

Hyperloom · KERNEL_AGENT Coordinator invokes GEAK e2e_workflow

GEAK · e2e_workflow

Whole-model serving optimization

- **01 Profile & Triage** — Identify hot kernels
- **02 Prioritize** — Amdahl analysis
- **03 Optimize** — Search & tune kernels

↓ Invoke for selected kernels

GEAK · kernel_workflow

Single GPU kernel optimization

- **Specialist Agents** — Algorithm · Memory · Compute
- **Kernel Technologies** — HIP · Triton · FlyDSL · CK
- **Kernel Verification** — Correctness · Microbenchmark

↓

End-to-End Validation · Serving Throughput · Output Parity · KEEP / REVERT

AMD 开发者生态：从技术探索到实践落地

AMD Developer Ecosystem & Resources · 学习资源、云端算力、在线实践与开发者支持

01 · AMD AI 开发者计划

（中国站）

100 小时 AMD 云算力券
Token 资源、专家社群与
AI Academy 学习资源

扫码获取资源

02 · AMD 开发者中心

官方技术工具、开发文档
以及最新开发者资讯

扫码获取资源

03 · AMD 开发者中心

（魔搭创空间）

在线使用 AMD Instinct GPU
运行 AI 任务，减少本地
驱动与环境配置负担

扫码获取资源

04 · AMD 开发者小助手

企业微信开发者支持
技术答疑、开发者活动
与相关项目资讯

扫码获取资源

Explore · Build · Deploy · Connect

GOSIM

GOSIM Shenzhen 2026

Thanks!



GOSIM

GOSIM Shenzhen 2026

Thanks!



GOSIM

GOSIM Shenzhen 2026

Thanks!

