GOSIM®
GLOBAL OPEN-SOURCE INNOVATION MEETUP

GOSIM Shenzhen 2026

Topic

激光雷达与相机目标检测的交互式启发式学习方法

Interactive Heuristic Learning Method of LiDAR and Camera for Target Detection



岑明 Ming Cen

重庆邮电大学教授

Professor, Chongqing University of Posts and Telecommunications



GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



GOSIM

GOSIM Shenzhen 2026

激光雷达和视觉目标检测的交互启发学习方法

Interactive Heuristic Learning Method of Lidar and Camera for Target Detection

岑明

重庆邮电大学-智能网联技术工程研究中心

2025.9.12



CONTENTS

Part 01 问题的提出

Part 02 目标检测的交互启发学习方法

Part 03 考虑上下文的交互启发学习方法

Part 04 效果及分析



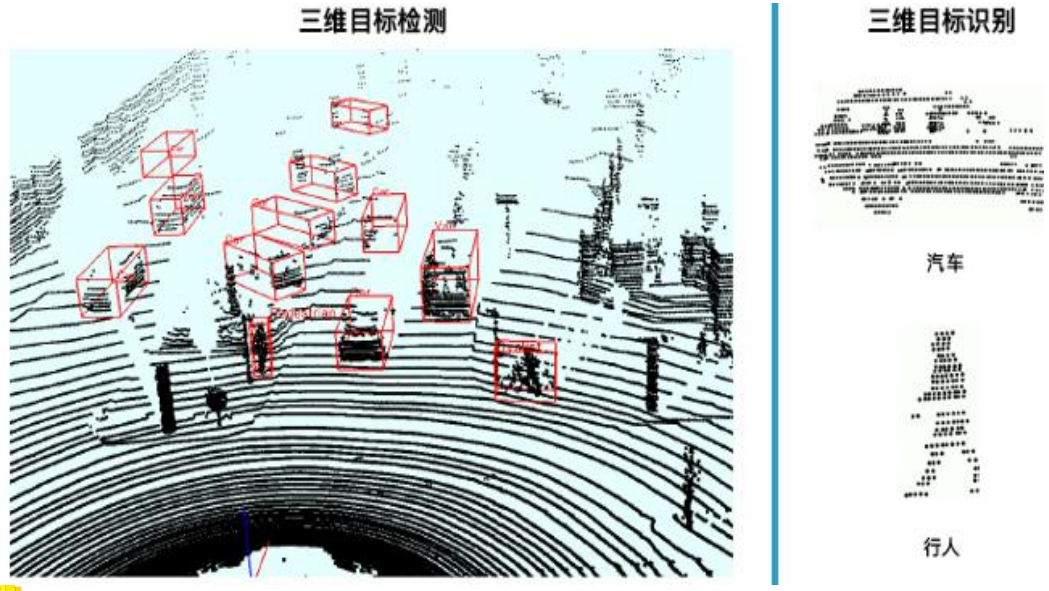
01

问题的提出

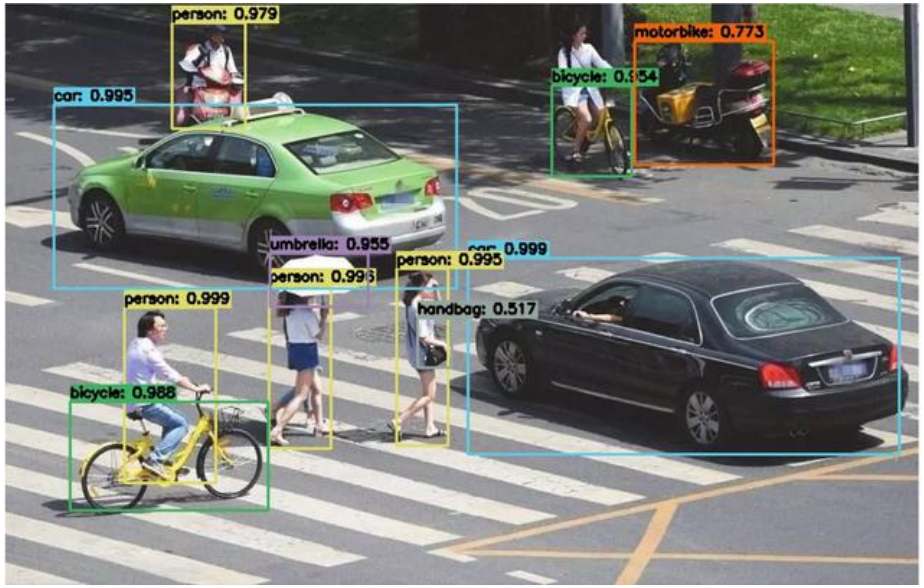


- 环境感知是机器人工作的基础
- 在机器人感知方面，激光雷达和相机是非常重要的两类传感器
- 在数据驱动框架下，这两类传感器的检测性能依赖于大规模人工标注数据

激光雷达检测



视觉检测



- 另一方面，机器人自进化学习是当前本领域最热门的方向之一



如何有效地根据这两类异构传感器的物理特性的差异，**通过自进化学习机制，进行交互启发，来减少人工标记的工作量，**提高模型训练效率，以高效率地增强机器人的目标检测与场景认知能力?

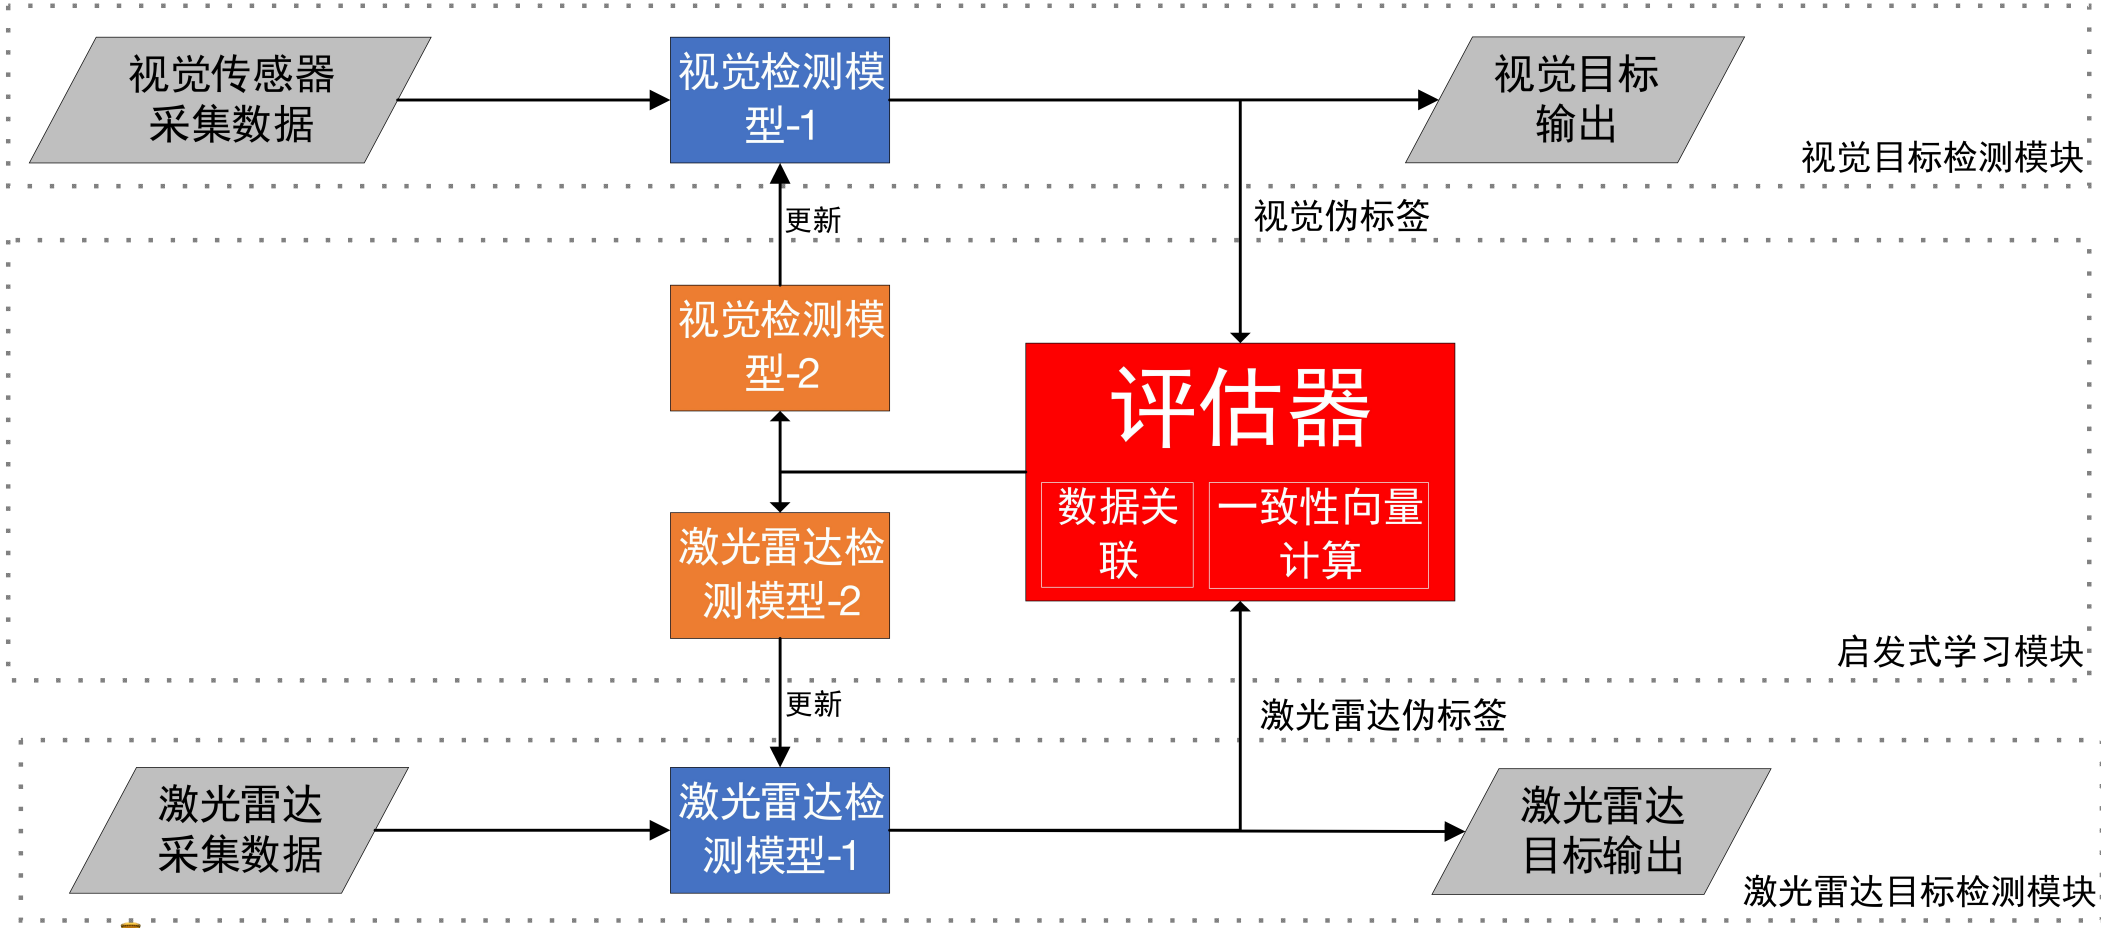
02

目标检测的交互启发学习方法



2.目标检测的交互启发学习方法

- 利用两种传感器在不同场景或特征下检测能力的差异性，互相生成启发数据进行训练



2.目标检测的交互启发学习方法

- 问题：何种情况下某个传感器的数据能用于启发学习?

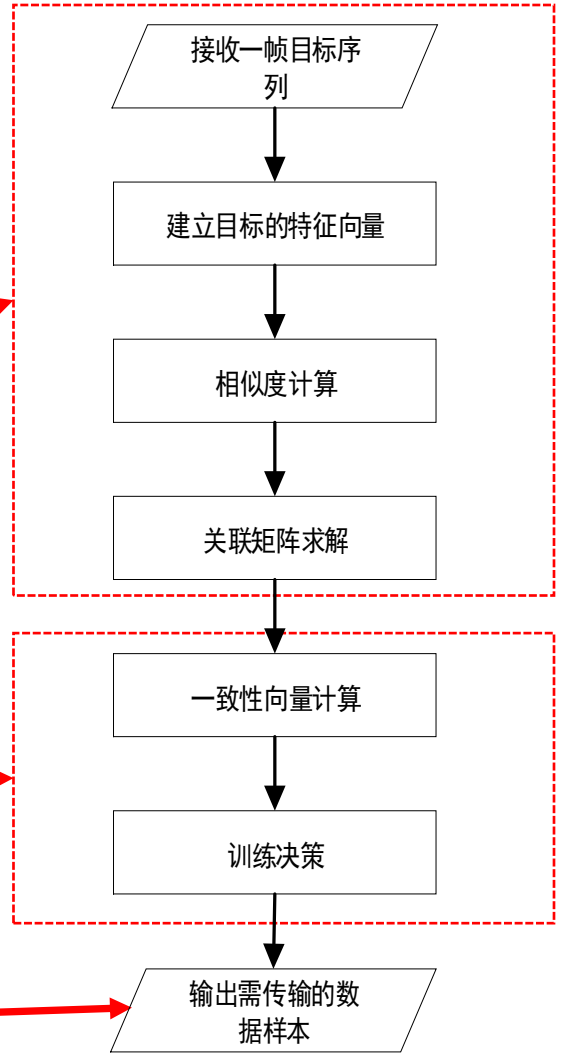
评估器：判断两种传感器数据是否能够提供给对方进行交互学习

同时序且感兴趣区域一致的目标检测样本作为输入

(1)评估器数据关联

(2)评估器训练决策

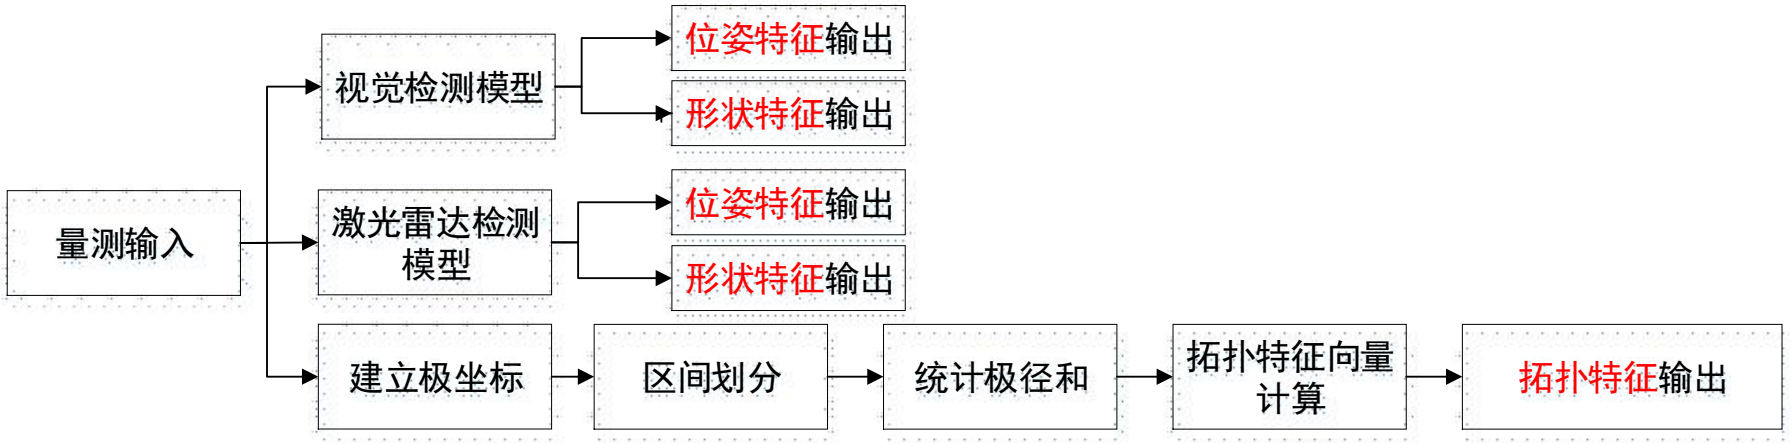
输出需传输的样本



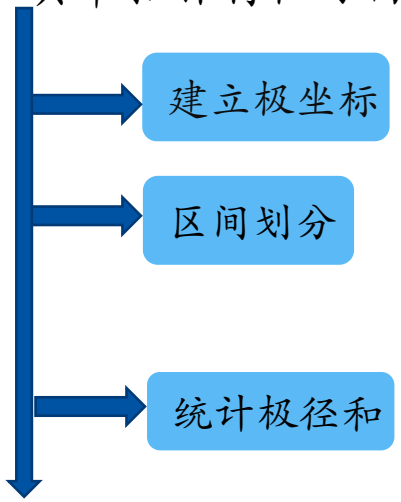
（1）评估器数据关联:在两个传感器得到的检测目标之间判断是否为同一目标

- 对两个传感器检测模型分别建立目标特征向量:

$$\begin{cases} x_k = [p, s, \mathrm{t}]^T \\ p = [x, y, a]^T \\ s = [l, w]^T \\ t = [h_1, h_2, \ldots, h_8]^T \end{cases}$$



- 其中拓扑特征可由以下流程得到:

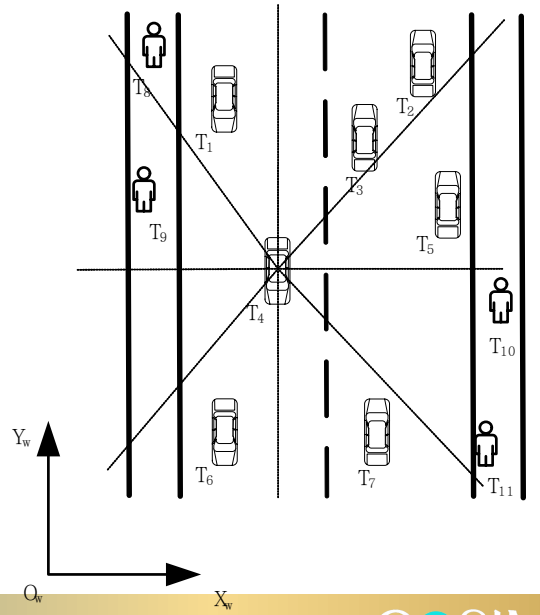


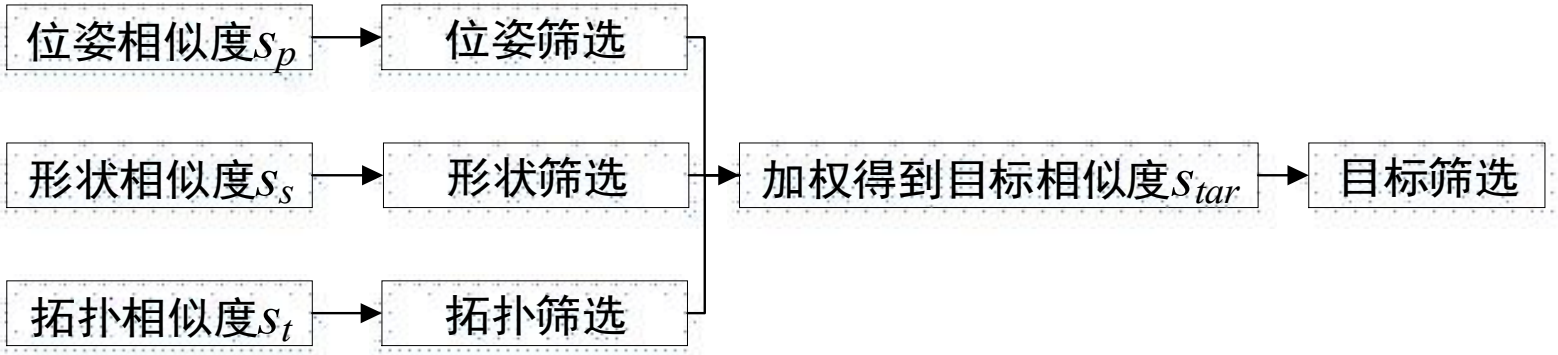
取其中第个i目标作为原点建立极坐标系。

按照极角划分扇形区间:

$$R_i = \{\theta \in E : \frac{\pi(i-1)}{4} \le \theta < \frac{\pi i}{4}\}, i = 1, 2, \ldots, 8$$

统计每个区间目标到原点的极径和h_i，最终得到目标i的拓扑特征$t_i = [h_1, h_2, \ldots, h_8]^T$。





特征相似度衡量方法使用欧氏距离：

$$d(x,y)=(\sum_{k=1}^{n}|y_k-x_k|^2)^{\frac{1}{2}} \qquad s=1-\frac{\min(d(x,y),d_{\max})}{d_{\max}}$$

→ 位姿、形状、拓扑相似度： s_p、s_s、s_t

- 加权计算得出目标相似度s_{tar}：

$$s_{tar}=l_1s_p+l_2s_s+l_3s_t$$

→ 相似度矩阵：

$$S_{p\times q}=\begin{bmatrix} s_{tar,1,1} & \cdots & s_{tar,1,q} \\ \vdots & \ddots & \vdots \\ s_{tar,p,1} & \cdots & s_{tar,p,q} \end{bmatrix}$$

- 设定阈值δ，当$s_{tar,i,j}<\delta$时，令$s_{tar,i,j}=0$，然后筛选出无可关联量测。

➢ 利用相似度做目标数据关联：

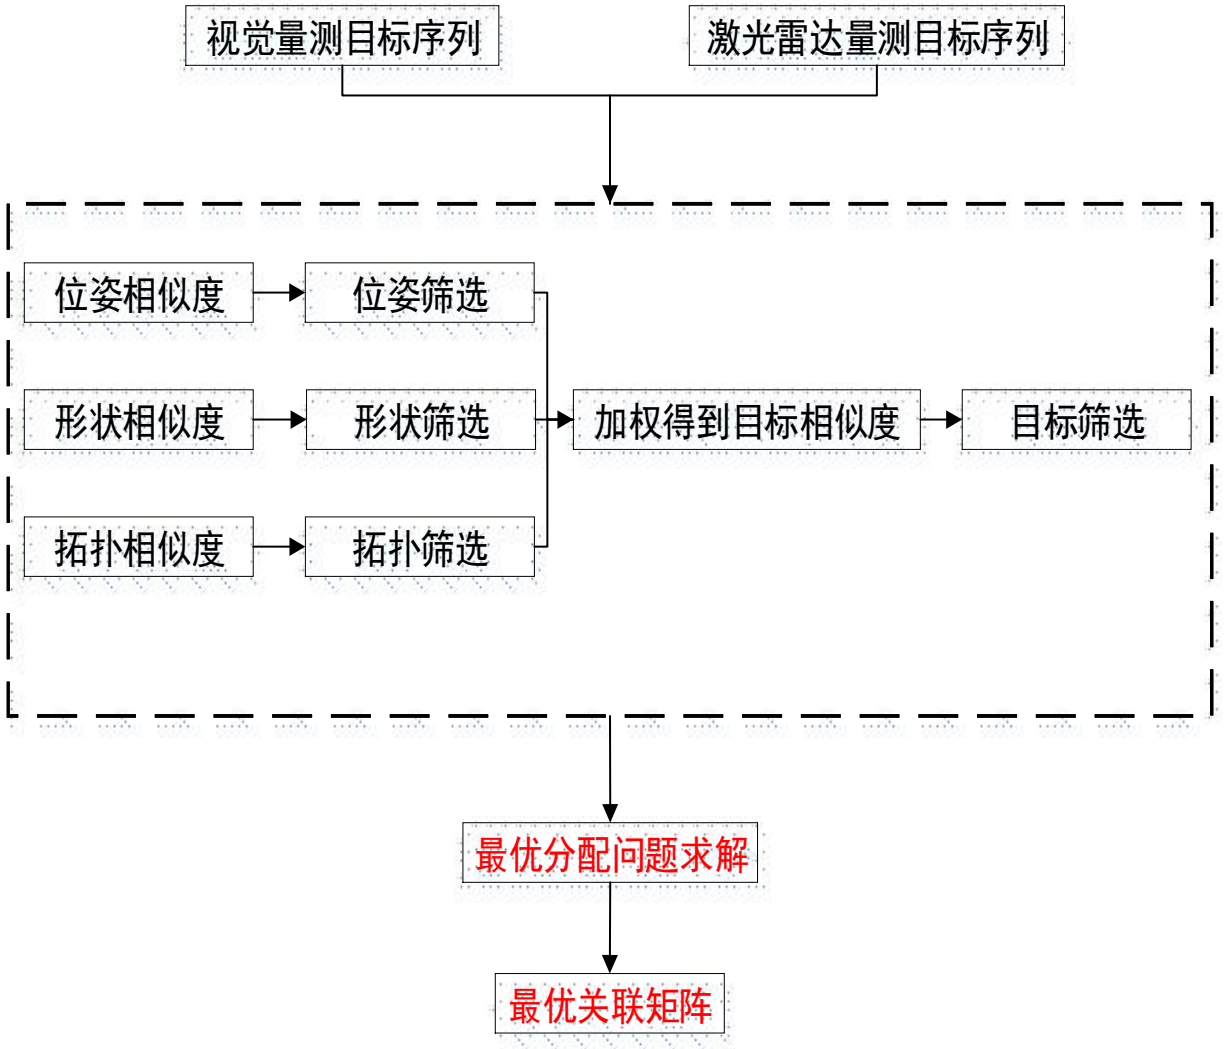
- 定义关联矩阵：$A_{p\times q}=\begin{bmatrix} a_{11} & \cdots & a_{1q} \\ \vdots & \ddots & \vdots \\ a_{p1} & \cdots & a_{pq} \end{bmatrix}$

  其中a_{ij}为二值变量，为0表示不关联，为1表示关联。

- 由此可定义一个最优分配问题：

  目标函数：$\max f(A)=\sum_{i=1}^{p}\sum_{j=1}^{q} s_{ij}a_{ij}$

  约束条件：$\sum_{i=1}^{p} a_{ij}\le 1 \qquad \sum_{j=1}^{q} a_{ij}\le 1$



（2）评估器训练决策: 根据数据关联结果去对目标进行分类

- 设置4类目标集合并进行分类:

  - 视觉伪标签目标中成功关联与未成功关联的目标集合:

$$P_Y^K=\{P_{Y1}^K,P_{Y2}^K,P_{Y3}^K,...,P_{Yn}^K\}$$

$$P_N^K=\{P_{N1}^K,P_{N2}^K,P_{N3}^K,...,P_{Nm}^K\}$$

  - 激光雷达伪标签目标中成功关联与未成功关联的目标集合:

$$P_Y^L=\{P_{Y1}^L,P_{Y2}^L,P_{Y3}^L,...,P_{Yu}^L\}$$

$$P_N^L=\{P_{N1}^L,P_{N2}^L,P_{N3}^L,...,P_{Nv}^L\}$$

- 一致性向量计算：用来评估目标是否具有一致性特征

定义一致性向量： $y_i=[t_1,t_2,t_3,t_4]^T$

➢ 训练方法

定义激光雷达与视觉伪标签数据： T^L 、 T^K

检测模型： A^l 、 A^k

t_1=1，不需要进行数据传输

t_2=1，将T^L传输给A^k进行进一步训练

t_3=1，将T^K传输给A^l进行进一步训练

t_4=1，将T^L传输给A^k，同时将T^K传输给A^l进行进一步训练

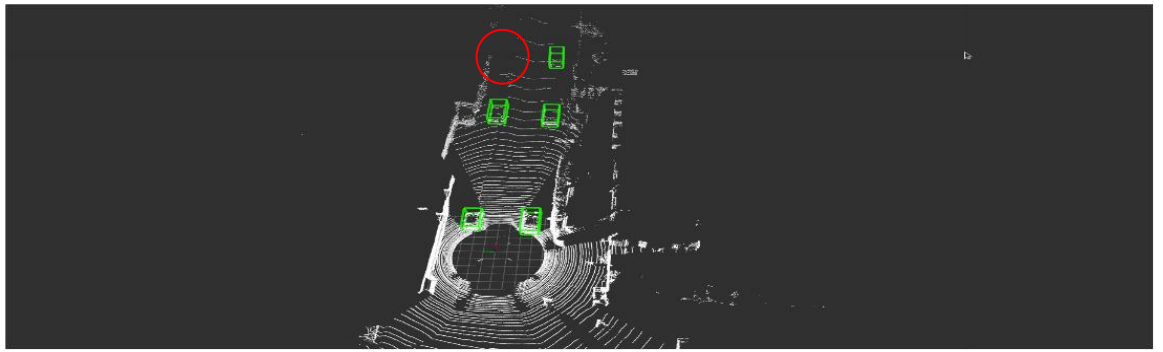
➢ 数据样本传输：

- 训练决策后，待训练数据样本进入传输缓冲区，当样本数量累积到ω后，提供给训练模型进行下一轮训练。

➢ 仿真效果（KITTI 数据集）



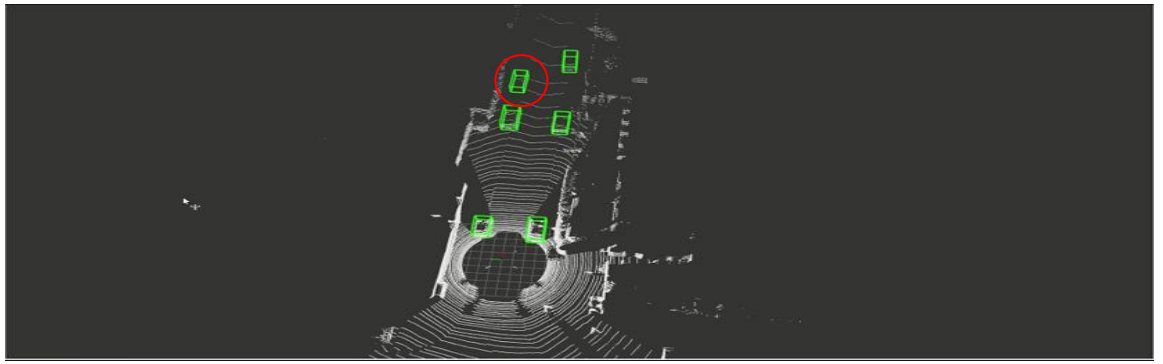
(a) 视觉模型未启发式学习检测结果



(b)激光雷达模型未启发式学习检测结果



(c) 视觉模型启发式学习后检测结果



(d) 激光雷达模型启发式学习后检测结果

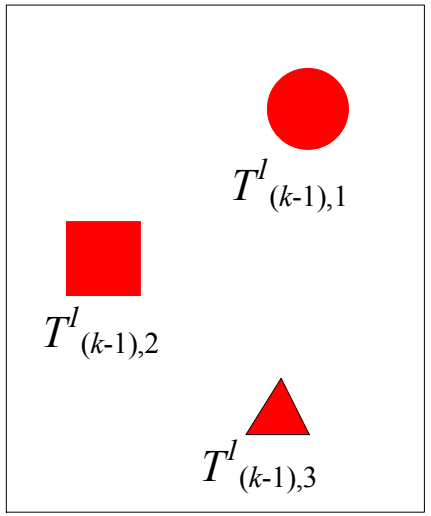
03

考虑上下文的交互启发学习方法

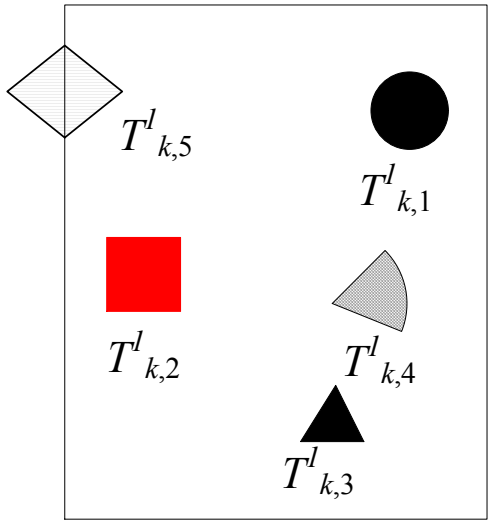


3.考虑上下文的交互启发学习方法

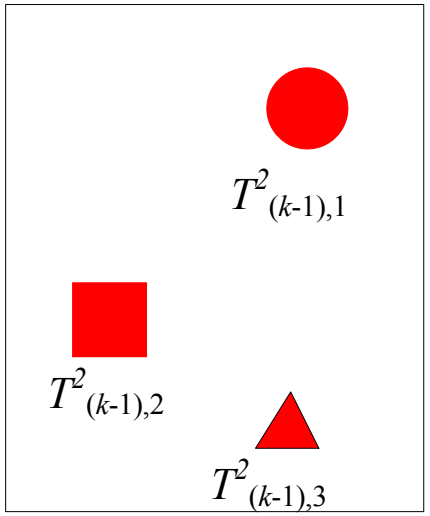
- 直接采用伪标签数据进行交互启发式训练可能会出现误检目标等问题，降低检测模型的性能
- 利用过去时刻的上下文信息，可以减少虚警对启发学习的影响



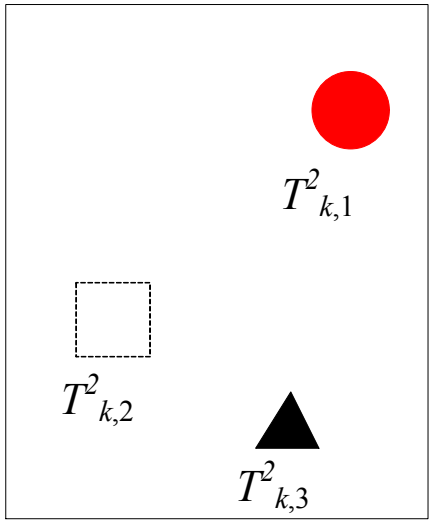
(a) 传感器C_1 k-1时刻伪标签数据



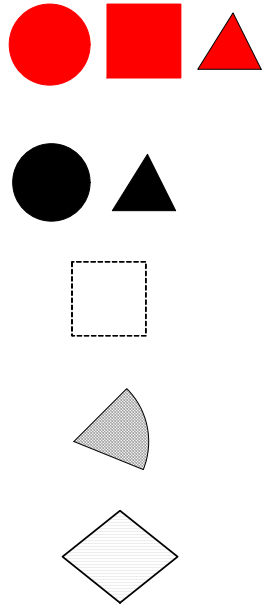
(b) 传感器C_1 k时刻伪标签数据



(c) 传感器C_2 k-1时刻伪标签数据



(d) 传感器C_2 k时刻伪标签数据



成功检测的目标

实际存在却未被成功检测的目标

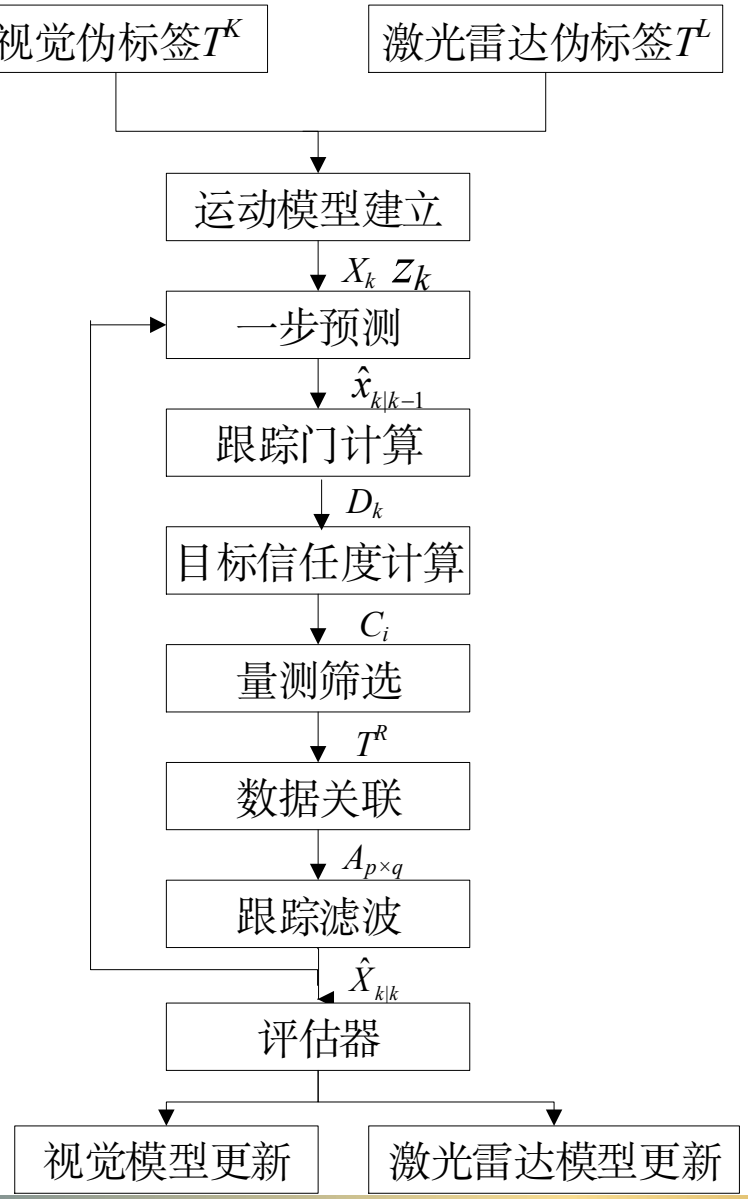
实际不存在且未被检测的目标

误检目标

无效目标：该目标仅有一部分在检测范围内

3.考虑上下文的交互启发学习方法

- 思路：利用过去时刻的上下文信息，滤掉误检目标，可以减少虚警对启发学习的影响



（1）运动模型建立

- 基于上下文信息重新建立目标特征向量，加入速度特征：

$$x_k = [p, s, v, \mathrm{t}]^T$$

- 使用目标特征向量 $x_k = [p, s, v, \mathrm{t}]^T$ 建立基于上下文的目标运动方程：

$$\begin{cases} x_k = F_{k-1} x_{k-1} + \Gamma \omega_{k-1} & \text{状态转移方程} \\ z_k = H_k x_k + v_k & \text{目标量测方程} \end{cases}$$

其中，
- F_{k-1} -- 状态转移矩阵
- Γ -- 噪声矩阵
- w_{k-1} -- 系统过程噪声
- z_k -- 量测向量
- H -- 量测矩阵
- v_k -- 量测噪声

➢ 一步预测

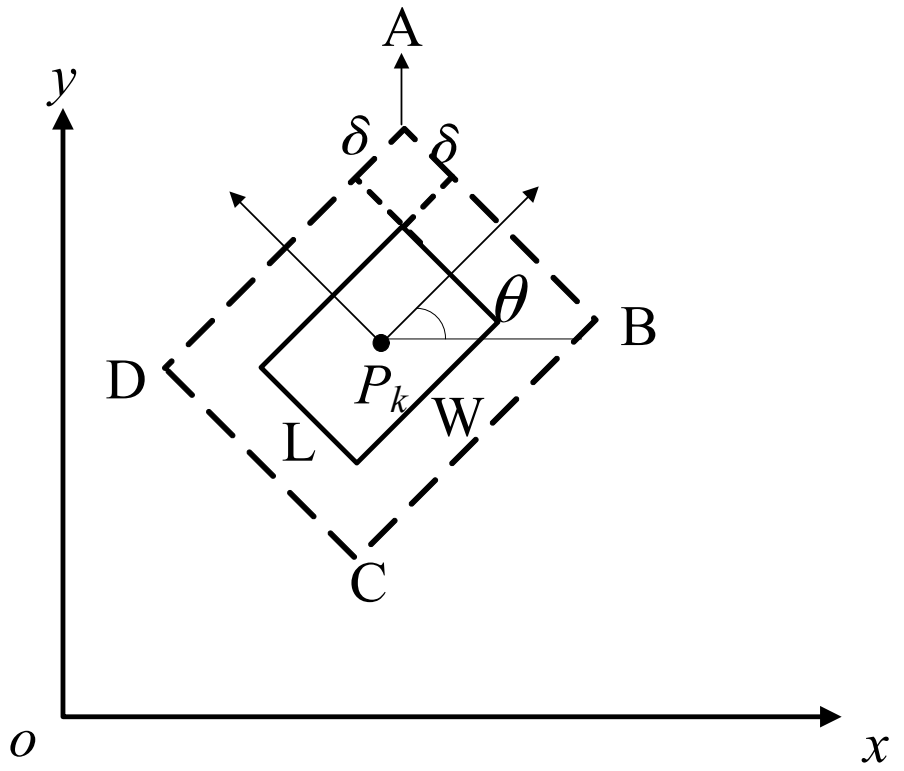
- 在时刻k，对上一时刻量测运动状态估计$\hat{X}_{k-1|k-1}$进行一步预测，得到k时刻的运动状态$\hat{X}_{k|k-1}$：

$$\hat{x}_{k|k-1} = F_{k-1}\hat{x}_{k-1|k-1}$$

$$P_{k|k-1} = F_{k-1}P_{k-1|k-1}F_{k-1}^{T} + Q_{k-1}$$

➢ 跟踪门计算

- 根据运动状态估计$\hat{X}_{k|k-1}$，将其投影至x-y平面上，可以得到量测在k时刻的估计位置，如右图中实线矩形



虚线表示跟踪门，使用跟踪门顶点坐标来表征跟踪门信息

➢ 目标信任度计算

- 目标基础信任度计算

图像分割 → 目标像素点N_t / 总像素点N_m → $C_i^B = \frac{N_t}{N_m}$

表示目标自身像素密度。

- 目标信任度增益计算

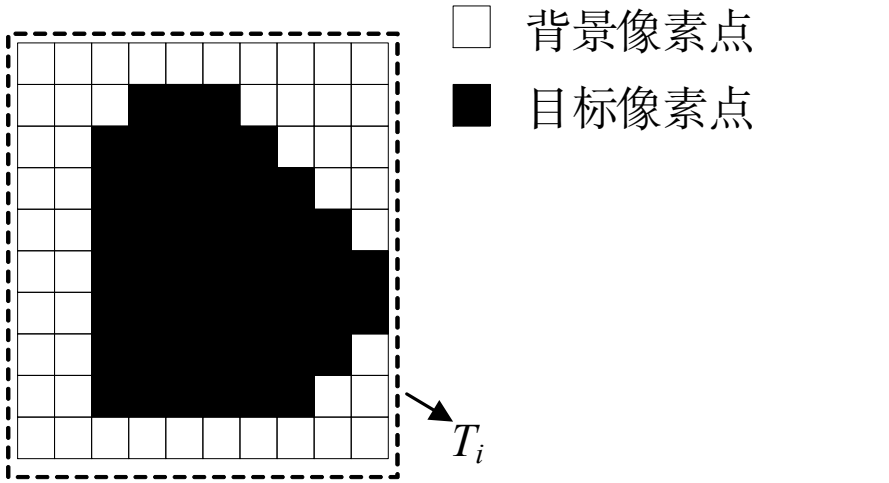
引入跟踪门 → 相交像素点N_{in} / 未相交像素点N_{out} → $C_{i,j}^G = \frac{N_{in}}{N_t}$

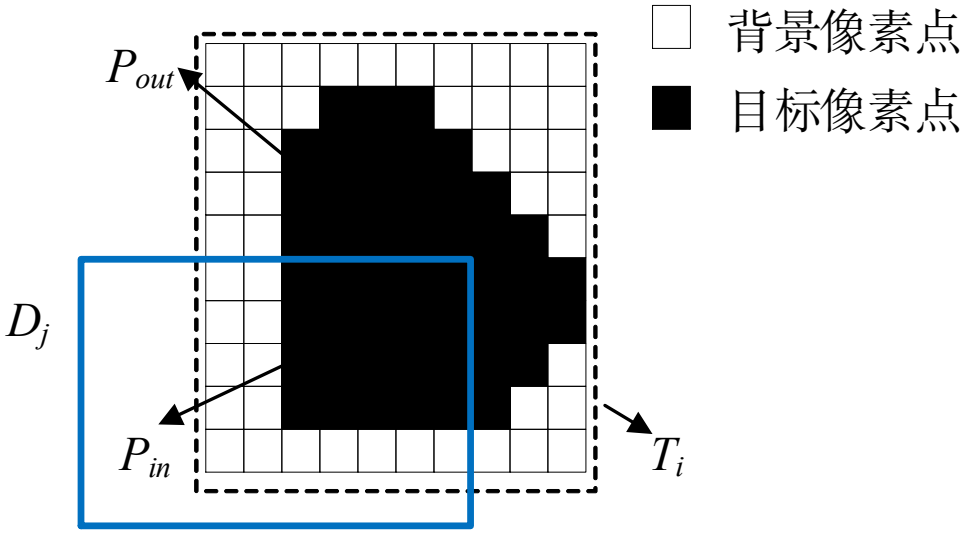
→ $C_i^G = \max(C_{i,j}^G), j = 1,...,m$

表示目标与跟踪门的相交程度。

- 加权计算最终信任度并进行目标筛选

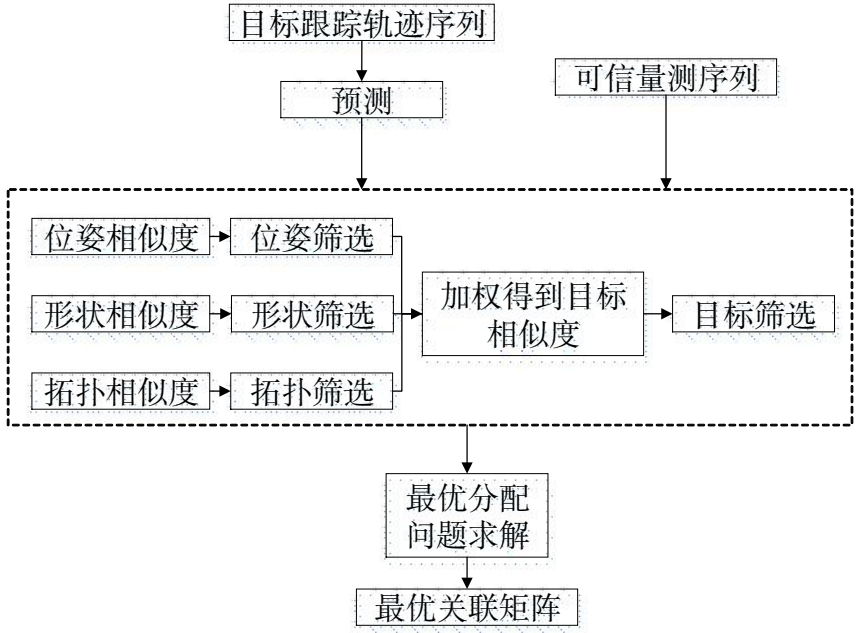
$C_i = \frac{\alpha C_i^B + \beta C_i^G}{2}$ → 信任度阈值C_{th} → 可信目标集合T^R / 不可信目标集合T^W





3.考虑上下文的交互启发学习方法

➢ 考虑上下文的目标数据关联



设有： $D_{k-1}=\{d_1,d_2,\ldots d_m\}$ k-1时刻跟踪轨迹序列

1： 跟踪轨迹状态预测

$D_{k-1}=\{d_1,d_2,\ldots d_m\}$ —一步预测→ $D'_k=\{d'_1,d'_2,\ldots d'_m\}$

2： 相似度计算

位姿相似度

$$\begin{cases} d_{i,j}^{p}=\sqrt{(x_i-x_j)^2+(y_i-y_j)^2} \\ \gamma^{p}=\mu\sqrt{v_x^2+v_y^2}+\varsigma \\ \lambda_{i,j}^{p}=1-\dfrac{\min(d_{i,j}^{p},\gamma^{p})}{\gamma^{p}} \end{cases}$$

形状相似度

$$\begin{cases} d_{i,j}^{s}=\left|\dfrac{l_i\times l_j+w_i\times w_j}{\sqrt{l_i^2+w_i^2}+\sqrt{l_j^2+w_j^2}}\right| \\ \lambda_{i,j}^{s}=\begin{cases}0, & if\ d_{i,j}^{s}<\gamma^{s}\\ d_{i,j}^{s}, & if\ d_{i,j}^{s}\geq\gamma^{s}\end{cases} \end{cases}$$

拓扑相似度

$$\begin{cases} d_{i,j}^{t}=\sqrt{\sum_{p=1}^{8}(h_p^i-h_p^j)^2} \\ \gamma^{t}=\max(\sum_{i=1}^{8}|h_p^i|,\sum_{j=1}^{8}|h_p^j|) \\ \lambda_{i,j}^{t}=1-\dfrac{\min(d_{i,j}^{t},\gamma^{t})}{\gamma^{t}} \end{cases}$$

目标相似度

$$\lambda_{i,j}=p_1\lambda_{i,j}^{p}+p_2\lambda_{i,j}^{s}+p_3\lambda_{i,j}^{t}$$

$$s.t.\begin{cases} p_1+p_2+p_3=1 \\ 0\le p_1\le 1 \\ 0\le p_2\le 1 \\ 0\le p_3\le 1 \end{cases}$$

- 红圈为过滤门限值

3： 关联矩阵求解

➢ 跟踪滤波

- 处理关联结果

建立计数器*LCount*统计轨迹丢失量测次数

计数器*NCount*统计新生目标连续关联成功次数

$$LCount_k = \begin{cases} LCount_{k-1} + 1, & \text{关联失败} \\ LCount_{k-1}, & \text{关联成功} \end{cases}$$

$$NCount_k = \begin{cases} NCount_{k-1} + 1, & \text{关联成功} \\ NCount_{k-1}, & \text{关联失败} \end{cases}$$

设定相关的阈值T_1与T_2

$$\begin{cases} NCount \geq T_1, & \text{生成轨迹，为目标跟踪起始} \\ LCount \geq T_2, & \text{销毁轨迹，为目标跟踪终止} \end{cases}$$

- 目标状态滤波

$$K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1}$$

$$\hat{X}_{k|k} = \hat{X}_{k|k-1} + K_k [Z_k - H_k \hat{X}_{k|k-1}]$$

$$\mathrm{P}_{k|k} = (I - K_k H_k) \mathrm{P}_{k|k-1} (I - K_k H_k)^T + K_k R_k K_k^T$$

→ 目标最优状态估计

➢ 仿真效果（nuScenes数据集）



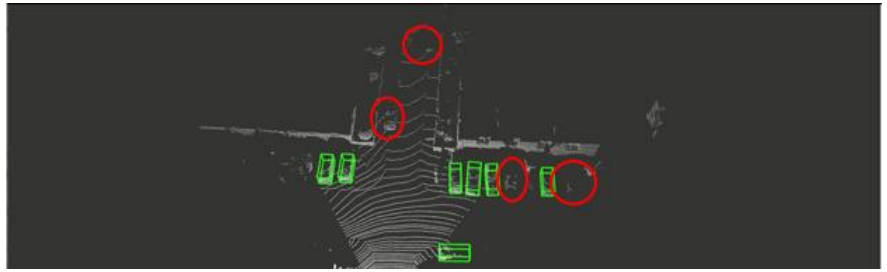
(a) 视觉模型未启发式学习检测结果



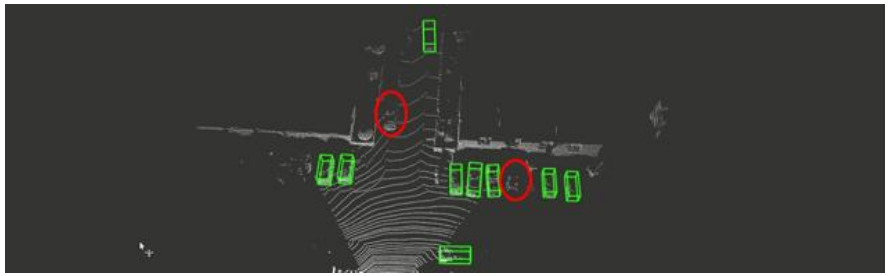
(b) 视觉模型无跟踪启发式学习检测结果



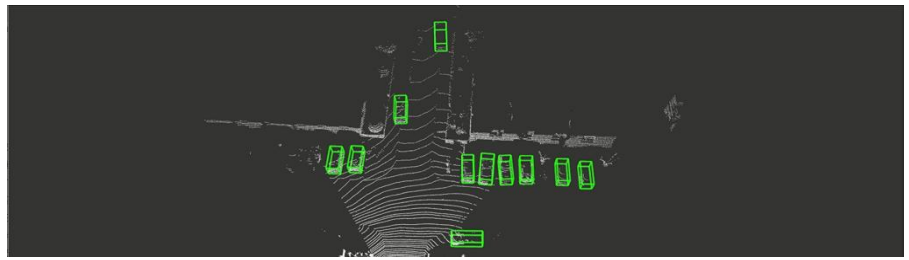
(c) 视觉模型有跟踪启发式学习检测结果



(d) 激光雷达模型未启发式学习检测结果



(e) 激光雷达模型无跟踪启发式学习检测结果



(f) 激光雷达模型有跟踪启发式学习检测结果

04

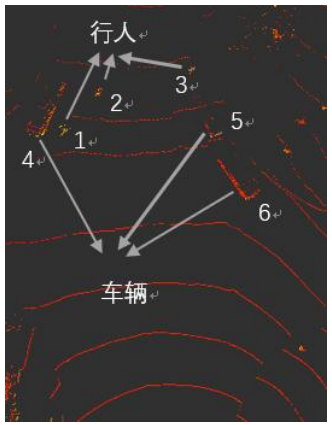
考虑上下文的交互启发学习方法



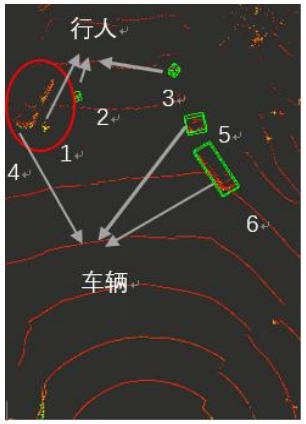
➢ 实验场景1: 城区道路

方法	*NTT*	*NTA*	r_{frr}
未启发式学习	Lidar 1362 Camera 1483	981 1192	0.280 0.196
启发式学习	Lidar 1362 Camera 1483	1136 1280	0.166 0.137

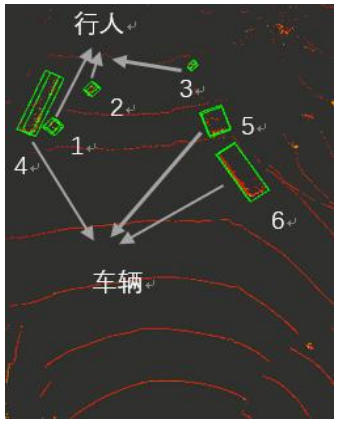
采用启发式学习后，激光雷达目标检测模型漏检率降低了11.4%，视觉目标检测模型漏检率降低了5.9%



(a) 原始点云



(b) 激光雷达未启发式学习检测效果



(c) 激光雷达启发式学习检测效果



(d) 原始图像



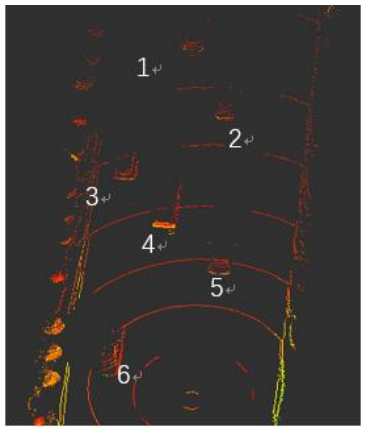
(e) 视觉未启发式学习检测效果



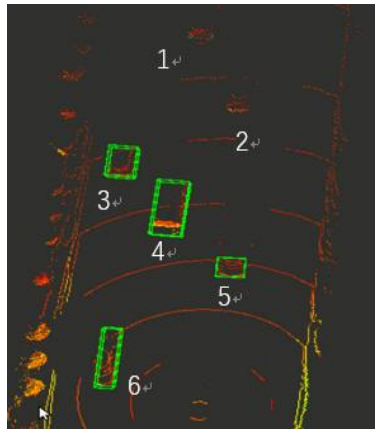
(f) 视觉启发式学习检测效果

➢ 实验场景2: 高速道路

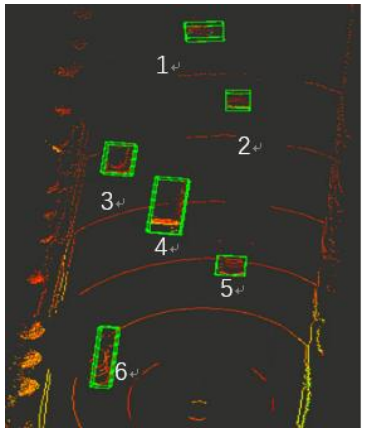
方法	*NTT*	*NTA*	r_{frr}
未启发式学习	Lidar 1413 Camera 1527	1046 1260	0.260 0.175
本文方法	Lidar 1413 Camera 1527	1197 1327	0.153 0.131



(a) 原始点云



(b) 激光雷达未启发式学习检测效果

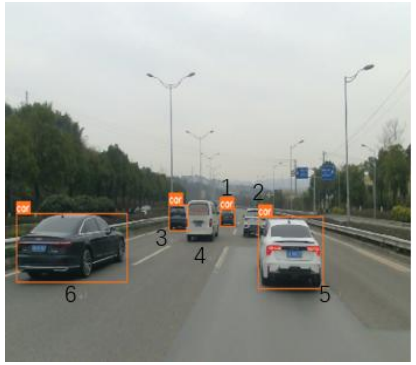


(c) 激光雷达启发式学习检测效果

采用启发式学习后，激光雷达目标检测模型漏检率降低了10.7%，视觉目标检测模型漏检率降低了4.4%



(d) 原始图像



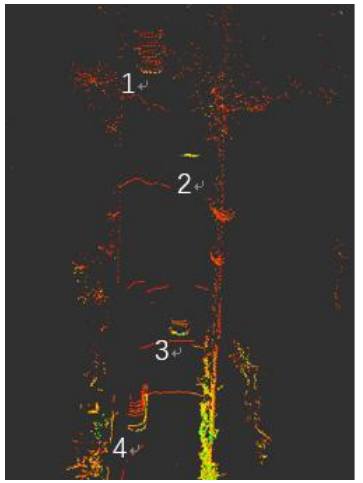
(e) 视觉未启发式学习检测效果



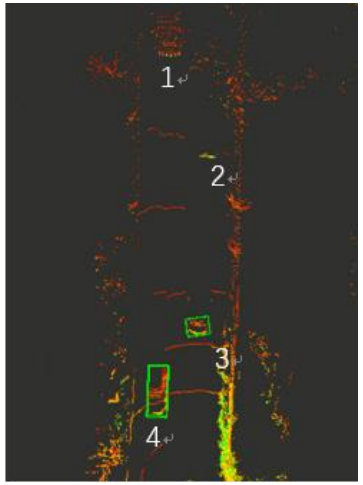
(f) 视觉启发式学习检测效果

➢ 实验场景3: 山路场景

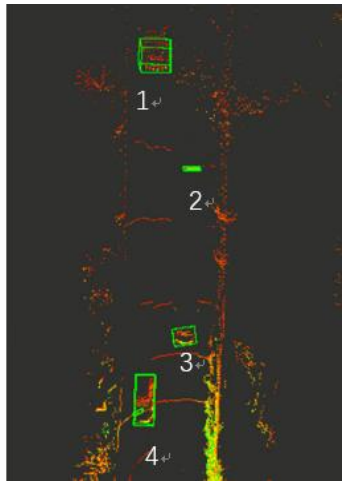
方法	*NTT*	*NTA*	r_{frr}
未启发式学习	Lidar 732 Camera 846	495 659	0.324 0.221
本文方法	Lidar 732 Camera 846	558 692	0.234 0.182



(a) 原始点云



(b) 激光雷达未启发式学习检测效果

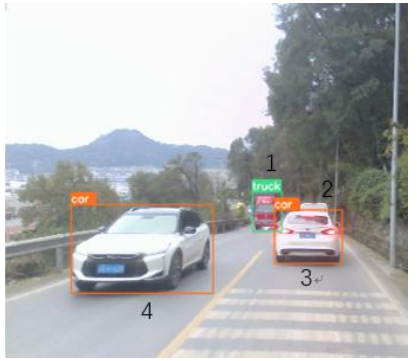


(c) 激光雷达启发式学习检测效果

采用启发式学习后，激光雷达目标检测模型漏检率降低了9%，视觉目标检测模型漏检率降低了3.9%



(d) 原始图像



(e) 视觉未启发式学习检测效果



(f) 视觉启发式学习检测效果

GOSIM

GOSIM Shenzhen 2026

Thanks!

