GOSIM®
GLOBAL OPEN-SOURCE INNOVATION MEETUP

GOSIM Shenzhen 2026

Topic

从排行榜到全球基础设施：构建面向具身智能的开放评测生态

From Leaderboards to Global Infrastructure: Building an Open Evaluation Ecosystem for Embodied AI



陈阳 Emily Chen

原力灵机开源战略与生态负责人

Head of Open Source Strategy & Ecosystem, Dexmal



RoboChallenge

洞察具身智能趋势，推动开发测评共建

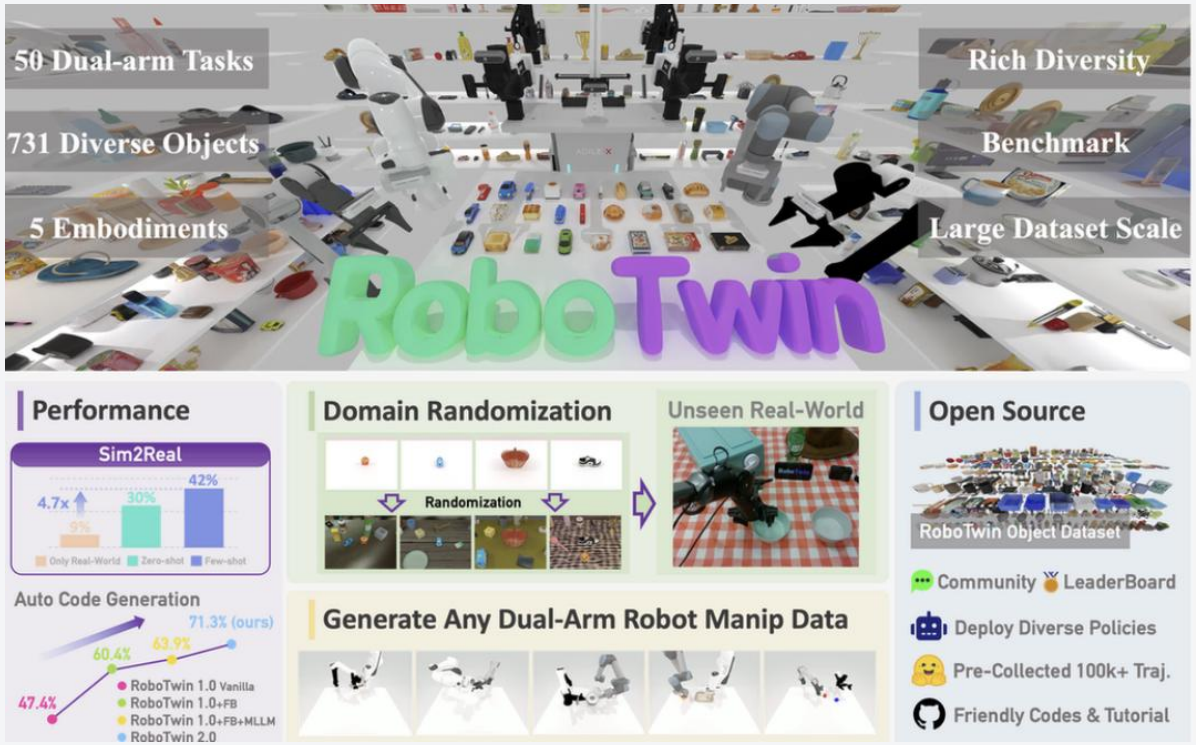
全球首个大规模具身智能真机测评平台

具身行业的痛点和乱象

RoboChallenge

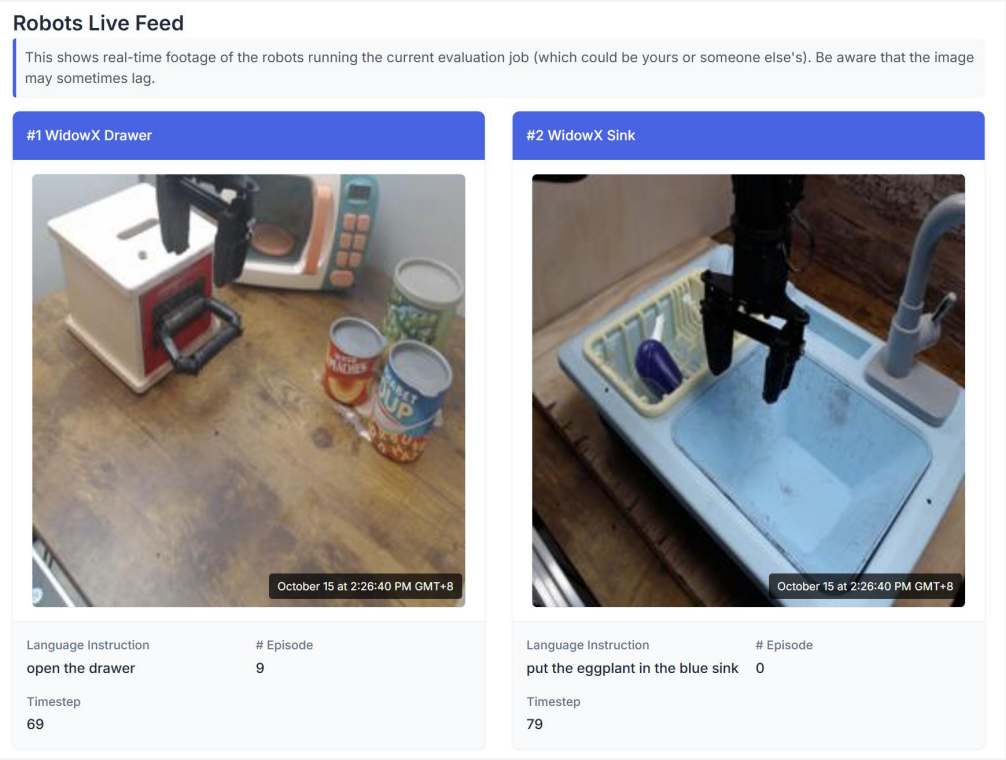
仿真环境

在仿真测评中，机器人的能力看起来到了一个新高度



真机环境

真实世界中，机器人的能力还是非常有限



RoboTwin 等主流仿真 Benchmark 部分任务成功率接近 99%，仿真 Benchmark 正逐步进入"高分时代"，行业亟需更具挑战性的真机评测体系。

RoboChallenge

统一的、真机、开放的测评标准

以测评推动科研

RoboChallenge 推出的首个真机桌面基准 - Table 30

RoboChallenge



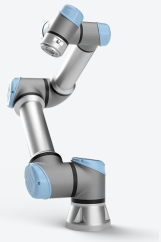
ARX-5



Aloha
COBOT Magic

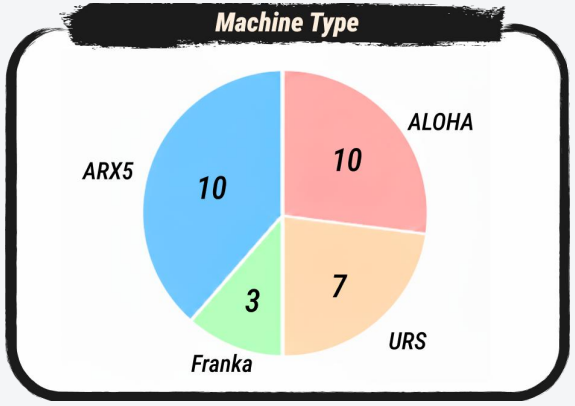


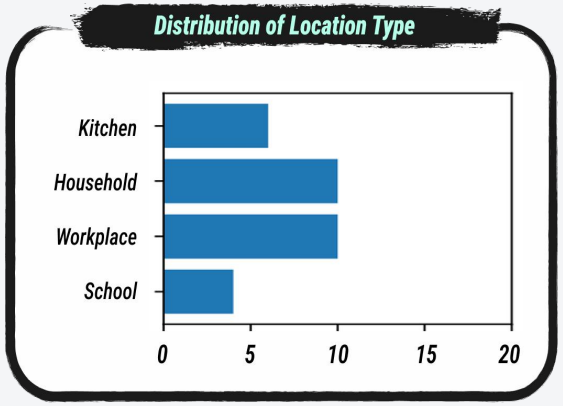
FRANKA
PANDA



UR5







RoboChallenge - Table 30 榜单

RoboChallenge

RoboChallenge Table 30 - Specialist

Rank	Model/User	Score	Success Rate
1	Era0/Robotera	76.34	**64.33%**
2	DM0/Dexmal	72.25	**62.00%**
3	GigaBrain-0.1/lyf	68.34	**51.67%**
4	Spirit-v1.5/Spirit AI	67.19	**51.00%**
5	pi0.5/rc_baseline	61.84	**42.67%**
6	wall-oss-v0.1/Pushi Zhang	55.30	**35.33%**
7	pi0/rc_baseline	46.41	**28.33%**
8	X-VLA/Chongyang Xu	34.75	**21.33%**
9	RDT-1B/zsz	28.84	**15.00%**
10	GR00T/Sicheng Xie	31.64	**14.33%**

RoboChallenge Table 30 - Generalist

Rank	Model/User	Score	Success Rate
1	Lira_generalist/Atlas	59.83	**45.00%**
2	Atlas_generalist/Atlas	55.10	**39.67%**
3	DM0_generalist/Dexmal	49.08	**37.33%**
4	VLO/Sicheng Xie	42.34	**25.67%**
5	pi05_generalist/wyf	31.27	**17.67%**
6	GR00T-MULTI/Sicheng Xie	28.39	**13.33%**
7	pi0_generalist/wyf	20.22	**9.00%**
8	VLA_test_0204/Xiangyue Wu	17.33	**9.00%**
9	VLA_test_0119/Xiangyue Wu	21.95	**5.00%**
10	--/--	--	**--**

开启具身智能通用泛化的测评基准 - Table 30 v2

RoboChallenge



任务升级

- 增加了柔性物体的处理
- 增加了大量需要双臂协作
- 多元化的硬件机型

测评升级

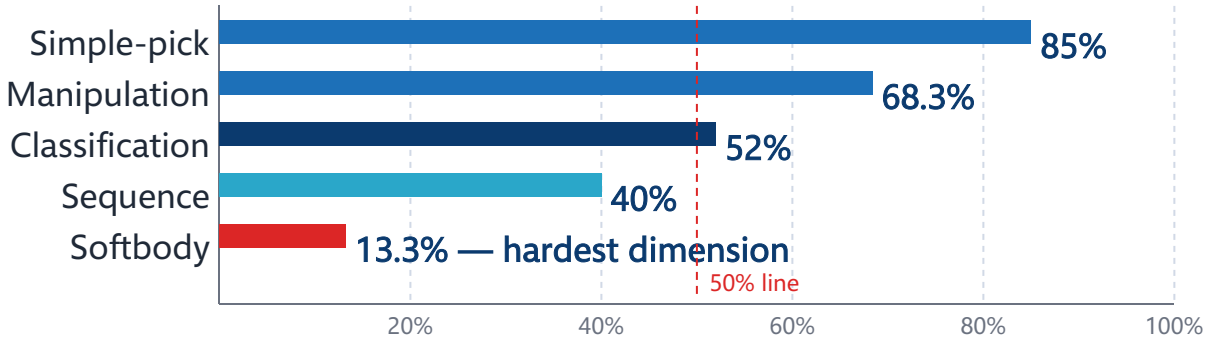
- Generalist
- 零样本测试的引入

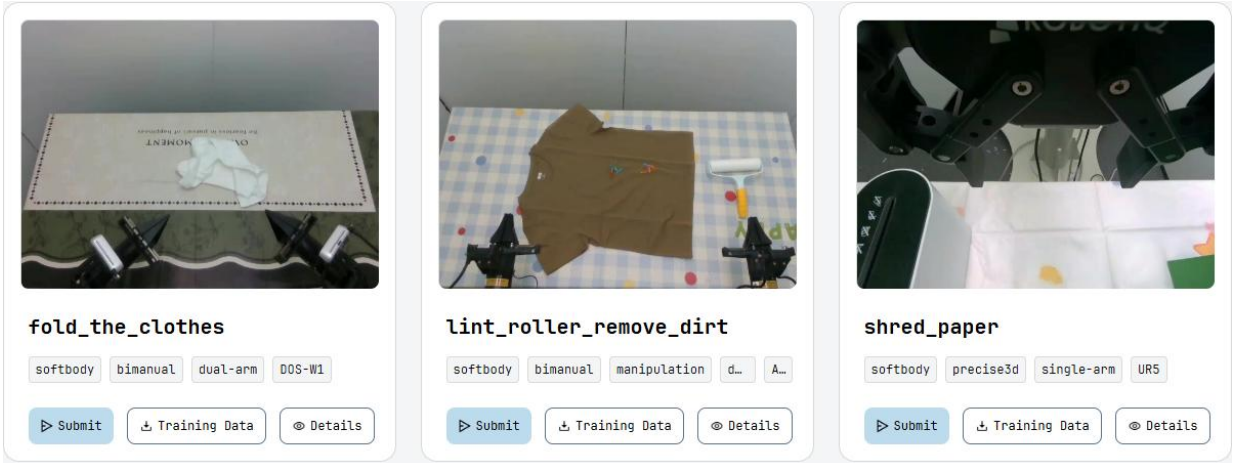
系统升级

- 吞吐量提升300%
- 引入“完成时间”作为关键评分维度

柔性物体是具身模型最具挑战的能力之一

RoboChallenge





RC 平台测评结果发现，相较于刚体操作，柔性物体操作仍然是具身模型最具挑战性的能力之一。

为此，我们在 Table30 V2 中引入了多项柔性物体任务，包括叠衣服、粘衣服上赃物、和绳索打结等典型场景，以更全面地评估模型在柔性物体上的操作能力。

从 Task Specialist 到 Generalist

RoboChallenge

RoboChallenge Table 30 - Specialist

Rank	Model/User	Score	Success Rate
1	Era0/Robotera	76.34	64.33%
2	DM0/Dexmal	72.25	62.00%
3	GigaBrain-0.1/lyf	68.34	51.67%
4	Spirit-v1.5/Spirit AI	67.19	51.00%
5	pi0.5/rc_baseline	61.84	42.67%
6	wall-oss-v0.1/Pushi Zhang	55.30	35.33%
7	pi0/rc_baseline	46.41	28.33%
8	X-VLA/Chongyang Xu	34.75	21.33%
9	RDT-1B/zsz	28.84	15.00%
10	GR00T/Sicheng Xie	31.64	14.33%

RoboChallenge Table 30 - Generalist

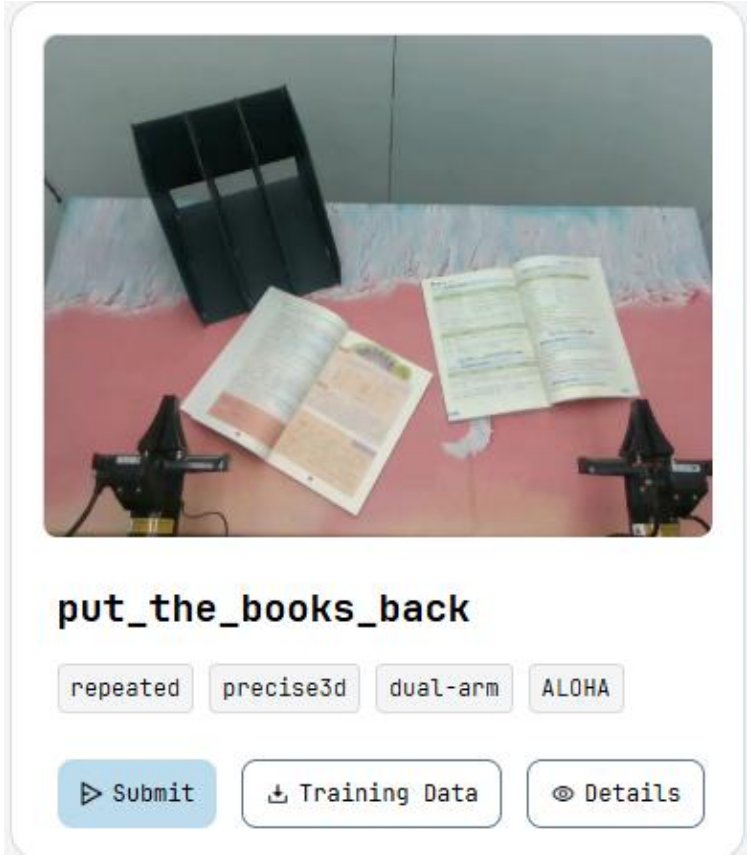
Rank	Model/User	Score	Success Rate
1	Lira_generalist/Atlas	59.83	45.00%
2	Atlas_generalist/Atlas	55.10	39.67%
3	DM0_generalist/Dexmal	49.08	37.33%
4	VLO/Sicheng Xie	42.34	25.67%
5	pi05_generalist/wyf	31.27	17.67%
6	GR00T-MULTI/Sicheng Xie	28.39	13.33%
7	pi0_generalist/wyf	20.22	9.00%
8	VLA_test_0204/Xiangyue Wu	17.33	9.00%
9	VLA_test_0119/Xiangyue Wu	21.95	5.00%
10	--/--	--	--

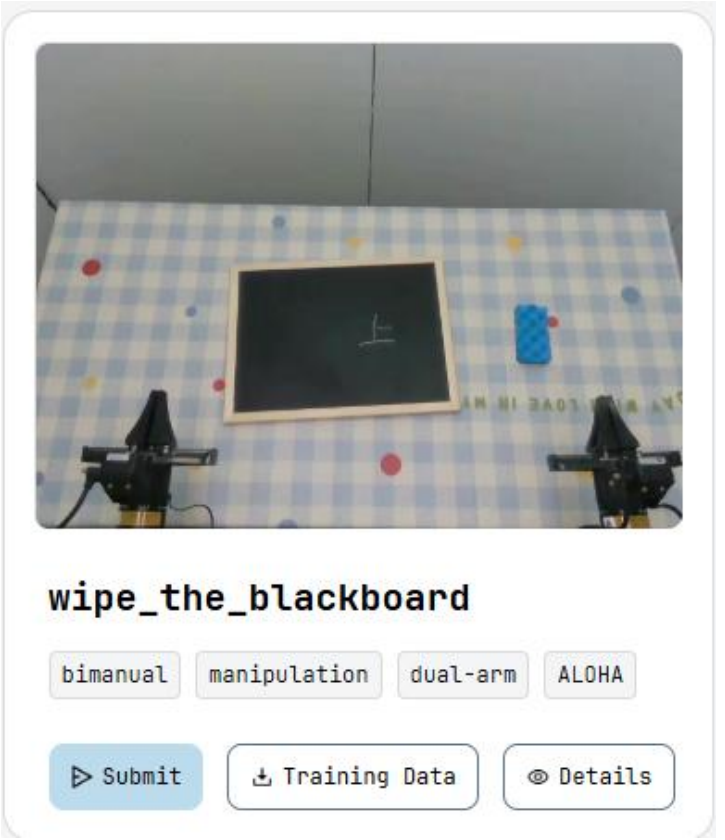
我们发现，Specialist 模型可以通过针对特定任务进行优化获得很高的分数，但这种能力往往难以迁移到新的任务，容易产生过拟合。相比之下，我们相信未来的具身基础模型将朝着 Generalist 的方向发展——能够适应更多场景、完成更多任务。

因此，在 Table30 V2 中，评测对象不再是单个任务，而是针对同一机型上的综合能力进行评估。我们希望评估的是**模型的整体泛化能力，而不是某个任务上的极致表现。**

真实世界的任务需要双臂协同操作

RoboChallenge



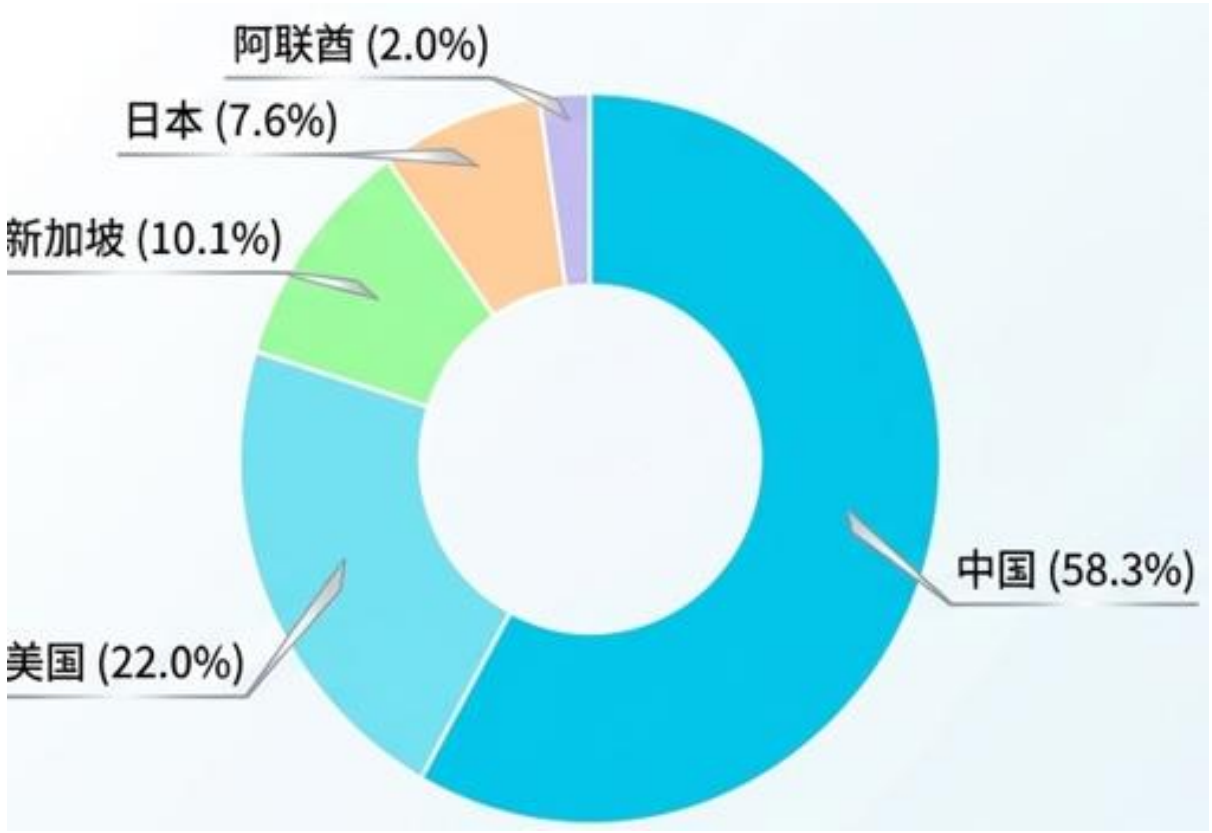


许多真实世界任务已经无法依靠单臂完成，而需要双臂协同操作。测评结果表明，双臂协同操作仍是当前模型的一项关键挑战。

因此，Table30 V2 引入了 20 项双臂协作任务，如将书放回书架、擦黑板等，更贴近家庭、办公等真实应用场景，也对模型的协同规划与执行能力提出了更高要求。

RoboChallenge 全球具身评测数据分析

RoboChallenge



10万+

平台累计执行真机Rollout

17K

Table30 数据集下载数量

181

单日真机测试峰值

39.2%

提测转换率

RoboChallenge 年度报告 - 核心发现和具身行业趋势



1. 平台数据显示，**真机评测**需求正在快速增长，已经成为行业发展的刚需。

2. Pick and Place已经成为具身智能领域的Hello World任务，但**长程**任务、**柔性物体**操作仍然是当前模型面临的主要挑战。

3. 即便是目前排行榜第一的模型，总体得分也只有64/100分，距离真正能够胜任真实世界复杂任务还有很大**提升空间**。

4. 具身智能的“ChatGPT**时刻**”仍未到来。

RoboChallenge 支持 EAI Bench 首批商业服务场景评测发布

RoboChallenge





EAI Bench 首批商业服务场景评测发布

RoboChallenge

应用导向，以真实场景需求牵引，选取代表性评测任务：面向仓储、酒店、零售等场景，从商品流转、设备操作、空间整理和清洁维护等高频业务需求中，提取共性能力要求，并将其转化为标准化评测任务。代表性评测任务是紧扣真实商业服务需求的关键作业能力集合，以支撑评测结果直接服务于产业实践。

真实场景

仓储物流

零售门店

酒店服务

→ 提取共性需求

高频业务需求

商品流转

设备操作

空间整理

清洁维护

以代表性任务映射真实业务需求所需能力

绿色方块分拣
属性识别 | 刚性抓放

物品打包
多类识别 | 定位与关系推理 | 长程执行

顺序按按钮
属性识别 | 顺序推理 | 接触控制

鞋子归位
同类识别 | 定位与关系推理 | 不规则抓放

粘毛器除尘
工具识别 | 环境理解 | 时序推理 | 双臂协同 | 接触控制

清扫垃圾
工具识别 | 环境理解 | 空间推理 | 双臂协同

世界机器人大会主论坛发布 四足 VLN Benchmark

RoboChallenge



RoboChallenge

RoboChallenge · Special Benchmark

让具身导航在真实世界
可测、可比、可进化

RoboChallenge 四足机器人本体感知视觉语言导航（VLN）Benchmark

自然语言 · 真实机器人 · 本体约束 · 可复核评测

RoboChallenge

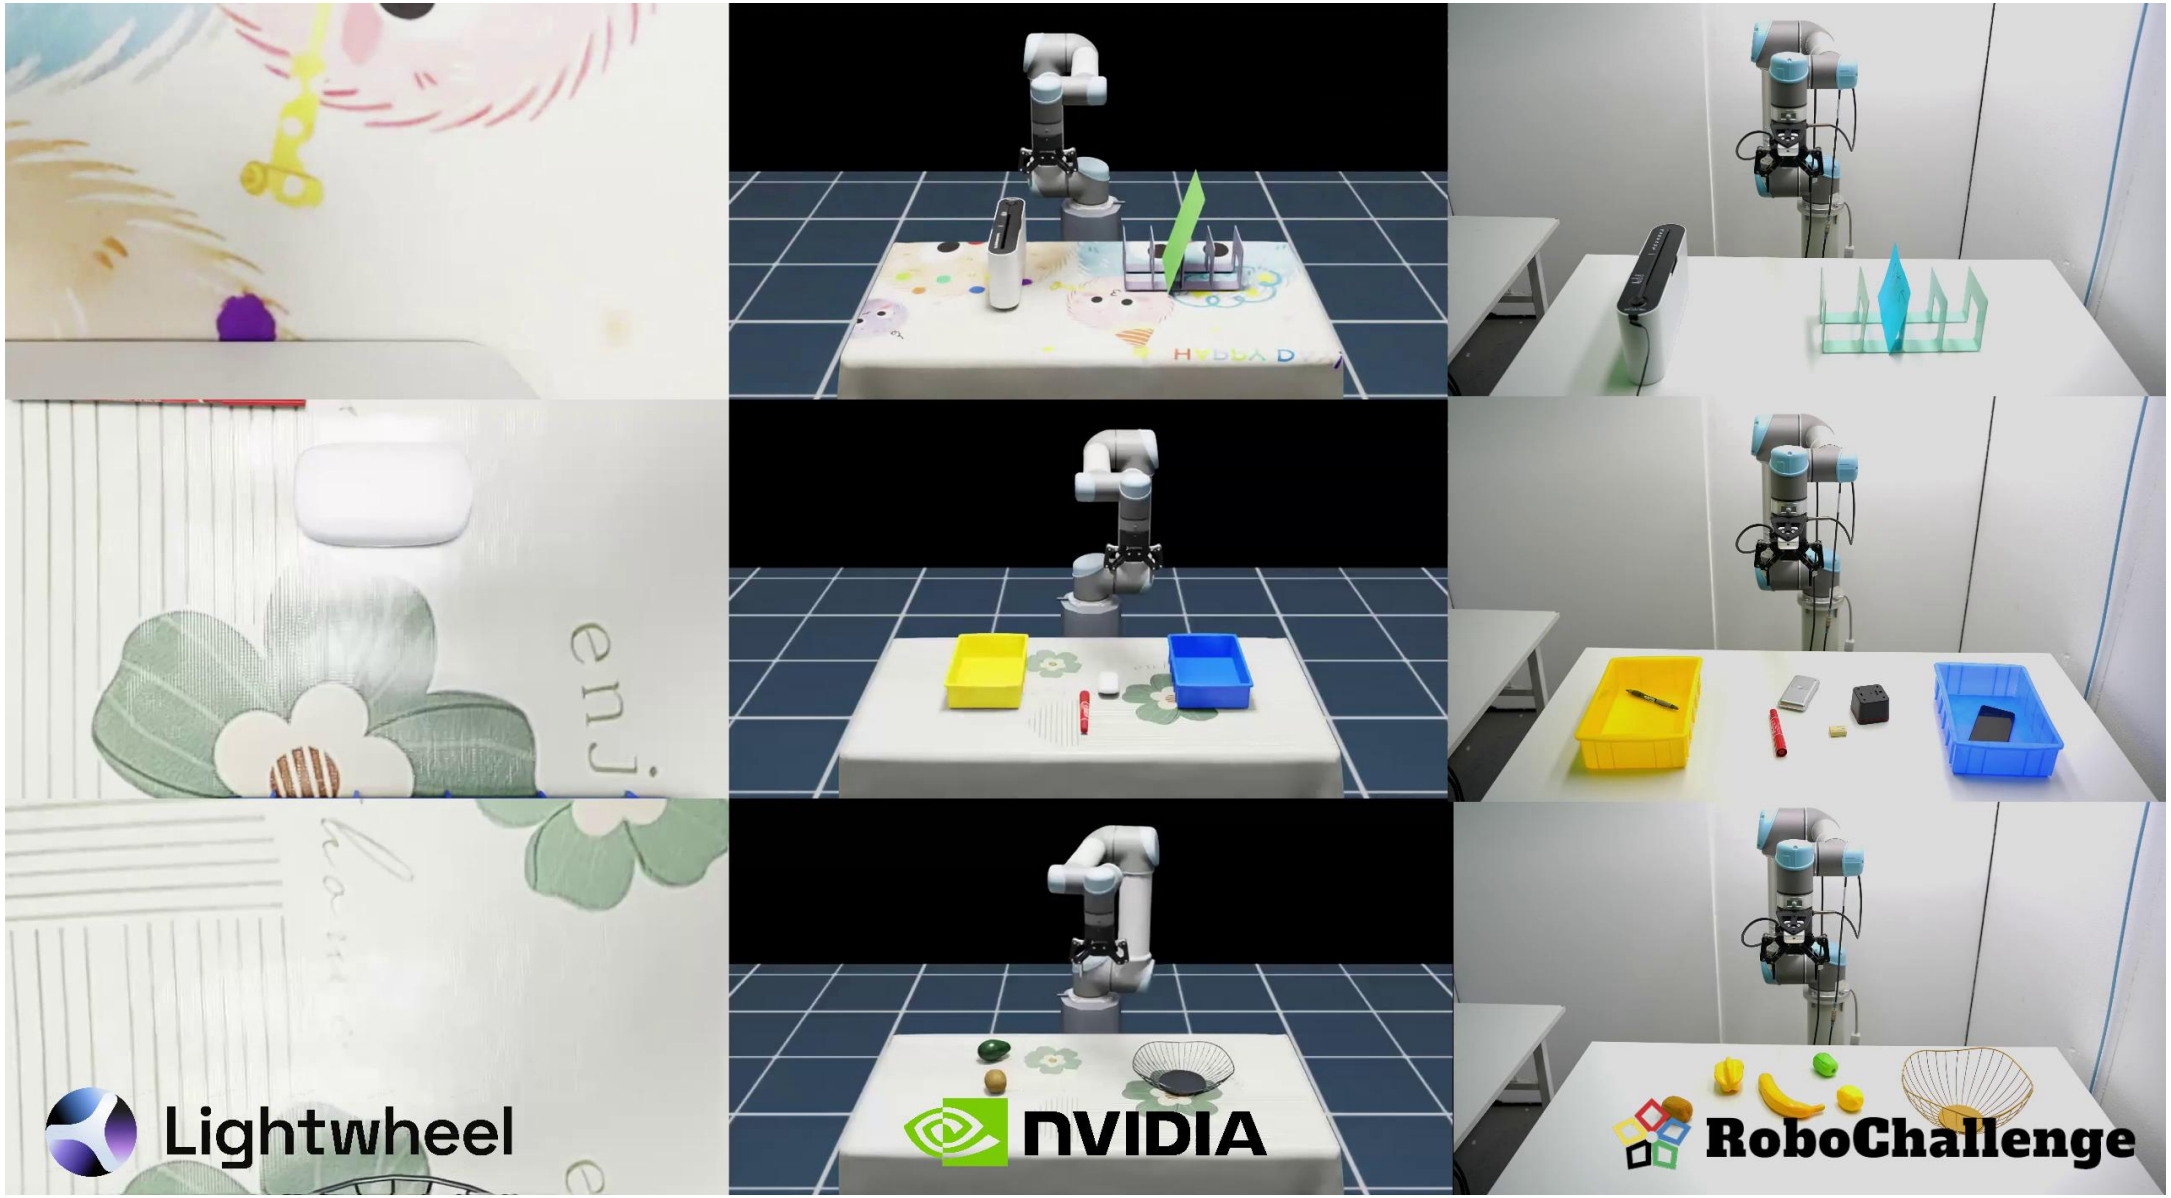
清華大學电子工程系
Department of Electronic Engineering, Tsinghua University



四足机器人 · 真机测试

联合英伟达 & 光轮智能共建Table30 V2真仿协同评测体系

RoboChallenge



RoboChallenge

双顶会赛事圆满收官

CVPR JUNE 3-7, 2026 DENVER COLORADO | ICRA 2026 VIENNA | DEXMAL | 极佳 GigaAI | AGIBOT

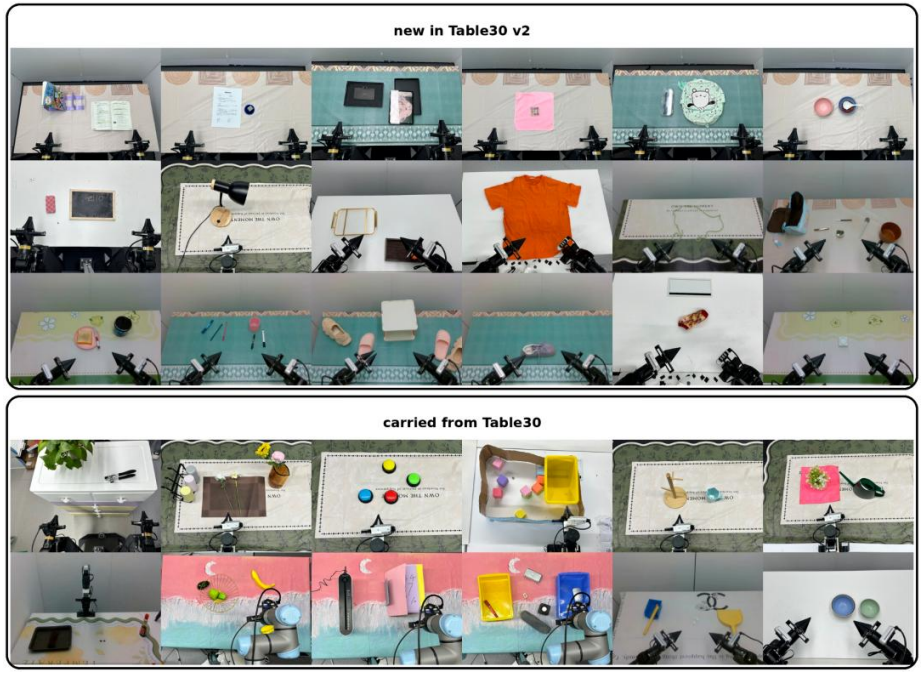
顶会历练，全球唯一在线的真机评测平台

RoboChallenge

1、CVPR赛事——全球首个大规模任务真机评测赛道

https://robochallenge.cn/competition/cvpr





2、ICRA赛事——全球首个商超场景的真机赛道

https://robochallenge.cn/competition/icra



全球影响力，具身智能领域关注度最高的赛事平台

RoboChallenge

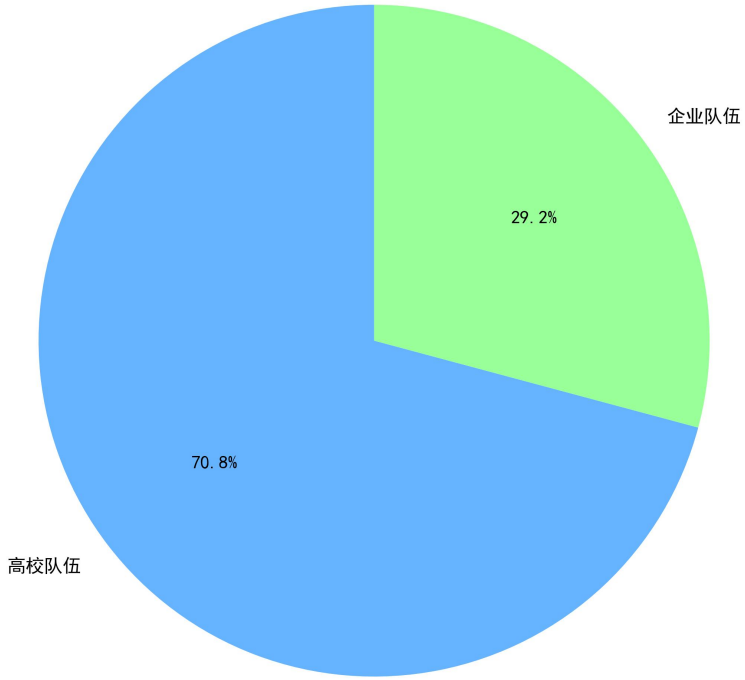
500+
全球报名人数

10+
覆盖全球国家数量

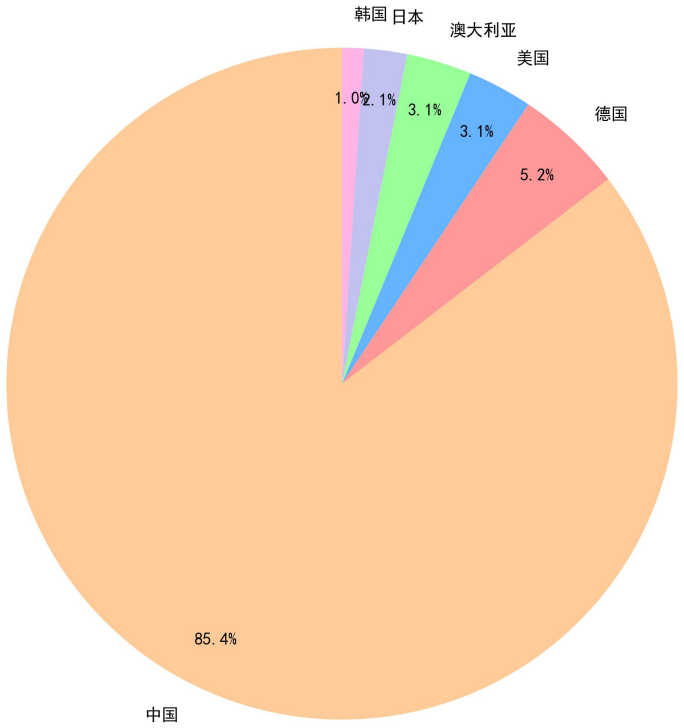
9520
真机测试次数

17K
Table30 V2 数据集下载量

参赛队伍机构类型占比



参赛队伍国家/地区分布占比



- 覆盖中国、美国、德国、韩国、日本、澳大利亚等多个国家和地区；
- 参赛阵容囊括中科院、清华大学、中国科学技术大学、加州大学圣迭戈分校等海内外知名院校，以及小米、地平线、vivo 、日本KDDI、韩国电子研究所等头部产业研发团队。

RoboChallenge

全球最大规模在线真机比赛的国际赛事平台

RoboChallenge 从一个测评平台，逐步发展成为连接全球具身智能社区的重要基础设施

RoboChallenge 硅谷/欧洲/联合国峰会

RoboChallenge





RC 在硅谷欧洲跟生态伙伴的合作



RoboChallenge 亮相 GTC 启明创投具身智能沙龙

RoboChallenge 在联合国AI for Good 全球峰会发布EAI Bench

RoboChallenge





RoboChallenge

建设全球中立、公益、非营利的具身智能平台

Looking Forward…

RoboChallenge 生态合作伙伴

RoboChallenge

合作伙伴生态

01 **聚汇全球领先具身模型**

通过开放的测评平台和全球社区， 汇聚全球最领先的具身模型

02 **测评推动科研和行业**

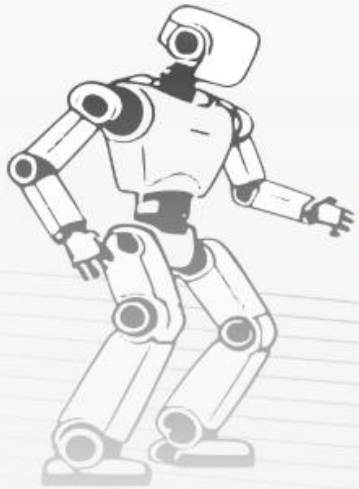
测评推动模型，模型解锁场景，场景定义本体，本体最终落地行业

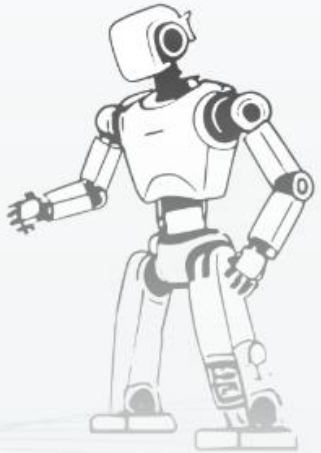
03 **生态持续扩大**

推进跟更多具身企业和政府的持续战略合作， 中试基地， 具身大赛，真实需求促进行业落地

04 **完整闭环**

建立 比赛 – 测评 – 模型迭代 – 真实场景 – 行业 的完整闭环





测评驱动创新、开放促进协作、标准认证质量、赛事连接产业

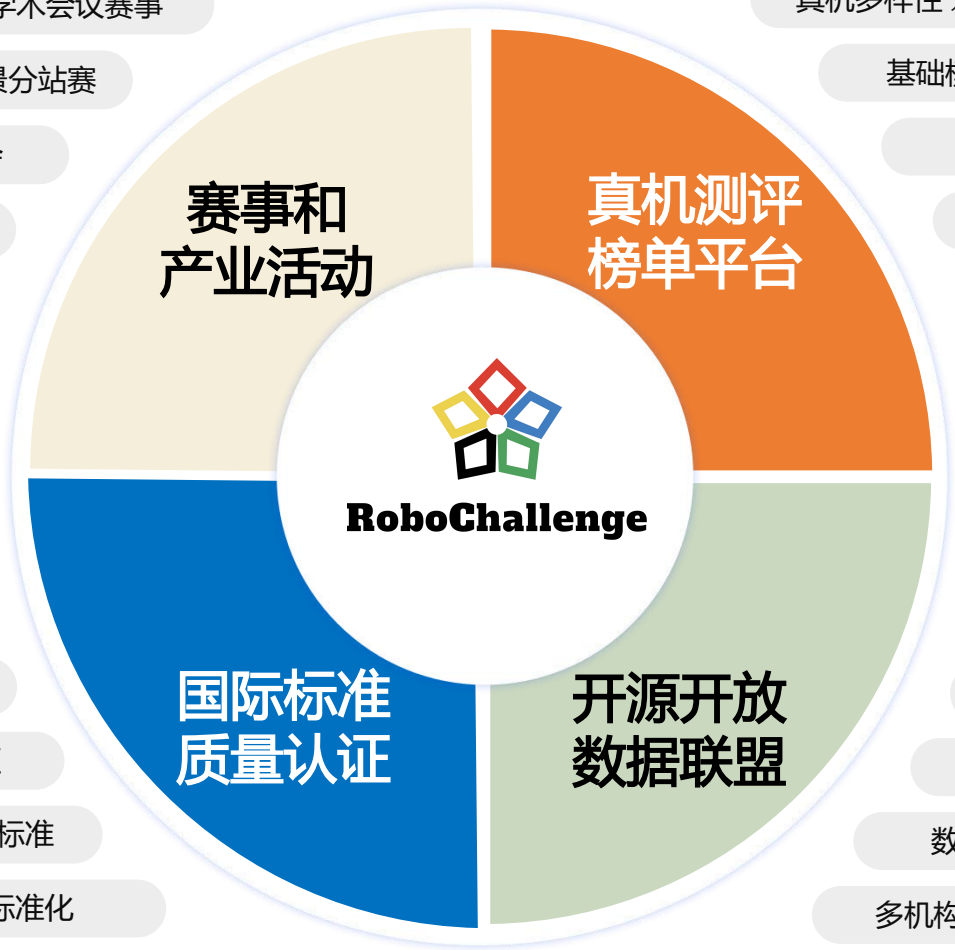
RoboChallenge

全球创新和产业平台

- 全球顶级学术会议赛事
- 国内行业真实场景分站赛
- 全球具身开发者大会
- 具身开发者网络和开源社区
- 培训和人才培养计划
- 国际合作和交流窗口

权威前沿的测评体系

- 真机多样性 人形，四足，灵巧手
- 基础模型测评 VLA/WM
- 真实场景测评
- 真实场景测评
- 工业场景挑战
- 全球榜单持续更新



国际标准和认证

- 参与国际标准制定
- 模型标准和认证
- 机器人本体质量认证
- 具身安全和可信的标准
- 测评方法标准化

开放数据核心枢纽

- 建设开放数据联盟
- 开源数据集与基准任务库
- 数据标准化规范
- 数据质量评估体系
- 多机构数据协作机制

RoboChallenge



RoboChallenge
Website

WeChat
Official Account

WeChat
Group

