GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



GOSIM

GOSIM Shenzhen 2026

机理合规审计与内生安全加固

张拳石



张拳石 Quanshi Zhang

上海交通大学，长聘副教授、博导
诠信全译智能科技（上海）有限公司，首席科学家
主要研究领域：可解释人工智能

- 海外高层次人才引进计划青年项目
- ACM CHINA 新星奖

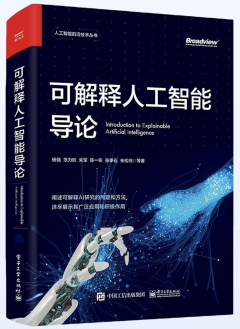
学术成果

一直专注于神经网络可解释性基础理论的研究，独立构建了「基于等效交互机理的可解释性理论体系」，产生了广泛的国际影响。

- 10 位知名学者其论文作为**论证其自身算法正确性的理论依据**
- 10 位知名学者**基于其理论开发了新型解释性算法**

兼任职务

领域主席	NeurIPS 2024,2025、ICML 2026、AAAI 2025领域主席
责任编辑	Transactions on Machine Learning Research 责任编辑
分论坛主席	AAAI 2019, CVPR 2019, ICML 2021 可解释性分论坛主席
主讲人	IJCAI 2020,2021 可解释性Tutorial主讲人



专著



ACM China新星奖



华为优秀技术成果奖



中国工程院院刊
最佳论文奖

AI市场痛点：评测、训练、推广，三者进退失据

评测进退失据

只有输出结果正确率，而无法发现无处不在的表征机理缺陷，无法证明头部AI模型的表征先进性，**无法帮助AI公司建立技术壁垒。**

训练进退失据

逃不出Scaling law限制，无法有的放矢地修正表征缺陷，只知道性能差距，但无法明确确切的优化方向，无法提升训练效率。**传统路线无法帮助AI公司真正战胜对手。**

推广进退失据

无法用严格的指标证明竞争对手的表征缺陷，**无法证明自身模型的优越性，**没有“一杆子打翻一船人”的指标。

- 痛点1: 头部AI公司**无法建立技术壁垒**
- 痛点2: 责任敏感型应用（法律模型、金融模型）**无法量化决策逻辑正确性**
- 痛点3: 高可靠性需求应用（军工武器、自动驾驶）**无法充分诊断神经网络机理层面的表征缺陷**
- 痛点4: 大模型公司**无法降低训练成本**

核心技术一：**解释**、**量化**并**评测**神经网络『精细决策逻辑』的正确性

核心技术二：率先基于神经网络『精细决策逻辑』有的放矢地debug神经网络，**提升神经网络训练效率**

“

Scaling Law的桎梏、评测的失能、优化方向的迷茫，

归根到底还是一个可解释性的问题。

—— 端到端训练，只惩罚模型输出，不惩罚底层机理。

”

困境：缺乏严谨技术路线保障神经网络模型的可解释性、安全与可信

天然反直觉：复杂的连接主义模型 vs. 简约的符号主义解释

悲观论调

长期经验性认为**对神经网络严谨的符号化解释**是**“不可能的问题”**

整个方向的**严谨性被经验性否定**



Nature MI: “标题直译：**在重大决策中停止解释黑盒机器学习模型，而要选用本身表征可解释的模型”**

引用7381次

— **杜克大学**的Cynthia Rudin教授





Viewpoint: “标题直译：**健康领域对可解释人工智能的错误期待”**

引用793次

— **MIT**的Ghassemi教授和**哈佛**的Beam教授



NeurIPS论文 指出：**大部分归因解释算法不可靠，其本质是图像的边缘提取器**

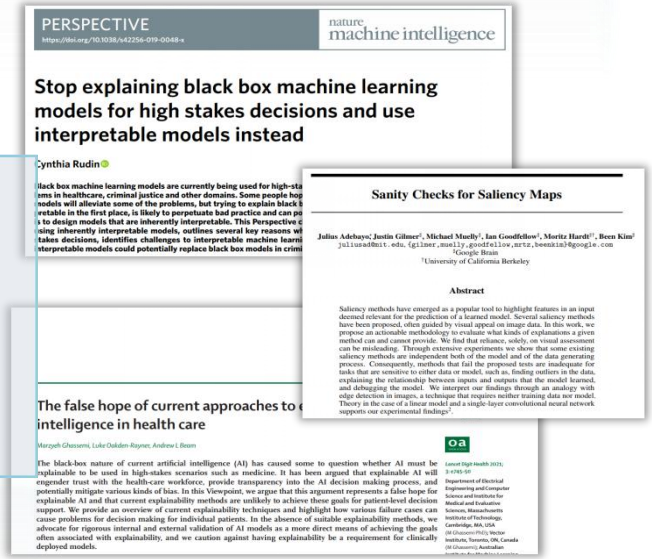
引用2319次

— **Google DeepMind** 科学家Been Kim

10K+

总引用次数

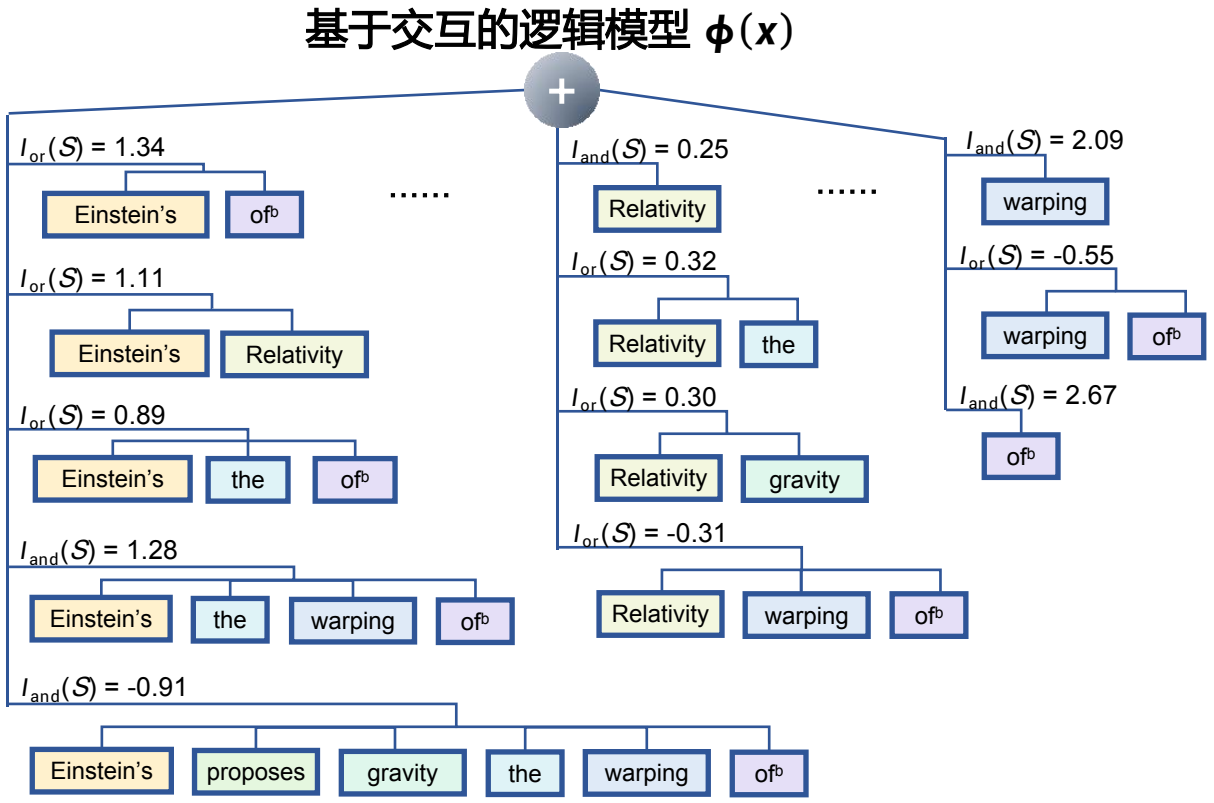
悲观论调
成为领域共识



市场机会 = 全球共识性期待 + 技术的禁区

全球独创等效交互机理技术

给定一个包含n个单元的输入样本，可以构造一个包含少量AND-OR交互的「AND-OR逻辑模型」。
此逻辑模型恰好可以精确拟合神经网络在此样本的全部2^n个遮挡状态下2^n个不同的分类值。



模型输入: Einstein's Theory of [a] General Relativity proposes that gravity is the warping of[b]

LLaMA-7B 模型的预测: space

输出分数 $v(\text{“space”}|\boldsymbol{x}) = 12.4$

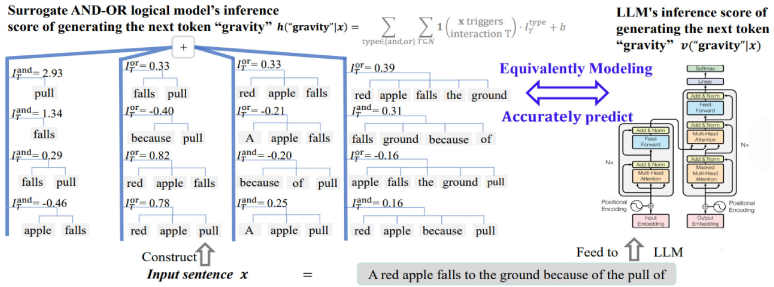
10个最显著的与或交互

{of[b]}	I_and(S) = 2.67
{warping}	I_and(S) = 2.09
{Einstein’ s, of[b]}	I_or(S) = 1.34
{Einstein’ s, Relativity, proposes, the, warping, of[b]}	I_and(S) = -1.31
{Einstein’ s, the, warping, of[b]}	I_and(S) = 1.28
{Einstein’ s, Relativity}	I_or(S) = 1.11
{Einstein’ s, proposes, gravity, the, warping, of[b]}	I_and(S) = -0.91
{Einstein’ s, the, of[b]}	I_or(S) = 0.89
{Einstein’ s, Theory, of[a], General, Relativity, proposes, that, gravity, is, warping, of[b]}	I_and(S) = 0.51
{Einstein’ s, of[a], Relativity, proposes, that, gravity, is, warping, of[b]}	I_and(S) = -0.30

证明神经网络精细逻辑可在数学上严谨地解释为交互概念

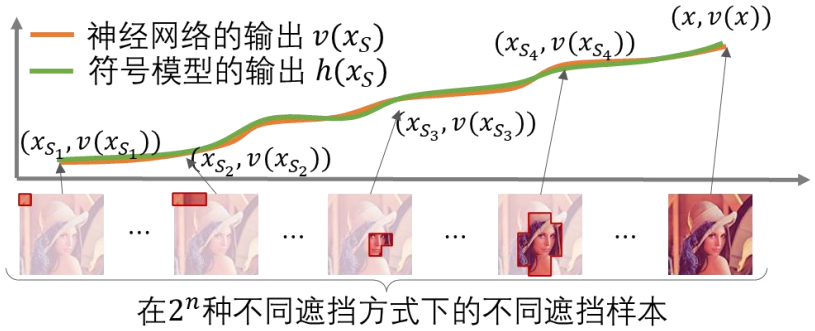
稀疏性（已证明）

神经网络往往只建模极少量的显著交互
（已在三个充分条件1下证明）



无限拟合性（已证明）

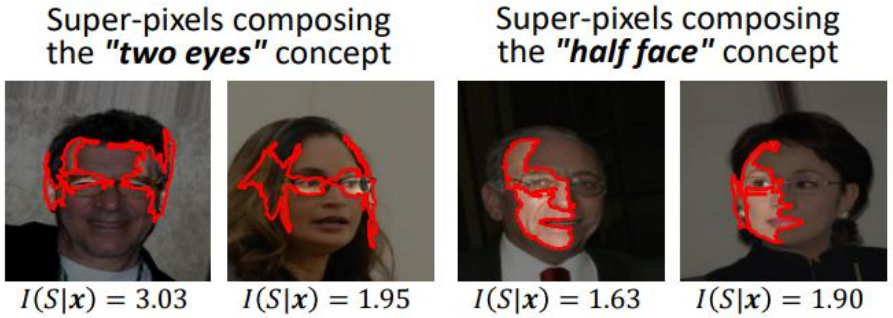
任意遮挡输入样本，等效交互逻辑模型均可精确拟合出神经网络在遮挡样本上的输出



在2^n种不同遮挡方式下的不同遮挡样本

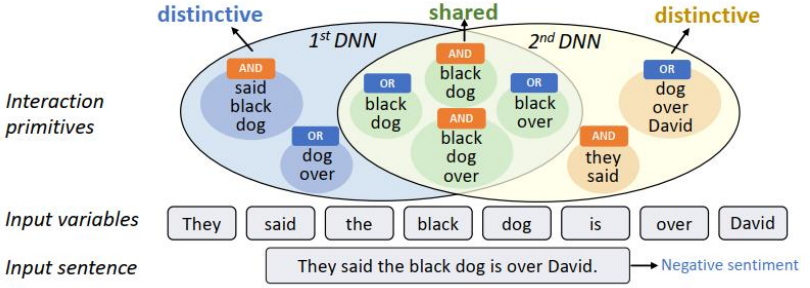
样本间的迁移性

神经网络在同一类别的不同样本上往往建模了相似的显著交互



模型间的迁移性（泛化性）

面向同一任务的不同神经网络往往建模了相似的交互

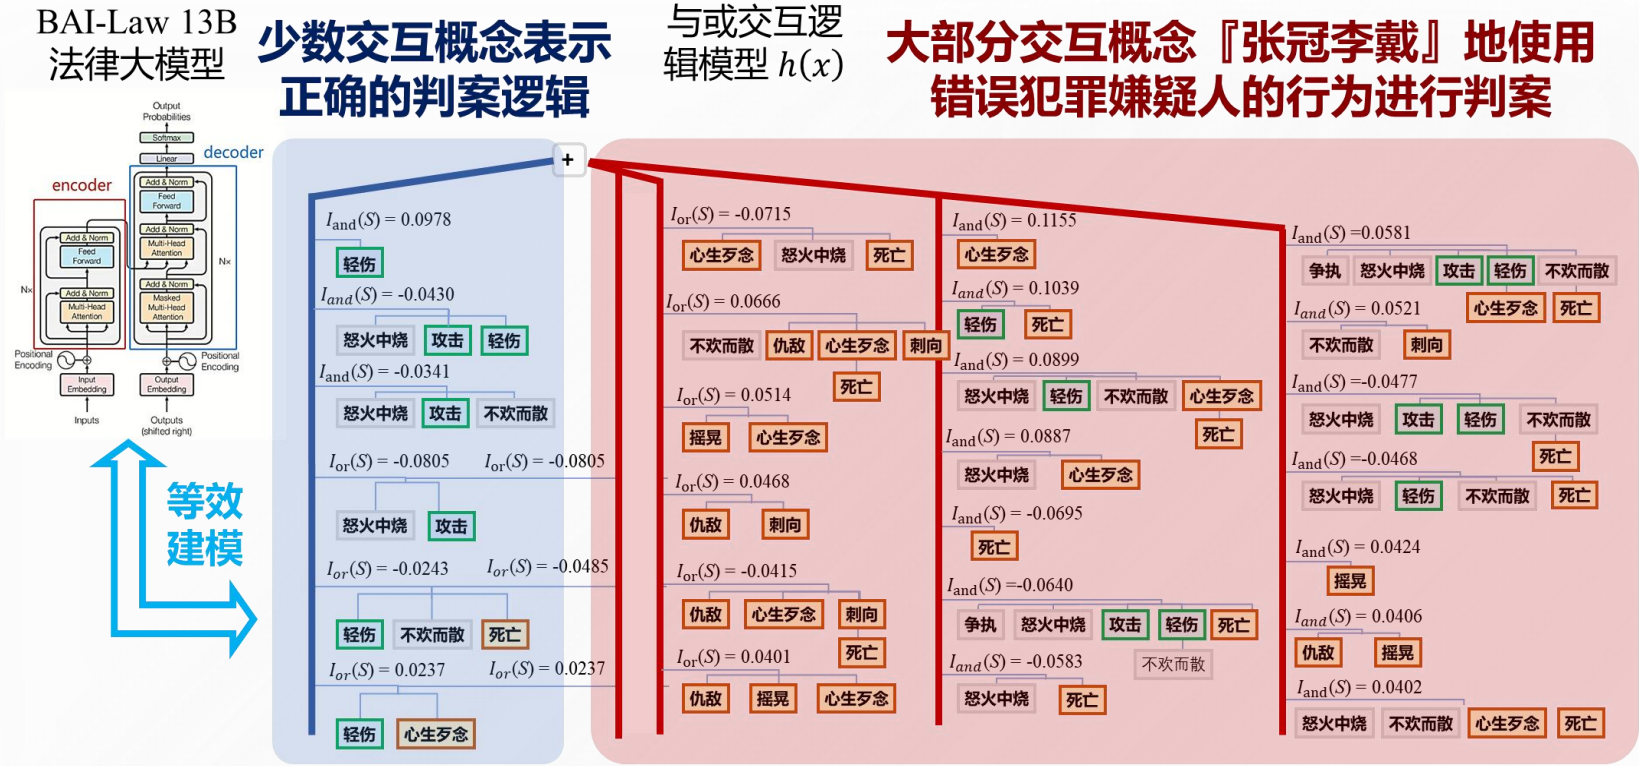


法律大语言模型的表征风险评估

法律大模型虽然输出结果正确，但是大部分内在交互逻辑张冠李戴。

大模型判决结果：

张三的行为已经构成了【伤害罪】



输入案例：张三与李四**争执**时言辞激烈，**怒火中烧**下张三**攻击**了李四的头部，造成李四**轻伤**，二人**不欢而散**。与张三分开后，李四遇到了**仇敌**王五。王五见李四走路**摇晃**，**心生歹念**，从口袋中掏出折叠刀**刺向**李四的腹部，导致李四**死亡**。张三的行为已经构成了故意**【大模型生成后续内容：伤害罪】**

正确的判案事实　错误人物的行为/动机　无关信息

自动驾驶/军事场景目标检测模型表征风险评测

在自动驾驶/军事目标检测应用中，发现即使检测结果正确，也有**超60%的交互表示正负抵消的高阶噪声。**

与或交互逻辑模型节点图例

1.每一个字母代表一个交互的图像区域，共选取10个交互元素

A　B　...　I

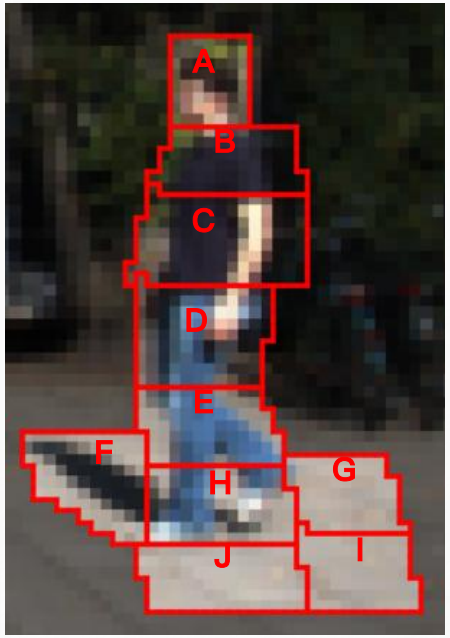
2.红色方块代表正向影响交互，蓝色代表负向干扰交互

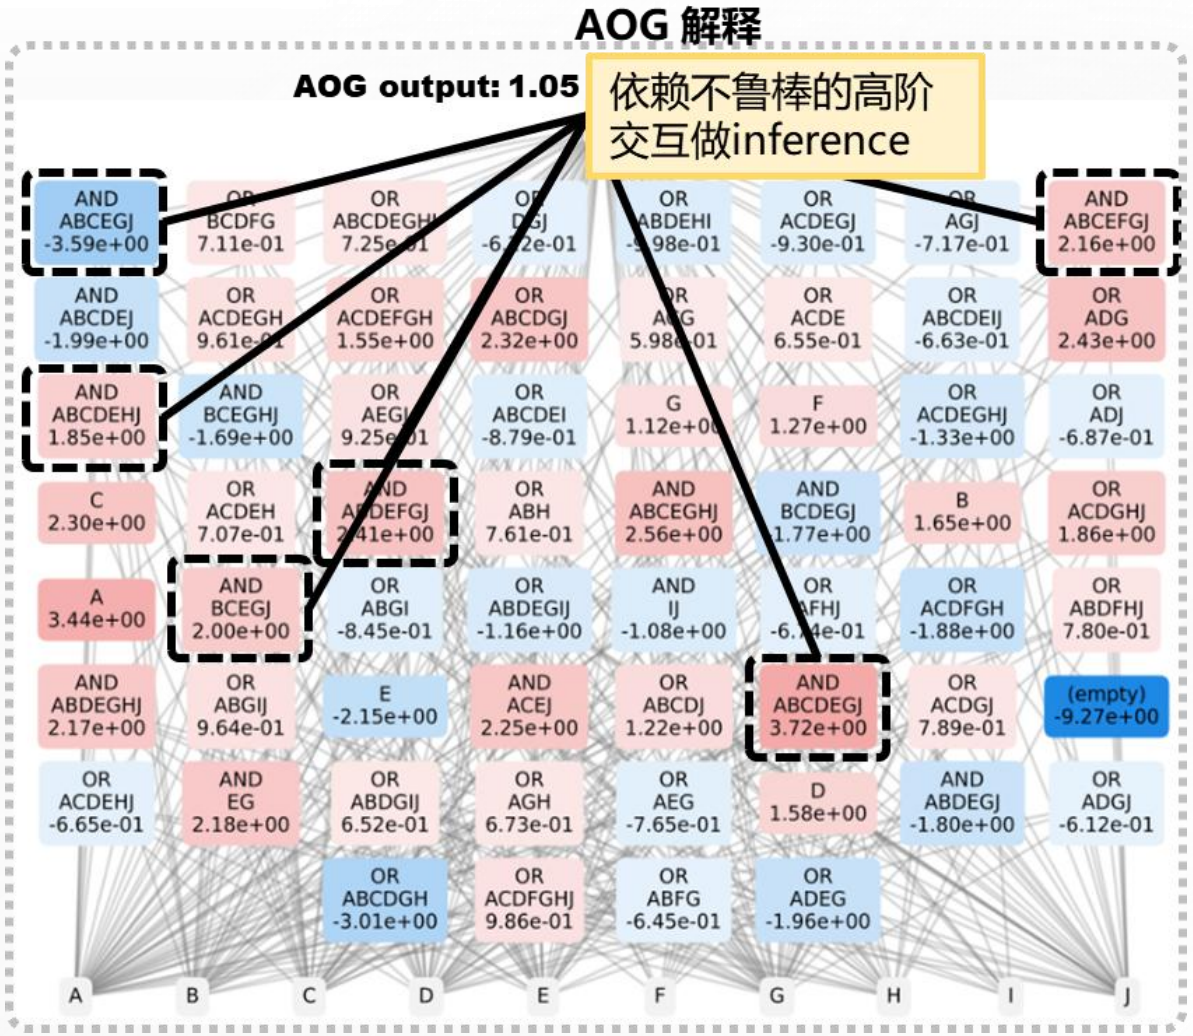
AND ABCEDG -3.59e+00　　OR BCDFG 7.11e-01

行人检测模型案例

模型输入：一张图像

模型输出：[是] [否]





标准：机理合规审查标准体系

基于可泛化交互理论，我们提出了一套机理合规审查框架，确保AI系统"做对的事"的同时也"正确地做事"。

由上海交通大学牵头，组织会议合作，推进测评标准

✦学术界参与：上海交通大学、清华大学、北京大学、浙江大学、北京通院人工智能研究院、中国人民大学、中山大学、北京交通大学、中国科学院大学、复旦大学、西安交通大学、同济大学、中国科学院计算技术研究所、中国科学院自动化所、南开大学、华东政法大学、华中科技大学、中国科学技术大学、南京大学、北京航空航天大学、西安电子科技大学

✦产业界参与：国家工信安全中心、华为公司、中国电信、上海无问芯穹智能科技有限公司、北京航宇天穹科技、深度符号公司，等等

同时，也参与起草由深圳市人工智能产业协会归口管理并组织的团体标准《智能体安全评测规范》

中关村信息技术和实体经济融合发展联盟

联盟函〔2025〕10号

关于批准《工业人工智能模型精细表征逻辑评测指标》团体标准立项的通知

各有关单位：

根据《中关村信息技术和实体经济融合发展联盟团体标准管理办法》的规定，中关村信息技术和实体经济融合发展联盟

深 圳 市 人 工 智 能 产 业 协 会

关于召开团体标准《智能体安全评测规范》专家评审会议的通知

按照《协会团体标准管理规定》的要求，为高质量完成团体标准的编制工作，确保标准更科学适用，更具专业性、实用性和可操作性，贴近产业特点及需求，团体标准《智能体安全评测规范》经过多次讨论，形成了征求意见稿，于 2025 年 12 月 20 日—至今挂网征求意见，现进入送审阶段，

大模型训练，是否真的只是一场盲目的试错？

人脑的神经连接各不相同，却能涌现出相似的符号认知。

那么，结构不同、数据不同的大模型，是否也存在趋同的训练演化？

发现殊途同归的优秀表征 —— 好模型不约而同的提升方向

Qwen模型中正负抵消的纺锤形交互
——已证明这些正负抵消的纺锤形交互代表过拟合的表征，而且这些纺锤形分布的交互的泛化性很差（多数交互无法在测试样本观察到）。

DeepSeek模型整体呈现指数下降趋势且无明显“纺锤形”大部分交互可以泛化到测试样本

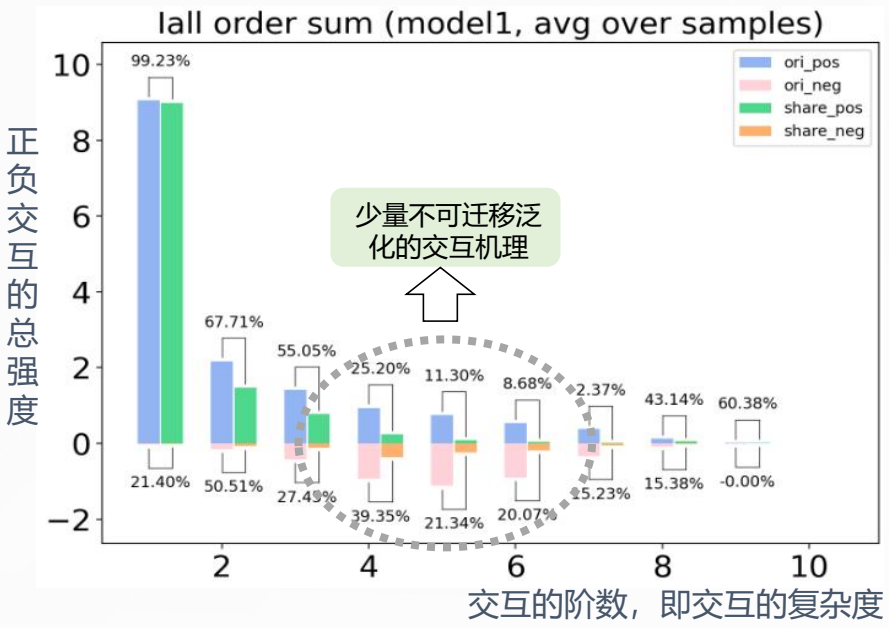
↗
提升模型之间的泛化可信交互机理的比例，惩罚呈现“纺锤形”的不可泛化交互机理。

蓝色柱状图和粉色柱状图各阶正负交互的总强度

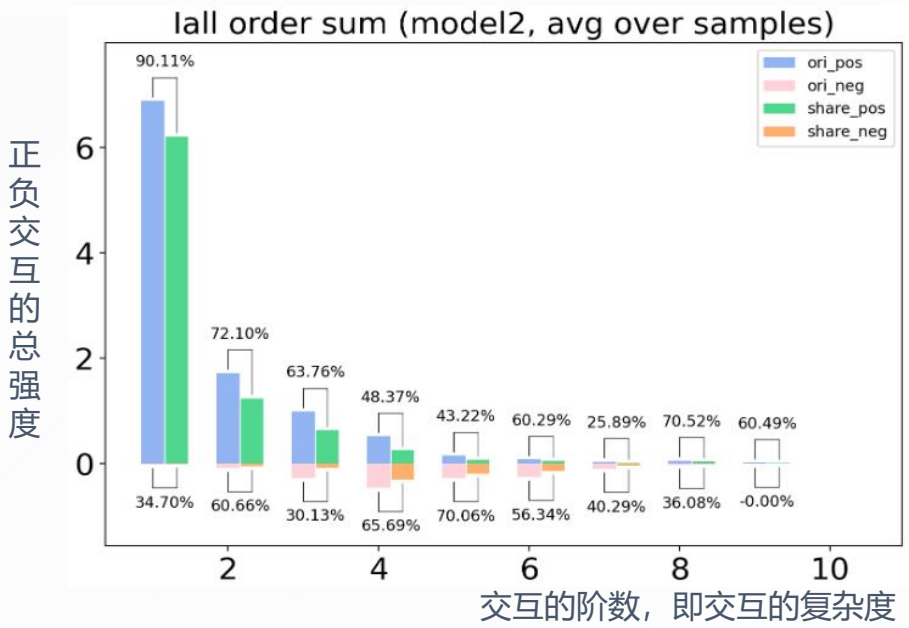
绿色柱状图和橙色柱状图表示公共交互

Qwen和DeepSeek模型虽然有全然不同的结构，他们**建模了相似的表征**。

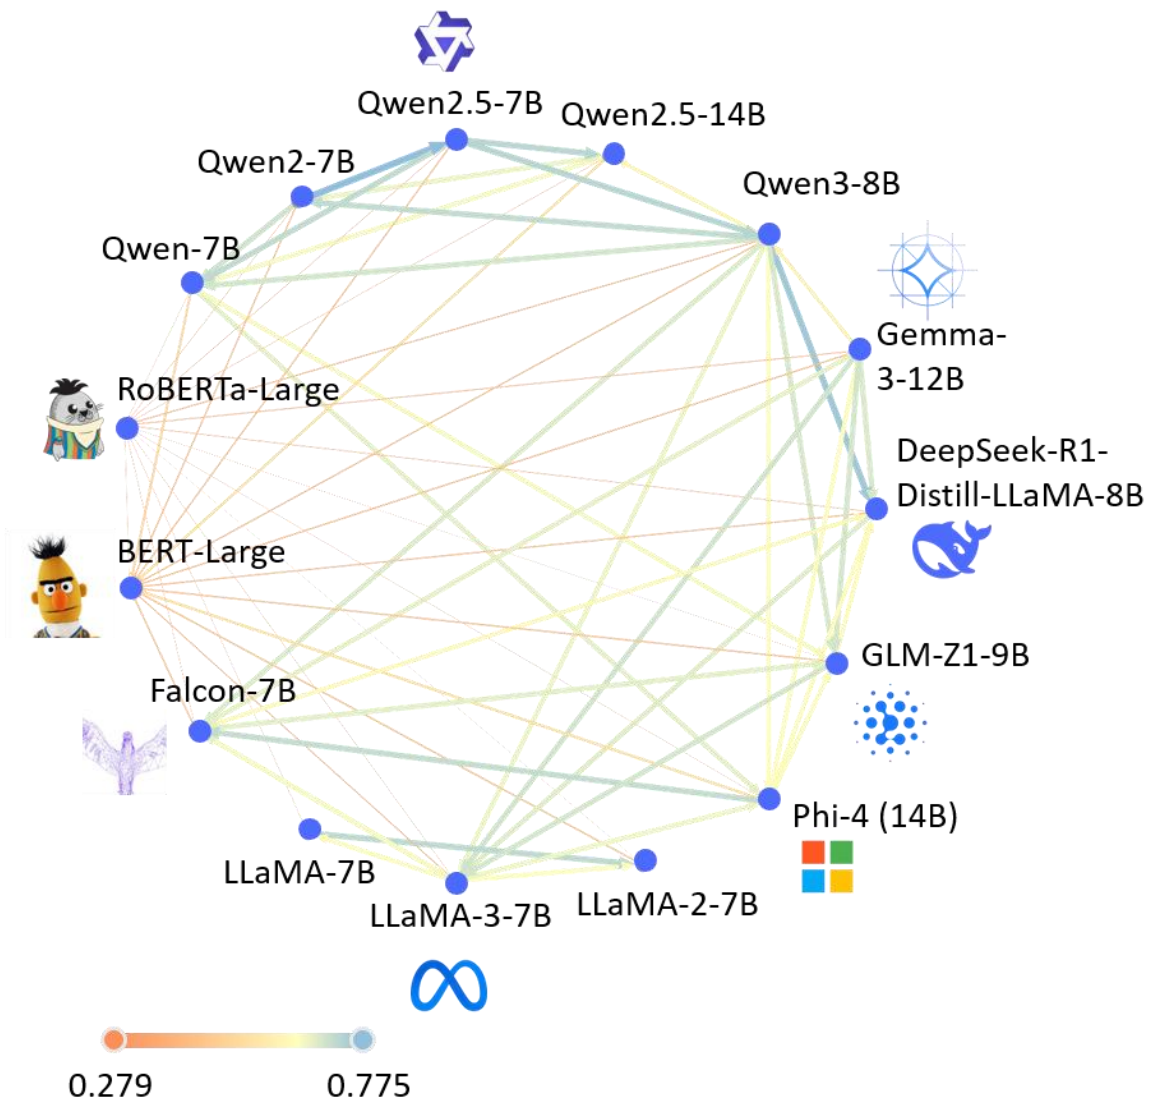
Qwen2.5-7b

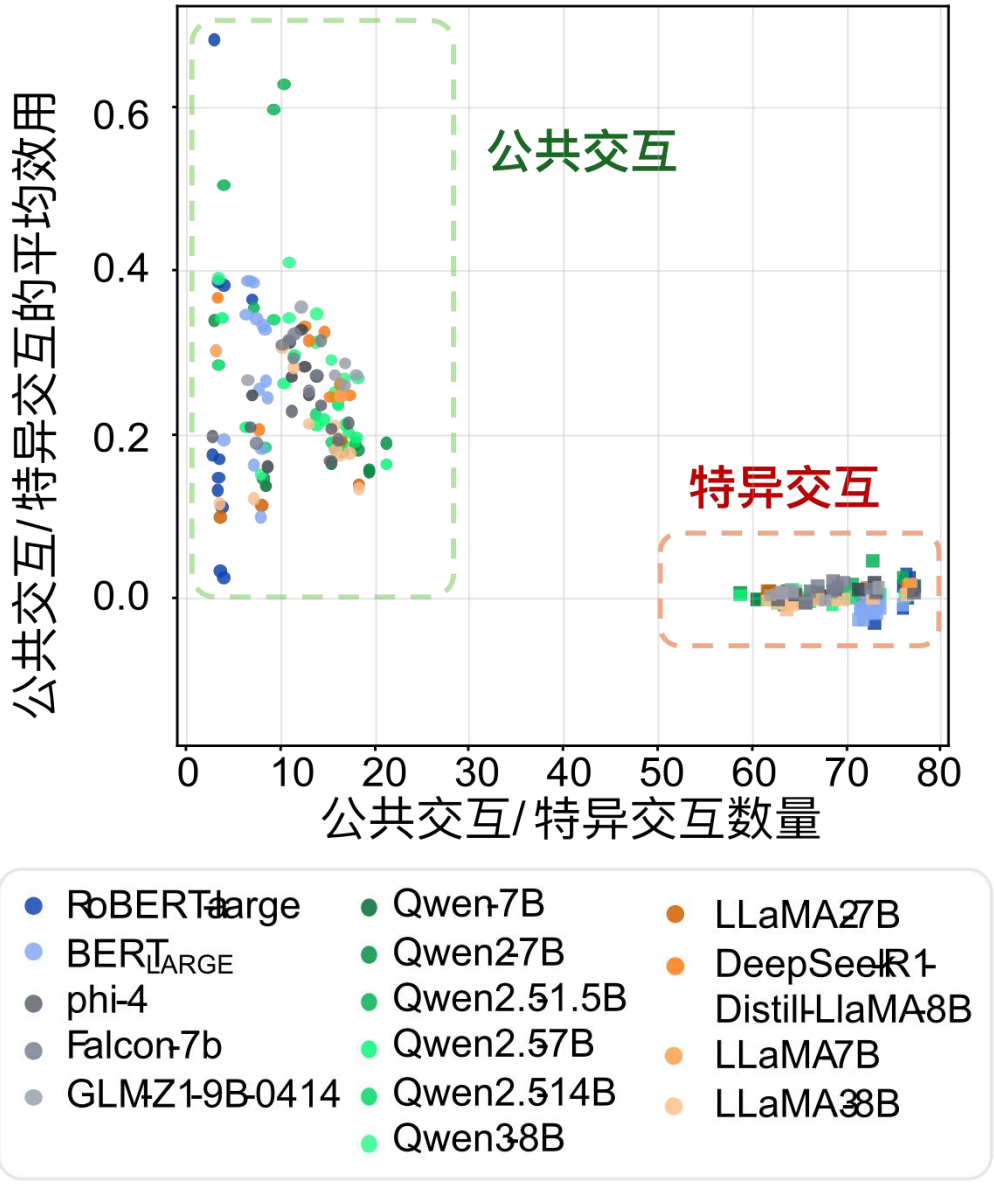


DeepSeek-r1-distill-llama-8b



前沿大模型在交互表征上的殊途同归





所以，我们该如何优化大模型?

惩罚每一个输出错误？ or 找到模型间的共识?

应用：指导模型训练效能提升与安全加固的解决方案

传统大模型公司

- 需要几周来验证模型的表征质量（**低效**）

VS

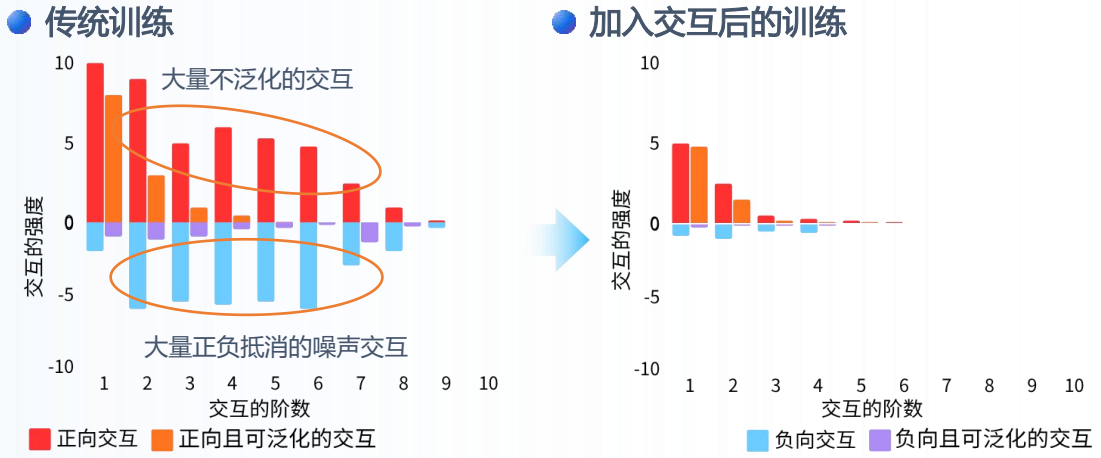
我们：高效跟踪检测交互的泛化性，大幅降低训练成本

- 实时反馈人工智能模型在哪个数据集上开始过拟合
- 实时指导评价相关的优化技术的有效性（数据清洗、思维链、等等）

$$h(x_S) = \underbrace{1\left(\begin{matrix}x_S \text{ triggers} \\ \text{interaction } T_1\end{matrix}\right)\cdot I_{T_1} + \ldots + 1\left(\begin{matrix}x_S \text{ triggers} \\ \text{interaction } T_2\end{matrix}\right)\cdot I_{T_2}}_{\text{泛化交互：可靠的表征}} + \underbrace{1\left(\begin{matrix}x_S \text{ triggers} \\ \text{interaction } T_3\end{matrix}\right)\cdot I_{T_3} + \ldots + 1\left(\begin{matrix}x_S \text{ triggers} \\ \text{interaction } T_4\end{matrix}\right)\cdot I_{T_4}}_{\text{不泛化交互：无法帮助提升模型测试性能的错误表征，带来潜在风险}} + b$$

基于机理解释的高效表征修复与训练，展现超越端到端训练的效率

- 去除大量不泛化的交互概念
- 保留可以泛化的交互概念
- 从精细逻辑层面提升神经网络表征健康程度



基于交互的大模型训练加速

精确判定过拟合样本和欠拟合样本
精确判定各类样本的过拟合时间点

模型后训练规律

基座模型的后训练 过程只有去噪（去除不可泛化的交互机理），而并不学习可靠表征。

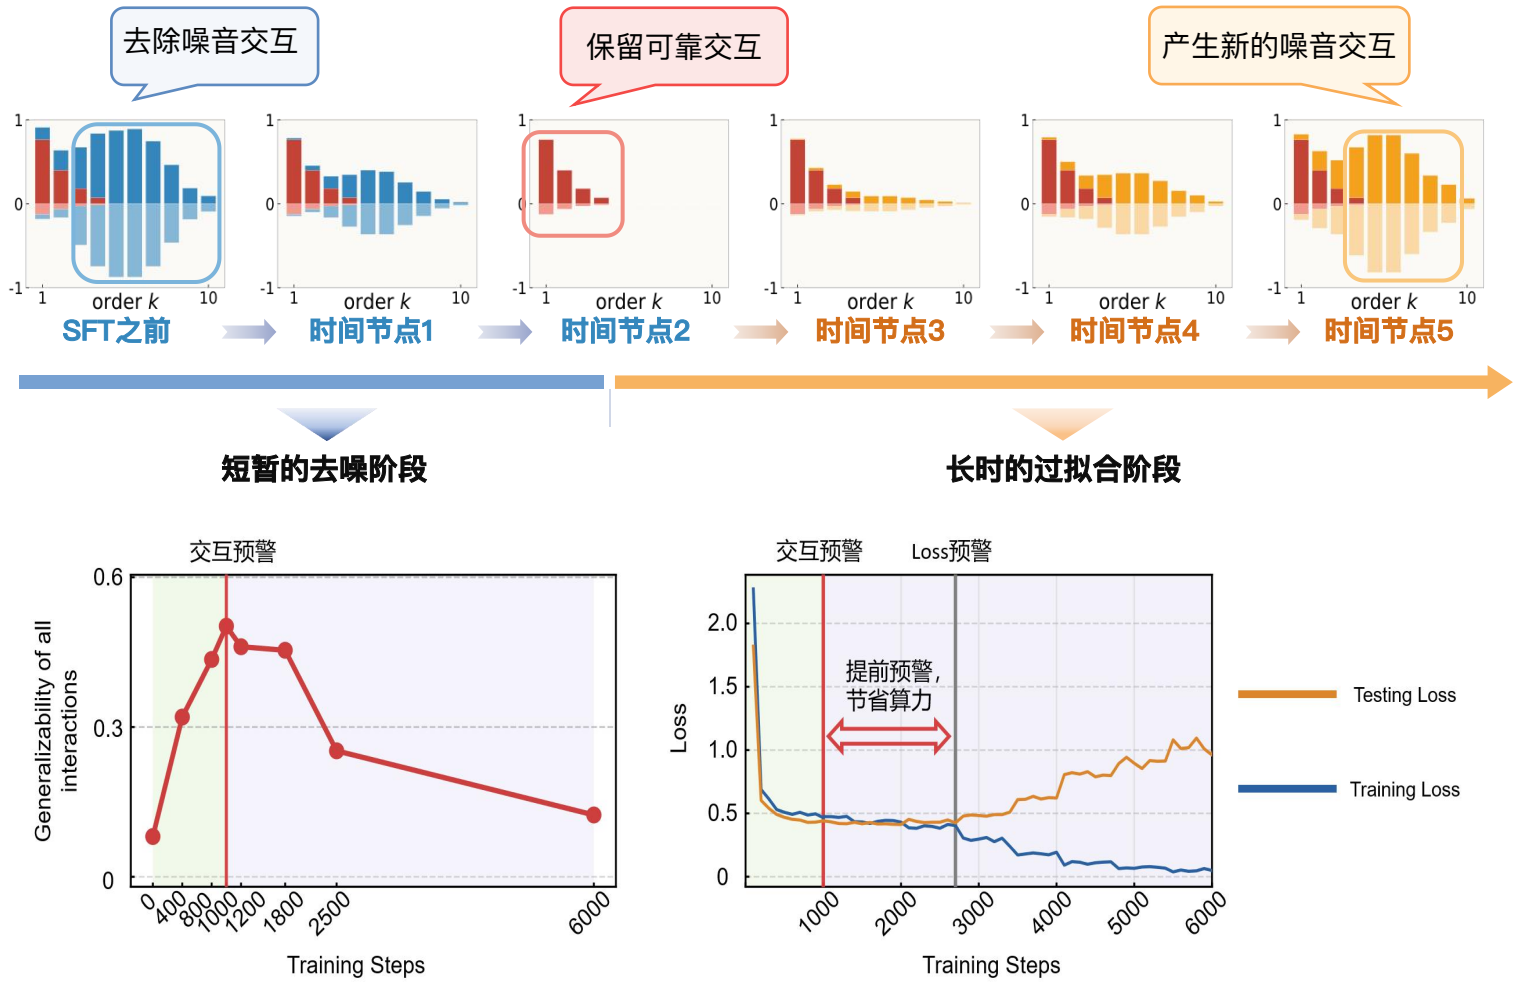
正常训练阶段

去噪阶段非常短，样本容纳量很少

过拟合阶段

一旦去噪结束，后续训练会重新学习不可泛化的噪声交互机理——过拟合的根因。

大模型在六个监督微调阶段（SFT）的交互分布



交互机理的表征质量决定模型的性能

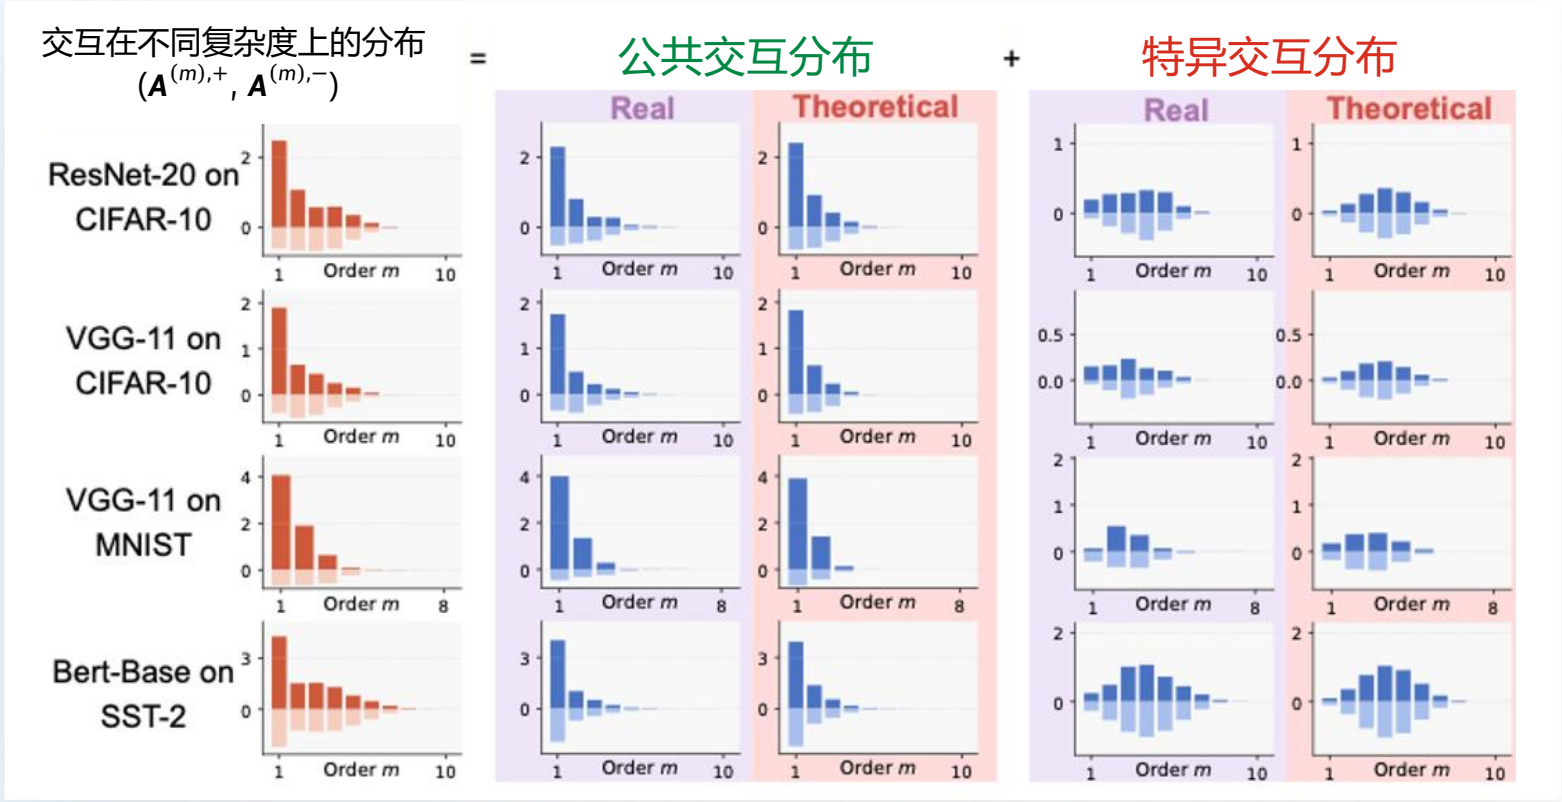
特异交互：模型过拟合的本质

大量正负抵消，数学上同构于噪声触发

核心证明：噪声同构

特异交互的统计特征与**随机噪声**完全同构：

1. **数值正负抵消**
2. **数量正比于潜在交互的组合数量**



分布形态对比

公共交互 → 呈**衰减形分布**：低阶交互主导，高阶交互迅速衰减，贡献稳定且正向

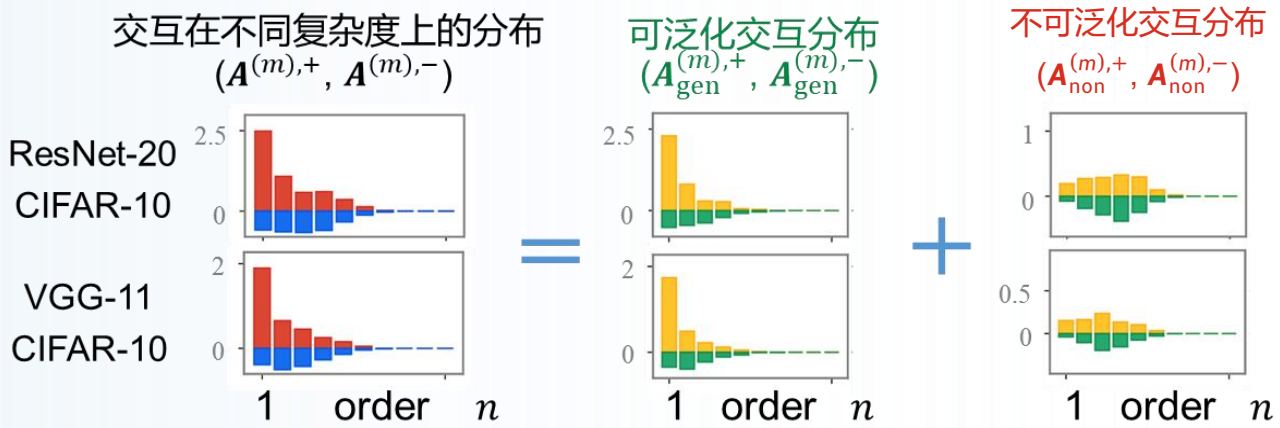
特异交互 → 呈**纺锤形分布**：中间高阶交互密集，正负随机抵消，净贡献趋近于零

过拟合根因：证明不泛化交互机理的分布

可泛化交互呈衰减形分布
不泛化交互呈纺锤形分布

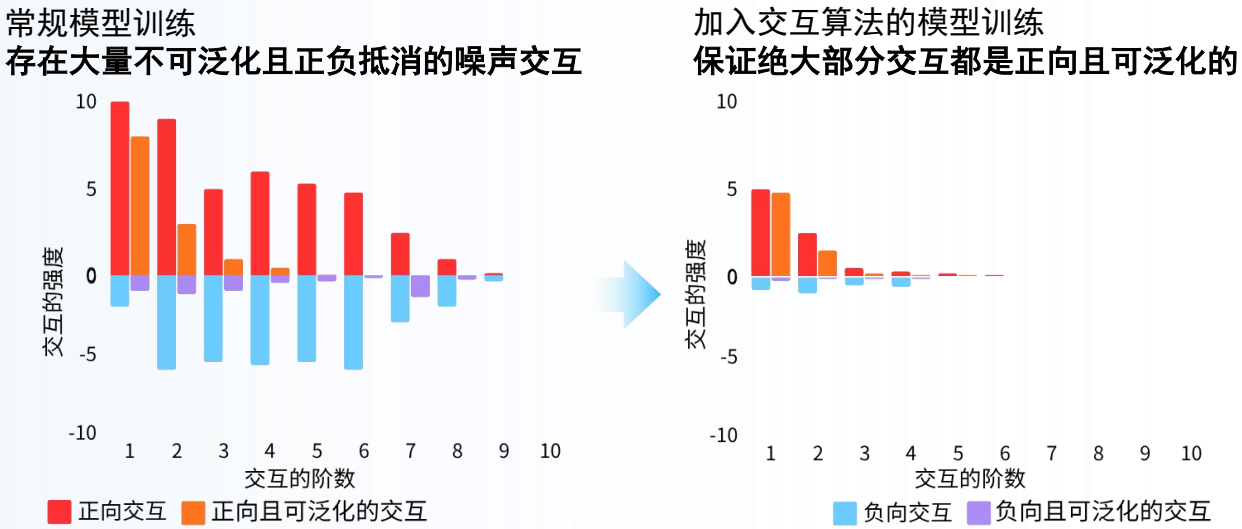
$$\mathcal{A}^{(m),+}_{\text{spindle}}(\alpha,\beta) = -\mathcal{A}^{(m),+}_{\text{spindle}}(\alpha,\beta) = \beta\frac{\Gamma(\alpha n+1)}{\Gamma(m+1)\cdot\Gamma(\alpha n-m+1)}$$

纺锤形分布



基于机理解释的高效表征修复与训练，展现超越端到端训练的效率

- 去除大量不泛化的交互概念
- 保留可以泛化的交互概念
- 从精细逻辑层面提升神经网络表征健康程度



交互机理的表征质量决定模型的性能，确定早停时机

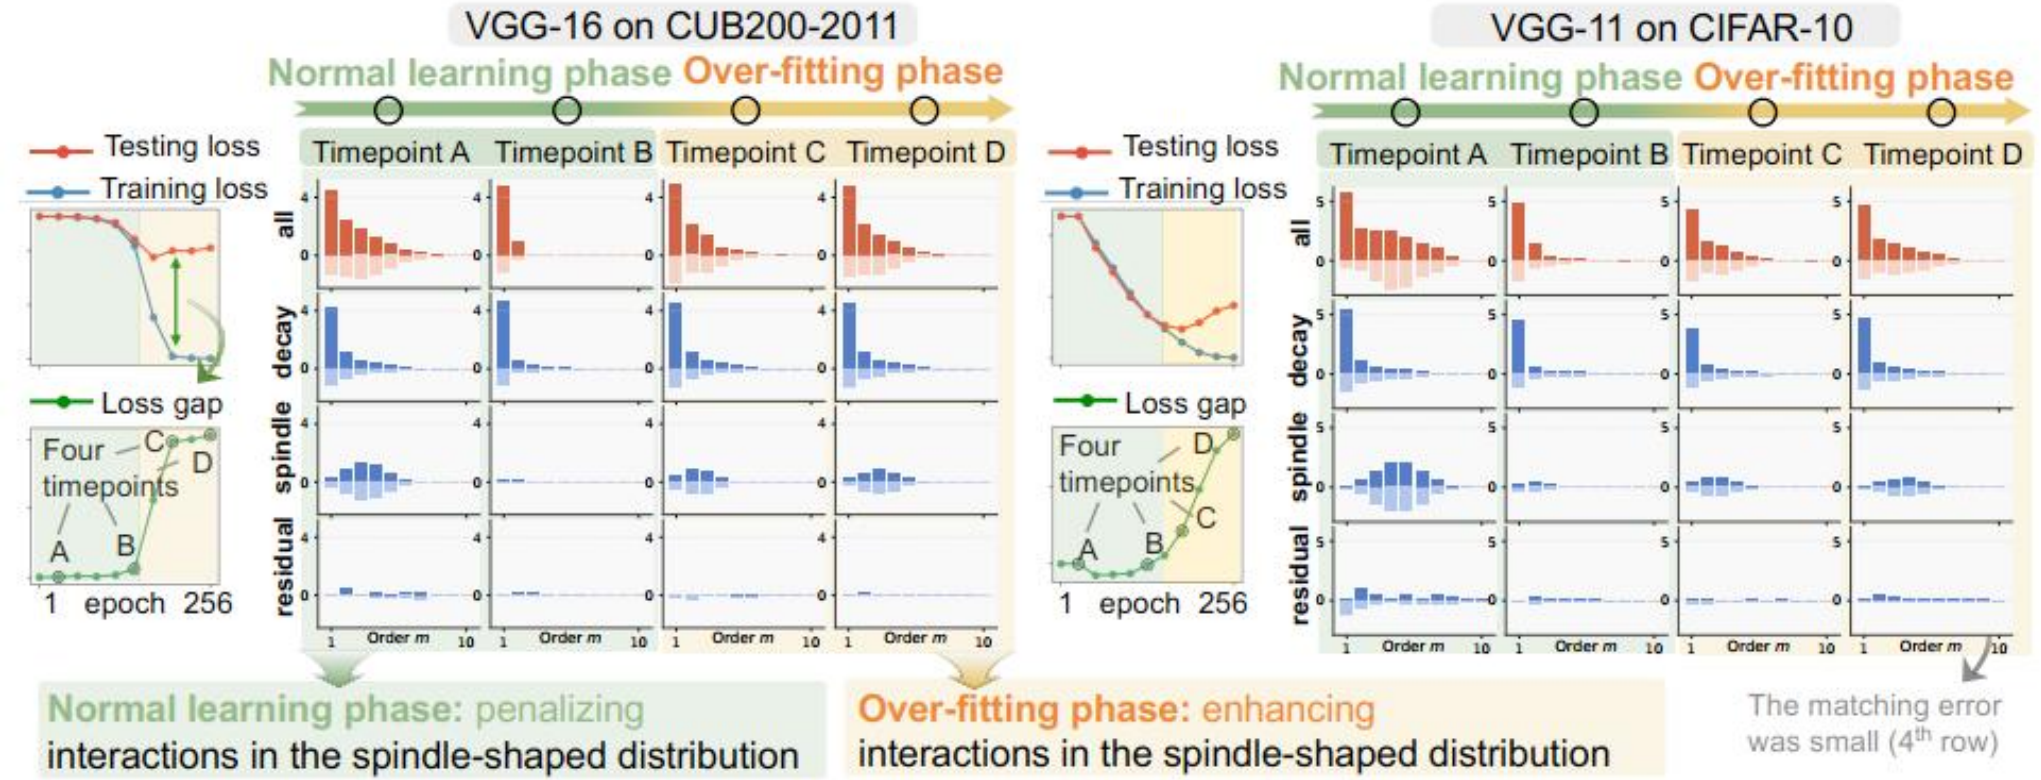
特异交互（呈纺锤分布）的出现，揭示过拟合本质，可指导判断早停时机

正常训练阶段

DNN 逐渐消除呈纺锤形分布的交互，使整体交互分布最终趋于衰减型形态。

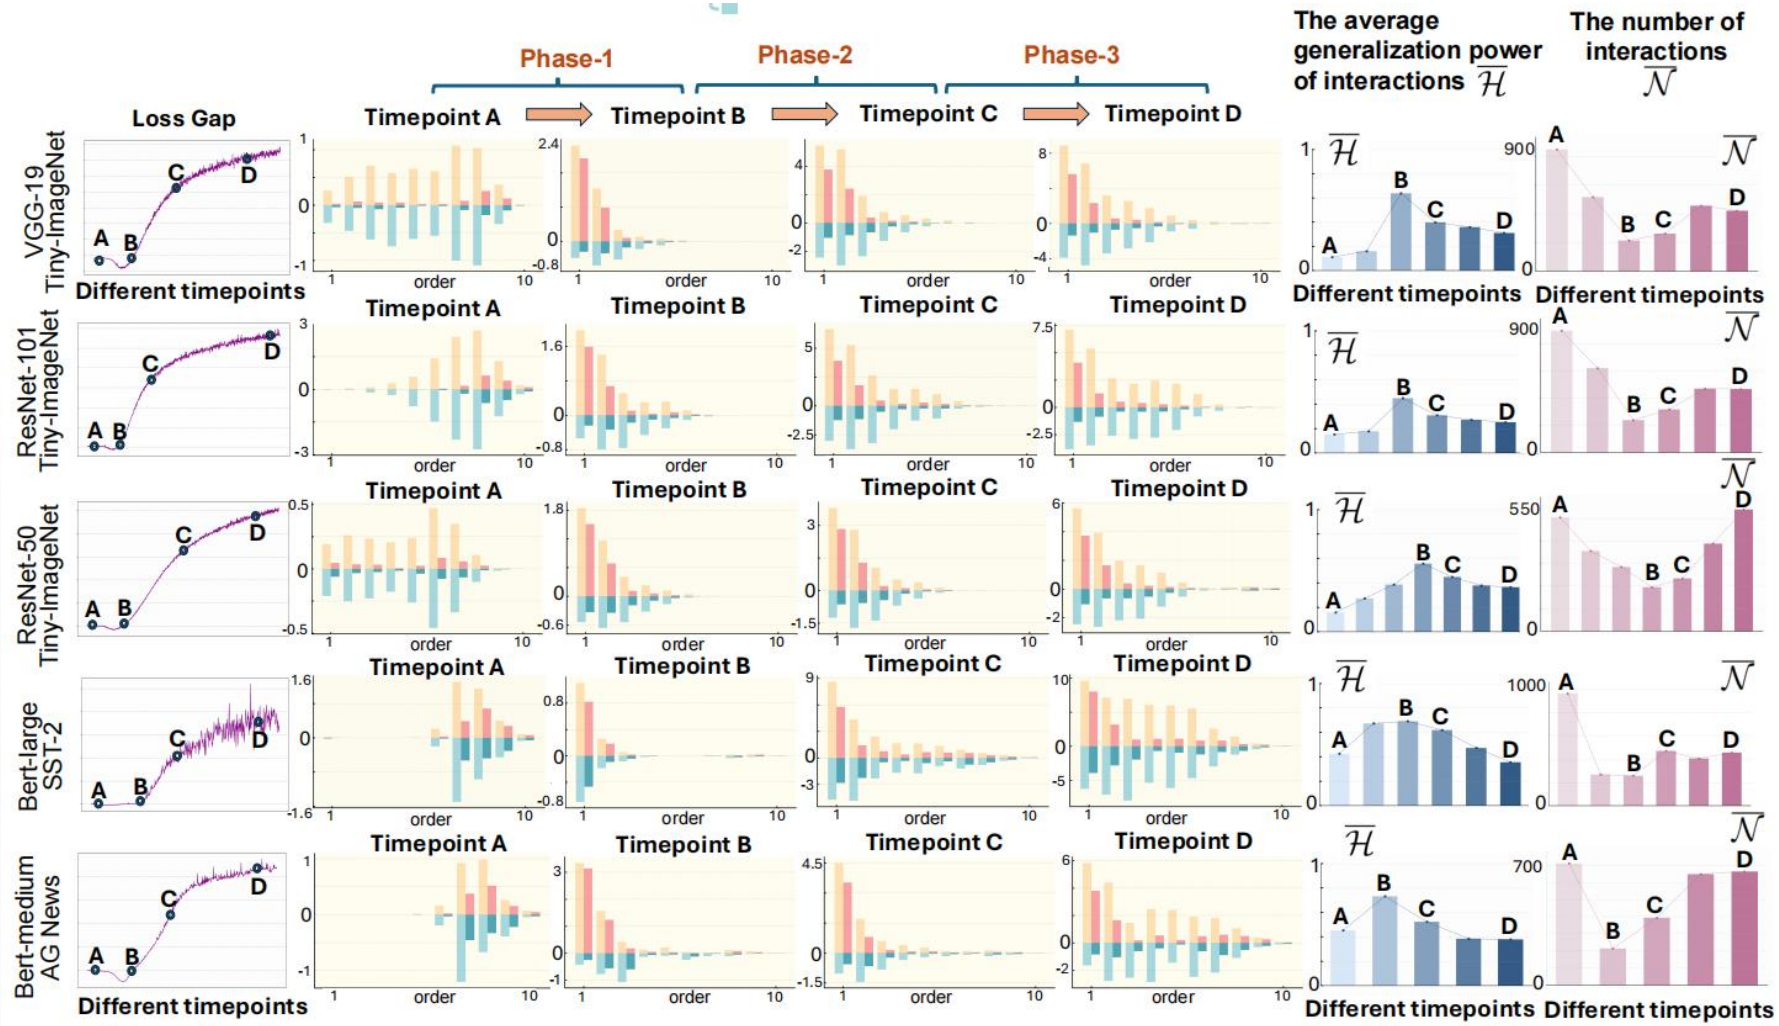
过拟合阶段

DNN 重新学习呈纺锤形分布的交互。



从交互机理的角度看清模型优化的本质

- 训练前期：
  去除噪声交互，学习可泛化交互机理。
- 训练后期：
  重新学习不可泛化的噪声机理



样本筛选：找出每一个被过拟合的训练样本

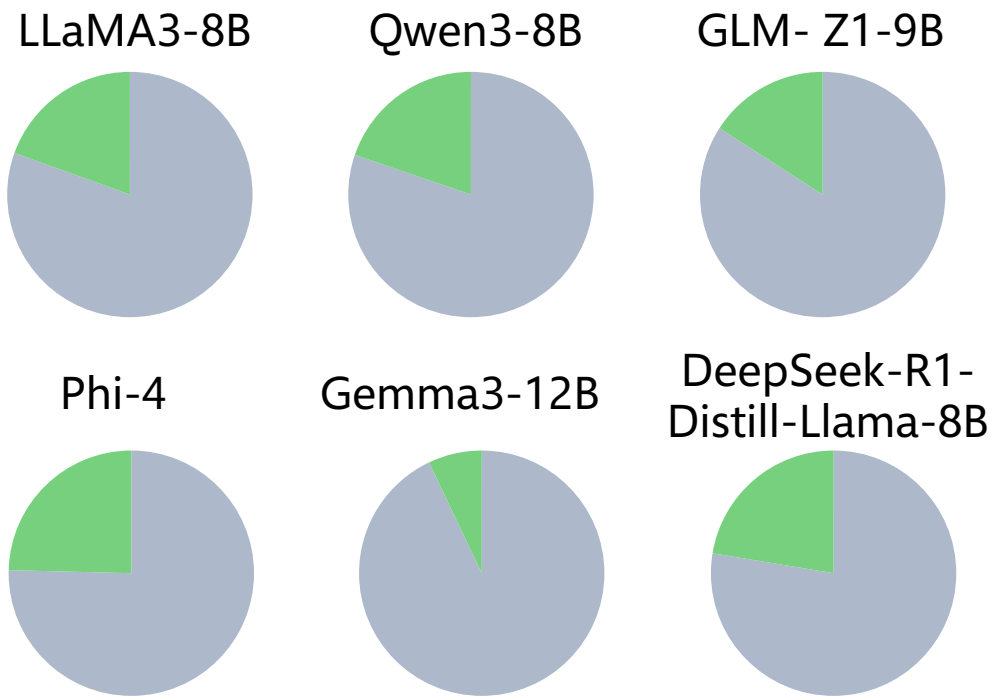
模型训练：根本上去除过拟合，或对样本的死记硬背

过拟合的交互机理，在一线大模型中有多么泛滥？

惩罚过拟合交互，提升模型机理泛化性

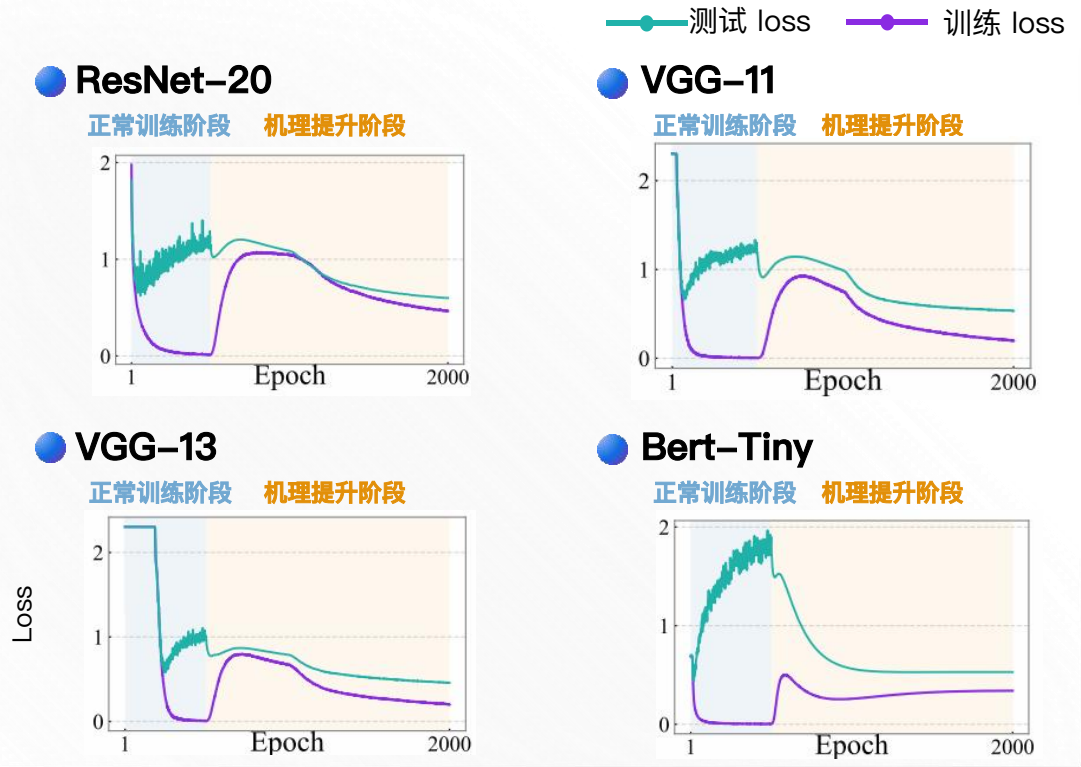
有效发挥作用的
可泛化交互机理

大量正负抵消的
过拟合（噪声）交互机理



把过拟合表征拉回健康表征

- 缩减 loss gap（训练/测试损失差距）
- 提升泛化效率 、加速收敛速度



深度学习的双重困境—『可信危机』和『效率困境』根因同源

Scaling Law 的瓶颈与可信性危机

挑战一：可信危机

在高风险场景

结果正确 ≠ 内在机理逻辑正确。

挑战二：效率困境

Scaling Law：资源堆砌式

端到端学习（监督结果） vs. 人类符号智能（对齐机理）

根本症结：表征能力缺少根本性解释

“可信危机”与“效率困境”本质指向同一根因

——对模型表征能力缺少根本性解释。

两大挑战交汇，亟需从「机理」层面突 破。

打破AI模型的优化死锁

- 死锁1：模型复杂度 vs. 模型过拟合
  - 量投模型：两家国际量投企业
- 死锁2：样本不均衡（样本记忆） vs. 样本数量
  - 大模型训练
- 类别间训练不平衡
  - 自动驾驶：某自驾企业
- 机理优化 vs. 性能成长
  - AI for Science
  - 法律垂类应用

等效交互技术极大赋能关键AI业务领域，构建可信智能

01.模型机理形式化审计

AI Evaluation

率先落地 AI 机理多维度审计，助力企业打造技术增长点与差异化优势

02. 训练效果提升

Training Navigation

机理对齐指导模型训练，高效提升模型训练效率，降低训练成本

03. 机理安全增强

Safety Assurance

从根源上消除模型机理隐患，赋能企业打造优于通用基座的可信模型

金融投资

识别低信噪比数据中的可靠机理，预警伪相关与过拟合，支撑策略风控与上线决策。

自动驾驶

界定端到端模型的安全边界，跳出长尾测试桎梏，检测隐藏在高精度模型中的安全隐患。

工业生产

诊断质检与工艺控制模型的异常，提升产线AI决策的稳定性，降低误检与停机风险。

大模型训练

通过识别过拟合样本与无效训练样本，指导模型后训练，增强机理安全性与泛化能力。

国防安全

面向风险零容忍AI系统，提供极致的风险排查与安全保障。

法律合规

核验法条引用与推理逻辑一致性，识别幻觉、错引与张冠李戴，支撑司法审计。

等效交互机理解释技术全面碾压头部公司

机理解释技术全面碾压 Google, OpenAI, Anthropic头部公司

	诠信全译 与或交互机理解释	Google, OpenAI, Anthropic等机构 Mechanistic interpretability
能否解释模型泛化性	可以证明交互机理与模型泛化性之间的数学关系	无法解释
能否保障机理语义清晰度	与或交互有天然的清晰性	无法保障
能否提升模型机理可信度	可以高效提升	无法高效提升
能否高效消除模型安全隐患	可以在机理层面消除	无法在机理层面消除
能否保障机理解释简洁性	50-150个语义单元	3000-5000个语义单元
能否验证数值严谨性	可验证无限拟合性与稀疏性	仅具备稀疏性

商业应用

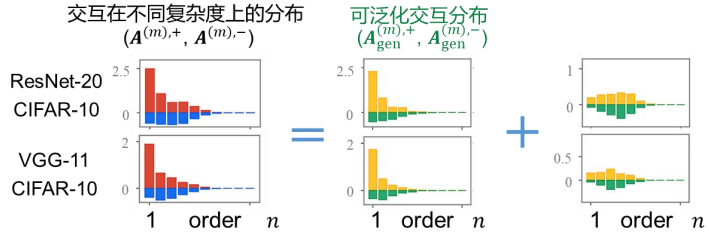
模型机理审计

解析模型内部决策逻辑，评估模型决策逻辑与人类认知的对齐程度，识别模型潜在风险与偏差。



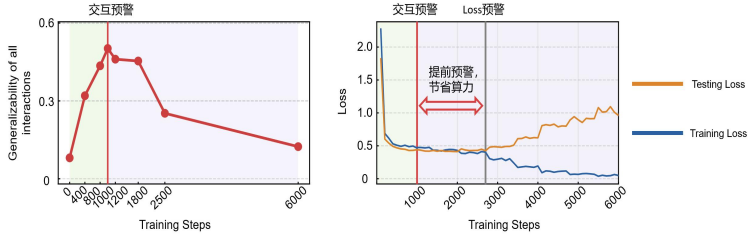
模型风险诊断与安全增强

发现不可泛化的脆弱交互，降低模型风险决策比例，提升模型稳健性。



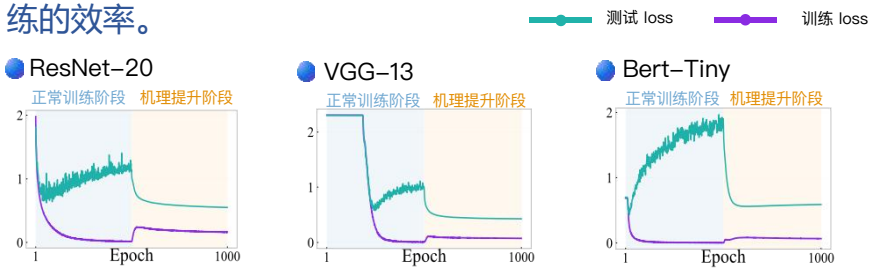
模型训练效果优化

监控训练过程中的交互变化，精确识别有效窗口，避免过拟合与算力浪费，实现精准优化。



高效表征修复与训练

基于机理解释的高效表征修复与训练，展现超越端到端训练的效率。



诠信全译 SymTrustAI

穿 透 黑 盒 · 智 见 可 信

诠信全译是一家面向可信 AI 的模型机理诊疗硬科技企业，致力于破解人工智能黑盒难题与模型训练瓶颈，推动人工智能发展从经验驱动走向机理驱动。

解决方案

AI 模型
机理形式化审计

率先落地 AI 机理多维度审计，助力企业打造技术增长点与差异化优势。



解决方案

AI 模型
机理安全增强

从根源上消除模型机理隐患，赋能企业打造优于通用基座的可信模型。



解决方案

AI 模型
训练效果提升

机理对齐指导模型训练，高效提升模型训练效率，降低训练成本。



诠信全译企业官网

诠信全译微信公众号

GOSIM

GOSIM Shenzhen 2026

Thanks!

