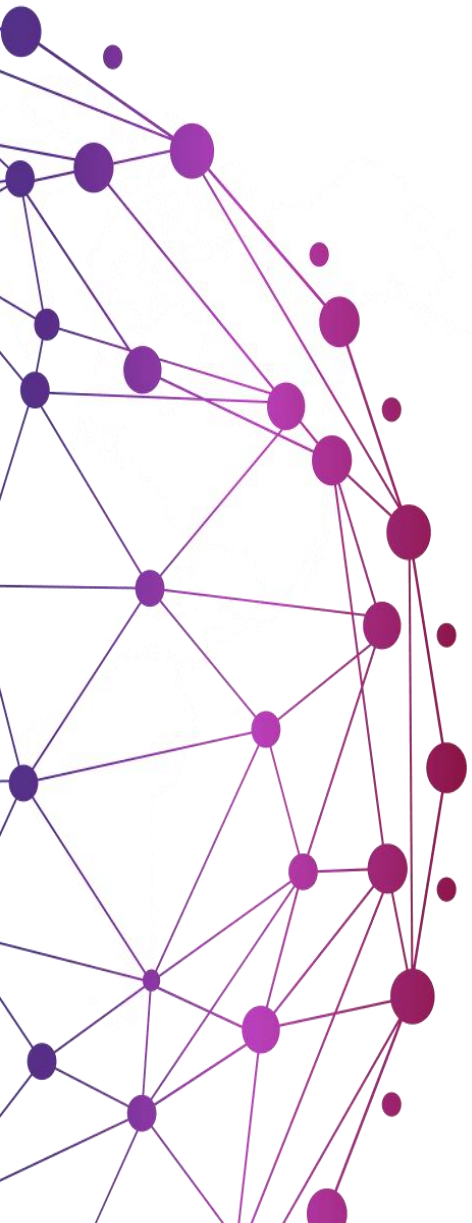


超节点Scale-up互联系统

郑嘉琦

南京大学计算机学院

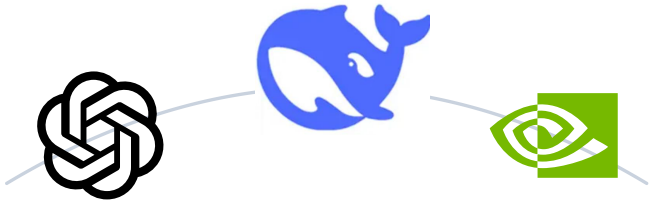
智能时代已至



约18世纪—20世纪中



约20世纪中后期—21世纪初



现在

工业时代

关键词：蒸汽机、电力、流水线、机械化

特征：机器替代体力劳动，规模化生产成为主流

代表：蒸汽机、电灯、汽车、工厂体系

信息时代

关键词：计算机、互联网、数字化

特征：信息获取、传播和处理效率大幅提升

代表：PC、智能手机、搜索引擎

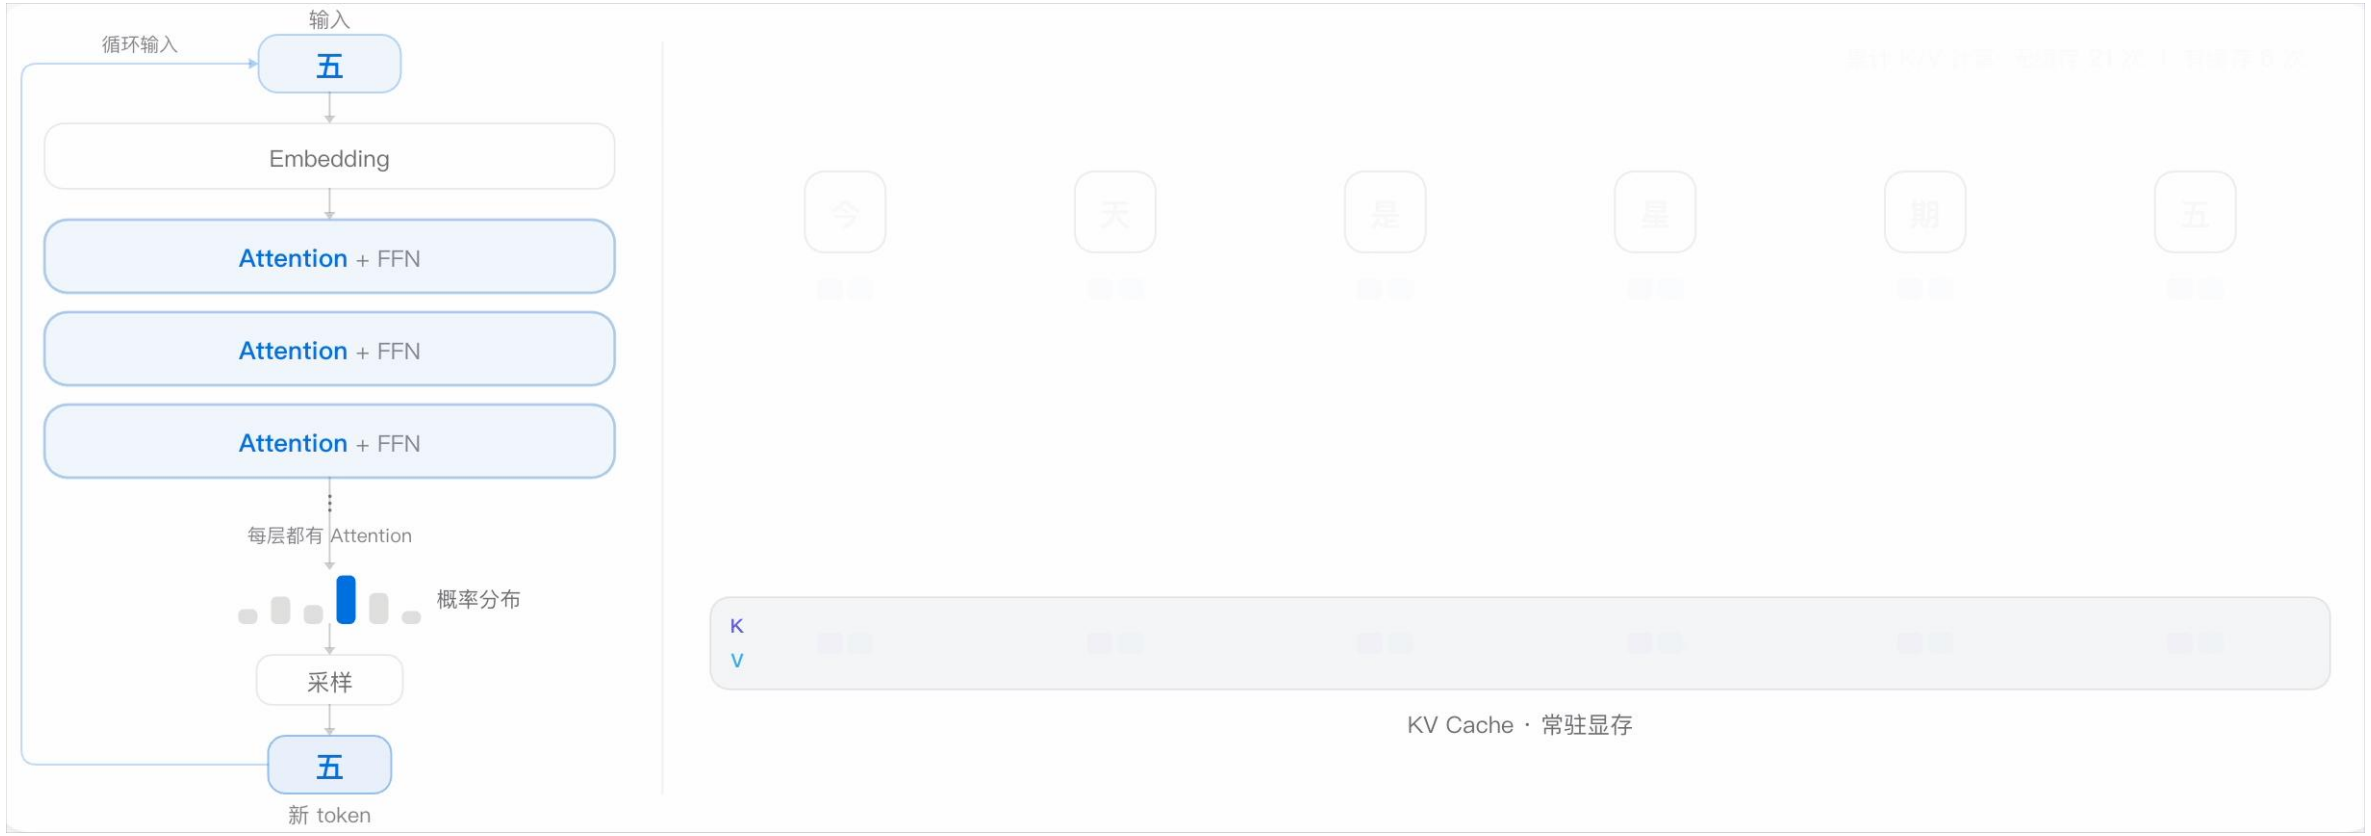
智能时代

关键词：AI、大数据、云计算、自动化决策

特征：机器开始“学习”“理解”“生成”，人机协同成为常态

代表：ChatGPT、自动驾驶、智能推荐、智能制造

电能通过算力基础设施转化为智能



算力决定智能上限：“大力出奇迹”





NVIDIA GB200 NVL72

NVL xxx?



Huawei CloudMatrix 384

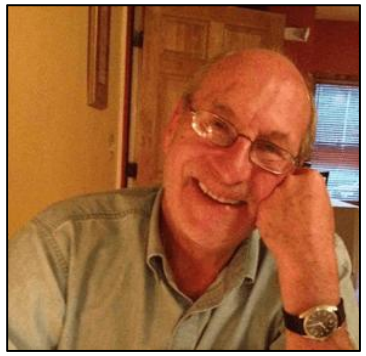
CM xxx?

“大力出奇迹”的“理论基础”



David Hilbert
1862—1943

1900 年，希尔伯特第13个问题”任给一个函数，能否把它分解成更简单函数的叠加？“（猜想倾向于否定）



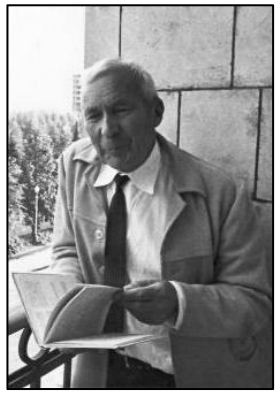
George Cybenko
Thayer School of Engineering at Dartmouth

1989年，Universal Approximation Theorem “只要神经网络层数足够多，任意连续函数甚至非连续函数都可以无限逼近”（堆算力！）

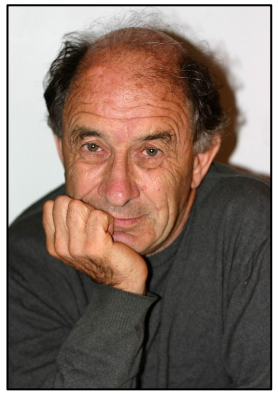
deepseek

1900 — 1956 — 1989 — 2020

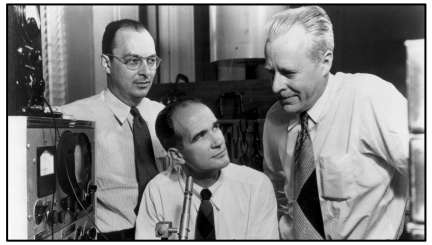
1956年，Kolmogorov-Arnold 叠加定理
任意多元连续函数可以展开表示为有限个简单连续函数的叠加（证明13问题Yes!）



Andrey Nikolaevich Kolmogorov



Vladimir Igorevich Arnold
1937—2010

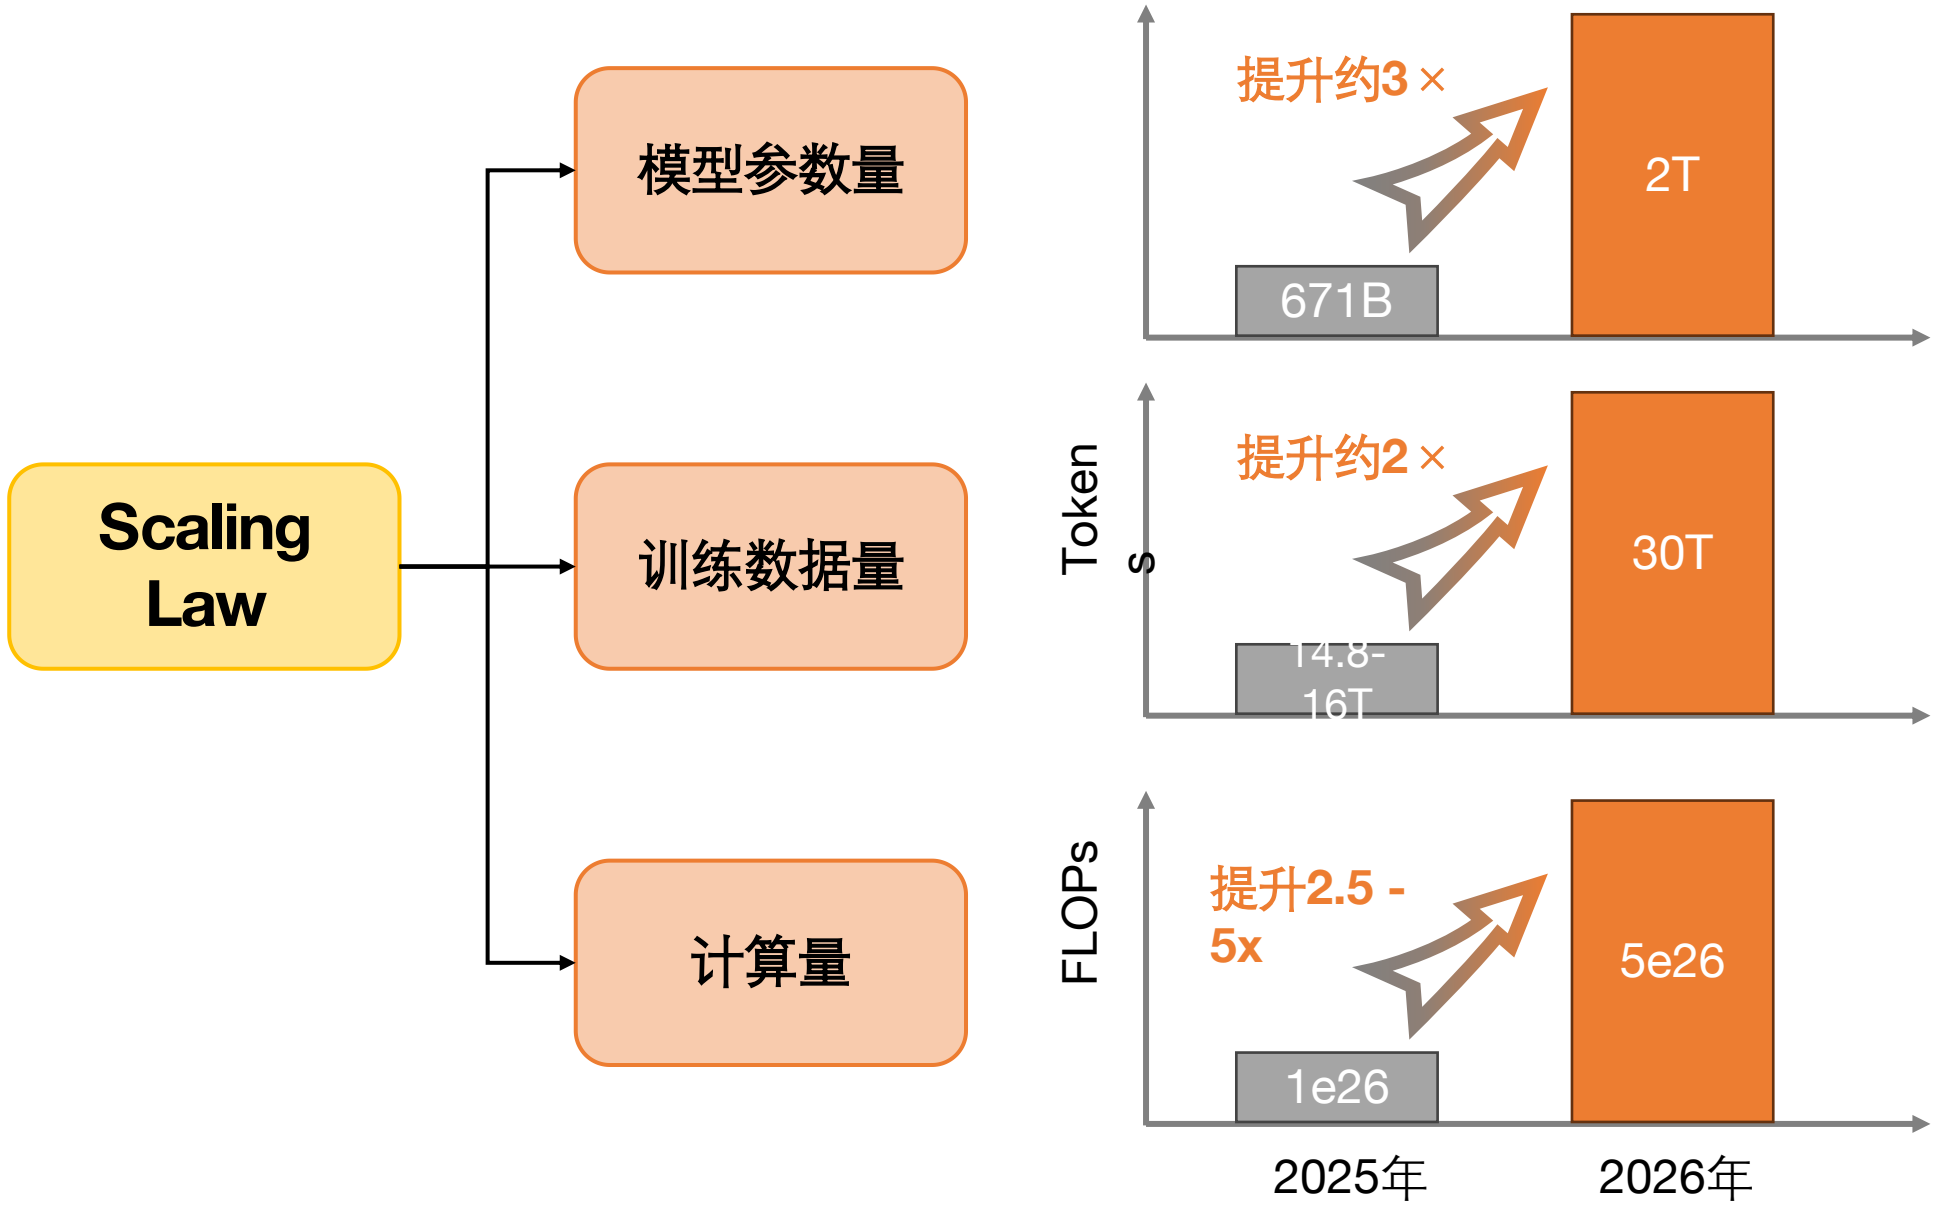


Bell Labs

OpenAI

Scaling Law
对于**计算量、数据大小、模型参数量**，模型性能与每个因素都呈幂律关系。

驱动Scaling Law的“三驾马车”



“今天我的GPT表现还不如BERT好，是因为你没给我足够的算力。” —— Ilya Sutskever
(OpenAI前首席科学家、联合创始人)



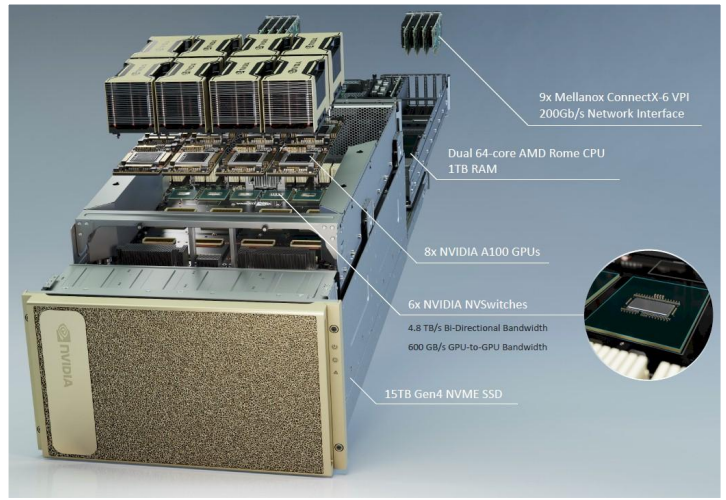


算力的物理形态：超节点

NVIDIA DGX-1 (V100)
8 × V100 GPU
Pascal 升级版。在原 DGX-1 架构上性能翻倍，支持 **Tensor Core**，成为全球研究机构与企业 AI 平台标配设备。



NVIDIA DGX A100
8 × A100
Ampere时代主力超节点。支持多实例GPU虚拟化，性能功耗平衡卓越，**是大模型训练与推理的主力机型。**



2016 2017 2018 2019 2020

NVIDIA DGX-1 (Pascal)
8 × Tesla P100 GPU
首款商用“**单机八卡超节点**”，AI训练里程碑。



NVIDIA DGX-2 **16 × V100 GPU**



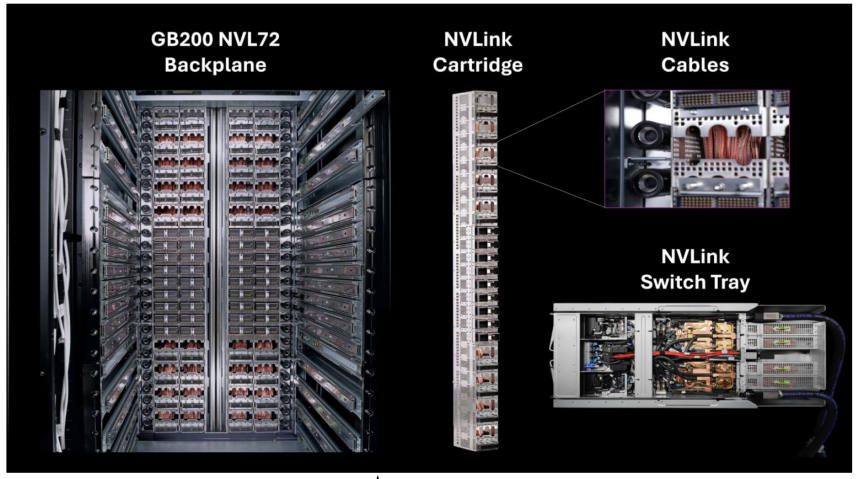
首台16卡全互联系统，提供统一**大显存访问**与更高带宽，是首台单机突破**2 PFLOPS**算力的超节点系统。

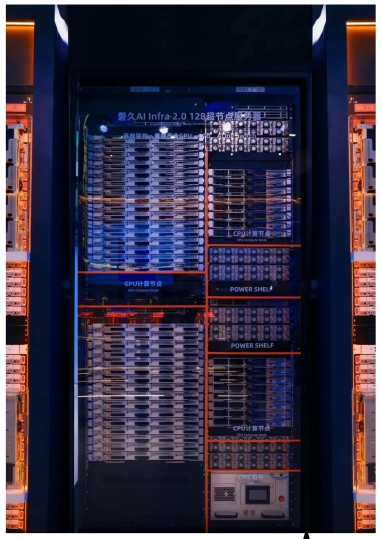
算力的物理形态：超节点

NVIDIA NVL72 / GB200 Supernode

72 × GB200 GPU

Blackwell旗舰机柜。整柜液冷高密度超算单元。



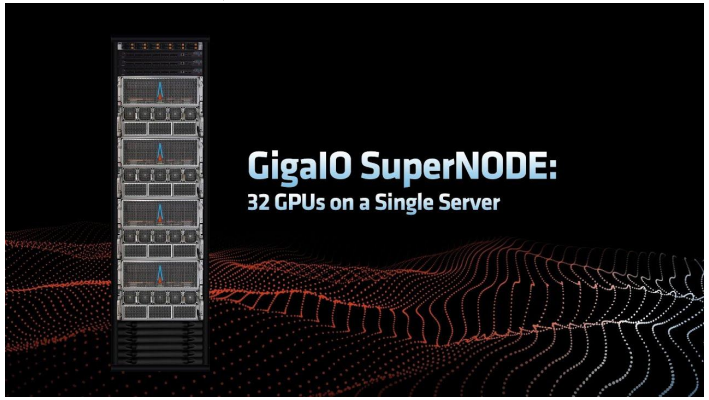


阿里云 “磐久” 128 卡超节点

128 × AI 芯片 (自研 / 兼容)

云端大模型节点，自研CIPU网络高带宽。

2023 2024 2025 2026



GigaIO SuperNODE

最多 32 × GPU (A100 / MI210)

可组合架构节点，模块化互联灵活，适配多芯片。



华为 CloudMatrix 384 Supernode

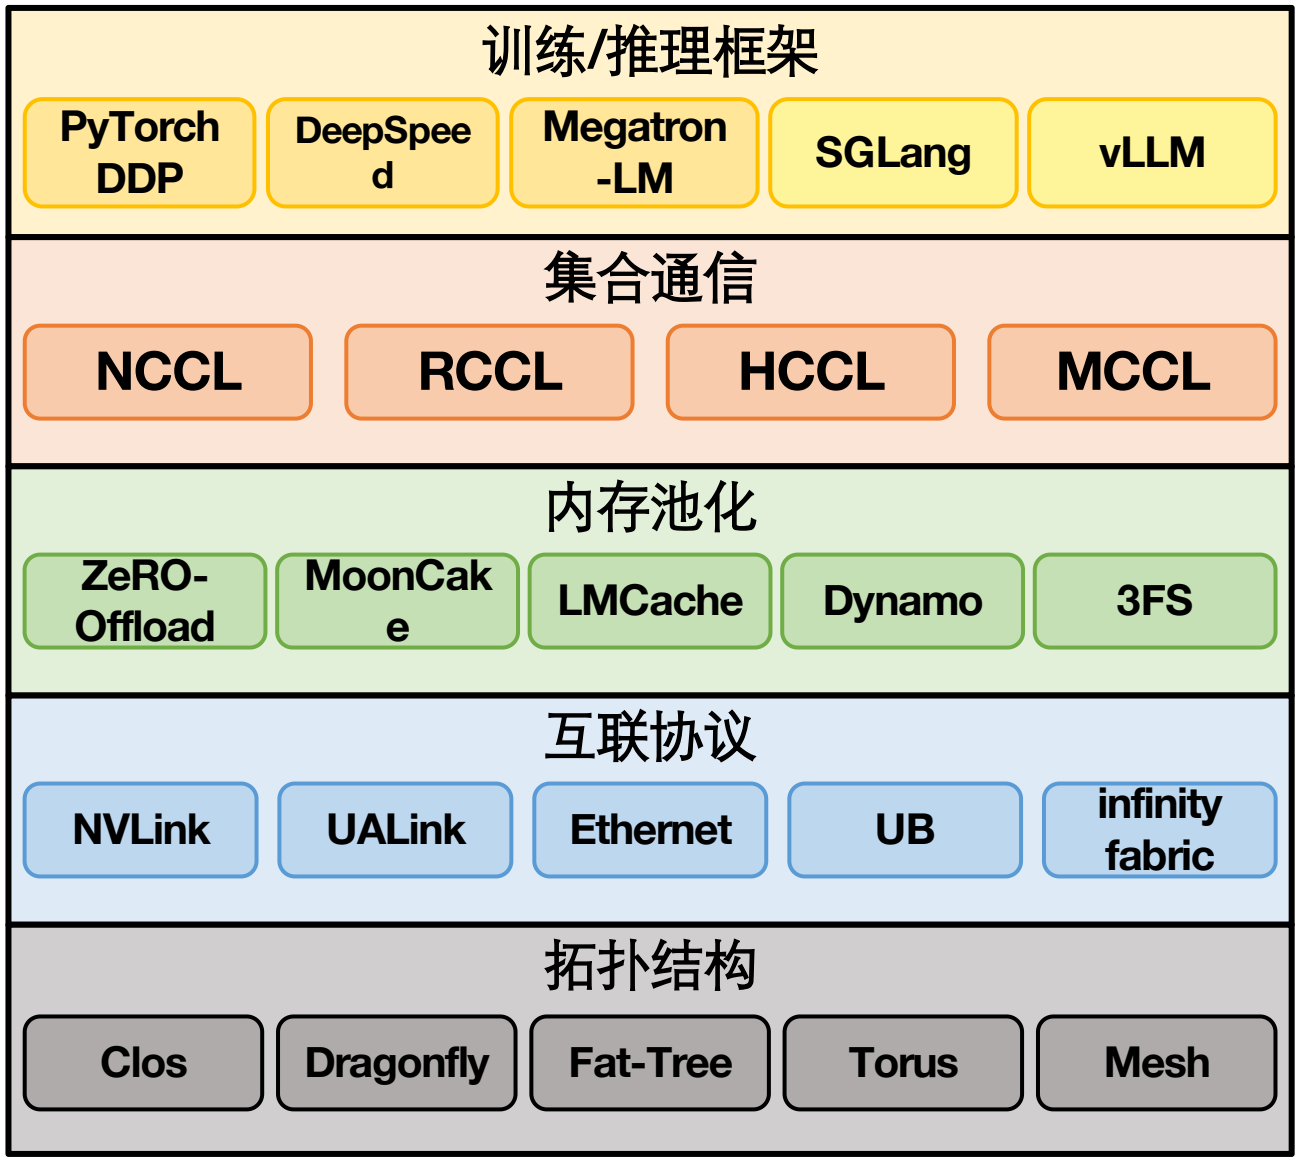
384 × 昇腾 AI 芯片

国产大模型训练核心节点，服务万亿参数模型训练。

高效算力需要超节点系统

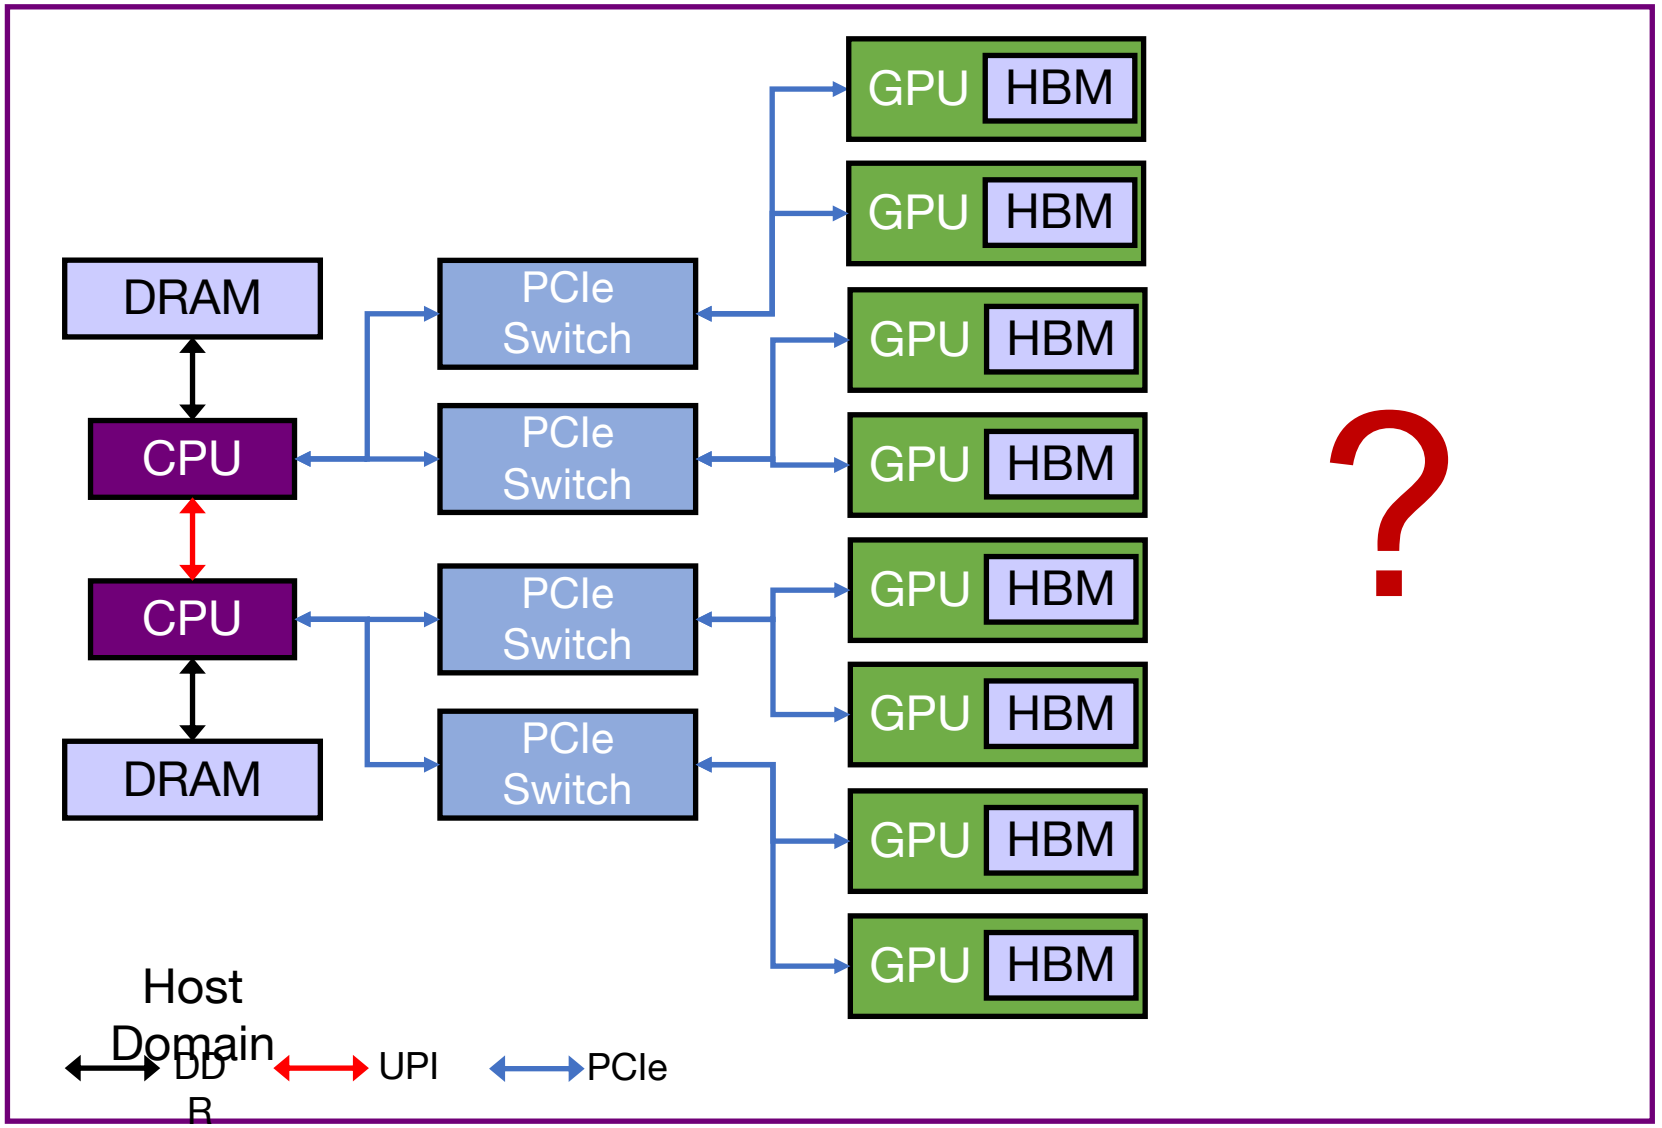
从硬件堆叠到系统协同

超节点系统



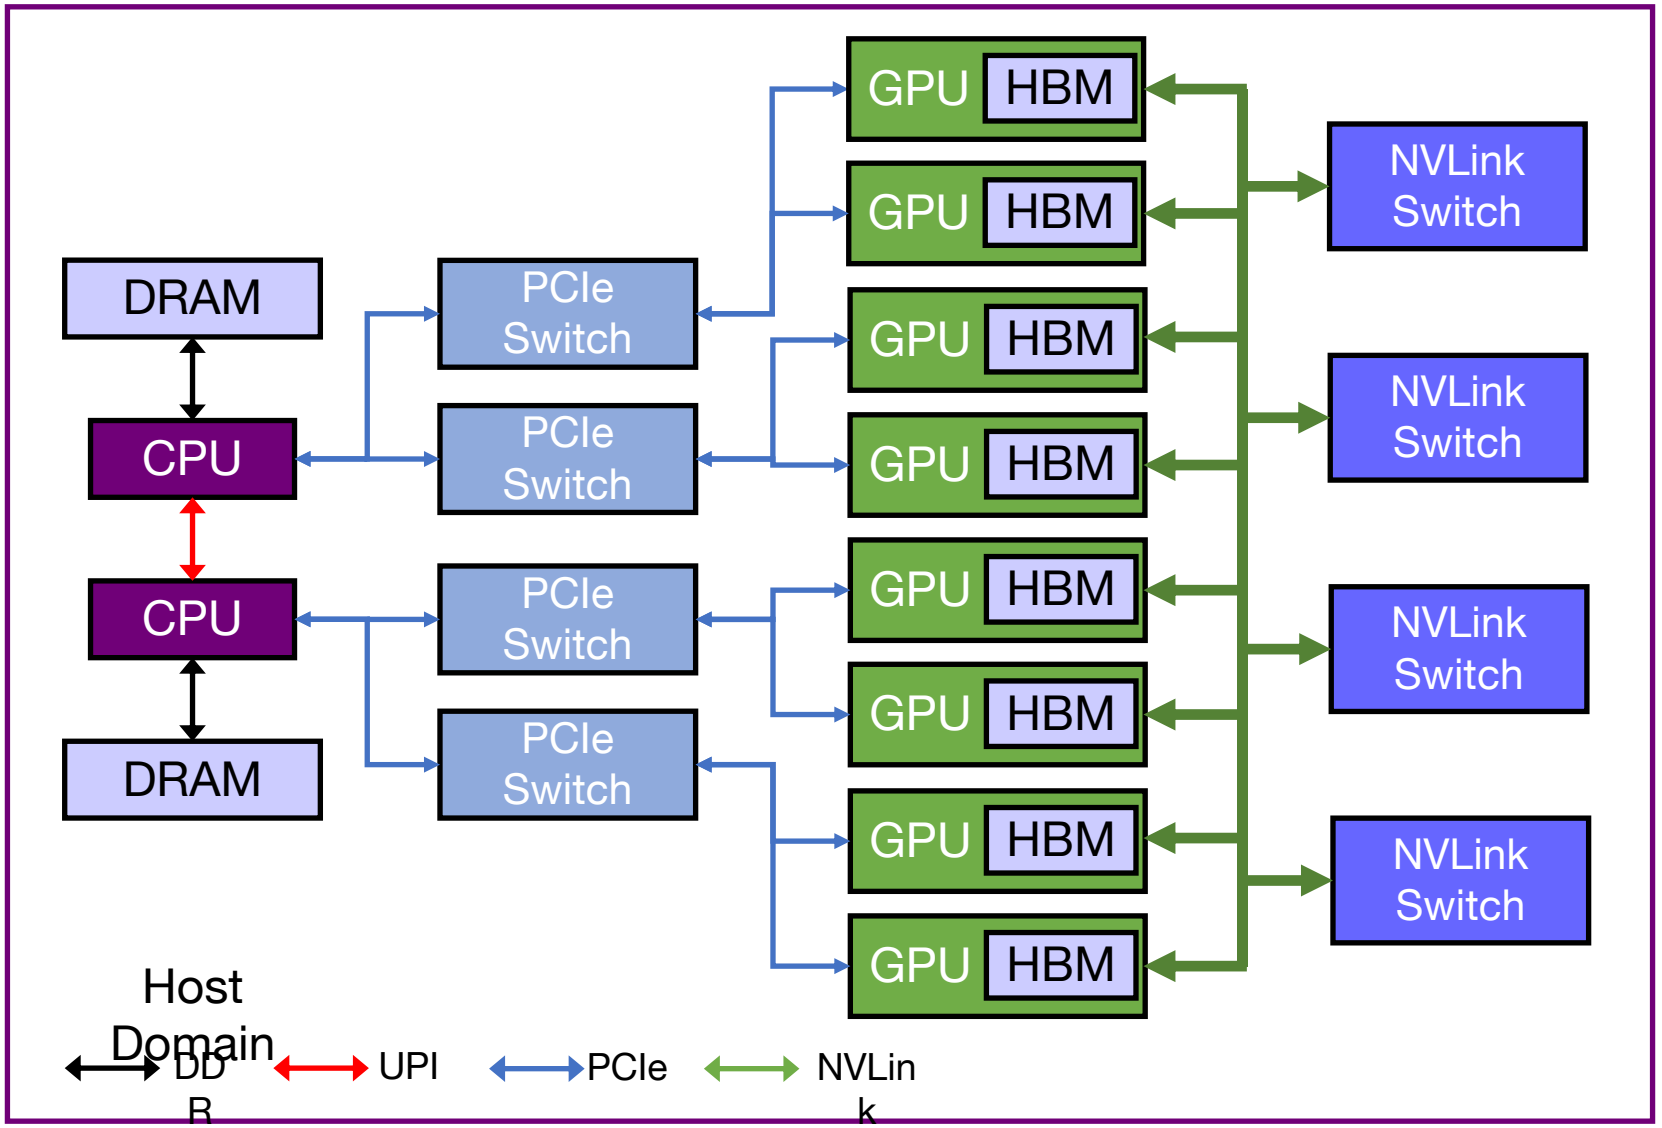
- **训练/推理框架**：上层使用**PyTorch DDP**、**DeepSpeed**等分布式训练框架；**SGLang**、**vLLM**等分布式推理框架负责**模型并行**与**任务调度**。
- **集合通信**：采用**NCCL**、**HCCL**等框架实现**多GPU/多节点间的高效数据同步与梯度聚合**。
- **内存池化**：通过**ZeRO-Offload**、**MoonCake**、**LMCache**等技术实现**显存/内存优化与共享**，提高资源利用率。
- **互联协议**：提供**节点间的通信能力**，包括**NVLink**、**Ethernet**、**UB**、**UALink**等高速互联技术。
- **拓扑结构**：定义设备间的**物理连接结构**，如**Clos**、**Dragonfly**、**Fat-Tree**等，决定通信路径和网络带宽。

传统PCIe互联体系成为GPU协同训练的瓶颈



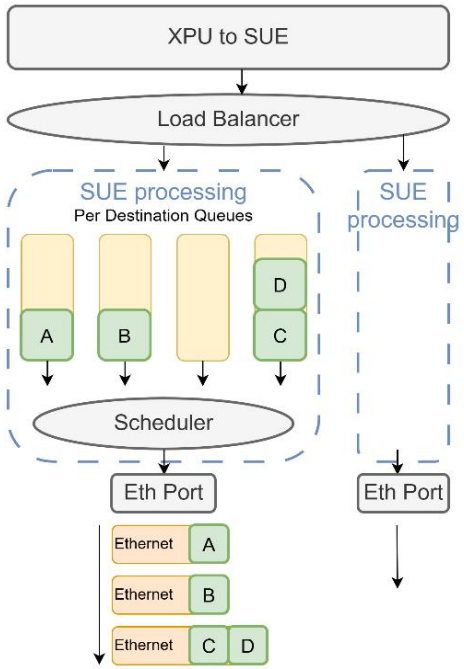
PCIe 版本	带宽 (单 Lane)
1.0	2.5 Gbps
2.0	5 Gbps
3.0	8 Gbps
4.0	16 Gbps
5.0	32 Gbps
6.0	64 Gbps
7.0	128 Gbps

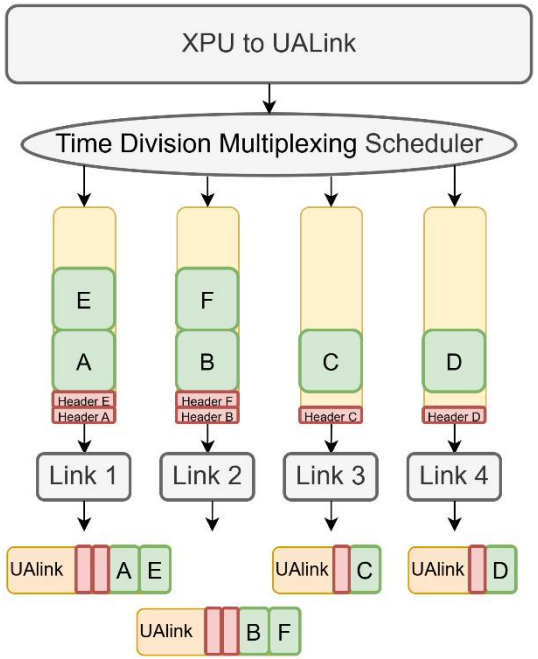
互联协议：高速NVLink/UALink/Eth/UB互联



NVL 版本	带宽 (单 Lane)
1.0	20 Gbps
2.0	25 Gbps
3.0	50 Gbps
4.0	100 Gbps
5.0	200 Gbps

互联协议：SUE V.S. UALink （端侧组包方式）



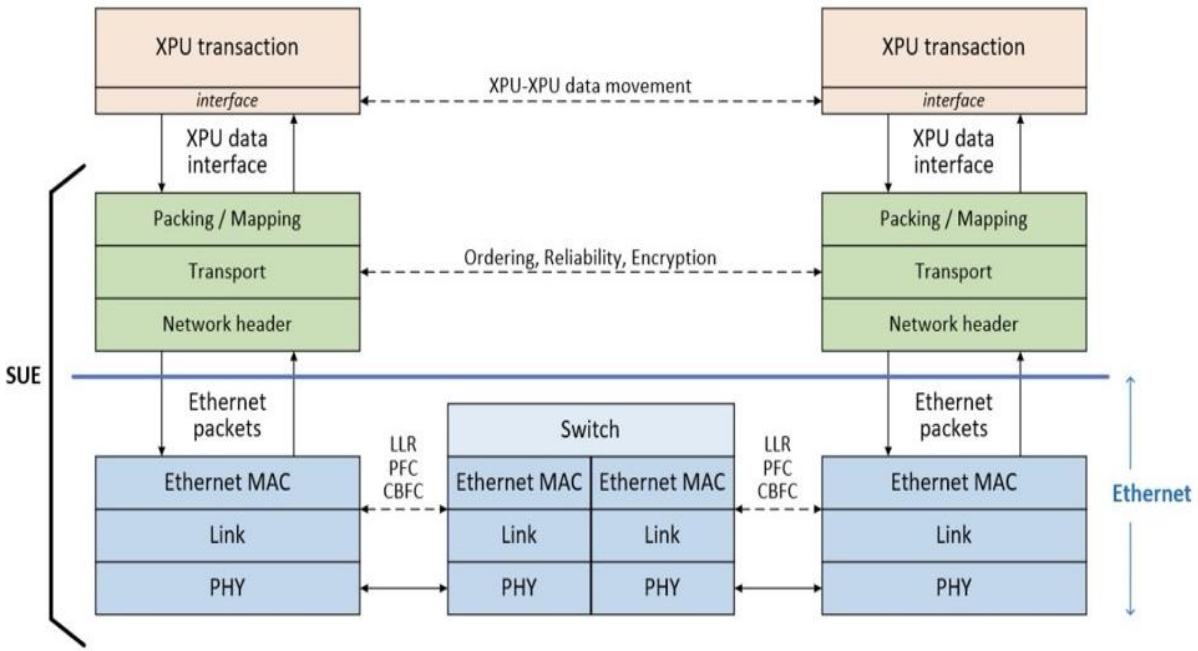


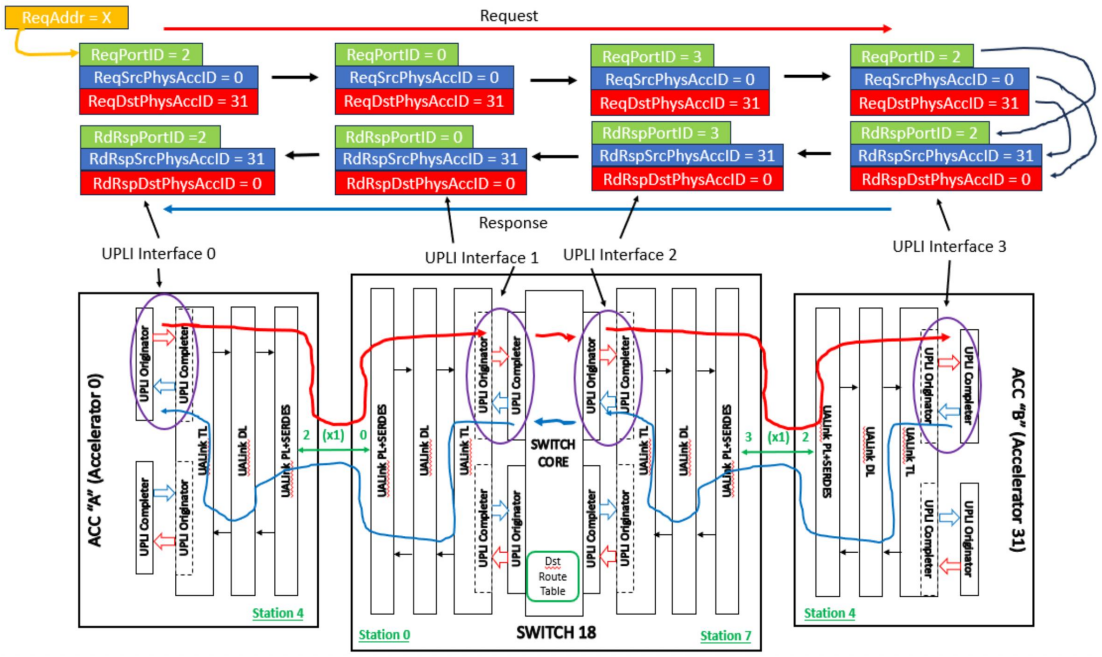
SUE Per-destination拼包	UALink Per-link拼包
发往相同目的地的数据会机会拼包	发往不同目的地的数据会机会拼包
网侧交换机只解析header	网侧交换机需要解析payload

SUE是简单网络，复杂终端；UALink是简单终端，复杂网络

[1] Scale-Up Ethernet Framework Scale-Up Ethernet Framework Specification
[2] Ultra Accelerator Link Consortium, Inc. Specification UALink_200 Rev 1.0

互联协议：SUE V.S. UALink（网侧交换方式）





SUE交换机不会进一步拼包拆包

UALink交换机会进一步拼包拆包

交换机只解析到数据链路层

交换机需要解析到事务层

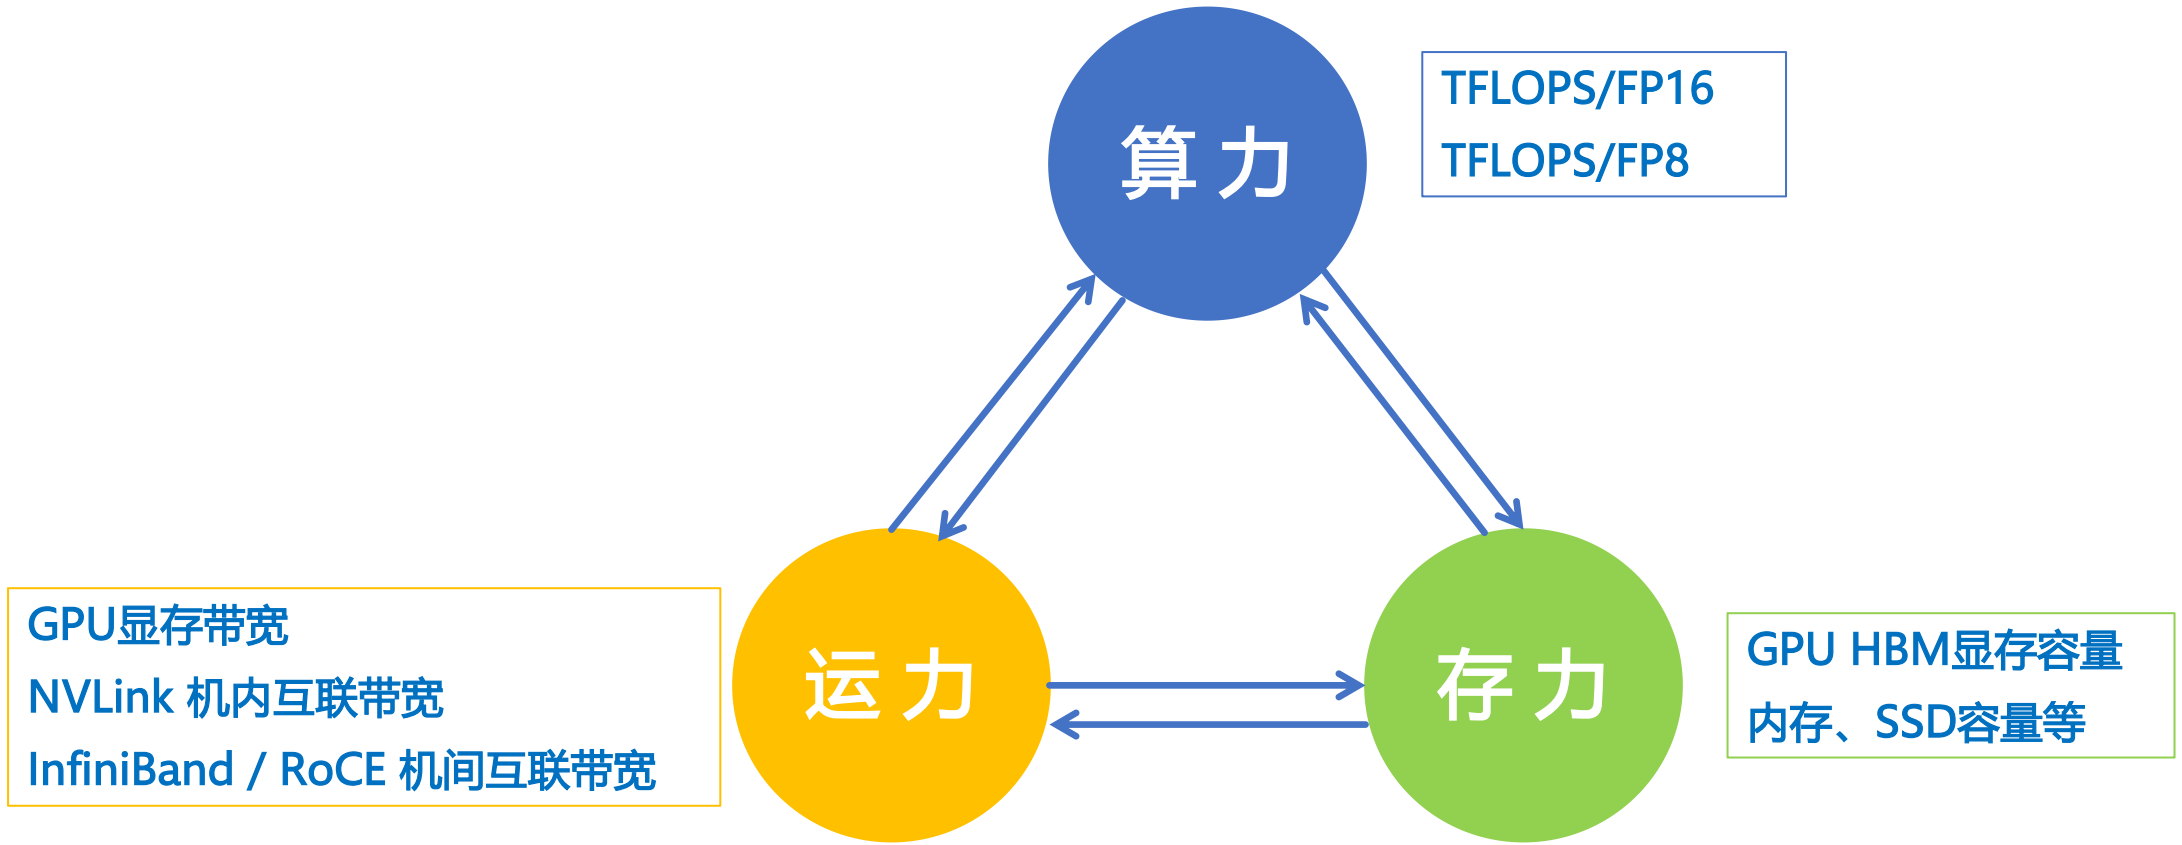
技术和生态成熟

交换机设计复杂，新标准和生态

SUE是简单网络，复杂终端；UALink简单终端，复杂网络

[1] Scale-Up Ethernet Framework Scale-Up Ethernet Framework Specification
[2] Ultra Accelerator Link Consortium, Inc. Specification UALink_200 Rev 1.0

超节点资源的三个维度

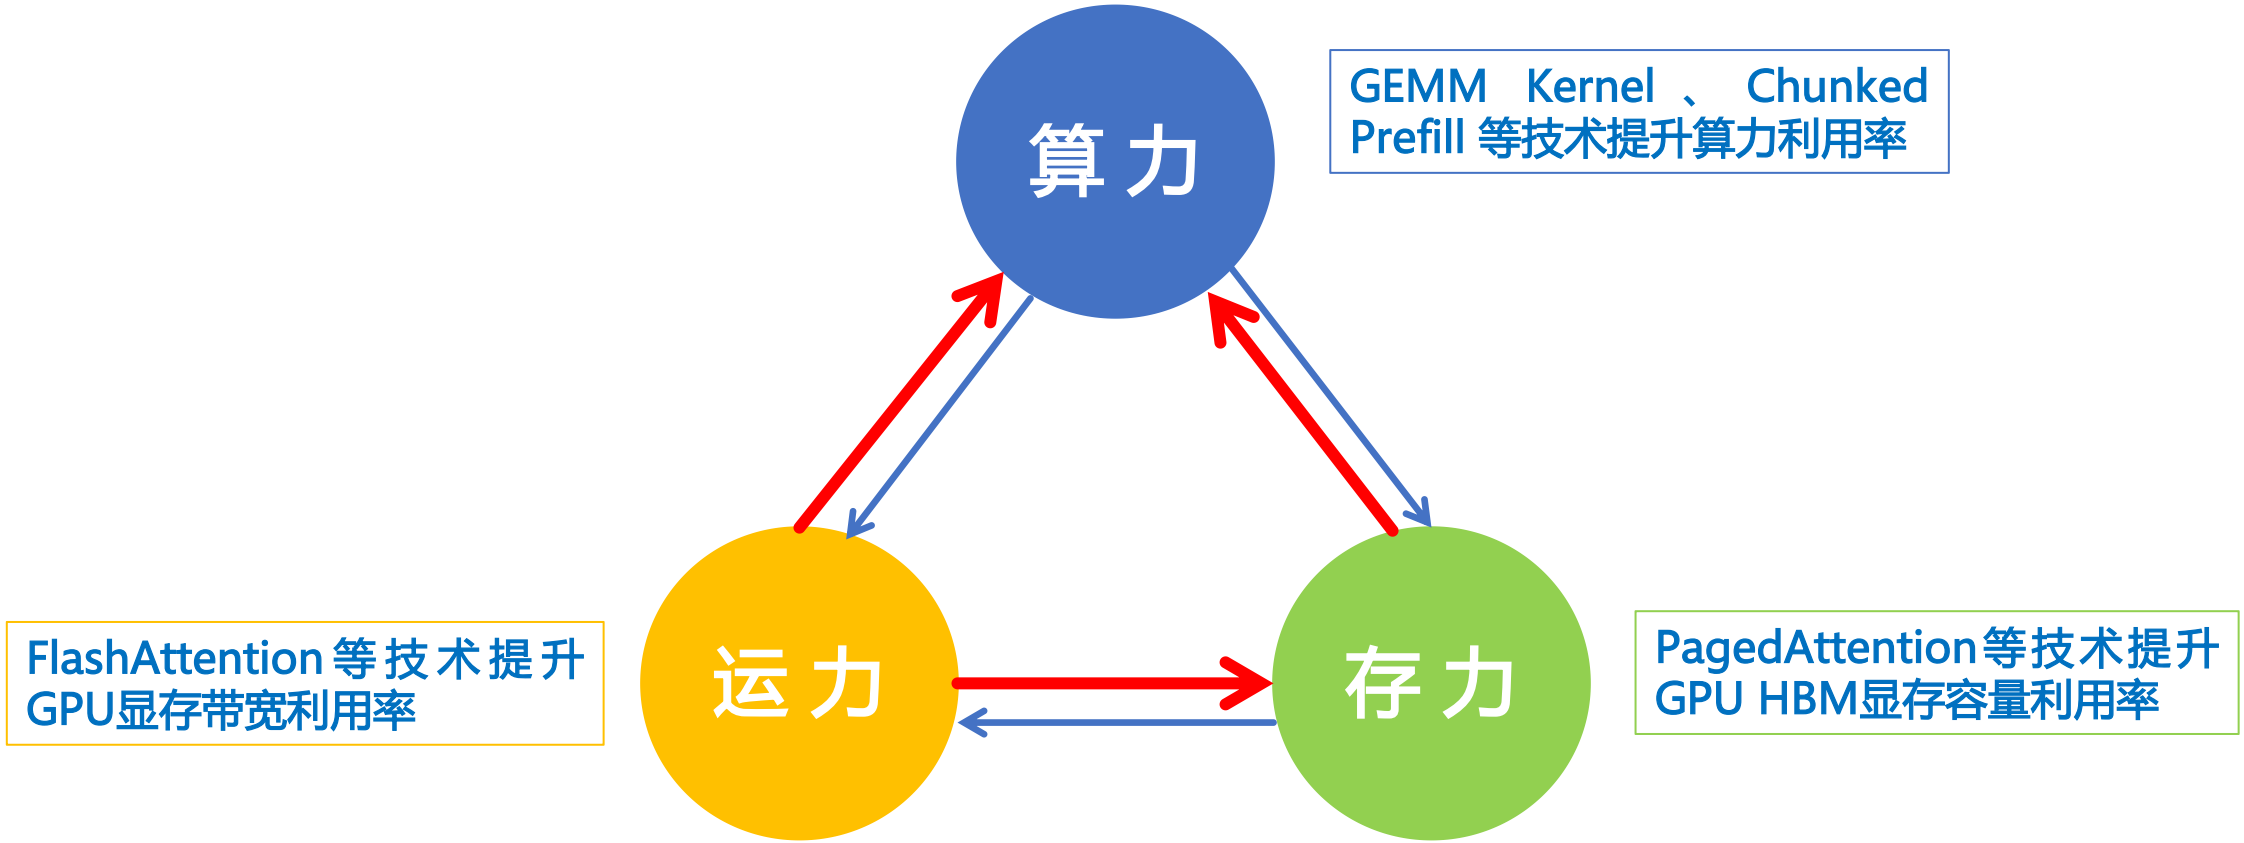

算力
TFLOPS/FP16
TFLOPS/FP8
运力
存力
GPU显存带宽
NVLink 机内互联带宽
InfiniBand / RoCE 机间互联带宽
GPU HBM显存容量
内存、SSD容量等

训练和推理对超节点算力、运力资源需求

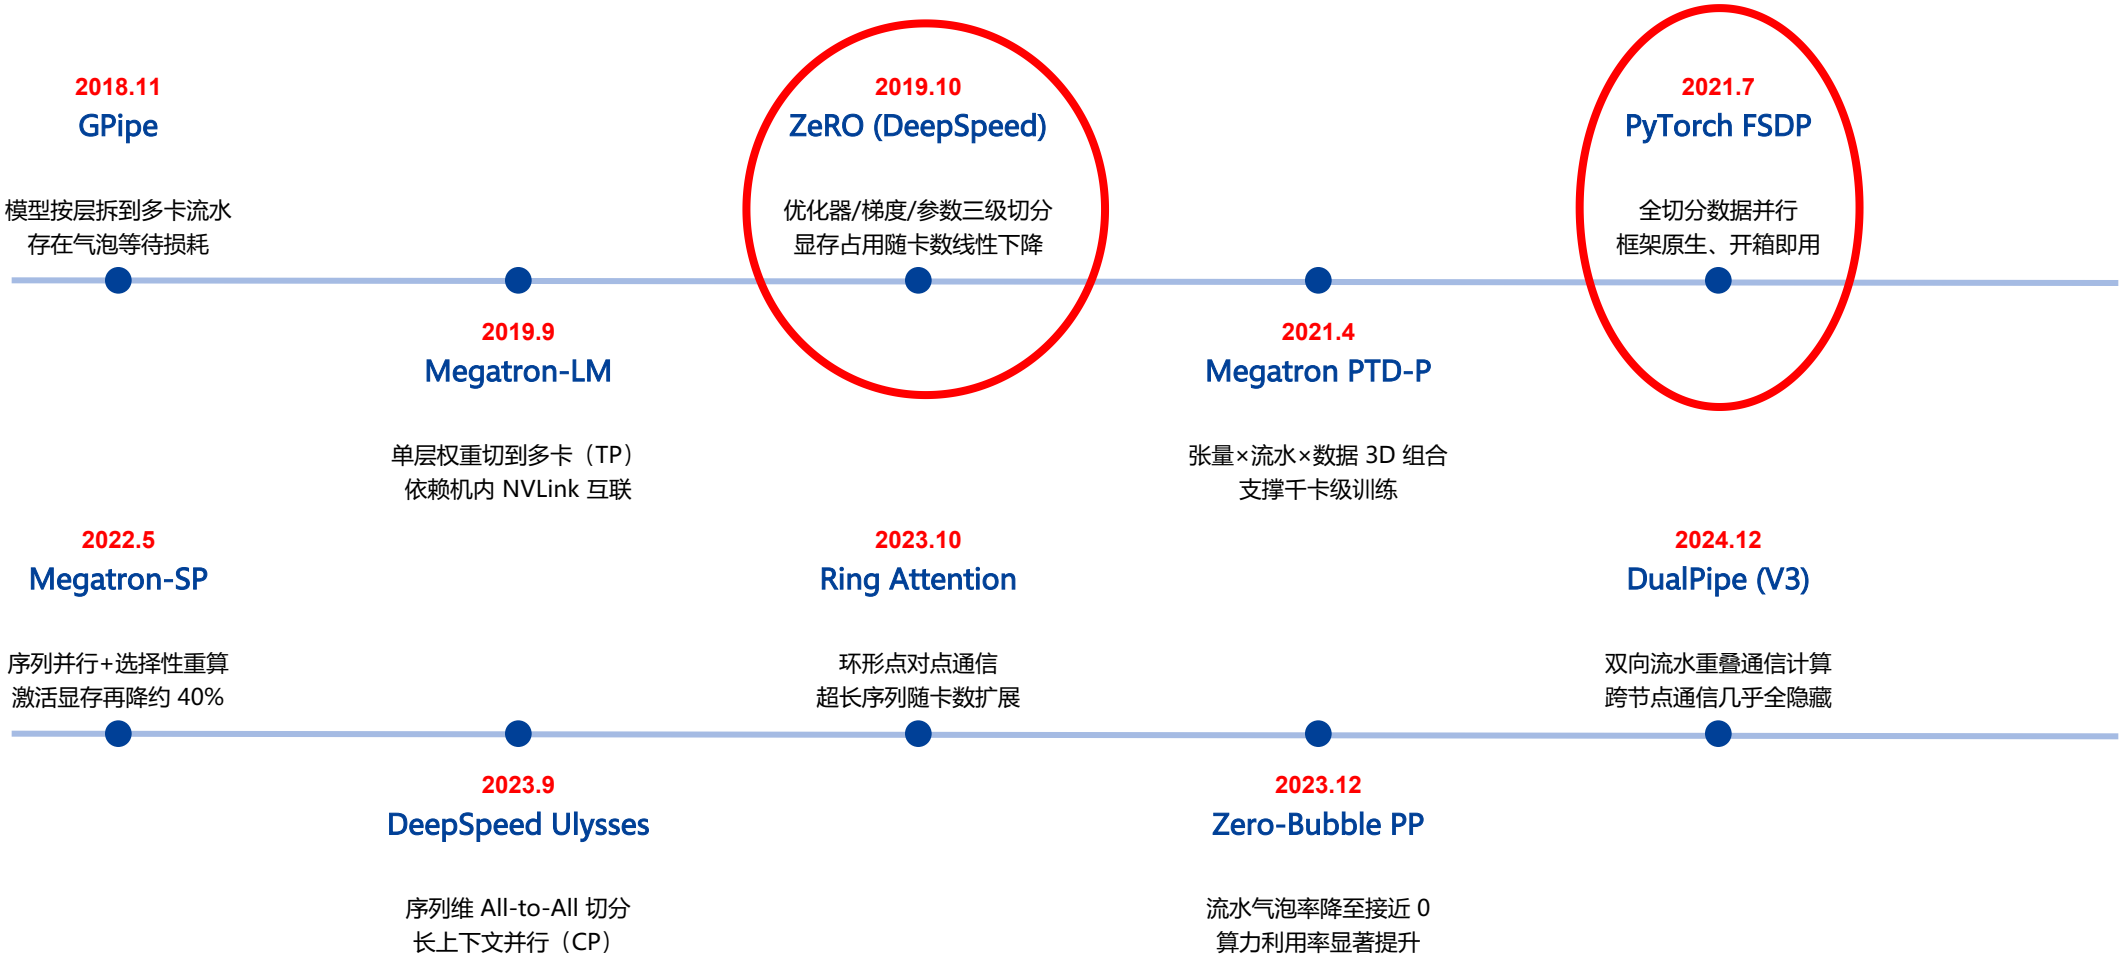
	训练	Prefill阶段	Decode阶段
算力	**高**（>1000 TFLOPS）	**高**（>1000 TFLOPS）	**低** （<300 TFLOPS）
GPU显存带宽	**中等** （1~3 TB/s）	**中等** （1~3 TB/s）	**高** （>3TB /s）
Scale-up互联带宽	**高**（>900 GB/s）	**高**（>900 GB/s）	**高**（>900 GB/s）
Scale-up域大小	大	小（~ 8 GPU）	大（~ 32 GPU）
并行策略	**小EP组**（~ 8 GPU）	**小EP组**（~ 8 GPU）	**大EP组**（~ 64 GPU）

训练/Prefill阶段需要更高的算力
Decode阶段需要更高的内存带宽以及更大的Scale-up域

从资源置换视角看超节点系统

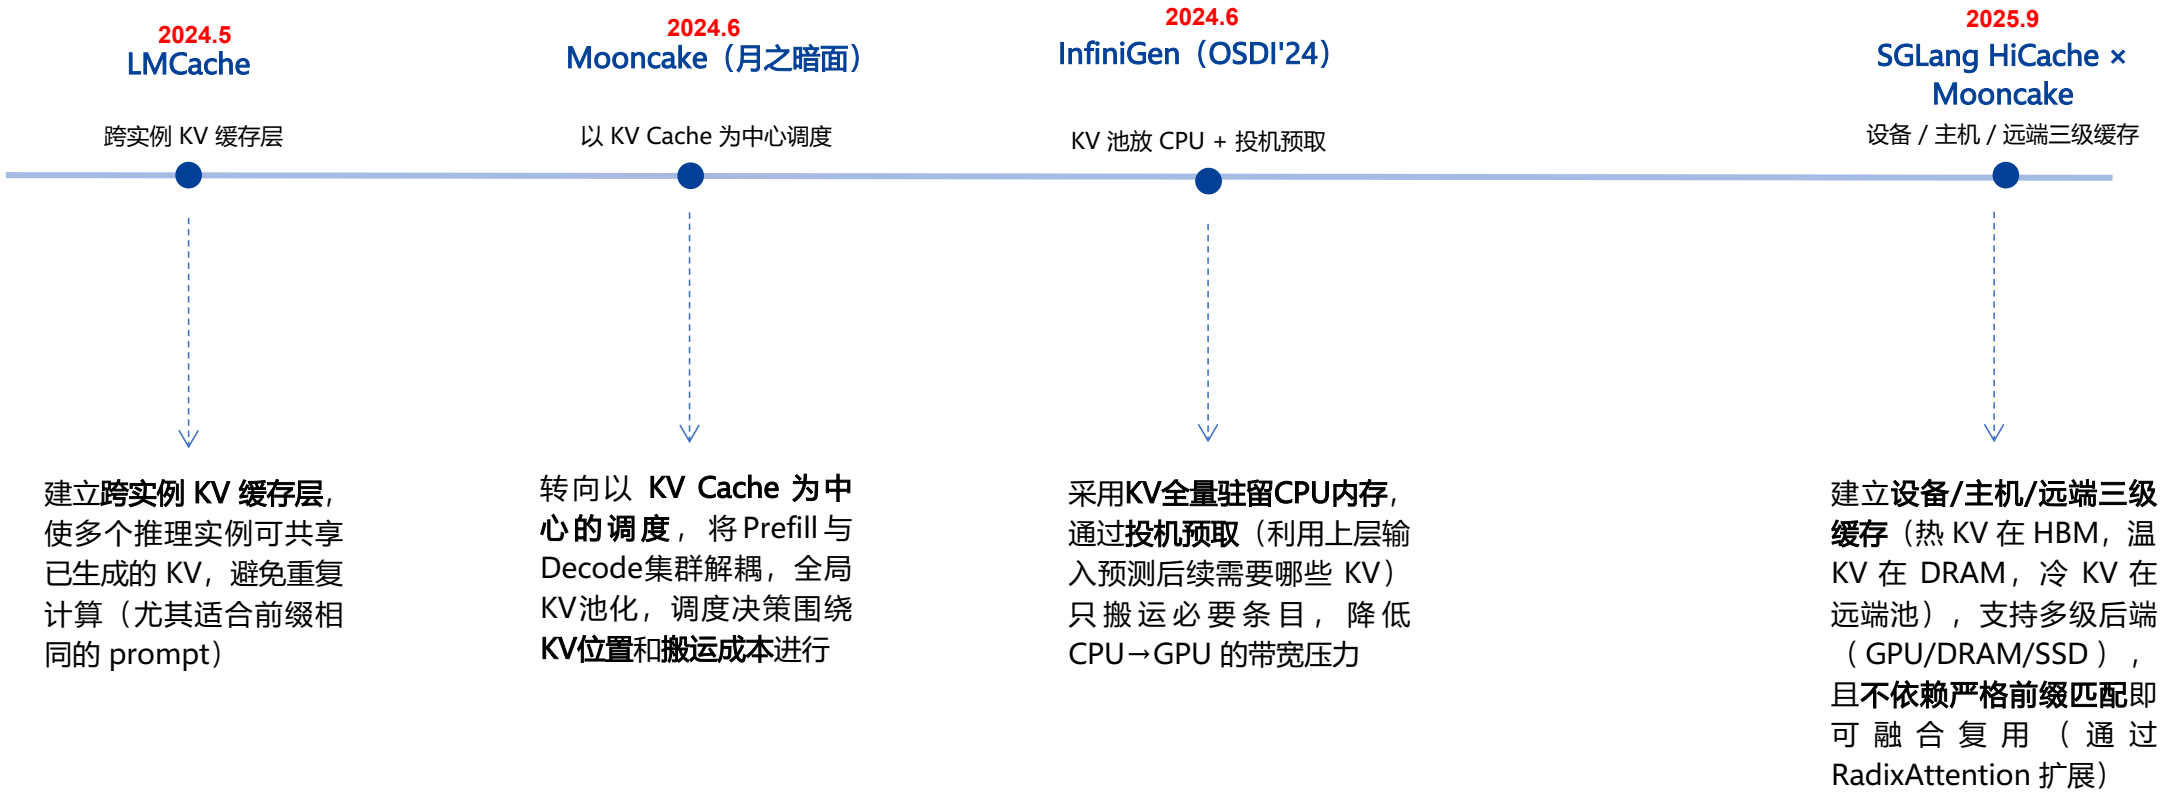


用运力换存力：数据并行



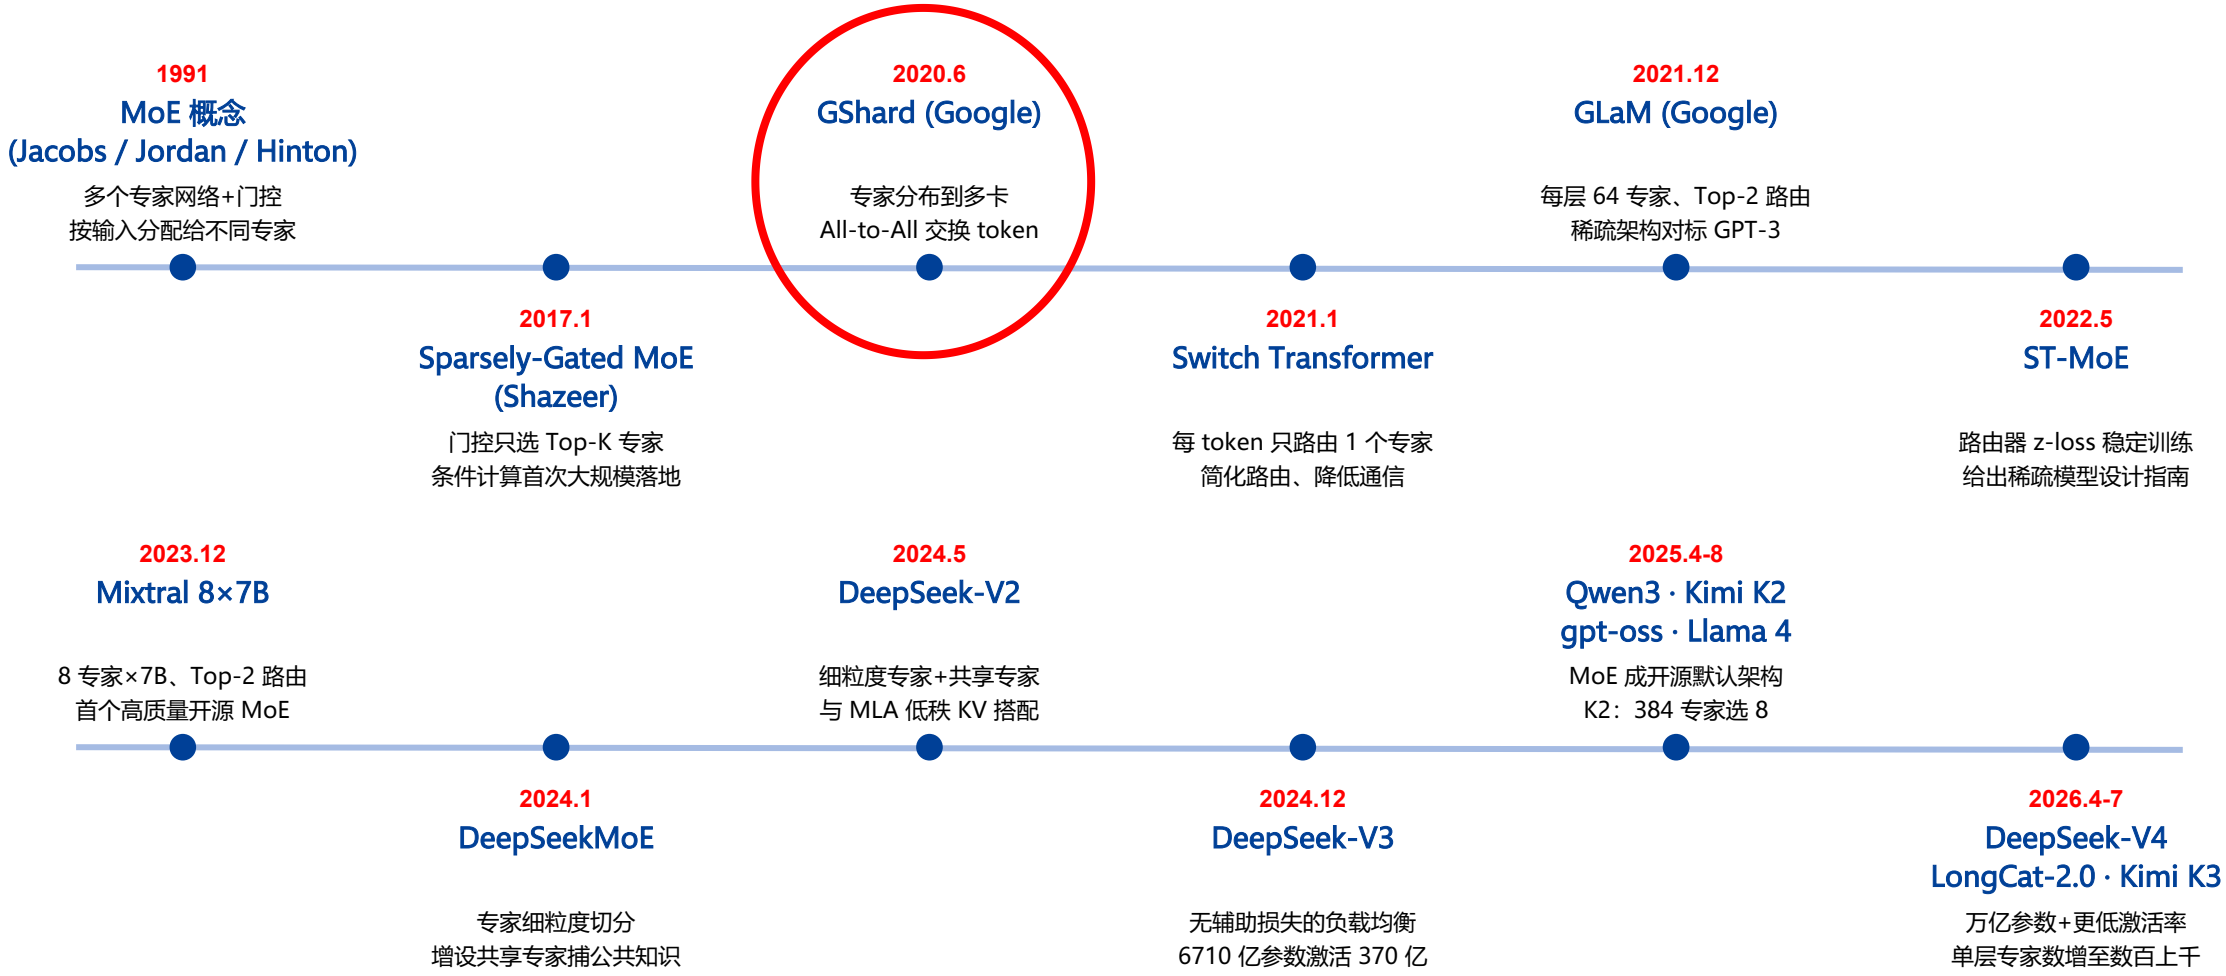
数据并行本质 = 用“运力（通信）”换“存力（显存容量释放）”。
卡越多，存力释放越多，但通信开销也越大。

用低价存力/运力换高价存力/算力：KV Cache分层



以存储介质(SSD/远端)的容量换显存(HBM)的容量，以数据搬运成本换重复计算成本

用存力(GPU显存)换算力：MoE模型

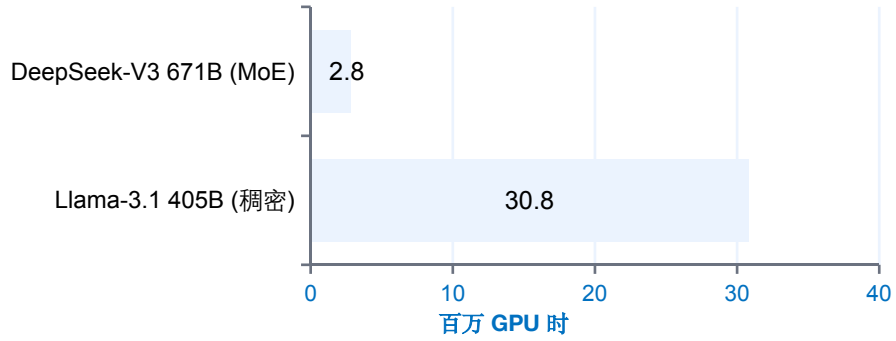


用存力(GPU显存)换算力：MoE模型

本质：以「显存 + 互联带宽」换「算力」—— 激活参数小 → FLOPs 与解码带宽需求低

模型（时间）	总参/激活	激活率	量化收益
Switch (2021.1)	1.6T / Top-1	~0.4%	相同算力下预训练提速 7 倍（对比 T5）
GLaM (2021.12)	1.2T / 96.6B	8%	训练能耗 456MWh（GPT-3 的 1/3）；推理算力降 48.6%
Mixtral 8×7B (2023.12)	46.7B / 12.9B	27.6%	推理速度达 Llama 2 70B 的 6 倍
DeepSeek-V2 (2024.5)	236B / 21B	8.9%	训练成本比同档 67B 稠密模型降 42.5%
DeepSeek-V3 (2024.12)	671B / 37B	5.5%	完整训练仅 278.8 万 H800 卡时（约 558 万美元）
MiniMax M3 (2026.6)	428B / 23B	5.4%	100 万 token 上下文单 token 计算量约为 M2 的 1/20
DeepSeek-V4 Pro (2026.4)	1.6T / 49B	3.1%	专家权重 FP4 存储，显存再减半
LongCat-2.0 (2026.7)	1.6T / 48B	3%	首个国产 5 万卡集群训出的万亿 MoE

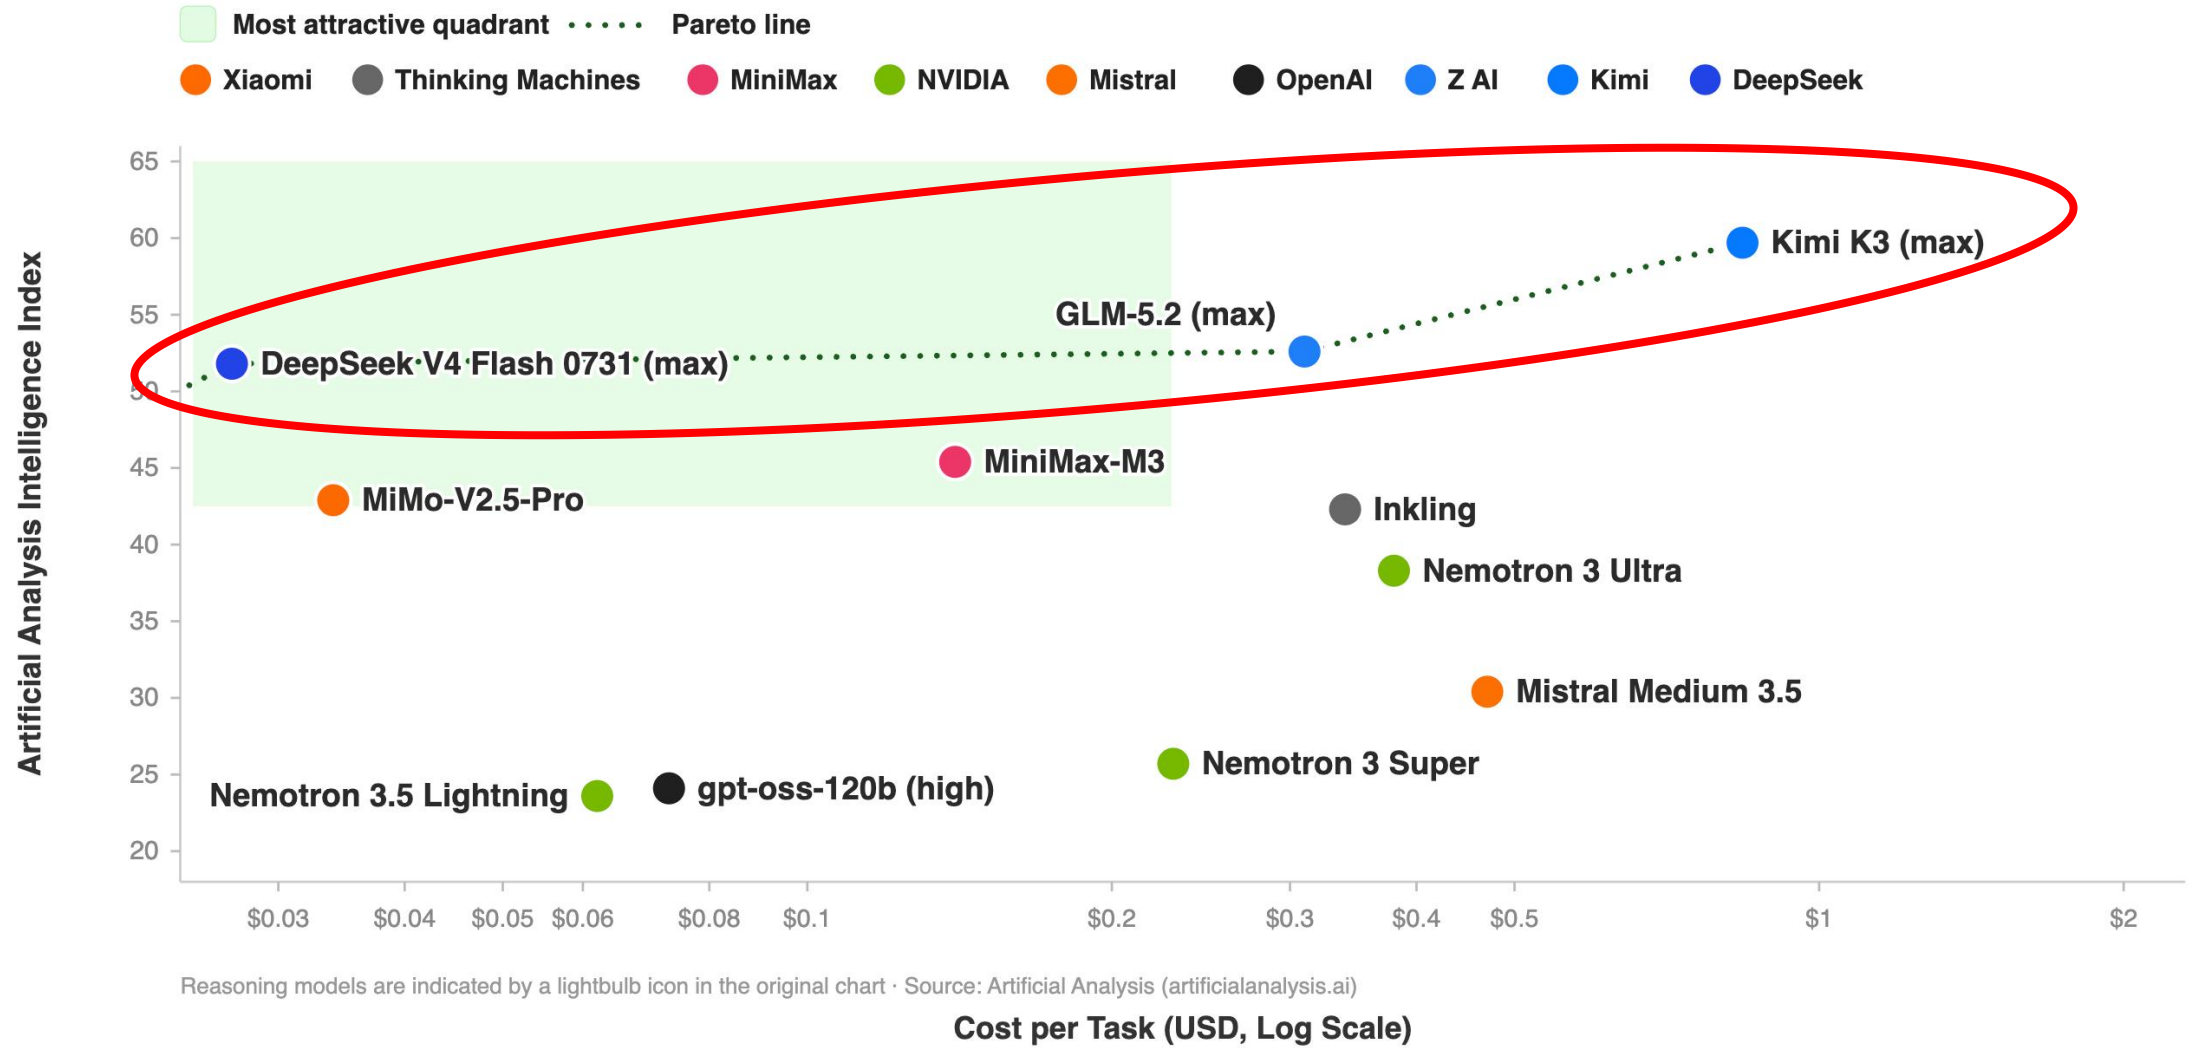
训练算力消耗对比（GPU 时，越低越省）



算力	同性能训练成本下降一个数量级（V3 ≈ 1/11 GPU 时）
显存	全部专家须驻留：671B BF16 ≈ 1.3TB，需 EP 切分
内存带宽	解码仅读激活参数，带宽需求随激活率下降
互联带宽	专家并行 All-to-All 成新瓶颈

MoE = 加大存力换低算力；瓶颈从算力转至运力，迫使存算置换中引入运力维度。

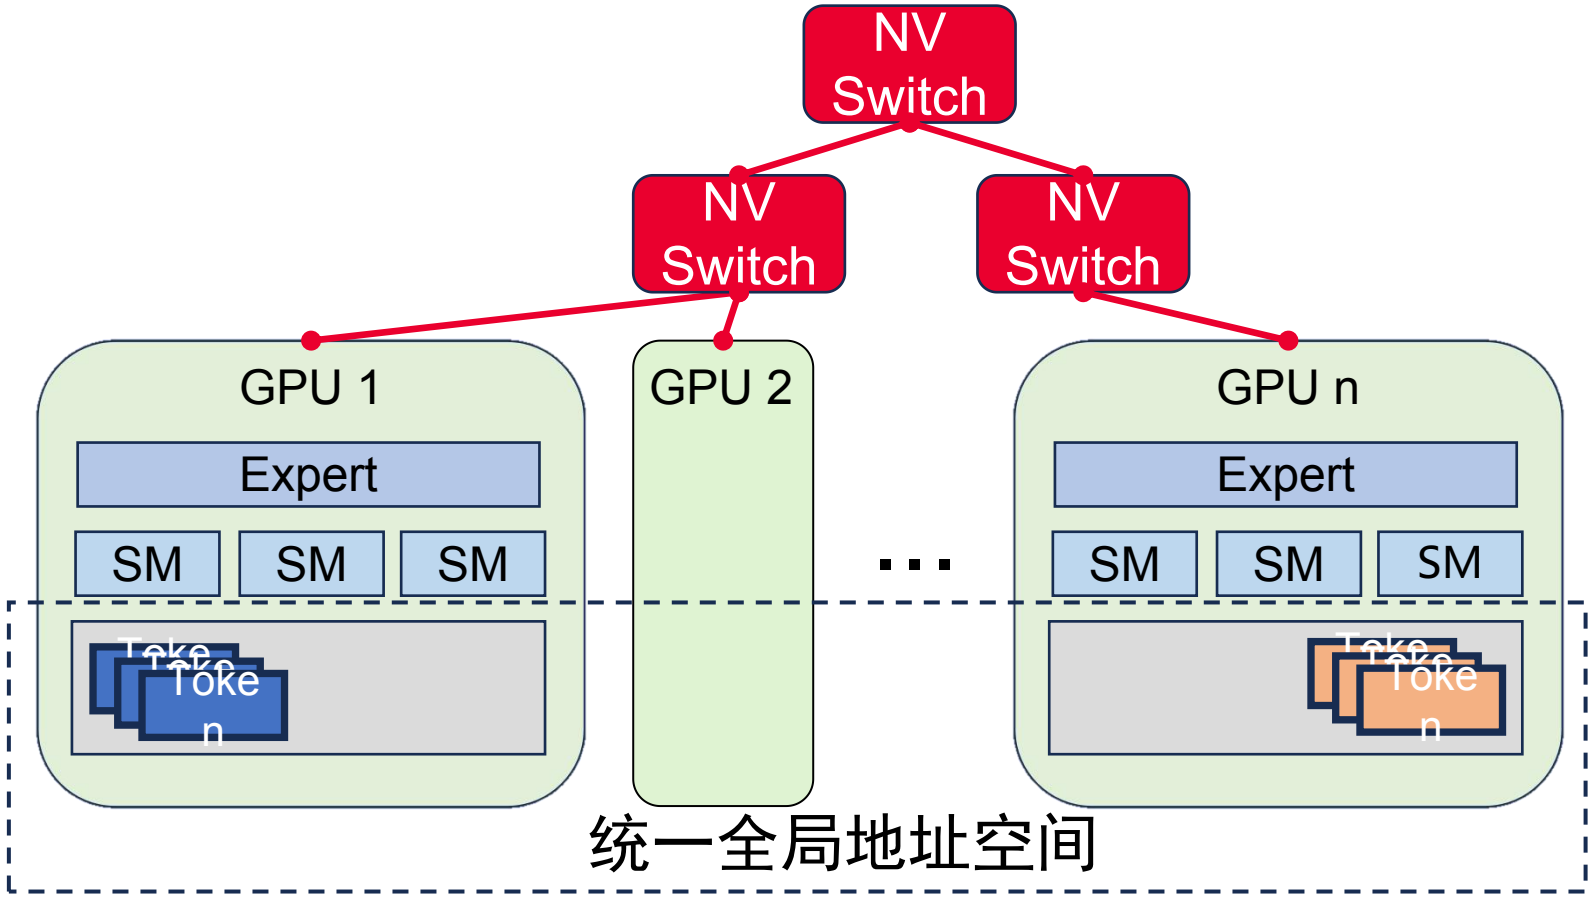
主流开源大语言模型通常是MoE模型



*Artificial Analysis Intelligence Index (11 Aug 2026)

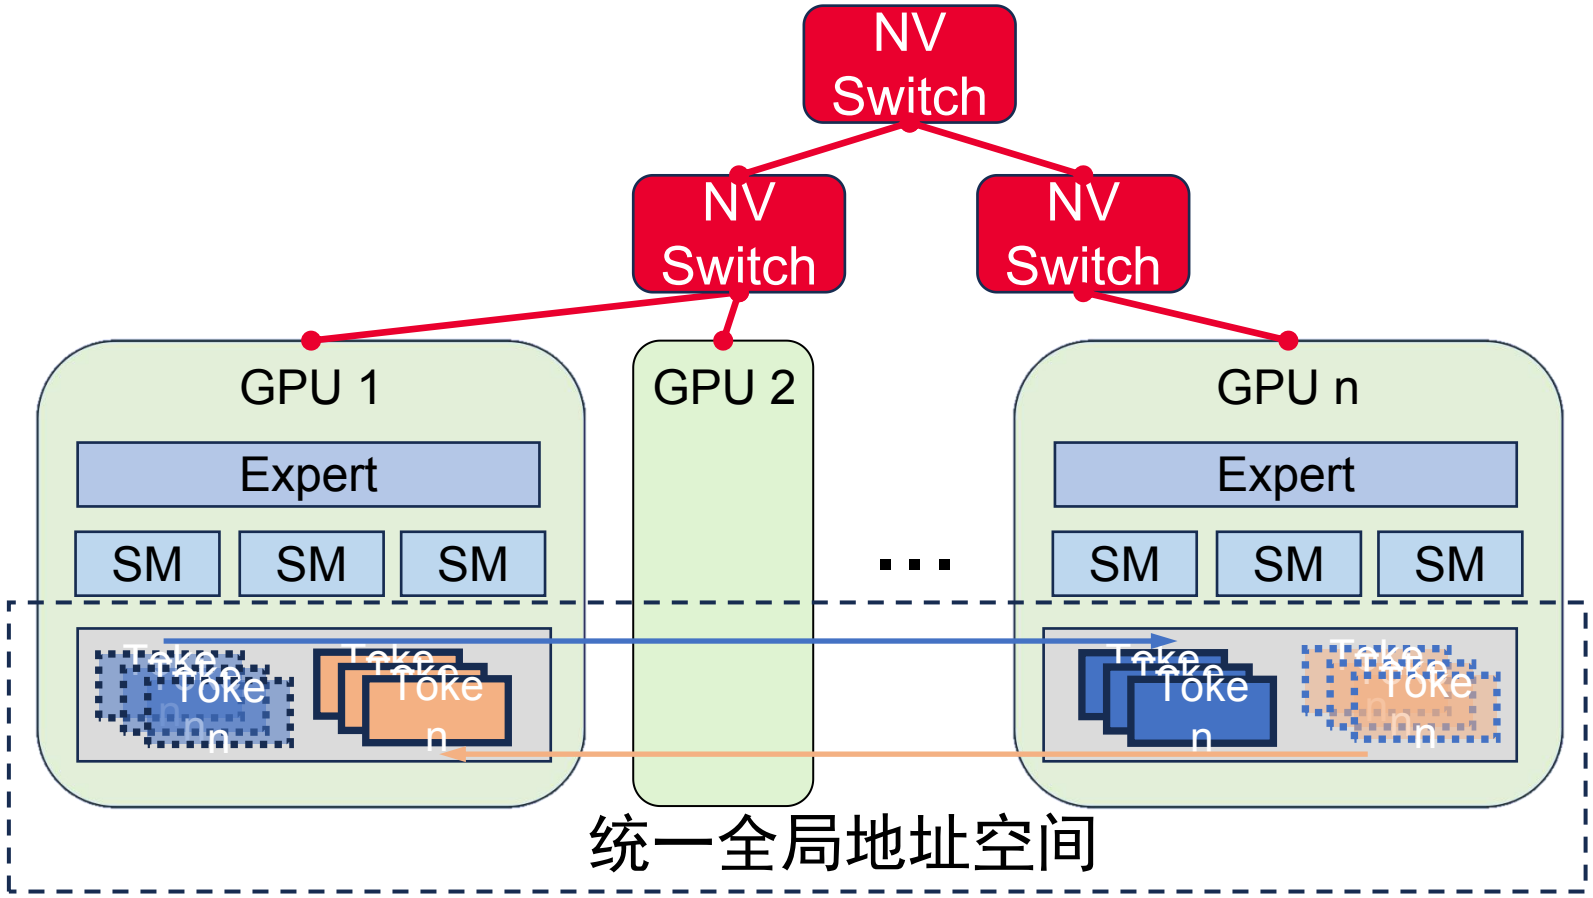
在某个大型生产超节点中部署MoE模型

- 超节点Scale-up域：400 GB/s带宽，亚微秒级延迟
- 统一全局地址空间：不同GPU的HBM被映射到统一全局地址空间中，所以一个GPU可以直接通过load/store的形式访问另一个GPU的HBM



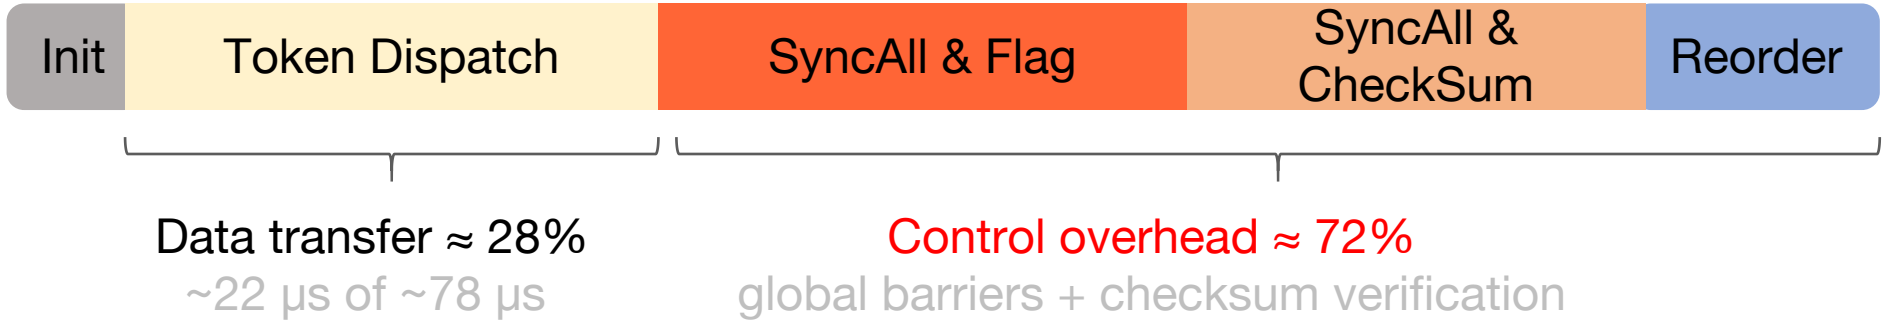
在某个大型生产超节点中部署MoE模型

- 超节点Scale-up域：400 GB/s带宽，亚微秒级延迟
- 统一全局地址空间：不同GPU的HBM被映射到统一全局地址空间中，所以一个GPU可以直接通过load/store的形式访问另一个GPU的HBM



Dispatch算子执行时间分解

- 在超节点亚微秒Scale-up网络中，Barrier和Flag协议等控制开销在总时间中占比高，而非Token传输时间



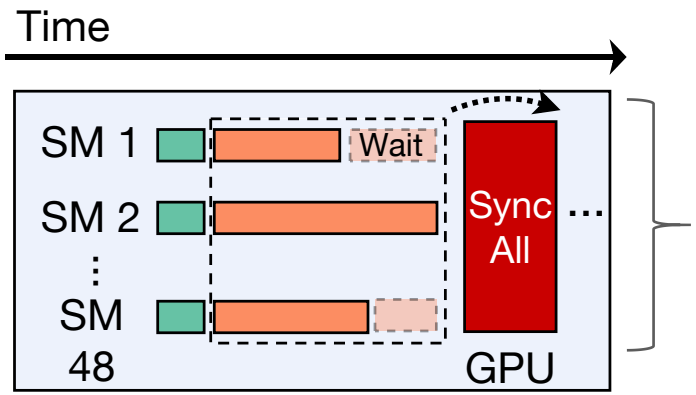
发现 1：控制开销在算子执行时间中占比高

SM任务分配与BSP的影响

- 部分通信SM能够使Token分派达到带宽饱和；阶段性的屏障（Barrier）使得其余SM处于空闲状态

#SM = 24
latency : 55 us

#SM = 32
latency : 52 us



#SM = 48
latency : 51 us

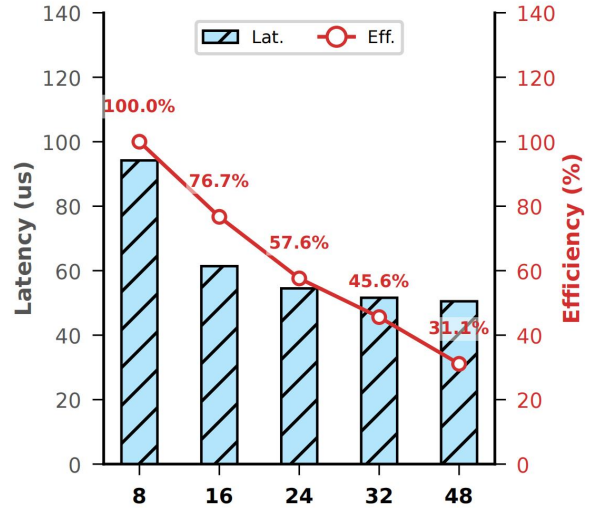


Figure : Scalability of the Token-Sending phase with varying SM allocations

发现 2：BSP限制了SM任务分配灵活性

两级互联拓扑的影响

- 同构的高带宽网络结构与统一地址空间消除了节点边界，但不同路径仍然会形成集群级别的NUMA效应

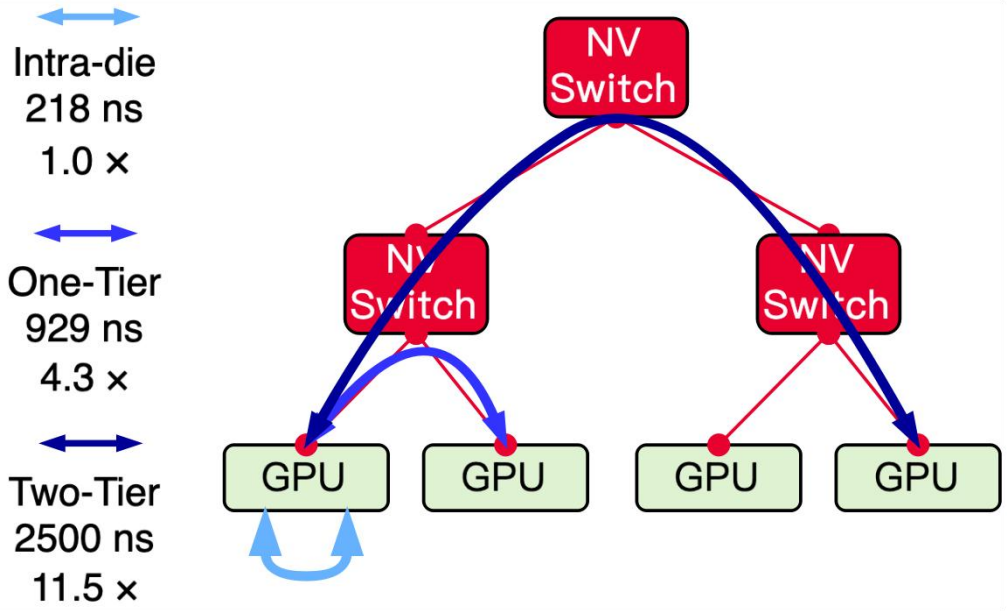


Table : Memory access latency hierarchy under distinct distance categories in a large production supernode.

Memory Access Level	Latency (ns)	Normalized
Intra-Die	218	1.0 ×
One-Tier	929	4.3 ×
Two-Tier	2500	11.5 ×

发现 3：超节点中带宽可能是同构的，但延迟可能是异构的

设计方案概览

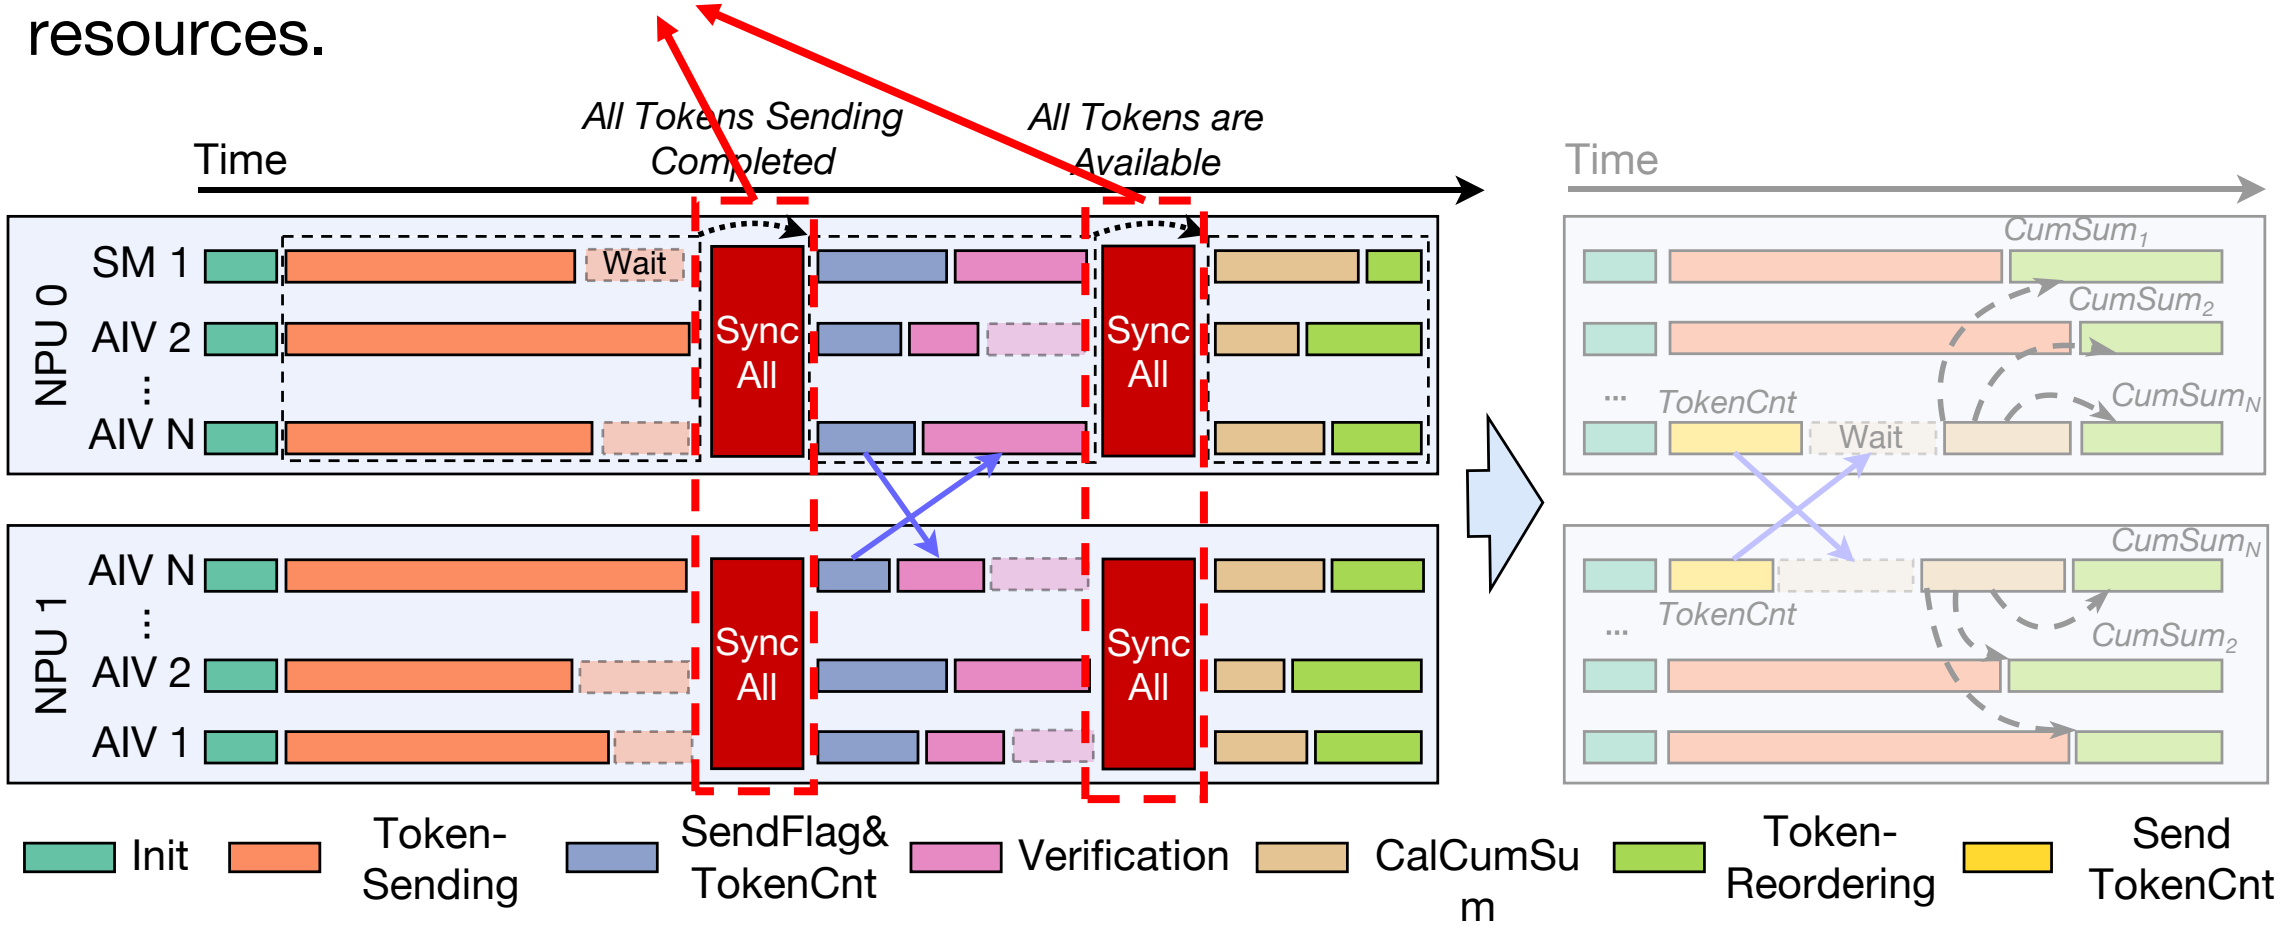
- **Insight 1**: SMs need to be assigned to different task, but Bulk Synchronous Parallel limits it.
- Kernel Decomposition: Partition SMs into groups and execute independent tasks in parallel.

- **Insight 2**: Control overhead becomes a visible bottleneck.
- Hierarchical Token-level Scheduling: Assign tokens by considering both SM load and latency.

- **Insight 3**: Superpods flatten bandwidth, not latency.
- Data-as-Flag: Embed readiness signals into atomically transferred data.

技术点1：内核分解技术

Problem: need SyncAll to satisfy data dependencies, reduce utilization of GPU resources.

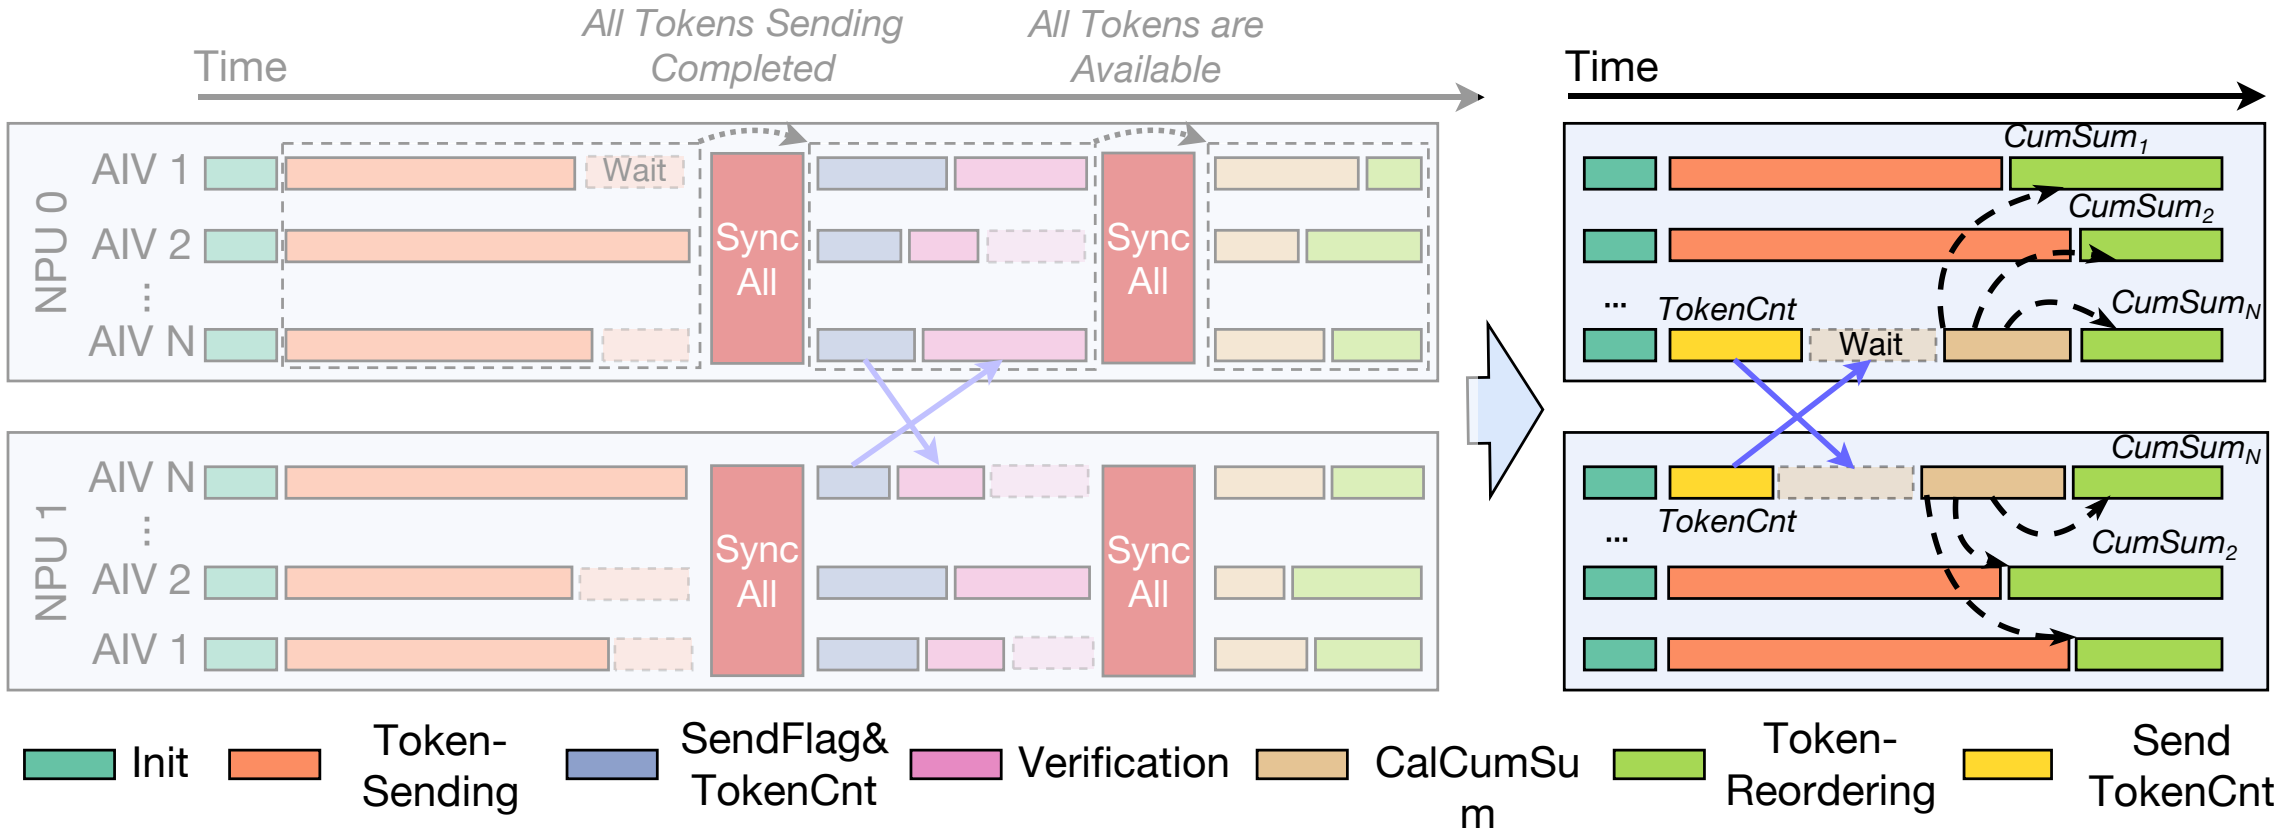


(a) BSP-based implementation

(b) Kernel Decomposition

技术点1：内核分解技术

Solution: assigning independent tasks to different SMs and employing asynchronous signals to decomposes tokens and metadata sending.

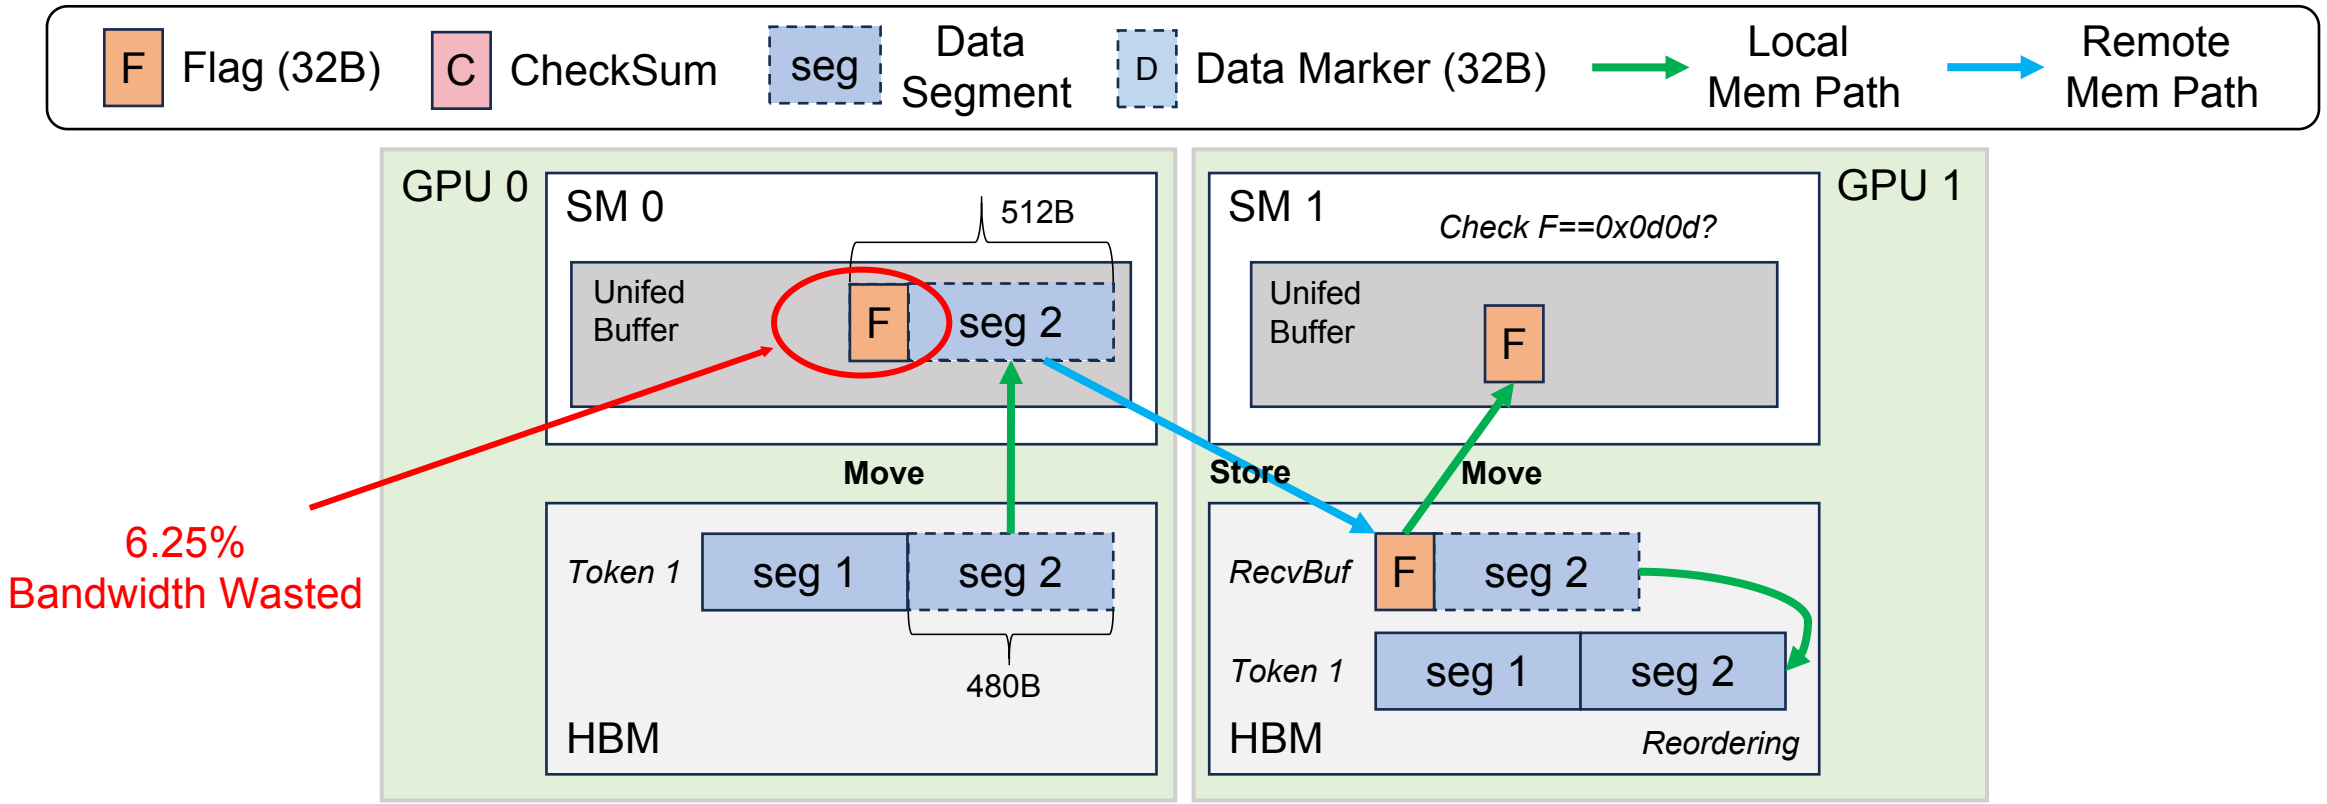


(a) BSP-based implementation

(b) Kernel Decomposition

技术点2：数据即标志同步技术

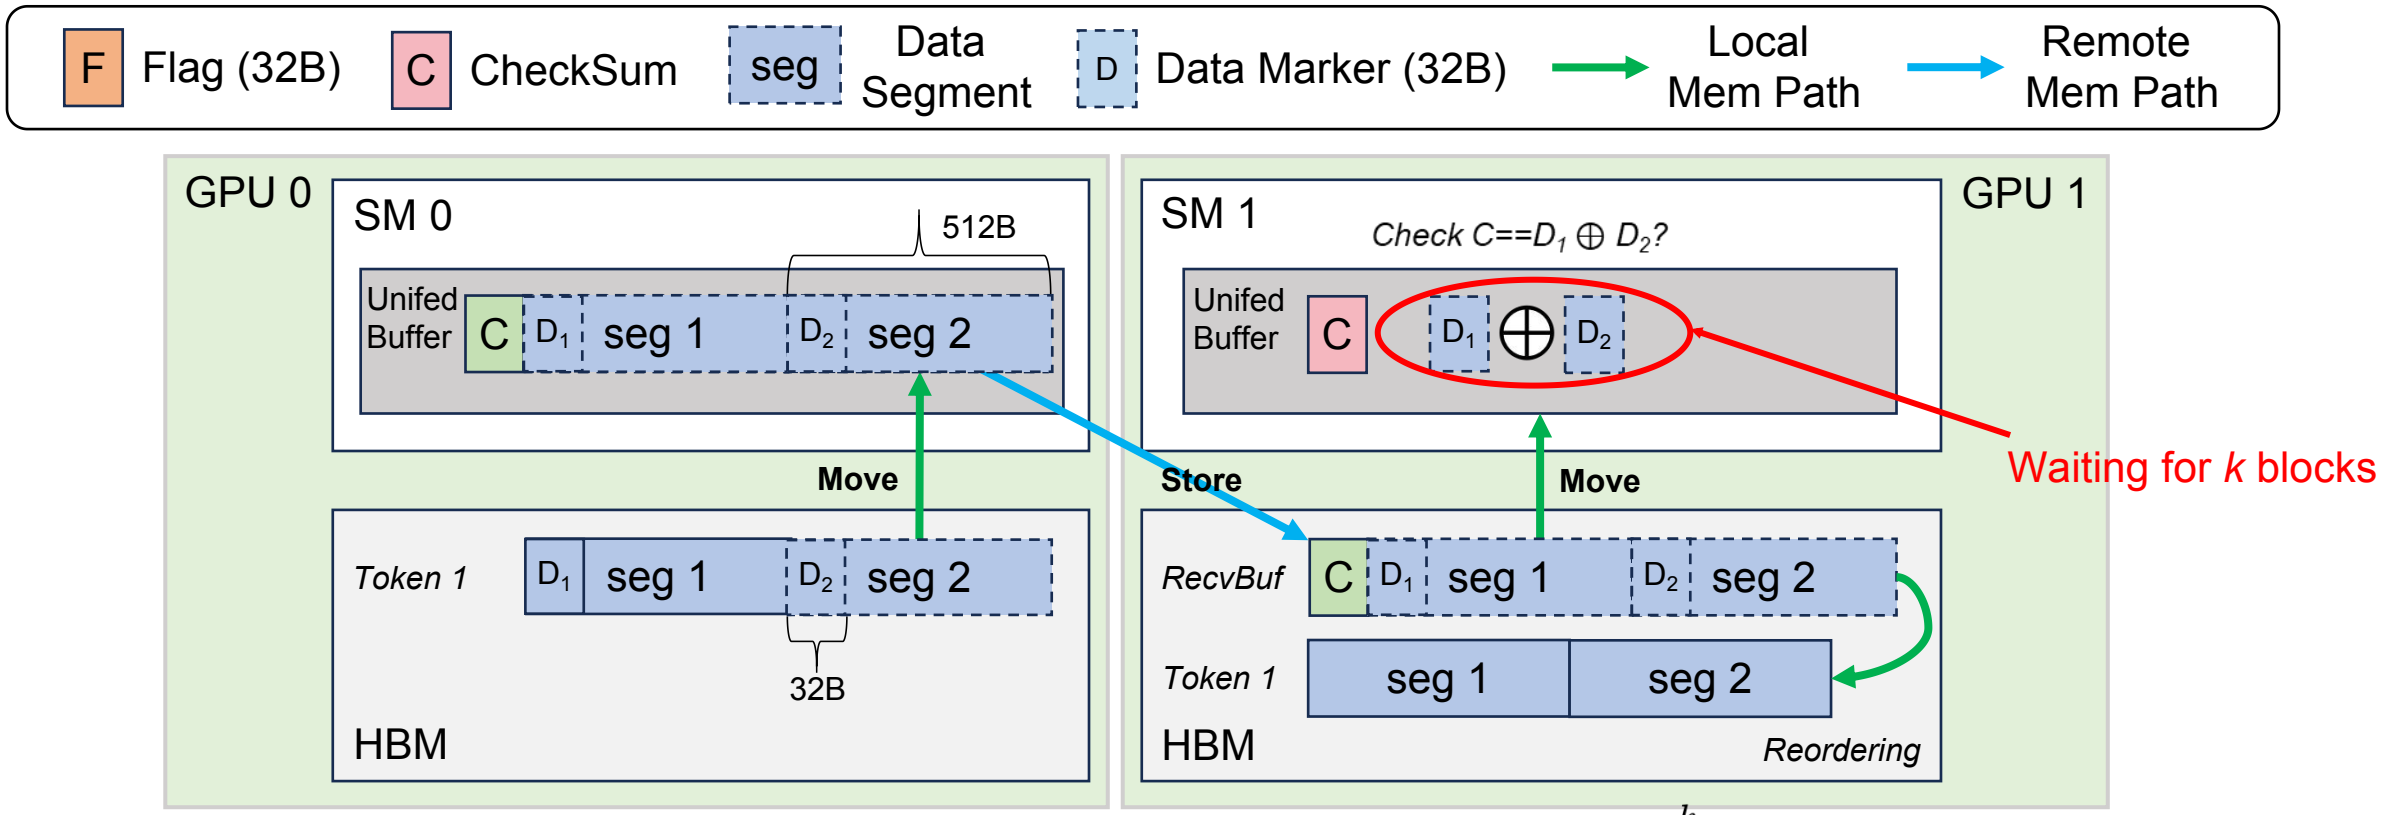
- Leverage 512B atomic write to ensure whole DataBlock simultaneous arrival



Token—Flag Fusion：512B Block = 32B Flag + 480B Data

技术点2：数据即标志同步技术

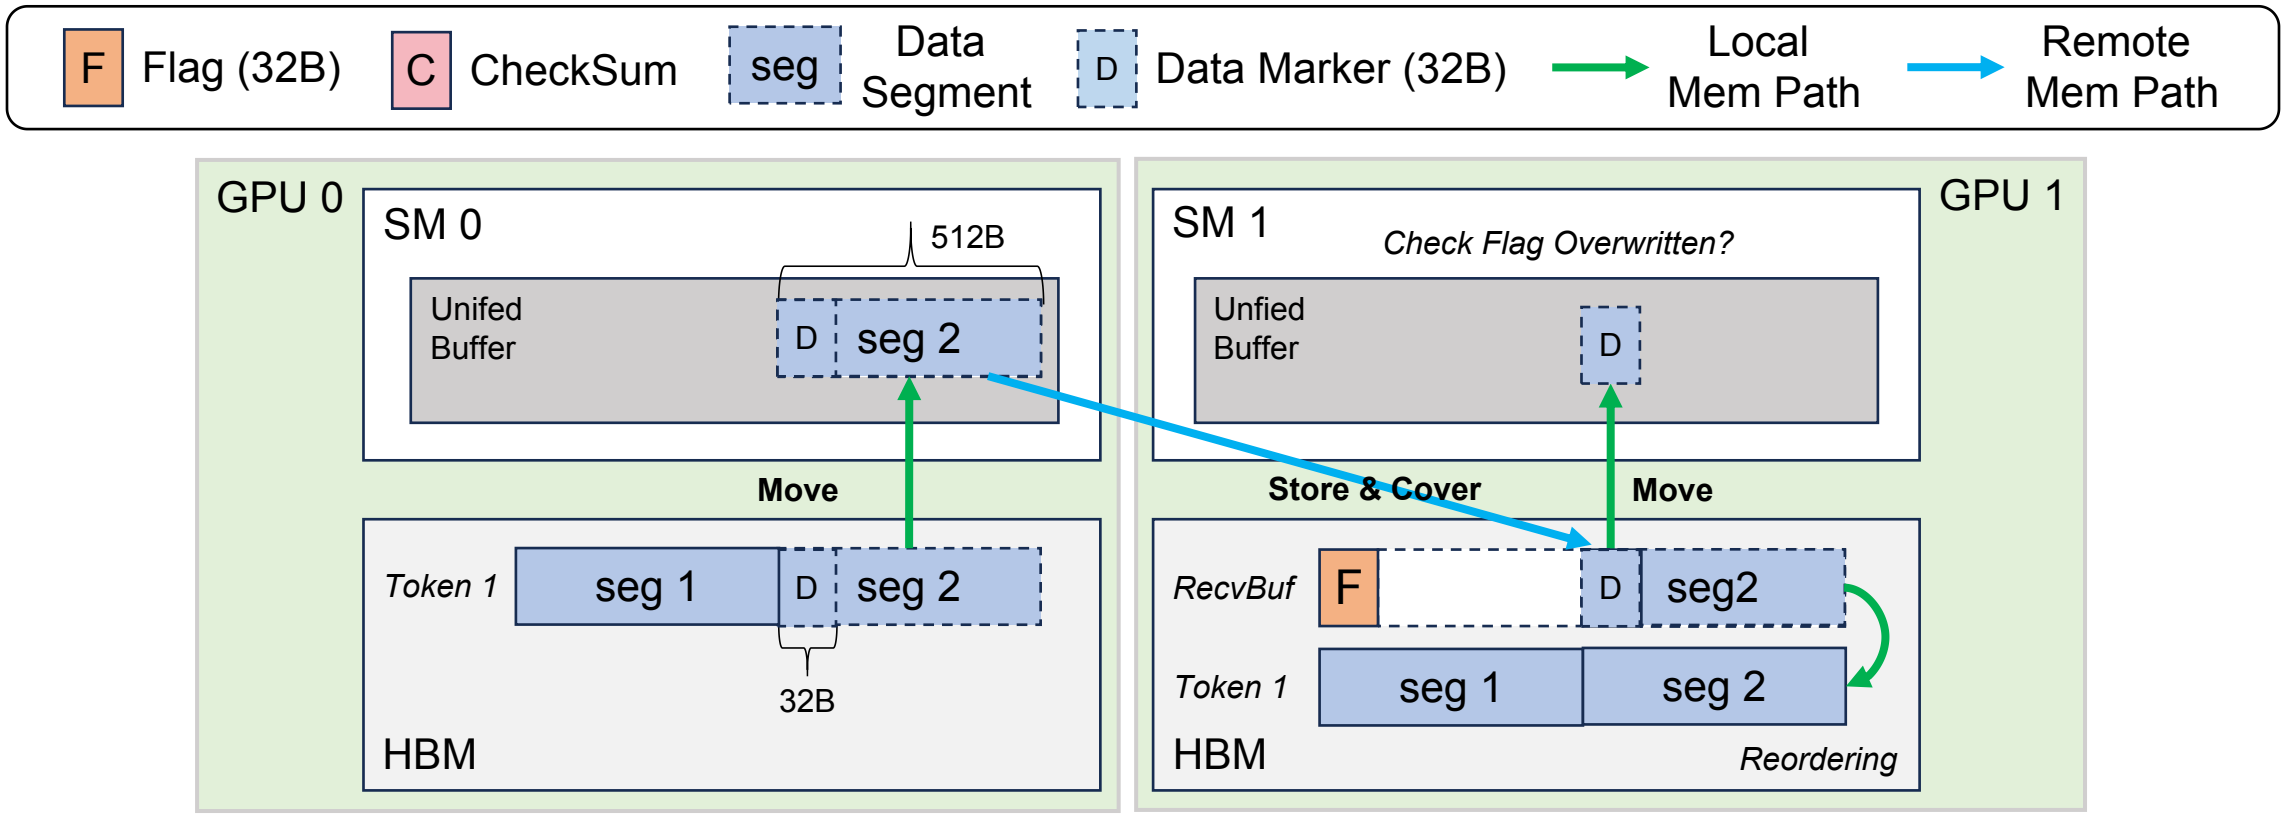
- Leverage 512B atomic write to ensure whole DataBlock simultaneous arrival



Data for checksum: k blocks arrived $\Leftrightarrow$ CheckSum $==\sum_{1}^{k}$ 32B Data Marker

技术点2：数据即标志同步技术

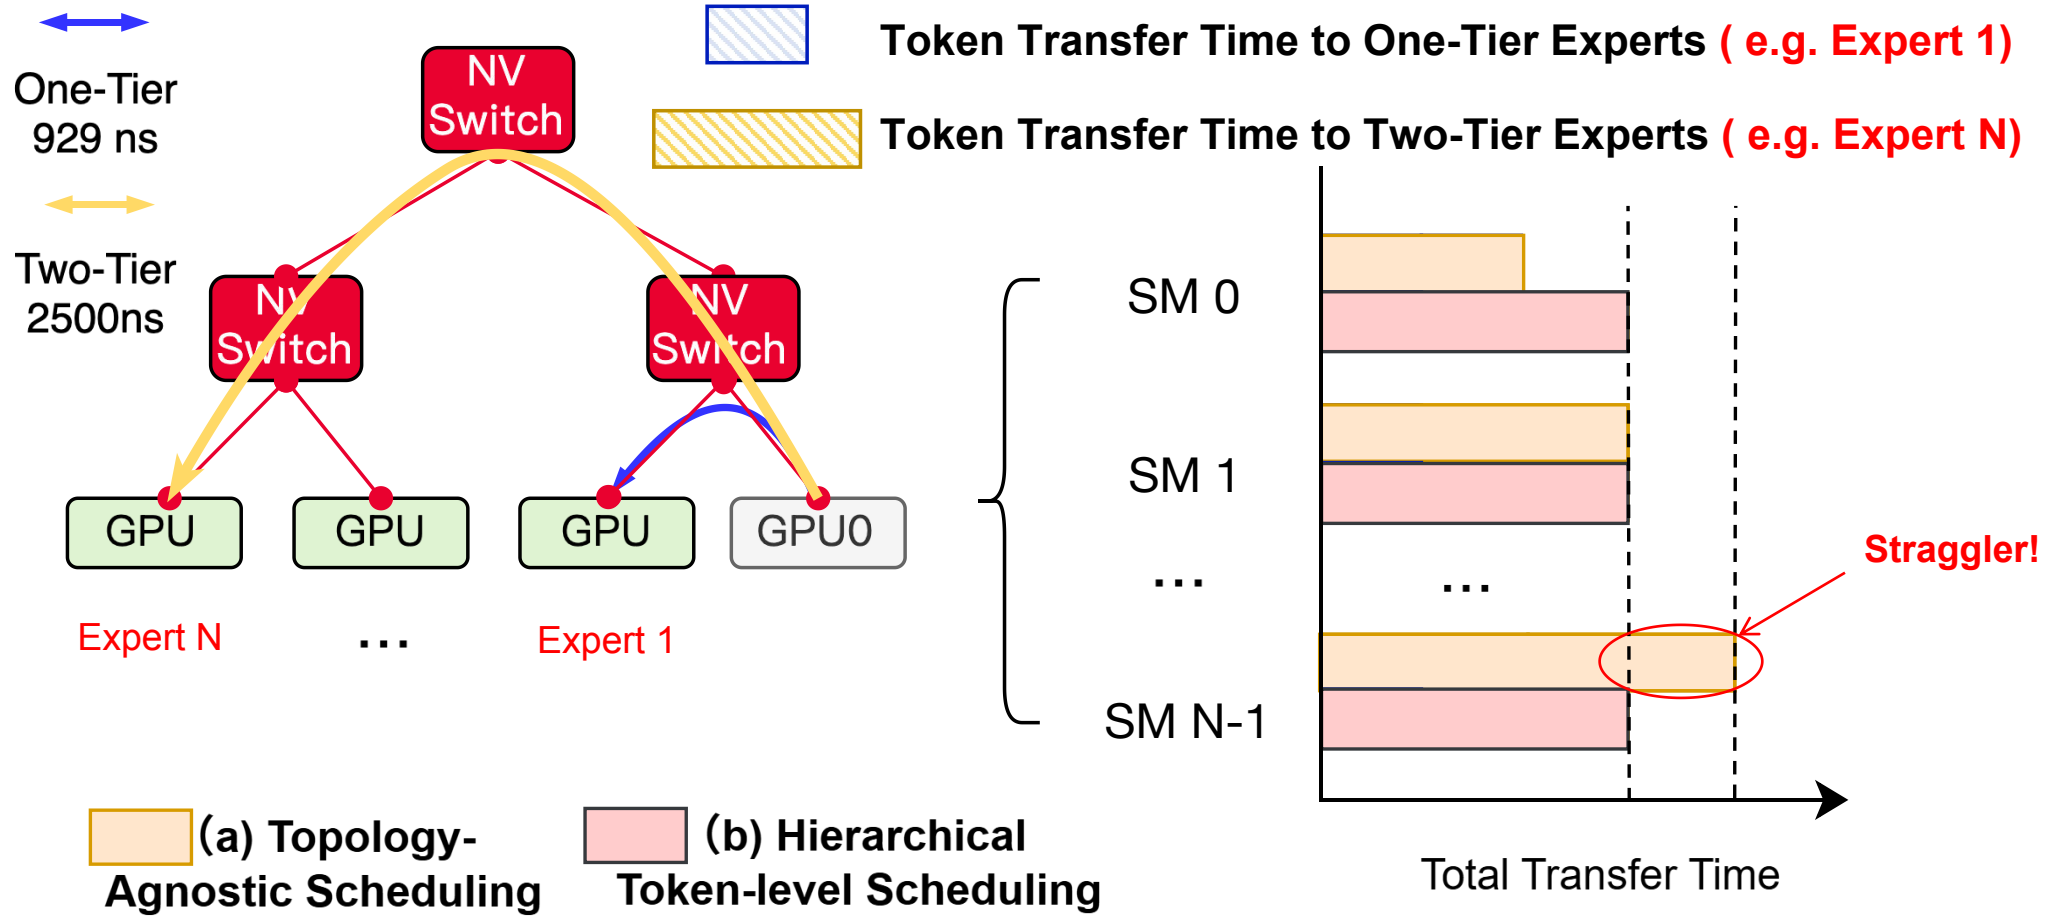
- Leverage 512B atomic write to ensure whole DataBlock simultaneous arrival



Sentinel Polling: Data Arrived ⇔ 32B Data Marker D != Sentinel Flag F

技术点3：两级互联拓扑感知的层次化调度

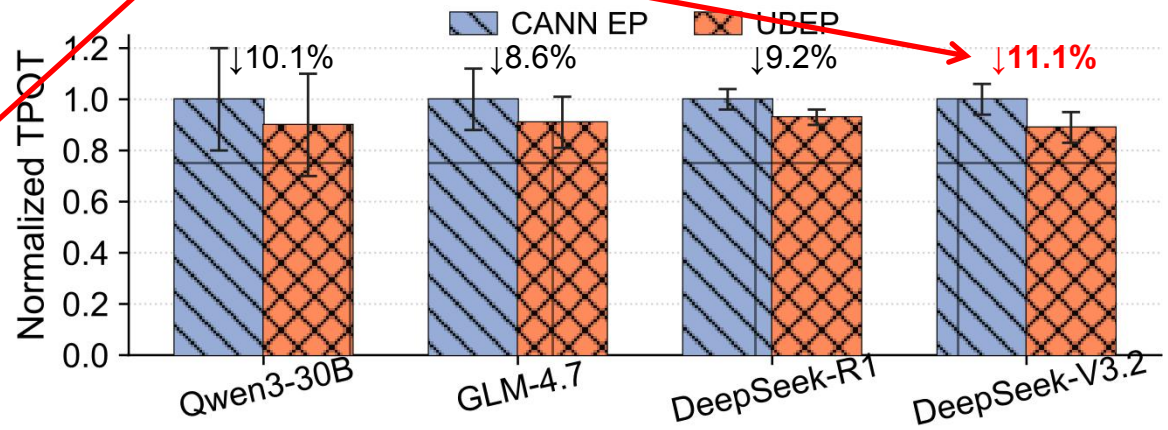
Hierarchical scheduling balances each hop-distance class across SMs, eliminating topology-induced stragglers.



性能收益

- UBEP improves EP communication bandwidth by 35.3–40.8% over CANN EP, translating to up to 11.1% lower end-to-end TPOT.

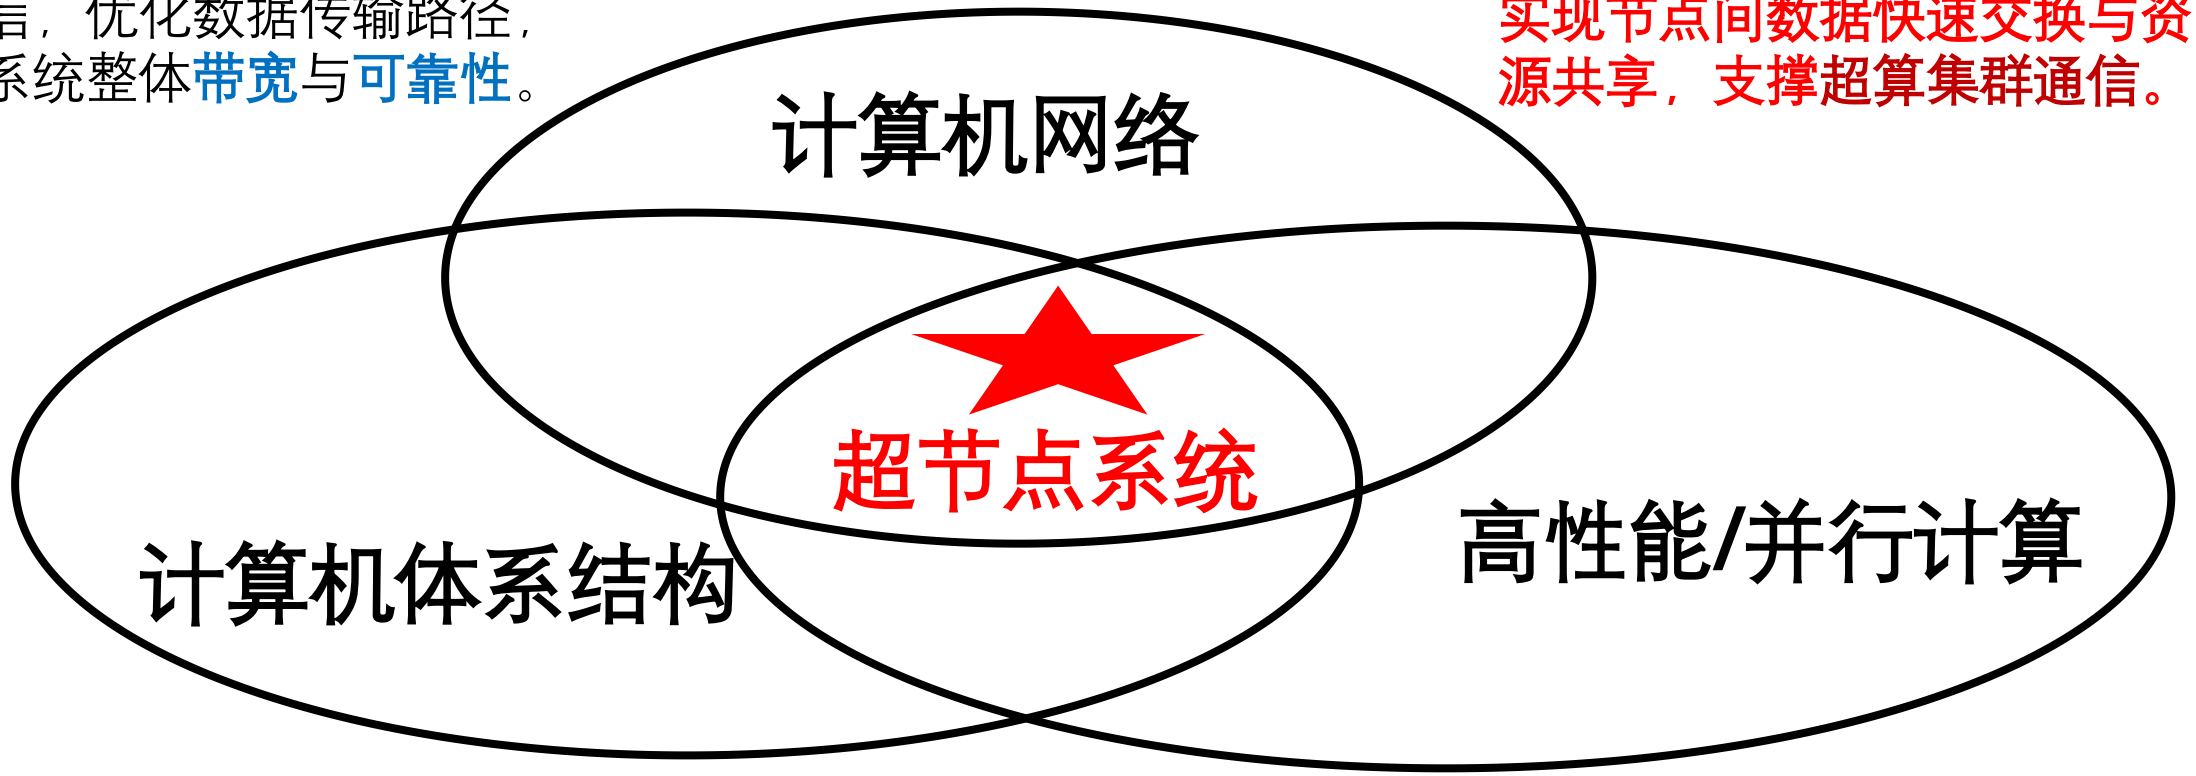
EP	CANN EP		UBEP		
	Latency (μs)	BW (GB/s)	Latency (μs)	BW (GB/s)	
16	103	71	**73**	**100**	**↑40.8%**
32	120	61	**86**	**85**	**↑39.3%**
64	139	53	**101**	**73**	**↑37.7%**
128	144	51	**106**	**69**	**↑35.3%**
256	151	48	**112**	**66**	**↑37.5%**



超节点系统是交叉领域

超节点通过高速互联实现多节点通信，优化数据传输路径，提高系统整体带宽与可靠性。

三者融合构成高效总线网络，实现节点间数据快速交换与资源共享，支撑超算集群通信。



超节点整合多核与多处理器架构，实现共享内存与协同计算，提升指令级与线程级并行度。

超节点利用并行调度与负载均衡，将复杂任务分解执行，显著提升计算速度与吞吐量。

谢谢! Q&A

jzheng@nju.edu.cn