GOSIM 晴数智慧

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



GOSIM 晴数智慧

GOSIM Shenzhen 2026

Voice Agent 在具身智能中的应用及高质量数据解决方案

北京晴数智慧科技有限公司

专注为对话式 AI 与 Voice Agent 提供高质量数据集及解决方案



晴数智慧

CONTENTS

GOSIM Shenzhen 2026

Part 01 具身智能时代，Voice Agent 行业现状与变革

Part 02 Voice Agent 三大核心交互困境深度拆解

Part 03 场景化高质量数据，破解具身智能交互瓶颈

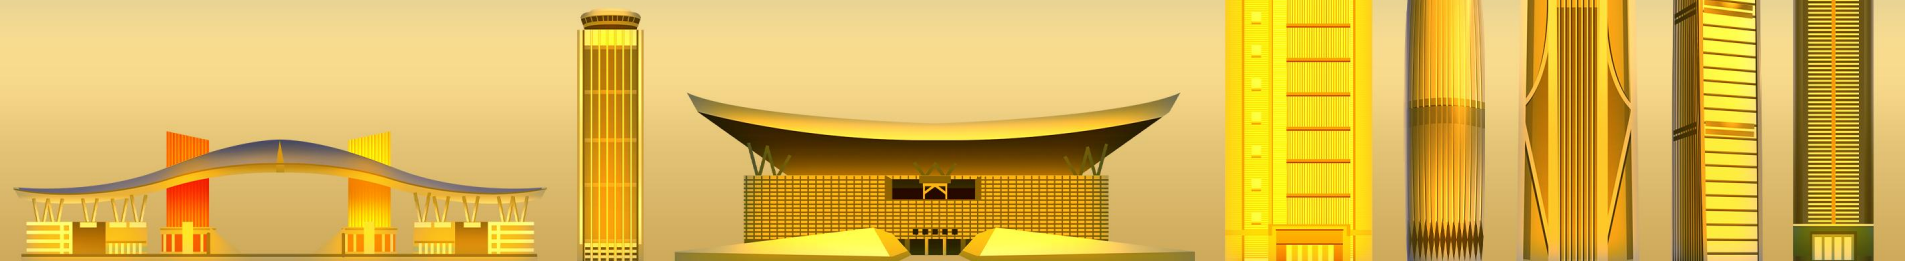
Part 04 晴数智慧：面向具身智能的数据合作伙伴



GOSIM 晴数智慧

GOSIM Shenzhen 2026

具身智能时代，Voice Agent 行业现状与变革



晴数智慧

“Voice Agent如何才能支持具身智能落地？”



三大核心瓶颈，严重制约了智能座舱、家庭服务机器人等终端具身及端侧AI产品的规模化商用

01 交互范式革命：AI Agent从软件对话走向物理世界实体落地

具身智能已成为AI实体化落地的核心赛道，行业正式从传统纯软件对话交互，迈入“感知、决策、执行”一体化的物理世界交互新时代，AI Agent的竞争重心全面转向实体场景的落地能力。

02 具身智能Voice Agent三大核心交互瓶颈与行业痛点

当前Voice Agent作为具身智能人机交互的核心载体，正面临行业共性核心困境，多数产品无法实现从“能聊”到“能干”的范式升级，普遍存在交互生硬不自然、口语模糊指令理解精准度低、复杂动态环境下任务执行低效、交互安全体系缺失等三大核心瓶颈。

智能座舱：高动态半封闭场景交互痛点与定制化数据方案

痛点：

- 交互延迟：半双工技术中，等一句话播报完，车已开出百米
- 方言口音："师傅，调个头"，要么没反应，要么导错航
- 多意图指令："降个温、再放首歌"，指令拆解困难

定制化数据方案：

双工对话数据 · 百城方言数据 · 座舱多意图数据集

家庭服务机器人：人机共融开放场景核心难题与数据落地实践

痛点：

- 指代消解："把那个递给我"，"那个"是哪个？
- 嘈杂共融：电视、多人、孩子跑动、远近场混叠
- 安全打断：老人小孩在场，动作要温柔、要能随时"停"下来

数据落地实践：

多模态交互数据 · 真实家庭环境语料 · 安全交互数据

同一套数据，往往难以支撑不同场景——场景化定制数据，才是具身智能落地的钥匙。

行业拐点：从“能聊”到“能干”，数据是核心引擎



2026年被视为AI Agent落地元年，终端具身产品的竞争维度已发生质变：从比拼“谁的模型大”转向“谁的体验好”，从被动的“对话 AI”进化为主动的“办事式具身智能体”。

实验室数据域偏移问题

实验室仿真数据无法复刻真实物理环境的复杂性、动态性与随机性，导致模型落地后适配性差、场景泛化能力薄弱。

核心症结：高质量数据的缺失

高质量、真实化、多维度的多模态交互数据，成为突破Voice Agent具身交互瓶颈、实现产品能力迭代升级的核心钥匙。

交互不自然

打破“说完再听”的割裂模式，实现像人与人一样自然、连续、多轮次的顺畅交互体验。

理解不精准

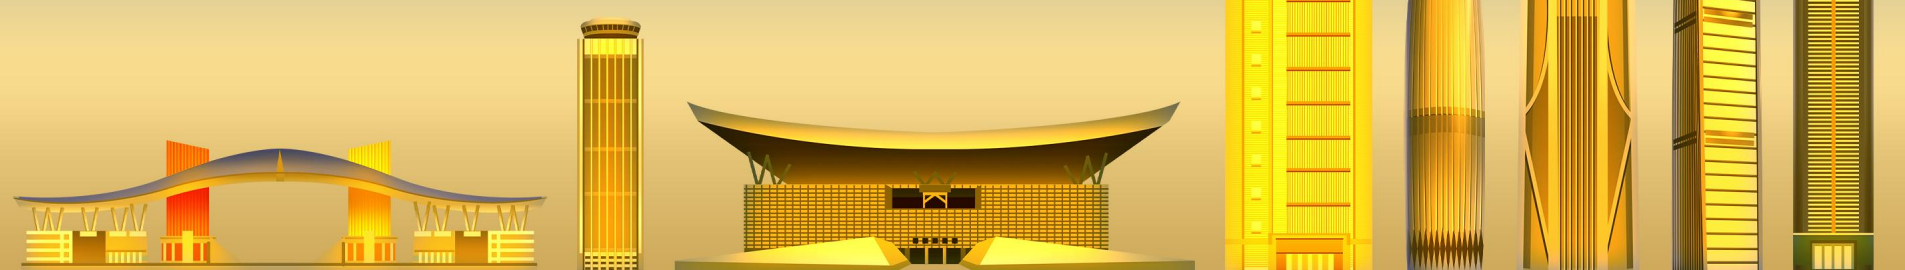
精准识别方言、口音与口语化表达，准确捕捉用户模糊指令背后的真实需求与潜在意图。

执行不智能

不仅听懂更要“会做”，跨系统协同调度复杂组合任务，而非仅执行单一简单指令。

02

Voice Agent
三大核心交互困境深度拆解



困境一：交互体验「高延迟」——等待与打断的烦恼



半双工交互的本质局限：
如同对讲机般的轮流沟通，难以还原人类自然对话的即时性与流畅感

现状：90%语音交互仍为“半双工”模式

传统级联式的交互模型存在显著的交互延迟，用户必须等待AI完全结束后才能下达新指令，无法实现日常生活中人与人交流时的随时插话与实时互动，沟通节奏被严重割裂。

痛点：交互延迟高，对话生硬死板

1. **交互延迟明显**：具身智能体对指令响应迟缓，任务流程卡顿，破坏物理场景下人机协同的使用节奏；
2. **打断操作困难**：用户无法随时插话修正或补充指令，强行打断易造成指令失效、任务中断；
3. **交互生硬无温度**：仅能识别标准化机械指令，无法感知用户犹豫、附和等语气，缺少类人对话质感。

根源：技术架构与数据的双重制约

半双工的底层技术架构难以支撑“边听边说”的并发处理，同时行业内缺乏包含“语音重叠、实时打断、情绪反馈”的真实双工对话数据，限制了具身 Voice Agent 突破 “机器式交互” 瓶颈。

困境二：用户语句「听不清」——方言、口音识别的局限



汉语方言体系复杂，地域与口音差异显著
成为具身智能语音交互普及的天然门槛

01 现状：方言识别出现明显断层

传统语音交互模型以标准普通话为核心训练样本，对各地方言的声学特征、词汇习惯适配度极低，导致非普通话用户无法实现自然、顺畅的语音对话，形成功能使用的断层。

02 痛点：下沉市场与广域用户触达失效

1.**功能体验断层：**面对广大方言区用户，语音唤醒、指令识别率大幅下降，家庭机器人、智能座舱等具身终端的语音便利无法覆盖这类群体
2.**细微口音难适配：**即便同一方言区，地级市甚至县级的口音差异（如四川话的梅花音、粤语九声六调）也会导致识别精准度骤降，无法满足本地化使用需求。

03 根源：方言训练数据与场景适配的双重缺失

行业缺少覆盖百城、分地域、分口音的大规模真实物理场景方言语料；模型未针对复杂环境声学条件做方言专项优化，难以捕捉方言的韵律、语调特征，限制具身智能体普惠落地。

困境三：任务指令「听不懂」——固定句式与场景局限



传统 Voice Agent 仅能响应孤立的单一指令，用户必须学习固定 “命令式” 话术才能触发功能，记忆成本高；无法像人与人交流那样自然表达复杂需求，制约智能座舱、家庭机器人等具身终端完成复合任务。

01 现状：单指令响应，多意图乏力

交互模型局限于 “一问一答” 机械模式，仅识别预设固定指令。面对 “打开空调降温并播放舒缓音乐” 这类复合需求，具身智能体无法拆解多意图，只能逐条执行，甚至完全无法响应。

02 痛点：指令刻板化，操作体验割裂

用户被迫使用刻板指令句式，不能自由使用日常口语；场景能力局限于基础控制，难以处理多场景复合任务；方言、口音进一步拉低识别精度，破坏物理空间内自然人机协同体验。

03 根源：数据缺失与模型能力的双重短板

核心原因是缺少覆盖真实物理场景、包含自然口语与多意图的高质量标注数据；传统模型缺少复杂语义理解与任务逻辑规划能力，不能像人一样拆解、调度并完成跨设备复合任务。

03

场景化高质量数据，破解具身智能交互瓶颈



数据破局

解锁下一代具身智能交互的钥匙

双工对话数据

针对「交互体验高延迟」的痛点，模拟真实物理空间双向互动对话场景，让模型熟练处理实时打断、话题自由切换等复杂交互，还原自然流畅的沉浸式交流体验，告别机械应答。

百城方言数据

针对「用户语句听不清」的问题，采集百城多元方言及特色口音数据，大幅提升模型对不同语言变体的识别理解能力，打破地域与语言壁垒，实现座舱、机器人等具身终端 “人人可用”。

Voice Agent多意图数据

针对「任务指令听不懂」的短板，构建家居、出行、娱乐等多场景任务数据集，助力模型精准解析复杂表达、串联执行多步任务，打造能理解复合诉求的具身智能。

—— 以高质量场景化数据为基石，驱动具身智能交互向自然、普惠、智能进阶 ——

双工对话：数据支撑与真实案例

- **数据规模与场景覆盖：**

10万+ 中文普通话双工语料

覆盖日常人机交互、室内服务等高频场景，搭建大规模基础对话语料库，强化具身智能体自然语言理解能力，为机器人实时类人交互筑牢数据底座。

万级+ 多方言双工数据

覆盖四川、广东、上海等主流方言区，破除地域语音交互壁垒，让具身智能适配多元用户，在多地域场景下实现更有亲和力的自然对话。

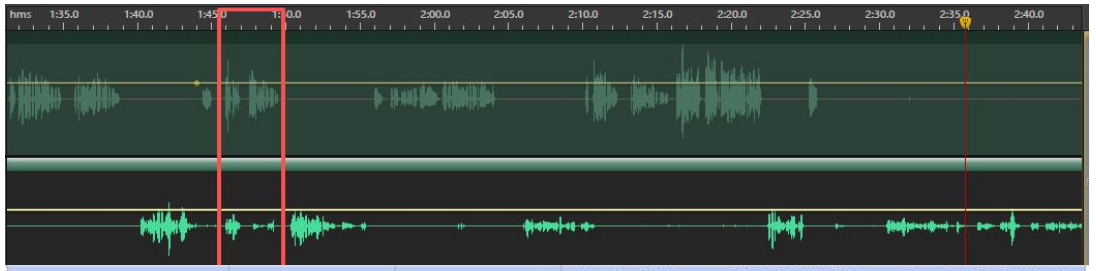
- **数据采集与样本特质：**

真实人际对话：
保留自然的打断、接话、重叠和微微反馈

分轨录制，原生双工：
双轨独立采集，说话人独立声道，无需后期分离

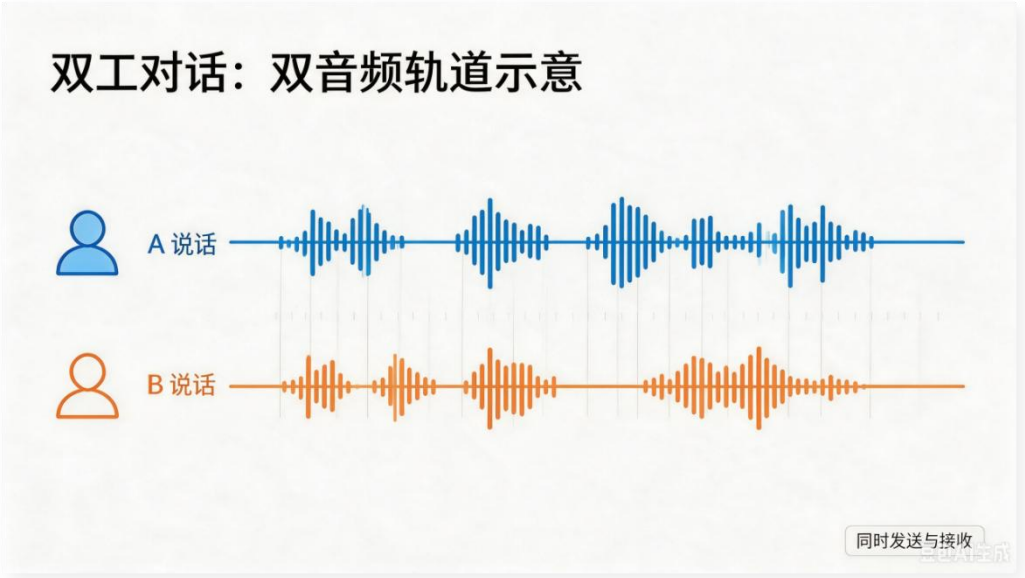
精选高交互样本：
筛选交互密度高的样本，有来有回，有情绪流动

合规采集，完整版权：
所有数据，完整版权所有数据合规采集，具有完整版权



[91.250,98.919]	G0627	女	对，但之前那一份学是学得到东西的，但是他其实相当于自己得倒贴好几千。
[100.070,103.960]	G0628	女	那我觉得也太不划算了，我感觉也没有必要其实。
[104.331,109.630]	G0627	女	对呀而且他学到的学到的东西并不多并不多。
[105.800,108.309]	G0628	女	就是学东西，对啊。
[110.180,115.539]	G0628	女	对啊，而且学东西也可以从其他的地方学其实，不一定就是对吧？
[115.850,124.221]	G0627	女	对啊，之前老师就把那份工作夸得很好，然后我翘掉了，我感觉我下个学期我还不知道该怎么过。
[125.930,130.930]	G0628	女	下个学期，那你们那个老师会会说你吗？
[130.070,142.191]	G0627	女	我我感觉会被针对，他可能都想发个通报批评一下，真的好几个怂恿我走吧，走吧，一起走吧，就只有我真的走了，其他人都不走。
[141.884,142.313]	G0628	女	[LAUGH]
[142.340,144.935]	G0628	女	结果他们都只是说说而已，对吧？
[145.165,145.856]	G0627	女	对啊。
[146.862,147.768]	G0628	女	[LAUGH]
[150.320,163.900]	G0628	女	没事走都走了，而且反正就是你也快要毕业了，其实我觉得，嗯这个也没有，就是也没有必要就是，感觉我觉得也反正也要毕业了嘛其实。

双工对话技术：告别“对讲式”交互



打破传统交互的“轮次”壁垒，让具身智能语音交互回归自然对话本质。双轨并行的技术架构，重新定义物理空间人机沟通方式，为具身智能体带来无延迟、更自然的交互体验。

技术原理：双轨并行分离

基于先进的声纹识别与信号处理算法，系统将用户与具身智能体的语音信号实时分离至独立音频轨道，实现双向信号并行处理与传输，从底层架构突破传统 “半双工” 交互的技术瓶颈。

大规模多语种全双工对话语音数据集

毫秒级响应，消除交互延迟
无需等待播报结束，系统在话音间隙即刻处理指令，响应速度较传统方式提升3倍以上，彻底告别等待焦虑。

随时插话，还原自然交流
支持用户随时打断具身智能体播报并下达新指令，打破传统交互的 “轮次” 限制，完全还原人与人之间自然的对话节奏。

捕捉细微语气，交互更有温度
精准识别犹豫、附和等自然语言现象，让具身智能交互从单纯的 “指令执行” 升级为更具情感的双向交流体验。

License: arXiv.org perpetual non-exclusive license
arXiv:2603.25727v1 [cs.AI] 26 Mar 2026

Back to Basics: Revisiting ASR in the Age of Voice Agents

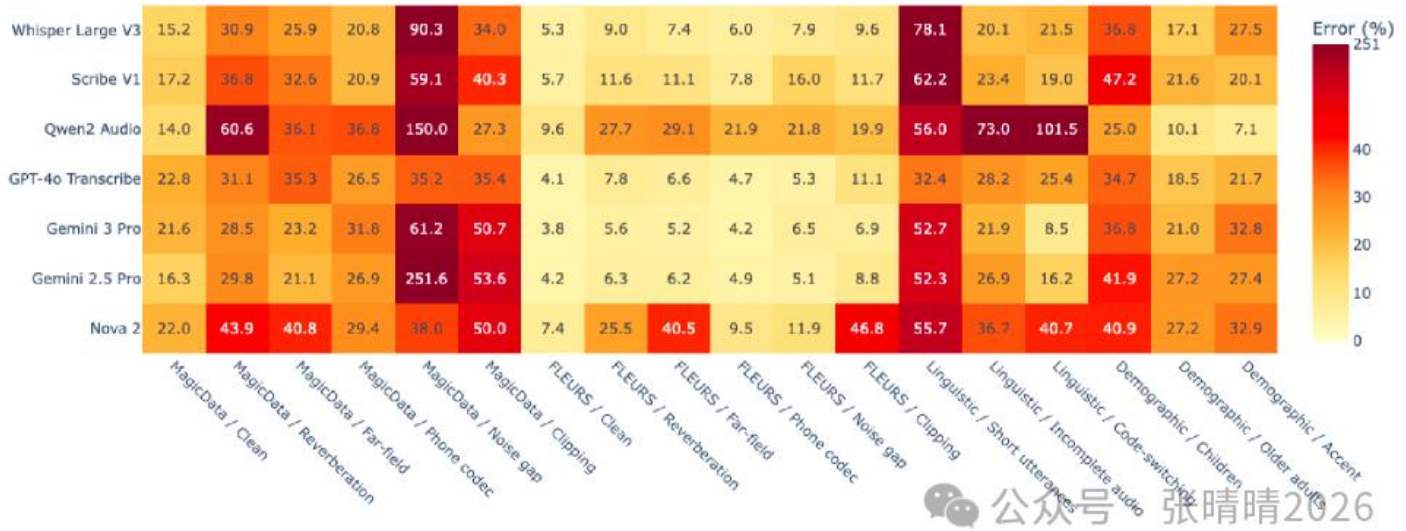
Geeyang Tay †, Wentao Ma †, Jaewon Lee, Yuzhi Tang, Daniel Lee,
Weisu Yin,
Dongming Shen, Silin Meng, Yi Zhu, Mu Li, Alex Smola
Boson AI

Corresponding to: wentao@boson.ai. † Equal contribution.

Abstract

Automatic speech recognition (ASR) systems have achieved near-human accuracy on curated benchmarks, yet still fail in real-world voice agents under conditions that current evaluations do not systematically cover. Without diagnostic tools that isolate specific failure factors, practitioners cannot anticipate which conditions, in which languages, will cause what degree of degradation. We introduce WildASR, a multilingual (four-language) diagnostic benchmark sourced entirely from real human speech that factorizes ASR robustness along three axes: environmental degradation, demographic shift, and linguistic diversity. Evaluating seven widely used ASR systems, we find severe and uneven performance degradation, and model robustness does not transfer across languages or conditions. Critically, models often hallucinate plausible but unspoken content under partial or degraded inputs, creating concrete safety risks for downstream agent behavior. Our results demonstrate that targeted, factor-isolated evaluation is essential for understanding and improving ASR reliability in production systems. Besides the benchmark itself, we also present three analytical tools that practitioners can use to guide deployment decisions.

公众号 · 张晴晴2026



公众号 · 张晴晴2026

WildASR benchmark测试使用Magichub的对话数据集作为真实、自发性人类语音的关键来源，这对于揭示ASR系统在真实世界条件下的真正鲁棒性差距至关重要。

百城方言数据：让 AI 真正听懂中国

30万+ 小时

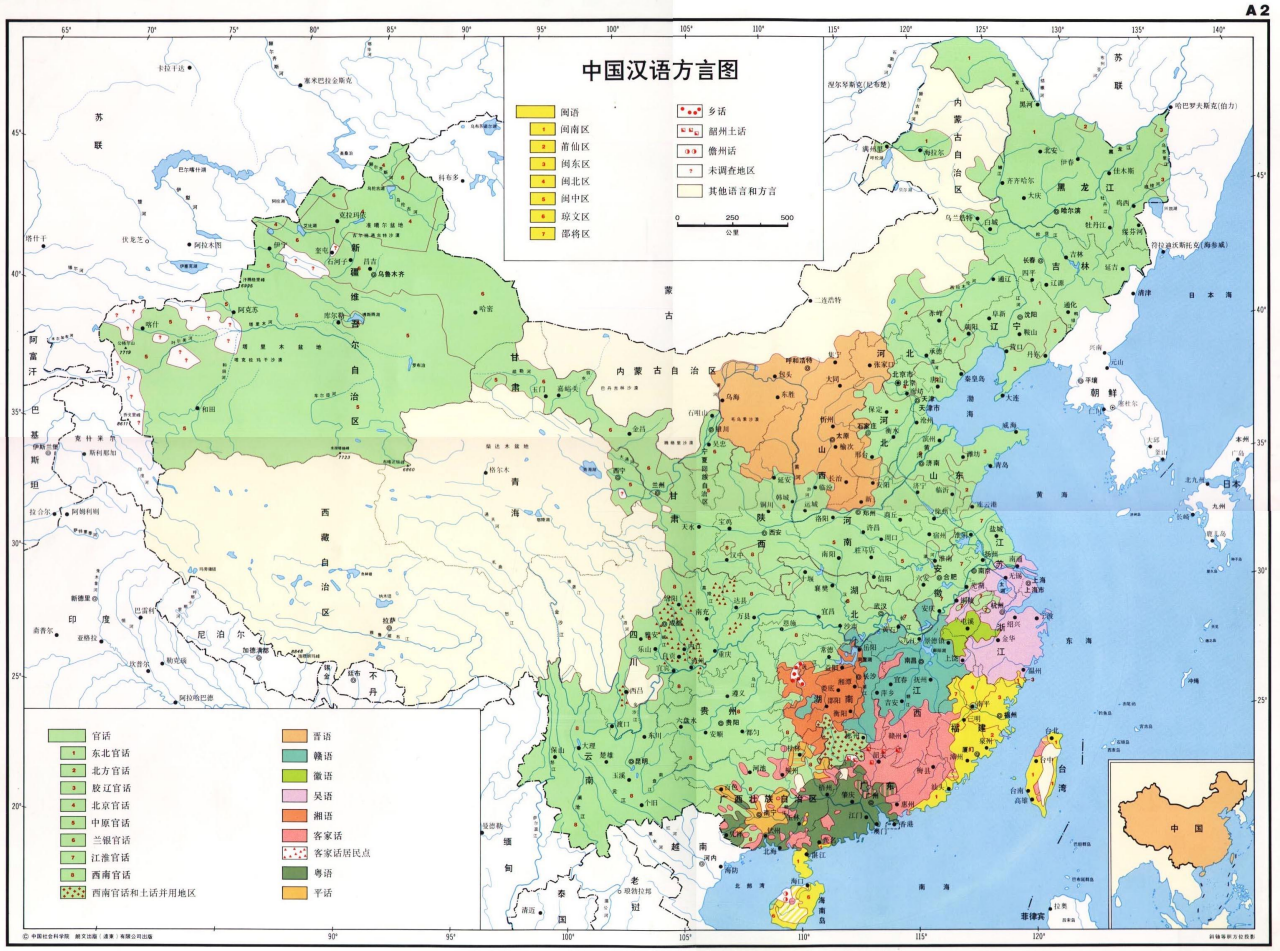
海量方言与口音语音素材，涵盖日常对话、智能设备交互等真实场景，为AI语音模型提供坚实的数据支撑。

30+ 省份 / 300+ 地级城市

深入各语系地域，感受同方言在不同地域的细微差异，深入挖掘不同地域的语言特色与表达习惯。

不仅覆盖北方官话体系，更系统采集晋、吴、湘、赣、粤、闽等南方方言区样本。深入至地级市，如四川话细分为**成都梅花元音、自贡翘舌音、乐山的短促变音**等，构建高密度方言库，让AI真正理解中国语言的多样性。

中国百城多方言语音大模型训练数据



百城方言：从「听见」到「听清」的价值

体验重塑：当AI不再是冰冷的指令执行者，而是能听懂“巴适得板”与“粿条”的贴心伙伴。这种“被听懂”的共鸣，是建立信任与情感连接的关键。

官话 · 通语之基

覆盖京、津、蓉、渝等超级城市，精准捕捉语调细节，筑牢沟通根基。

粤语 · 岭南腔调

精准识别广府发音，吃透倒装句式与市井俚语，还原岭南的鲜活市井气。

湘语 · 泼辣鲜活

覆盖长株潭娄，攻克浊音调值难题，还原湖湘大地的热辣口语与本土俚语。

晋语 · 古韵腔调

深耕太原、呼市等晋地，破解独特声调体系，还原黄土高原的语言韵味。

闽语 · 海丝余音

解码福州、潮汕等分支，攻克复杂韵发规则，听懂闽南闽东的山海对话。

赣语 · 江右古音

扎根南昌抚州，解析古今音变规律，捕捉赣鄱大地的厚重古朴声韵。

吴语 · 侬语软韵

覆盖沪苏杭温，还原吴侬软语的柔美韵律，读懂江南水乡的细腻语境。

客家 · 古音留存

深耕梅州赣州，吃透古汉语底层音韵，识别多县口音与特色古语词汇。

平话 · 百越交融

聚焦桂南桂北，区分两套发音体系，破译百越文化交融的独特声调密码。

Voice Agent 多意图数据集：从「听懂」到「理解」

动态交互是具身智能最高频任务场景，面临口音多变、环境噪声、表达口语化、意图模糊等复杂挑战。
行业共识：具身智能语音交互的系统增益，核心驱动力来自高质量真实场景数据，而非单纯的算法迭代。

Voice Agent 多意图数据集

真实自然口语表达

摒弃僵硬的指令式话术，还原真实动态场景下的自然对话，包含停顿、重复、改口等非标准表达，让具身智能交互更贴近人与人之间的自然沟通。

多口音与方言覆盖

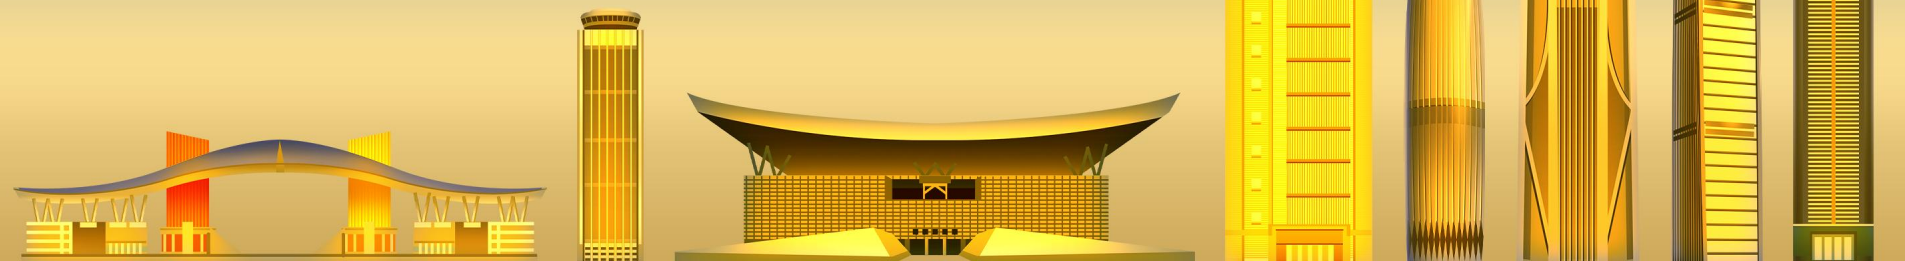
系统性覆盖全国主要方言区及口音变体，突破地域语音交互识别瓶颈，让具身智能体真正听懂每一种地道的 “中国声音”，消除地域使用障碍。

全链路场景覆盖

从任务发起、临时目标变更，到实时环境问询、周边目标检索，完整覆盖具身交互全流程，精准满足用户多样化交互与动态决策需求。


EMBODIED INTELLIGENCE
REAL SCENARIOS
REAL VOICES
BETTER AI
面向具身智能的Voice Agent训练数据集
覆盖真实日常场景 打造更懂你的语音助手
目标检索
实体位置 / 空间地标 / 家居设备
任务调整
路径改向 / 任务重规划 / 多方案比对
状态问询
实时环境 / 异常原因 / 时间预估
资源检索
空间设施 / 服务资源 / 设备查询
10,000+
小时
高质量语音数据
全场景覆盖
城市 / 高速 / 地下车库 / 居家室内
多口音方言
普通话 / 粤语 / 四川话 / 东北话等
自然语义表达
口语化 / 打断 / 插话 / 多轮对话
质量严控
严格质量检测
海量真实数据
多维标签体系
训练更充分
效果更智能
泛化能力更强
体验更自然

晴数智慧
面向具身智能的数据合作伙伴



关于晴数智慧：您值得信赖的数据合作伙伴

01 具身智能 AI 数据解决方案专家

专注为具身智能客户提供高质量、合规、场景化的数据解决方案。从多源数据采集、精细化标注到安全合规治理，我们构建全链路数据能力，助力打造更懂用户的智能体交互体验。

02 共建开放共赢的智能生态

携手全球科技巨头与行业领军者，打破技术与场景的边界。通过深度协同与资源互补，共同推动具身智能的技术革新，重新定义未来人机交互与智能空间交互方式。

生态协同 · 携手行业领军者共创未来

NVIDIA

QUALCOMM®

Microsoft

高德地图 amap.com

cerence™

科大讯飞 iFLYTEK

我们的核心能力

01 场景化数据能力

深度适配物理动态环境，提供覆盖室内服务、人机对话、多音区交互及复杂环境噪声场景的一站式数据解决方案，精准匹配具身智能体在真实物理空间的落地测试需求。

02 全球化语言与方言覆盖

拥有覆盖全球60余种语言及中国百城方言的海量数据积累，打破地域与沟通壁垒，助力具身智能企业高效开拓海外市场与广阔的国内下沉市场。

03 国际标准合规与安全

严格遵循ISO/IEC 27001、27701等国际权威安全与隐私保护标准，全链路确保数据来源合法、采集合规、使用安全，为业务发展筑牢安全防线。

04 灵活多元的合作模式

提供高质量开源数据集用于模型验证，标准化OTS数据集支持快速商用部署，更可提供从数据采集、清洗标注到模型优化的全流程定制化服务，满足多样化需求。

我们的资质



CMMI-3 软件能力成熟度认证

获得全球公认的软件能力成熟度三级认证，标志着我们在软件开发、项目管理与服务交付全流程具备国际标准的高质量管控能力，为项目稳定落地提供坚实保障。



北京市“专精特新”小巨人企业

入选北京市“专精特新”小巨人企业名单，充分体现了我们在核心技术创新、细分市场占有率及专业化配套能力方面的领先优势与行业认可度。



CCF 中国计算机学会会员单位

彰显了我们在计算机科学领域的专业积淀与技术影响力，持续与行业前沿技术同频共振，共建技术生态。承办 CCF IVC 2026 智能导航方言语音识别挑战赛并圆满收官，赋能方言语音技术创新。

权威资质加持，构筑技术与服务的双重壁垒，为客户创造可持续的价值与保障。

GOSIM 晴数智慧

GOSIM Shenzhen 2026

Thanks!

公司官网

Magichub.com

晴数智慧