GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



GOSIM

GOSIM Shenzhen 2026

面向开源模型的 AI-Ready 数据生产与闭环优化

强美伊 | 北京大学 DCAI Lab 硕士、创业者



CONTENTS

Part 01 统一数据底座：从原始数据到可复用资产

Part 02 领域数据生产：从静态知识到可验证任务

Part 03 数据与模型协同：动态训练与评估闭环

Part 04 Agentic Execution：从自然语言到可执行数据工作流



01

统一数据底座：从原始数据到可复用资产



范式迁移：AI竞争从模型规模转向数据与执行系统

大模型能力继续提升，但瓶颈正在从 “更大的模型” 转向 “更好的数据生产、训练调度与评估反馈系统”。

过去： Model-Centric Competition

- **模型结构** — 架构创新与升级
- **参数规模** — 更大参数量
- **算力训练** — 更多算力投入

竞争焦点迁移

现在： Data-Infra Competition

- **数据规模** — 持续扩展
- **数据质量** — 高质量、可控
- **数据多样性** — 多源异构融合
- **训练调度** — 选择、混合、加权
- **评估反馈** — 闭环与回流

为什么竞争焦点在迁移?

1 数据规模持续增长

预训练、微调、RAG、Agent 训练都需要持续扩展的数据供给，人工清洗难以跟上。

量级提升 | 持续增长 | 人工不可扩展

2 数据形态更加复杂

PDF、网页、表格、代码、多模态、交互轨迹并存，传统脚本难以统一治理。

多源异构 | 格式多样 | 治理复杂

3 训练效率取决于数据策略

选择哪些样本、如何混合、如何加权，会直接影响收敛速度、算力成本和模型上限。

样本选择 | 数据混合 | 加权策略 | 成本与上限

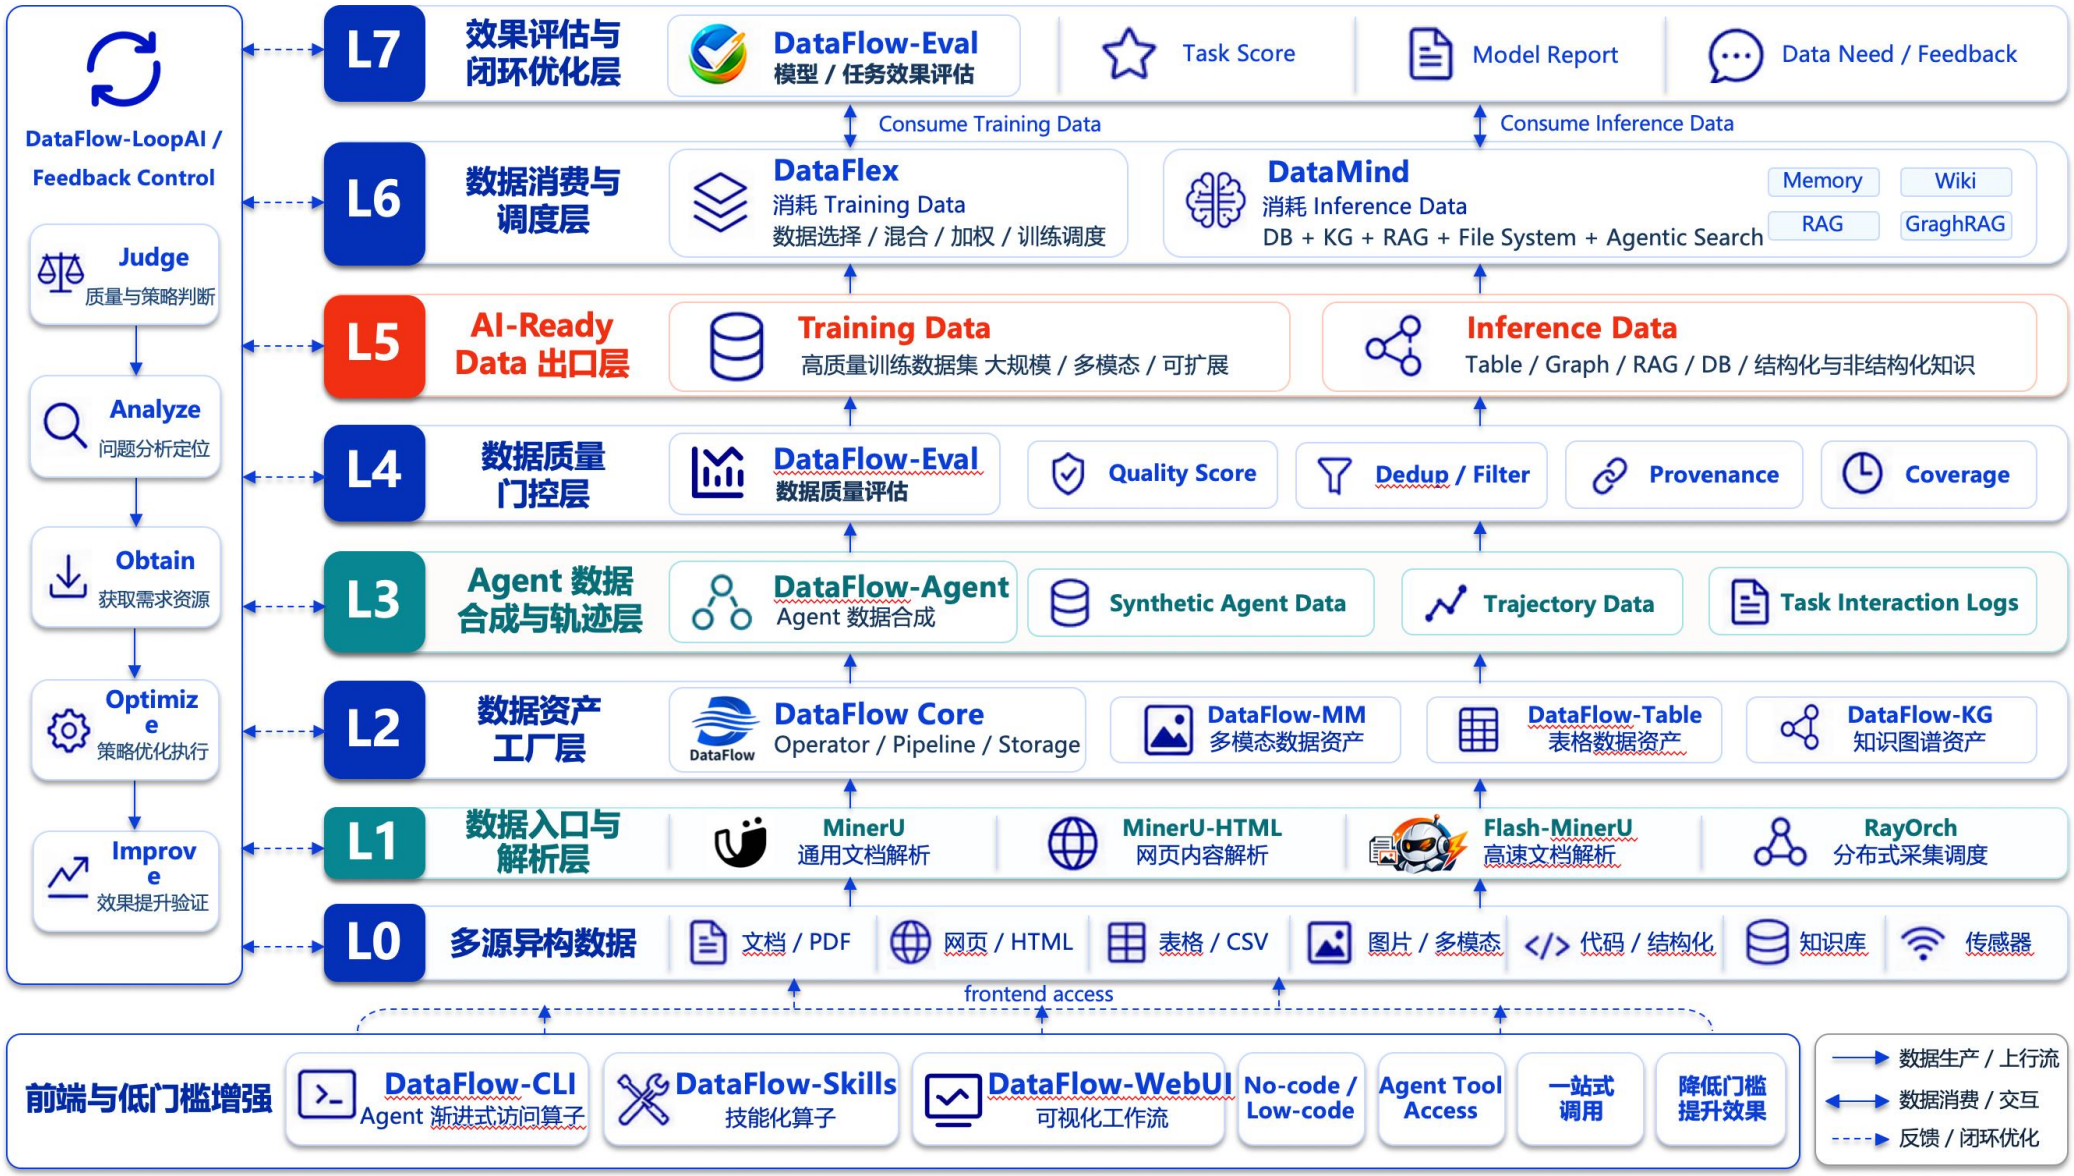
4 评估必须回流数据生产

模型失败样本、任务得分、错误类型，需要转化为下一轮可执行的数据需求。

失败样本 | 任务得分 | 错误类型 | 数据需求

谁能更快生产、治理、评估并复用高质量数据，谁就能更快迭代模型。

DataFlow 自进化数据基础设施与生态：L0–L7 总体架构



从原始数据到AI-Ready资产：解析、结构化、可追溯

L0 原始数据问题

1. 格式散乱
多种文件与编码混存，格式不统一，无法直接消费或训练。

典型示例
- PDF 扫描件/图片 PDF
- HTML 网页/动态页面
- DOC / PPT / TXT 多版本
- CSV / XLS 字段不一

2. 噪声与重复
包含大量广告、导航、版权页、页眉页脚、水印、重复内容与低质量文本。

典型示例
- HTML 导航/广告 /推荐
- 页眉页脚/页码/水印
- 重复段落/镜像站点内容
- OCR 噪声/ 组字/换行杂乱

3. 版面结构复杂
多栏排版、表格、公式、图片、脚注、 动框、跨页元素导致语义割裂，难以抽取。

典型示例
- 图片/ 表格/ 公式混排
- 多栏/跨栏/跨页表格
- 脚注/批注/浮动文本
- 目录/层级标题嵌套重复

4. 元数据缺失
缺少主题、版次、语种等关键信息关键信息，无法支撑检索与治理。

典型示例
- 缺少标题/摘要/作者
- 缺少创建时间/更改时间
- 缺少类别/标签
- 缺少文类型/版本信息

5. 来源/权限不清
来源分散，所有者与授权不明，合规风险高，难以追溯与复现。

典型示例
- 日志 / API / DB / 文件分散
- 缺少来源站点 /抓取时间
- 缺少许可/权限/协议
- 缺少变更记录/版本链

L1入口解析

- **抽取** 内容提取 去噪清洗
- **结构化** 识别版面 重建层级
- **标准化** 统一格式 规范字段
- **元数据** 补全属性 分类标注
- **可追溯** 来源链与 版本记录

价值转变
从“文件 / 网页集合”
到“可计算、可检索、可评估、可复用”
的结构化数据资产

L1 解析后的中间产物

1. Markdown / JSON
纯文本语义内容，保留层级结构，适合训练、检索与分析。

示例
- Markdown：标/段落/列表/引用
- JSON：结构化节点与关系
- 段落级唯一 ID
- 语义清晰、可切片、可紫引

2. 表格结构
表格识别并转为结构化数据，统一字段、类型与对齐方式。

示例
- 表头识别与合并
- 单元格对齐与合并
- 数据类型识别与标准化
- CSV / Parquet / JSON 表结构

3. 图片/公式/版面元素
抽取并分类各类非文本元素，保留坐标、顺序与引用关系。

示例
- 限片：PNG/JPG +位置坐标
- 公式：LaTeX/MathML
- 元素类型：图表/代码 / 框注等
- 与正文双向引用与编号

4. 文档元数据
补全文档属性与业务标签，支持检索、过滤与治理。

示例
- 标题/作者/ 机构 / 日期 /语种
- 领域/标签/关键词
- 文档类型/版次/语言
- 文件大小/页效/编码

5. 可追溯来源链
记录来源、抓取、处理与版本链路，保证合规与可复现。

示例
- 来源 URL / 站点/采集时间
- 处理流水线/解析版本
- 操作入/审核状态/许可协议
- 变更记录/版本链/哈希校验

典型工具映射

MinerU 文档解析
- 支持 PDF / Office / 扫描件
- 分析/OCR / 表格 / 公式 / 图片
- 输出 Markdown / JSON / 结构化

MinerU-HTML 网页解析
- 去噪/ 主体内容提取
- 导航/广告/评论区识别过滤
- 输出结构化文本与元数据

Flash-MinerU 高速解析
- 多线程/流式解析
- 大批显文件并发处理
- 高吞吐低延迟

RayOrch 分布式调度
- 分布式任务 排与资源调度
- 弹性伸缩/断点续传
- 监控/告警 /成本优化

L1 的价值：把不可直接消费的原始数据，变成可进入资产工厂的结构化原料。

AI 数据入口：解析、加速与调度的统一底座

1 MinerU：通用文档解析

输入 PDF / 图片 / 扫描件 / 复杂版面（多栏 / 混排 / 表格 / 公式）

输出 Markdown / JSON / 表格 / 公式 / 图片元素

价值 高质量文字与结构抽取能力，作为训练数据入口、知识库构建、RAG 语料

能力特色

- 版面检测与区域划分
- 表格 / 公式结构识别
- 公式 LaTeX 还原
- OCR 高精度文字识别
- 多语言支持
- 可扩展模板与规则

2 MinerU-HTML：网页主内容解析

输入 HTML / Common Crawl / 论坛 / 问答 / 长文页面

输出 结构化 JSON → Markdown（纯净主内容）

价值 去除导航、广告、推荐、模板等噪声，提升网页语料质量与可用性

能力特色

- 主内容抽取（正文为主）
- 广告 / 导航 / 脚本过滤
- 阅读顺序重建
- 链接与媒体资源处理
- 高召回 + 高精度

3 Flash-MinerU：高速文档解析

输入 大批量 PDF / 扫描件 / 图片文档

核心能力 VLM 并行推理 / 多卡加速 / 批处理流水线

价值 显著降低解析耗时与成本，支撑海量文档的快速入库与清洗

能力特色

- 多卡 / 多节点并行
- 批量调度与队列管理
- 流水线式处理
- 自动负载均衡
- 与 MinerU 兼容输出

4 RayOrch：分布式采集调度

输入 多环境 / 多模型 / 多模态任务（解析 / 下载 / 转换 / 抽取）

核心能力 Ray 集群调度 / DAG 流水线 / 任务编排 / 存储与通信优化。

价值 scale-up 数据治理流水线，实现大规模、稳定、可观测的解析与采集

能力特色

- DAG / 环图任务编排
- 高并发与容错重试
- 数据分片与结果合并
- 多源存储接入
- 监控 / 指标 / 日志体系

L0 多源数据 → L1 解析与调度（本层） → L2 数据资产工厂

L0 多源数据：文档/PDF · 网页/HTML · 表格/CSV · 图片/多模态 · 代码/结构化 · 知识库 · 传感器/交互

L1 解析与调度（本层）：MinerU · MinerU-HTML · Flash-MinerU · RayOrch

L2 数据资产工厂：清洗去重 · 标准化 · 结构化资产 · 元数据管理 · 质量评估

结论：L1 不是单点 OCR，而是可扩展的数据入口基础设施。

统一入口 · 高质量抽取 · 高性能处理 · 可扩展调度

L2 数据资产工厂：从一次性产物到可复用资产

L1 结构化原料

解析后的结构化文档、表格、图像、日志等标准化中间产物

L2 数据资产工厂：三类资产车间

1 DataFlow Core

清洗治理 / 标准化 / 质量规则

2 多模态与表格

图片视频 / 表格数据 / 统一标注

3 知识与科学数据

KG 构建 / 科学实验 / 评测集

解析 → 清洗 → 标注 → 资产沉淀

L3 / L4 消费层

Agent 数据合成 / 筛选

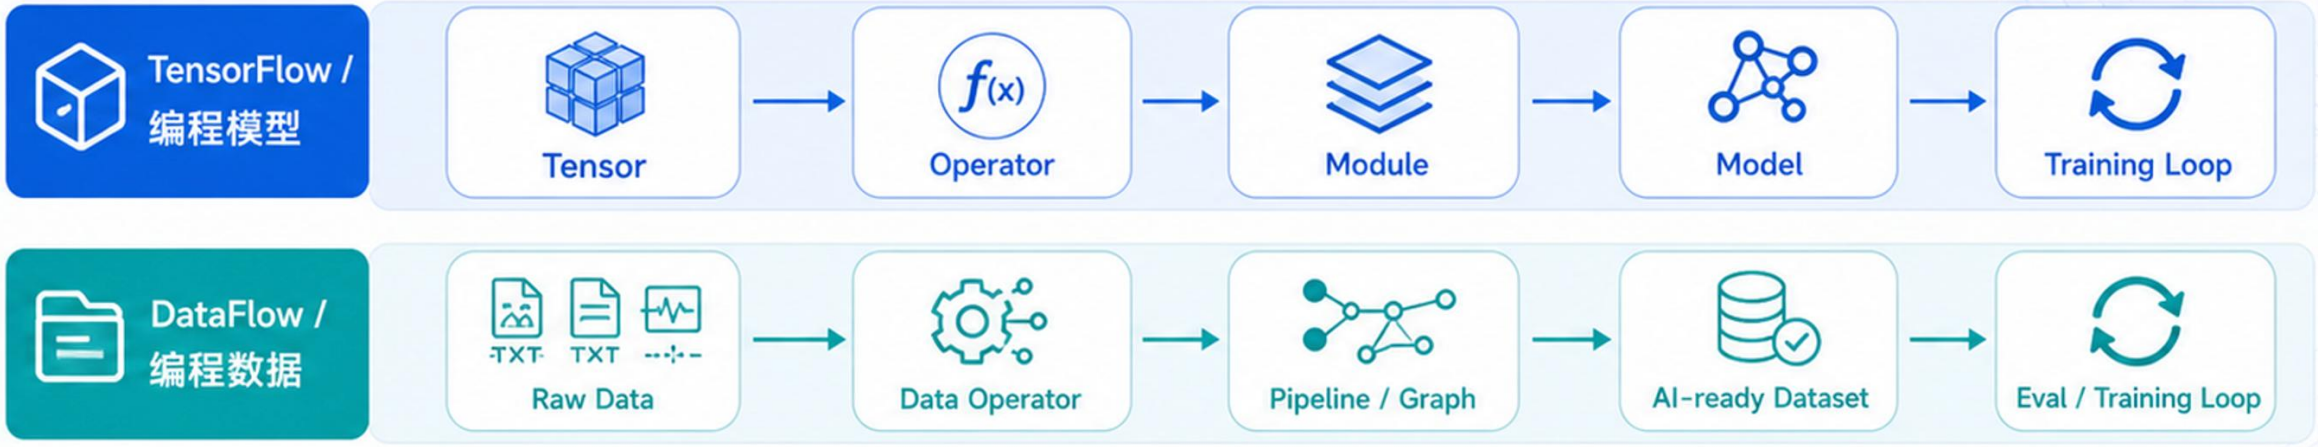
质量门控 / 评估门控

AI-Ready 数据出口

L2 的价值：让数据从一次性脚本产物，变成可复用、可组合、可评估的数据资产。

DataFlow 核心抽象：像编程模型一样编程数据

TensorFlow 将张量与算子组合成模型；DataFlow 将原始数据与数据算子组合成可训练、可评估、可回流的数据资产。



像 TensorFlow 编程模型一样编程数据

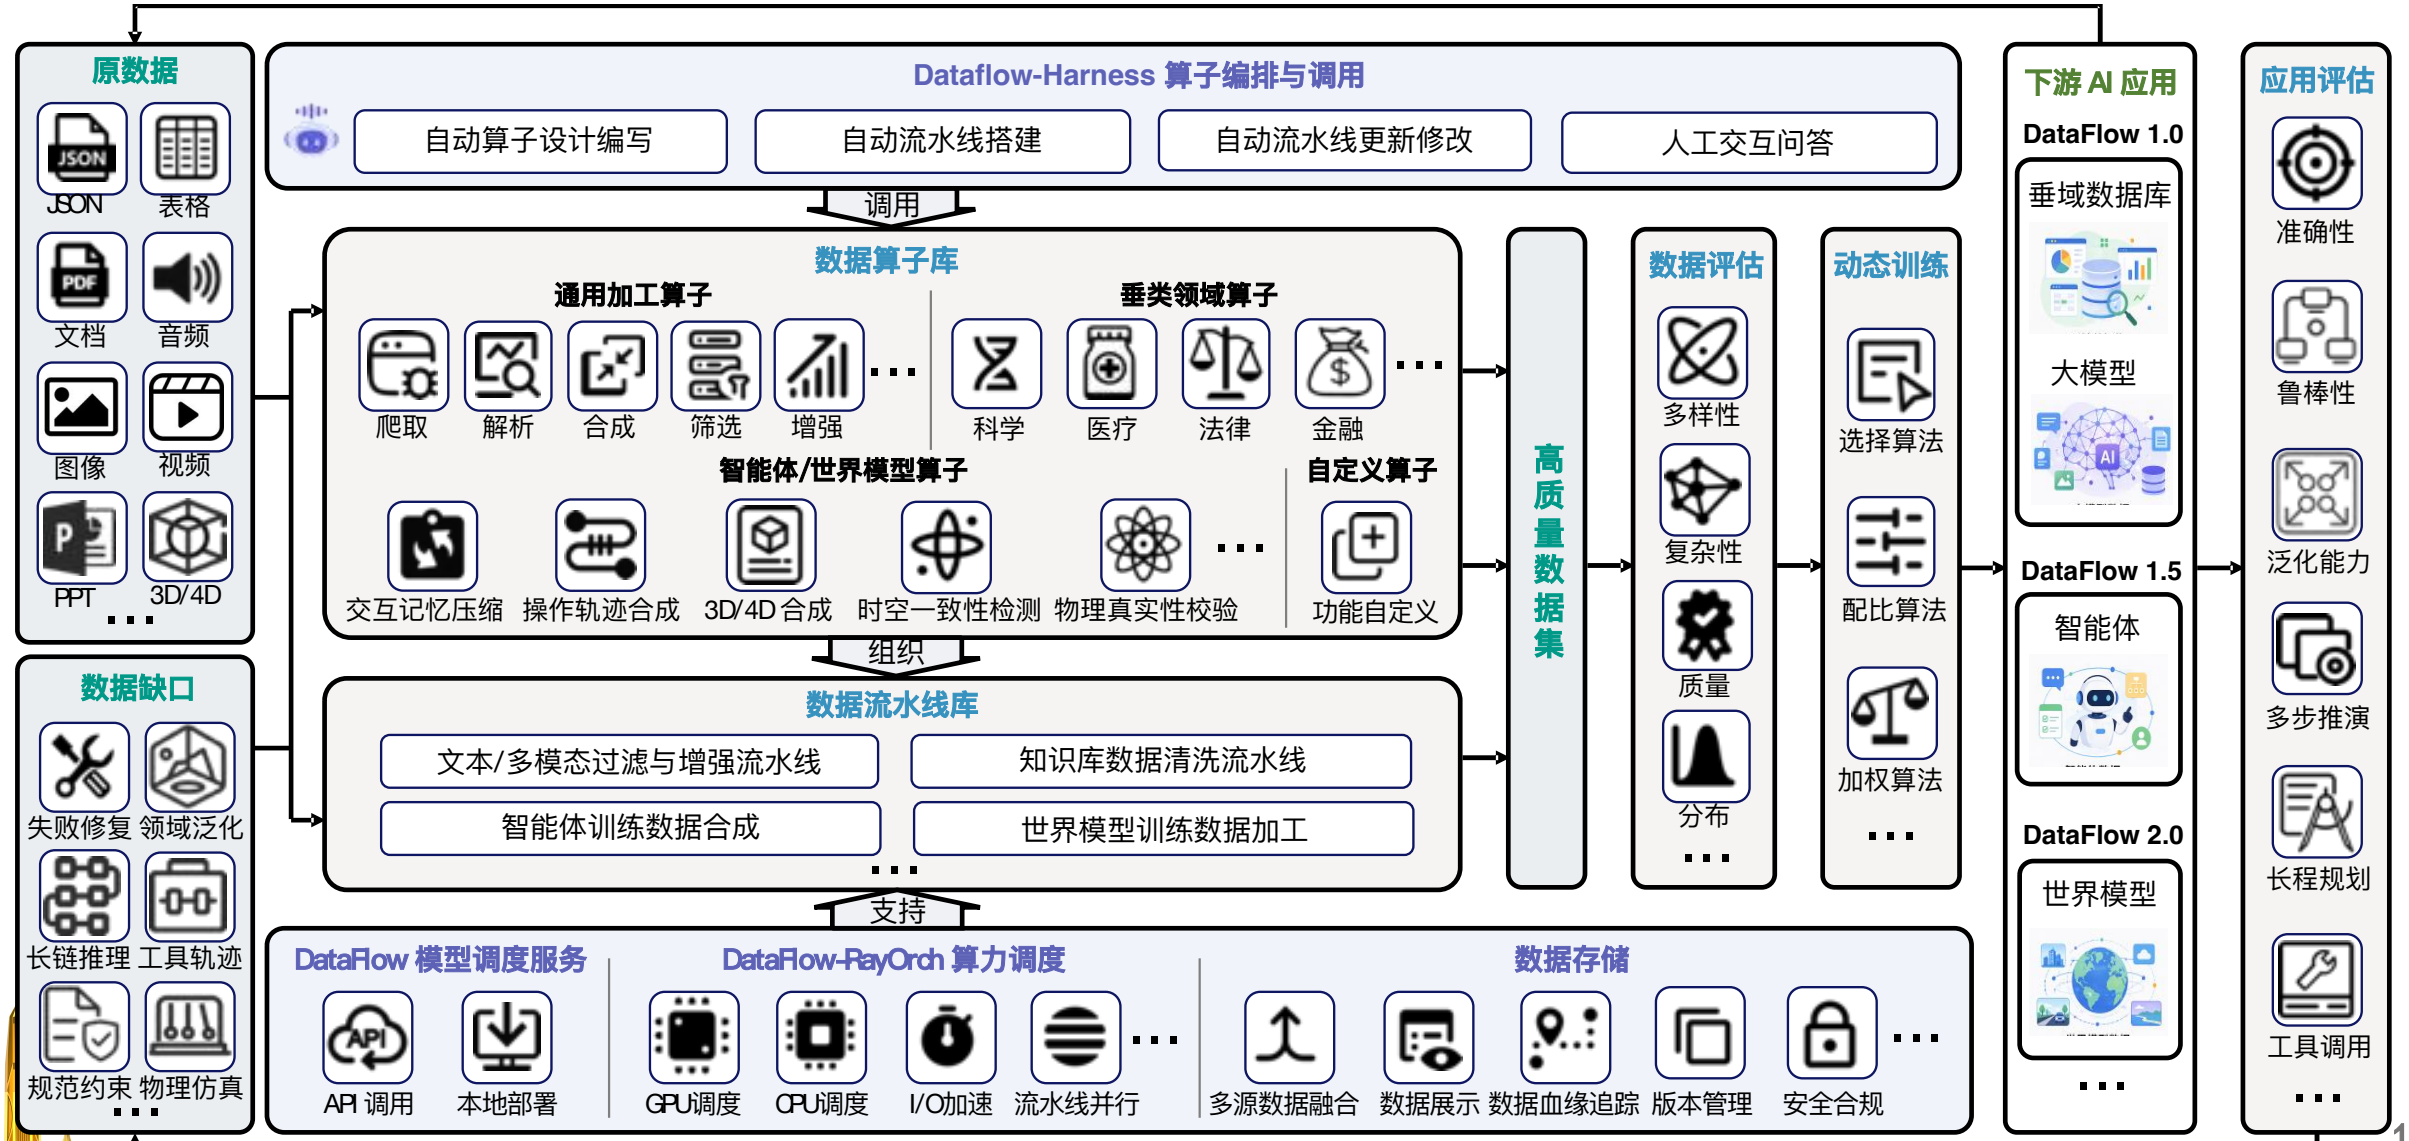
	TensorFlow（编程模型）	DataFlow（编程数据）
编程对象	模型参数与计算图	数据资产与生命周期
基本单元	算子 / 层 / 模块	数据算子 / Prompt / Pipeline
组合方式	计算图 / 模型结构	数据流图 / 治理流水线
交付结果	可训练模型	AI-ready 数据资产
反馈闭环	Loss 更新模型	Eval 更新数据与管线

DataFlow：200+ 通用处理算子，覆盖文本、表格、图像、视频、音频与知识图谱

https://github.com/OpenDCAI/DataFlow



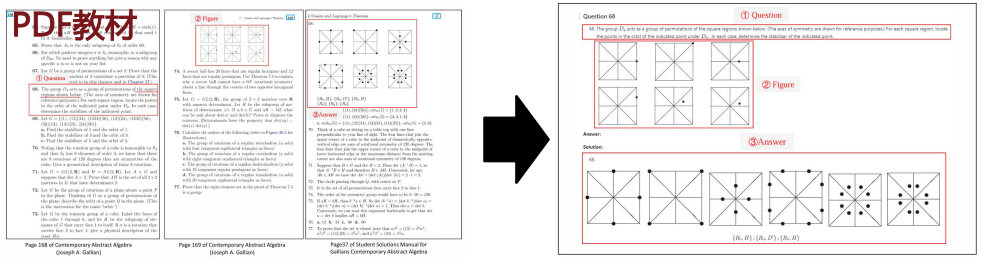
DataFlow 系统设计：算子、流水线、调度与反馈



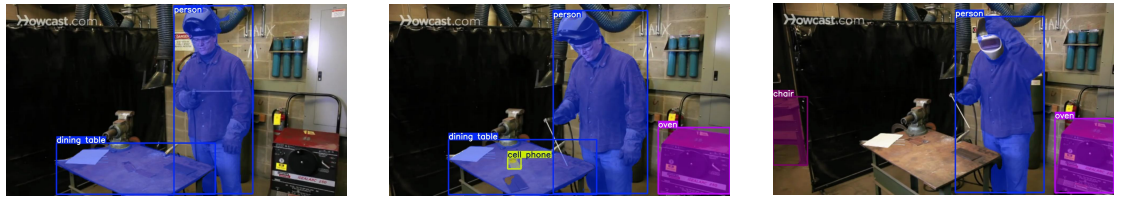
行业落地：三层金字塔架构

- 行业应用： ✔
  领域数据集/数据处理
  垂类大模型/智能体训练
- 流水线（算子组合）： ✔
  数据加工处理流水线
  智能体数据合成流水线
- 基础算子： ✔
  通用数据处理算子
  领域专用算子
  智能体训练算子





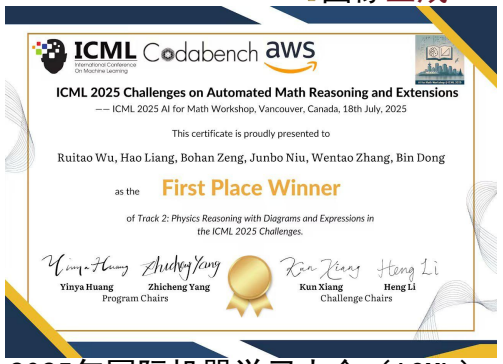
多模态文档提取视觉问答（VQA）数据



视频关键影像提取与语义描述



图像生成



2025年国际机器学习大会（ICML）多模态物理推理挑战赛—— 冠军



2025 智源“语言与智能”技术竞赛 —— 冠军

02

领域数据生产：从静态知识到可验证任务



Agent数据层：静态资产如何变成任务轨迹

L2 数据资产 → 任务定义 → Agent 执行 → 轨迹采集 → 合成增强 → L4 质量门控

AgentFlow

数据合成与统一框架

- 统一任务结构
- 多 Agent 协同
- 环境反馈闭环

Task Definition

把静态资产变成任务

- 任务模板
- 约束条件
- 成功标准

Trajectory Data

记录可回放执行过程

- Action
- Observation
- Outcome

Interaction Logs

日志转成反馈信号

- 工具调用日志
- 用户反馈
- 环境事件

L3 输出给下游什么？

- SFT / RL 训练轨迹
- 工具使用行为数据
- 任务环境轨迹
- 评估回放数据

L3 核心数据闭环

任务 → 执行 → 轨迹 → 反馈

L3 的价值：把静态语料扩展为可训练、可评估、可回放的任务过程。

可执行 | 可回放 | 可评估 | 可复用

Coding Pipeline：可执行工程任务的数据生产与验证

01 场景定义
能力目标、约束条件
难度与验收口径

→

02 任务构造
Instruction、初始状态
参考解与候选测试

→

03 环境准备
Repository / Container
依赖、工具与资源限制

→

04 自动执行
Agent 求解任务
记录 Action 与 Observation

→

05 验证修复
运行测试与防作弊检查
失败任务自动修正复验

→

06 产出资产
任务、环境、测试、轨迹
评分与元数据版本化入库

统一任务结构适配三类工程场景

场景	输入与环境	任务行为	自动验证
SWE	Repository、Issue、依赖与构建环境	跨文件修改、缺陷修复与功能实现	Unit / Integration Tests
Infra	配置、日志、服务与资源状态	故障定位、配置修复与服务恢复	Health / Constraint Check
Terminal	操作目标、文件系统与工具集合	命令、脚本和文件系统操作	输出、状态与副作用检查

最终交付：可复现任务包

Instruction + Constraints
Repository / Starter State
Sandbox / Container / Tools
Tests + Hidden Checks
Reference Solution
Trajectory + Score + Metadata

四级质量门控

① 可解：存在有效完成路径
② 可判：测试区分正确和错误
③ 稳健：不存在明显投机路径
④ 可复现：重复执行结果稳定

未通过任务返回第 05 步

规模供给
日产 100+ 任务

场景扩展
Prompt 配置接入新任务

训练难度测量
7 个前沿模型 · 1,184 次有效评分

资产沉淀
成功与失败轨迹均入库

最终产出包含任务定义、执行环境、自动测试和完整轨迹，可直接用于模型训练、评估与失败分析。

DataFlow-Lean：可验证数学数据的双资产生产

01 语料采集
教材 / 论文 / 题库
保留章节、引用、版本与出处

02 命题单元化
拆分定义、定理和证明
明确变量、假设与结论

03 检索底座
构建定理依赖图与向量索引
支持定义和引理召回

04 形式化生成
生成 Lean theorem 与 proof
同步记录检索上下文

05 编译修复循环
根据 Proof State 与错误信息
重新检索并修改证明

06 内核验证入库
Kernel 验证通过后
轨迹与知识分别入库

单个命题的形式化执行循环

命题单元

自然语言命题
变量、假设与结论
数学符号和上下文
原文、章节与出处

① Retriever 召回 Mathlib 定义与引理

② Generator 生成 Lean 命题与候选证明

③ Repair Agent 根据编译反馈修改证明

记录检索上下文、候选证明、错误类型与修复动作

Lean 执行环境

Parser 与类型检查
Proof State / Goals
错误类型与代码位置
Kernel 对最终证明进行验证

产出 A NL2Lean 过程数据
Prompt / Retrieval Context
Candidate Proof / Proof State
Compiler Feedback / Error Type
Repair Action / Success State
用途：训练生成、工具调用与错误修复

产出 B 已验证 Lean 知识库
Theorem / Proof / Dependencies
Natural Language Alignment / Source
Kernel Status / Version / Metadata
用途：供数学 Agent 检索、组合与验证

Hoeffding 示例

自然语言命题
独立、中心化的子高斯变量
$P(\Sigma X_i \geqslant \varepsilon) \leqslant \exp(-\varepsilon^2 / 2C)$

检索依赖
iIndepFun · HasSubgaussianMGF
有限和与尾概率界

Lean 定理映射
条件、类型、依赖与证明项对齐

Kernel Verified ✓

过程轨迹用于训练生成与修复能力；验证后的定理库支持数学 Agent 检索、复用和组合证明。

DataFlow Eval：领域数据的统一质量门控

输入 / Storage

- 数据源
- 样本
- 答案
- 任务

DataFlow Eval Operator Map

1 Benchmark / Answer
match | judge | answer key

2 General Text
similarity | diversity | safety

3 Pre-training Text
perplexity | dedup | quality

4 SFT / Instruction
format | coverage | consistency

5 Reasoning / Code
solve | tests | complexity

6 Domain Tasks
RAG | agents | scientific

输出 / Gate Results

- eval_score
- eval_valid
- result.json
- feedback

L3/L2 数据资产
结构化数据资产 / 多模态数据资产

→ **Eval 打分**
由 Operator Map 产出分数、有效性与错误信号

→ **阈值过滤 / 分层采样**
按评分阈值过滤，按得分分层采样

→ **L5 AI-Ready Data**
高质量训练数据 / 推理数据 / 评估数据

L4 的价值：把数据质量从人工经验，变成可执行、可审计、可组合的评估门控。

03

数据与模型协同：动态训练与评估闭环



统一数据出口：Training / Inference Data

L5 AI-Ready Data 出口层

Training Data
高质量训练数据
大规模 / 多模态 / 可扩展

Inference Data
Table / Graph / RAG / DB /
结构化与非结构化知识

消费 Training Data

DataFlex 消费 Training Data

输入	训练数据集	数据混合	重加权	调度
能力	更低成本	更快收敛		
输出	样本权重	领域配比与训练调度策略		
回流	Loss 与样本表现回流			

消费 Inference Data

DataMind 消费 Inference Data

输入	Profile	Wiki	RAG	GraphRAG
能力	任务上下文			
输出	企业 AI Harness	知识与记忆服务		
回流	检索失败与效果反馈			

训练优化 VS 推理上下文

	成本	收敛	相关性	可追溯 / 复用
训练优化（DataFlex）	更低训练成本	更快收敛速度	更高样本质量与多样性	训练过程可追溯
推理上下文（DataMind）	更低检索与推理成本	更高命中率与相关性	知识来源可溯源	知识与记忆可复用

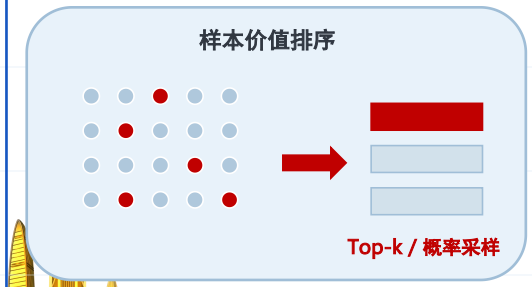
L6 的价值：让数据资产从存储层进入训练与推理的真实闭环。 资产驱动 | 双向回流 | 效果可度量 | 复用可扩展

DataFlex：以模型状态反馈调度训练数据

面向大模型预训练、微调及持续演进过程中的数据治理需求，核心研究内容聚焦为 Data Select、Data Reweight 与 Data Mix：以模型状态反馈为信号，动态决定“选哪些样本、给多大权重、按什么领域比例训练”，形成数据在环的动态训练闭环。

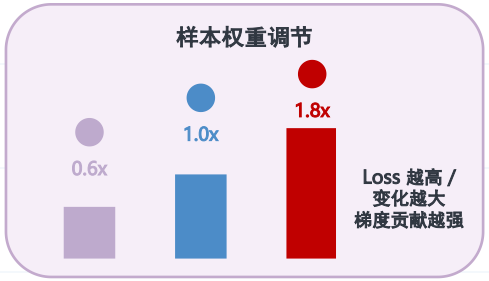
Select：动态样本选择

- **Data Select**：动态评估样本对当前目标的效用。
- **研究重点**：以梯度相似性、Loss / Delta Loss、验证反馈和分布覆盖为评分信号，形成候选排序、Top-k选择与周期更新机制。



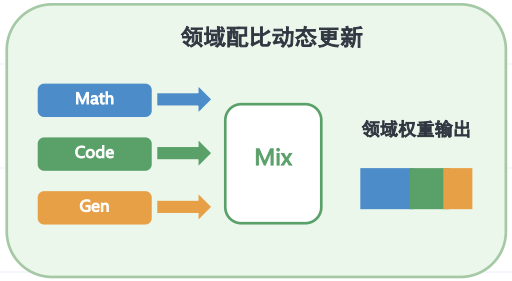
Reweight：样本重加权

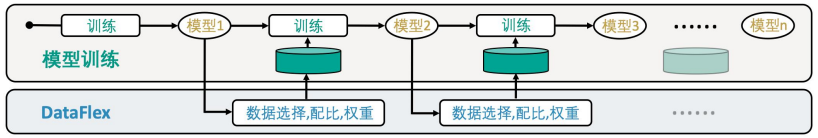
- **Data Reweight**：在不改变样本进入批次的前提下，调节样本反向传播权重。
- **研究重点**：基于 per-sample Loss、Loss变化、梯度/对齐信号构建权重函数，使困难样本、高收益样本对梯度贡献更大。



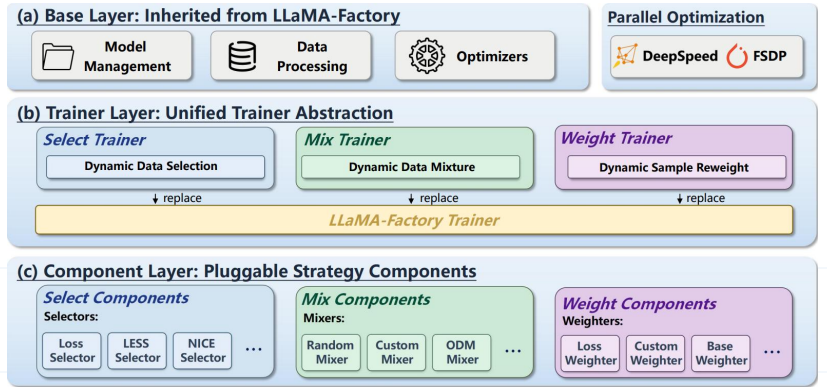
Mix：动态领域配比

- **Data Mix**：面向数学、代码、通用知识、行业语料等多域数据，动态决定训练配比。
- **研究重点**：结合代理模型/验证集过剩损失、在线 Loss 反馈等，随训练阶段输出领域权重。

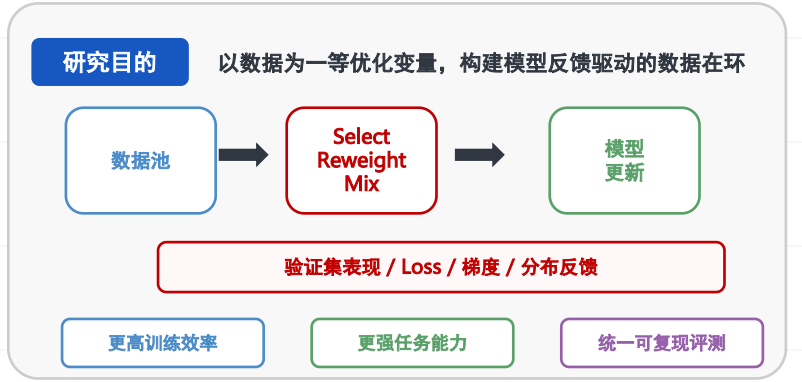




数据-模型训练信号反馈机制



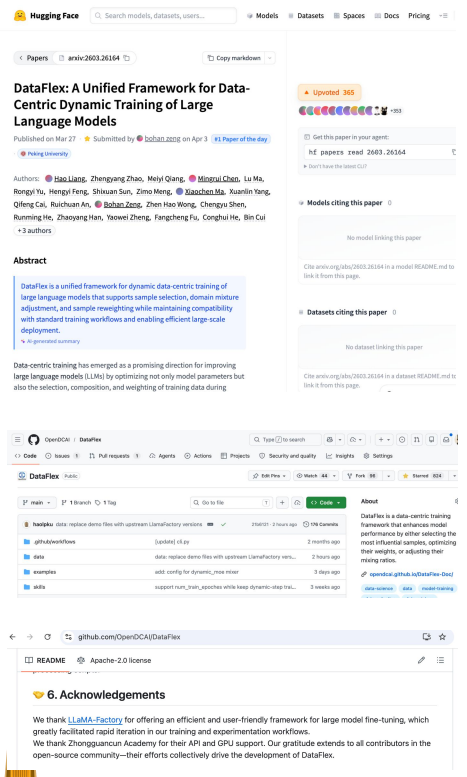
选择/混合/重加权算法层级设计



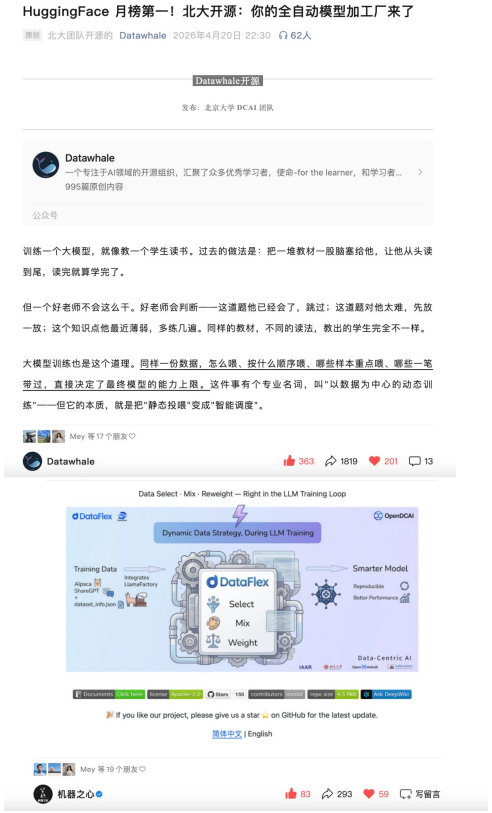
DataFlex生态：训练数据优化闭环的社区基础

围绕 DataFlex 构建数据驱动动态训练核心框架，获得开源社区、前沿研究者与论文传播认可，并与 DataFlow、LLaMA-Factory 深度协同，初步形成训练数据优化开源生态。

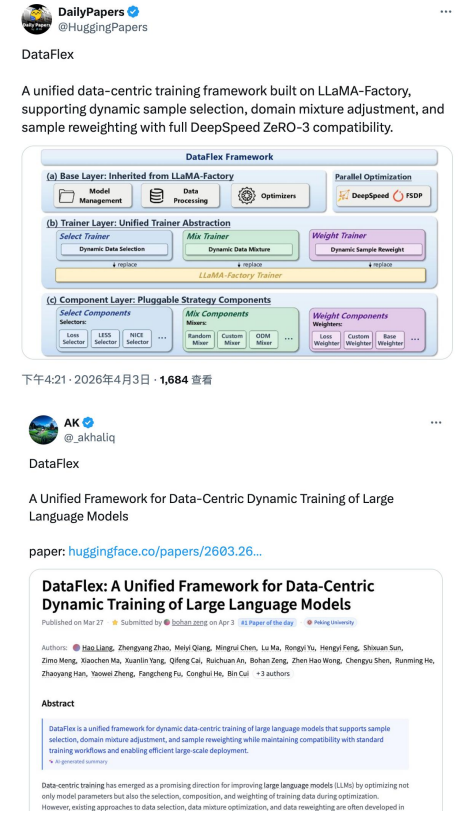
开源生态基础



前沿社区推荐

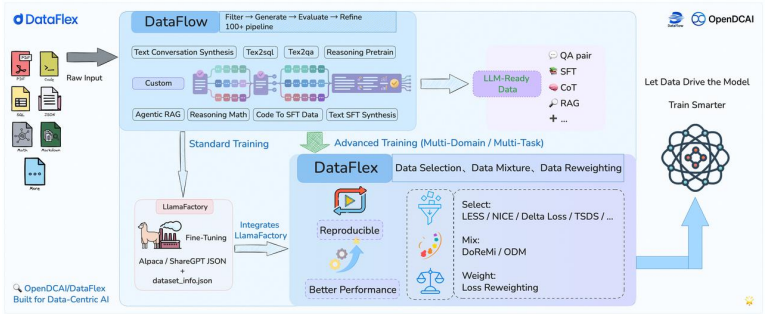


论文与国际研究者讨论



序号	论文名称	社区影响力 github stars
1	DataFlex: A Unified Framework for Data-Centric Dynamic Training of Large Language Models	3.0K
2	DataFlow: An LLM-Driven Framework for Unified Data Preparation and Workflow Automation in the Era of Data-Centric AI	8.2K

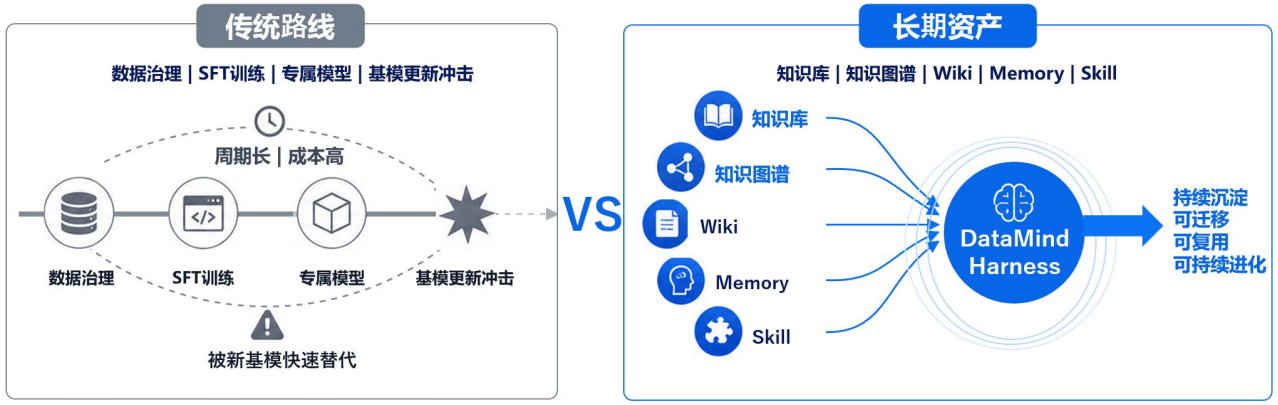
- 多项研究成果进入国际前沿社区，形成数据驱动训练关键科研成果积累。



- 已与 DataFlow、LLaMA-Factory 建立深度共建机制，打通“高质量数据供给—训练时动态优化—模型效果提升”技术闭环，具备技术持续共建生态。

DataMind：把企业数据组织成可复用上下文资产

模型迭代太快，企业不能只押注训练专属模型



企业真正需要沉淀的是可复用、可迁移、可持续积累的上下文资产

从文件到第二大脑： DataMind 技术架构



把企业资料组织成 Wiki、检索、图谱、记忆与工作流



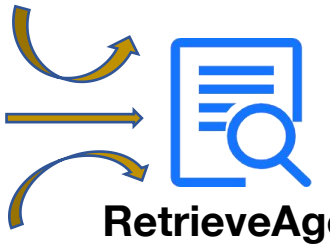
文档、表格、关系、经验分散在不同数据形态中



StoreAgent

核心职责：
数据入库，自主决策写入知识库/数据库/图谱/记忆等





RetrieveAgent

核心职责：
数据检索，自主选择检索来源（KB语义搜索、SQL查询、图遍历、技能调用、记忆等），输出统一可溯源的Evidence



跨源智能问答

融合异构数据源，一次性给出带证据的答案。



安全数据操作

自然语言查数据，危险操作自动拦截并审计，安全可控。



持续上下文复用

项目级 **Memory / Skills**
→ 跨任务、跨会话复用

L7闭环：评估结果生成下一轮数据需求

输入：模型与任务数据源

模型输出：
生成结果与错误样本

任务基准：
Benchmark / 公开集 / 企业数据集

运行轨迹：
Agent 调用、日志、上下文

One-Eval 评估中枢

统一评估、诊断与任务控制

- **任务评分** Task Score
- **模型报告** Model Report
- **失败定位** Failure Analysis
- **数据需求** Data Need

输出：可执行反馈与回流

- **L6 数据消费与调度：** DataFlex / DataMind 调度
- **L4 质量门控：** 规则、阈值、再评估
- **L3 Agent 数据层：** 工具结果与合成样本
- **L1 数据入口层：** 新增数据采集与样本充实

执行任务 → 评估表现 → 定位失败 → 生成数据需求 → 回流数据生产

L7 的价值：让评估结果变成下一轮可执行的数据生产与优化任务。

One-Eval：Agent化评测与诊断中枢

One-Eval 的目标: 把传统评测里的重复劳动尽可能交给 Agent。

痛点 1 Benchmark 选择依赖经验

面对具体模型与具体目标, 很多使用者如果不在该领域做充分调研，并不知道应该先评什么、用哪个 benchmark 更合理。

痛点 2 配置链路碎片化

数据下载、字段与 key 对齐、Prompt 模板、metric 配置, 通常要耗费大量时间成本。

痛点 3 评测结果太单一

当下评测框架往往只能给出单一角度的评测指标，缺少更加全面的错因分析以及完整的评测报告以供模型再训练的闭环。

One-Eval 的目标: NL2Eval

“请帮我评测模型在 GSM8K 上的数学能力, 并给出可复核的分析报告。”

理解需求 → **规划 bench** → **执行评测** → **生成报告**

不是简单把脚本包一层壳, 而是把自然语言需求转成图式执行流程, 自动完成 benchmark 推荐、配置补全、评测调用与报告生成, 并在关键节点保留人工 review 的入口。



1.Bench Gallery：让找Bench像在书架上翻找书籍

2.自动推荐评测指标 & 评测报告生成

开源仓库： https://github.com/OpenDCAI/One-Eval

技术报告： https://arxiv.org/abs/2603.09821

关键闭环：Evaluation Signal → Data Production Plan

1 任务执行



- Benchmark/Agent交互
- 失败样本记录

2 评估表现



- Score/Ranking/报告
- 异常模式定位

3 失败归因



- 类型与能力短板
- 数据缺口定位

4 数据需求



- 采集/合成/修复
- 进入下一轮训练

评估信号 → 数据生产计划

典型失败 → 数据补齐

数学推理失败	补充推理链样本
RAG引用错误	增加可验证证据
GUI任务失败	补齐工具轨迹
多模态偏差	扩充跨模态样本

闭环优化的核心，是把 evaluation signal 翻译成 data production plan.

可采集　可合成　可修复　可评估

DataFlow-LoopAI：“数据—评估—优化”自演化流程

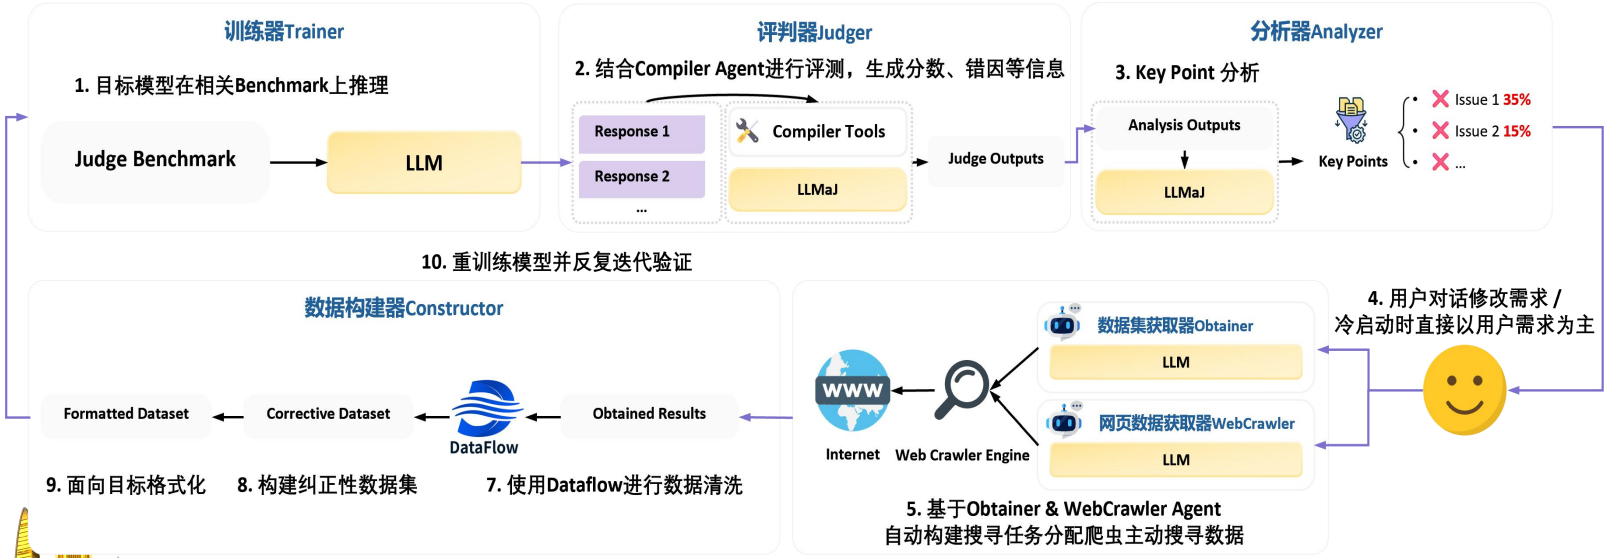
DataFlow-LoopAI摒弃单纯依赖模型规模的思路，按照**“数据—评估—优化”**流程，将**大模型评估、缺陷分析、数据搜寻**和**模型更新**四个关键环节紧密连接，形成一个能够自我强化、持续优化的正反馈循环。

A. **数据层：** 构建Agent驱动的数据嗅探Workflow，基于Web Crawler和Dataflow实现靶向数据合成。

B. **评估层：** 建立面向多模态数据自适应的统一智能评估体系，实现模型性能评估和缺陷分析。

C. **优化层：** 将评估反馈转化为精细化奖励，驱动模型自我演进。

核心目标: 通过自主协同闭环优化提升模型的性能



性能验证

Bird-dev (Text2SQL)	Greedy	Major voting
Qwen-Code-7B-Instruct	43.8	49.2
w/o Analyzer	44.5	51.0
w/ Analyzer	-	**51.96**

已适配任务:

- Text2SQL
- Code-Generation

数据获取能力:

- 网页数据集获取
- 网页数据获取和解析

04

Agentic Execution：从自然语言到可执行数据工作流



DataFlow Skills&Harness：自然语言驱动的数据执行系统

帮我生成一个数据清洗的pipeline

自然语言需求

管线推荐

- 用户意图解析
- Pipeline拆解
- 算子匹配
- Pipeline组合推荐
- Pipeline调试
- 返回pipeline

算子编写

- 用户意图解析
- 算子RAG
- 编写 df 风格算子
- 算子调试
- 返回算子

管线Refine

- 管线结构化提取
- 匹配refine需求
- Refine结构化管线
- 返回pipeline

数据获取

- 用户关键词提取
- 分配数据源
- 下载数据
- 整理成df-Ready形式数据

算子 Refine

- 获取指定算子
- 修改算子 PromptTemplate
- 调试算子
- 处理数据

AI Ready 数据集

DataFlow WebUI：让业务用户用自然语言编排Pipeline

更快

数据洞察速度更快： 显著缩短从数据需求到数据产出的时间，加速业务决策循环。

更省

数据操作成本和人力成本更省： 打破技术壁垒，让非技术背景的业务专家也能直接设计和执行数据流程。

更高

数据处理质量和可靠性更高： 数据处理过程可复现、可验证，提升数据操作的可靠性与标准化水平。

更强

业务适应性和敏捷性更强： 构建能够随业务需求快速调整和扩展的数据架构，支撑持续创新。

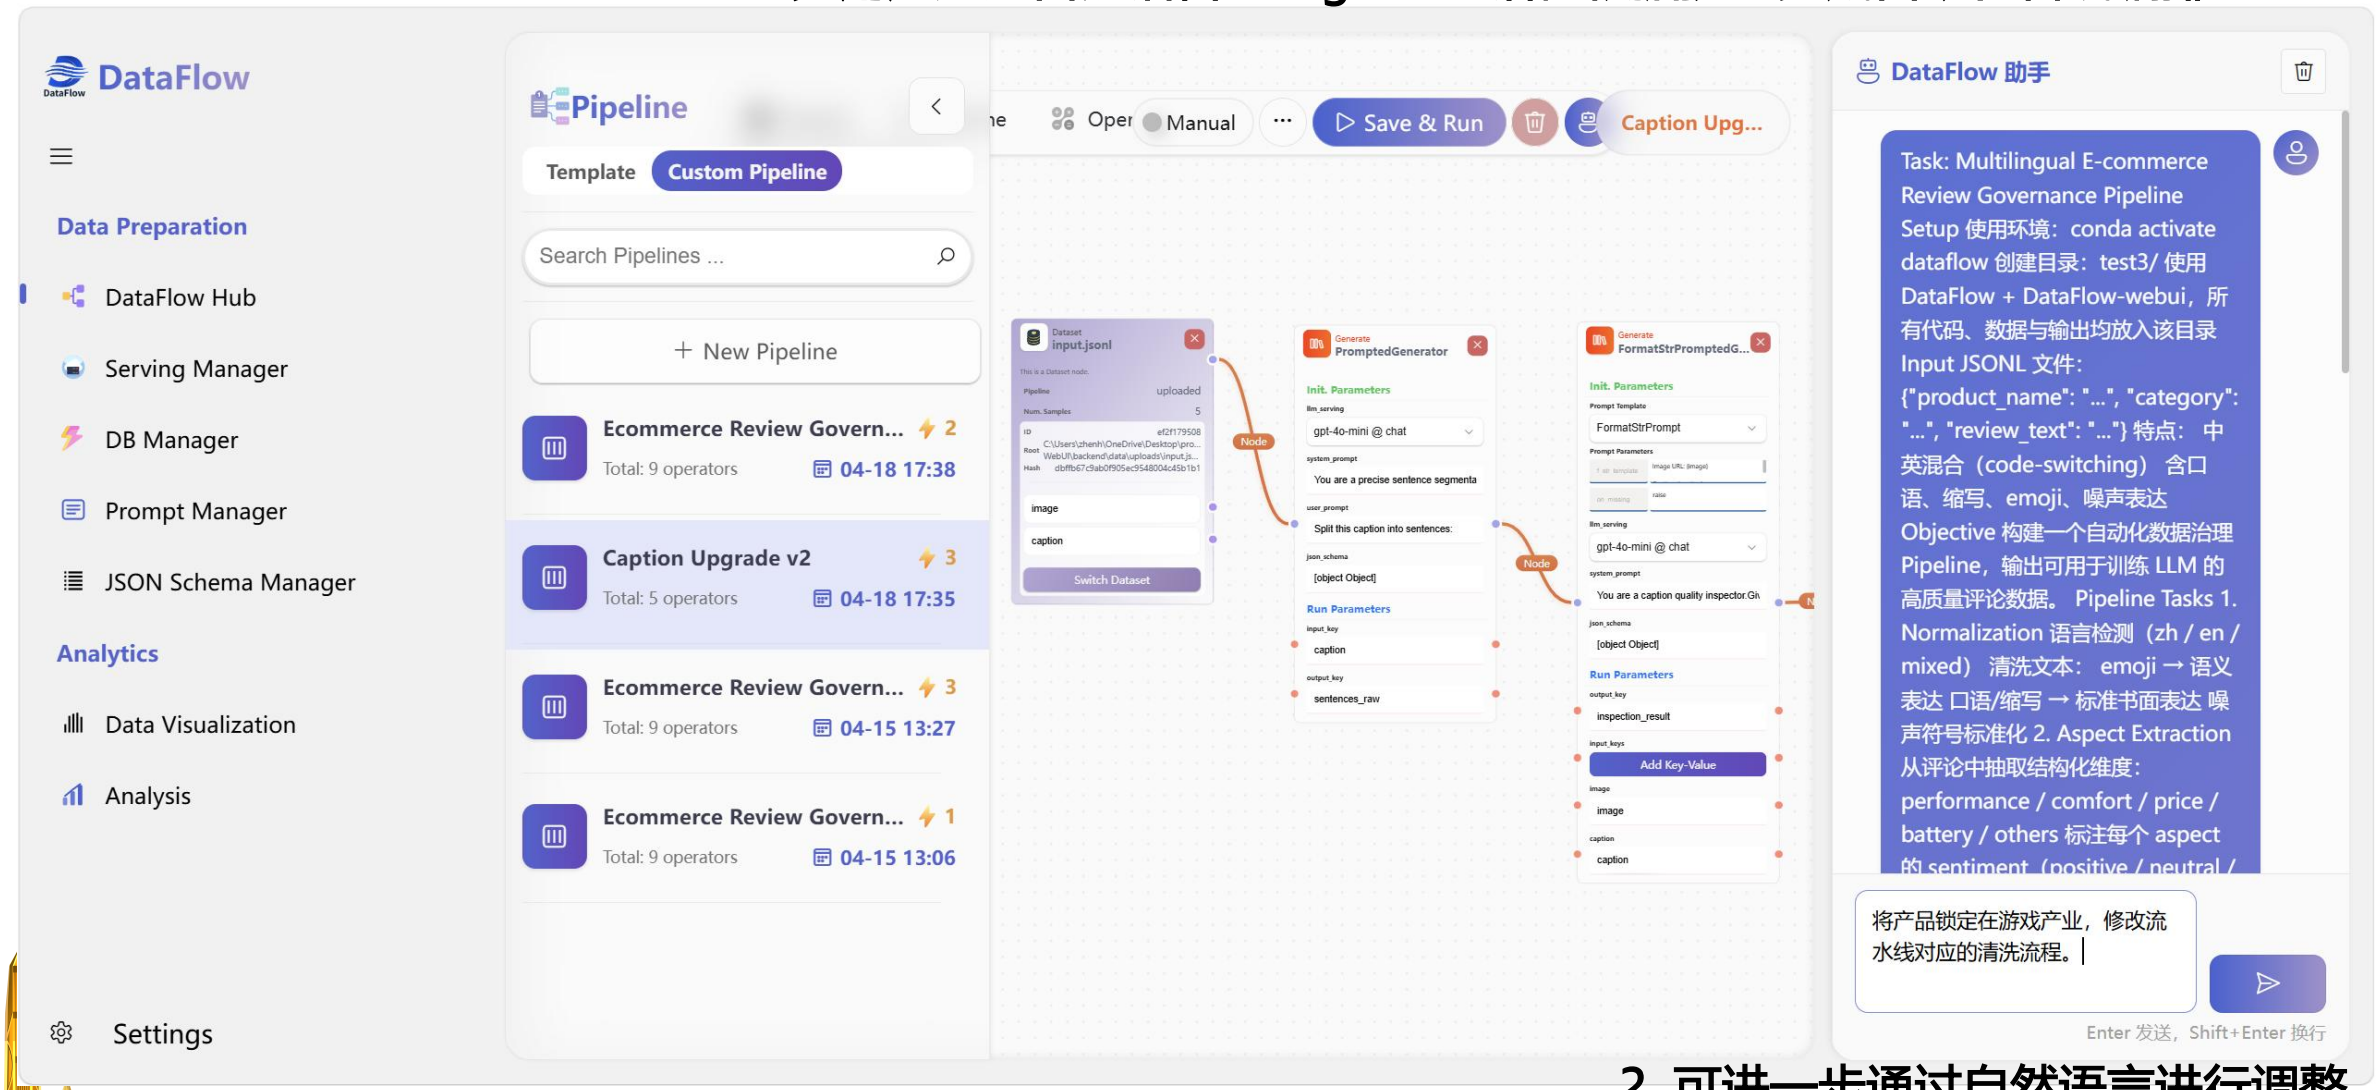
业务用户通过自然语言与 Agent 对话，根据提示完成自动化管线编排



Pipeline自动优化 + 二次编辑

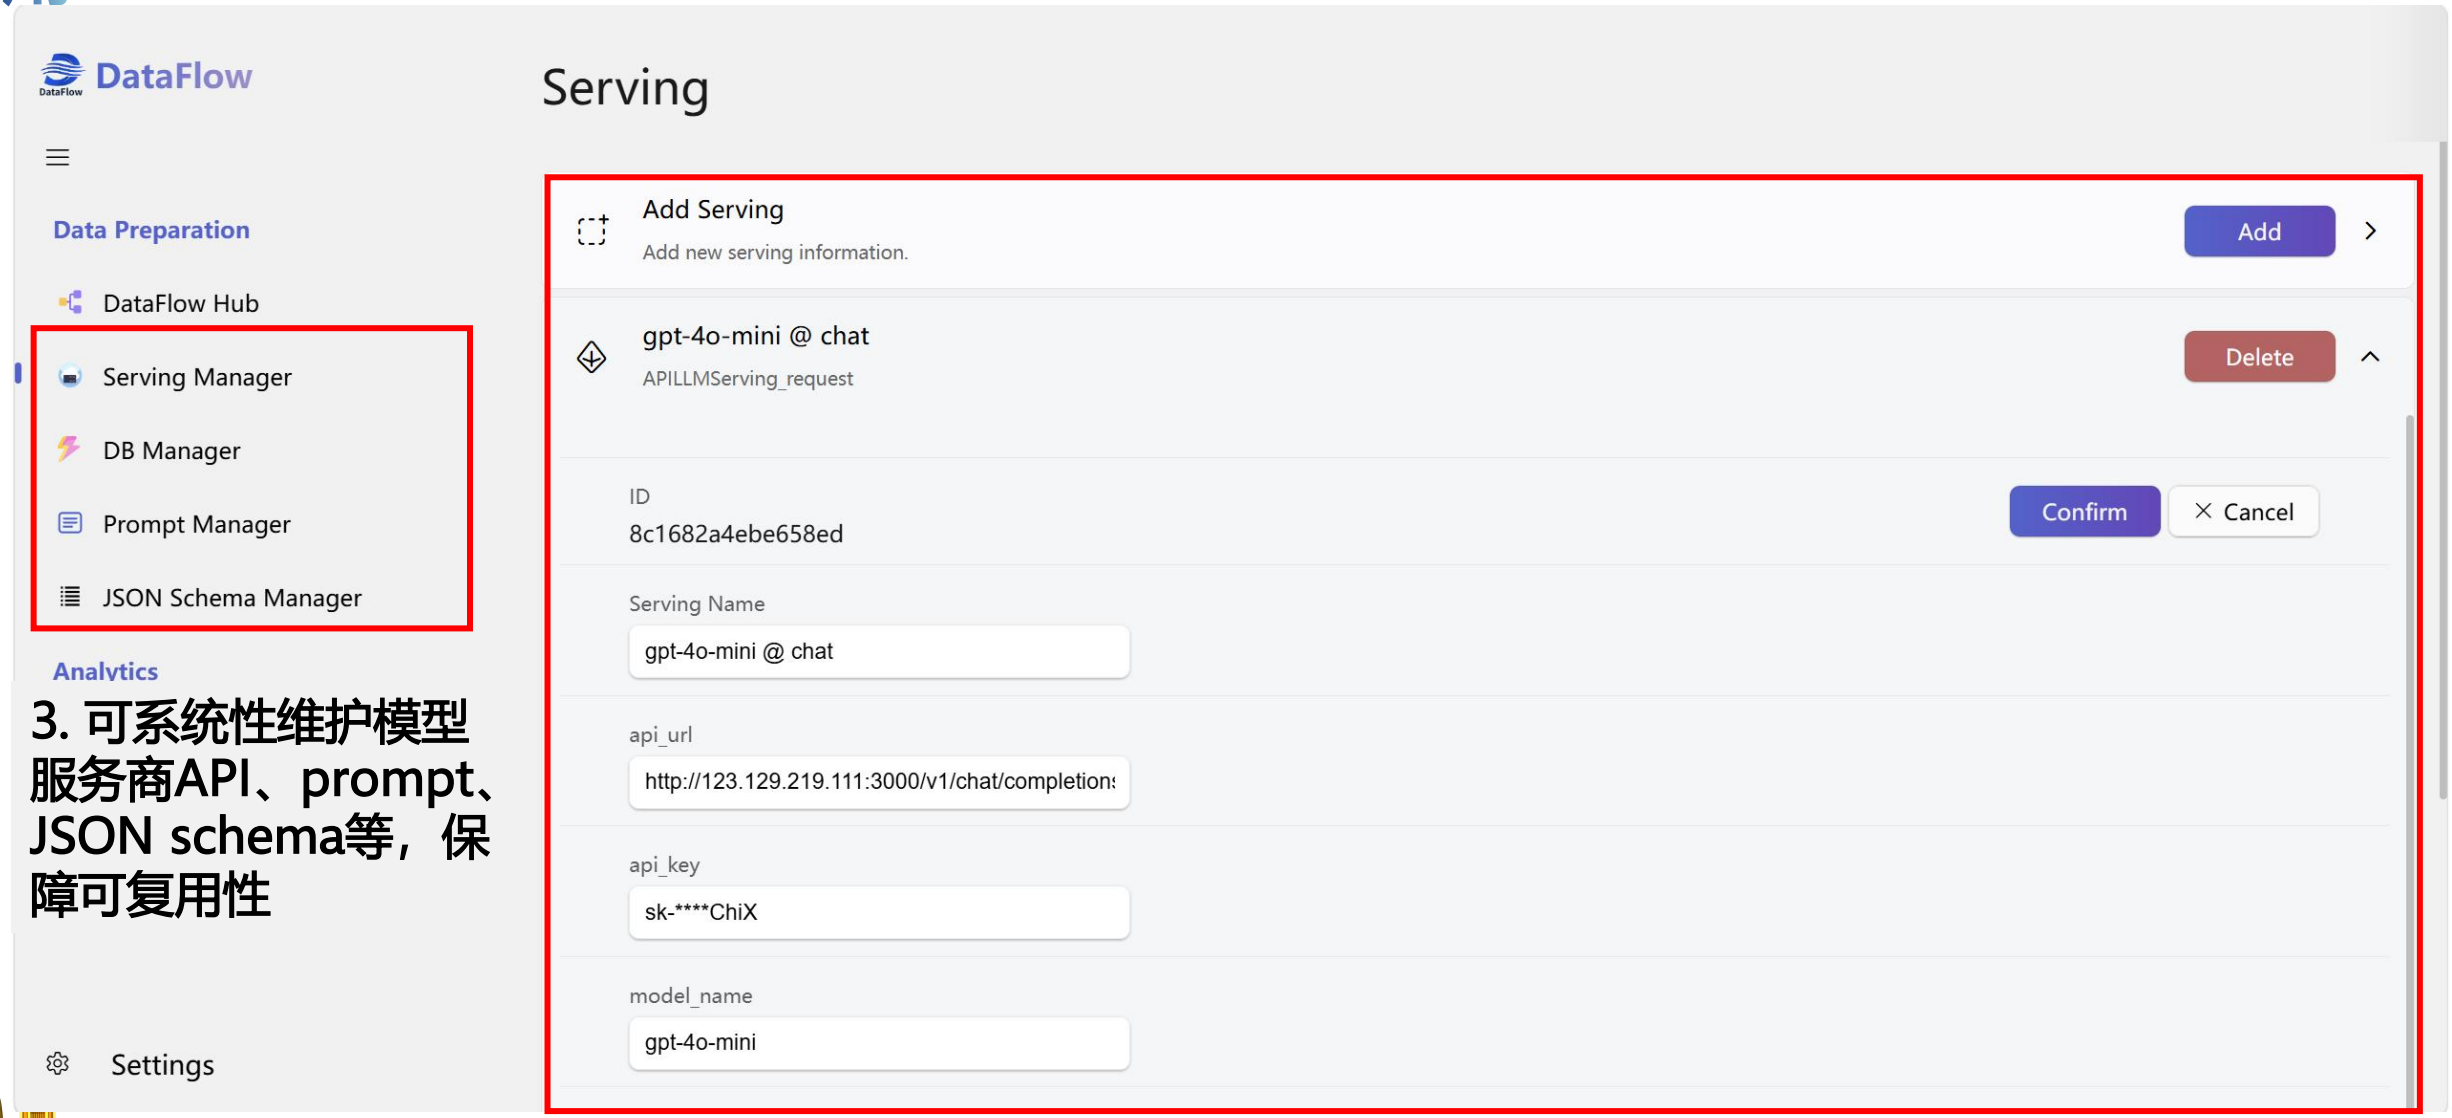
DataFlow 流程：对话式调整Pipeline

1. 业务用户通过自然语言与 Agent 对话，根据提示完成自动化管线编排



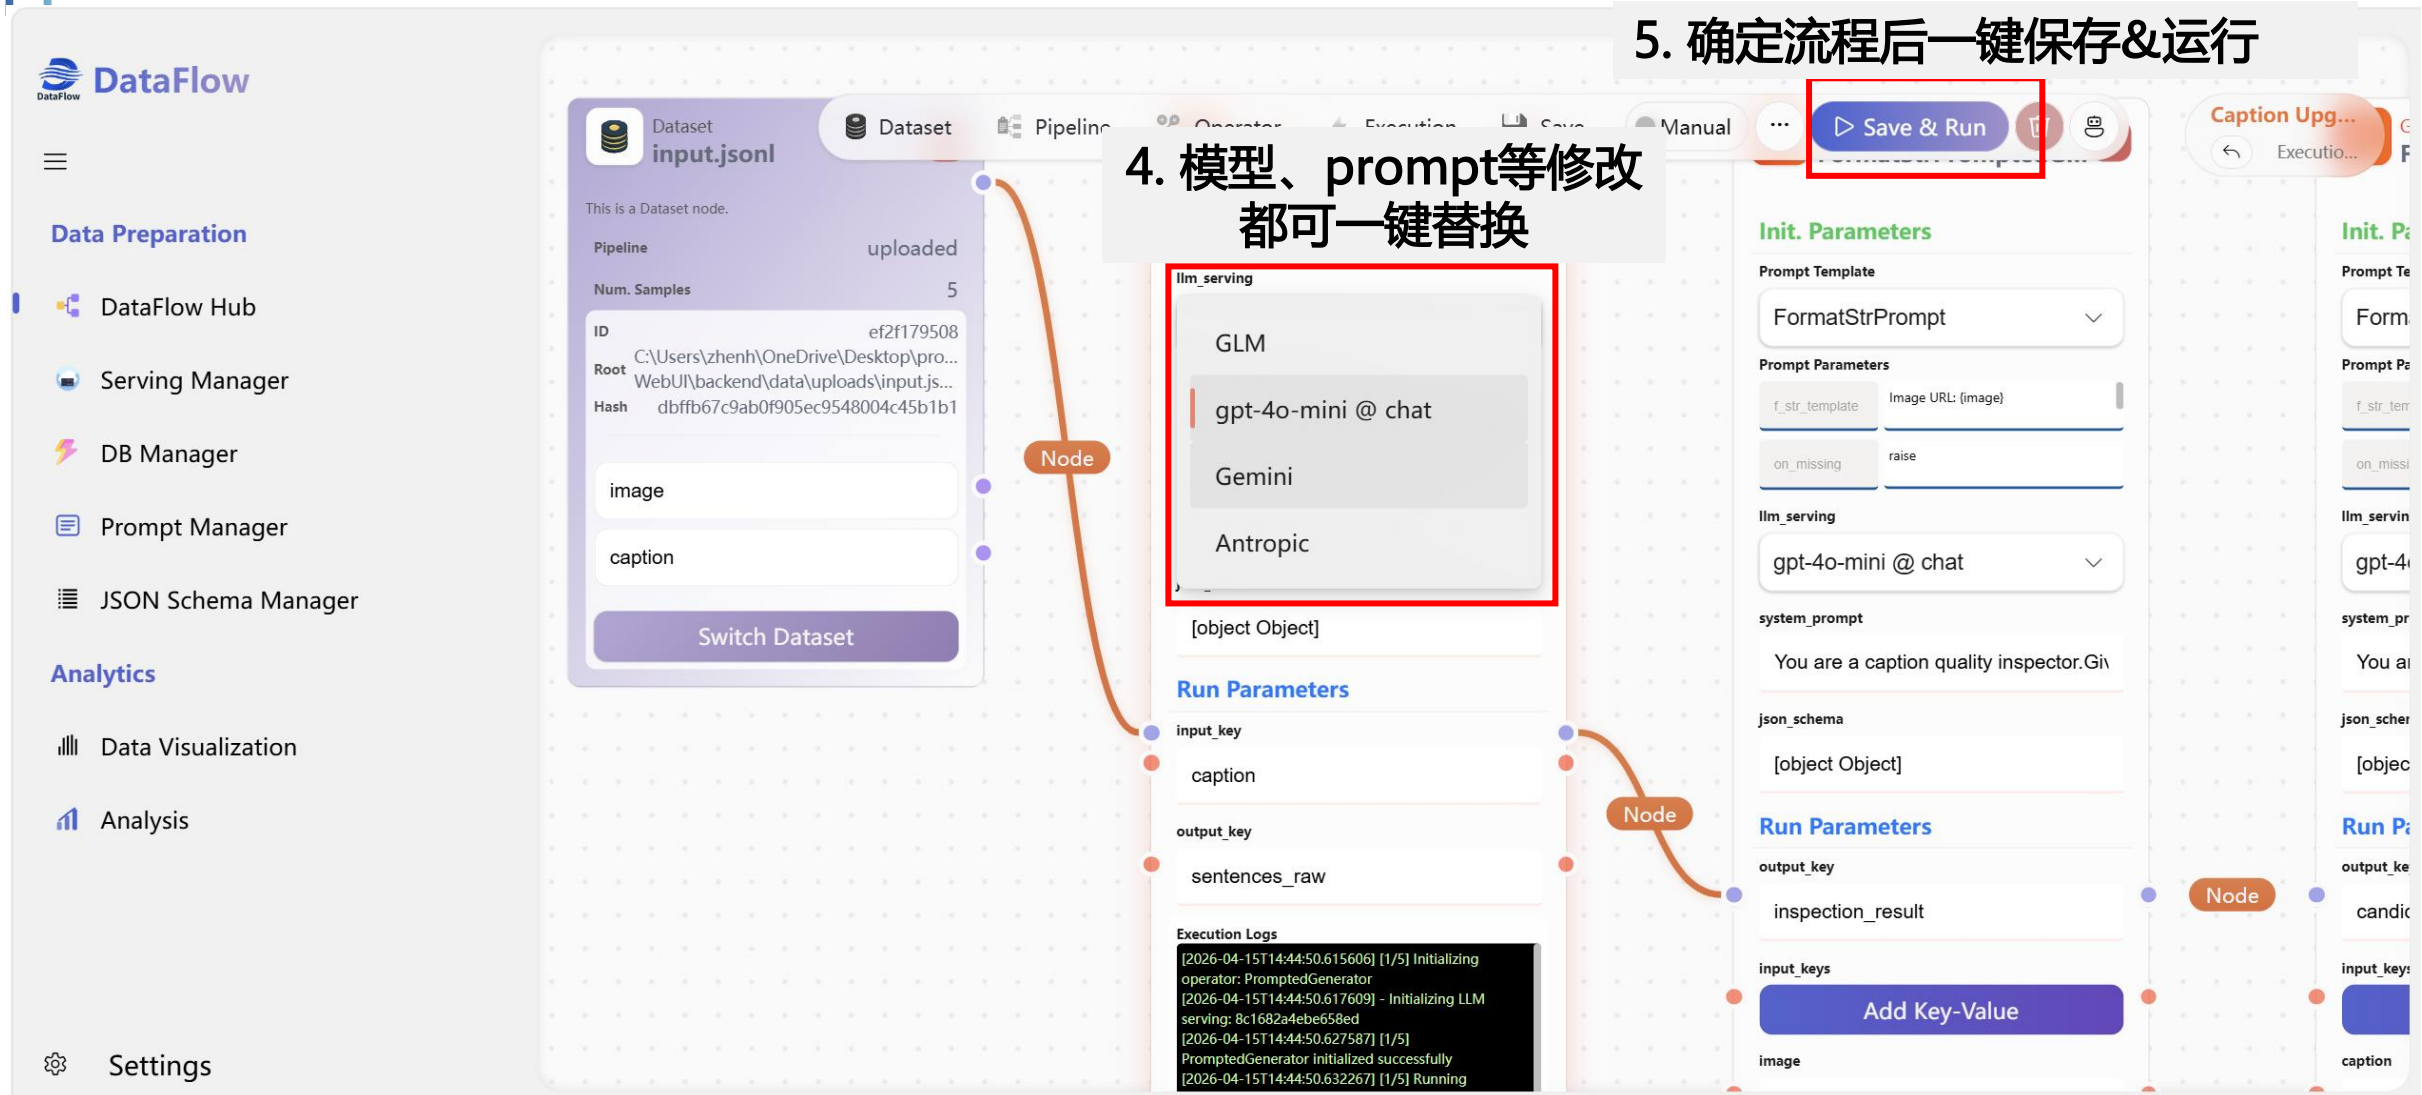
2. 可进一步通过自然语言进行调整

DataFlow WebUI配置管理：模型、Schema等可复用

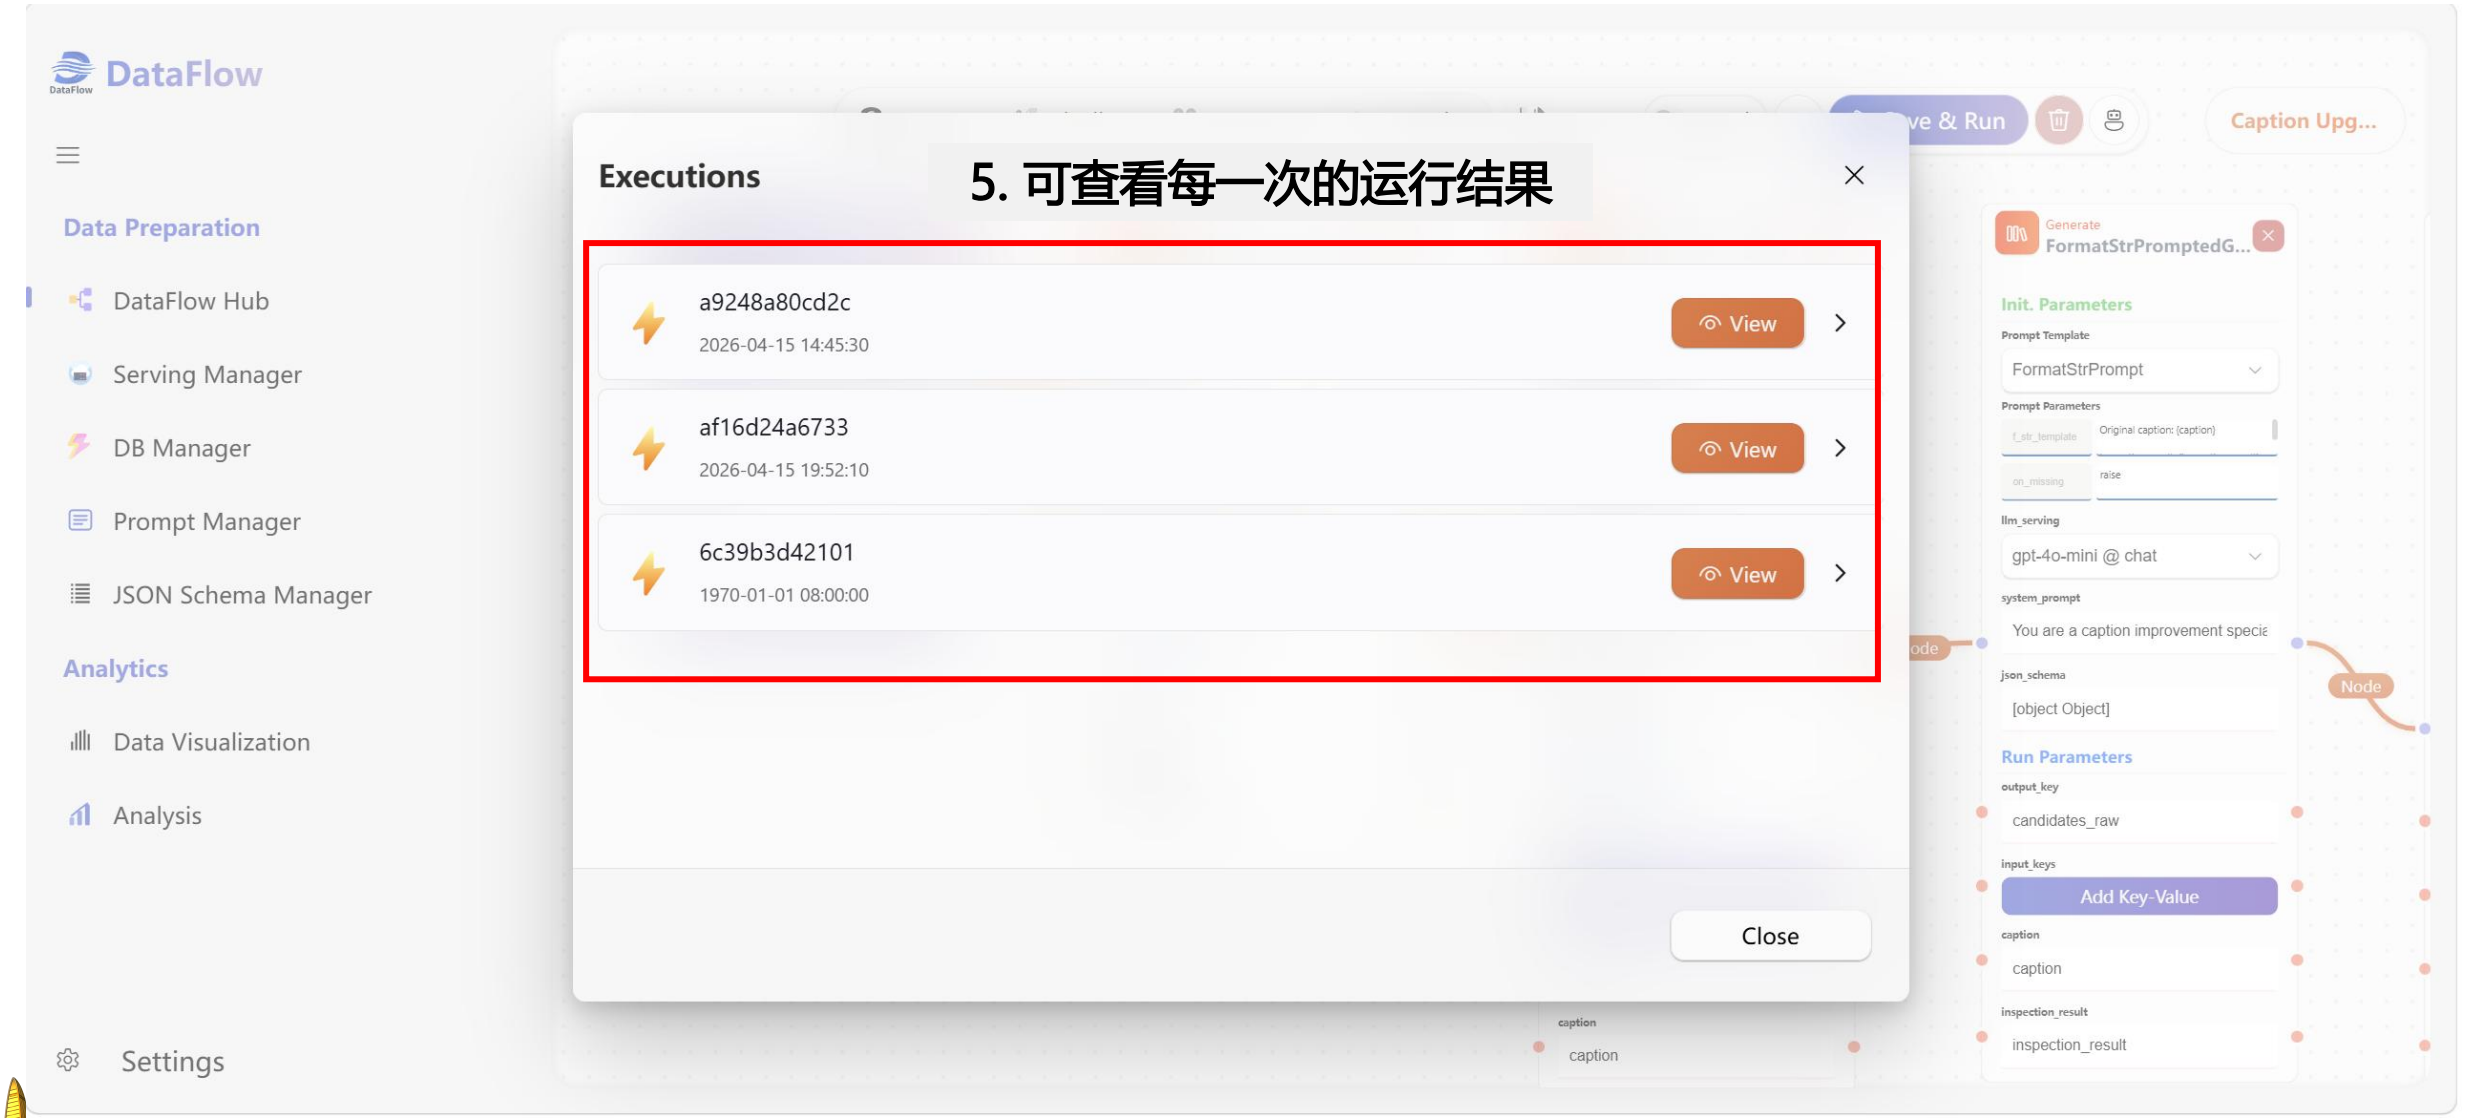


3. 可系统性维护模型服务商API、prompt、JSON schema等，保障可复用性

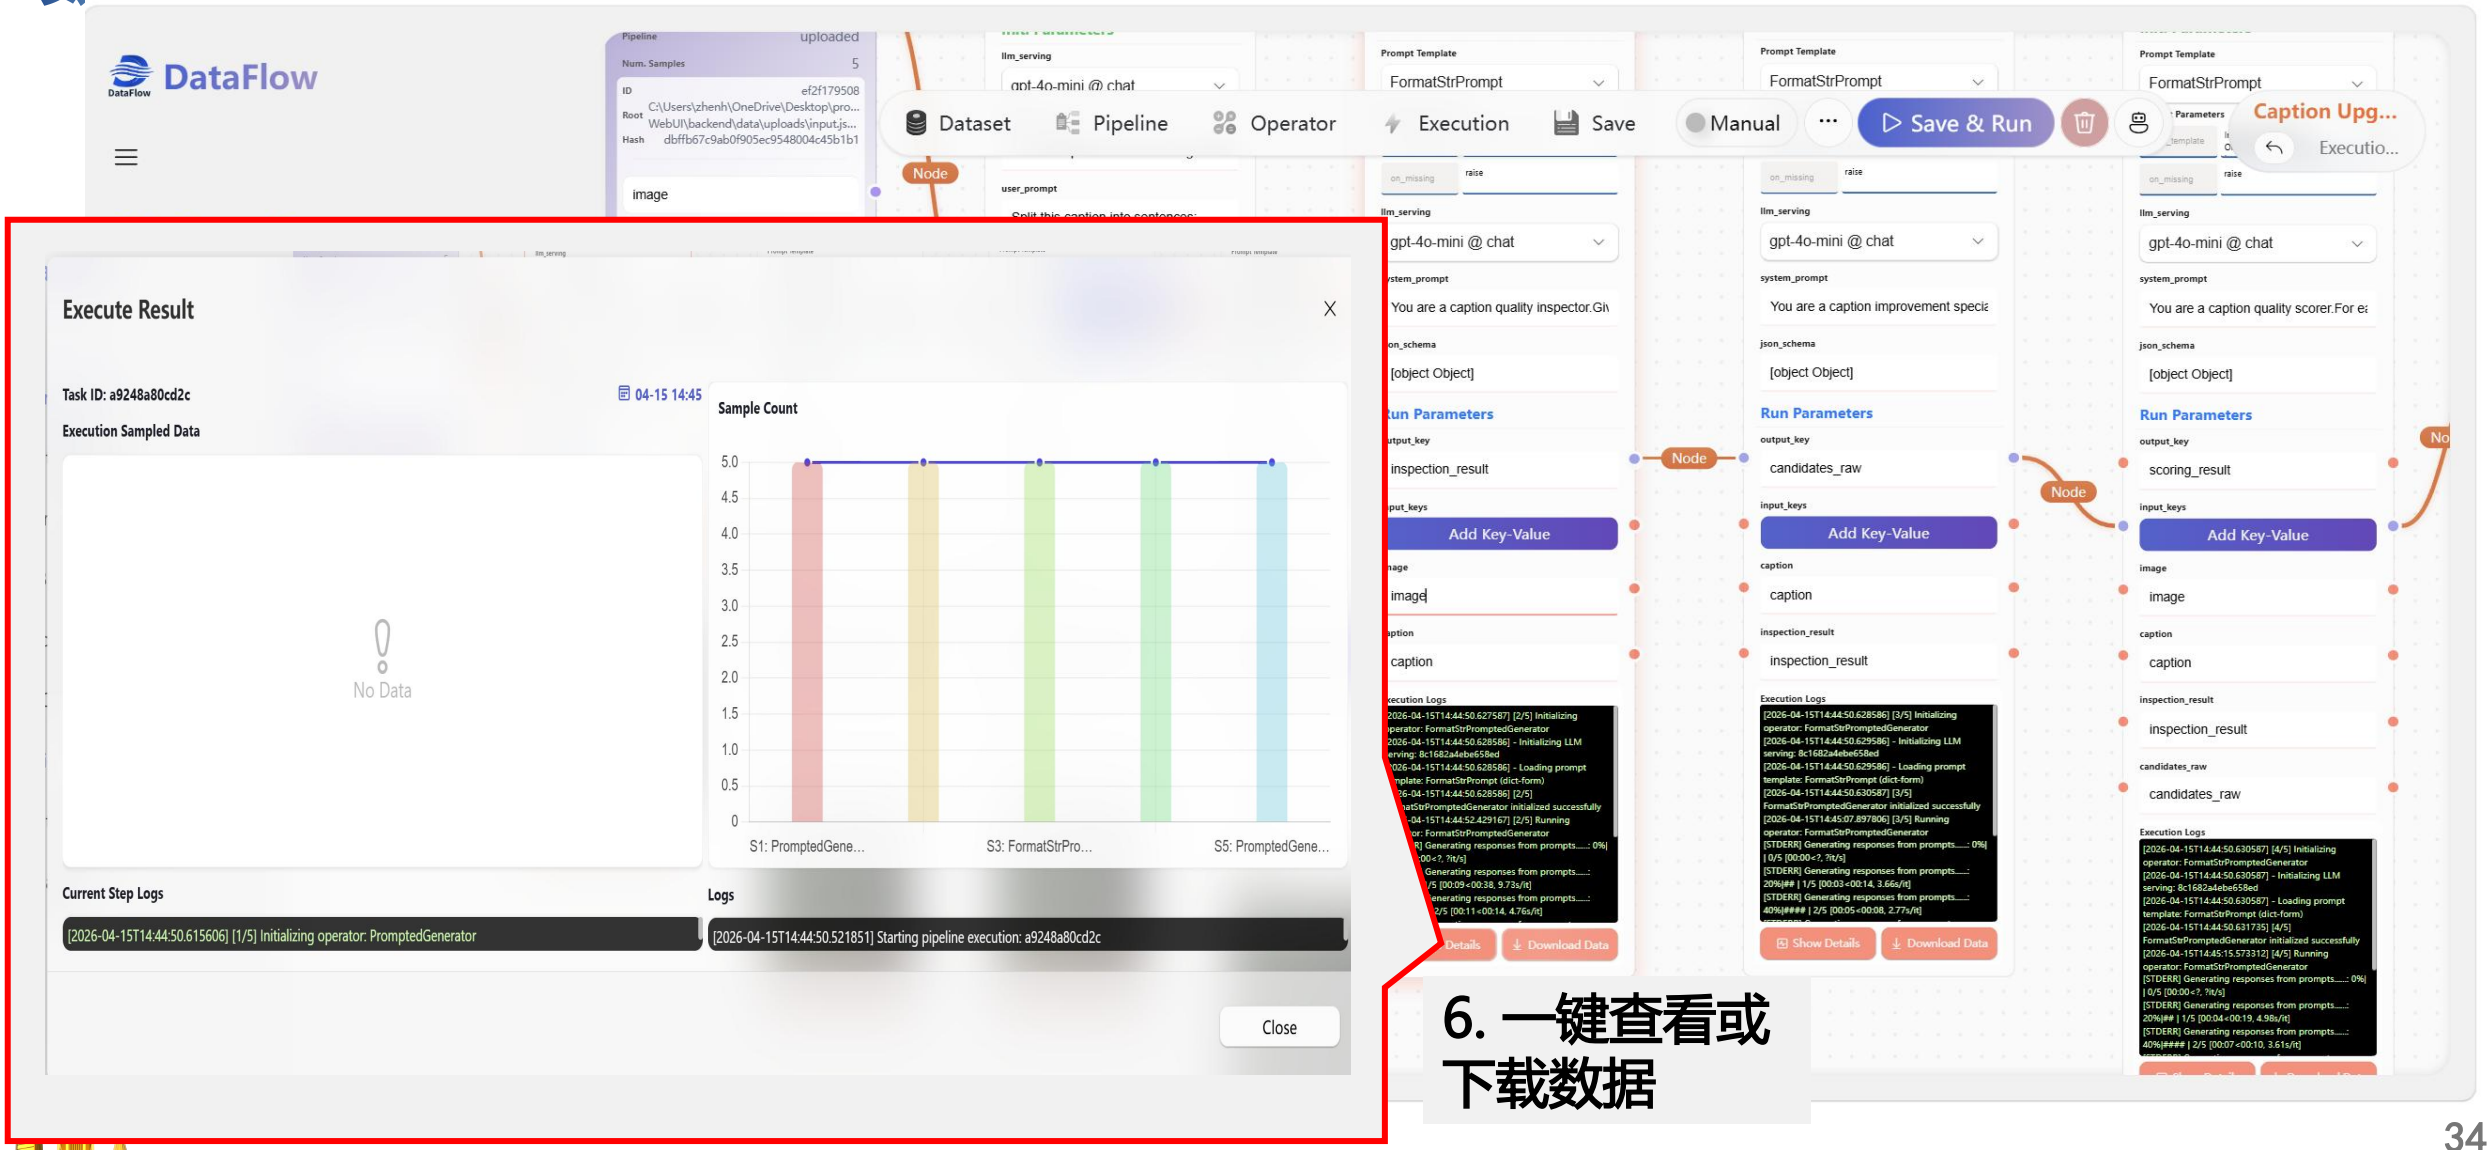
DataFlow WebUI运行管理：一键替换、保存与执行



DataFlow WebUI结果追踪：每一次运行都可复现



DataFlow WebUI数据出口：一键下载AI-Ready数据



6. 一键查看或下载数据

强美伊

北京大学 DCAI Lab 硕士、创业者

DataFlow 开源技术交流群

DataFlow 技术生态

DataFlow: https://github.com/OpenDCAI/DataFlow

DataFlow-MM: https://github.com/OpenDCAI/DataFlow-MM

DataFlow-WorldModel: https://github.com/OpenDCAI/OpenWorldLib

DataFlow-OneEval: https://github.com/OpenDCAI/One-Eval

DataFlex: https://github.com/OpenDCAI/DataFlex

DataFlow-WebUI: https://github.com/OpenDCAI/DataFlow-WebUI

DataFlow-Agent: https://github.com/OpenDCAI/DataFlow-Agent

Flash-MinerU: https://github.com/OpenDCAI/Flash-MinerU

开源生态合作伙伴

DCAI @PKU · OriginHub MyScaleDB · MemOS · LLaMA-Factory Easy and Efficient LLM Fine-Tuning · MinerU · CAMEL AI

GOSIM

GOSIM Shenzhen 2026

Thanks!

