GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



GOSIM

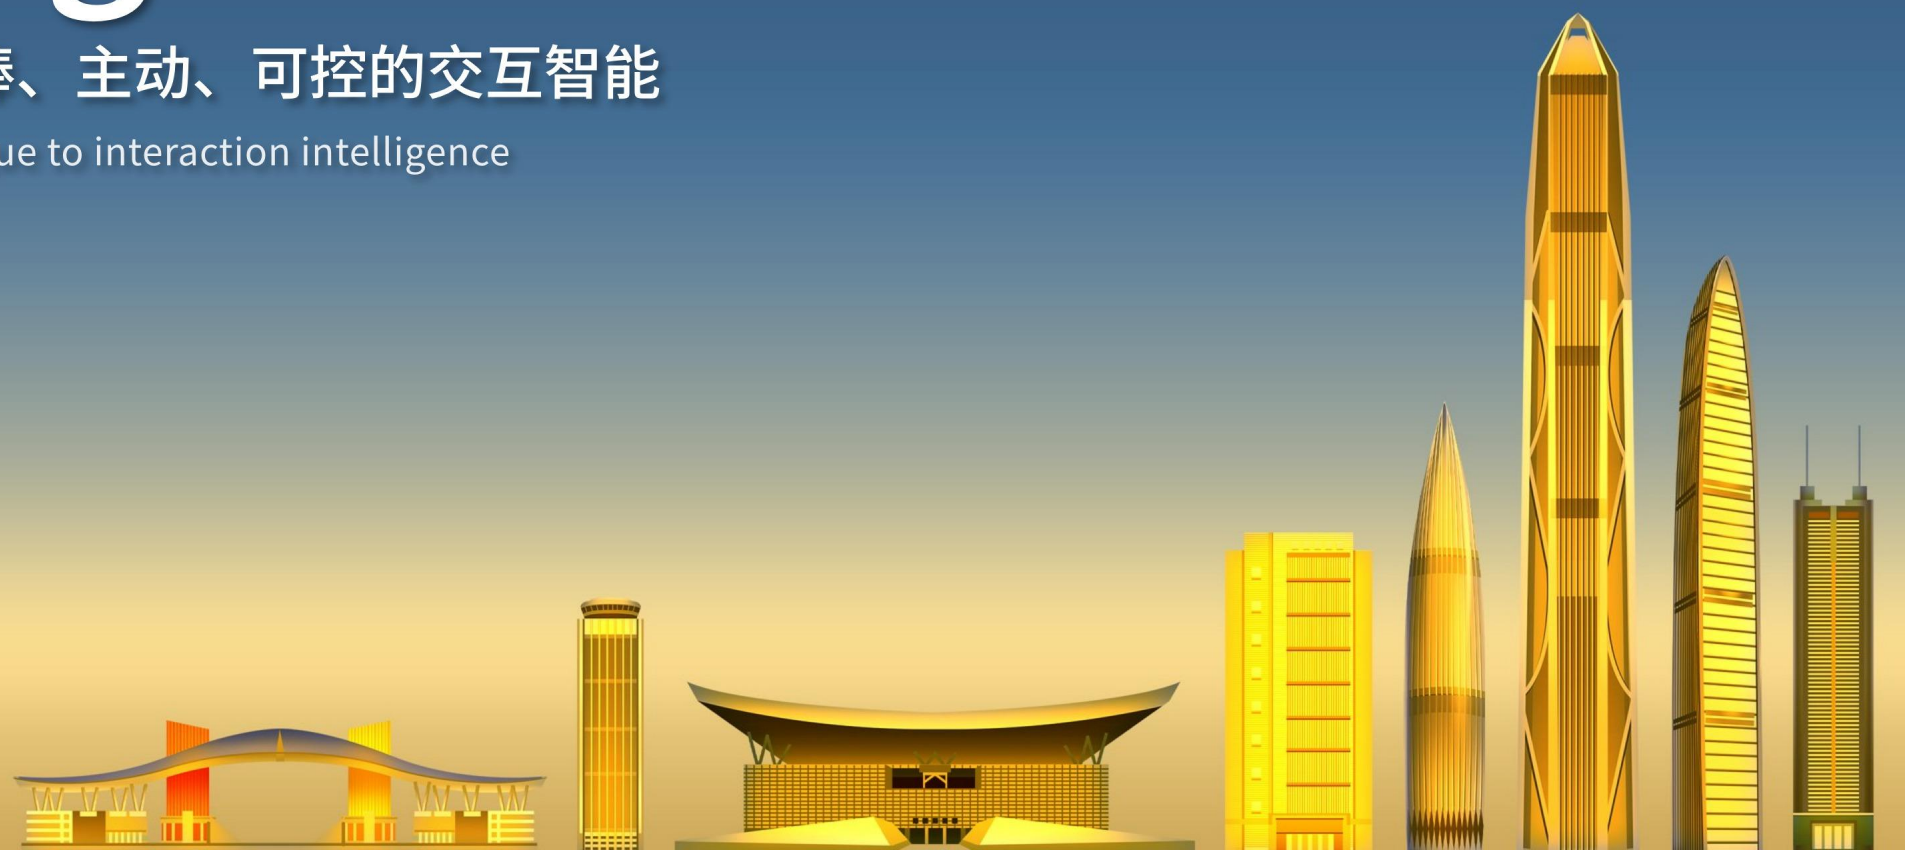
GOSIM Shenzhen 2026

Voice Agent

从端到端对话，到鲁棒、主动、可控的交互智能

From end-to-end speech dialogue to interaction intelligence

Zhifei Xie



CONTENTS

Part 01
Mini-Omni 开启端到端对话
Hear, talk while thinking — in streaming

Part 02
Voice Agent 的底层能力
鲁棒 Mega-ASR · 主动 Pask · 模型结构 Audio Interaction Model

Part 03
Voice Agent
VoiceMem 流式双脑记忆 · Duplex-Harness 可控的类人交互



GOSIM

GOSIM Shenzhen 2026

01

Mini-Omni 开启端到端对话

Language Models Can Hear, Talk While Thinking in Streaming

Mini-Omni | Mini-Omni2 | 开源社区



起点：Hello VITA

WHERE IT STARTED

VITA: Towards Open-Source Interactive Omni Multimodal LLM

开源 Open-source　交互式 Interactive　全模态 Omni

一次真实的语音对话演示：用户开口，模型用声音回应。
问题随之而来 —— 怎样让它**更快、更像人**？

vita-home.github.io/



从级联到端到端

CASCADE · 级联方案

用户语音
speech in

→

ASR
语音识别 → 文本

→

Text2Text LLM
文本理解与生成

→

TTS
文本 → 语音合成

→

回复语音
speech out

等待完整识别 | 等待完整回答 | 合成后才能播放

≈3s
首句回复延迟 latency

END-TO-END · 端到端

用户语音
speech in

→

Speech Language Model：边听、边想、边说
语音直接进入模型，文本推理与语音输出同步流式生成

→

流式语音
stream out

→ 这正是 Mini-Omni 要回答的问题：Language models can hear, talk while thinking in streaming.



OPEN-SOURCE · 2024

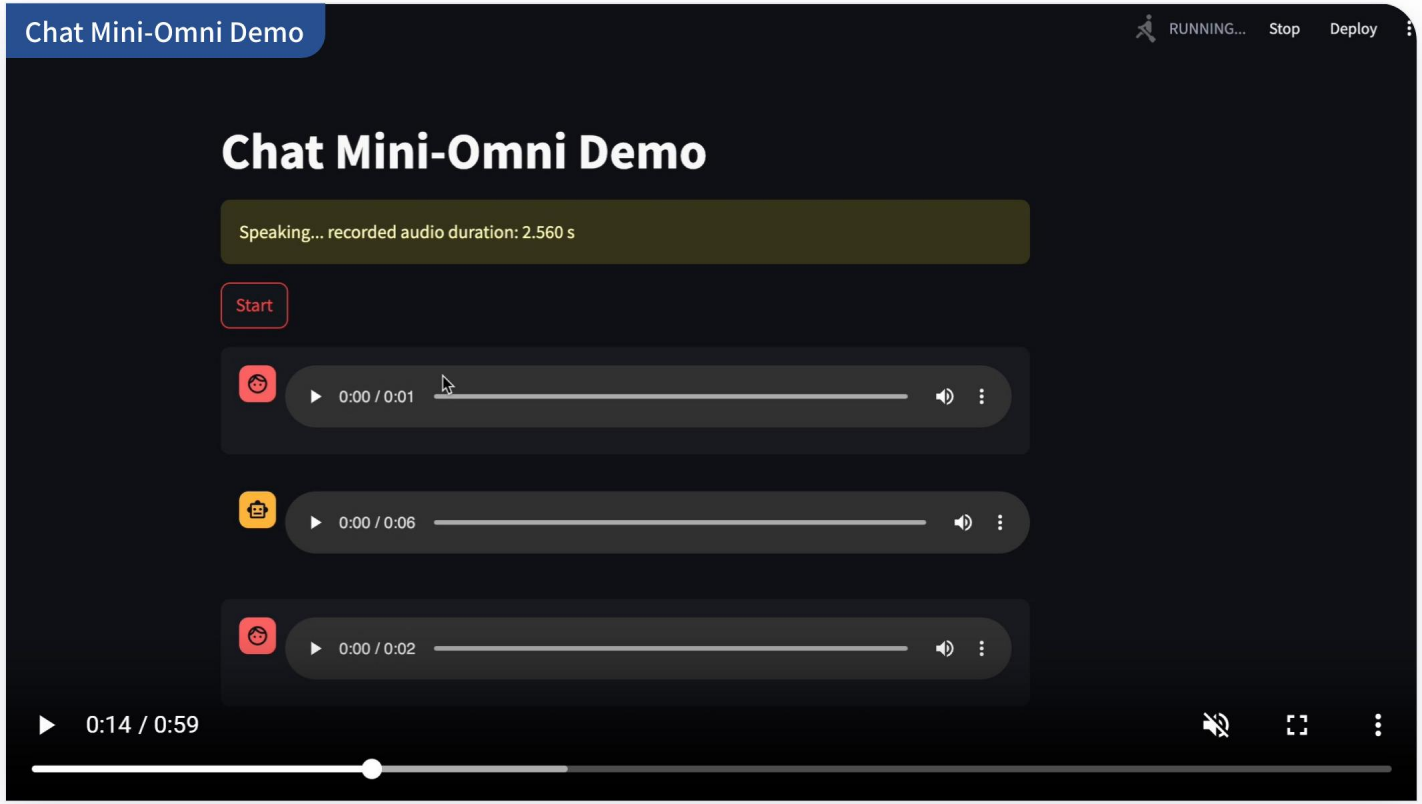
Mini-Omni

Language Models Can Hear, Talk While Thinking in Streaming

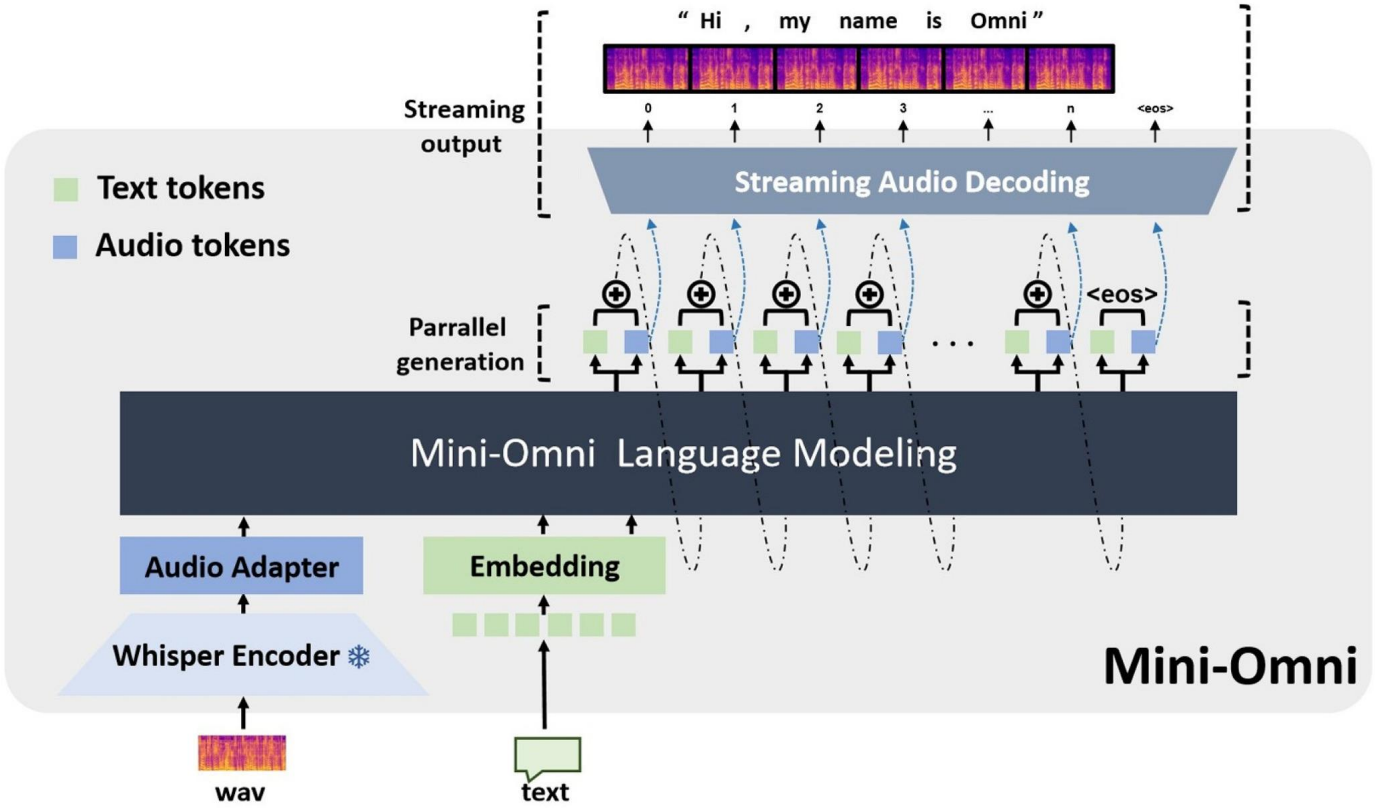
开源多模态大模型：端到端的实时语音输入，配合流式语音输出，在“思考”的同时开口说话。

实时语音输入　流式语音输出　Talk while thinking

github.com/gpt-omni/mini-omni



Mini-Omni 架构：文本与音频并行生成



1 语音直接进入语言模型

Whisper Encoder + Audio Adapter 把语音特征接入 LM，无需先转写成文本。

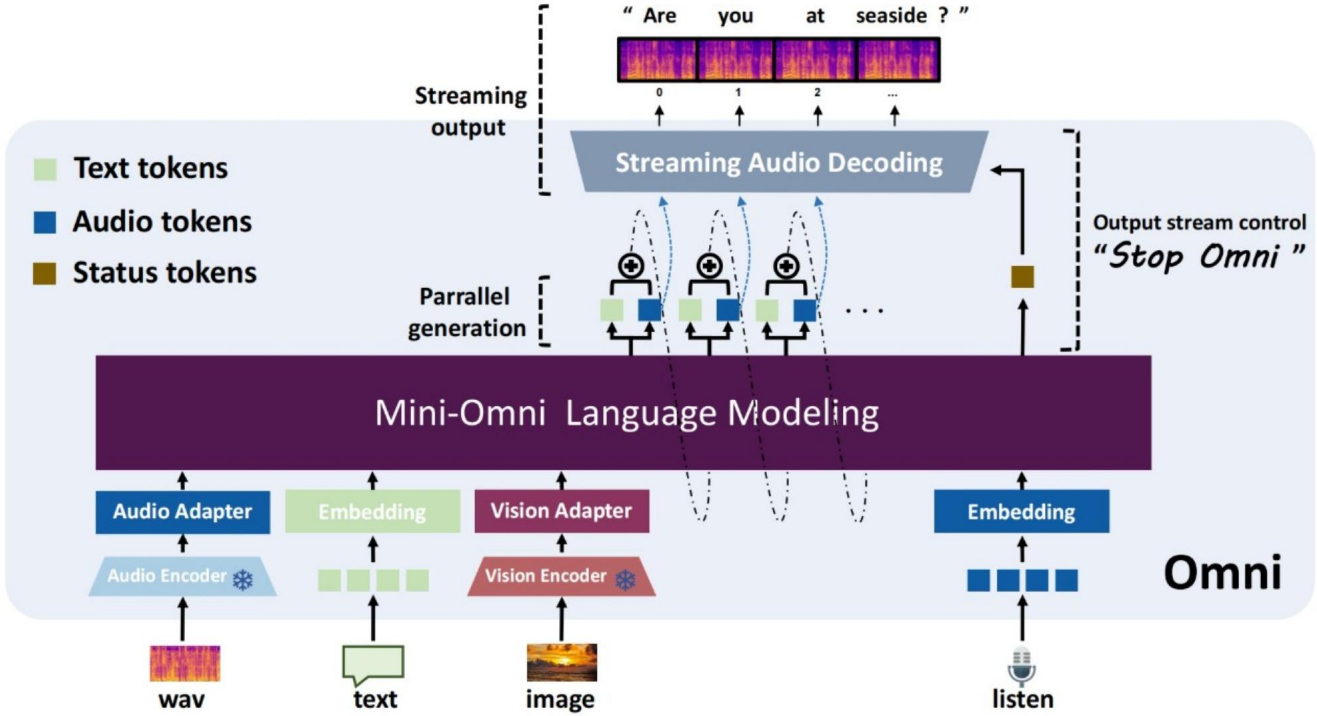
2 文本与音频 token 并行

每一步同时生成 text token 与 audio tokens，让文本推理能力引导语音输出。

3 流式音频解码

Streaming Audio Decoding：边生成边播放 —— 边想边说。

Mini-Omni2：视觉、语音与双工

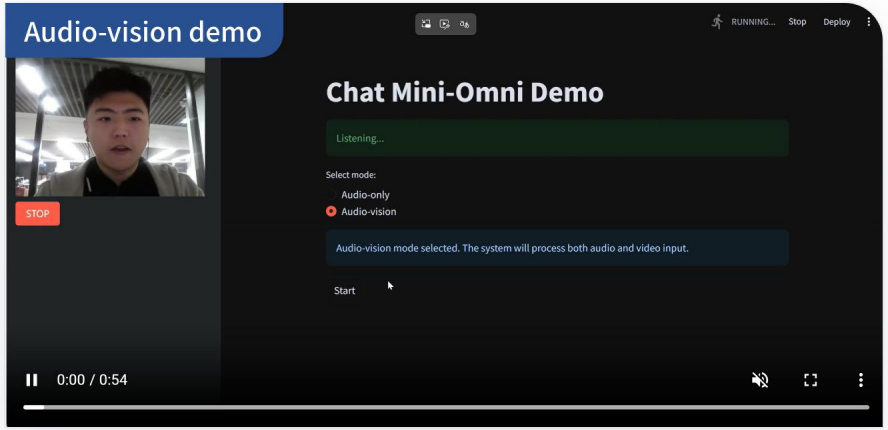


Vision Adapter · 看　Audio Adapter · 听　"Stop Omni" · 可打断

GPT-OMNI / MINI-OMNI2

Towards Open-source GPT-4o with Vision, Speech and Duplex Capabilities

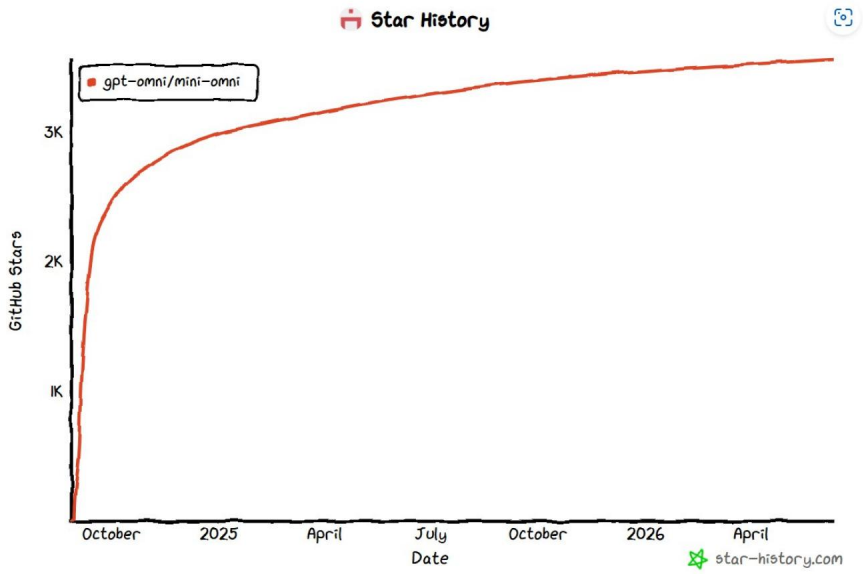
在 Mini-Omni 之上加入图像输入；模型在说话时持续 `listen`，用状态 token 控制输出流，听到“Stop Omni”即停下。



开源社区的回响

3K+

GitHub Stars · gpt-omni/mini-omni



Thinker-Talker

Qwen2.5-Omni 的 Talker 设计

Talker 采用双轨自回归 Transformer Decoder —— “motivated by Mini-Omni (Xie & Wu, 2024)”

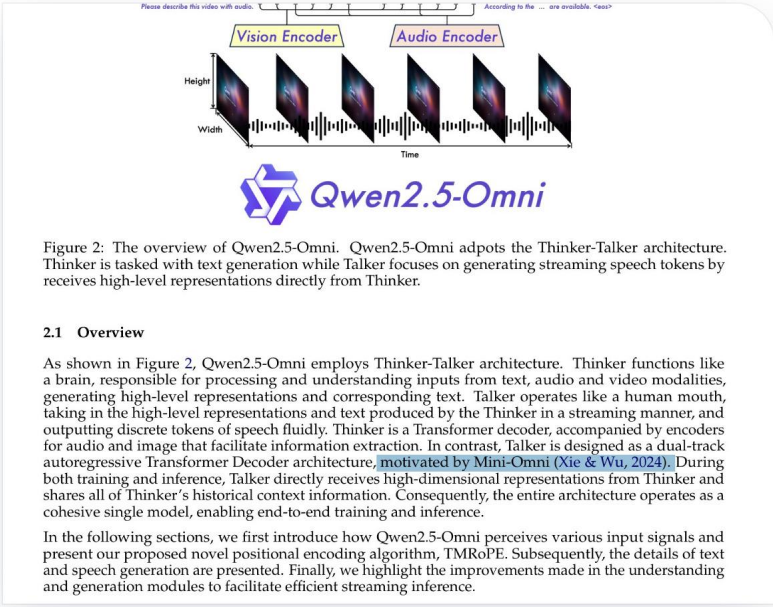


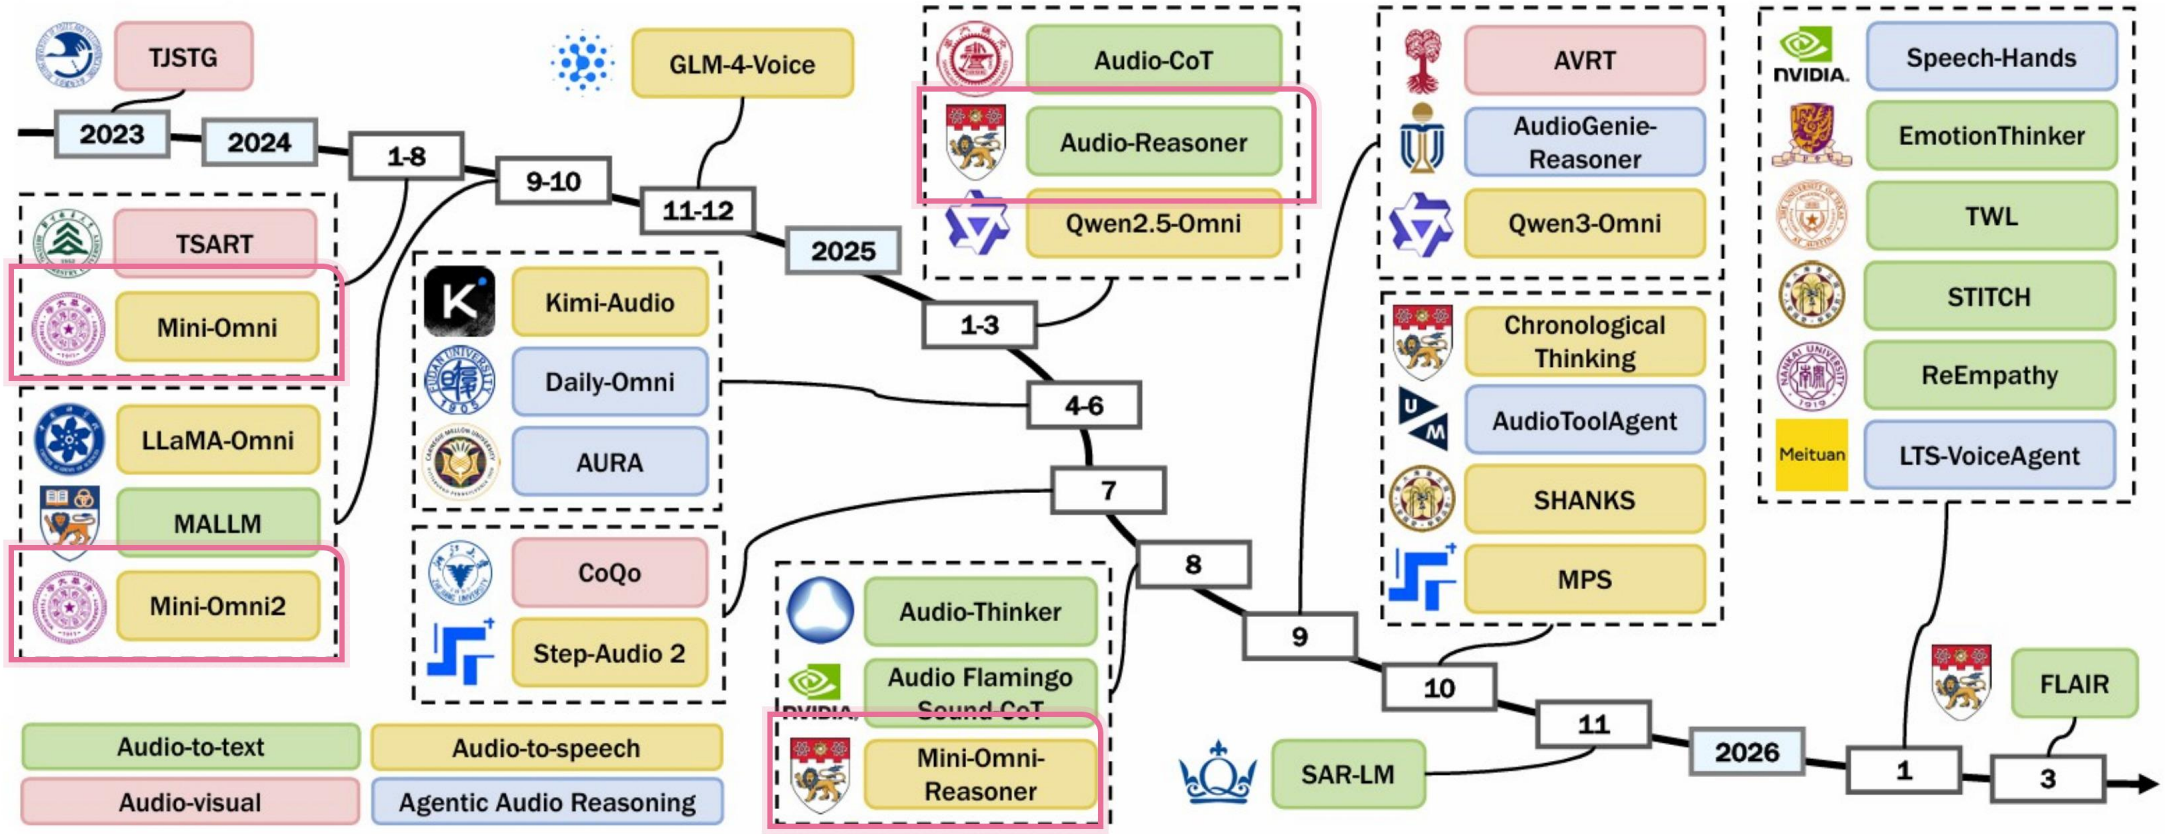
Figure 2: The overview of Qwen2.5-Omni. Qwen2.5-Omni adpots the Thinker-Talker architecture. Thinker is tasked with text generation while Talker focuses on generating streaming speech tokens by receives high-level representations directly from Thinker.

2.1 Overview

As shown in Figure 2, Qwen2.5-Omni employs Thinker-Talker architecture. Thinker functions like a brain, responsible for processing and understanding inputs from text, audio and video modalities, generating high-level representations and corresponding text. Talker operates like a human mouth, taking in the high-level representations and text produced by the Thinker in a streaming manner, and outputting discrete tokens of speech fluidly. Thinker is a Transformer decoder, accompanied by encoders for audio and image that facilitate information extraction. In contrast, Talker is designed as a dual-track autoregressive Transformer Decoder architecture, motivated by Mini-Omni (Xie & Wu, 2024). During both training and inference, Talker directly receives high-dimensional representations from Thinker and shares all of Thinker's historical context information. Consequently, the entire architecture operates as a cohesive single model, enabling end-to-end training and inference.

In the following sections, we first introduce how Qwen2.5-Omni perceives various input signals and present our proposed novel positional encoding algorithm, TMRoPE. Subsequently, the details of text and speech generation are presented. Finally, we highlight the improvements made in the understanding and generation modules to facilitate efficient streaming inference.

端到端音频模型的演进 2023 → 2026



我们的工作：Mini-Omni • Mini-Omni2 • Audio-Reasoner • Mini-Omni-Reasoner

GOSIM

GOSIM Shenzhen 2026

02

Voice Agent 的底层能力

让语音 Agent 在真实世界里可用：听得准、懂时机、一个模型统一交互

鲁棒 · Mega-ASR

主动 · Pask

模型结构 · Audio Interaction Model



Voice Agent 的三块底座

01

鲁棒

ROBUSTNESS

噪声、混响、远场、遮挡、传输丢包……真实声学环境下依然听得准、不幻觉。

7 类声学域 · 54 种混合场景 · 11K 小时

Mega-ASR

02

主动

PROACTIVITY

理解场景与意图，判断什么时候保持沉默、什么时候主动帮忙。

Keep silence · Load memory · Proactively help

Pask

03

模型结构

ARCHITECTURE

Always-on：一个模型统一识别、翻译、理解与对话等音频交互任务。

Each task becomes an instruction

Audio Interaction Model



鲁棒：Mega-ASR 在真实场景下的识别

真实场景挑战 Challenge	Qwen3-ASR by Qwen Team	Gemini-3-Pro by Google DeepMind	Seed-ASR by Seed	Mega-ASR Ours
Empty Output Recovery 困难音频上不再“交白卷”	100.0	86.1	85.3	47.1
Long-Utterance Semantic Recovery 长句的语义完整还原	64.7	64.7	38.2	5.9
Babble Noise & Hallucination 人声嘈杂下不编造内容	57.1	42.9	28.6	0.0
Restaurant Noise Recovery 餐厅噪声下的准确识别	40.0	100.0	20.0	0.0

典型案例的词错误率 WER（%，越低越好）



VOICES-IN-THE-WILD-2M：真实声学场景数据



噪声 | 回声与混响 | 远场 | 遮挡 | 录音染色 | 传输丢失 | 电子失真

2.4M

精选音频片段

curated audio clips

11Kh

总时长

hours in total

7 / 54

领域 / 混合场景

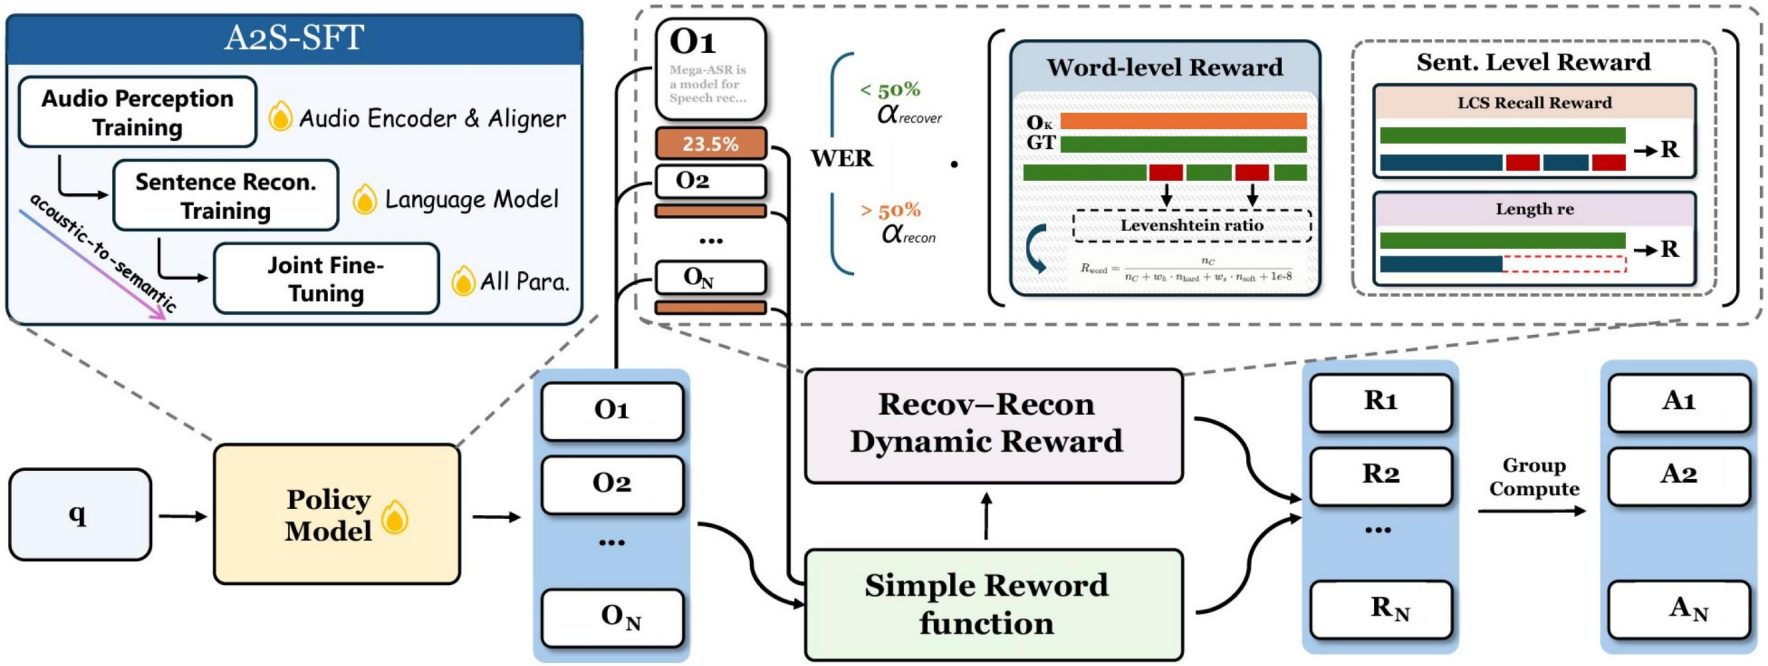
domains / hybrid scenarios

5K

混合样本用于评测

mixed for benchmarking

训练：A2S-SFT + Recov–Recon 动态奖励



① A2S-SFT：从声学到语义

Audio Perception → Sentence Recon. → Joint Fine-tuning

② Recov–Recon 动态奖励

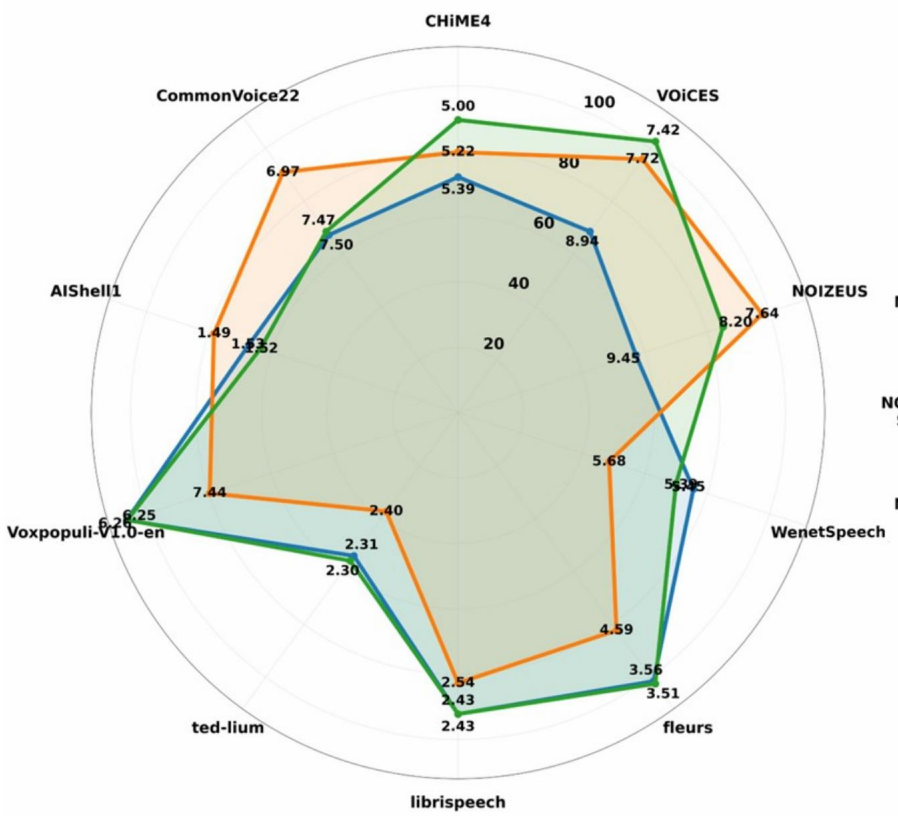
WER < 50% 侧重恢复 $\alpha_{recover}$；> 50% 侧重重建 α_{recon}

③ 词级 + 句级奖励

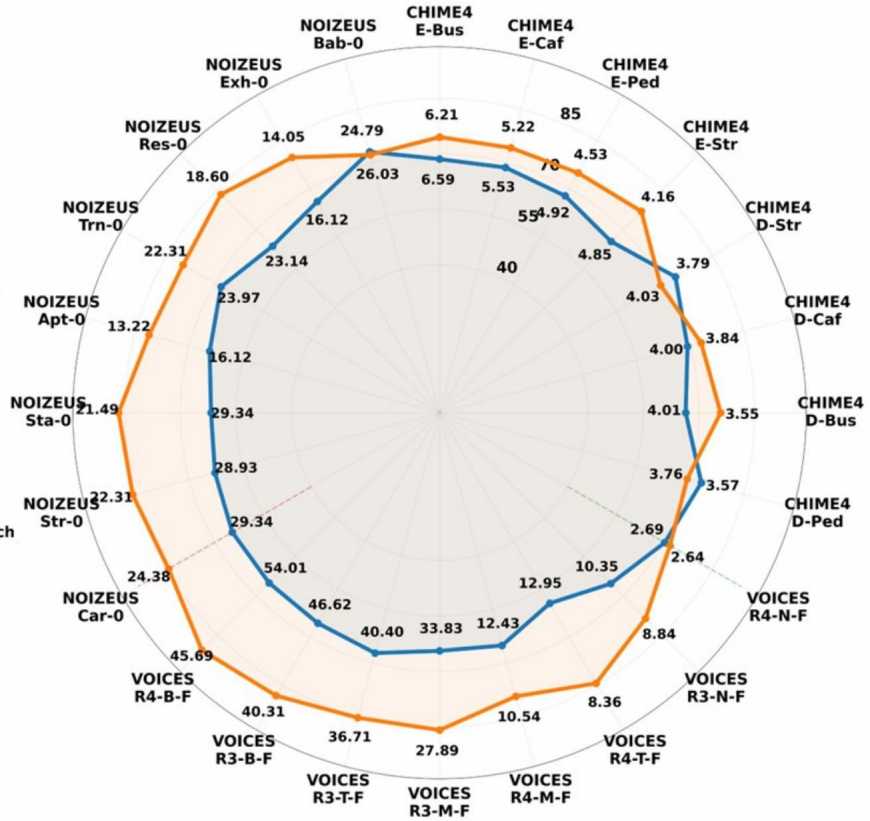
Levenshtein ratio · LCS recall · 长度奖励，按组计算优势

多场景鲁棒性评测

标准测试集 · STANDARD BENCHMARKS



噪声 / 混响 / 远场子集 · CHIME4 · NOIZEUS · VOICES



各测试集 WER（%）对比

FOR MEETINGS AND STUDY

Pask

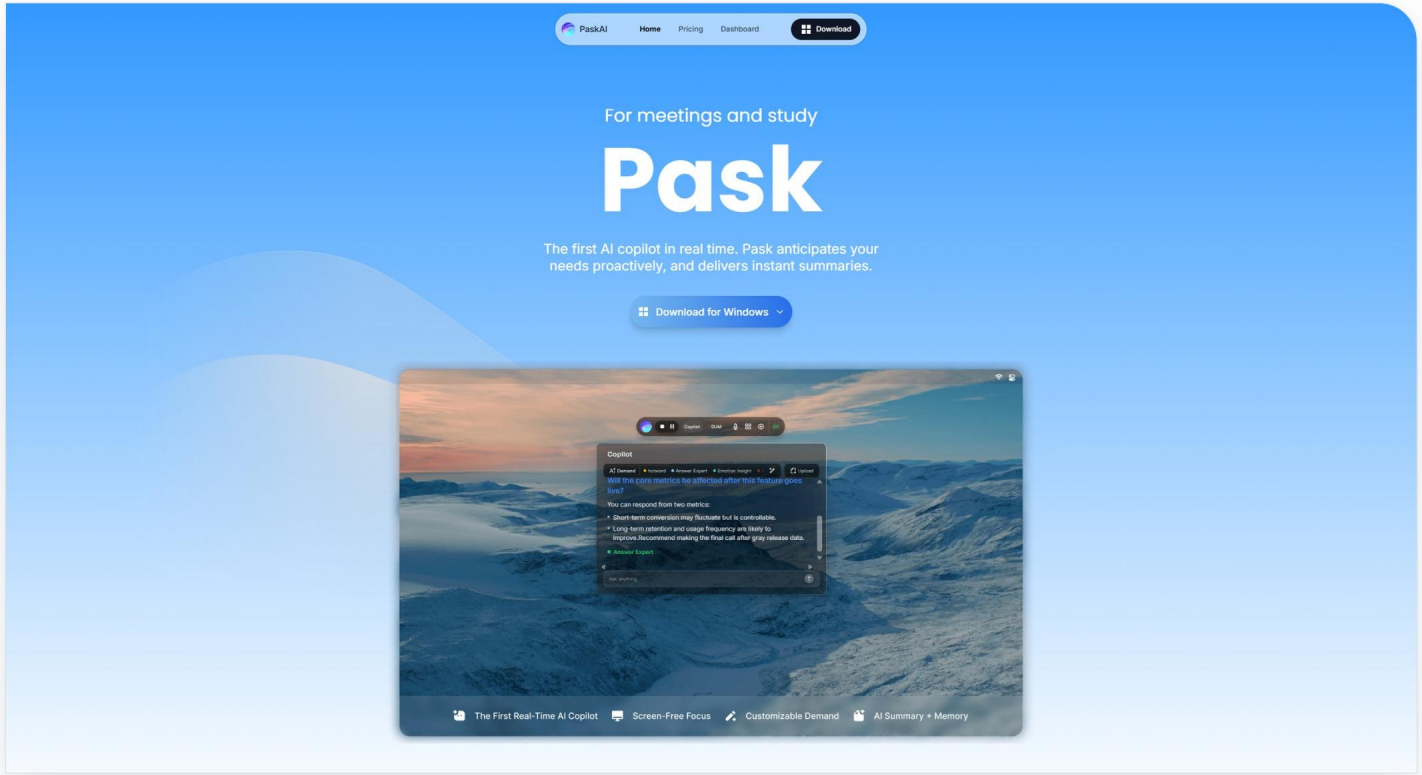
The first AI copilot in real time.

在会议与学习中实时陪伴：主动预判你的需求，并即时给出总结。

Real-time Copilot | Screen-free Focus

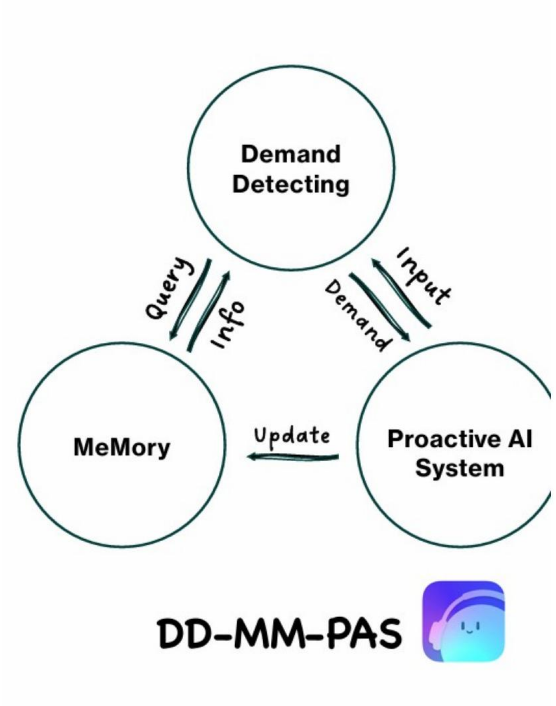
Customizable Demand | AI Summary + Memory

xzf-thu.github.io/Pask



Pask：意图感知的主动 Agent

TOWARD INTENT-AWARE PROACTIVE AGENTS WITH LONG-TERM MEMORY



DD

Demand Detecting

从实时输入中检测用户需求

MM

Memory

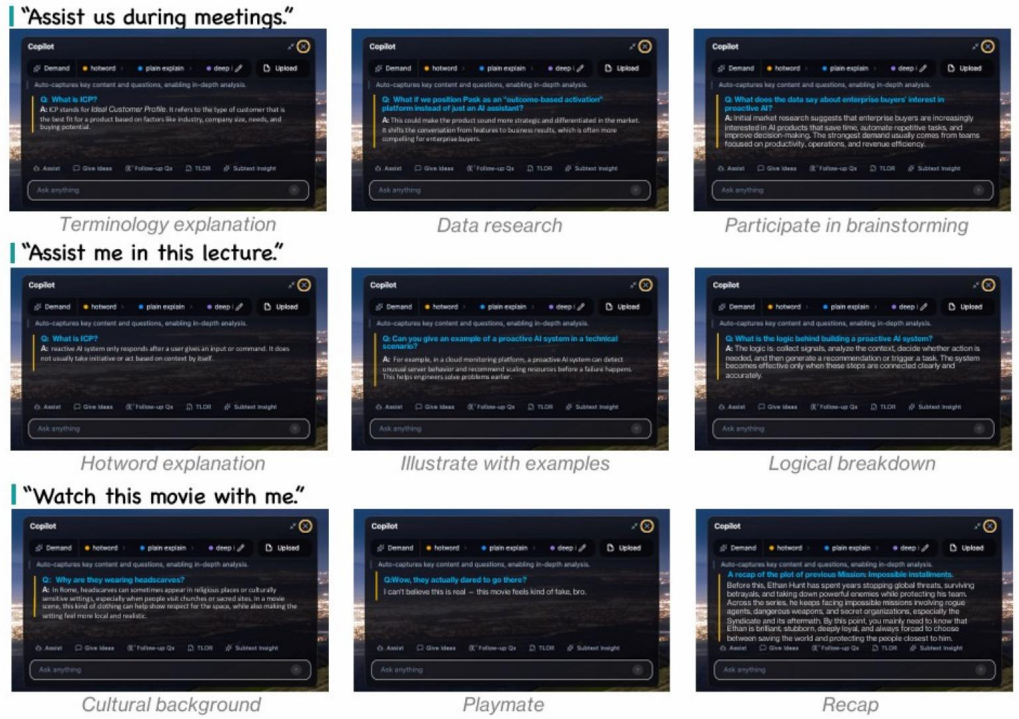
查询与更新长期记忆，补全上下文

PAS

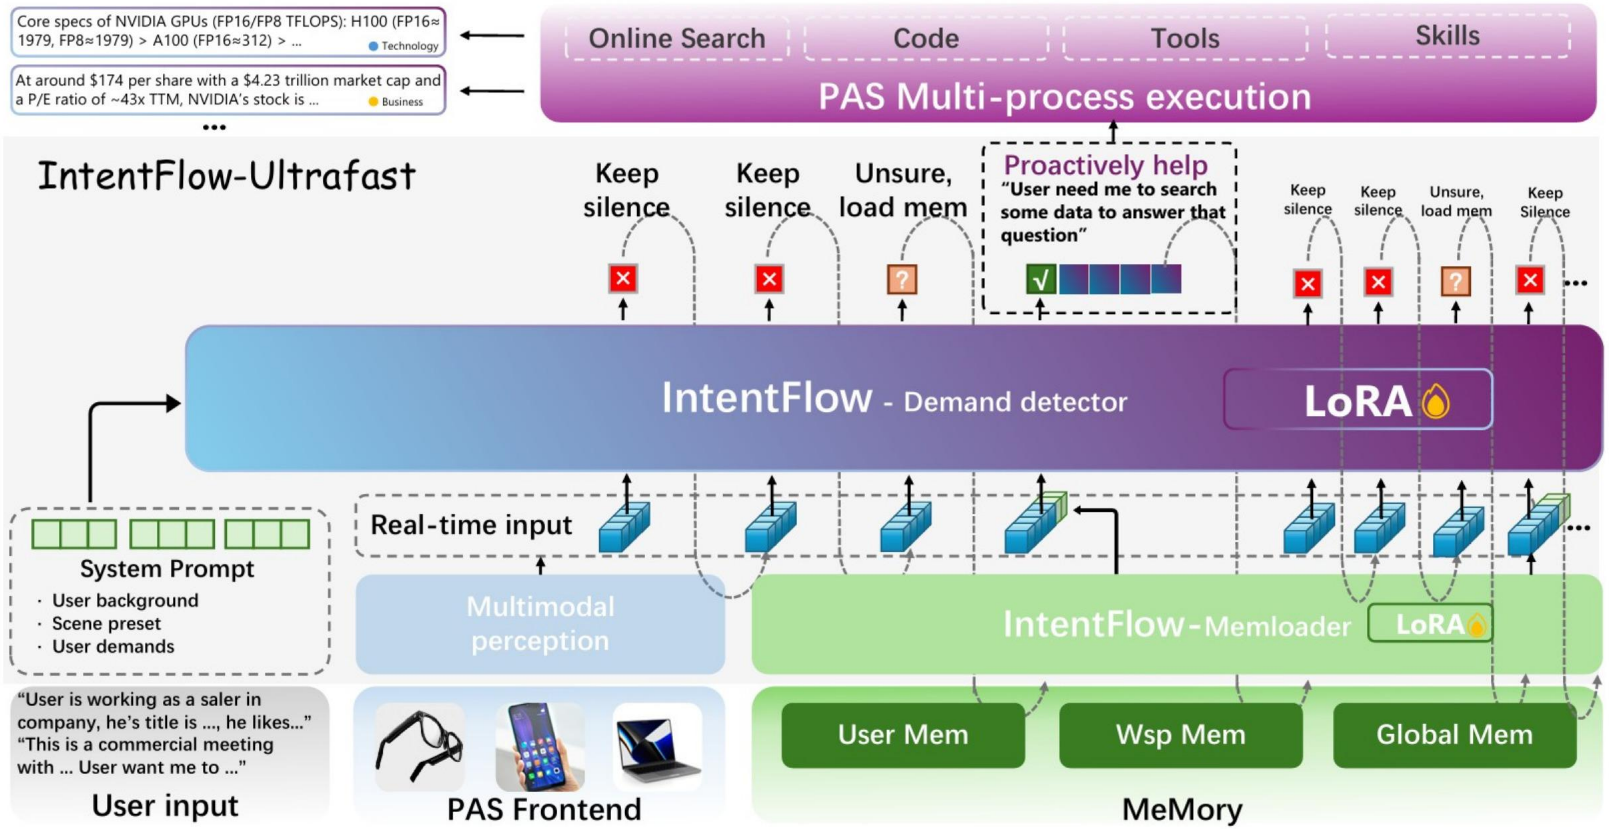
Proactive AI System

感知场景，主动给出帮助

场景 · 会议 / 课堂 / 观影



IntentFlow：实时需求检测 + 记忆 + 多进程执行



1 IntentFlow 需求检测

LoRA 检测器逐段判断：Keep silence / Unsure, load mem / Proactively help

2 Memloader 按需加载记忆

User Mem · Wsp Mem · Global Mem

3 PAS 多进程执行

Online Search · Code · Tools · Skills

4 多终端前端

眼镜 · 手机 · 电脑

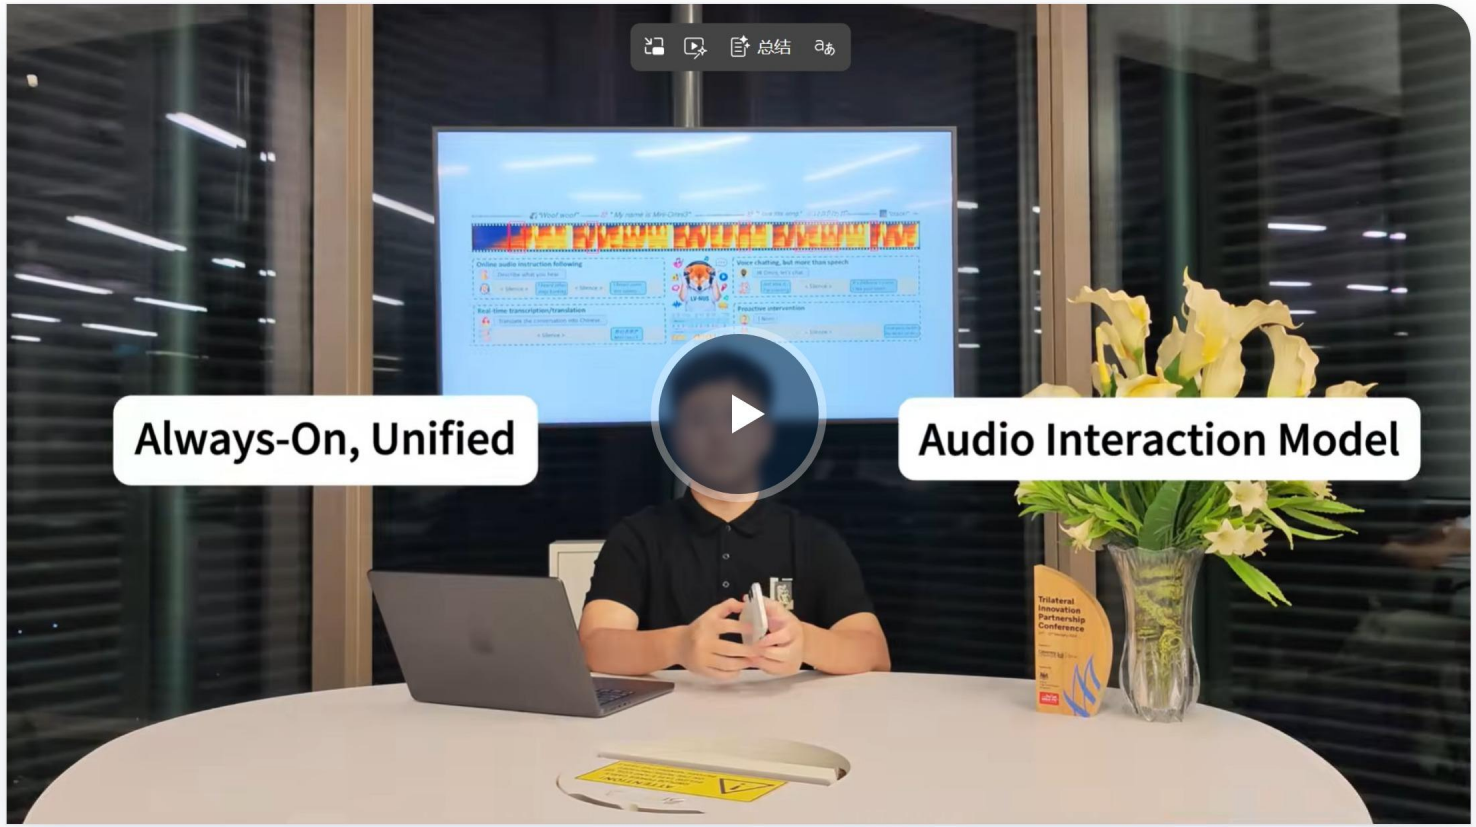
ALWAYS-ON · UNIFIED

Always-On, Unified Audio Interaction Model

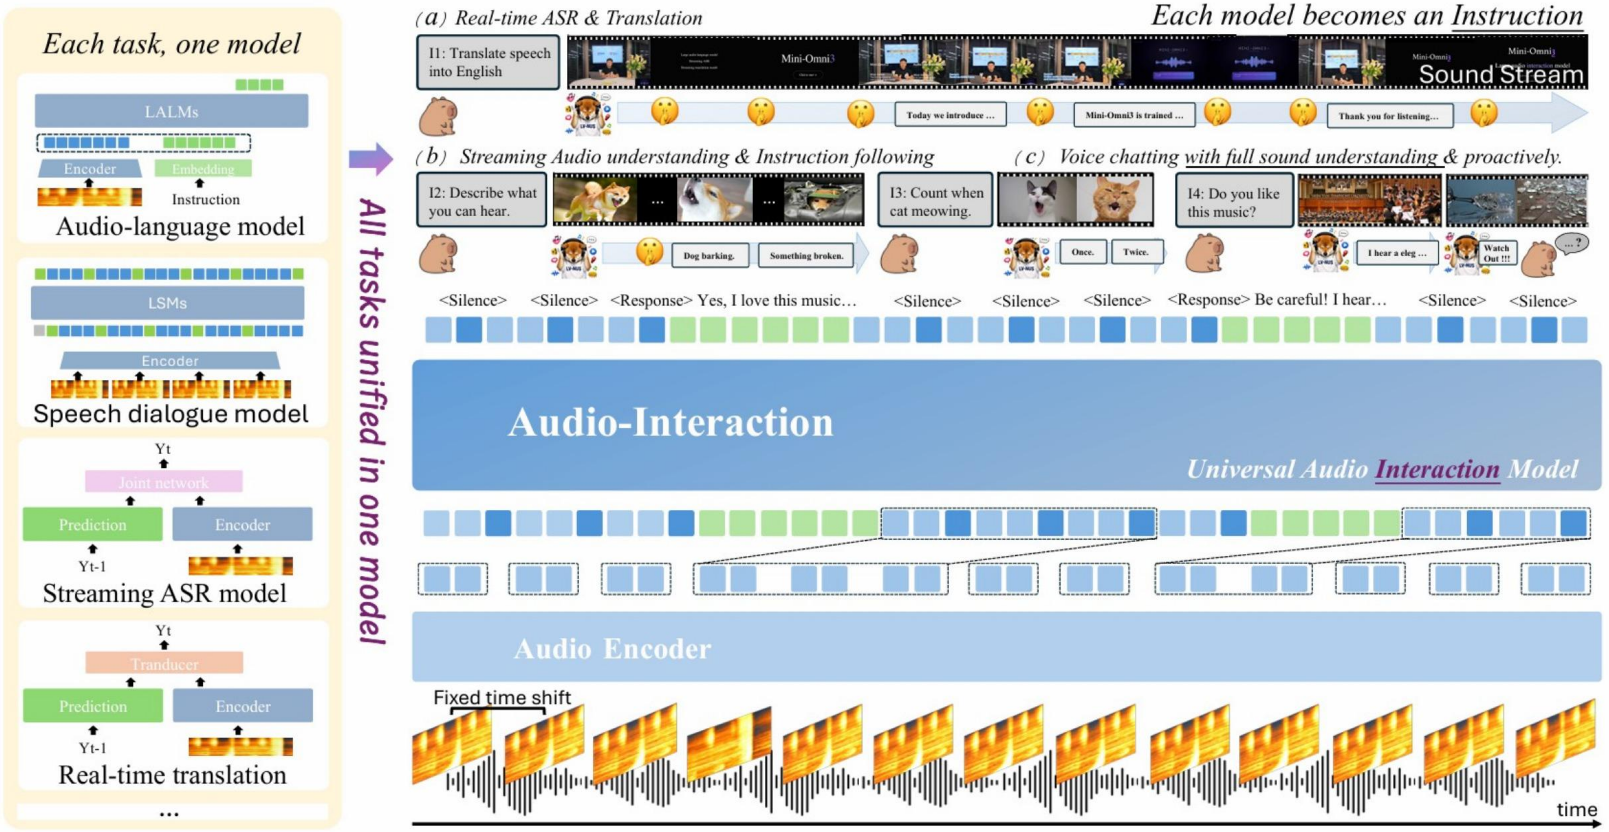
Welcome the era of Audio Interaction Models!

一个始终在线的统一音频模型：持续聆听，实时理解声音与指令，并主动参与对话。

▶ 观看演示视频 · YouTube



一个模型，统一所有音频交互任务



EACH MODEL BECOMES AN INSTRUCTION

(a)

实时识别与翻译

Real-time ASR & Translation

(b)

流式音频理解与指令跟随

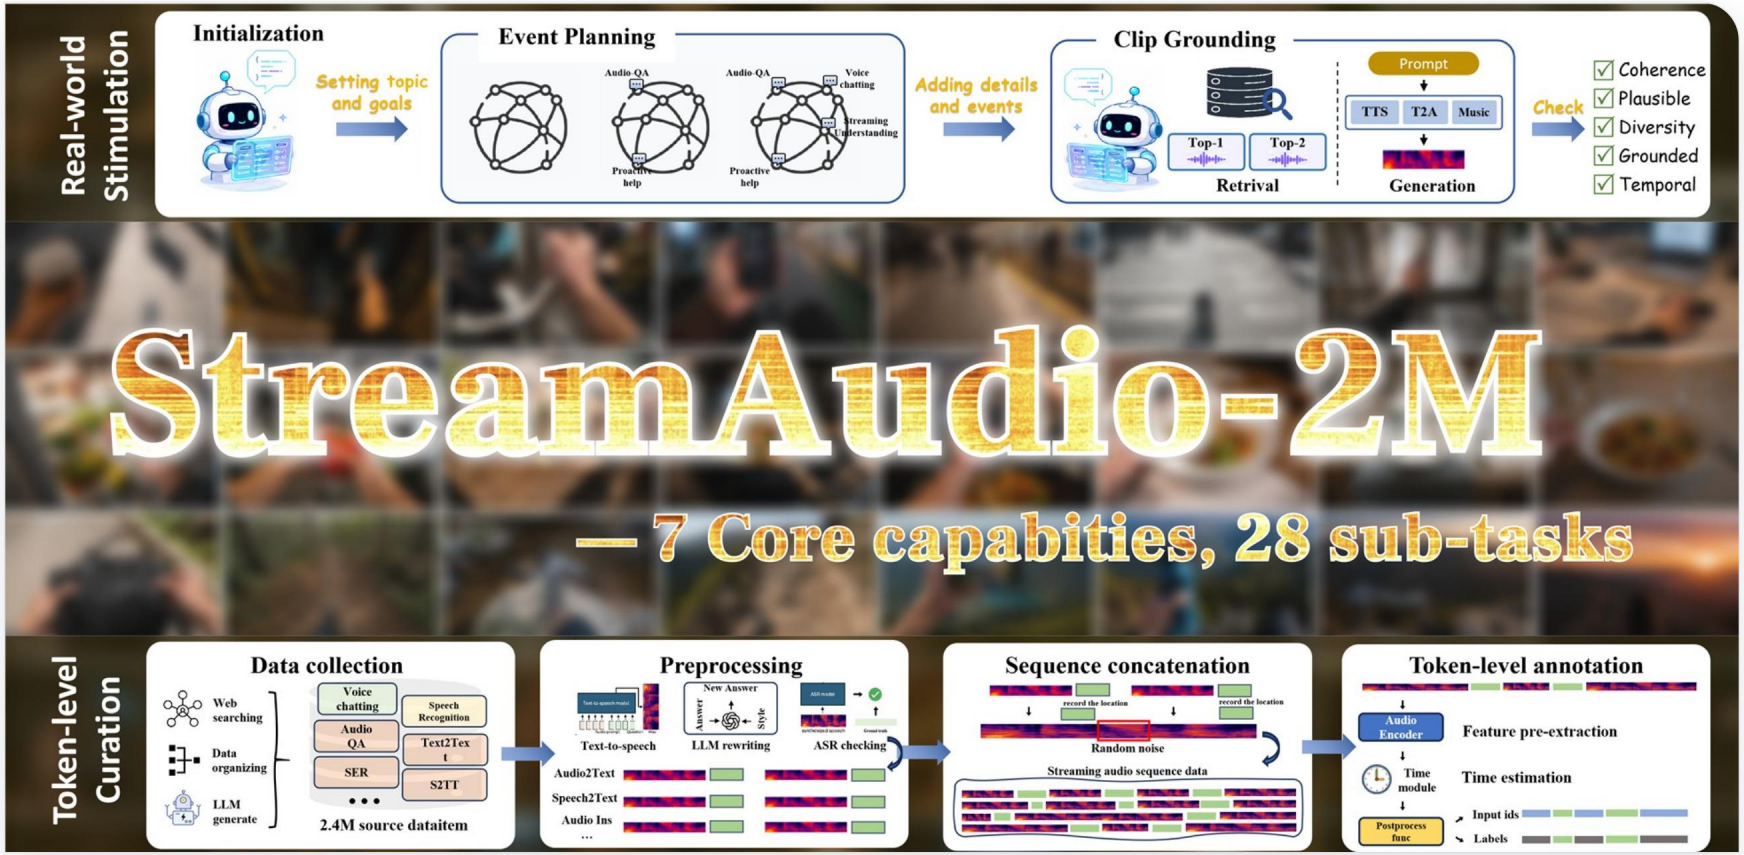
Streaming audio understanding & instruction following

(c)

全声音理解的主动对话

Voice chatting with full sound understanding & proactively

StreamAudio-2M：流式音频交互数据



7

核心能力

core capabilities

28

子任务

sub-tasks

2.4M

源数据条目

source data items

Real-world Stimulation

Token-level Curation

GOSIM

GOSIM Shenzhen 2026

03

Voice Agent

记得住你是谁，也知道何时开口：记忆与可控的类人交互

VoiceMem · 流式双脑记忆

Duplex-Harness · 可控交互



实时交互系统：交互层是关键

RENDERING LAYER

渲染层

语音 + 视觉输出：声音、数字人、幻灯片、程序界面

INTERACTION LAYER = $(\mathcal{D}, H)$

交互层：系统实时的“小脑”

Duplex Module 负责听与说、轮次与打断；Harness 负责控制

VoiceMem 记忆 | Duplex-Harness 控制 | 实时工具调用 | 角色扮演

REASONING & TOOL LAYER

推理与工具层

深度推理、工具执行与返回结果

HUMAN-LIKENESS IS THE NEXT GOAL

不只是听起来像人，而是像人一样对话

说什么	what to say
是否思考或行动	whether to think or act
何时开口	when to speak
如何维持交流	how to sustain an exchange

VoiceMem 让交互层**记得住**，Duplex-Harness 让交互层**可控**。

记忆，让“会回答的助手”变成“懂你的伙伴”。

它既要存下用户说过什么，也要记住**用户是谁** —— 并且快到实时语音 Agent 用得起。

C1 ARCHITECTURE

情感需要自己的记忆

情感常被“附加”在事实库上：能检索，却没人负责修正对这个人的理解。事实会累积，对人的判断会被覆盖。

C2 DENSITY UNDER LATENCY

延迟预算下的密度

语音 Agent 约 1 s 内就要发出首帧，常见记忆检索要 2–3 s。只能取 top-3~5，精度必须来自检索前的候选密度。

~1 s 首帧预算 **2–3 s** 典型检索

C3 EVOLVABILITY

可演化，且不丢声音

存储后端与对话模型都在快速迭代；只存转写文本，会丢掉语音独有的信息：谁在说、怎么说、周围发生了什么。



VoiceMem：流式双脑记忆

左脑 · 信息脑 INFORMATION BRAIN

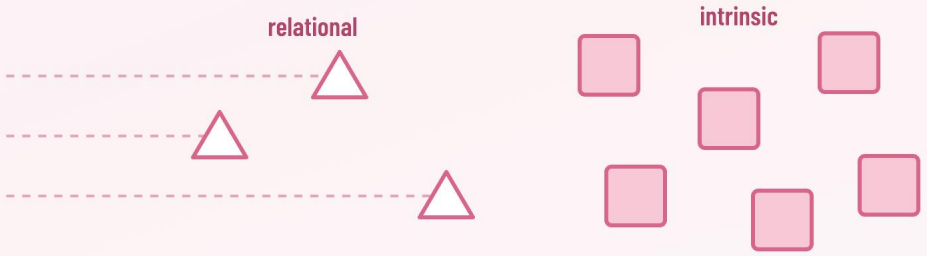


Schema–Entity 两级图 schema 是语义簇中心，entity 是具体的人、事件、概念

Schema 涌现 用系统自己的查询流量，发现应当独立成 schema 的子图

Graph over graph 原始记忆留在 Mem0 / Zep / 向量库等后端，索引在其之上

右脑 · 人格脑 PERSONA BRAIN



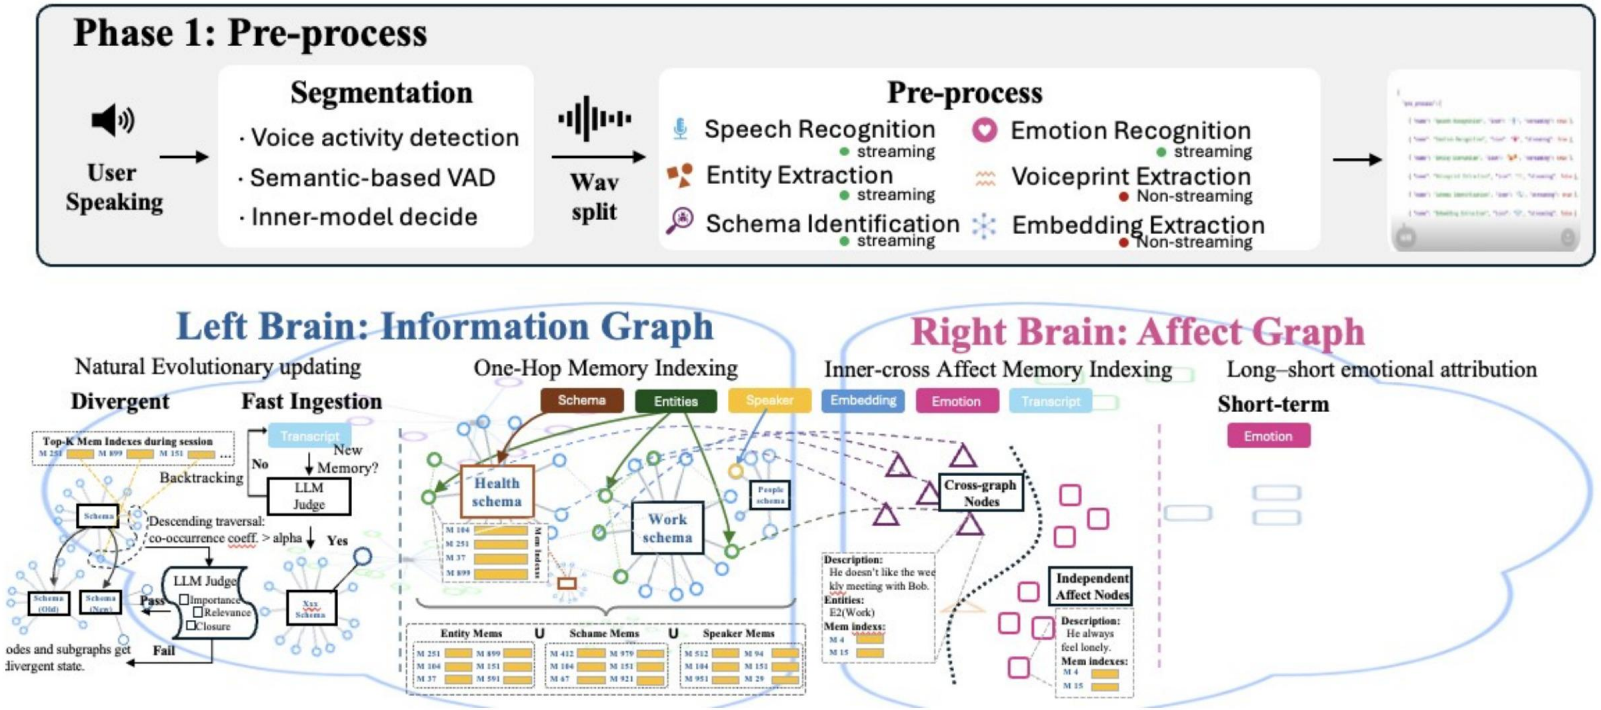
扁平图 intrinsic 节点记录性格与情感特质，relational 节点记录对左脑实体的感受

快慢两级归因 每轮快速更新 + 每会话慢速修正，对人的判断可被覆盖

Audio Node voiceprint · embedding · waveform 三级音频证据挂在实体上

STREAMING 转写、实体识别、schema 匹配、声纹提取都在聆听窗口内完成

边听边记：流式写入与检索



Phase 1 预处理 → 左脑信息图（一跳索引、自然演化）＋ 右脑情感图（跨图情感索引、长短期情感归因）

1 切分 Segmentation

Voice activity detection · Semantic VAD · Inner-model decide

2 流式预处理

语音识别 · 实体抽取 · Schema 识别 · 情感识别，随语音同步进行

3 声学证据

声纹与 embedding 提取，补全“谁在说、怎么说”

4 说话时就完成检索

每轮一次写入决策，只注入 Top-K 条记忆

VoiceMem 结果：更准、更省、更快

LOCOMO ACCURACY (%)



69.44% **PersonaMem**
个性化记忆基准

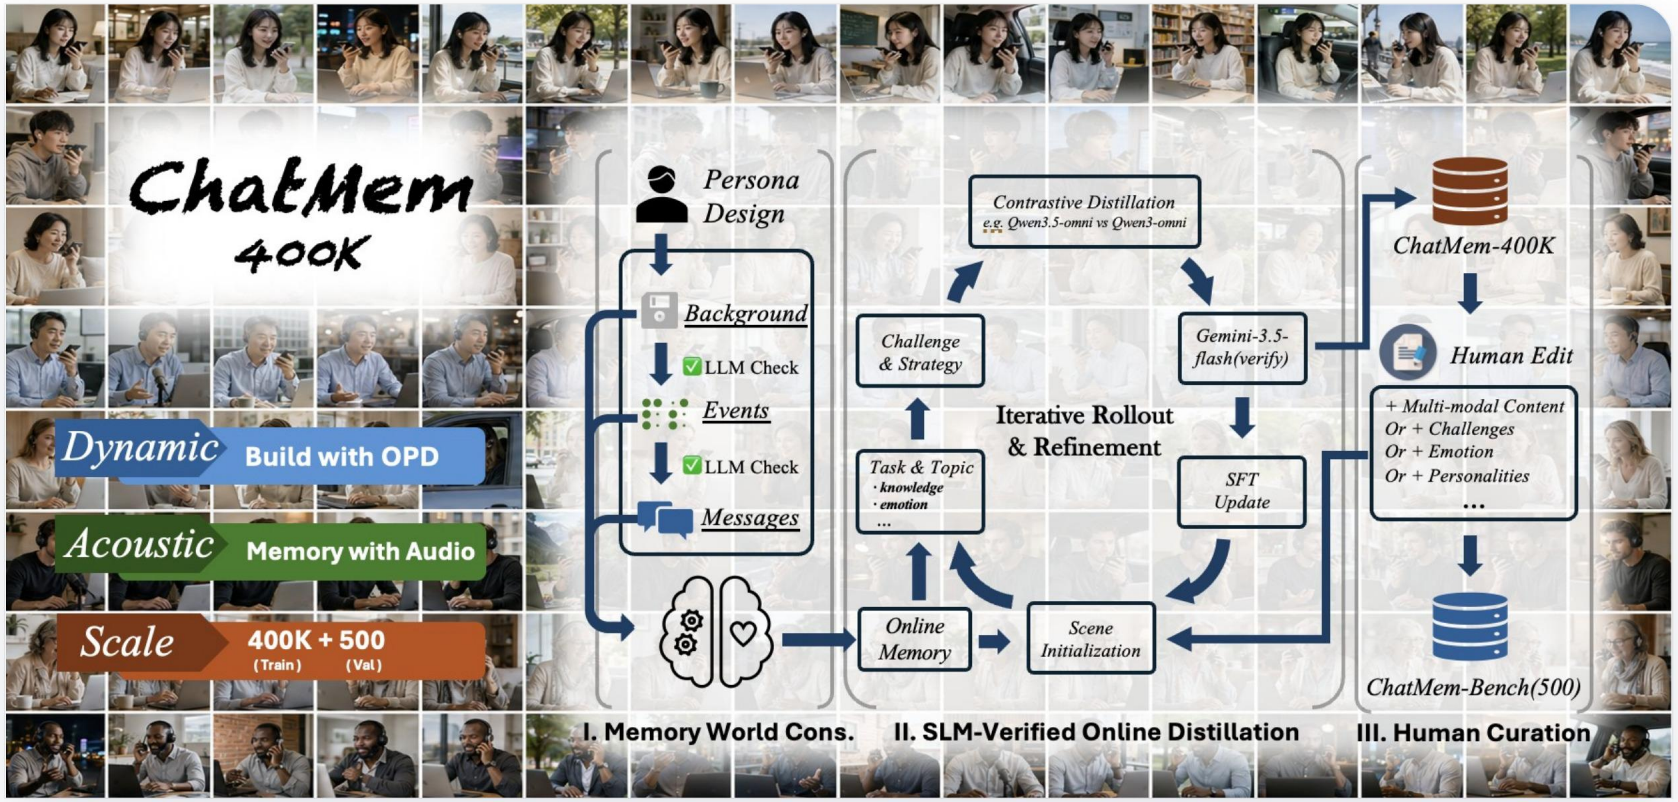
134 ms **检索延迟**
Mem0 1,440 ms · Full-Context 17,120 ms

430 **LoCoMo 记忆 token**
Mem0 6,956 · EverMemOS 1,899

K=5 **只注入 Top-5 条记忆**
Mem0 top-200 · Zep / LangMem top-100 · EverMemOS top-10

数据来源：xzf-thu.github.io/VoiceMem

ChatMem-400K：教语音模型主动调用记忆



400K

训练对话

ChatMem-400K

500

人工校验评测集

ChatMem-Bench

Online on-policy distillation

在线同策略蒸馏，训练 Qwen2.5-Omni · Qwen3-Omni · Step-Audio2-Mini 主动调用记忆

Duplex-Harness：可控性是核心挑战

END-TO-END

端到端语音模型

感知与生成耦合：学习重叠语音、打断、风格与回复时机；通过扩大参数换取更高质量。

Moshi　Mini-Omni2　SteerDuplex

CASCADED

级联系统

仍是应用中的主流：通过显式的组件接口换取稳定与控制。

LiveKit　Pipecat

Controllability：高质量语音 + 稳定交互 + 应用可引导

两条路线平行发展，真正的挑战是在整段对话中保持可控

把 LLM Agent 的 Harness 带进语音交互　Skills　ReAct • Tools　Memory → Voice Harness



语音动作空间 × 四个 Harness

$$\mathcal{A}_{\text{speech}} = \{\ \textbf{Speak, Think or Act, Naturalness, Interactivity}\ \}$$

Speak 说什么

Persona & Task Harness

角色、任务目标、数据与记忆、说话风格、决策逻辑，整合成一致的对话配置

Think or Act 是否思考或行动

Mode Harness

在快速回应、上下文回答、深度推理与外部执行之间路由，并跟踪挂起的请求

Duplex Module

$\mathcal{D} = (S, A, N, I)$

Naturalness 何时开口

Naturalness Harness

被动 backchannel、主动等待、语义确认与轮末静默

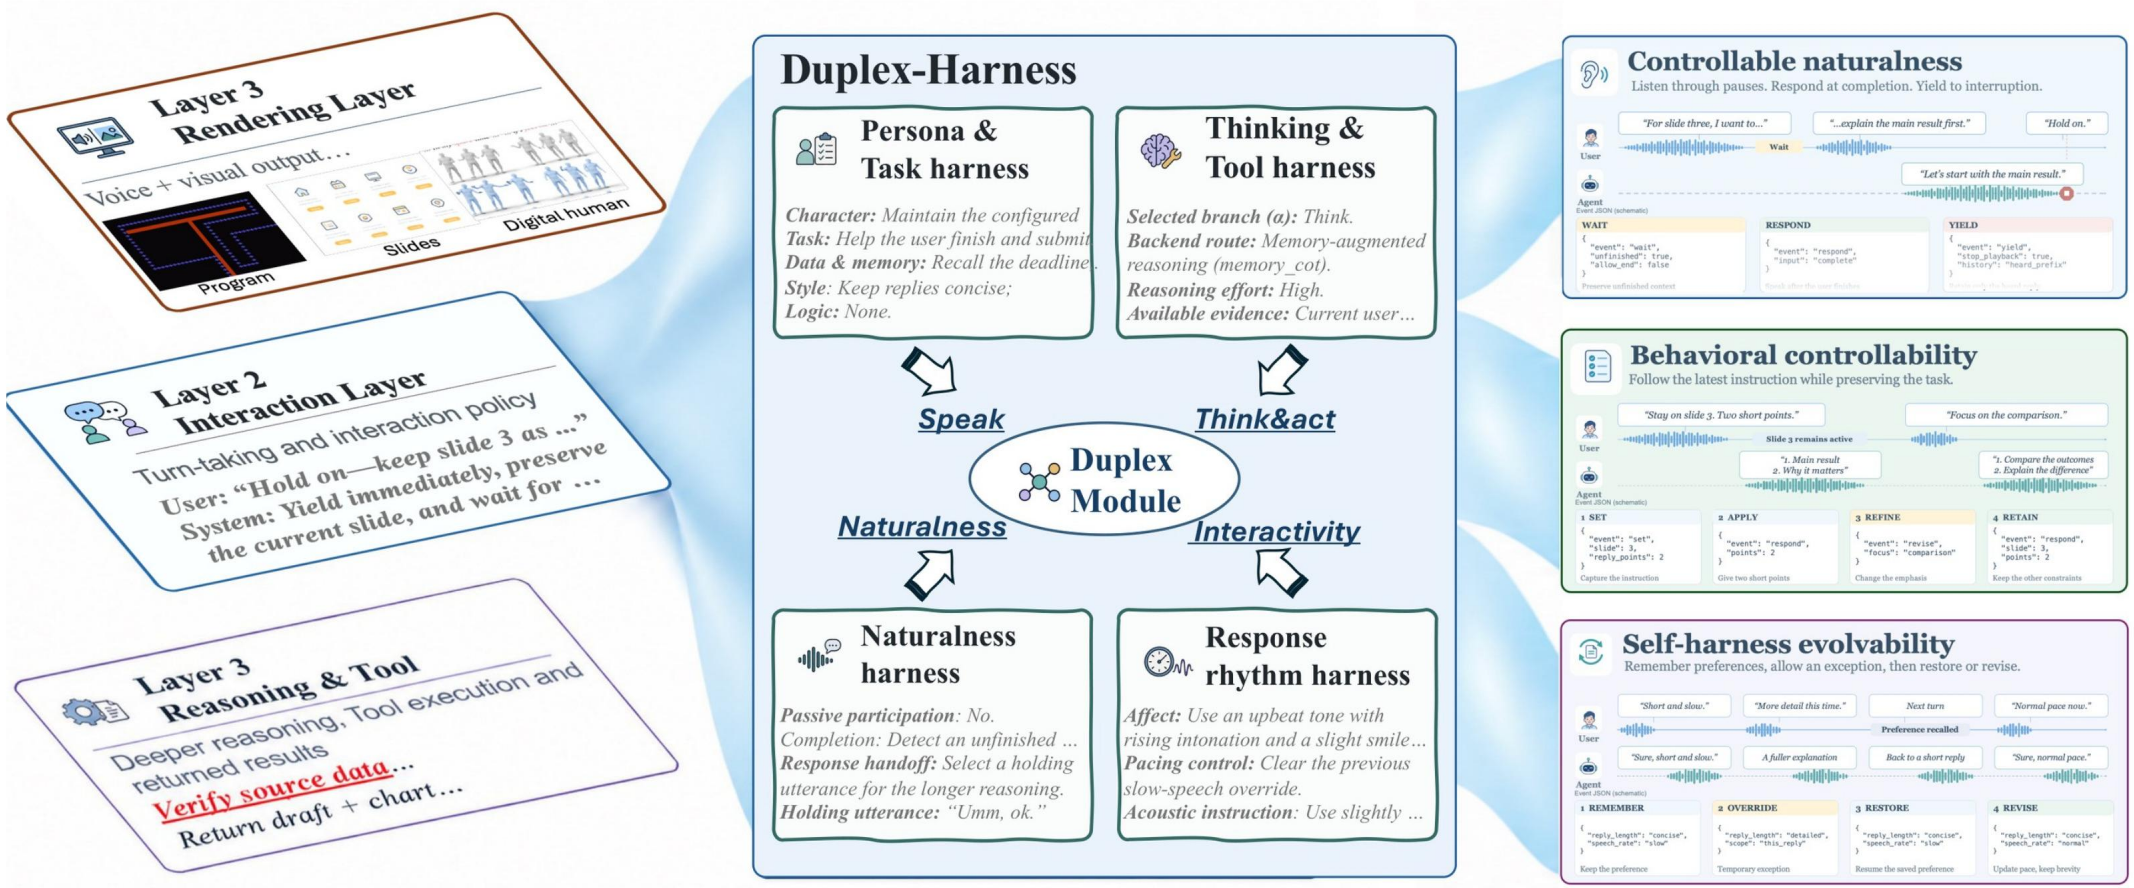
Interactivity 如何维持交流

Long-Term Rhythm Harness

回应节奏、跨轮内容变化与情感表达

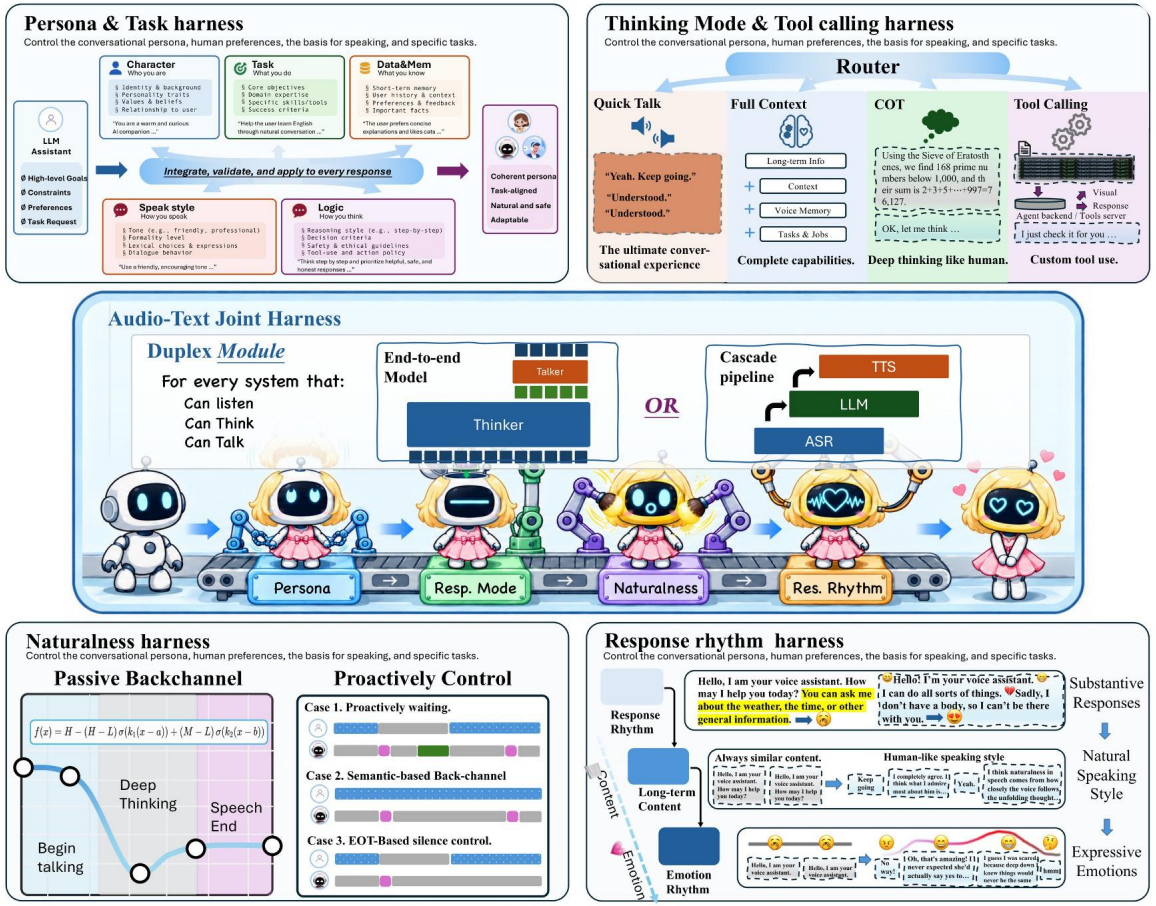
每个干预都可以在其作用域内保留、修改或释放，同时保持持久的承诺

Duplex-Harness 系统总览



Duplex-Harness 包裹统一的 Duplex Module，同时支持端到端模型与级联系统

四个 Harness 如何工作



Persona & Task

Character · Task · Data & Mem · Speak style · Logic：整合、校验，并作用于每一次回复

Mode · Router

Quick Talk · Full Context · CoT · Tool Calling；进入思考分支时可以先说一句 “Let me think”

Naturalness

被动 backchannel + 主动控制：主动等待、语义 backchannel、基于 EOT 的静默控制 —— 语义未完整时可以压过声学端点

Long-Term Rhythm

句内组织、跨轮内容推进与情感节奏：同一内容可以有不同的节奏与情感表达

VoiceMem-Studio：会自我调整的 Harness

AUDIO-TEXT JOINT HARNESS

1 一套 Harness，多种后端

GPT Realtime · Qwen Realtime · Seed Realtime 等原生语音模型，与 GPT-4o 级联共用同一控制接口

2 Self-Harness

根据用户的口头反馈与记住的偏好，在会话中自适应调整交互配置

3 作用域化的修改与释放

持久的承诺被保留，临时的约束到期后自动释放



Duplex-Harness 结果

RQ1 · 可控的自然度

51.9–62.1%

平均响应延迟下降

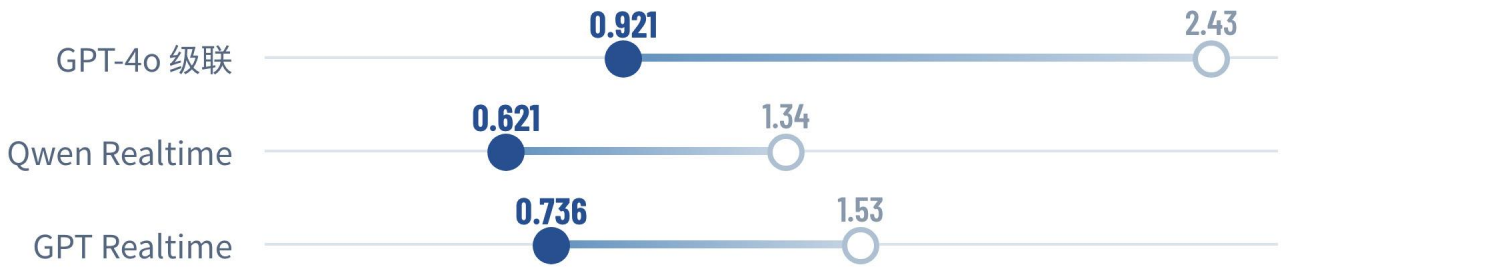
人声停顿处抢话

18.2% → 5.2% GPT-4o 级联

语音自然度（5 分制）

4.0 → 4.5 GPT-4o 级联

RESPONSE DELAY (S) ↓



RQ2 行为可控 · RQ3 反馈自适应

IFEval 指令跟随
GPT Realtime
68.1 → **75.9**

BFCL 多工具选择
Qwen Realtime
65.5 → **70.1**

六轮反馈成功率
GPT Realtime · 固定策略→动态
54.2 → **83.3**

六轮反馈成功率
Seed Realtime · 固定策略→动态
62.5 → **100**

基于所评测子集；数据来自 Duplex-Harness 论文

OpenInteraction

+ 新对话

设置

我的空间

你能帮我写一个贪吃蛇游戏。

你能帮我写一个贪吃蛇游戏。

Kimi

要写一个可玩的贪吃蛇，键盘控制移动，吃食物变长，撞墙或撞自己结束，附分数和重开，开始吧？

嗯，行，开始吧。

Kimi

好，开始做。

你能帮我写一个贪吃蛇游戏。确认的任务理解：要写一个可玩的贪吃蛇，键盘控制移动，吃食物变长，撞墙或撞自己结束，附分数和重开 补充要求（优先）：嗯，行，开始吧。

好，开始做。

使用我选择入



GOSIM

GOSIM Shenzhen 2026

Thanks!

Q&A

