GOSIM®
GLOBAL OPEN-SOURCE INNOVATION MEETUP

GOSIM Shenzhen 2026

Topic

Jiuwen Agent Memory记忆系统

Jiuwen Agent Memory System



赵靖文 Jingwen Zhao

openJiuwen技术专家

openJiuwen Technical Expert, Huawei

openJiuwen Agent-Memory 记忆发布介绍

华为-泊松实验室
赵靖文



Security Level:

HUAWEI

Memory

记忆关键技术与规划

记忆趋势和挑战

典型应用场景

HUAWEI

智能系统范式迁移与记忆演进阶段

记忆等级

初级: 单次预测准确性
(Next Token Prediction)
- 通过LSTM（长短期记忆网络）完成一次任务工具，无状态推理，参数简单。

中级：感知与注意力
(Next Task Prediction)
- 通过Attention自注意力机制 + 1M上下文窗口，具备推理泛化能力。

高级:个性化/经验/可进化
(Mulit Task collaboration)
- 记忆操作系统，服务化单独部署，通过多模态长短期记忆、情景与语义记忆，实现情景与用户偏好持续性记忆，历史经验沉淀，指导智能体行为纠偏。

Now

卓越: 记忆自主进化
(Complete Tasks independently)
- 通过经验蒸馏与 RL 自验证，把技能、偏好与“如何记忆的策略”内化进参数，从调用记忆进化为成为记忆，行为随使用持续自我进化。

数据飞轮等级	L1：Stateless ML	L2：Context-Centric	L3：Memory-Centric	L4： Weight-Centric
记忆能力	无状态模型	推理上下文	**理解上下文，持续进化系统**	记忆内化到模型权重
核心技术	LSTM	Attention、Transformer、**RAG**	**多模态，Dreaming，分层，演进**	**参数记忆**、RL 、蒸馏
关注点	失忆	上下文爆炸、个性化	失忆、迁移、治理	推理效率、长上下文
演进目标	预测下一个token	单智能体完成任务	多智能体协同，沉淀经验	AGI自主执行，指导决策

Huawei Proprietary - Restricted Distribution

让AI从“第一次见面”到“认识你”，记忆系统的六大攻坚方向



Huawei Proprietary - Restricted Distribution

知识和技能可以把事情做对，记忆让事情做得更好

以教学和考试为例

日常教学依靠知识与技能，保障大多数学生学会

保障班级平均分下限

日常教学依靠统一知识与标准化技能，把正确内容
稳定传递给大多数学生。

知识 提供正确内容

技能 保障规模教学

大多数学生学会

共性问题得到稳定解决

教学效果

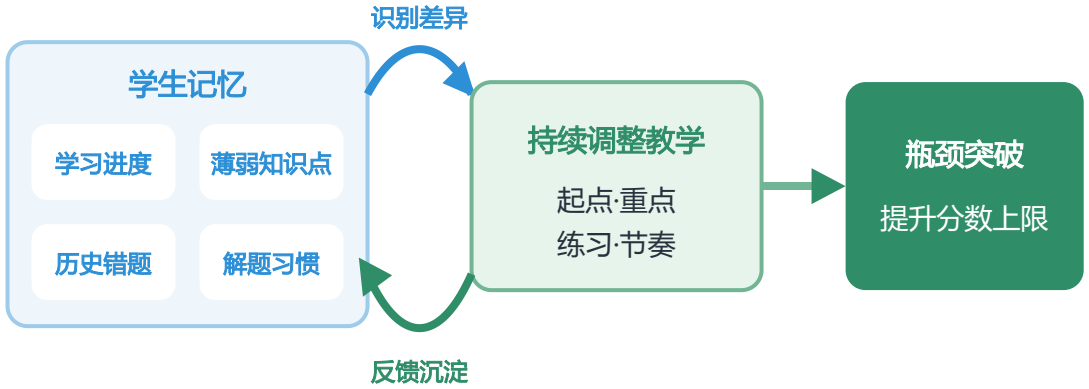
采用标准教学内容、标准方法和统一进度，
解决大多数学生的共性问题，保障平均教学质量。

影响的是教学质量下限

课后辅导利用对学生的记忆，帮助学生突破学习上限

提高班级平均分上限

在相同知识与技能基础上，课后辅导利用学生记忆
识别个体差异，持续调整教学策略。



教学效果

记忆让教学从服务大多数人的共性需求，
走向适配具体学生的个性化提升。

补齐学生短板，拔高学生长版，影响的是教学质量上限

记忆不是对知识与技能的替代，而是建立在正确交付之上的个性化增益。

记忆服务赛道全景：五家标杆产品，从"能存"到"场景专精"，迈向"全能规模化应用"

mem0 通用记忆层	OpenViking 上下文数据库	TD Agent Memory 团队级记忆 Hub	MemOS 记忆操作系统	ReMe 模块化记忆工具包
GITHUB mem0ai/mem0	GITHUB volcengine/OpenViking	GITHUB TencentCloud/...	GITHUB MemTensor/MemOS	GITHUB agentscope-ai/ReMe
STARS ~46k	STARS ~15.8k	STARS ~15k+	STARS ~4.8k	STARS ~1.8k
LoCoMo 基准 92.5% (官方)	LoCoMo 基准 80-83%	LoCoMo 基准 —	LoCoMo 基准 88.83%	LoCoMo 基准 86.23%
TOKEN 效率 <7K tokens/查询	TOKEN 效率 降低 80-91%	TOKEN 效率 节省 61.38%	TOKEN 效率 节省 35-72%	TOKEN 效率 99.5% 压缩率
发起方 · 协议 mem0ai (YC S24) Apache 2.0	发起方 · 协议 字节跳动 Apache 2.0	发起方 · 协议 腾讯云 MIT	发起方 · 协议 MemTensor Apache 2.0	发起方 · 协议 阿里 AgentScope 未明确

核心洞察 KEY INSIGHTS

1 **场景分化，分层定位**

记忆服务按场景分层分化，专用化与通用化并存。

不同产品聚焦不同粒度：从通用记忆层到上下文数据库，从团队级 Hub 到操作系统，市场正在快速细分。

2 **大厂重仓入局，端到端自研整合**

巨头自研 Agent 与记忆，只有深度耦合，才能跑出极致效率。

字节、腾讯、阿里等大厂纷纷布局，记忆能力成为 Agent 平台的核心竞争力。

3 **热度 ≠ 实力，评测共识未定**

社区热度与评测分数无法直接等同，行业标准有待建立。

Stars 数量不代表技术实力，LoCoMo 等基准测试方法论尚不统一，需审慎看待各类排名。

4 **Token 效率已成生存门槛**

极致降本从产品亮点演变为规模化落地的核心前提。

从 99.5% 压缩率到 80-91% 降低，Token 效率已成为产品能否规模化落地的关键指标。

主流记忆系统测评覆盖情况：测评集分散、标准未统一，六维度透视产品各有所长



评估维度	数据来源基准	Mem0	MemOS	Tencent	OpenVikingt	ReMet
显式事实检索	LoCoMo Single-hop	**91.2**	78.44[†v1]	76.0[P]	82.5[L]	89.89[*]
多跳组合推理	LoCoMo Multi-hop / HotpotQA	**91.3**	64.30[†v1]	50.0[~]	91.0[H]	82.98[*]
时序事件推理	LoCoMo Temporal	**92**	73.21[†v1]	45.0[~]	82.5[L]	83.80[*]
长上下文记忆	LongMemEval / BEAM / RAG平均	**94.4**	89.2	85.2[‡]	66.9[R]	89.4
个性化能力	AML维度E / PersonaMem	55.29[A]	48.73[A]	**76.0[P]**	55.0[~]	58.0[~]
生态成熟度	Stars/SDK/存储/集成/部署（归一化）	**95**	60	55	50	45

结论

Mem0 强在"准"，MemOS 强在"全"，腾讯强在"规"，OpenViking 强在"省"，ReMe 强在"明"

每款记忆产品都在解决特定场景问题，没有一统天下

记忆系统是体系化服务，除了基础能力外，也要考虑运行态成本、性能等评价

标注说明：
[A]=AML官方数据；[P]=PersonaMem；[L]=LoCoMo总体；
[H]=HotpotQA；[R]=5数据集RAG平均；[‡]=Hy-Memory官方数据；
[†v1]=MemOS v1论文数据；
[*]=ReMe早期LoCoMo版本成绩；[~]=基于公开信息估算参考值。
绿色为该行最高值。

Huawei Proprietary - Restricted Distribution

Memory

记忆趋势和挑战

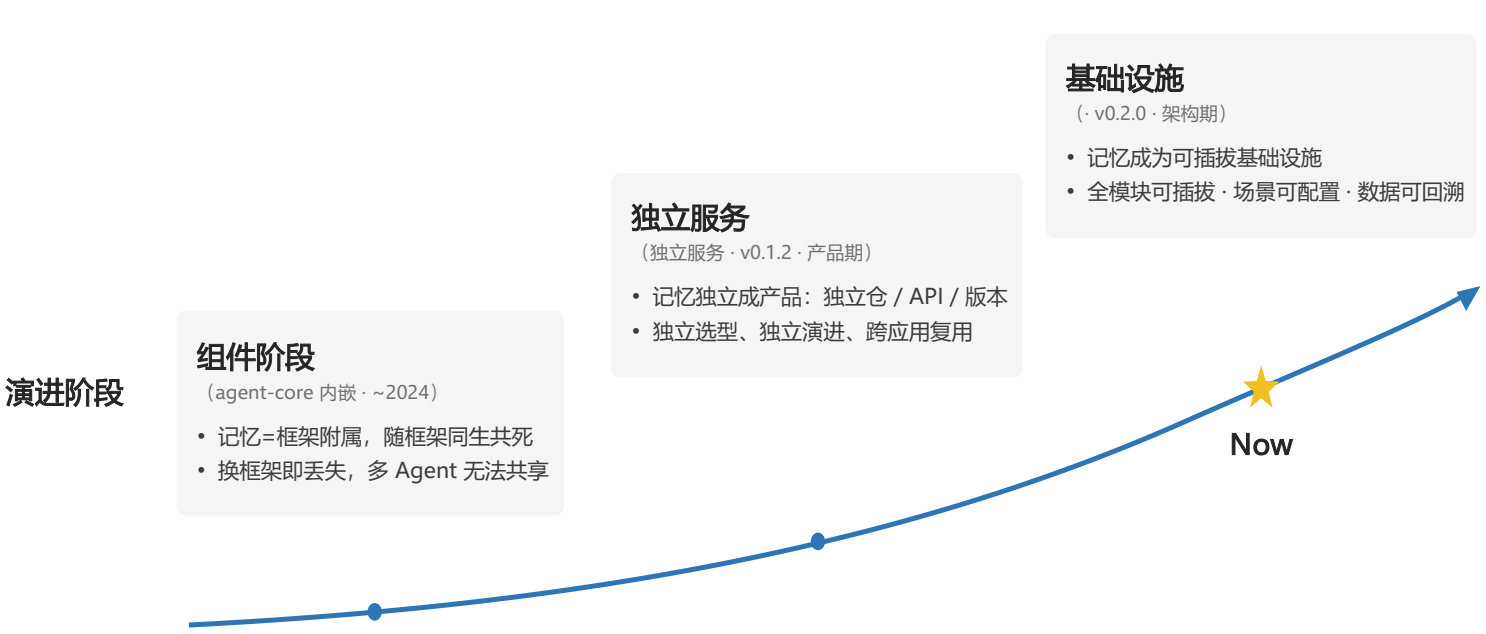
记忆关键技术与规划

典型应用场景

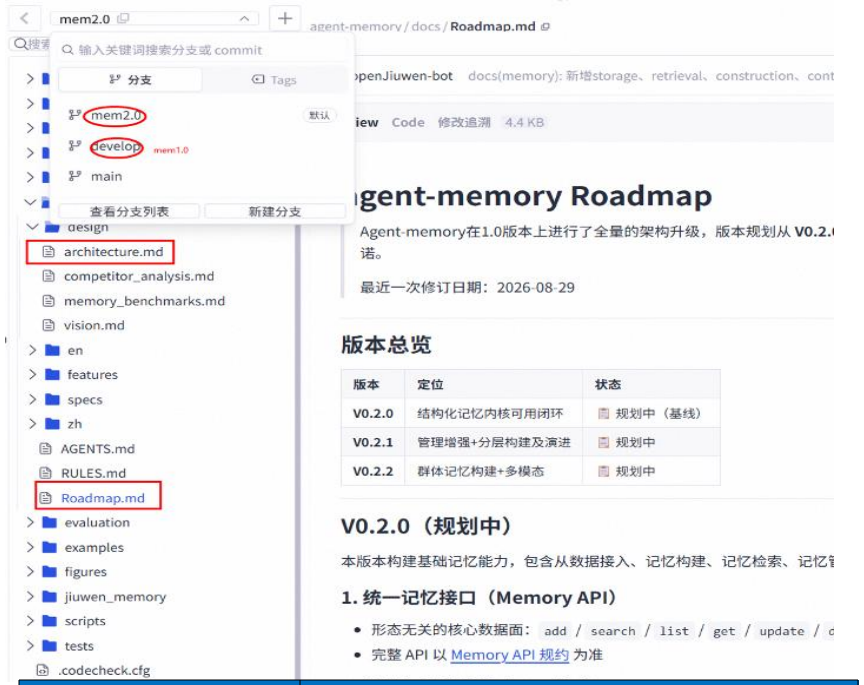
HUAWEI

Agent Memory 演进与版本特性规划：1.0版本不再演进，9月开始牵引客户使用2.0

- **Agent-Memory 2.0版本：主推版本。**mem2.0分支，第一个Beta版本已发布，用户可POC
- **Agent-Memory 1.0版本：收编版本。**develop分支，9月2日发布最后一个**v0.1.2版本后不再演进**，已使用客户后续需牵引客户切换2.0（目前已知仅银联客户使用）。



	S1： agent-core 组件	S2：Memory 1.0	S3：Memory 2.0
记忆形态	框架附属功能	独立记忆产品	**可插拔基础设施**
驱动力	上下文爆炸	Mem0、 MemOS等市场形态驱动	**工程天花板驱动**
架构	内嵌 agent-core 子模块	独立 FastAPI 服务 · 手写单体	**AI原生 · 7 层单向依赖 · 214 处自注册**
客户价值	基础存储 / 检索	换框架也能带走记忆	**定制人月→人天 · 历史可回溯**



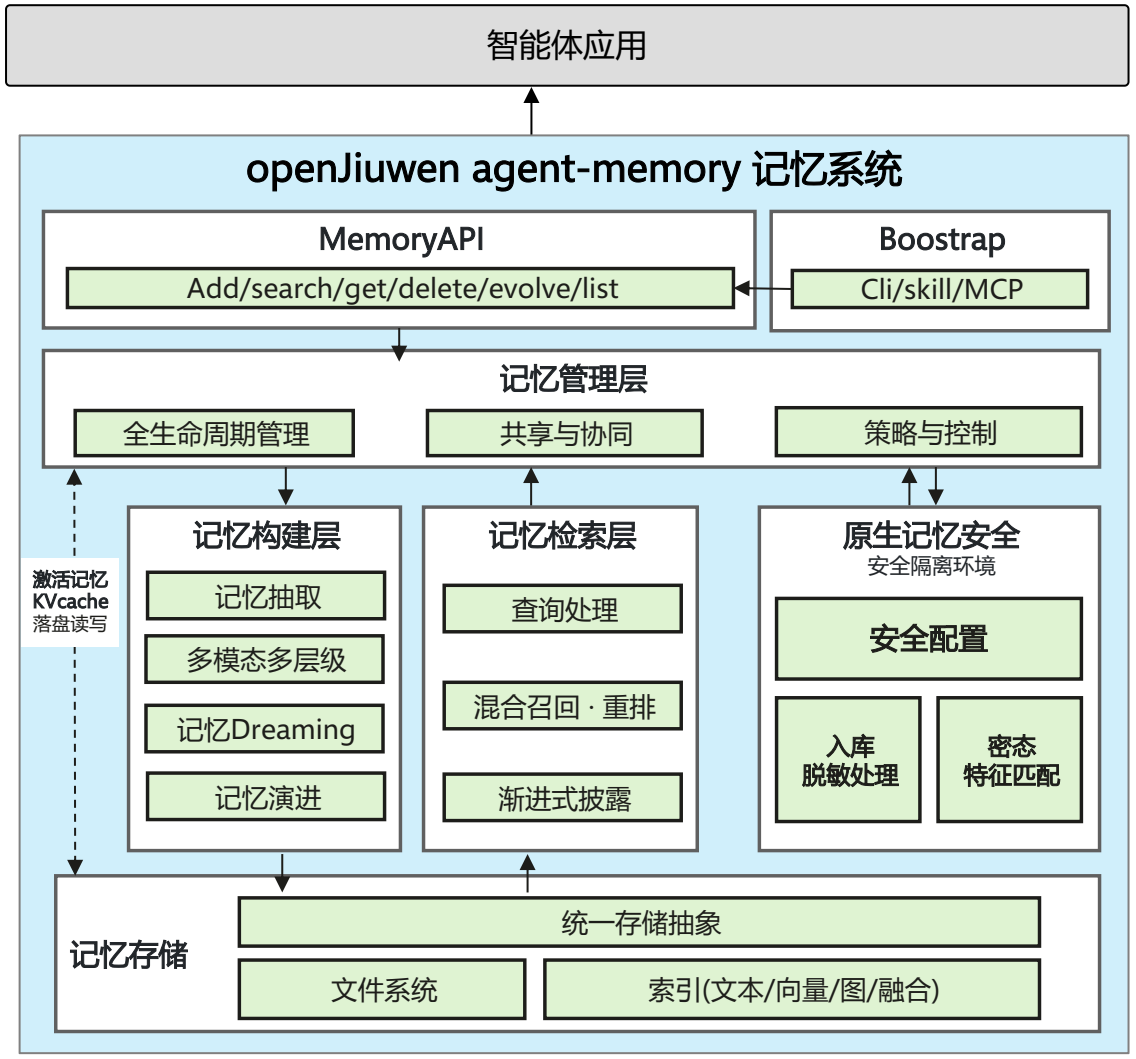
功能	价值
全模块可插拔	"你的场景特殊？换实现，不改内核——定制成本从'改源码'降到'写一个类'"
场景预设 + 四级配置	"既能全、也能轻：POC 用默认栈零依赖跑通，生产按 yml 裁剪，成本按场景付"
双时间	"改了不丢：任何时点的有效记忆可回溯——审计与合规的硬需求"
Scope 五维 + PEP + AES256	"多租户硬隔离 + 入口鉴权 + 加密绑数据，Security by Design 而非事后加开关"

https://gitcode.com/openJiuwen/agent-memory/blob/mem2.0/docs/Roadmap.md

1.0 证明了“记忆值得独立”；2.0 让记忆以可插拔、可演进、AI 可维护的方式真正独立

Agent记忆系统设计及关键技术

整体目标：打造以用户为中心，高精准、高性能、安全、可配置的Agent记忆系统



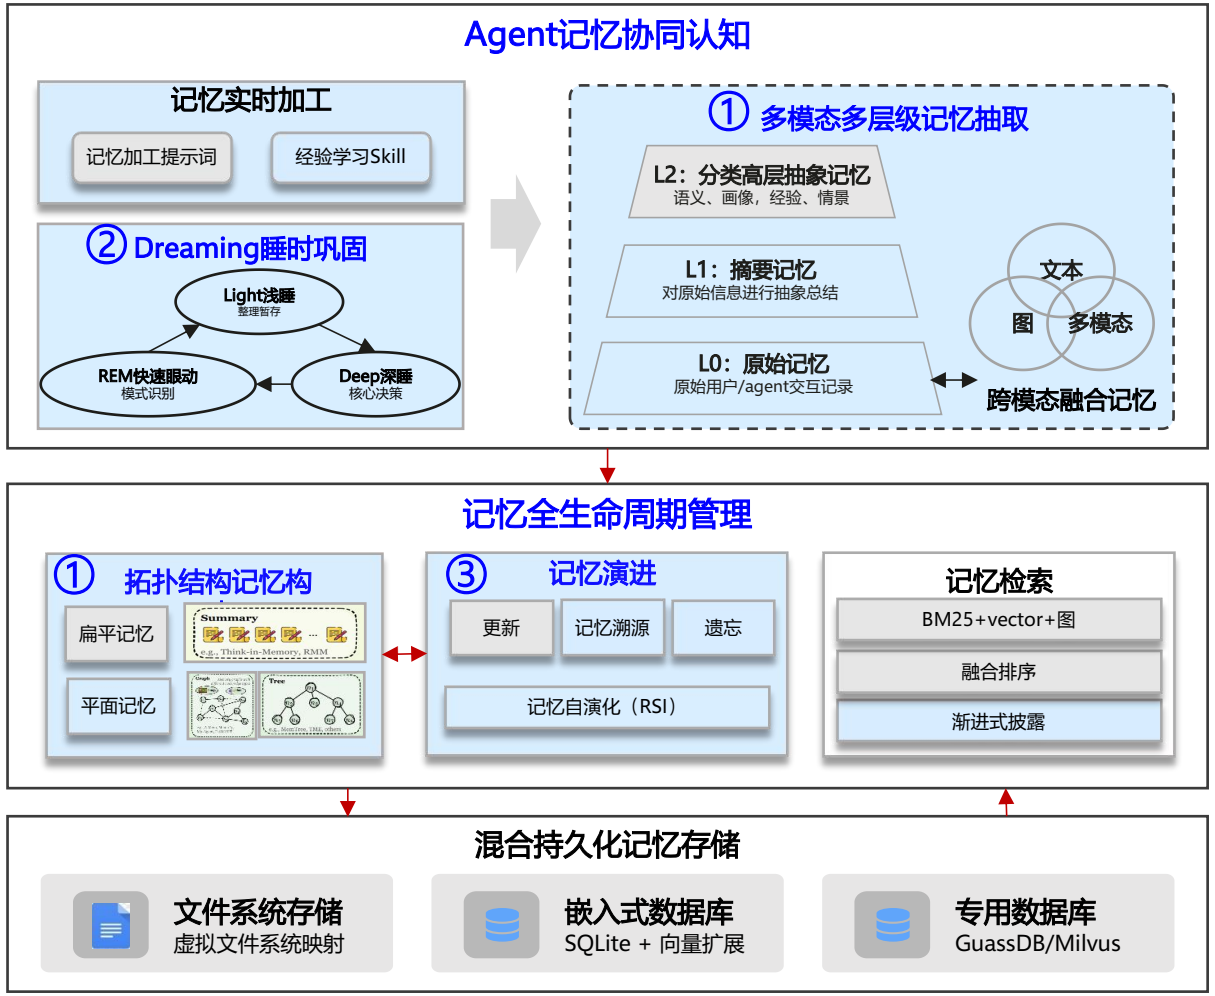
关键竞争力

- **高精准**
  - **多模态多层级记忆构建:** 覆盖语义、程序、情景、用户等四类典型记忆类别的提取、分析，及多种索引形式（关键词/向量/图/融合/文档）构建
  - **时间层级记忆索引：**支持按照时间维度构建分层记忆抽象及逐层渐进式检索，实现跨会话长时查询准确率90%。
  - **可溯源记忆演进：**支持按照上下文、热点关联、用户反馈等多种方式触发记忆dreaming能力，实现记忆的演进。
  - **多模wiki文档记忆：**支持多模态文档记忆，并支持多视图构建及渐进式关联检索
- **高性能：**通过表征推理加速、索引检索加速、异步调度与关联匹配合并，实现实时记忆响应，记忆构建token消耗和时延降低>50%，检索时延<=200ms
- **安全保障：**支持权限管理、全局审计、数据加密等多重安全保障机制
- **可配置性:** 支持”Pipeline+预置算子”形式开箱即用，也可根据场景配置算子，并支持算子二次开发。

Huawei Proprietary - Restricted Distribution

记忆构建：多模态多层级记忆构建+Auto Dreaming+记忆演进，保障记忆精准

技术方案



场景挑战

- 个人终端伴随态等场景中涉及**多模态记忆**的构建与检索，同时需要支持**语义关联、多跳推理**
- 用户的使用习惯、事实、偏好、最优执行路径等需要进行**统一结构化建模**
- 真实场景中，用户表达往往短促离散、**长期偏好稀疏且多为隐性信号**，导致用户记忆构建困难

关键竞争力

① **多模态多层级记忆构建**：支持多模态信息输入，对用户记忆采用情景–语义-用户画像多重认知建模，记忆构建准确率90%；构建多层次异构记忆拓扑架构（图形/树形），在多跳推理、关系约束复杂任务场景下提升记忆检索准确率20% 。

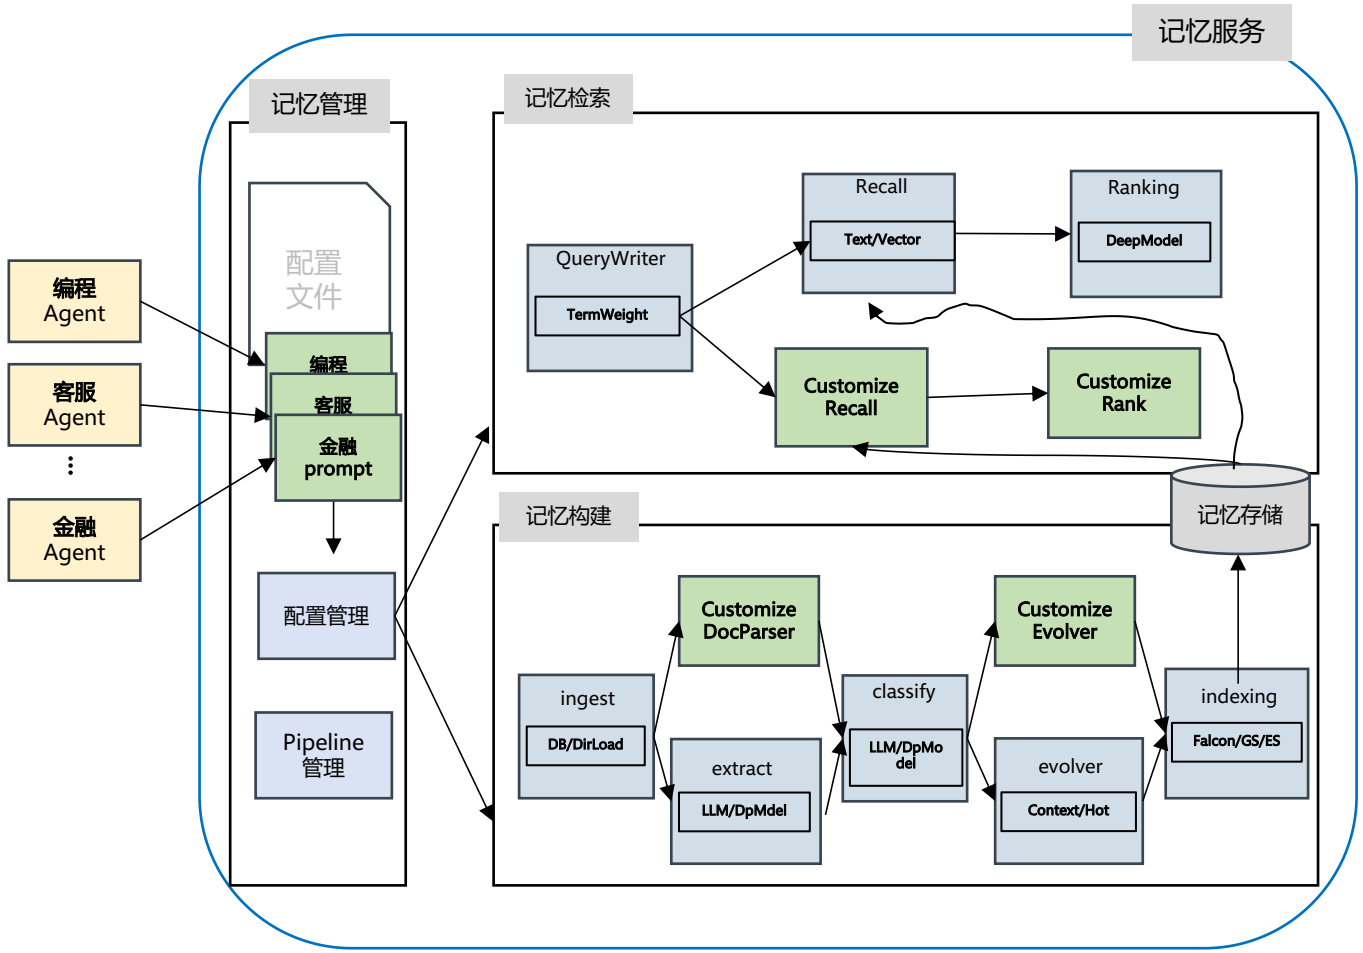
② **Dreaming睡时巩固机制**：通过Light/Deep/REM三阶段协作，对日间记忆片段进行自动化筛选与权重评估，将高频激活、反复检索的关键信息进行固化整理，完成向长时记忆体系的层级升格

③ **记忆演进**： 主动识别冲突进行消解与记忆更新，使Agent长期记忆从孤立条目堆积，演化为持续自洽、完善的知识；基于git式记忆管理，实现记忆溯源；自动提炼可复用、可迭代的程序经验/Skill，实现递归自我改进。

HUAWEI

场景可配置：三层能力递进 · 四种接入形态 · 五类场景全覆盖

技术方案



场景挑战

现有记忆系统用一套通用提示词覆盖所有场景，本质是取“**最小公约数**”存在三大缺陷：

- **注意力冲突**：代码、情绪、条款共用同一提示词，注意力被稀释，关键信息丢失。
- **质量方差大**：熟悉场景 90% 准确率，陌生场景骤降至 30%；提示词膨胀，80% 指令是冗余。
- **无法热加载**：场景切换必须重启，无法按需切换记忆注意力。

最终：编程记不住函数名，客服记不住情绪，金融记不住条款——记忆服务无法规模使用。

关键竞争力

① **算子级可插拔**：通过**策略模式、工厂自注册设计**，将记忆的全生命周期拆解为六个独立算子接口

② **Prompt 热加载**：根据场景自定义提示词，提升业务**记忆的注意力**聚焦能力，热加载生效并覆盖默认配置

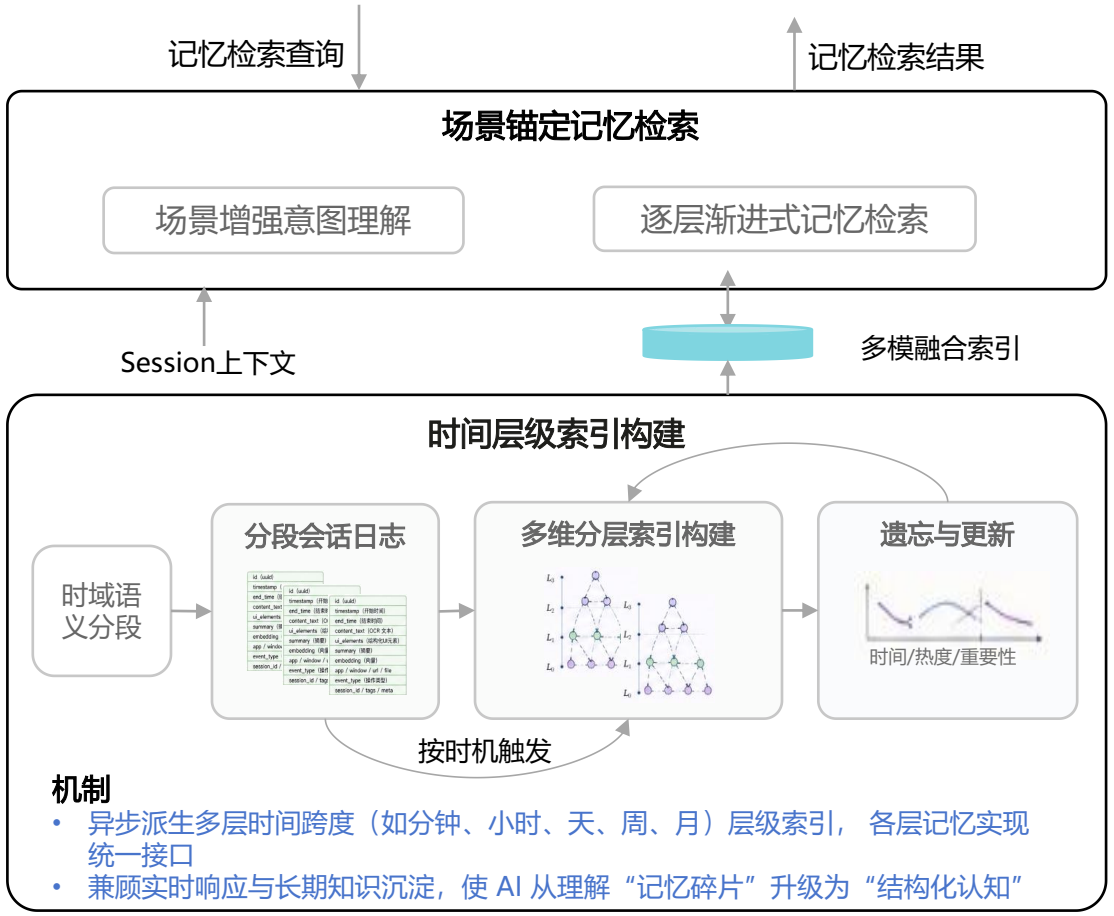
③ **场景化路由**：Pipeline 按记忆类型路由自动分流到不同算子产线

④ **两级命名空间配置**：从全局默认到调用级 options 逐层就近覆盖，空白即默认，用户只写要改的

⑤ **运行时策略动态调整**：PolicyManager 支持运行时查询/调整可变配置

时间层级记忆索引：按照时间维度构建分层记忆抽象及逐层渐进式检索，实现跨会话长时查询准确率90%，token降低10%

技术方案



机制

- 异步派生多层时间跨度（如分钟、小时、天、周、月）层级索引， 各层记忆实现统一接口
- 兼顾实时响应与长期知识沉淀，使 AI 从理解“记忆碎片”升级为“结构化认知”

场景挑战

业界记忆系统多采用“语义/情景/程序/用户”等传统记忆分类及抽象， **缺乏时间维度的记忆抽象**，对跨会话长时查询需检索**大量零散、长时跨度、跨类别**的相关记忆：

- 大量噪声记忆，有效信息占比低，导致准确率低
- 需将大量候选结果送入LLM, 导致**token消耗大**，时延高。
- 归纳推理理解弱，难以准确定位关键时间段与事件演化

关键竞争力

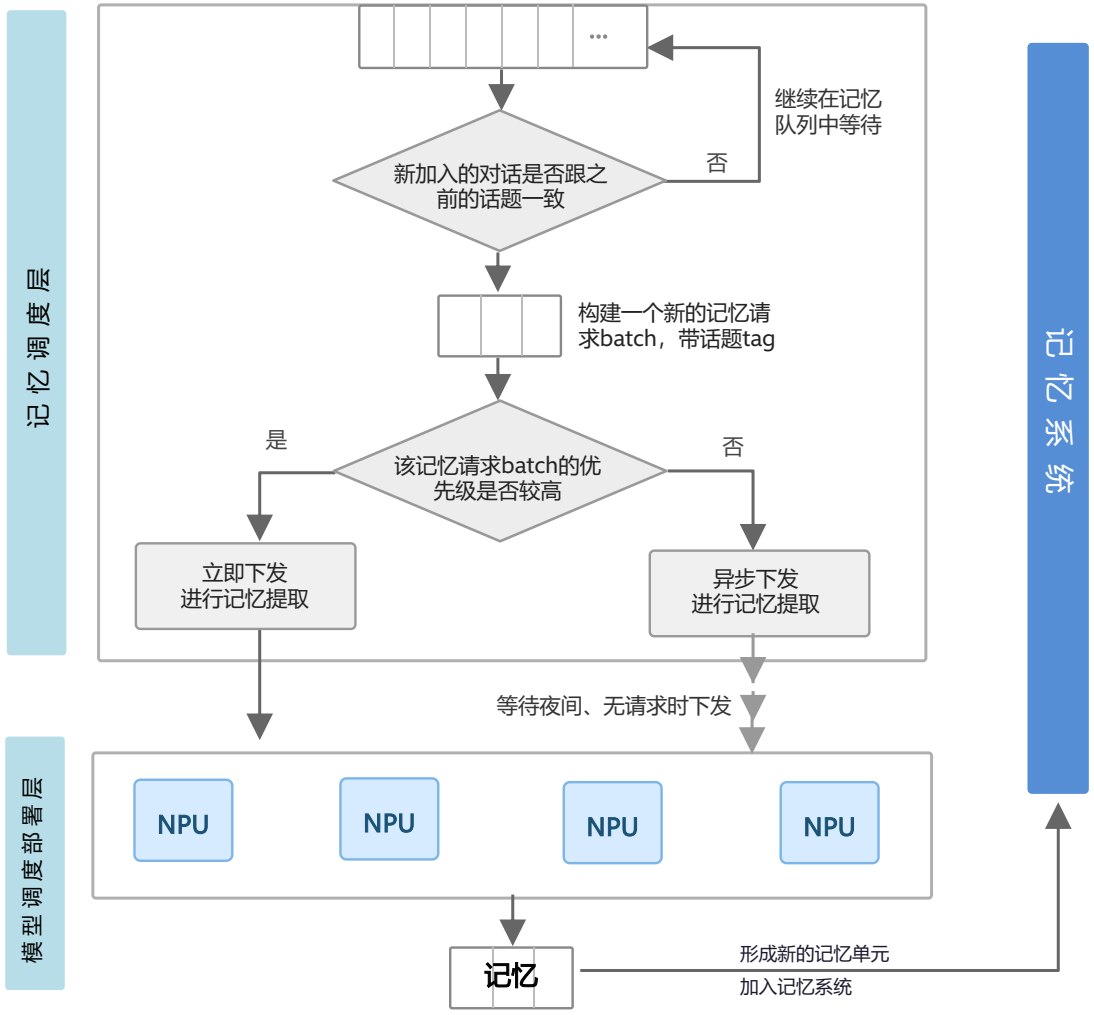
① **时间层级索引构建 (Temporal Hierarchical Indexing)**：将行为流数据进行时间聚合提取结构化“观察日志 ”，通过多维（如时间、主题）分层语义抽象，构建时序感知的记忆索引，通过遗忘与更新机制实现长时记忆索引检索。

② **场景锚定记忆检索 (Context Anchored Retrieval)**：构建场景增强意图理解与逐层渐进式记忆检索，实现token消耗的降低平均降低10%，准确率达90%

③ **渐进式记忆检索（ Progressive Retrieval ）**：**L0/L1/L2 三层渐进式披露**：L0 概要（50-100 字）→ L1 要点（200-500 字）→ L2 全文，ADAPTIVE 模式按 token预算自动选层实现token 再降 10%

异步高性能构建优化：通过异步调度与关联匹配合并，实现记忆构建token消耗和时延降低>50%

技术方案



场景挑战

主流记忆系统每轮对话后都同步触发一次记忆写入与更新，存在：

- **写入阻塞**：抽取→去重→合并全程同步等 LLM，单次写入秒级挂起，多并发下时延线性放大，实时对话不可用
- **成本爆炸**：候选逐条过 LLM，调用次数与 Token 开销随记忆量线性增长
- **精度退化**：缺少合并机制，冗余持续堆积，过时记忆污染召回，白白挤占上下文窗口

关键竞争力

① **记忆调度异步推理：**
- 在记忆分层上层设置一个记忆调度层，统一管理不同层次之间记忆的流转和更新
- 根据算力，异步下发并处理记忆请求

② **关联匹配合并：**
- 将记忆请求按话题相关度、时间、优先级等关联匹配分类合并
- 将合并后的多轮原始对话一起调用一次大模型提起记忆，大大减少调用大模型的次数，提高推理效率，降低token使用量

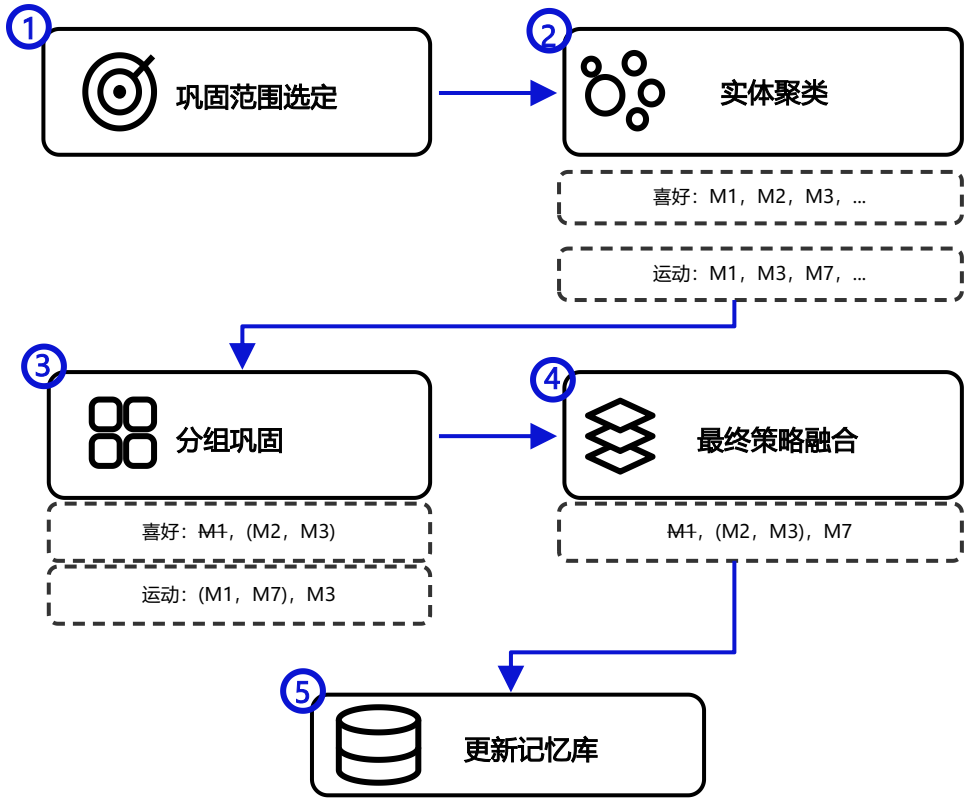
③ **实测性能数据：**
- 记忆添加token使用量降低57.34%
- 记忆添加总时延，单并发下降低10.39%，多并发下降低56.55%
- 检索token降低12.84%的情况下，精度维持不变

Huawei Proprietary - Restricted Distribution
HUAWEI

记忆巩固：基于实体图谱驱动的记忆整合，记忆空间缩减20%，问答准确率提升10%

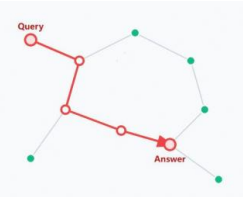
技术方案

Temporal Memory Reconsolidation（TMR）：**基于实体关系进行聚类与分组巩固，持续维护时效性强、结构紧凑的记忆库。**



场景挑战

- **海量记忆持续增长：**记忆系统实时接收大量数据，记忆库持续膨胀，记忆噪声持续增长，检索效率逐渐降低。
- **世界事实持续变化：**同一实体的信息持续变化，重复、冲突、互补和过时记忆交织，Agent难以判断生效记忆。
- **复杂记忆一致演化：**记忆图谱中实体状态多变，多种记忆类型并存，单条记忆承载多个关联事实，难以一致、安全地混合演进。



实体状态多变

- **时间维度：**同一实体状态呈动态非线性变化
- **视角维度：**观察角度不同，实体表征存在显著差异
- **交互维度：**与不同对象交互时实体的语义角色发生漂移



复杂系统通常混合多种记忆

- **构成混杂：**单一系统内嵌多种异质记忆类型
- **场景分野：**不同应用域的记忆“配方”截然不同
- **动态调配：**同一场景内不同时刻需切换记忆重心

关键竞争力

① 基于开源榜单（Memory Agent Bench - Fact Consolidation）达到业界领先，**记忆数量缩减20%+，回答准确率提升10%**

② **记忆巩固调度模块：**以热点记忆出发寻找相关记忆，确定巩固范围，兼顾高频记忆的实时优化与全局记忆的周期治理，实现效率、成本与覆盖率的动态平衡。

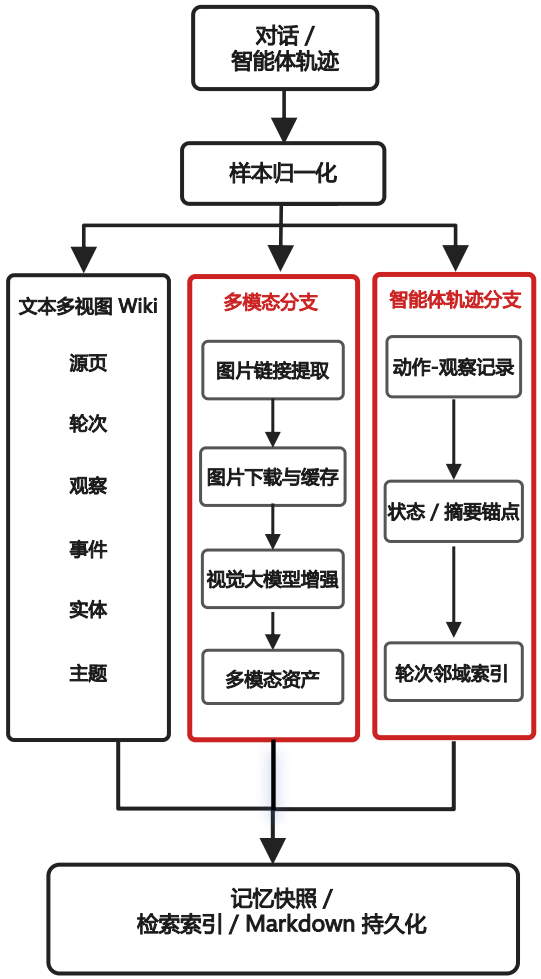
③ **核心实体校准引擎：**基于实体频率分布识别高价值实体，利用消歧实体与时间信息，精准识别重复、冲突、互补和过时记忆，避免误识别造成记忆库污染。

④ **全局冲突消解模块：**消解记忆巩固冲突，保留有效事实，确保记忆更新的一致性与安全性。

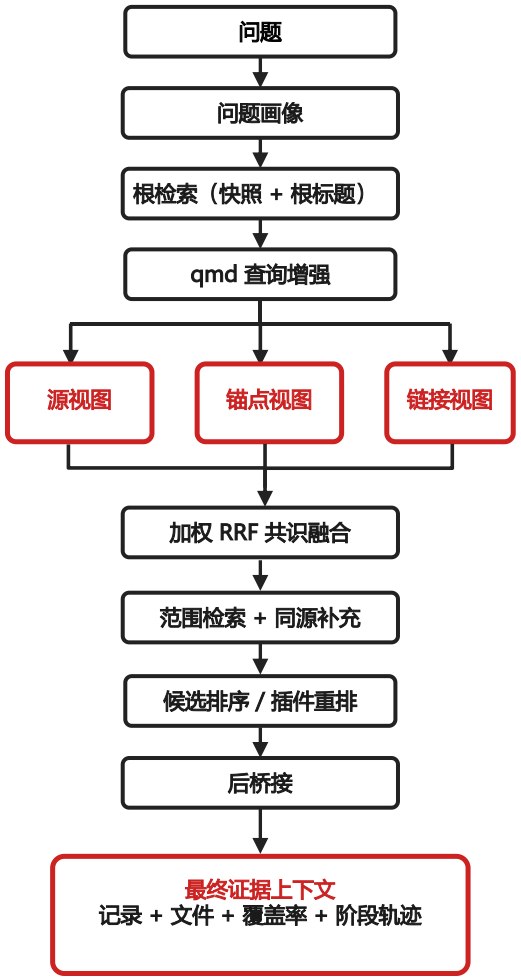
多模文档记忆：从文本“记忆存储”转化为可解释、可演进、多模结构化个人记忆知识，支撑端侧等轻量级记忆场景性能与效果

技术方案

A. 端到端构建流程



B. 端到端查询流程



场景挑战

Markdown memory解决“如何保存过去的信息”，难以支撑**长期、复杂、多模态**等记忆需求：

- 仅支持文本存储，**图片信息只作为URL**，内容信息无法参与检索
- 缺乏显示知识结构，难以表达复杂关系及知识演化；且更新困难易冲突



基准数据集	评测指标	最优分数 (Score)	核心方案
LoCoMo	Recall@24	0.9428	cc_memory
LoCoMo_refined *(多模态图像证据)*	Recall@24	0.9558	cc_memory + 多模态KB检索增强
LongMemEval *(仅 Turn-level)*	Turn Recall Avg (@5 / @10 / @30)	0.8700 / 0.9372 / 0.9774	cc_memory
Meta-CRAG *(多模态RAG)*	Recall@12	0.9847	cc_memory + 多模态KB检索增强
Mem-Gallery *(图像+对话联合)*	Recall@24	0.7416	cc_memory + 多模态KB检索增强 + 多查询/RRF融合
AMA-Bench *(自主Agent轨迹)*	Proxy R@112	0.9143	cc_memory + AMA-Memory

关键竞争力

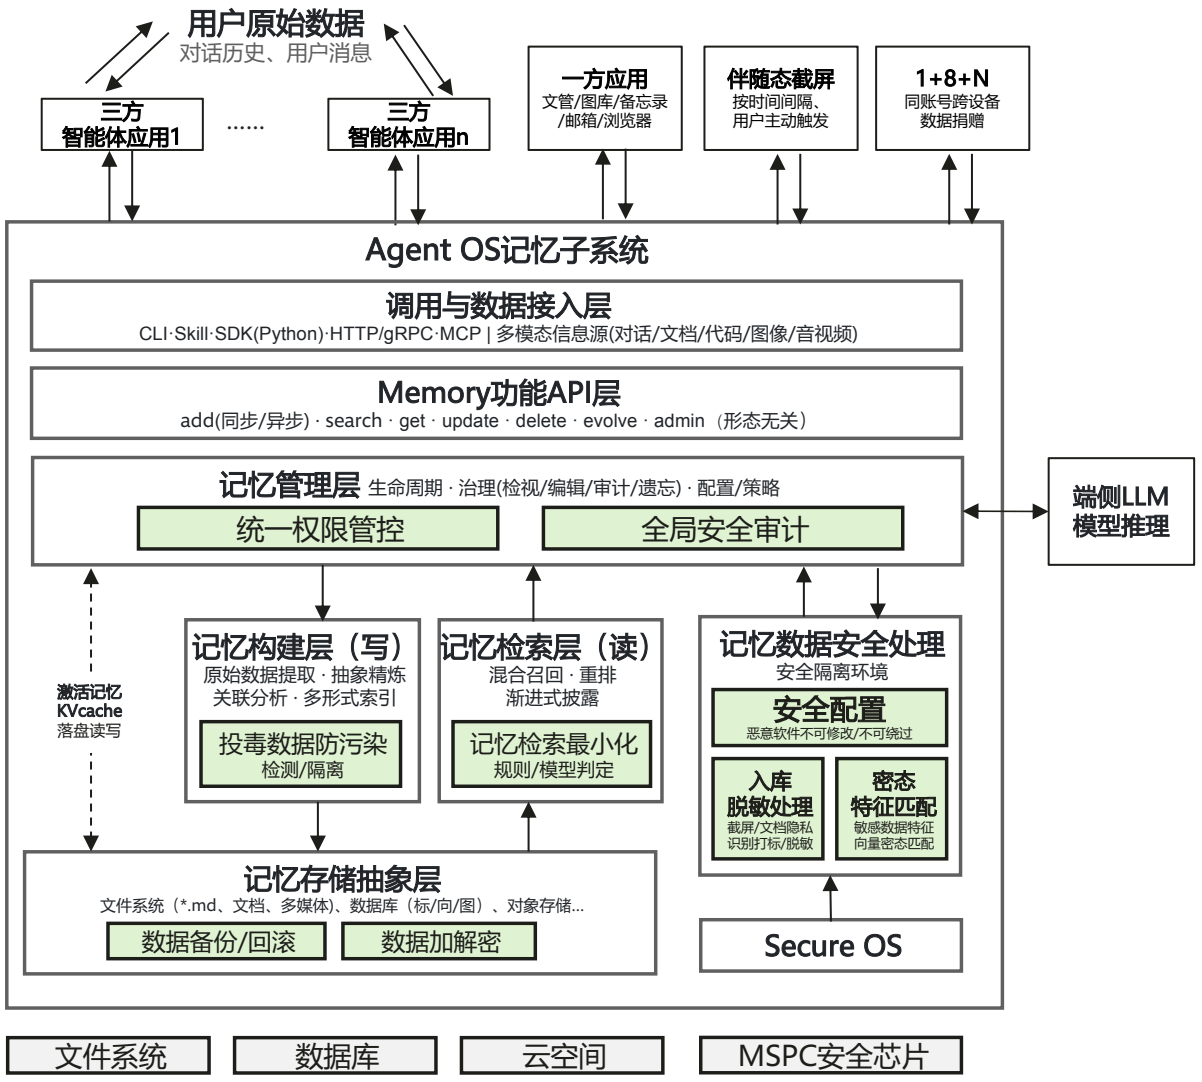
① **多模文档记忆构建**：突破传统 Wiki 仅支持文本存储局限，将交互中产生的图像、视频等多模态输入进行缓存、资产托管及Vision LLM语义抽取，构建成包含摘要、实体、action、attribute、keyword五维结构化记忆对象，与文本记忆共同建立多模索引。

② **Wiki-first多视图融合**：将对话解构为源、轮次、观测、事件等原子单元并进行多粒度记忆视图构建，降低表达不一致导致的低召回问题；通过问题类型采用不同处理预算和召回策略。四线程在locomo上检索召回达到94.28%, 性能吞吐提升2.02x。

③ **Agent轨迹学习**: 通过保留智能体与环境交互过程中的客观信息与明确的因果依赖关系，记忆“状态-行动-结果”之间的链条，弥补了传统方法丢失因果信息的缺陷, AMA-Bench上提升30.9%，实现91.43%的检索召回。

记忆安全：原生记忆安全，支持权限管理、全局审计、数据加密等多重安全保障机制【Q4】

技术方案



场景挑战

- **越个性化越侵犯隐私**：记忆系统需要深度理解用户偏好、习惯与历史行为，但偏好数据本身是最敏感的隐私信息，个性化与隐私保护存在天然张力。
- **强监管行业合规要求**：金融、医疗等场景要求等保/密评3级，记忆数据需可审计、可遗忘、可脱敏，且审计日志不可篡改。
- **多源数据投毒风险**：第三方智能体应用、伴随态截屏、数据捐赠等多源输入通道，恶意输入可能污染记忆库，影响Agent决策。
- **跨租户隔离与越权防护**：万级工作流、千级智能体共享同一记忆服务，租户间数据隔离与权限边界必须严格不可穿透。

关键竞争力

① **三道防线安全架构**：认证支持多模式插拔与凭据撤销；授权实现Scope五维隔离；数据采用三级信封AES-GCM加密，密钥缺失即熔断。

② **入口防护与防耗尽**：认证前令牌桶限流防枚举；WorkloadGuard管控昂贵操作并发槽位；DEV模式强制回环绑定，杜绝非法访问。

③ **不可篡改全局审计**：全覆盖记录8类关键事件，链式HMAC保障完整性，PII信息自动脱敏，日志仅归档不删除。

④ **全生命周期治理**：支持非破坏式遗忘与归档，血缘可追溯；基于Scope的硬隔离与细粒度操作鉴权，确保流转可控。

⑤ **请求安全上下文传播**：RequestSecurityContext绑定单次请求可信身份，ContextVar隔离传播，操作结束强制Reset，杜绝线程池复用导致的权限泄漏。

记忆运维服务化整体方案与架构需求：为万级工作流，千级智能体提供记忆，几个人就能管理，能运维

技术方案



场景挑战

没有记忆运维 Console 治理的记忆系统，存在问题：

- **记忆投毒**：恶意记忆如定时炸弹，跨会话累积延迟引爆，无审计无法发现和回滚
- **沉默漂移**：记忆逐渐偏离组织真实状态，数周不可见，无告警直到灾难级才暴露
- **完成率幻觉**：任务完成率 100% 但记忆召回率仅 13%，仪表盘绿灯掩盖 87% 的知识遗忘
- **合并链路黑盒**：无 Console 展示记忆链路，LLM 去重合并的抽取、判定、合成、落盘四步均不可观测，故障无法归因定位

关键竞争力

大规模记忆运维方案以 **DFS 可服务性四维度**（可交付性 / 可用性 / 可维护性 / 多租管理）为框架，构建三大支柱：

① **14 模块服务中间层**：覆盖六层架构（接入 / 编排 / 构建 / 检索 / 存储 / 共享），达成可交付、高可用、可维护、可运营目标

② **5 角色分权分域**：服务层与内核 HTTP API 完全隔离，通过内核存储机制为治理与追溯提供数据基础

③ **日常运维功能**：显式记忆管理、冲突记忆检测与消解、批量删除记忆等运营操作

HUAWEI

Memory

记忆趋势和挑战

记忆关键技术与规划

典型应用场景

HUAWEI

九问记忆适合场景

01

个性化偏好记忆

让AI记住每个用户的偏好和历史

安全 + 时间感知 + 场景路由

02

长程任务上下文记忆

跨会话任务不丢上下文

时间 + 图谱 + 渐进式 + 安全

03

经验沉淀与技能归纳

让AI越用越聪明

Auto Dreaming + procedural + 路由

场景	九问	mem0	OpenViking	TencentDB	MemOS
个性化偏好 （手机银行）	★★★	★ 能记无安全	★ 能降本无安全	★★ 有溯源无加密	★ 有隔离无加密
长程任务 （故障溯因/风控）	★★★	★ 无时间无图谱	★★ 渐进式但无安全	★★ 有溯源无图谱	★ 无图谱无安全
经验沉淀 （Coding/客服）	★★★	★ 只记不学	★★ 无procedural	★ 无自进化	★★ 无场景路由

跨会话 + 安全 + 时间感知 + 差异化策略

不适合：纯一次性问答 | 强事务一致性业务主数据 | 毫秒级实时流处理

手机银行：上下文管理对接记忆，解决历史对话经验沉淀，提升用户体验

个性化 + 经验沉淀

As-Is（首次请求：无匹配意图被拦截）



Tech Pipeline（场景化记忆提取配置）

配置中心：生成候选卡

场景化记忆提取配置

【交房租场景】	【付房贷场景】	【还信用卡场景】
• 收款人 • 金额 • 账号/银行 • 备注（可选）	• 贷款账户 • 金额 • 还款日 • 备注（可选）	• 信用卡号 • 还款金额 • 还款账户 • 备注（可选）

等待用户确认

明确授权后，才可写入近期情景记忆库

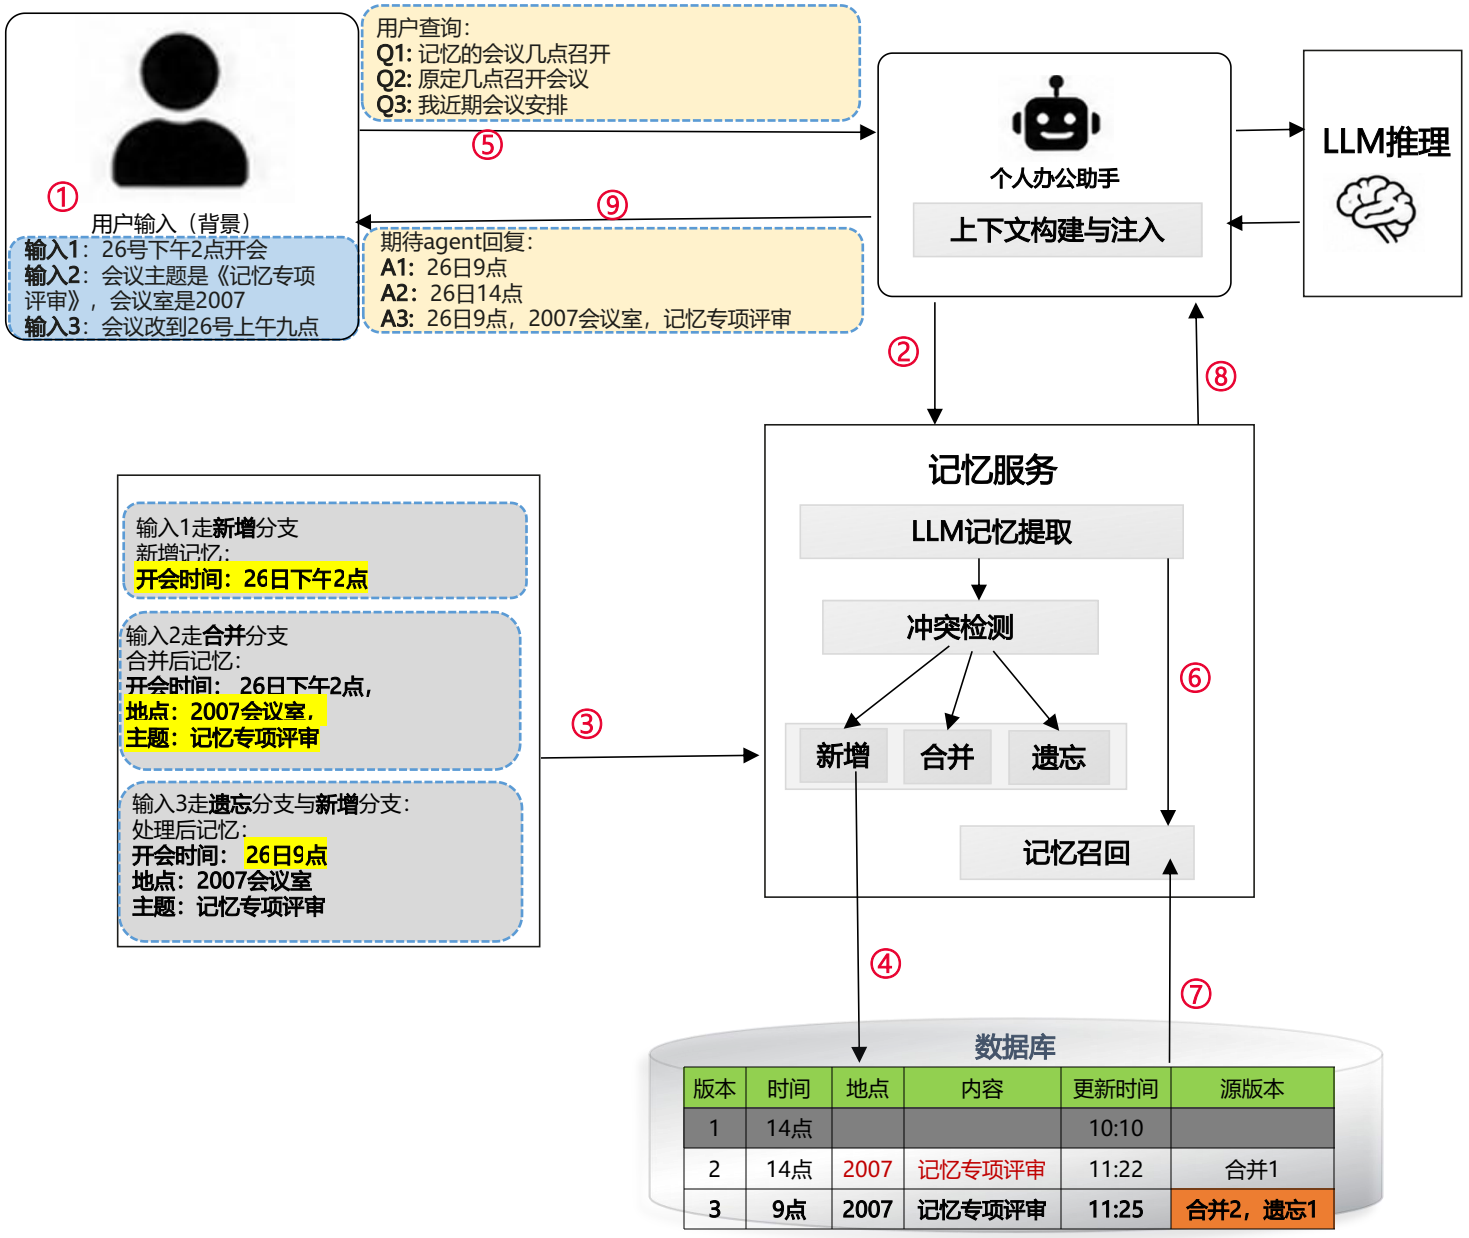
用户是否同意？

- 同意 → **写入近期情景记忆库**：加密存储，授权可召回使用
- 拒绝 → **丢弃候选卡**：不写入记忆库

To-Be（再次请求：可信召回直达）



办公场景记忆应用现状：用户数据冲突，检索输出需求差异大，当前记忆系统尚不满足



场景痛点

- 记忆提取内容黑盒、存什么不可控，无法适配超级智能体**不同业务的记忆提取诉求**
- **生命周期黑盒**：冲突不可见、操作无审计、运维无治理、无记忆多多版本管理等
- 单一向量相似度/图遍历不满足**时间过滤**、重要度等复杂检索
- 子智能体全量加载记忆**撑爆上下文**，完全不共享又各自重复构建

解决方案

① **场景配置**：开会、编码、娱乐各配专属提取策略——办公记决议、编码存方案、娱乐留偏好，**提示词级精准提取**

② **链式治理**：每次更新成链、Console 一屏可视，冲突谁替代谁一目了然，个性化有据可依

③ **融合检索**：用户说“几点开会”，多路召回 + 双时间模型把“几点”换算成时间窗口，一击即中

④ **分域共享**：团队记忆进共享空间协同复用，个人隐私锁在专属 Scope——协同与隔离兼得

PyPI / Git / 离线三种方式，4 步到 hello-memory，开启你的第一条记忆

① 三种安装方式

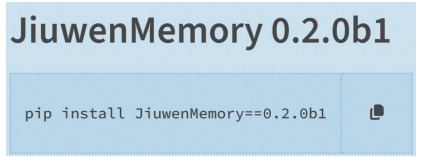
生产部署
快速试用

PyPI 安装（推荐）

pip install jiuwen-memory

pip install ".[mcp,embed]"

√ wheel 仅 590KB
√ 自动拉取 17 项基础依赖



https://pypi.org/project/JiuwenMemory/0.2.0b1/

开发调试
研读源码

源码安装（开发者）

```
git clone https://gitcode.com/openJiuwen/agent-memory.git
cd agent-memory
git fetch --tags
git checkout 0.2.0.beta1
pip show JiuwenMemory
pip install -e ".[dev,deploy,mcp,nlp,embed,multimodal]"
python -c "import jiuwen_memory; print('OK')"
```

内网隔离

离线包（无网环境）

地址：https://gitcode.com/openJiuwen/agent-memory/tags

```
unzip agent-memory-0.2.0.beta1.zip
cd agent-memory-0.2.0.beta1
pip install -e ".[dev,deploy,mcp,nlp,embed,multimodal]"
```



JiuwenMemory下载与安装指南.md

agent-memory 2.0 部署与使用指南.pptx

② 四步主流程

1 环境准备

Python ≥ 3.11 · 建议 venv 隔离 · pip 升级到最新

```
python -m venv .venv
# Windows: .venv\Scripts\activate Linux: source .venv/bin/activate
```

2 安装（按需选 Extras）

6 类可选：deploy/mcp/nlp/embed/dev/test

```
pip install jiuwen-memory # 基础 17 项, ~500MB
pip install "jiuwen-memory[mcp]" # +MCP SDK (轻量)
```

3 启动入口（三选一）

CLI	HTTP Server	MCP Server
memory-cli memory-mcp	memory-server 默认 :8000	stdio / HTTP MCP_PORT 切换

4 速查：三条关键 curl

```
健康检查 → {"status":"ok"}
curl http://localhost:8000/healthz
```

```
写入记忆
curl -X POST http://localhost:9999/v1/add -d '{ "content": "用户喜欢深色主题" }'
'
```

```
检索记忆
curl ":8000/v1/memories/search?query=..."
# 共 11 个端点，详见 /docs (Swagger)
```

Thank you.

让 AI 从“第一次见面”走到“认识你”

Memory 2.0：可插拔、可演进、可运维的记忆基础设施

关键技术：记忆构建 · 时间层级索引 · 异步高性能 · 记忆巩固 · 多模文档 · 记忆安全 · 运维服务化

落地场景：手机银行、办公助手等真实场景已跑通

Memory 2.0 已正式发布,欢迎大家做 POC、提反馈。

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。

Bring digital to every person, home and organization for a fully connected, intelligent world.

Copyright©2018 Huawei Technologies Co., Ltd.
All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.

HUAWEI

GOSIM®
GLOBAL OPEN-SOURCE INNOVATION MEETUP

GOSIM Shenzhen 2026

智能体操作系统与应用

Agentic OS & App

