GOSIM

GOSIM Shenzhen 2026

October 16-17, 2026 Shenzhen, China



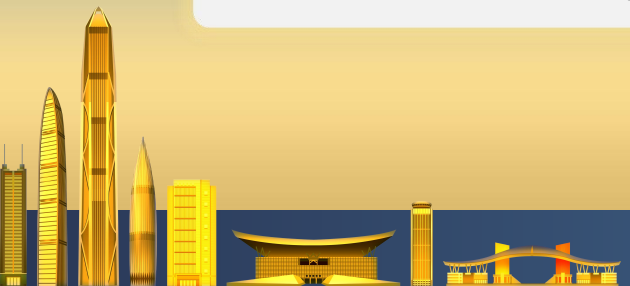
CONTENTS

GOSIM Shenzhen 2026

端侧智能的技术发展与 MiniCPM 开源生态实践观察

2026 年 10 月 14 日 | 报告人：井晨哲

OpenBMB ModelBest



GOSIM

端侧智能的四象限：计算在哪里，价值在哪里

横轴看 AI 计算是否发生在端侧，纵轴看 产品价值是否深度嵌入物理环境

价值深度嵌入物理环境

计算在云端

计算在端侧

价值不嵌入物理环境

云端大脑

有物理感知与执行，但智能依赖网络，断网即失能

- 人工智能语音音箱
- 家用摄像头
- 遥操作机器人
- 初代拍照上传 AI 眼镜

端侧智能体

感知—决策—执行闭环在设备内完成，不依赖网络

- 端侧自主决策机器人
- 智能汽车座舱
- 实现本地推理的AI眼镜
- AI 辅助功能硬件

云服务终端

硬件是云服务的接入端，能力与寿命都在云上

- 云电脑、云游戏机
- Rabbit R1
- AI 学习机
- 手机与 PC 上的 AI 助手 App

本地算力盒子

在本地跑模型，价值在隐私、离线与零边际成本

- 本地推理工作站
- NAS 与家庭服务器
- 端侧输入法、离线字幕
- 本地文档问答

端侧智能相较云端的三大优势



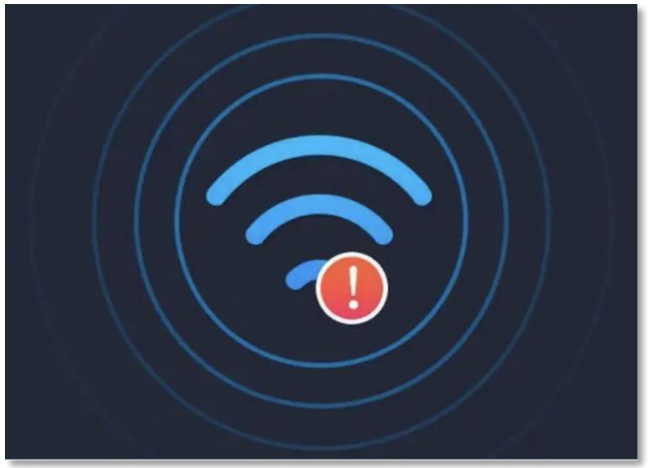
隐私性

数据不出端　最大可能保护个人隐私



实时性

全天候陪伴　实时倾听用户最真实的需求

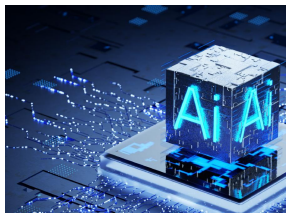


可靠性

守候不掉线

不在用户最需要的时候缺席

端侧智能天然适配消费硬件的商业逻辑

商业模式	按量付费	免费获客	一次性买断
适用场景	水电、算力等基础设施	移动互联网应用 APP	硬件设备如汽车、家电、手机
用户体验	能省则省	有丰富的应用内引导消费	购买决策成本高使用黏性强
场景特性	资源导向的刚需性投资或消费	以用户注意力为核心的商业	以产品功能创新为更新驱动力
			

杰 文 斯 悖 论

随着技术进步提高资源利用效率，该资源的总消耗量反而会增加，而不是减少

端侧智能相对于云端的商业优势

用户侧

持续使用成本低

黏性强

厂商侧

功能设计不算力

天花板

GOSIM

GOSIM Shenzhen 2026

端侧智能的历史机遇期



能力密度：兼顾效果与效率的评测指标

$$\rho = \frac{\text{同能力的标准模型激活参数量}}{\text{目标模型激活参数量}} = \text{单位参数中蕴含的智能水平}$$

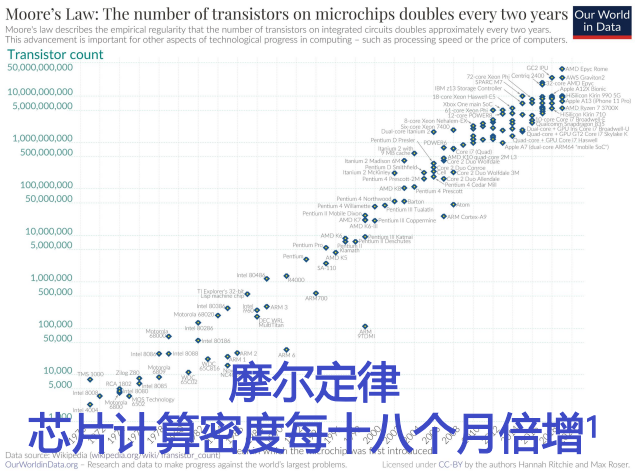
使用 Predictable Scaling 技术估算模型相对密度

标准模型  参数量 2.4 B ← 参数量 175B GPT-3 目标模型

标准模型能力密度 GPT-3 相对能力密度

1 = 2.4B / 175B = 0.0137

行业意义：洞察大模型高效能发展规律



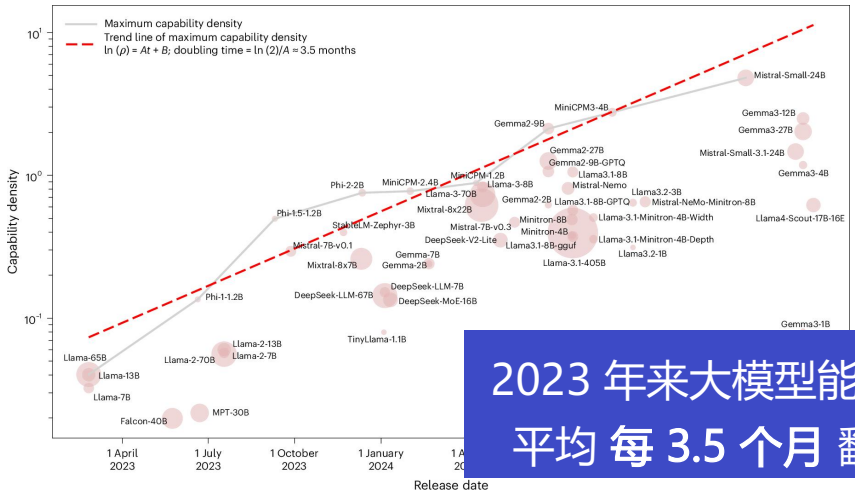
摩尔定律

芯片计算密度每十八个月倍增[1]

信息革命

迈向

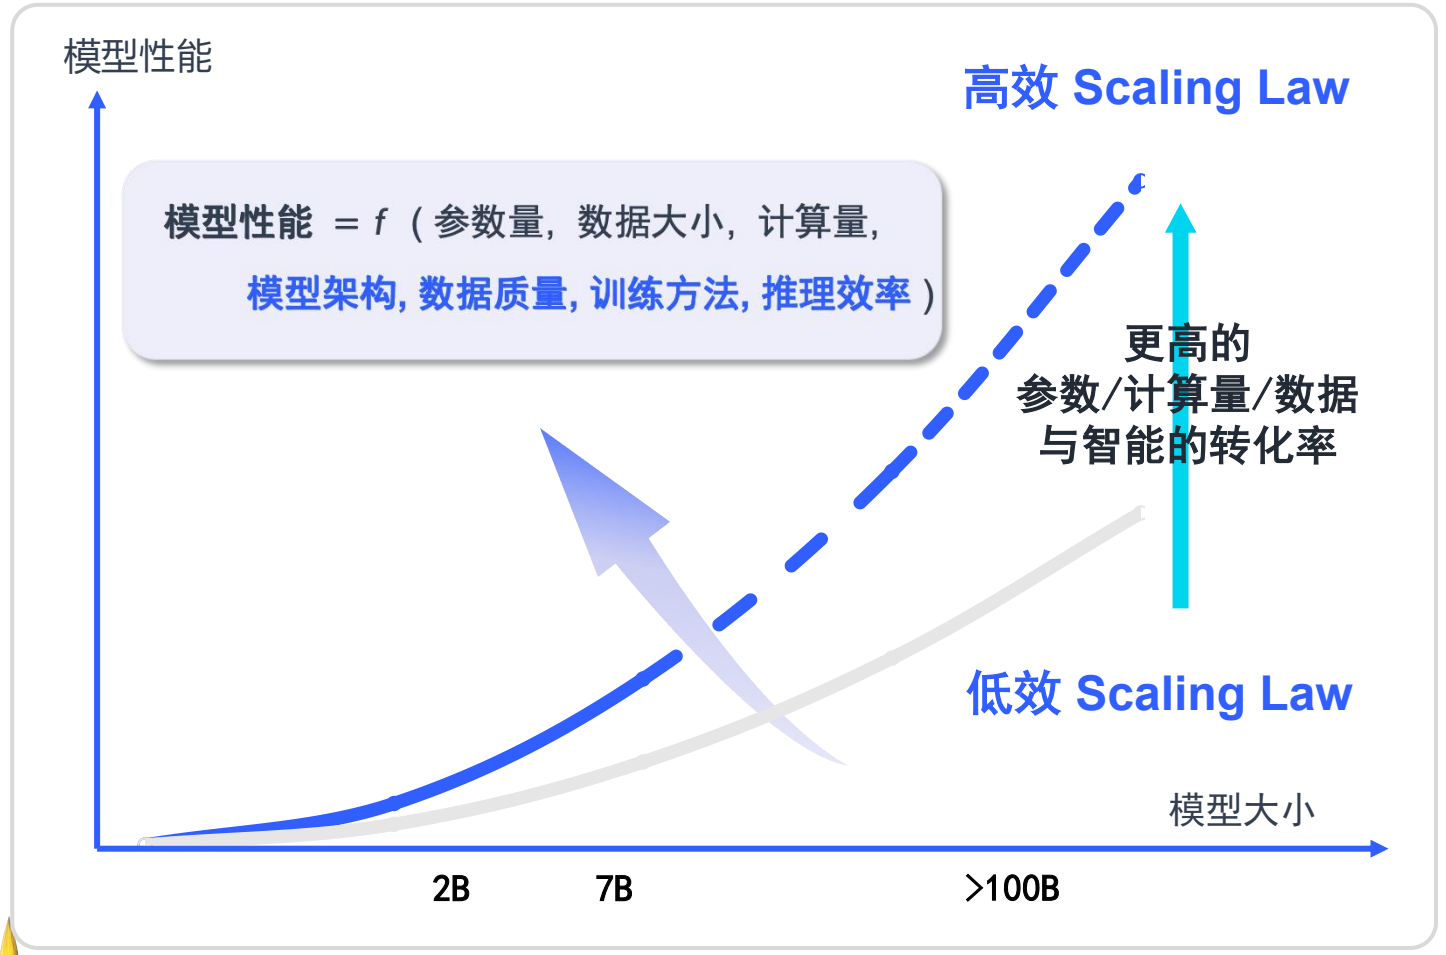
智能革命



2023 年来大模型能力密度

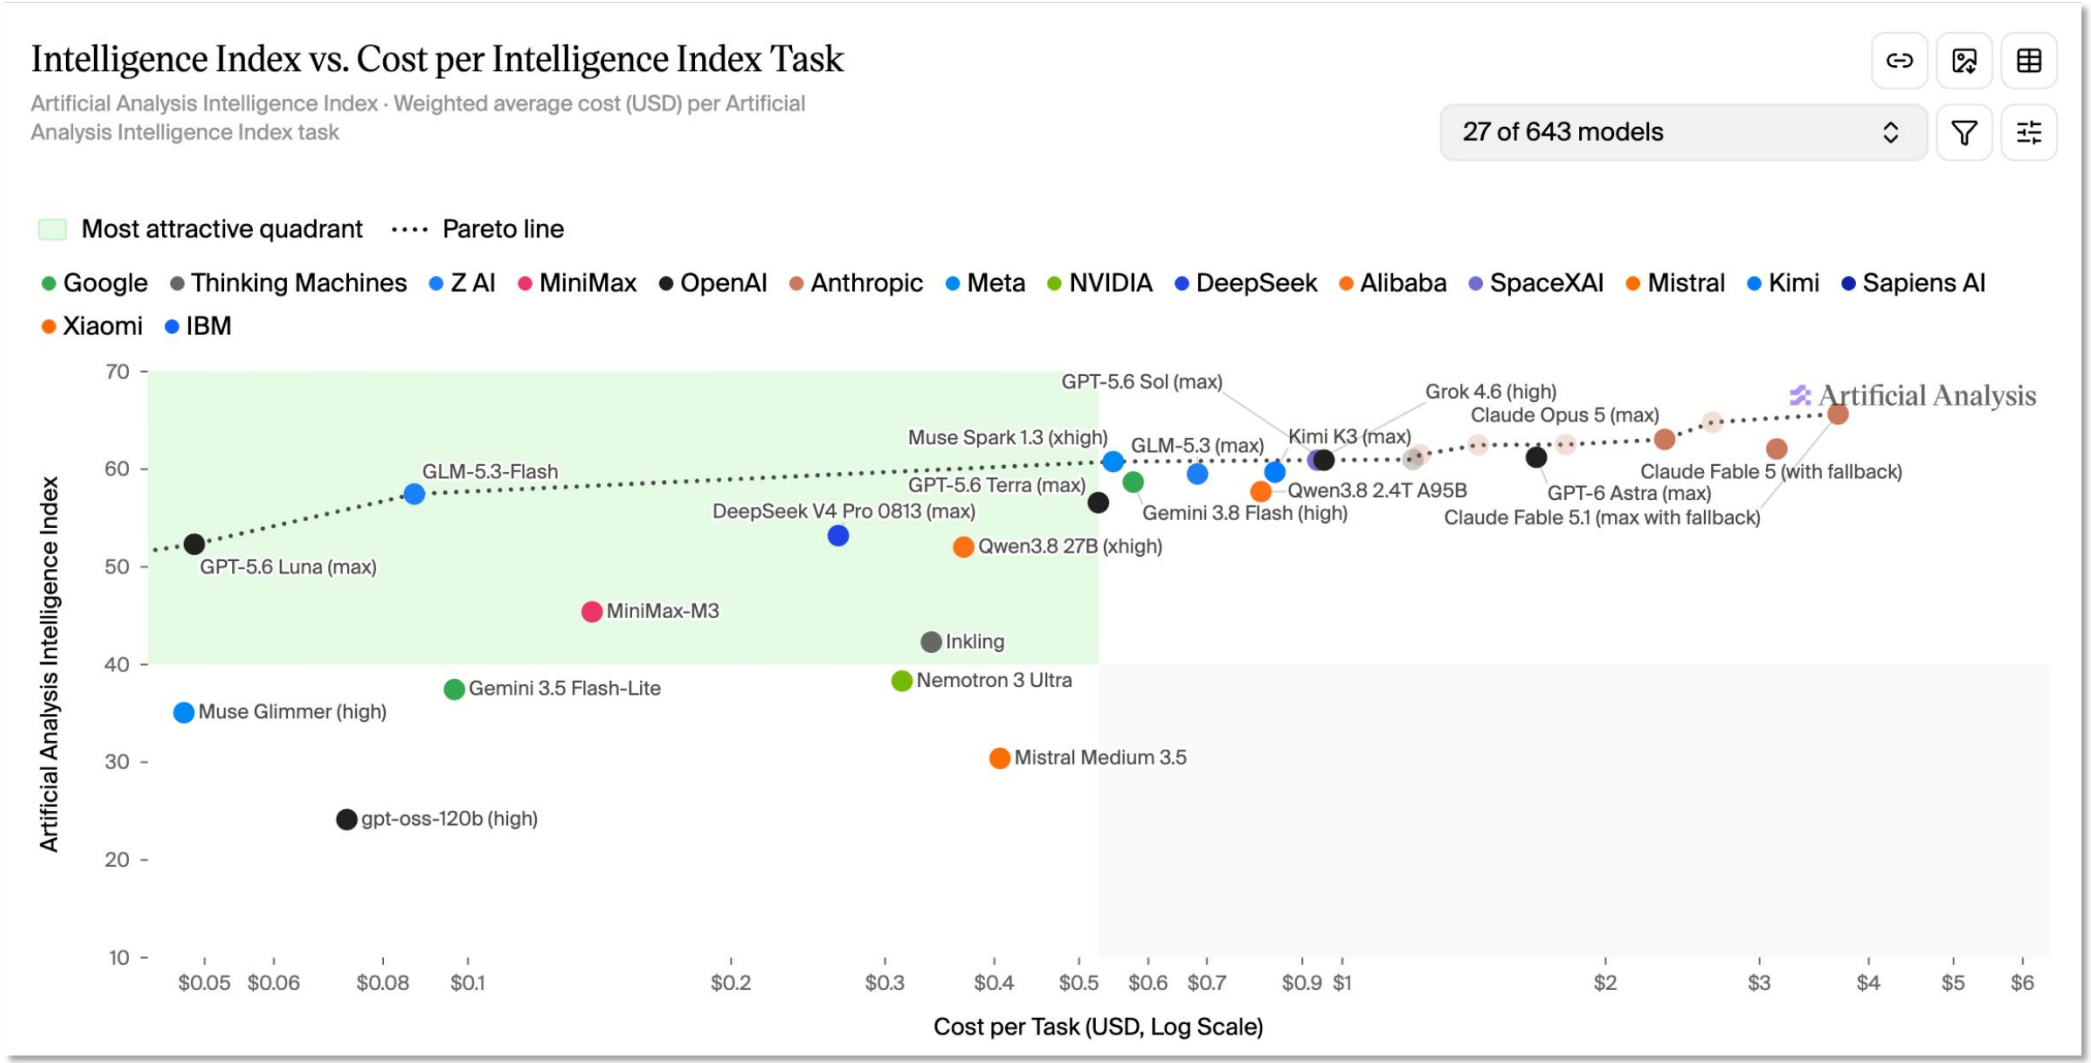
平均 每 3.5 个月 翻一倍

[1]Max Roser, Hannah Ritchie - https://ourworldindata.org/uploads/2020/11/Transistor-Count-over-time.png, CC BY 4.0, https://commons.wikimedia.org/w/index.php?curid=98219918



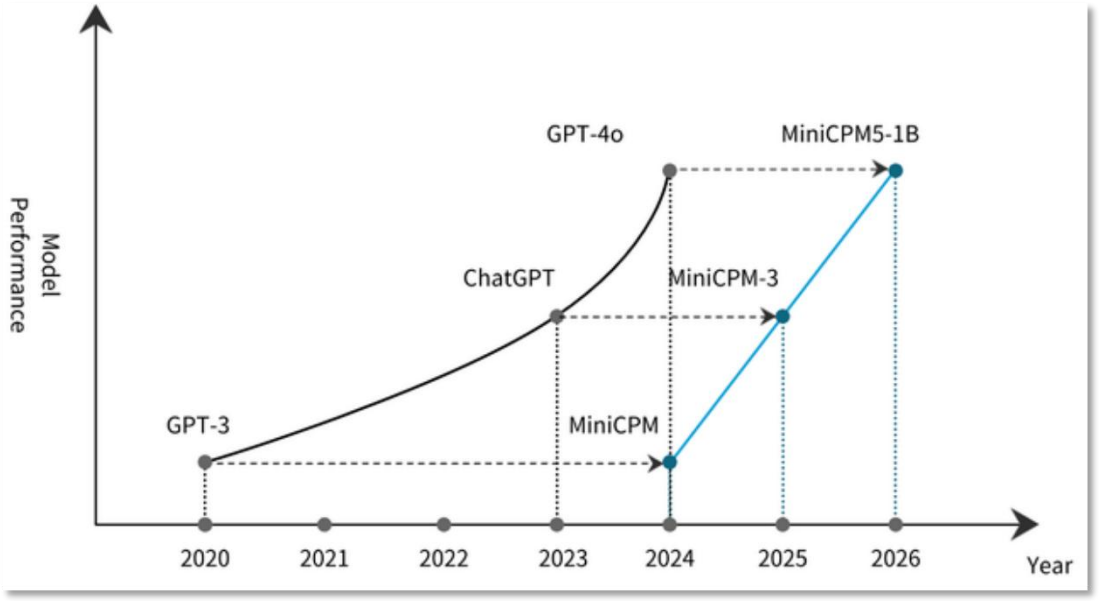
	规模范式	密度范式
模型	增加参数量	**高效率**结构
数据	增加数据量	**高质量**数据
训练	增加计算量	**高效率**训练
推理	增加机器量	**高效率**推理

模型能力密度在各个领域受到越来越多的关注

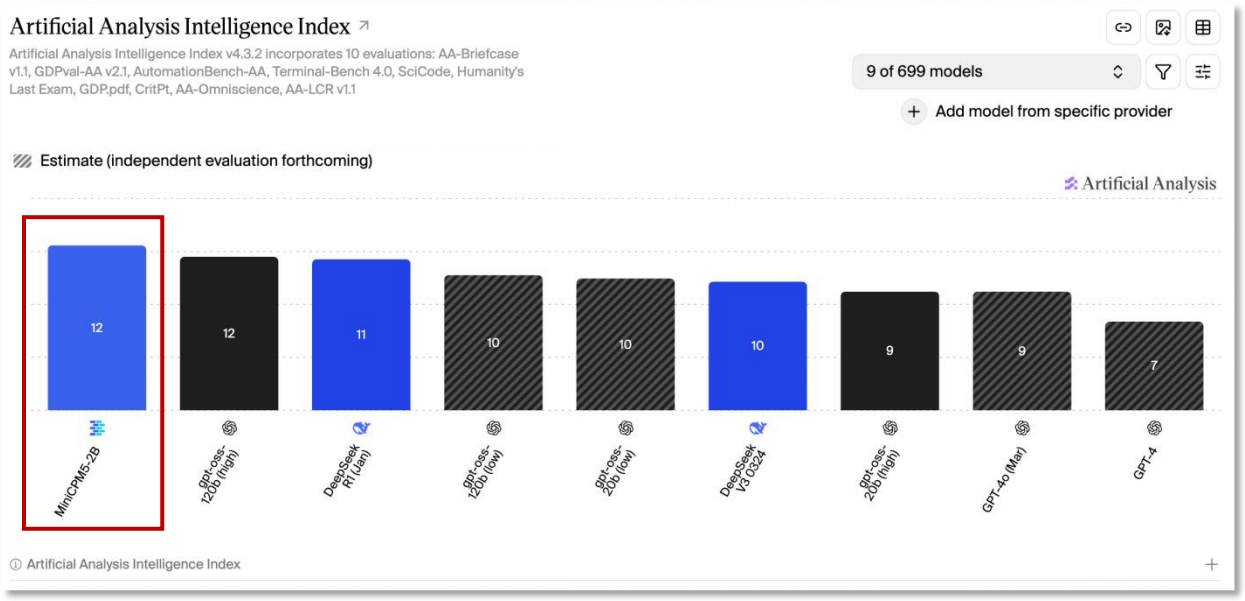


https://artificialanalysis.ai/

案例：MiniCPM 持续将行业前沿落在端侧设备



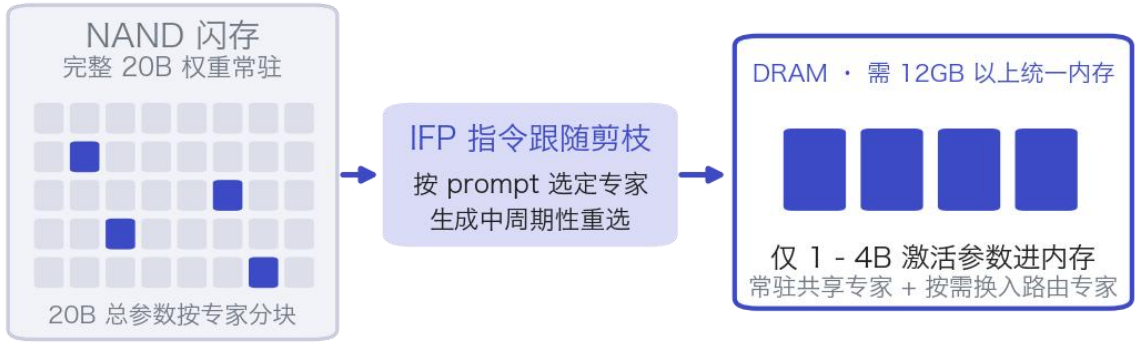
2026 年 MiniCPM-5 1B 在 AA-index 榜单上分数和 GPT-4o 基本平齐



2026 年 MiniCPM-5 2B 在 AA-index 榜单上分数超越 DeepSeek-R1

Apple：用闪存换内存，做更开放的 Apple Intelligence

用架构创新抬高端侧上限：20B 参数模型跑在手机上，代价是把权重留在闪存里



AFM 3 Core Advanced：把模型规模扩展到远超 DRAM 上限

传统 MoE 需全部权重驻留 DRAM，这是端侧模型规模的硬上限



AFM 3（WWDC 2026，6 月 8 日）

- 端侧双模型：AFM 3 Core（约 3B dense）+ Core Advanced
- Core Advanced：**20B 总参数，每次仅激活 1–4B**
- 原生多模态、支持 tool use；语言覆盖 **16 种**（官方口径）
- 需 **≥12GB 统一内存**：iPhone 17 Pro / Air、M4+ iPad、M3+ Mac

Foundation Models：端侧成为基础设施

- 端侧调用 **零成本**、无需 API key、离线可用
- 开放模型抽象层，可接入 Claude / Gemini（需各自 API key）
- 开源 CoreAILanguageModel 与 MLXLanguageModel
- Guided Generation 直接产出类型安全的 Swift 结构体

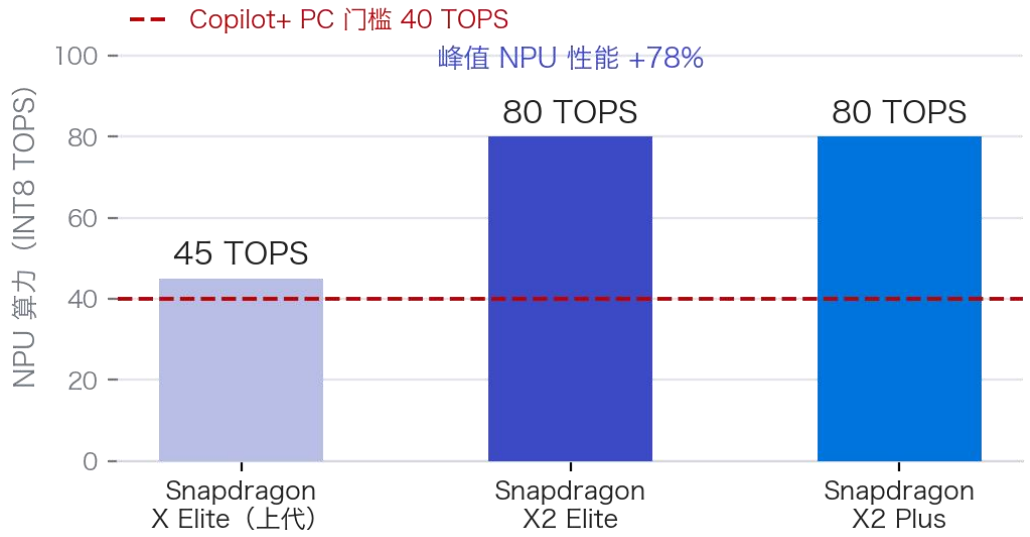
硬件配合：M5 把矩阵引擎放进 GPU

- 每个 **GPU 核心**内置 Neural Accelerator
- GPU **峰值** AI 算力比 M4 高 **4 倍以上**（实测 TTFT 约 4.1 倍）
- 统一内存带宽 **153GB/s**，比 M4 高近 30%
- MLX / llama.cpp / PyTorch 已接入（需 macOS 26.2+）

资料来源：machinelearning.apple.com（AFM 3 第三代基础模型）、WWDC26 Session 241 / 319、Apple Newsroom（M5）；Apple AI 副总裁 Amar Subramanya 在 WWDC26 后媒体沟通会上称四个 AFM 3 模型「利用 Gemini 前沿模型的输出进行优化（refined using outputs from）」，Apple 官方技术博客未提及此事，且明确否认运行时依赖（出厂权重不含 Gemini 代码或架构）；12GB 门槛出自 Apple 设备支持文

高通：把 Agentic AI 写进 SoC 产品定义

叙事从「NPU 有多少 TOPS」升级为「**能不能跑一个会主动行动的 Agent**」，手机与 PC 双线并进





Snapdragon 8 Elite Gen 5（手机旗舰）

- Hexagon NPU **性能 +37%**，能效（perf/W）+16%
- 支持 **INT2 / INT4 / FP8** 等混合精度
- 高通称本地生成可达 **220 tokens/s**；AI Hub 实测 18–33
- NPU 与 ISP 直连，实时参与影像处理管线

Agentic AI 的产品化

- Sensing Hub 上的 **Personal Knowledge Graph** 个人知识图谱
- Personal Scribe：端侧学习并记忆过往对话
- 学习作息、偏好与对话；位置等数据需用户授权
- 支持 Gen AI 模型加密，保护端侧模型资产

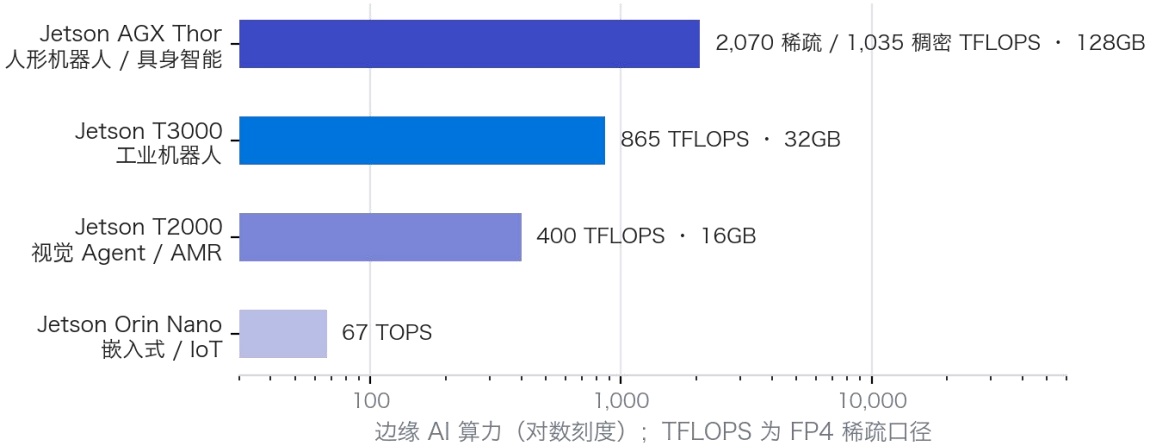
PC 线与开发者生态

- X2 Elite：**80 TOPS（INT8）**，64-bit 寻址突破 4GB 上限
- Sensing Hub 另有双 Micro NPU 处理常驻感知
- Qualcomm AI Hub + GenieX / Workbench 工具链
- 瓶颈：持续压力下明显降频，15 分钟 CPU 节流至 58%

资料来源：Qualcomm 官方产品简报（Snapdragon 8 Elite Gen 5 / X2 Elite）、Qualcomm AI Hub、Futurum Group；220 tokens/s 仅见于高管口头受访，无量化精度与测试条件，官方 AI Hub 上 Llama 3.2 3B 于同芯片为 18–33 tokens/s；高通未公布手机 NPU 的 TOPS 数值，流传的 100 TOPS 为第三方推算；降频数据来自第三方持续压力测试（iQOO 15）

NVIDIA：具身智能与本地 Agent

定义的是另一种端侧：机器人本体与本地工作站，覆盖从嵌入式到人形机器人的完整算力阶梯



相比上代 Orin：AI 算力 7.5 倍 · CPU 3.1 倍 · 内存 2 倍



Jetson Thor：边缘的生成式推理超算

- AGX Thor：**2,070 稀疏 / 1,035 稠密 FP4 TFLOPS**，128GB
- 相比上代 Orin：AI 算力 7.5 倍、CPU 3.1 倍、内存 2 倍
- 新增 T3000（865 TFLOPS / 32GB / 稀疏FP4）与 T2000（400 / 16GB / 稀疏FP4 ）
- 软件栈可回收 **10–12GB** 内存（客户实测最多 15GB）

自研端侧小模型 Nemotron 3

- Nano 4B：混合 Mamba-Transformer，**首个专为端侧优化**
- Orin Nano 8GB 上 Q4_K_M 达 **18 tokens/s**，吞吐翻倍
- Nano 30B-A3B 精度优于 GPT-OSS-20B（厂商自报），1M 上下文
- Super 120B（12B 激活）：PinchBench **85.6%**，同级最强开源

运行时与本地 Agent

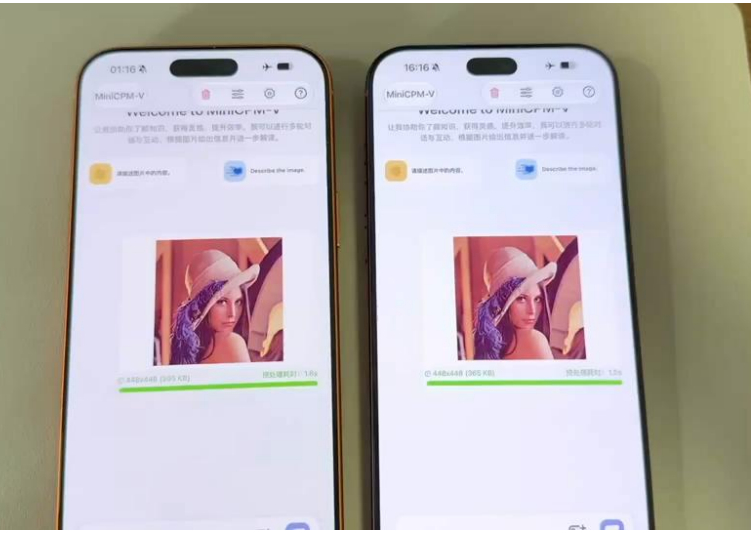
- TensorRT Edge-LLM：部署运行时纯 C++，无 Python 依赖
- 支持 Cosmos Reason 2、Qwen3-TTS / Qwen3-ASR
- Cosmos 3 Edge：4B 具身模型，后训练约一天完成
- NemoClaw 本地 Agent 栈：沙箱隔离、数据不出设备

资料来源：NVIDIA 官方博客 blogs.nvidia.com、developer.nvidia.com、research.nvidia.com/labs/nemotron、Jetson Thor 官方规格表；FP4 TFLOPS 官方分稀疏与稠密两档，实际部署的 LLM / VLM 多数不满足 2:4 结构化稀疏，工程测算建议用稠密值；T3000 / T2000 计划 2027 年 Q1 上市；Nemotron 3 Super 定位 DGX Spark 与工作站，非手机端侧

专家预取与计算调度：提前备好，边算边读

把当前层的路由输入特征直接送入下一层的路由模块，在计算当前层的同时，提前预测下一层将要使用的专家，并由后台线程提前把它们从闪存读入内存。

调整了层内专家的计算顺序：实际路由选中且已经加载到位的专家先算，其余所需专家同步加载。通过让计算与读取尽可能并行，进一步减少加载等待和 GPU 的空闲时间。

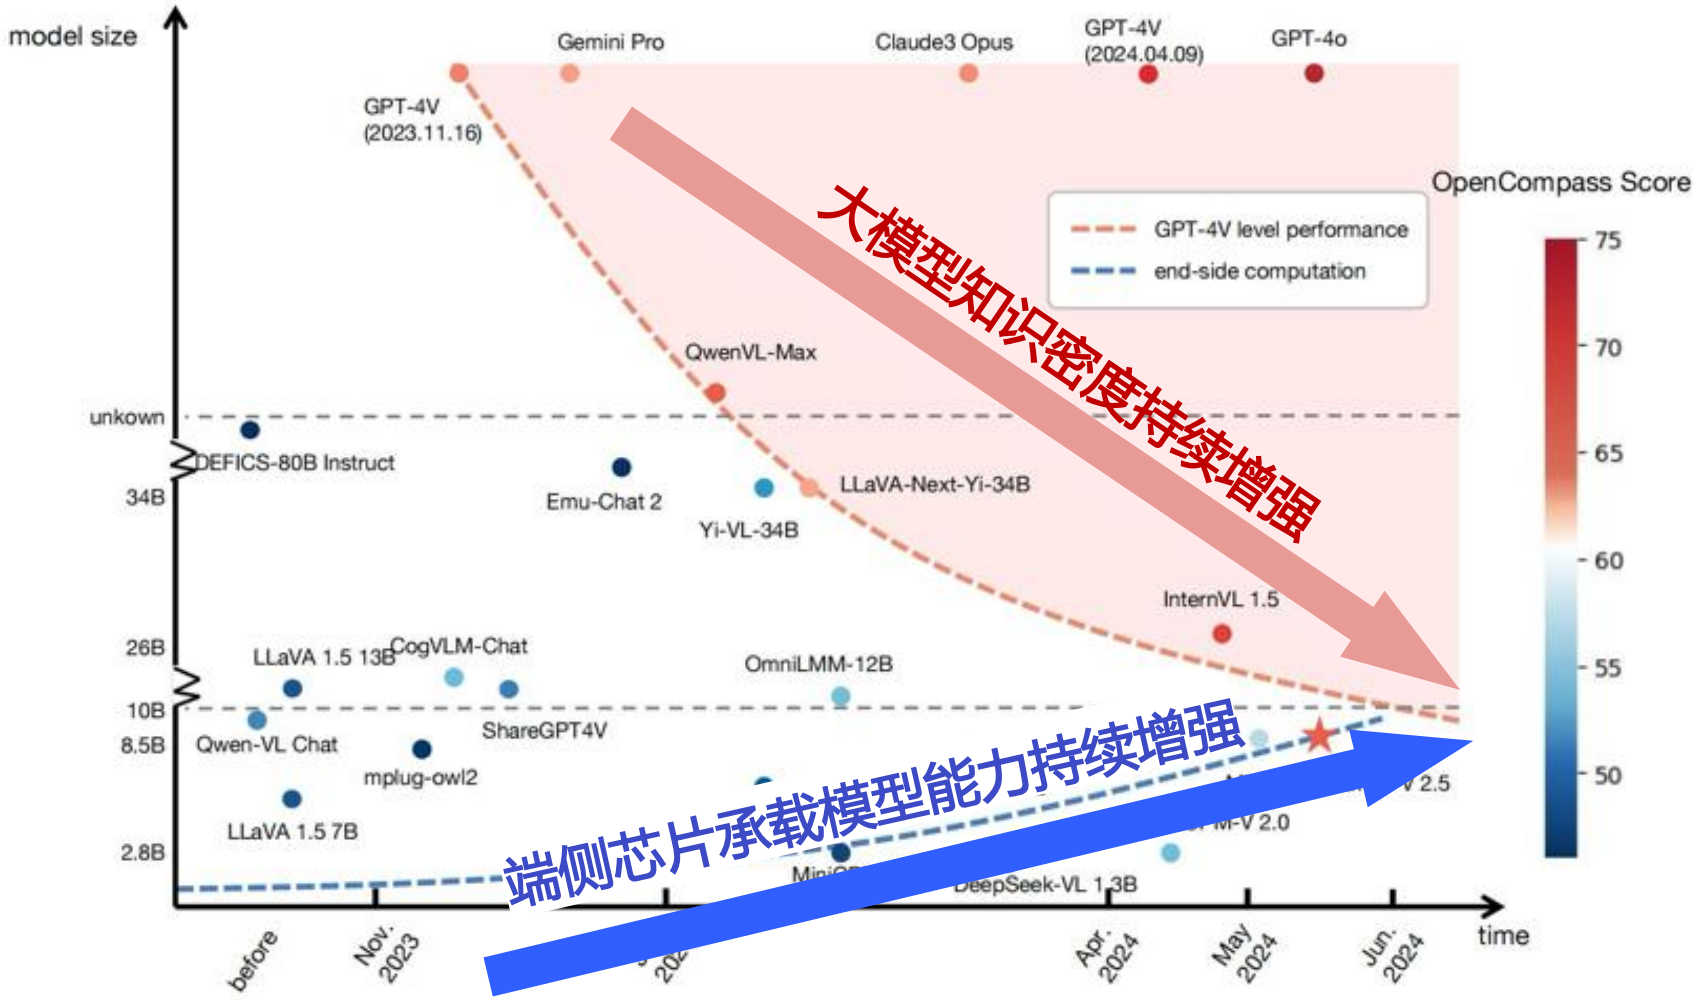


Iphone 18 pro 上 MiniCPM-V4.7

实测 ～20 tokens/s



模型知识密度增强揭示端侧智能巨大潜力



GOSIM

GOSIM Shenzhen 2026

端侧模型带来的技术价值思考



端侧智能的四象限：计算在哪里，价值在哪里

横轴看 AI 计算是否发生在端侧，纵轴看 产品价值是否深度嵌入物理环境

价值深度嵌入物理环境

计算在云端

计算在端侧

价值不嵌入物理环境

云端大脑

有物理感知与执行，但智能依赖网络，断网即失能

- 人工智能语音音箱
- 家用摄像头
- 遥操作机器人
- 初代拍照上传 AI 眼镜

端侧智能体

感知—决策—执行闭环在设备内完成，不依赖网络

- 端侧自主决策机器人
- 智能汽车座舱
- 实现本地推理的AI眼镜
- AI 辅助功能硬件

云服务终端

硬件是云服务的接入端，能力与寿命都在云上

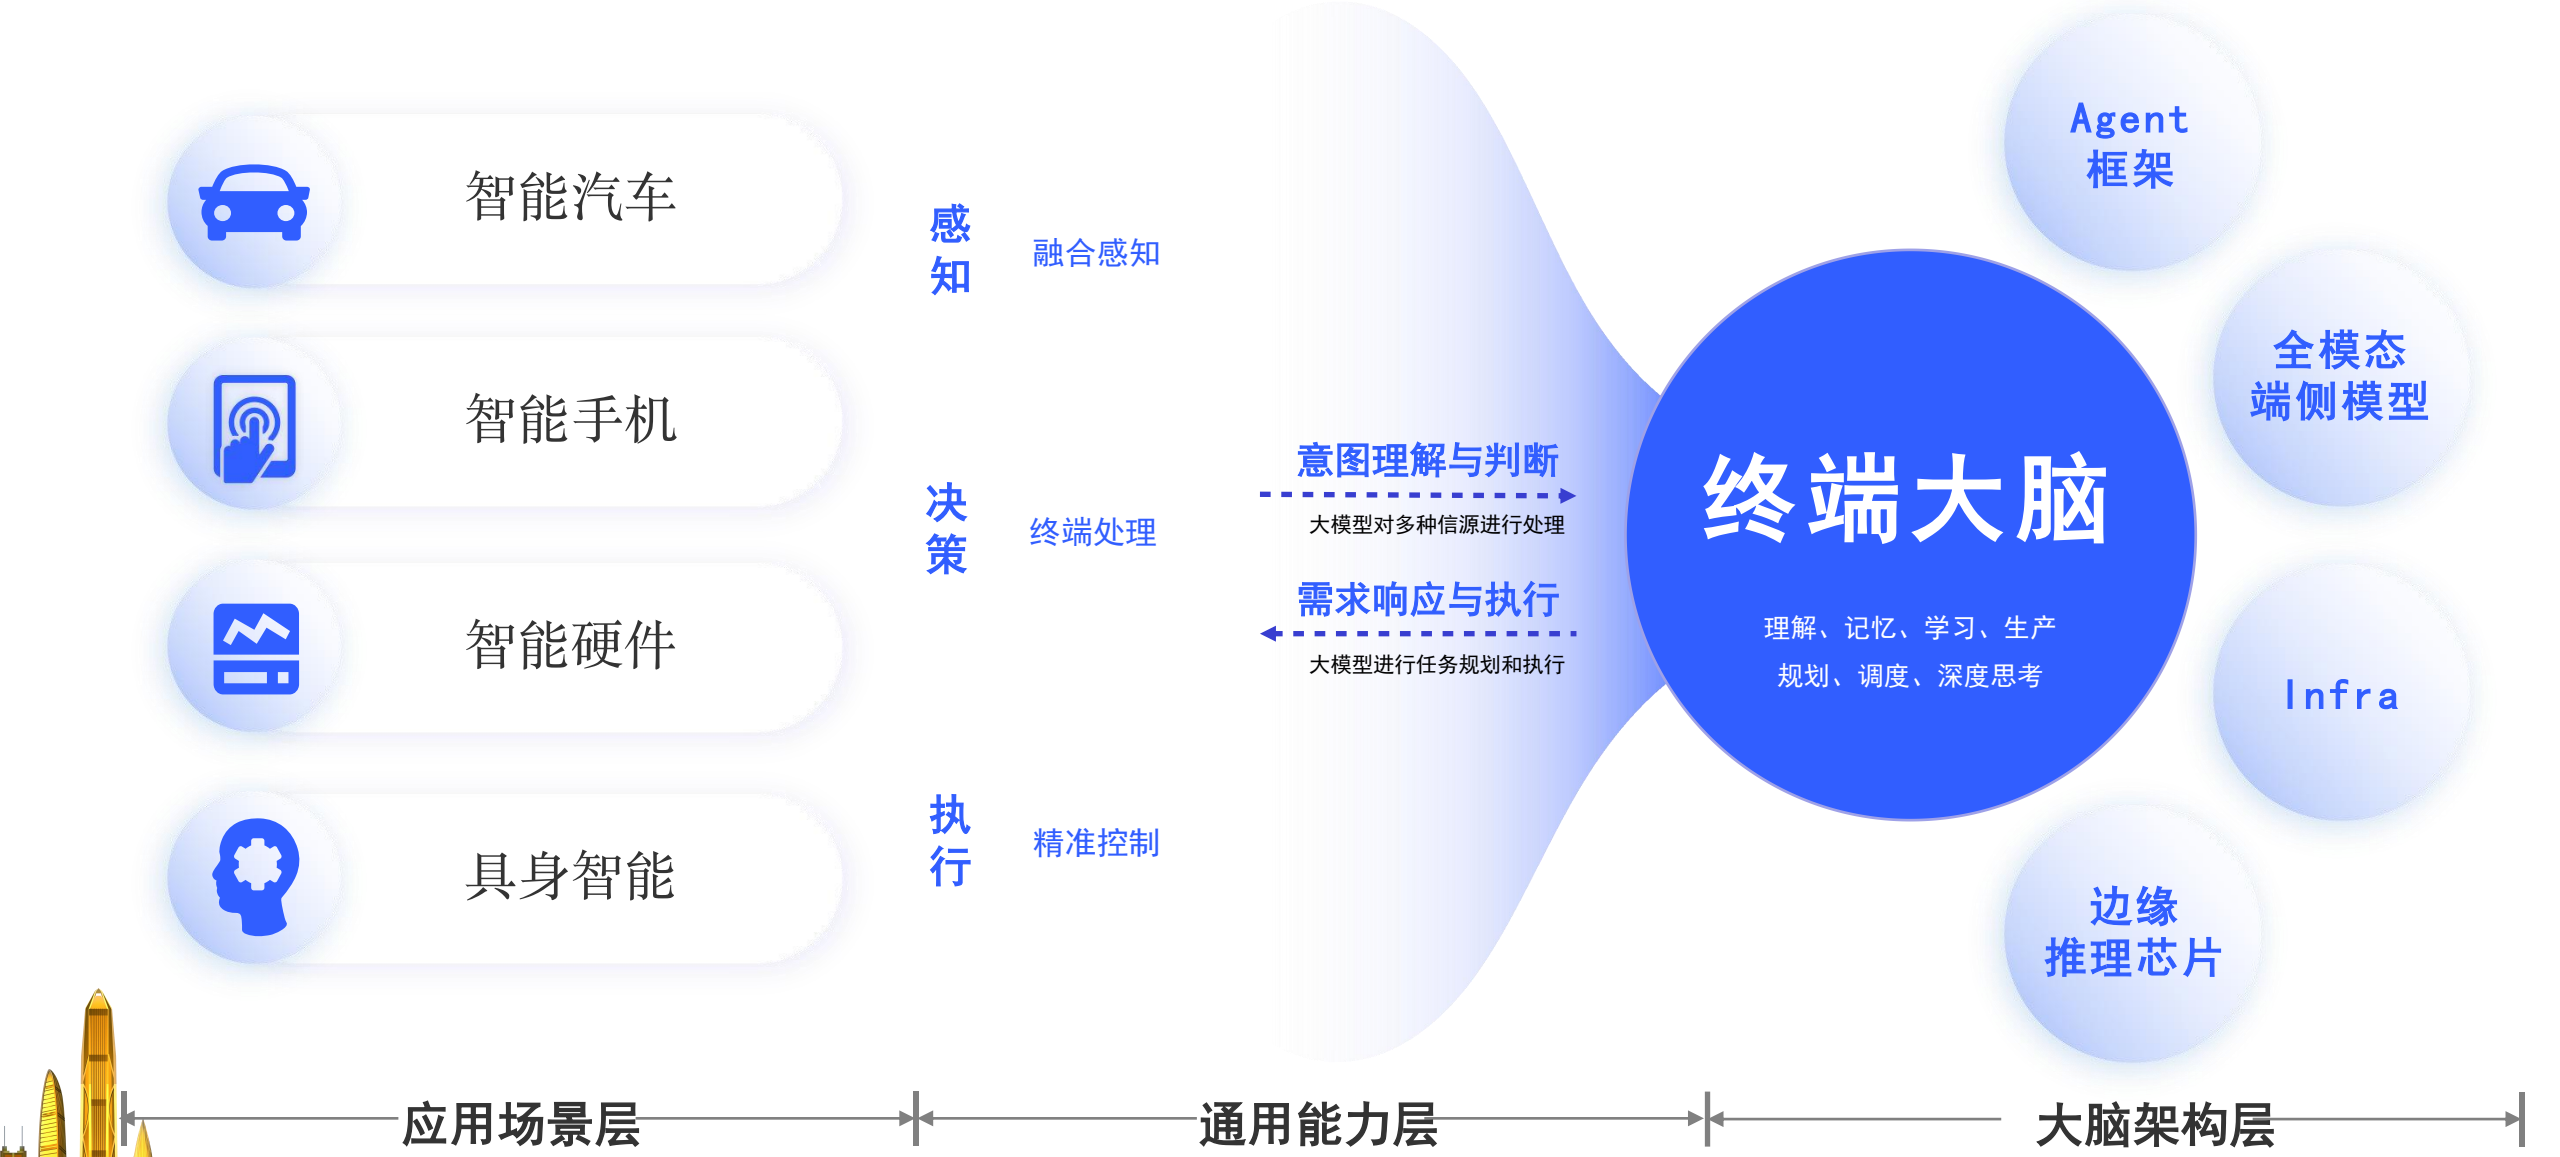
- 云电脑、云游戏机
- Rabbit R1
- AI 学习机
- 手机与 PC 上的 AI 助手 App

本地算力盒子

在本地跑模型，价值在隐私、离线与零边际成本

- 本地推理工作站
- NAS 与家庭服务器
- 端侧输入法、离线字幕
- 本地文档问答

以终为始：智能终端的通用大脑



让大模型更像人?

- 朴素的直觉
  - AGI至少应该达到人类水平 -> 多模态动态世界强交互能力
- Point1: Context and Bandwidth
  - 上下文越多，模型（越聪明）越有帮助
  - 传统交互模式带宽极窄，类似发邮件
  - 上下文 = 接管“用户”上下文 + 客观环境全息上下文
- Point2：The Bitter Lesson
  - 手工构建的系统会被基础模型的通用能力取代
  - For interactivity to scale with intelligence, it must be part of the model itself

MiniCPM-o 4.5：类人多模态感知交互

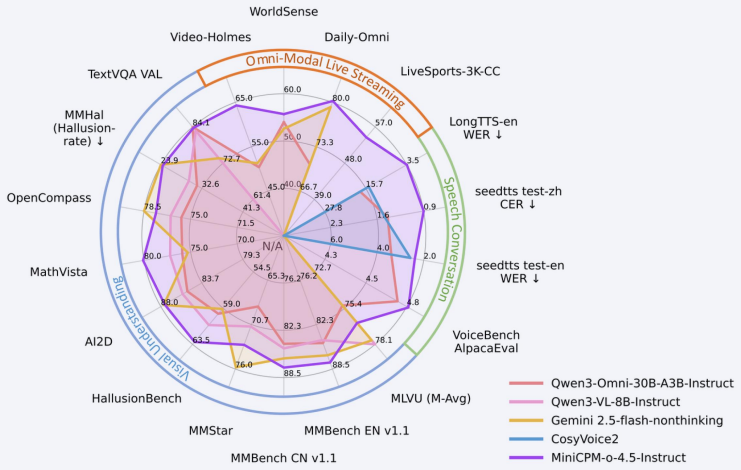
- 能力探索
  - 「边看-边听-主动说」的端到端全模态能力
  - 「即时自由对话」，弱化一问一答的轮次对话概念
  - 真人感语音对话能力

- 技术探索
  - 首个全双工全模态大模型
  - 全模态自主交互机制

- 基础能力
  - 9B参数量，全模态能力、视觉能力、语音能力同尺寸领先

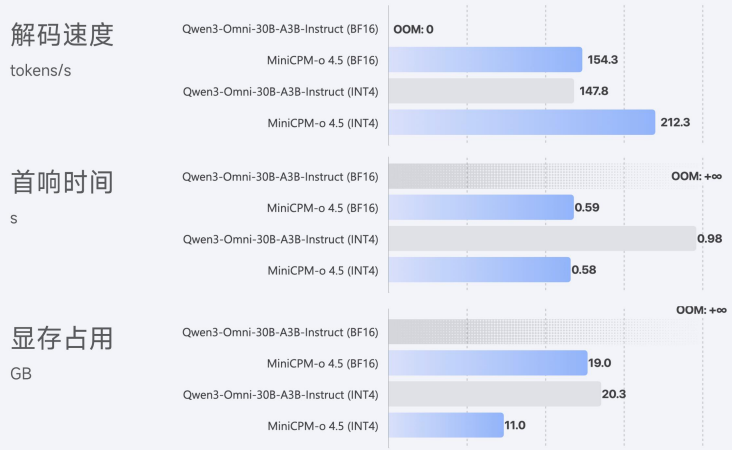


全模态六边形战士 「看听说」全面领先



高效低成本

多模态模型推理「极致」性价比



告别对讲机式死板交互 实现即时自由对话

全双工模型
根据动态变化实时反应
择机自主回答

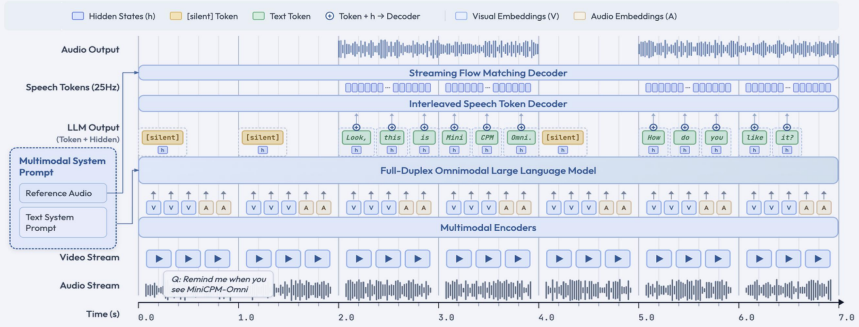
传统模型
只能死板
「一问一答」

摈弃传统 VAD 等外部工程化实现
语言模块持续监控输入的视频和音频流
以 1Hz 的最佳频率自动决策发言机会

首创端到端全双工架构 耳眼口并用 全模态全时感知

全双工模型
随时保持「看听」感知 输入输出不阻塞

单工模型
说完再看 说完再听



原生端到端全模态架构

毫秒内同步模态输入输出流

强大语音能力 带来情绪饱满、超拟人听感

- 支持英文、中文双语实时对话
- 支持少量样本语音克隆 性能超 CosyVoice2
- 音色、拟人度、声音表现力全面提升 全模态模型SOTA
- 支持自定义选择合适语气、音色
- 超长语音生成更稳定 音色统一、语气自然

Powered by MiniCPM-o 4.5



多模态大模型行业趋势

1. 全双工交互成为行业共识

技术路线从外置VAD+Turn-based收敛，转向 **模型自主决策交互节奏**，实现实时感知、自主回应与动态打断

2. 全模态能力与全双工加速融合

模型在连续多模态信息流中同步感知与输出，**“边看、边听、边说”**成为核心能力形态

3. 从「能说话」走向实时智能

前台感知交互+后台推理规划的双层架构，视觉流使助手 **持续理解环境并主动规划**

4. 端云协同支撑新一代智能终端

智能眼镜、耳机、座舱、机器人和伴随式助手，将成为 **全双工Omni的重要载体**；在行业场景中，它也将成为客服、销售、培训和业务工作的智能入口

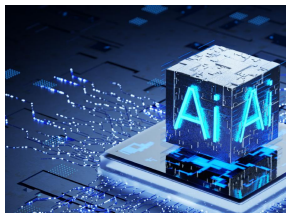
GOSIM

GOSIM Shenzhen 2026

端侧智能创新过程中的思考



商业模式问题：一次性买断 or 订阅付费?

商业模式	按量付费	免费获客	一次性买断
适用场景	水电、算力等基础设施	移动互联网应用 APP	硬件设备如汽车、家电、手机
用户体验	能省则省	有丰富的应用内引导消费	购买决策成本高使用黏性强
场景特性	资源导向的刚需性投资或消费	以用户注意力为核心的商业	以产品功能创新为更新驱动力
			

杰 文 斯 悖 论

随着技术进步提高资源利用效率，该资源的总消耗量反而会增加，而不是减少

端侧智能相对于云端的商业优势

用户侧

持续使用成本低

黏性强

厂商侧

功能设计不算力

天花板

场景选择问题：谁掌握定价权?



Labubu The Monsters 联名



Even Realities G2



MacBook Air M5

MiniCPM 系列模型受到开发者广泛支持

广泛适配于主流推理框架

vLLM · SGL · Xinference · OpenVINO · FlagOS · llama.cpp · Ollama

LM Studio · MNN · MLX · LLaMA-Factory (Easy and Efficient LLM Fine-Tuning) · swift (LLM training and deployment framework) · unsloth

广泛适配于主流芯片生态

intel · Ascend · NVIDIA · AMD · Qualcomm · MEDIATEK · Rockchip 瑞芯微电子

Cambricon 寒武纪科技 · 摩尔线程 MOORE THREADS · HYGON · METAX 沐曦 · 天数智芯 Iluvatar CoreX · 昆仑芯 KUNLUNXIN · T-HEAD · arm

GOSIM

GOSIM Shenzhen 2026

Thanks!



GOSIM

GOSIM Shenzhen 2026

Thanks!



GOSIM

GOSIM Shenzhen 2026

Thanks!

